

Python

10 giugno 2026

Indice

I	Linguaggio	15
1	Introduzione	17
1.1	Esecuzione	17
1.2	Ottenere aiuto	19
2	Dati	21
2.1	Introduzione	21
2.2	Tipi nativi	22
2.3	Classificazione dei tipi di base	23
2.4	Numeri	24
2.5	Date e ore	25
2.6	Sequenze: stringhe, liste e tuple	26
2.6.1	Operatore di slice (selezione da sequenza) e indici	26
2.6.2	Stringhe	28
2.6.2.1	Stringhe valide	28
2.6.2.2	Formattazione	28
2.6.2.3	Elaborazioni varie	30
2.6.2.4	Classe con formato	31
2.6.3	Liste	31
2.6.3.1	Definizione	32
2.6.3.2	Manipolazione e modifica	32
2.6.3.3	Metodi utili	32
2.6.3.4	Liste nested	33
2.6.3.5	List comprehensions	33
2.6.4	Tuple	35
2.6.5	Sequence unpacking	36
2.7	Classi mapping e set	36
2.7.1	Dict	36
2.7.1.1	Dict comprehension	37
2.7.2	Sets	37
2.7.2.1	Operatori/metodi utili	38
2.7.2.2	Set comprehension	39
2.8	Altri tipi utili	39
2.8.1	<code>namedtuple</code>	39
2.8.2	<code>Counter</code>	40
2.8.3	Enum & Flag	40
2.8.3.1	Enum	40
2.8.3.2	Flag	42

2.9	Type annotation	44
2.9.1	Sintassi	44
2.9.2	Checking	44
2.9.3	Tipi utilizzabili per variabili	45
2.9.4	Creazione di alias	46
2.9.5	Annotazione di funzioni	46
2.9.6	Annotazione di metodi in classi	47
3	Controllo del flusso	49
3.1	Costrutti condizionali: <code>if</code> e <code>while</code>	49
3.1.1	<code>if</code>	49
3.1.2	<code>match</code>	50
3.1.3	<code>while</code>	50
3.1.4	<code>break</code> , <code>continue</code> ed <code>else</code>	50
3.2	Condizioni e test logici	50
3.2.1	Test verità	50
3.2.2	Operatori booleani	51
3.2.3	Comparazioni	51
3.2.4	Comparazioni concatenate	52
3.2.5	Check appartenenza: <code>in</code> e <code>not in</code>	52
3.2.6	Comparare sequenze e altri tipi	52
3.3	Looping su oggetti: <code>for</code>	53
3.3.1	Looping in sequenze (stringhe, liste, tuple)	53
3.3.2	Looping nei dict	54
3.3.3	Looping sui set	54
3.3.4	L'utilizzo di <code>range</code>	54
4	Funzioni	57
4.1	Definizione	57
4.1.1	Argomenti	58
4.1.2	Stringa di documentazione	58
4.2	Chiamata	59
4.2.1	Valutazione dei valori di default	59
4.2.2	Valore ritornato	60
4.2.3	Liste/tuple/dict come parametri di chiamata	60
4.3	Regole di scope	61
4.3.1	Namespace	61
4.3.2	Attributi	61
4.3.3	Scoping	62
4.4	<code>lambda</code> e funzioni anonime	63
4.5	Programmazione funzionale	63
4.5.1	Funzioni classiche	64
4.5.1.1	<code>map</code> (= <code>Map/lappy</code>)	64
4.5.1.2	<code>itertools.starmap</code>	64
4.5.1.3	<code>functools.reduce</code>	65
4.5.1.4	<code>itertools.accumulate</code>	65
4.5.1.5	<code>filter</code>	65
4.5.2	Partialling	66
4.5.2.1	<code>functools.partial</code>	66
4.5.2.2	<code>functools.partialmethod</code>	66

4.5.3	Function factory	67
4.5.4	Composizione di funzioni	67
4.5.5	Decorators	68
4.5.5.1	Definizione e utilizzo	68
4.5.5.2	Decoratori già disponibili	69
4.5.5.3	Esempi di creazione/utlizzo di custom	69
4.5.6	Single e multiple dispatch	72
4.5.6.1	Single dispatch: <code>functools.singledispatch</code> e <code>functools.singledispatchmethod</code>	72
4.5.6.2	Multiple dispatch	73
4.6	Altri argomenti	75
4.6.1	<code>atexit</code>	75
5	Input/Output	77
5.1	File testuali	77
5.1.1	Testo semplice	77
5.1.1.1	Lettura	78
5.1.1.2	Scrittura	78
5.1.2	Formati tabulari (csv, tsv)	79
5.1.2.1	Lettura	79
5.1.2.2	Scrittura	79
5.1.3	JSON	79
5.1.3.1	Scrittura	80
5.1.3.2	Lettura	80
5.1.3.3	Formati custom	81
5.2	Formati binari	81
5.2.1	<code>pickle</code>	81
5.3	Accesso al filesystem	82
5.3.1	Ottenere/cambiare directory di lavoro	82
5.3.2	Listing di directory e glob files	82
5.3.3	Creazione/rimozione di file e directory	83
5.3.4	Manipolazione di path e metodi utili	83
5.3.5	Creazione filename temporaneo	85
5.3.6	Uso di file e directory temporanei	85
5.4	File di configurazione	86
5.5	Esecuzione di programmi esterni	86
5.6	Parsing opzioni da linea di comando	88
5.6.1	<code>sys.argv</code> e <code>sys.argv</code>	89
5.6.2	Modulo <code>argparse</code>	89
5.7	Accesso variabili d'ambiente	90
6	Object Oriented Programming	91
6.1	Classi	91
6.1.1	Definizione e scoping	91
6.1.2	Metodi	93
6.1.2.1	Definizione e chiamata	93
6.1.2.2	Costruttore custom	93
6.1.3	Condivisione dati	93
6.1.4	Data hiding	94
6.2	Ereditarietà	95

6.2.1	Singola	95
6.2.2	Multipia	95
6.3	Classi notevoli	96
6.3.1	<code>dataclass</code>	96
6.3.1.1	<code>field</code> : dati mutabili, valori default, parametri	96
6.3.1.2	Eseguire codice post inizializzazione: <code>post_init</code>	97
6.3.1.3	Freezing di una <code>dataclass</code>	98
6.3.1.4	Altri parametri utili del decoratore	98
6.3.2	Iteratori	98
6.3.2.1	Funzionamento	99
6.3.2.2	Implementazione mediante classe	100
6.3.2.3	Implementazione mediante espressioni generatrici	101
6.3.2.4	Implementazione mediante generatori	101
6.3.2.5	Funzioni e operatori utili su iteratori	102
6.3.2.6	Il modulo <code>itertools</code>	103
6.3.3	Context Managers	105
6.3.3.1	Implementazione mediante classe	105
6.3.3.2	Implementazione mediante generatore	105
7	Eccezioni	107
7.1	Gestire eccezioni	107
7.1.1	Sintassi minimale: <code>try except</code>	107
7.1.2	<code>else</code>	109
7.1.3	<code>finally</code>	109
7.2	Sollevare eccezioni	109
7.3	Creare eccezioni custom	111
7.4	Sollevare warnings senza stoppare l'esecuzione	111
8	Debugging	113
8.1	Debugging	113
9	Testing	115
9.1	Introduzione e concetti	115
9.1.1	Tipologie di testing	115
9.1.2	Test driven development	116
9.2	<code>unittest</code>	116
9.2.1	Test del valore ritornato	116
9.2.2	Test eccezioni	118
9.2.3	Test fixtures	119
10	Espressioni regolari	121
11	Moduli e pacchetti	125
11.1	Introduzione	125
11.2	Moduli	126
11.2.1	Nome e namespace	126
11.2.2	Importazione dei moduli	126
11.2.3	Path di ricerca dei moduli	127
11.2.4	Templates	127
11.2.4.1	Modulo libreria	127

11.2.4.2	Script della libreria	128
11.3	Pacchetti	129
11.3.1	Struttura e <code>__init__.py</code>	129
11.3.1.1	Struttura semplice	129
11.3.1.2	Struttura con subpackages	129
11.3.2	<code>__init__.py</code> , <code>__all__</code> e <code>import *</code> da pacchetto	131
11.4	Packaging e distribuzione di pacchetti	131
11.4.1	Flow	131
11.4.2	<code>pyproject.toml</code>	131
11.4.3	Aggiornamento toolchain	132
11.4.4	Creazione del tree del pacchetto	132
11.4.5	Installare un pacchetto in modalità devel	132
11.4.6	Build di sdist e wheel	132
11.4.7	Upload a pypi	132
11.5	Altre utilità	133
11.5.1	Inserimento di script nel pacchetto	133
11.5.2	Documentazione	133
11.5.2.1	Setup	133
11.5.2.2	Doc-writing e reStructuredText	133
11.5.2.3	Building	134
11.5.2.4	Setup di readthedocs	135
11.5.3	Testing	135
11.5.4	Timing/temporizzazione	136
11.5.5	Profiling	136
11.5.5.1	Tempo	136
11.5.5.2	Memoria	136
12	Logging	137
12.1	Uso del logger di default	137
12.1.1	Setup	137
12.2	Logger custom	139
12.2.1	Setup degli handler	139
12.2.2	Impostare la formattazione di un handler	139
12.2.3	impostare livello di log generale e di un handler	140
12.2.4	Filtrare log	140
13	Tools	143
13.1	uv	143
II	Scientific Stack	145
14	Numpy	147
14.1	L'ndarray	148
14.1.1	Creazione e copia	148
14.1.2	Tipi (<code>dtype</code>): coercizione e testing	149
14.1.3	Forma, dimensioni e reshape	150
14.1.3.1	Forma e dimensioni	150
14.1.3.2	Reshaping	151
14.1.3.3	Ravelling/flattening	151

14.2	Indexing	152
14.2.1	Array unidimensionali	152
14.2.2	Array multidimensionali	153
14.2.3	Subarray come viste vs copie	156
14.2.4	Assegnazione e unicità degli indici	157
14.3	Elaborazioni di array	157
14.3.1	Inserimento/rimozione elementi (<code>insert</code> , <code>delete</code>)	157
14.3.2	Aritmetica vettorizzata	157
14.3.3	Operazioni insiemistiche	158
14.3.4	Concatenazione (<code>concatenate</code> , <code>vstack</code> , <code>hstack</code>)	158
14.3.5	Splitting (<code>split</code> , <code>vsplit</code> , <code>hsplit</code>)	159
14.3.6	Ripetizione/binding (<code>repeat</code> , <code>tile</code>)	160
14.3.7	Sorting/ordine (<code>sort</code> , <code>argsort</code>)	161
14.4	Universal functions	162
14.4.1	Introduzione	162
14.4.2	Metodi delle ufunction (<code>reduce</code> , <code>accumulate</code> , <code>outer</code>)	162
14.4.3	Creazione di ufunctions	164
14.5	Broadcasting	165
14.6	Altri argomenti	169
14.6.1	Lavorare con booleani	169
14.6.2	Array di stringhe	170
15	Pandas	173
15.1	Data I/O	174
15.1.1	Importazione dati	174
15.1.2	Importazione con dati mancanti	175
15.1.3	Esportazione	175
15.2	Series	175
15.2.1	Creazione	175
15.2.2	Contenuto (<code>array</code> , <code>index</code> , <code>name</code> , <code>dtype</code>)	176
15.2.3	Indexing e selezione	176
15.2.3.1	Utilizzo di <code>[]</code>	176
15.2.3.2	<code>.iloc</code>	177
15.2.3.3	<code>.loc</code>	177
15.2.3.4	Altri metodi di selezione (<code>.filter</code> , <code>.reindex</code>)	178
15.2.4	Modifica valori	178
15.2.5	Funzionalità per indici (<code>reset_index</code> , <code>rename</code>)	178
15.2.6	Rimozione elementi (selezione, <code>drop</code> , <code>del</code>)	179
15.2.7	Elaborazione vettorizzata	179
15.2.8	Elaborazione allineata	180
15.2.9	Coercizione di tipo (<code>astype</code>)	180
15.2.10	Valori condizionali a-la <code>ifelse</code> (<code>.where</code>)	180
15.2.11	Applicazione di una funzione (<code>map</code>)	180
15.2.12	Applicazione di più funzioni (<code>.agg</code>)	181
15.2.13	Sostituzione (<code>replace</code>) o recode (<code>map</code>)	181
15.2.14	Test di appartenenza (<code>in</code> , <code>isin</code>)	181
15.2.15	Dati mancanti	182
15.2.16	Duplicati	182
15.2.17	Sorting	182
15.2.18	Discretizzazione/creazione di classi (<code>cut</code> , <code>qcut</code>)	183

15.2.19	Dummy variables	184
15.2.19.1	Utilizzo base (<code>get_dummies</code>)	184
15.2.19.2	Variabili a risposta multipla (<code>str.get_dummies</code>)	184
15.2.20	Stringhe	184
15.2.20.1	Paste	184
15.2.20.2	Collapse	185
15.2.20.3	Formattazione varia	185
15.2.20.4	Lunghezza ed sottostringhe	186
15.2.20.5	Splitting	186
15.2.20.6	Ricerca/rimpiazzo	186
15.2.21	Date/ore	187
15.2.21.1	Parsing da stringa	187
15.2.21.2	Creazione da componenti	188
15.2.21.3	Estrazione componenti	188
15.2.21.4	Esportazione a stringa	189
15.2.21.5	Conversione di tipo/arrotondamenti	189
15.2.21.6	Intervalli di tempo	190
15.2.22	Dati categorici (<code>Categorical</code>)	190
15.2.23	Indexing gerarchico e reshape	192
15.2.23.1	Definizione	192
15.2.23.2	Indexing	193
15.2.23.3	Reshape	193
15.3	<code>DataFrame</code>	194
15.3.1	Creazione	194
15.3.2	Contenuto (<code>info</code> , <code>shape</code> , <code>index</code> , <code>columns</code> , <code>values</code> , <code>name</code>)	195
15.3.3	Selezione	196
15.3.3.1	Uso di <code>[]</code>	196
15.3.3.2	Uso di <code>.loc</code> e <code>.iloc</code>	197
15.3.3.3	<code>query</code> per selezione righe	200
15.3.3.4	Selezione di colonne sulla base di tipo	201
15.3.3.5	Accesso a singoli numeri: <code>.at</code> , <code>.iat</code>	201
15.3.4	Modifica valori	202
15.3.5	Aggiunta di colonne	202
15.3.5.1	Assegnazione	202
15.3.5.2	Uso di <code>insert</code>	203
15.3.5.3	Uso di <code>assign</code>	203
15.3.6	Rimozione righe/colonne (<code>drop</code> , <code>del</code>)	204
15.3.7	Rinominare colonne/indici (<code>rename</code>)	205
15.3.8	Gestione indici	205
15.3.8.1	Creazione indici da colonne	205
15.3.8.2	Reset indici	206
15.3.8.3	<code>MultiIndex</code>	206
15.3.9	Elaborazione allineata	207
15.3.10	Coercizione di tipi (<code>astype</code>)	208
15.3.11	Applicazione di funzioni	208
15.3.11.1	A molteplici righe/colonne (<code>apply/agg</code>)	208
15.3.11.2	A ciascun elemento del <code>DataFrame</code> (<code>map</code>)	209
15.3.11.3	All'intero dataframe (<code>pipe</code>)	210
15.3.12	Ciclo su righe/colonne	210
15.3.12.1	Righe	210

15.3.12.2	Colonne	211
15.3.13	Merge	212
15.3.13.1	Due dataframe	212
15.3.13.2	Molteplici dataframe	213
15.3.14	Binding (<code>pd.concat</code>)	214
15.3.14.1	Di riga	214
15.3.14.2	Di colonna	214
15.3.15	Reshape	215
15.3.15.1	Uso di <code>lb.r.reshape</code>	215
15.3.15.2	Porre in long (<code>melt</code>)	216
15.3.15.3	Porre in wide (<code>pivot</code>)	217
15.3.16	Test di appartenenza (<code>in</code> , <code>isin</code>)	217
15.3.17	Dati mancanti	218
15.3.17.1	Identificazione	218
15.3.17.2	Rimozione	219
15.3.17.3	Imputazione	219
15.3.18	Duplicati	220
15.3.18.1	Identificazione (<code>duplicated</code>)	220
15.3.18.2	Rimozione (<code>drop_duplicates</code>)	221
15.3.18.3	Indici duplicati	221
15.3.19	Sorting	221
15.3.19.1	Su valori (<code>sort_values</code>)	221
15.3.19.2	Su indici (<code>csort_index</code>)	222
15.4	Cookbook	222
15.4.1	Stampa tutto il contenuto di un DataFrame	222
15.4.2	Old stuff	223
15.4.2.1	Reindexing (<code>reindex</code> , <code>loc</code>)	223
15.4.2.2	Applicare diverse funzioni a diversi elementi	223
15.4.2.3	Reshape sulla base di indici (<code>stack</code> , <code>unstack</code>)	224
16	Matplotlib	227
16.1	Introduzione	228
16.2	Salvataggio figura	230
16.3	Impostazione layout figura ed esempi	230
16.3.1	Layout standard	230
16.3.2	Layout custom	232
16.4	Fine tuning	234
16.4.1	Ticks e subticks	234
16.4.2	Spines e grid	237
16.4.3	Gestire la sovrapposizione di elementi diversi (<code>zorder</code>)	238
16.4.4	Legenda	239
16.4.5	Plot con doppio asse delle y	245
16.4.6	Padding dei subplots (spazio bianco bordi)	245
16.5	Configurazioni	246
16.5.1	Ottenimento e modifica	246
16.5.2	Ripristino impostazioni default	247
16.5.3	Cambiare stile	247
16.6	Grafici utili	247
16.6.1	Linee	248
16.6.2	Diagramma a barre	248

16.6.3	Istogramma	249
16.6.4	Scatterplot	249
16.6.5	Matrice di scatterplot	252
16.6.6	Boxplot	252
16.6.7	Correlation matrix	255

III Cookbook 257

17 Algebra lineare 259

17.1	Vettori, matrici e dimensioni	259
17.1.1	Creazione	259
17.1.2	Funzioni utilità per creazione	260
17.2	Operazioni	261
17.2.1	Somma	261
17.2.2	Trasposizione	261
17.2.3	Prodotti	262
17.3	Misc	263

18 Statistica descrittiva 265

18.1	Info generali	266
18.2	Univariate	266
18.2.1	Statistiche varie	266
18.3	Bivariate	267
18.3.1	Tabelle di contingenza	267
18.3.2	Covarianza e correlazione	268
18.3.3	Tabelle pivot	268
18.3.4	Tabella trial	270
18.3.5	Stratificate	270
18.3.5.1	Splitting	271
18.3.5.2	Convertire indici di grouping in variabili	273
18.3.5.3	Memorizzare in un dict lo split	274
18.3.5.4	Iterazione sui gruppi	274
18.3.5.5	Scelta delle variabili di analisi	275
18.3.5.6	Applicare funzioni di aggregazione custom	275
18.3.5.7	Elaborazioni custom	276
18.3.5.8	Trasformazioni group-wise	277

19 Probabilità e simulazione 281

19.1	Funzionalità native	281
19.1.1	Combinatoria	281
19.1.2	Numeri casuali (<code>random</code>)	282
19.2	Numeri casuali (<code>numpy</code>)	283
19.2.1	Creazione del generatore	283
19.3	Variabili casuali (<code>scipy.stats</code>)	285
19.3.1	Funzioni e parametri principali	285
19.3.2	Uso interattivo rapido	285
19.3.3	Freezing di una distribuzione	286
19.3.4	Uso del generatore di <code>numpy</code>	286
19.4	Altri argomenti	286

19.4.1	Bootstrap CI	286
20	Test statistici	289
20.1	Setup	290
20.2	Medie	290
20.2.1	Test t: 1 gruppo vs valore teorico	290
20.2.2	Test t: 2 gruppi indipendenti	290
20.2.3	Anova (2+ gruppi indipendenti)	290
20.2.4	Test t: 2 gruppi appaiati	291
20.2.5	Anova per misure ripetute (2+ gruppi appaiati)	291
20.3	Non parametric	292
20.3.1	Wilcoxon	292
20.3.2	Mann Whitney	292
20.3.3	Kruskal Wallis	292
20.3.4	Friedman test	292
20.4	Proporzioni	293
20.4.1	Test binomiale e CI clopper pearson	293
20.4.2	Test di Fisher	293
20.4.3	Chisquare	294
20.4.4	McNemar	294
20.4.5	Q di Cochran	294
20.5	Tassi	295
20.5.1	Comparazione 2 tassi	295
20.6	Correlazione	295
20.6.1	Pearson	295
20.6.2	Spearman	295
20.6.3	Tests	295
20.7	Varianze	295
20.7.1	Test di Bartlett	296
20.7.2	Test di Levene	296
20.7.3	Test di Fligner	296
20.8	Sopravvivenza	296
20.8.1	Logrank test	296
20.9	Agreement	297
20.9.1	Cohen's K	297
20.9.2	Fleiss K	297
20.9.3	Lin coefficient	297
20.10	Reliability/consistency	297
20.10.1	Cronbach α	297
20.10.2	ICC	297
20.11	Multiplicity	297
20.12	Test simulativi	298
21	Integrazione con R	299
21.1	Interscambio dataset	299
21.1.1	Da R a Python	299
21.1.2	Da Python a R	300
21.2	Chiamare R da Python: rpy2	300
21.2.1	Importazione di pacchetti	300
21.2.2	Ottenimento di dati con rpy2	300

21.2.3	Valutare stringhe di R	301
21.2.4	Creazione di vettori	301
21.2.5	Conversione <code>DataFrame</code> a R	301
21.2.6	Utilizzo di funzioni	302
22	Misc cookbook	303
22.1	Validazione <code>DataFrame</code> con <code>pandera</code>	303
22.2	SymPy	305
22.3	Esecuzione parallela	305
22.4	Calendario	306
22.5	Tcl/Tk	307
22.6	Telegram	307

Parte I

Linguaggio

Capitolo 1

Introduzione

Contents

1.1	Esecuzione	17
1.2	Ottenere aiuto	19

1.1 Esecuzione

Vi sono due modi per utilizzare l'interprete classico:

- in via batch, alternativamente:
 - creando un file con estensione `.py`, che contenga istruzioni python valide a seconda della versione, ed eseguendolo attraverso `python file.py`
 - creando un file senza estensione con le seguenti sha-bang, dargli i permessi di esecuzione e porlo nel path degli eseguibili

```
#!/usr/bin/env python
#!/usr/bin/env python3
```
- in modalità interattiva:
 - entrando nell'interprete mediante `python` o `python3`
 - editando un file `.py` in Emacs, questi va in `python-mode`. Far partire un processo python in un buffer con `C-c C-p` e passando all'interprete i comandi descritti in tabella 1.1.

Sequenza	Comando	Descrizione
C-c C-r	<code>python-shell-send-region</code>	invia la regione selezionata
C-c C-e	<code>python-shell-send-statement</code>	manda la regione selezionata o lo statement della linea
C-c C-s	<code>python-shell-send-string</code>	invia una riga da specificare
C-c C-c	<code>python-shell-send-buffer</code>	invia tutto il buffer corrente
C-c C-l	<code>python-shell-send-file</code>	tipo <code>source</code> di bash
C-c C-d	<code>python-describe-at-point</code>	descrivi la cosa
C-c C-v	<code>python-check</code>	usa qualche tester da impostare con <code>python-check-command</code>
C-c C-t c	<code>python-skeleton-class</code>	introduci una classe da template
C-c C-t d	<code>python-skeleton-def</code>	introduci una funzione da template
C-c C-t f	<code>python-skeleton-for</code>	introduci un for da template
C-c C-t i	<code>python-skeleton-if</code>	introduci un if da template
C-c C-t m	<code>python-skeleton-import</code>	introduci un import da template
C-c C-t t	<code>python-skeleton-try</code>	introduci un try da template
C-c C-t w	<code>python-skeleton-while</code>	introduci un while da template
C-c <	<code>python-indent-shift-left</code>	indenta a sinistra
C-c >	<code>python-indent-shift-right</code>	indenta a destra

Tabella 1.1: Comandi `python-mode` di emacs

1.2 Ottenere aiuto

`help` fa uso di docstring e si usa alternativamente come

```
help()          # help di sistema (moduli, keyword, simboli, topics)
help(oggetto)   # help specifico di un oggetto - docstring
```

Si può accedere alla documentazione anche dalla shell mediante `pydoc`

```
pydoc nome      # equivale a help(nome) dall'interprete
```


Capitolo 2

Dati

Contents

2.1	Introduzione	21
2.2	Tipi nativi	22
2.3	Classificazione dei tipi di base	23
2.4	Numeri	24
2.5	Date e ore	25
2.6	Sequenze: stringhe, liste e tuple	26
2.6.1	Operatore di slice (selezione da sequenza) e indici . .	26
2.6.2	Stringhe	28
2.6.3	Liste	31
2.6.4	Tuple	35
2.6.5	Sequence unpacking	36
2.7	Classi mapping e set	36
2.7.1	Dict	36
2.7.2	Sets	37
2.8	Altri tipi utili	39
2.8.1	namedtuple	39
2.8.2	Counter	40
2.8.3	Enum & Flag	40
2.9	Type annotation	44
2.9.1	Sintassi	44
2.9.2	Checking	44
2.9.3	Tipi utilizzabili per variabili	45
2.9.4	Creazione di alias	46
2.9.5	Annotazione di funzioni	46
2.9.6	Annotazione di metodi in classi	47

2.1 Introduzione

Assegnazione Gli oggetti del linguaggio vengono creati mediante l'**assegnazione**, che avviene attraverso l'uso di `=`, e non vi è necessità di dichiarare precedentemente il tipo della variabile (dinamically typed):

```
message = 'Hi friend'
pi = 3.1415926535897932
```

Keyword linguaggio I nomi non utilizzabili come identificatori sono:

and	del	from	not	while
as	elif	global	or	with
assert	else	if	pass	yield
break	except	import	print	
class	in	raise	nonlocal	
continue	finally	is	return	
def	for	lambda	try	

Eliminazione oggetti La rimozione del binding ad aree di memoria (pre intervento del garbage collector) avviene mediante la keyword `del`

```
a = 1
del a
```

Operazioni su oggetti Di ogni oggetto è possibile:

- conoscere la **classe di appartenenza** mediante `type` o `isinstance`

```
>>> type(1)
<class 'int'>
>>> isinstance(1, int)
True
```

- **listare dati e metodi disponibili** (ai quali si accede mediante l'operatore punto), derivanti dalla classe di appartenenza mediante `dir`

```
>>> dir(1)
['__abs__', '__add__', '__and__', '__bool__', '__ceil__', '__class__', '__delattr__',
```

- ottenere un **identificatore univoco** (della singola istanziazione), ottenuto mediante la funzione `id` applicata all'oggetto (questa non restituisce altro che l'indirizzo in memoria dell'oggetto)

```
>>> a = 1
>>> id(a)
10738416
```

2.2 Tipi nativi

I tipi più di base che il python mette a disposizione sono:

- **bool**: variabili booleane come `True` o `False`
- **int**: gli interi
- **float**: numeri con virgola mobile
- **str**: stringhe di caratteri unicode (non modificabili) compresi tra virgolette

- **bytes**: per la manipolazione di binario

A partire da questi tipi di base si possono creare oggetti composti tra i quali:

- **set**: insiemi di elementi non ordinati
- **list** sono sequenze ordinate e modificabili di elementi
- **tuple** sono sequenze ordinate e non modificabili di elementi
- **dict**: sono array coppie chiave - valore

Infine altri tipi builtin (che servono soprattutto nell'ottica della programmazione) sono:

- **type**: la classe di un oggetto è essa stessa un oggetto di classe **type**
- **None**: serve per indicare un valore vuoto ed ha classe **NoneType**. Non presenta attributi.
- funzioni
- classi
- moduli

Il nome del singolo tipo (ad esempio **int**) serve generalmente, se utilizzato come funzione¹, per **coercire da un tipo all'altro**:

```
>>> int(1.1)
1
>>> float(1)
1.0
>>> str(123)
'123'
```

2.3 Classificazione dei tipi di base

I tipi di base possono essere classificati a seconda di:

- **storage** model: quanti oggetti base possono essere contenuti in un oggetto? in base a questo distinguiamo
 - *oggetti scalari*: contengono un singolo oggetto base
 - *oggetti container*: contengono molteplici oggetti singoli. Il fatto che contengano molteplici oggetti pone poi che questi debbano essere o meno della stessa tipologia. In python tutti i tipi container base possono esser formati da oggetti base di tipo diverso.
- **update** model: una volta creato l'oggetto può esser modificato? Distinguiamo oggetti *mutabili* e *immutabili*
- **access** model: come si accede ad un singolo elemento facente parte dell'oggetto? distinguiamo

¹Questo perchè il nome di una classe usato come funzione, serve come costruttore.

Data type	Storage	Update	Access
Numbers	Scalar	Immutable	Direct
Strings	Scalar	Immutable	Sequence
Lists	Container	Mutable	Sequence
Tuples	Container	Immutable	Sequence
Dictionaries	Container	Mutable	Mapping

Tabella 2.1: Classificazione dei tipi

- accesso *direct*: caratteristico di alcuni oggetti atomici per i quali non si pone problemi di accesso particolare
- accesso *sequence*: accesso mediante indice numerico
- accesso *mapping*: accesso mediante key alfanumerica

Tabella 2.1 sintetizza la classificazione seguendo i criteri presentati.

2.4 Numeri

Vi sono tre tipi numerici: interi, floating point e complessi; i booleani sono un sottotipo di intero. Tutti i tipi numerici ad eccezione dei complessi supportano le seguenti operazioni, le quali hanno maggior priorità che gli operatori di comparazione

```

x + y      somma
x - y      differenza
x * y      prodotto
x / y      quoziente
x // y     parte intera della divisione
x % y      resto della divisione
divmod(x, y) la coppia (x // y, x % y)
x ** y     elevamento a potenza
pow(x, y)  elevamento a potenza
abs(x)     valore assoluto
int(x)     x convertito a intero
float(x)   x convertito a virgola mobile
complex(re, im) numero complesso con re parte reale e im immaginaria
c.conjugate() conjugate of the complex number c

```

int e float supportano

```

math.trunc(x)      parte intera
round(x[, n])      x arrotondato a n digits (se omissso default a 0)
math.floor(x)      maggiore intero <= x
math.ceil(x)       minor intero >= x

```

Infine l'unico metodo che sembra veramente utile per i float è `is_integer` (gli int non hanno metodi di interesse soprattutto in ambito reale)

```

>>> f1 = 2.0
>>> f1.is_integer()

```


True

```
>>> f2 = 1.2
>>> f2.is_integer()
False
```

Per operazioni aggiungive vedere i moduli `math` e `cmath`

2.5 Date e ore

il modulo `datetime` mette a disposizione le classi di base per date, ore, dateore etc

```
>>> import datetime as dt

>>> # definire date/ore
>>> birth = dt.date(1983, 11, 4) # year, month, day
>>> birth_time = dt.time(15, 50, 37) # hour, minute, second
>>> birth_dt = dt.datetime(1983, 11, 4, 15, 50, 37) # tutto

>>> # parsing/importazione da stringhe
>>> dt.datetime.strptime("11/11/2011", "%d/%m/%Y") # custom
datetime.datetime(2011, 11, 11, 0, 0)
>>> dt.datetime.strptime("11/11/2011 12:12:12", "%d/%m/%Y %H:%M:%S") # custom
datetime.datetime(2011, 11, 11, 12, 12, 12)
>>> dt.date.fromisoformat('2019-12-04') # iso
datetime.date(2019, 12, 4)
>>> dt.datetime.fromisoformat('2011-11-04T00:05:23') # iso
datetime.datetime(2011, 11, 4, 0, 5, 23)

>>> # oggi/ora
>>> oggi = dt.date.today() # oggi: data
>>> ora = dt.datetime.now() # adesso: datetime

>>> # accesso a singoli elementi
>>> [birth.year, birth.month, birth.day]
[1983, 11, 4]
>>> [birth_time.hour, birth_time.minute, birth_time.second]
[15, 50, 37]
>>> [birth_dt.year, birth_dt.month, birth_dt.day,
...  birth_dt.hour, birth_dt.minute, birth_dt.second]
[1983, 11, 4, 15, 50, 37]

>>> # convertire datetime in date
>>> ora.date()
datetime.date(2026, 6, 10)

>>> # differenze di date
>>> diff = oggi - birth
>>> diff
datetime.timedelta(days=15559)
```

```

>>> diff.days / 365.25
42.59822039698837

>>> # differenza di tempi
>>> a = dt.datetime(2000, 11, 11, 2, 50, 30)
>>> b = dt.datetime(2001, 11, 13, 2, 50, 0)
>>> diff_t = b - a
>>> diff_t
datetime.timedelta(days=366, seconds=86370)
>>> diff_t.total_seconds() # secondi di differenza totali
31708770.0

>>> # far scorrere il tempo
>>> un_giorno = dt.timedelta(days = 1)
>>> ieri = oggi - un_giorno
>>> ieri
datetime.date(2026, 6, 9)
>>> domani = oggi + un_giorno
>>> domani
datetime.date(2026, 6, 11)

>>> # esportazione/formattazione a stringa
>>> ora.strftime("%d-%m-%Y") # custom
'10-06-2026'
>>> ora.strftime("%d-%m-%Y - %H:%M:%S") # custom
'10-06-2026 - 07:51:05'
>>> oggi.isoformat() # iso
'2026-06-10'
>>> ora.isoformat() # iso
'2026-06-10T07:51:05.306189'

```

2.6 Sequenze: stringhe, liste e tuple

Introduciamo prima gli operatori e le funzioni builtin che funzionano con tutte le sequenze per affrontare le peculiarità di ognuna in sezione separata.

Gli operatori presentati in tabella 2.2 si applicano a tutte le sequenze. Altre funzioni di utilità per tutte le sequenze² sono quelle di tabella 2.3 Agli iterabili (di cui le sequenze fanno parte) si possono applicare le funzioni di tabella 2.4 per coercirli a sequenze.

2.6.1 Operatore di slice (selezione da sequenza) e indici

Le parentesi `[]` (operatore di slice) servono per effettuare estrazione da una sequenza. Le sequenze hanno indici che, alternativamente

- vanno da 0 (indice del primo elemento) a `n-1` dove `n` è la lunghezza della sequenza, restituita da `len` (analogamente a quanto avviene nel C).
- vanno da `-n` a `-1` per riferirsi agli oggetti dal primo all'ultimo con indici negativi

²A parte `len`, `reversed` e `sum` queste si applicano agli iteratori in genere

Operatore	Funzione
<code>seq[::]</code>	accedi ad elementi specifici di <code>seq</code>
<code>seq[ind1:ind2]</code>	da <code>ind1</code> incluso sino a <code>ind2</code> escluso
<code>seq[ind1:ind2:ind3]</code>	da <code>ind1</code> incluso a <code>ind2</code> escluso, facendo passi di <code>ind3</code>
<code>seq * expr</code>	ripeti la sequenza <code>expr</code> volte
<code>seq1 + seq2</code>	concatena le due sequenze
<code>obj in seq</code>	testa se l'oggetto <code>obj</code> è presente nella sequenza <code>seq</code>
<code>obj not in seq</code>	contrario del precedente test

Tabella 2.2: Operatori comuni per le sequenze

Funzione	Attività
<code>enumerate(iter)</code>	ritorna un oggetto enumerato
<code>len(seq)</code>	ritorna la lunghezza della sequenza
<code>max(iter)</code>	ritorna il massimo dell'iterabile
<code>min(iter)</code>	ritorna il minimo dell'iterabile
<code>reversed(seq)</code>	ritorna un iteratore che attraversa la sequenza in ordine inverso
<code>sorted(iter)</code>	ritorna una lista ordinata dell'iterabile fornito
<code>sum(seq)</code>	somma della sequenza

Tabella 2.3: Operatori per la coercizione a sequenze

Funzione	Attività
<code>list(iter)</code>	converti l'iterabile ad una lista
<code>str(iter)</code>	converti l'iterabile ad una stringa
<code>tuple(iter)</code>	converti l'iterabile ad una tuple

Tabella 2.4: Operatori per la coercizione a sequenze

```
len = 6
+---+---+---+---+---+
| P | y | t | h | o | n |
+---+---+---+---+---+
  0   1   2   3   4   5
-6  -5  -4  -3  -2  -1
```

La sintassi dello slicing prevede al massimo tre indici

`seq[partenza:termine:passo]`

- indice di partenza: specifica da che elemento partire, se mancante (o `None`) si intende di partire dall'inizio della sequenza
- indice di termine: specifica sino a quale elemento (escluso) terminare con l'estrazione. Se mancante (o `None`) si intende il termine della sequenza.
- indice di passo: specifica lo step dell'estrazione: se mancante lo step è di singola unità

2.6.2 Stringhe

La creazione avviene normalmente mediante assegnazione; la stringa può essere ugualmente inclusa tra apici singoli o doppi. Vediamo alcuni metodi comuni

2.6.2.1 Stringhe valide

```
>>> stringa = "asdomar"
>>> stringa_multilinea = """
... bla bla bla
... qua qua qua
... za za za
... """
>>> stringa_multilinea2 = (
...     "Queste stringhe tra parentesi, senza virgola, "
...     "saranno concatenate "
...     "come avviene nel C, "
...     "sono utili per spezzare."
... )
>>> print(stringa_multilinea2)
Queste stringhe tra parentesi, senza virgola, saranno concatenate come avviene nel C,
```

2.6.2.2 Formattazione

```
>>> import datetime

>>> s = "test"
>>> n = 13
>>> p = 2/3
>>> a_mill = 1000000
>>> dt = datetime.datetime.now()
>>> the_format = ".3f"
```

```

>>> address = "Via Tal dei tali"
>>> name = "Mario"

>>> # per formattazione. Quello messo a dx di : dipende dal tipo
>>> f"{s} {n}" # standard..
'test 13'
>>> f"{p:.2f}" # float con numero decimali
'0.67'
>>> f"{p:.0f}" # rimuovere decimali da un float
'1'
>>> f"{p:{the_format}}" # formato nested
'0.667'
>>> f"{p:.2%}" # percentuali con due decimali
'66.67%'
>>> f"{p:e}" # notazione scientifica
'6.666667e-01'
>>> f"{a_mill:,}" # re di migliaia
'1,000,000'
>>> f"{a_mill:,.2f}" # separatore di migliaia e specifica dec
'1,000,000.00'
>>> f"{dt:%d/%m/%Y}" # date
'10/06/2026'
>>> f"{dt:%Y-%m-%d (%H:%M:%S)}" # datetime
'2026-06-10 (07:51:05)'
>>> f"today is a {dt:%A of %B}" # giorno della settimana e mese
'today is a Wednesday of June'

>>> # per debugging: a sinistra di = una espressione, a destra il risultato
>>> f"{s = }, {n = }"
"s = 'test', n = 13"
>>> f"{n % 2 = }" # qualsiasi espressione a sinistra viene valutata
'n % 2 = 1'
>>> f"{isinstance(n, int) = }" # e il rispettivo valore restituito
'isinstance(n, int) = True'

>>> # padding/allineamento di stringhe e numeri
>>> f"{s:8}" # allineato a sinistra in campo da 8
'test      '
>>> f"{s:>8}" # allineato a destra
'      test'
>>> f"{s:*<8}" # allineato a sx riempiendo con *
'test****'
>>> f"{s:_^8}" # centrato riempiendo con _
'__test__'
>>> f"{s:_^{n}}" # uso di una variabile per n. di padding
'____test____'
>>> f'{address:20}{name:10}' # tabulating without libs
'Via Tal dei tali      Mario      '
>>> f"{n:06}" # aggiungere zeri prima di un numero
'000013'

```

2.6.2.3 Elaborazioni varie

```

>>> # Aggiunta di zero
>>> # -----
>>> "123".zfill(4)      # Aggiunta di 0 iniziali
'0123'

>>> # Rimozione spazi
>>> # -----
>>> "  test di strip ".strip() # finali e iniziali
'test di strip'
>>> "  test ".lstrip()        # solo iniziali
'test '
>>> " test ".rstrip()         # solo finali
' test'

>>> # Join di iterabili contenenti stringhe
>>> # -----
>>> ", ".join(["a", "b", "c"])
'a, b, c'

>>> # Ricerca/rimpiazzo
>>> # -----
>>> "aiuola".find("a")      # Ricerca da sx (prima occorrenza)
0
>>> "aiuola".find("u")
2
>>> "aiuola".find("x")
-1
>>> "aiuola".rfind("a")     # Ricerca da destra (ultima occorrenza)
5
>>> "prova".replace("a", "e") # Rimpiazzo
'prove'

>>> # Splitting
>>> # -----
>>> "amicici".partition("c")
('ami', 'c', 'ici')
>>> "amicici".rpartition("c")
('amici', 'c', 'i')
>>> "amicici".split("c")
['ami', 'i', 'i']
>>> "linea1\nlinea2".splitlines()
['linea1', 'linea2']

>>> # Checks
>>> # -----
>>> "PROVA".islower()      # Lower/upper case
False
>>> "PROVA".isupper()
True

```

```

>>> "BRGLCU83S04H223C".isalnum() # alfanumerico/alfabetico
True
>>> "BRGLCU83S04H223C".isalpha()
False
>>> "prova".startswith("f")      # inizia/termina con
False
>>> "prova".endswith("a")
True

>>> # Coercizioni
>>> # -----
>>> "PROVA".lower()
'prova'
>>> "prova".upper()
'PROVA'
>>> "uno due tre prova".capitalize()
'Uno due tre prova'
>>> "uno due tre prova".title()
'Uno Due Tre Prova'

```

2.6.2.4 Classe con formato

```

>>> class MyClass:
...     def __format__(self, format_spec) -> str:
...         return "object"
...
>>> class MyClass2:
...     def __format__(self, format_spec) -> str:
...         match format_spec:
...             case 'upper':
...                 return "OBJECT"
...             case 'lower':
...                 return "object"
...             case _:
...                 raise ValueError(f"{format_spec} not accepted")
...
>>> obj1 = MyClass()
>>> obj2 = MyClass2()

>>> f"{obj1}"      # classe con formato
'object'
>>> f"{obj2:upper}" # classe con formato e parametro
'OBJECT'
>>> f"{obj2:lower}" #
'object'

```

2.6.3 Liste

Le **liste** una sequenza di valori, non necessariamente dello stesso tipo, separati da virgole e racchiusi tra parentesi quadre. Le liste sono modificabili

2.6.3.1 Definizione

La definizione di una lista avviene come segue

```
>>> squares = [1, 2, 4, 9, 16, 25]
>>> letters = ['a', 'b', 'c', 'd']
>>> squares
[1, 2, 4, 9, 16, 25]
>>> letters
['a', 'b', 'c', 'd']
```

2.6.3.2 Manipolazione e modifica

Le liste si comportano similmente alle stringhe per ciò che riguarda il **subset**:

```
>>> squares[0]
1
>>> squares[-1]
25
>>> squares[-3:]
[9, 16, 25]
```

e operatori (concatenazione, moltiplicazione)

```
>>> squares + squares
[1, 2, 4, 9, 16, 25, 1, 2, 4, 9, 16, 25]
>>> squares*2
[1, 2, 4, 9, 16, 25, 1, 2, 4, 9, 16, 25]
```

A differenza delle stringhe sono modificabili:

```
>>> squares[0] = 0 # modifica di un valore
>>> squares
[0, 2, 4, 9, 16, 25]
>>> letters[1:2] = [] # eliminazione di valori
>>> letters
['a', 'c', 'd']
```

Le liste sono oggetti e hanno **metodi** per le operazioni più classiche. Si veda `help(list)`.

2.6.3.3 Metodi utili

```
>>> l = []
>>> a = ["a", "c", "d"]

>>> # Aggiunta elementi
>>> # -----
>>> l.append(1) # un elemento in coda
>>> a.insert(1, "b") # un elemento prima dell'indice specificato
>>> l.extend([1,2,3]) # elementi da un iterabile in coda

>>> # Rimozione elementi
>>> # -----
```



```

>>> a.remove("c")      # rimuove la prima occorrenza di un elemento
>>> x = a.pop(1)       # rimuove il valore all'indice specificato e lo ritorna
>>> l.clear()          # rimuove tutti gli elementi

>>> # Ricerca elementi
>>> # -----
>>> ["a", "x", "c", "x"].index("x") # indice di un elemento (prima occorrenza)
1
>>> [1,2,1,3].count(1)          # conta le occorrenze di un dato elemento
2

>>> # Ordinamento
>>> # -----
>>> x = ["w", "j", "a" ]
>>> x.sort()      # ordina
>>> x.reverse()   # inverte

```

2.6.3.4 Liste nested

Le liste possono essere nested, e nel caso il subsetting necessita di una parentesi graffa per ogni livello:

```

>>> a = [1, 2, 3]
>>> b = ['a', 'b', 'c']
>>> c = [a, b, 3]
>>> c
[[1, 2, 3], ['a', 'b', 'c'], 3]
>>> c[0]
[1, 2, 3]
>>> c[1]
['a', 'b', 'c']
>>> c[2]
3
>>> c[1][2]
'c'

```

2.6.3.5 List comprehensions

Sono un trick del linguaggio per creare liste in maniera concisa.

Definizione La versione più generale è

```

newlist = [expression for item1 in iterable1 if condition1
            for item2 in iterable2 if condition2
            ...
            for itemN in iterableN if conditionN
            if conditionN+1
            if conditionN+2
            ...
            if conditionN+M
]

```

con:

1. **expression** è una espressione contenente **item1..itemN**;
2. seguita da uno statement **for** (obbligatorio) che si riferisca ad un iterabile (volendo filtrato mediante **if**);
3. al quale seguono 0+ più ulteriori statement **for** con altrettanti iterabili (per ciclare su altro, eventualmente filtrando con **if**);
4. al quale seguono 0+ statement **if** (opzionalmente per selezionare gli elementi da porre nell'output).

Gli **iterable*** non necessariamente debbono essere della stessa lunghezza, perché sono iterate da sinistra a destra, non in parallelo: per ogni elemento in **iterable1**, viene fatto loop su **iterable2** e tutte le rimanenti a cascata

Esempi

```
>>> ## Esempio base
>>> doubled = [x * 2 for x in range(10)]
>>> doubled
[0, 2, 4, 6, 8, 10, 12, 14, 16, 18]

>>> ## Esempio con if
>>> combs = [(x, y) for x in [1, 2, 3] for y in [3, 1, 4] if x != y]
>>> # che equivale a
>>> combs = []
>>> for x in [1,2,3]:
...     for y in [3,1,4]:
...         if x != y:
...             combs.append((x, y))
...

>>> X = [1, 2, 3]
>>> Y = [4, 5, 6]
>>> res = [[x, y, x*y]
...         for x in X if x > 1
...         for y in Y if y < 6
...         if y % x == 0]
```

Espressioni più complesse e trick utili a seguire

```
>>> vec = [-4, -2, 0, 2, 4]

>>> ## Selezionare gli elementi >= 0
>>> [x for x in vec if x >= 0]
[0, 2, 4]

>>> ## Applicare una funzione a tutti gli elementi di una lista
>>> [abs(x) for x in vec]
[4, 2, 0, 2, 4]
```

```

>>> ## utilizzo di più di un if: stampa dei numeri divisibili per 2 e per 5
>>> ## tra 0 e 100
>>> [y for y in range(100) if y % 2 == 0 if y % 5 == 0]
[0, 10, 20, 30, 40, 50, 60, 70, 80, 90]

>>> ## Le espressioni possono essere molto generali;
>>> ## if .. else con list comprehension
>>> [">=0" if i>=0 else "<0" for i in vec]
['<0', '<0', '>=0', '>=0', '>=0']

>>> ## creiamo una lista composta da tuple
>>> [(x, x**2) for x in range(6)]
[(0, 0), (1, 1), (2, 4), (3, 9), (4, 16), (5, 25)]

>>> ## esegui un metodo su ogni elemento
>>> fruit = ['banana', 'strawberry', 'passion fruit']
>>> [y.capitalize() for y in fruit]
['Banana', 'Strawberry', 'Passion fruit']

```

List comprehensions nested Espressione di una list comprehension può esser qualunque cosa, quindi anche una list comprehension. Questo può essere utile per creare liste di liste, che possono avere applicazione.

```

>>> ## Calcolo tabelline del 7 e dell'8 (nb:cicla per prima è la lista
>>> ## esterna, poi quella interna)
>>> nl = [[i*j for j in range(1, 11)] for i in range(7, 9)]
>>> nl
[[7, 14, 21, 28, 35, 42, 49, 56, 63, 70], [8, 16, 24, 32, 40, 48, 56, 64, 72, 80]]

>>> ## Trasposizione di matrice creata mediante lista di liste
>>> matrix = [
...     [1, 2, 3, 4],
...     [5, 6, 7, 8],
...     [9, 10, 11, 12]
... ]
>>> t = [[row[i] for row in matrix] for i in range(4)]
>>> t
[[1, 5, 9], [2, 6, 10], [3, 7, 11], [4, 8, 12]]

```

2.6.4 Tuple

Le **tuple** sono insiemi di valori separati da virgole (buona norma porle tra parentesi tonde per chiarezza) e non modificabili una volta create

```

>>> ## Definizione
>>> atuple = ('robots', 77, 93, 'try')
>>> atuple
('robots', 77, 93, 'try')

>>> ## subset
>>> atuple[:3]

```

```

('robots', 77, 93)

>>> ## tuple nested
>>> a = (1, 2)
>>> b = ('x', 'y')
>>> c = (a, b)
>>> c
((1, 2), ('x', 'y'))

>>> ## modifica diretta? no: da errore
>>> atuple[1] = 1
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'tuple' object does not support item assignment
>>> ## tuttavia è possibile creare tuple che contengono oggetti modificabili
>>> btuple = ([1,2], "abc")
>>> btuple[0][0] = 3
>>> btuple
([3, 2], 'abc')

>>> ## Metodi utili, uguali a quelli delle liste
>>> atuple.count(93)
1
>>> atuple.index("try")
3

```

2.6.5 Sequence unpacking

Consiste nell'assegnare gli elementi di una sequenza (posta come *rvalue*) a variabili separate (*lvalue*)

```

>>> ## Esempio con lista
>>> a, b, c = [1, 2, 'goodbye']

>>> ## Esempio con tupla
>>> t = (12345, 54321, 'hello!')
>>> t1, t2, t3 = t

>>> ## Esempio con stringa
>>> x, y, z = 'cia'

```

2.7 Classi mapping e set

2.7.1 Dict

Sono un insieme non ordinato di coppie **key:value**, con **key** univoche all'interno di un dict (e immutabili), utile per memorizzare un dato e ritornarlo attraverso la sua chiave.

```

>>> ## Definizione, accesso e modifica
>>> ## -----

```

```

>>> d = {'planet': 'earth', 'region': 'europe', 'prefix': 39, 'number_list': [1, 2, 3]}
>>> d
{'planet': 'earth', 'region': 'europe', 'prefix': 39, 'number_list': [1, 2, 3]}
>>> d2 = {1: "a", 2: "b"} # esempio con chiave numerica
>>> f = dict(sape = 4139, guido = 4127, jack = 4098) # Metodo alternativo: funzione dict
>>> g = dict([('sape', 4139), ('guido', 4127), ('jack', 4098)])

>>> ## Accesso/modifica
>>> ## -----
>>> d.get('planet')    # ottiene un valore data la chiave
'earth'
>>> d['prefix']        # accesso in lettura ad un elemento
39
>>> d['prefix'] = 45   # modifica consentita
>>> d['foo'] = "bar"   # nuovo inserimento consentito
>>> d2[1]
'a'
>>> g.clear()         # rimuove tutti gli item

>>> ## ottenere le chiavi/valori come iterabili (es per un for)
>>> ## -----
>>> d.keys()          # ottenere le chiavi
dict_keys(['planet', 'region', 'prefix', 'number_list', 'foo'])
>>> 'foo' not in d.keys()
False
>>> d.values()        # ottenere valori come iterabile
dict_values(['earth', 'europe', 45, [1, 2, 3], 'bar'])
>>> d.items()         # coppia (indice, valore) come iterabile per unpacking
dict_items([('planet', 'earth'), ('region', 'europe'), ('prefix', 45), ('number_list', [1, 2, 3]), ('foo', 'bar')])

```

2.7.1.1 Dict comprehension

Hanno sintassi analoga a quella delle liste e possono tornare talvolta utili come forma di mapping

```

>>> pow2 = {x: x**2 for x in (2, 4, 6)}
>>> pow2[2]
4

```

2.7.2 Sets

Sono una collezione di elementi senza ordine e duplicati. Si usano tipicamente per:

- verificare l'appartenenza di un qualcosa ad un insieme (mediante `in`);
- per eliminare duplicati di altre strutture dati
- per effettuare operazioni insiemistiche

Si definiscono mediante parentesi graffe o la funzione `set`.

```

>>> basket = {'apple', 'orange', 'apple', 'pear'}
>>> basket ## elementi doppi vengono eliminati
{'pear', 'orange', 'apple'}

>>> ## definizione mediante set: dalla sequenza fornita sono eliminati i doppi
>>> a = set('abracadabra') ## stringa
>>> a
{'d', 'a', 'r', 'b', 'c'}
>>> a = set(['asd', 'foo', 'bar', 'asd']) ## lista
>>> a
{'asd', 'bar', 'foo'}
>>> a = set( ('asd', 'foo', 'bar', 'asd') ) ## tuple
>>> a
{'asd', 'bar', 'foo'}

>>> ## emptyset: si usa set, non due graffe (usate per dict vuoto)
>>> empty = set()

>>> ## Test appartenenza
>>> 'orange' in basket
True
>>> 'strawberry' in basket
False

>>> ## aggiunta, rimozione, azzeramento
>>> empty.add(1)
>>> empty.remove(1)
>>> empty
set()
>>> empty.add(1)
>>> empty.add(2)
>>> empty.clear()

```

2.7.2.1 Operatori/metodi utili

```

>>> ## Applicazione operatori numerici e logici
>>> a = set('abracadabra')
>>> b = set('alacazam')
>>> a
{'d', 'a', 'r', 'b', 'c'}
>>> b
{'l', 'm', 'z', 'a', 'c'}

>>> ## Operazioni insiemistiche
>>> a - b # lettere in a ma non in b
{'d', 'r', 'b'}
>>> a | b # lettere in a o in b
{'d', 'l', 'm', 'z', 'a', 'r', 'b', 'c'}
>>> a & b # lettere sia in a che in b
{'a', 'c'}
>>> a ^ b # xor: lettere in a o in b ma non in entrambi

```

```
{ 'l', 'd', 'm', 'z', 'r', 'b' }

>>> ## Test insiemistici
>>> # intersezione
>>> {1,2}.isdisjoint({3,4})
True
>>> {1,2}.isdisjoint({2,3})
False
>>> # sottinsieme e sovrainsieme
>>> a = {1, 2}
>>> b = {1}
>>> a.issuperset(b)
True
>>> b.issubset(a)
True
```

2.7.2.2 Set comprehension

Le comprehension sono ammesse anche nei set

```
>>> a = {x for x in 'abracadabra' if x not in 'abc'}
>>> a
{'d', 'r'}
```

2.8 Altri tipi utili

2.8.1 namedtuple

Espandono le tuple (immutabili) con l'uso di key dei dict per facilità di accesso

```
>>> from collections import namedtuple

>>> # Problem with tuples and dictionary
>>> # color = (55, 155, 255) # immutable but standard tuple has no names, less readable
>>> # color = {"red": 55, "green": 155, "blue": 255} # dict is mutable

>>> # the right mix
>>> Color = namedtuple("Color", ["red", "green", "blue"]) # create the object
>>> color1 = Color(blue = 55, green = 155, red = 255) # create an instance
>>> color2 = Color(255, 255, 255) # another instance

>>> # Accessing data two way (still read-only)
>>> color1
Color(red=255, green=155, blue=55)
>>> color1.red # no color1["red"]
255
>>> color1.red = 123 # error: tuples are still immutable
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
AttributeError: can't set attribute
```

2.8.2 Counter

Sono versioni speciali di `dict` che servono per contare frequenze di occorrenze

```
>>> from collections import Counter
>>> import random

>>> c = Counter() # create an empty counter

>>> # it's dict like, no initialization needed
>>> c["a"] += 1 # increase count of an element (starting from 0)
>>> c["a"] += 3 # increase count of an element (starting from 0)
>>> c["b"] = 2
>>> c["c"] = 1
>>> c["x"] # no elements counted
0

>>> # typical methods
>>> sorted(c.elements()) # accesso a tutti gli elementi, con ripetizione
['a', 'a', 'a', 'a', 'b', 'b', 'c']
>>> c.total() # sum of all frequencies
7
>>> c.most_common(2) # most common modalities
[('a', 4), ('b', 2)]

>>> # # other are as in dict
>>> # c.keys()
>>> # c.values()
>>> # c.items()

>>> # example 2: 100d4
>>> d4 = [1, 2, 3, 4]
>>> c2 = Counter()
>>> for i in range(100):
...     roll = random.choice(d4)
...     c2[roll] += 1
...
>>> c2
Counter({3: 26, 1: 26, 2: 24, 4: 24})

>>> # example3: use a counter on elements of a list
>>> rolls = random.choices(d4, k = 200) # list of 200 d4 rolls
>>> c3 = Counter(rolls)
>>> c3
Counter({3: 56, 1: 50, 4: 47, 2: 47})
```

2.8.3 Enum & Flag

2.8.3.1 Enum

Sono usate per dati con un set prefissato di opzioni /categorie

- raggruppano ordinatamente stati/costanti prefissate
- aumentano leggibilità
- facilitano debugging
- single source of truth/consistency

Possono essere pensate come un binding nome valore

```
>>> from enum import Enum

>>> class State(Enum):
...     OFF: int = 0
...     ON: int = 1
...
>>> class Color(Enum):
...     RED: str = 'R'
...     GREEN: str = 'G'
...     BLUE: str = 'B'
...
>>> # Cosa contengono
>>> dir(Color)
['BLUE', 'GREEN', 'RED', '__class__', '__contains__', '__doc__', '__getitem__', '__init_subclass__',
...
>>> dir(Color.RED)
['__class__', '__doc__', '__eq__', '__hash__', '__module__', 'name', 'value']
>>> Color.RED.name      # etichetta
'RED'
>>> Color.RED.value     # valore associato
'R'
```

L'utilizzo base è chiaro dal punto di vista del codice

```
>>> print(Color.RED) # autocompletamento dopo . fornisce i colori disponibili
Color.RED
>>> print(Color("R"))
Color.RED
>>> Color("R") == Color.RED # si può usare sia il valore che l'etichetta
True
>>> Color.RED is Color("R") # same thing direi
True

>>> def create_car(color: Color) -> None:
...     match color:
...         case Color.RED:
...             print("A red car was created")
...         case Color.BLUE:
...             print("A blue car was created")
...         case Color.GREEN:
...             print("A green car was created")
...         case _:
...             print(f"We don't have {color} in our database")
```

```
...

>>> create_car(Color.RED)
A red car was created

>>> # # in una classe
>>> # macchina.color = Color.RED
>>> # ...
>>> # if macchina.color == Color.BLUE:
>>> # ...
```

2.8.3.2 Flag

Sono enum che permettono di combinare valori per indicare assieme di valori (tipo set)

```
>>> from enum import Flag

>>> # Se definiamo a mano meglio usare le potenze del 2
>>> class Color(Flag):
...     RED: int = 1      # 00001
...     GREEN: int = 2    # 00010
...     BLUE: int = 4     # 00100
...     YELLOW: int = 8   # 01000
...     BLACK: int = 16   # 10000
...

>>> # Mix di colori
>>> red_and_yellow = Color.RED | Color.YELLOW

>>> # stampa del contenuto (tipo set)
>>> print(red_and_yellow)
Color.RED|YELLOW
>>> for col in red_and_yellow:
...     print(col)
...
Color.RED
Color.YELLOW
>>> # utilizzo (set/combination)
>>> cool_colors = Color.YELLOW | Color.BLACK | Color.RED # creo set colori
>>> my_car_color = Color.BLACK
>>> my_car_color in cool_colors # testo appartenenza a set di colori
True
```

Sotto la scocca una combinazione di gruppi di enum somma le relative costanti associate;

```
>>> red_and_yellow.value
9
```

nella definizione sopra non abbiamo impostato a 9 nessun colore nella definizione se no il programma si confonde e ci restituisce il colore impostato a 9. Tuttavia se impostiamo le costanti a mano potremmo fare danni

```

>>> # power of two
>>> class Wrong(flag):
...     RED: int = 1      # 00001
...     GREEN: int = 2   # 00010
...     BLUE: int = 3    # 00100
...

>>> red_or_green = Wrong.RED | Wrong.GREEN
>>> red_or_green
<Wrong.BLUE: 3>
>>> red_or_green.value
3

```

Motivo per cui si può usare `auto` nella definizione (di `Flag` ed `enum`)

```

>>> # to prevent these errors, use auto in definition
>>> from enum import Flag, auto

>>> class Right(flag):
...     RED: int = auto()      # auto assign a proper value
...     GREEN: int = auto()   # we don't have to worry
...     BLUE: int = auto()
...

>>> Right.RED
<Right.RED: 1>
>>> Right.GREEN
<Right.GREEN: 2>
>>> Right.BLUE
<Right.BLUE: 4>

```

Nel caso di `Enum` secche, `auto` non usa le potenze di due ma un progressivo numerico

```

>>> class Right2(Enum):
...     RED: int = auto()
...     GREEN: int = auto()
...     BLUE: int = auto()
...

>>> Right2.RED
<Right2.RED: 1>
>>> Right2.GREEN
<Right2.GREEN: 2>
>>> Right2.BLUE
<Right2.BLUE: 3>

>>> # btw with enums one cannot use | . errore
>>> Right2.RED | Right2.GREEN
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: unsupported operand type(s) for |: 'Right2' and 'Right2'

```

Al termine, come informazione, Possiamo usare la combinazione anche in sede di definizione con |

```
>>> class Right2(Flag):
...     RED: int = auto()
...     GREEN: int = auto()
...     BLUE: int = auto()
...     ALL: int = RED | GREEN | BLUE # 1 + 2 + 4
...

>>> Right2.ALL
<Right2.ALL: 7>
```

2.9 Type annotation

Qui sono presentati concetti che richiedono conoscenze più approfondite rispetto ad una prima lettura, nella quale si possono tralasciare.

Sebbene Python sia un dynamic language con variabili aventi un tipo non stabilito a priori/che può variare nel corso dell'esecuzione del programma, è possibile specificare il tipo assunto da una variabile nonché il tipo ritornato da una funzione in maniera tale da usare tool esterni che analizzino il codice e riportino utilizzi impropri.

2.9.1 Sintassi

```
>>> ## -----
>>> ## File test.py
>>> ## -----

>>> # formati per variabile: in unico colpo
>>> x: int = 4

>>> # spezzato
>>> x: int
>>> x = "4" # qua viene dato errore nei programmi giusti, non nell'interprete

>>> # esempio con funzioni, notare i parametri e il tipo restituito
>>> # z è un parametro opzionale (può essere int al massimo) di default a None
>>> def repeat(x: str, y: int = 2, z: int|None = None) -> None:
...     if z is None:
...         print(x * y)
...     else:
...         print(x * y * z)
...
>>> repeat(x = 'foo')
foofoo
```

2.9.2 Checking

La sintassi di cui sopra è tool indipendente quindi può essere potenzialmente gestita da diversi eseguibili. Qui utilizziamo mypy. Per installarlo

```
pip install --user mypy
```

Dopodiché per controllare il file di cui sopra

```
mypy test.py
```

Per controllare una pacchetto posizionarsi nella directory base (quella con requirements.txt e compagnia) e comandare

```
mypy .
```

2.9.3 Tipi utilizzabili per variabili

Tutti i tipi di base quindi `str`, `int`, `float`, `bool`, ma anche `None` per indicare che la funzione non ritorna nulla.

Per i tipi compositi: sotto alcuni esempi di assegnazione corretta

```
# lista di sole stringhe
x: list[str] = ["foo", "bar"]

# insieme di interi
x: set[int] = {6, 7}

# per dict fornire il tipo di key e value
x: dict[str, float] = {"field": 2.0}

# tuple di dimensione fissa si specifica il tipo di ogni elemento
x: tuple[int, str, float] = (3, "yes", 7.5)

# tuple di dimensione variabile: si usa un tipo e l'ellissi
x: tuple[int, ...] = (1, 2, 3)

# se ad esempio vogliamo essere generali
# e specificare un iterabile (lista, tuple, set, altro) di interi

from typing import Iterable
x: Iterable[str] = ...

# i tipi Mapping sono dict-like non mutabili (con metodo __getitem__)
from typing import Mapping
x: Mapping[int, str] = {3: 'yes', 4: 'no'}
x[5] = 'foo' # qui mypy si lamenta

# MutableMapping sono dict-like mutabili (con metodo __setitem__)
x: MutableMapping[int, str] = {3: 'yes', 4: 'no'}
x[5] = 'foo' # qui mypy non si lamenta

# accettare tipi molteplici
x: list[int | str] = [3, 5, "test", "fun"]
# questo è utile in funzioni per specificare parametri opzionali

# Optional per dati che possono essere anche None
```

```
from typing import Optional
x: Optional[str] = "something" if some_condition() else None
```

mypy conosce i tipi della standard library e fornisce suggerimenti sui pacchetti da installare nel caso non sia così

```
prog.py:2: error: Library stubs not installed for "requests"
prog.py:2: note: Hint: "python3 -m pip install types-requests"
```

2.9.4 Creazione di alias

La digitazione di tipi complessi più volte può essere evitata mediante la creazione di alias, fatti semplicemente mediante assegnazione. Ad esempio

```
Vector = list[float]

def scale(scalar: float, vector: Vector) -> Vector:
    return [scalar * num for num in vector]

# utile anche per rendere i tipi più leggibili/compatti/riutilizzabili
ConnectionOptions = dict[str, str]
Address = tuple[str, int]
Server = tuple[Address, ConnectionOptions]
def broadcast_message(message: str, servers: Sequence[Server]) -> None:
    ...
```

2.9.5 Annotazione di funzioni

Abbiamo già visto un esempio abbastanza generico di funzione

```
def show(value: str, excitement: int = 10) -> None:
    print(value + "!" * excitement)
```

Per la programmazione funzionale può essere necessario specificare un tipo Callable (funzione):

```
from typing import Callable

def repeat(x: str, y: int = 2) -> None:
    print(x * y)

# variabile: x può essere una funzione di tipo def xx(str, int): -> None
x: Callable[[str, int], None] = repeat
```

Per funzioni generatrici che restituiscono un iteratore di int si può fare così

```
def gen(n: int) -> Iterator[int]:
    i = 0
    while i < n:
        yield i
        i += 1
```

2.9.6 Annotazione di metodi in classi

`self` non va caratterizzato (nei parametri, se restituito si usa `Self`), poi spesso le funzioni di classi modificano dati internamente non restituendo nulla quindi si userà `None` come dato restituito

```
from typing import Self

class BankAccount:
    def __init__(self, account_name: str, initial_balance: int = 0) -> None:
        self.account_name = account_name
        self.balance = initial_balance

    def deposit(self, amount: int) -> None:
        self.balance += amount

    def withdraw(self, amount: int) -> None:
        self.balance -= amount

    def returnme(self) -> Self:
        return self
```

Le classi definite dall'utente sono tipi validi da usare per le annotazioni

```
account: BankAccount = BankAccount("Alice", 400)
def transfer(src: BankAccount, dst: BankAccount, amount: int) -> None:
    src.withdraw(amount)
    dst.deposit(amount)
```

Funzioni che accettano una classe, accetteranno anche classi derivate senza problemi:

```
class BankAccountForYoungs(BankAccount):
    ....

timmysba = BankAccountForYoungs("Timmy", 2)
transfer(account, timmysba, 100) # type checks!
```


Capitolo 3

Controllo del flusso

Contents

3.1	Costrutti condizionali: if e while	49
3.1.1	if	49
3.1.2	match	50
3.1.3	while	50
3.1.4	break, continue ed else	50
3.2	Condizioni e test logici	50
3.2.1	Test verità	50
3.2.2	Operatori booleani	51
3.2.3	Comparazioni	51
3.2.4	Comparazioni concatenate	52
3.2.5	Check appartenenza: in e not in	52
3.2.6	Comparare sequenze e altri tipi	52
3.3	Looping su oggetti: for	53
3.3.1	Looping in sequenze (stringhe, liste, tuple)	53
3.3.2	Looping nei dict	54
3.3.3	Looping sui set	54
3.3.4	L'utilizzo di range	54

3.1 Costrutti condizionali: if e while

3.1.1 if

Ha la seguente sintassi con <> a indicare un contenuto obbligatorio, [] uno facoltativo e * la possibilità di ripetizione:

```
if <condizione>:
    <istruzioni>
[elif <condizione>:
    <istruzioni>]*
[else:
    <istruzioni>]
```

3.1.2 match

Simile allo switch di altri linguaggi, `match` prende una espressione e la compara ad una casistica di altre espressioni (poste dopo `case`) per eseguire azioni specificate:

```
def http_error(status):
    match status:
        case 400:
            return "Bad request"
        case 401 | 403 | 404:
            return "Not allowed"
        case 418:
            return "I'm a teapot"
        case _:
            return "Something's wrong with the internet"
```

Si notano che si possono specificare match multipli con `|`, mentre `_` matcha sempre e quindi può essere usato come caso default (eventualmente) quando nessun altro caso ha matchato.

3.1.3 while

python ha solo l'istruzione `while` per implementare l'iterazione nel senso di altri linguaggi come il Pascal o il C:

```
while <condizione>:
    <istruzioni>
[else:
    <istruzioni>]
```

3.1.4 break, continue ed else

Sia in `while` che `for` (che vedremo poi):

- `continue` permette di saltare le rimanenti istruzioni del ciclo passando all'iterazione successiva;
- `break` termina il ciclo;
- se è presente la clausola `else` le sue istruzioni vengono eseguite qualora il ciclo termini normalmente, mentre non vengono eseguite se il ciclo termina a causa dell'istruzione `break`.

3.2 Condizioni e test logici

3.2.1 Test verità

Un oggetto può essere testato come `True/False` in un `if` o in un `while`: in generale un oggetto è considerato `True` a meno che, alternativamente

- la sua classe definisce il metodo `__bool__`, che restituisce `False`

- il metodo `__len__` ritorna qualcosa, se chiamato sull'oggetto

Quindi:

- `None` è valutato `False`
- i numeri restituiscono tutti `True` ad eccezione dello 0 (`int` o `float` che sia) che è `False`
- stringa, lista, tuple, set e dict **vuoti restituiscono False**, altrimenti (con almeno un elemento) viene restituito `True` (indipendentemente dal contenuto)

Mediante una funzioni del genere possiamo testare la valutazione booleana di oggetti di natura diversa:

```
>>> def is_it_true(anything):
...     if anything:
...         print("yes, it's true")
...     else:
...         print("no, it's false")
... 
```

3.2.2 Operatori booleani

Le comparazioni possono esser elaborate mediante operatori booleani `and` `or` e `not`.

È sempre meglio aggiungere le parentesi per indirizzare ordine/priorità di valutazione. In assenza tra gli operatori `not` ha la priorità maggiore, `or` la minore. Pertanto:

`A and not B or C`

equivale a

`(A and (not B)) or C`

3.2.3 Comparazioni

Vi sono otto operatori di comparazione, hanno tutti la stessa priorità (che è superiore a quella degli operatori booleani)

<code><</code>	minore
<code><=</code>	minore o uguale
<code>></code>	maggiore
<code>>=</code>	maggiore o uguale
<code>==</code>	equal
<code>!=</code>	not equal
<code>is</code>	due oggetti sono identici
<code>is not</code>	due oggetti sono diversi

Alcune regole:

- oggetti di tipo differente (esclusi numeri) son sempre diversi

- oggetti non identici di una stessa classe sono diversi, a meno che forniscano un metodo `__eq__` che li battezzi come uguali
- istanze di una classe non possono essere ordinate tra loro a meno che la classe non definisca `__lt__` ed `__eq__` (si può definire volendo `__lt__`, `__le__`, `__gt__`, `__ge__`)
- il funzionamento di `is` e `is not` non può esser modificato ed è supportato da iterabili o oggetti che implementano il metodo `__contains__`

3.2.4 Comparazioni concatenate

Le comparazioni possono essere concatenate, come in:

```
a < b == c
```

che equivale a in pratica

```
(a < b) and (b == c)
```

3.2.5 Check appartenenza: `in` e `not in`

`in` e `not in` controllano se un valore è presente o meno in una sequenza

3.2.6 Comparare sequenze e altri tipi

Oggetti di tipo sequenza possono esser comparati con oggetti del medesimo tipo; la comparazione avviene in maniera ricorsiva, con ordinamento lessicografico (in base a unicode). Vi sono alcune peculiarità:

- se tutti gli item di due sequenze sono uguali, le sequenze sono considerate uguali
- se una sequenza costituisce l'inizio di un'altra sequenza più lunga, la sequenza più corta è considerata minore

La comparazione restituisce un valore `True` o `False`; ad esempio nei seguenti casi viene restituito sempre `True`:

```
>>> (1, 2, 3) < (1, 2, 4)
True
>>> [1, 2, 3] < [1, 2, 4]
True
>>> 'ABC' < 'C' < 'Pascal' < 'Python'
True
>>> (1, 2, 3, 4) < (1, 2, 4)
True
>>> (1, 2) < (1, 2, -1)
True
>>> (1, 2, 3) == (1.0, 2.0, 3.0)
True
>>> (1, 2, ('aa', 'ab')) < (1, 2, ('abc', 'a'), 4)
True
```

3.3 Looping su oggetti: for

Nel python serve per iterare sugli elementi di una sequenza (come lista stringa o tuple) e presenta questa sintassi

```
for <variabile> in <sequenza>:
    <istruzioni>
[else:
    <istruzioni>]
```

Il funzionamento interno del `for` verrà spiegato nella sezione di OOP; qui si riassume l'utilizzo standard coi dati più comuni.

3.3.1 Looping in sequenze (stringhe, liste, tuple)

Nelle sequenze possiamo:

- fare loop sul singolo elemento (ponendo la sequenza nel `for` direttamente)
- ottenere un progressivo numerico indice e il contenuto della sequenza con `enumerate`
- fare loop sull'oggetto ordinato con `sorted`
- fare loop sull'oggetto ordinato in maniera decrescente con `reversed`

Gli esempi presentano liste, ma il funzionamento è speculare anche per stringhe e tuple:

```
>>> games = ['monopoli', 'risiko', 'dnd']
```

```
>>> for g in games:
...     print(g)
...
monopoli
risiko
dnd
>>> for i, g in enumerate(games):
...     print(i, g)
...
0 monopoli
1 risiko
2 dnd
>>> for g in sorted(games):
...     print(g)
...
dnd
monopoli
risiko
>>> for g in reversed(games):
...     print(g)
...
dnd
risiko
monopoli
```

3.3.2 Looping nei dict

Di un dict possiamo volere le chiavi (usiamo l'oggetto direttamente o ne chiamiamo/esplicitiamo il metodo `keys`), i contenuti (risp `values`) o tutti e due (`items`):

```
>>> knights = {"gallahad": "the pure", "ciro": "the brave"}

>>> for k in knights:
...     print(k)
...
gallahad
ciro
>>> for k in knights.keys():
...     print(k)
...
gallahad
ciro
>>> for v in knights.values():
...     print(v)
...
the pure
the brave
>>> for k, v in knights.items():
...     print(k, v)
...
gallahad the pure
ciro the brave
```

3.3.3 Looping sui set

La forma più semplice, si pone il set nel for

```
>>> S = {2, 3, 5, 7}
>>> for i in S:
...     print(i)
...
2
3
5
7
```

3.3.4 L'utilizzo di range

Se è necessario iterare su una sequenza di interi la funzione `range` torna utile

```
>>> range(5)           # 0, 1, 2, 3, 4
range(0, 5)
>>> range(5, 10)      # 5, 6, 7, 8, 9
range(5, 10)
>>> range(0, 10, 3)    # 0, 3, 6, 9
range(0, 10, 3)
```

```
>>> range(-10, -100, -30)  # -10, -40, -70
range(-10, -100, -30)
```


Capitolo 4

Funzioni

Contents

4.1	Definizione	57
4.1.1	Argomenti	58
4.1.2	Stringa di documentazione	58
4.2	Chiamata	59
4.2.1	Valutazione dei valori di default	59
4.2.2	Valore ritornato	60
4.2.3	Liste/tuple/dict come parametri di chiamata	60
4.3	Regole di scope	61
4.3.1	Namespace	61
4.3.2	Attributi	61
4.3.3	Scoping	62
4.4	lambda e funzioni anonime	63
4.5	Programmazione funzionale	63
4.5.1	Funzioni classiche	64
4.5.2	Partialling	66
4.5.3	Function factory	67
4.5.4	Composizione di funzioni	67
4.5.5	Decorators	68
4.5.6	Single e multiple dispatch	72
4.6	Altri argomenti	75
4.6.1	atexit	75

4.1 Definizione

Avviene mediante `def`, seguita dal nome della funzione e ponendo tra tonde i parametri:

```
def nome_funzione(arg1, arg2 = default2, *args, **kwargs):  
    codice  
    ...
```

4.1.1 Argomenti

Gli argomenti devono essere specificati nell'ordine di cui sopra, e sono:

1. *positional argument* (**arg1**) son definiti con solamente il nome dell'argomento. In chiamata è obbligatorio specificarli inserendo alternativamente **valore** o **nome = valore** (in questo secondo caso sarà possibile seguire un ordine di argomenti diverso da quello dato in definizione);
2. *keyword argument* (**arg2**) son definiti con un valore di default: in sede di chiamata non sono obbligatori da specificare;
3. *arbitrary argument list*: se si specifica ***args** in definizione, la variabile **args** memorizzerà una tupla con gli argomenti posizionali della chiamata (specificati mediante il solo **valore**) esclusi i valori associati ad altri argomenti posizionali: ad esempio sopra prima viene riempito **arg1**, poi **args**);
4. *arbitrary keyword argument list*: se si specifica ****kwargs** in definizione, la variabile **kwargs** memorizzerà un dizionario con i keyword argument (**nome=valore**) specificati in sede di chiamata (esclusi quelli che matchano keyworded argument specificati, es **arg2**)

Un esempio

```
>>> def args_demo(arg1, *args, **kwargs):
...     print("arg1 = ", arg1)
...     print("args = ", args)
...     print("kwargs = ", kwargs)
... 
```

Parametri speciali /* per imporre la chiamata Gli argomenti possono esser passati alle funzioni sia per posizione che utilizzando la keyword. Si può (leggibilità/performance) in definizione imporre che la chiamata di alcuni possa avvenire in un modo, nell'altro o in entrambi, specificando gli argomenti opzionali / e *

```
def f(pos1, pos2, /, pos_or_kwd, *, kwd1, kwd2):
    -----
    |           |           |
    |           Positional or keyword |
    |                                           +-- Keyword only
    +-- Positional only
```

4.1.2 Stringa di documentazione

Da porre come prima istruzione all'interno del corpo, come segue:

```
>>> def sq(n):
...     """
...     Returns the square of n.
...     """
...     return(n * n)
... 
```

mediante `sq.__doc__` si accede alla documentazione della funzione.

4.2 Chiamata

In chiamata si:

- specifica tutti gli argomenti per i quali in definizione non sono dati default;
- pone gli argomenti posizionali prima dei keyworded;
- i posizionali posti senza **nome** verranno associati nell'ordine dato in definizione; se si specificano tutti **nome = valore** l'ordine può differire dalla definizione

```
>>> args_demo(1, 2, 3, foo = 6, baz = 7)
arg1 = 1
args = (2, 3)
kwargs = {'foo': 6, 'baz': 7}
```

4.2.1 Valutazione dei valori di default

Questa:

- avviene al punto in cui la funzione è stata *definita*, non quando viene chiamata

```
>>> x = 5
```

```
>>> def f(arg = x):
...     print(arg)
...
>>> x = 6
>>> f()
5
```

- il valore valutato viene conservato per le future chiamate; se modificabile (lista, dict, classe) e modificato, la versione cambiata sarà conservata per le prossime chiamate (non sempre voluto)

```
>>> # modifica di valore di default imm modificabile è locale e non
>>> # conservato per le prossime chiamate
```

```
>>> def f(x = 1):
...     print(x)
...     x = 2
...
>>> f()
1
>>> f()
1
```

```
>>> # modifica di valore di default modificabile
>>> def f(x, L = []): # una lista è modificabile
...     L.append(x)
```

```

...     return L
...
>>> f(1)
[1]
>>> f(2)
[1, 2]
>>> f(3)
[1, 2, 3]

```

Se non si vuole che il valore di default sia condiviso tra successive chiamate scrivere una funzione come la seguente

```

def f(x, L = None):
    if L is None:
        L = []
    L.append(x)
    return L

```

4.2.2 Valore ritornato

Se:

- si utilizza l'istruzione `return` viene restituito dalla funzione alla chiamante un determinato dato fornito come argomento di `return`;
- se non si specifica nulla (o `return` senza argomenti) viene restituito `None`.

4.2.3 Liste/tuple/dict come parametri di chiamata

Per usarle aggiungere rispettivamente `*` (lista, tuple) e `**` (dict) prima del nome della variabile

```

>>> def foo(x,y,z):
...     print("x=" + str(x))
...     print("y=" + str(y))
...     print("z=" + str(z))
...
>>> l = [1,2,3]
>>> t = (4, 5, 6)
>>> d = {'z': 'foo', 'x': 'bar', 'y': 'baz'}

>>> foo(*l) # same foo(*t)
x=1
y=2
z=3
>>> foo(**d)
x=bar
y=baz
z=foo

```

Vediamo le regole di scoping, ovvero come Python dove cerca i valori delle variabili dati i nomi forniti in programmazione.

Un *namespace* è abbinamento di nomi ad oggetti presenti in memoria; sono *creati in diversi momenti* e hanno *differente durata*. I principali sono:

- Per ottenere la lista di nomi di un namespace si utilizza `dir`:

4.3.2 Attributi

Gli attributi possono essere *read-only* o *scrivibili*; nel secondo caso:

- è possibile assegnarvi qualcosa mediante `x.attributo = valore`;
- è possibile eliminarli mediante `del x.attributo`, che rimuove attributo da `x`.

¹Le funzioni ricorsive hanno un namespace per ogni chiamata

4.3.3 Scoping

All'interno della chiamata di una funzione, la ricerca di un nome avviene nel seguente ordine:

1. nel namespace della *funzione corrente*;
2. nella funzione *enclosing* (quella all'interno del quale la funzione corrente è stata definita²); dopodichè la *enclosing della enclosing*, e così via;
3. il *namespace del modulo* corrente, sia esso `main` o importato
4. il namespace delle *builtin functions*.

Eccezioni: `nonlocal` e `global` Alcuni casi particolari:

- `nonlocal` serve per dichiarare nomi che devono essere presi non dal namespace corrente ma da quelli enclosing

```
>>> a = 1

>>> def scope_local():
...     a = 2
...     print(a)
...
>>> scope_local()
2

>>> def scope_nonlocal_read():
...     a = 3
...     def nested():
...         nonlocal a
...         print(a)
...     nested()
...
>>> scope_nonlocal_read()
3

>>> def scope_nonlocal_write():
...     a = 3
...     def nested():
...         nonlocal a
...         a = 4
...     nested()
...     print(a)
...
>>> scope_nonlocal_write()
4
```

- se un nome è dichiarato mediante `global` la lettura e scrittura da tale variabile va a inficiare il namespace del modulo, indipendentemente da dove essa sia stata effettuata

²Questo è quello che permette le *function factory*.

```
>>> a = 1

>>> def scope_global():
...     global a
...     print(a)
...
>>> scope_global()
1
```

4.4 lambda e funzioni anonime

Le funzioni anonime:

- sono create mediante la keyword `lambda`. Ad esempio la seguente ritorna la somma dei due argomenti passati:

```
lambda a, b: a + b
```

Possono essere assegnate (volendo) comportandosi come normali funzioni

```
>>> x = lambda a, b : a * b
>>> x(5, 6)
30
```

- possono essere usate dove è necessaria una funzione (il suo nome). Ad esempio anche con:

```
>>> (lambda a, b: a+b)(1, 2)
3
```

- sono limitate a *una singola espressione* come corpo

4.5 Programmazione funzionale

Le funzioni sono first class object (quindi possono essere date in input e ritornate come output) e ciò rende possibile la programmazione funzionale. In questa si possono sfruttare caratteristiche del linguaggio come:

- funzioni builtin tipiche della pf: `map`, `filter` etc
- funzioni anonime definite mediante `lambda`
- per i dati analizzati: *iterabili* e *iteratori* (quindi anche generatori ed espressioni generatrici) e le funzioni utili su di essi (es `enumerate`, `sorted`, `any`, `all`, `zip`)

A livello di pacchetti

- `itertools`: iteratori comuni e funzioni per elaborarli
- `functools`: high order functions (funzioni che processano funzioni modificandole)
- `operator`: funzioni che corrispondono agli operatori del python e possono aiutare in un approccio funzionale (evitandoci di scrivere funzioni triviali per effettuare singole operazioni)

4.5.1 Funzioni classiche

4.5.1.1 `map` (= `Map/lapply`)

La builtin

```
map(f, iterA, iterB, ...)
```

restituisce un iteratore sulla sequenza che applica la funzione con argomenti presi dagli iterabili passati:

```
f(iterA[0], iterB[0]), f(iterA[1], iterB[1]), ....
```

Può essere usata anche con un solo iterabile, e nel caso funziona tipo `lapply` di R. Ad esempio:

```
>>> def upper(s):
...     return s.upper()
...
>>> list(map(upper, ['sentence', 'fragment']))
['SENTENCE', 'FRAGMENT']
```

Altro esempio, per applicare un set di n funzioni su un set di n input:

```
>>> def per2(x):
...     return [y*2 for y in x]
...
>>> def per3(x):
...     return [y*3 for y in x]
...
>>> f = (per2, per3)
>>> i = ([1,2,3], [4,5,6])

>>> def apply(f, i):
...     return f(i)
...
>>> list(map(apply, f, i))
[[2, 4, 6], [12, 15, 18]]
```

4.5.1.2 `itertools.starmap`

Applicata ad un singolo iterabile crea un iteratore che valuta la funzione utilizzando argomenti ottenuti dall'iterabile; da utilizzare al posto di `map` quando gli input sono già stati raggruppati (iterabile di iterabili) o zippati nell'iterabile passato

```
>>> from itertools import starmap

>>> def custom_f(a, b, c):
...     return(a * b - c)
...
>>> x = (2,5,2)
>>> y = (3,2,1)
>>> z = (10,3,2)
```



```
>>> # nel primo caso prende a,b,c separatamente da x (poi y e z)
>>> # nel secondo da tutti e tre

>>> list(starmap(custom_f, [x, y, z]))
[8, 5, 28]
>>> list(starmap(custom_f, zip(x, y, z)))
[-4, 7, 0]
```

4.5.1.3 `functools.reduce`

Applica una funzione (che prende in input due parametri e ne restituisce uno) agli elementi di una sequenza:

- la funzione è applicata ai primi due, il risultato applicato insieme al terzo elemento, e così via
- se `initializer` è presente viene piazzato prima della sequenza nel calcolo e funge da default se la sequenza è vuota;

```
>>> from functools import reduce
>>> from operator import add

>>> reduce(add, [1,2,3])
6
>>> reduce(add, [1,2,3], 5)
11
```

4.5.1.4 `itertools.accumulate`

A differenza di `functools.reduce` (che da il risultato finale) restituisce un iteratore sui risultati parziali:

```
>>> from itertools import accumulate
>>> from operator import add

>>> res = accumulate([1,2,3], add)
>>> list(res)
[1, 3, 6]
```

4.5.1.5 `filter`

```
filter(predicate, iter)
```

ritorna un iteratore su tutti gli elementi che rispettano un `predicate`, ossia una funzione che restituisce `True` o `False`. Per funzionare con `filter`, il predicato deve prendere in input un singolo parametro

```
>>> def is_even(x):
...     return (x % 2) == 0
...
>>> list(filter(is_even, range(10)))
[0, 2, 4, 6, 8]
```

Su iteratori funzionalità analoghe si hanno con `filterfalse` e `takewhile` di `itertools`

4.5.2 Partialling

Consiste nel creare una copia di una funzione con uno o più argomenti settati ad un default

4.5.2.1 `functools.partial`

Per parzializzare funzioni

```
>>> from functools import partial

>>> def spam(a, b, c, d):
...     print(a, b, c, d)
...
>>> s1 = partial(spam, 1)           # a = 1
>>> s1(4, 5, 6)
1 4 5 6

>>> s2 = partial(spam, d = 42)     # d = 42
>>> s2(4, 5, 6)
4 5 6 42

>>> s3 = partial(spam, 1, 2, d = 42) # a = 1, b = 2, d = 42
>>> s3(5)
1 2 5 42
```

4.5.2.2 `functools.partialmethod`

Per parzializzare metodi

```
from functools import partialmethod

class Cell:

    def __init__(self):
        self._alive = False

    @property
    def alive(self):
        return self._alive

    # general method ...
    def set_state(self, state):
        self._alive = bool(state)

    # ... and partialled methods
    set_alive = partialmethod(set_state, True)
    set_dead = partialmethod(set_state, False)

c = Cell()
c.alive # False
```

```
c.set_alive()
c.alive # True
```

4.5.3 Function factory

Le function factory fanno uso della capacità del linguaggio di ritornare una funzione che fa uso del namespace della chiamante per la risoluzione di alcune free variable. Vediamo una implementazione di una function factory che crea funzioni potenze in base al parametro passatogli

```
>>> def make_power(n):
...     def power(x):
...         print(x ** n)
...     return power
...
>>> square = make_power(2)
>>> square(3) # restituisce 9
```

```
>>> # con funzione anonima, più compatta ma forse meno leggibile
>>> def lambda_power(n):
...     return lambda x: print(x ** n)
...
>>> square1 = lambda_power(2)
>>> square1(3)
```

4.5.4 Composizione di funzioni

Sfruttando le function factory per comporre diverse funzioni in una sola si può definire la seguente

```
>>> def compose(*funcs):
...     """
...     Return a new function which is composition in math sense
...     compose(f,g,...)(x) = f(g(...(x)))
...     """
...     def worker(data, funcs = funcs):
...         result = data
...         for f in reversed(funcs):
...             result = f(result)
...         return result
...     return worker
...
>>> def add2(x):
...     return x+2
...
>>> def mul2(x):
...     return x*2
...
```

```
>>> f = compose(add2, mul2) # 2x + 2
>>> g = compose(mul2, add2) # 2*(x+2)

>>> X = [1,2,3]
>>> [f(x) for x in X]
[4, 6, 8]
>>> [g(x) for x in X]
[6, 8, 10]
```

Alternativamente, `functools.reduce` può essere utilizzata per comporre una lista di funzioni, ad esempio:

```
>>> import functools

>>> def compose(f, g):
...     return lambda x: f(g(x))
...
>>> funcs = [lambda s: s + "a",
...          lambda s: s + "j",
...          lambda s: s + "e",
...          lambda s: s + "j",
...          lambda s: s + "e"]
>>> # questo è necessario se compose è definita
>>> # applicando la funzione sinistra come seconda (come in math) invece
>>> # di prima, come pensiamo a livello di logica sopra
>>> funcs.reverse()

>>> worker = functools.reduce(compose, funcs)
>>> worker("brazorv_")
'brazorv_ajeje'
```

4.5.5 Decorators

Un decorator è una funzione, solitamente³, che wrappa un'altra funzione modificandone il comportamento standard in qualche modo

4.5.5.1 Definizione e utilizzo

Nel Python è possibile definirli una volta ed utilizzare una sintassi speciale/compatta per applicarli a molteplici funzioni. Di base il funzionamento è il seguente:

```
def foo():
    # do something

def decorator(fun):
    # manipulate fun
    return fun
```

Una volta definito possiamo usarlo come

³Decorator può essere qualsiasi callable, ovvero un oggetto che presenta il metodo `__call__`

```
foo = decorator(foo)  # Manually decorate
```

```
@decorator
def bar():
    # Do something
    # bar() is decorated
```

4.5.5.2 Decoratori già disponibili

Alcuni utili sono

- `functools.cache` memorizza i risultati di una funzione in un dict e controlla alla seconda chiamata che non sia già disponibile (tipo `memoize` usata sotto)
- ...

4.5.5.3 Esempi di creazione/utilizzo di custom

Un semplice decorator Ad esempio supponiamo di avere una funzione che calcoli l'*i*-esimo numero di Fibonacci (con index che partono da 0) in maniera particolarmente inefficiente

```
>>> def fib(n):
...     if n in (0,1):
...         return n
...     else:
...         return fib(n - 1) + fib(n - 2)
...
>>> fib(3)
2
```

per renderla più veloce (specialmente in seguito ad utilizzo ripetuto) utilizziamo la tecnica di *memoization* ovvero salvare risultati parziali in una cache

```
>>> def memoize(f):
...     cache = {}
...     def helper(x):
...         if x not in cache:
...             cache[x] = f(x)
...         return cache[x]
...     return helper
...
```

Per applicare la memoizzazione si farebbe:

```
>>> memoized_fib = memoize(fib)
>>> memoized_fib(3) # ritorna 2
2
```

La funzione `memoize` funge da decoratore della funzione `fib`; come sintassi specifica del python, una volta definita `memoize` potevamo decorare la definizione di `fib` (alternativamente a creare `memoized_fib`) come segue:

```

>>> @memoize
... def fib(n):
...     # Stesso codice di prima
...     if n in (0,1):
...         return n
...     else:
...         return fib(n - 1) + fib(n - 2)
...
>>> fib(3) # memoized
2

```

Decorator multipli I decorator possono essere concatenati, facendo sì che ad una funzione base vengano applicati più decorator contemporaneamente (aggiungendo feature in maniera pulita).

Ad esempio se vogliamo aggiungere sia la memoizzazione che il logging alla funzione `fib` di cui prima, definiamo prima i due decorator `memoize` e `trace`, dopodichè decoriamo la definizione di `fib`

```

>>> def trace(f):
...     def helper(x):
...         call_str = "{0}({1})".format(f.__name__, x)
...         print("Calling {0} ...".format(call_str))
...         result = f(x)
...         print("... returning from {0} = {1}".format( call_str, result))
...         return result
...     return helper
...
>>> @memoize
... @trace
... def fib(n):
...     # stesso codice di prima
...     if n in (0,1):
...         return n
...     else:
...         return fib(n - 1) + fib(n - 2)
...
>>> fib(3)
Calling fib(3) ...
Calling fib(2) ...
Calling fib(1) ...
... returning from fib(1) = 1
Calling fib(0) ...
... returning from fib(0) = 0
... returning from fib(2) = 1
... returning from fib(3) = 2
2
>>> fib(1)
1
>>> fib(4)
Calling fib(4) ...
... returning from fib(4) = 3

```

3

Decorator con parametri I decorator visti sin'ora non si prestano ad essere configurati (ossia ad utilizzare parametri. Il seguente codice

```
@decorator(params)
def func_name():
    ''' Function implementation'''
```

è equivalente a

```
def func_name():
    ''' Function implementation'''

func_name = (decorator(params))(func_name)
```

L'interpretazione avviene da sinistra a destra: viene chiamato il decoratore col suo parametro; questo deve ritornare una funzione (**inner**, di sotto) che elabora la funzione passatagli in sede di chiamata (restituendone una versione modificata **wrapper**).

Un esempio di decoratore con parametro (temporizza il codice, il parametro **n** serve per scegliere il numero di esecuzioni della funzione

```
def timeit(n=1):    # la funzione esterna prende in input i parametri del decoratore
    def inner(f):   # l'intermedia è la funzione utilizzata in chiamata (come in precedenza)
        def wrapper(*args, **kwargs):    # la piu interna i parametri della chiamata
            start_time = _time.perf_counter()
            for i in range(n):
                rval = f(*args, **kwargs)
            stop_time = _time.perf_counter()
            elapsed = stop_time - start_time
            function_name = f.__name__
            msg_start = f"{n} calls of" if n > 1 else "Function"
            msg_end = f" (mean: {elapsed/n:.4f} secs)" if n > 1 else "."
            msg = f"{msg_start} {function_name} [{args=} {kwargs=}] " \
                f"took {elapsed:.2f} secs{msg_end}"
            print(msg)
            return rval
        return wrapper
    return inner

# esempio di utilizzo per temporizzare tre esecuzioni ad ogni chiamata
@timeit(n=3)
def test2():
    time.sleep(2)

test2()
```

4.5.6 Single e multiple dispatch

4.5.6.1 Single dispatch: `functools singledispatch` e `functools singledispatchmethod`

Le funzioni con single dispatch sono tipo le S3 di R, che stabiliscono come comportarsi (evitando `if/elif`) sulla base dell'input fornito.

`singledispatch` Per definire una funzione generica la si decora con `singledispatch` di `functools`.

```
>>> from functools import singledispatch

>>> @singledispatch
... def f(arg, verbose = False):
...     print("Unhandled arg")
...
>>> @f.register
... def _(arg: int, verbose = False):
...     print(arg, "is integer")
...     if verbose:
...         print("f call was verbose too")
...

>>> @f.register
... def _(arg: str, verbose = True):
...     print(arg, "is a string")
...     if verbose:
...         print("f call was verbose too")
...

>>> f(3)
3 is integer
>>> f("foo")
foo is a string
f call was verbose too
>>> f("bar", verbose = False)
bar is a string

>>> ## La definizione si può veder scritta anche come segue, dove il tipo
>>> ## di arg è passato a f.register

>>> @f.register(list)
... def _(arg, verbose = True):
...     print(arg * 2)
...
>>> f([1,2,3])
[1, 2, 3, 1, 2, 3]

>>> ## Si possono registrare lambda e funzioni pre-esistenti utilizzando
>>> ## register in chiamata

>>> def none_dispatch(arg, verbose = False):
...     print("You passed nothing.")
```



```

...
>>> f.register(type(None), none_dispatch)
<function none_dispatch at 0x7fb062b1aac0>

>>> f(None)
You passed nothing.

>>> ## register può essere usata in stack per definire una medesima
>>> ## funzione per diversi tipi, o in combinazione con altri decoratori
>>> ## (es per test indipendenti)

>>> @f.register(int)
... @f.register(float)
... def _(arg, verbose = False):
...     print(arg * 2)
...
>>> f(2)
4
>>> f(3.5)
7.0

>>> ## se passiamo un oggetto non conosciuto dalla funzione ritorna alla
>>> ## base
>>> a_dict = {'planet':'earth', 'region':'europe', 'prefix':39}
>>> f(a_dict)
Unhandled arg

singledispatchmethod  TODO

```

4.5.6.2 Multiple dispatch

Si implementa mediante `multimethod` (dall'omonimo pacchetto) che fornisce decoratori per il multiple dispatch. Un esempio che riproduce il funzionamento di `*` con numeri e stringhe

```

>>> from multimethod import multimethod

>>> @multimethod
... def test(a, b): # default senza specificare il tipo
...     print("boo")
...
>>> @multimethod
... def test(a: int, b: int): # particolarezzando il tipo
...     return a + b
...
>>> @multimethod
... def test(a: str, b: int):
...     return a * b
...
>>> test(2, 3)
5

```

```
>>> test("a", 3)
'aaa'
>>> test("e", "qui")
boo
```

Un esempio nel caso di metodi di una classe, la funzione sceglie il metodo sulla base dei tipi degli attributi dell'oggetto

```
from dataclasses import dataclass
from multimethod import multimethod

@dataclass
class Test:
    x: int|str
    y: int|str|None = None

    def do(self):
        self._dispatch(self.x, self.y)

    @multimethod
    def _dispatch(self, a, b): # default case
        print("dunno")

    @multimethod
    def _dispatch(self, a: int, b: None):
        print("int x none")

    @multimethod
    def _dispatch(self, a: str, b: None):
        print("str x none")

    @multimethod
    def _dispatch(self, a: int, b: str):
        print("int x str")

    @multimethod
    def _dispatch(self, a: str, b: str):
        print("str x str")

    # etc..

## what is printed is always the default case
Test(1).do() # prints int x none
Test("test").do() # prints str x none
Test(1, "test").do() # prints int x str
Test("test", "test").do() # prints str x str
```

4.6 Altri argomenti

4.6.1 atexit

Similmente a `on.exit` di R possiamo registrare funzioni che vengano eseguite prima dell'uscita da una funzione mediante il decoratore `atexit.register`

```
import atexit

# General before exit actions in exit_from_main
@atexit.register
def before_exit_from_main():
    print("Before exiting from main")

def my_fun():
    # function specific act
    @atexit.register
    def before_exit_from_function():
        print("Before exiting from my_fun")

    print("Within my_fun")

print("In main")
my_fun()
```

Che una volta fatto eseguire farà

```
l@ambrogio:~/src/tests/python$ python atexit.py
In main
Within my_fun
Before exiting from my_fun
Before exiting from main
```

Se

- necessario registrare una chiamata ad una funzione con parametri utilizzare esplicitamente `atexit.register`

```
def goodbye(name, adjective):
    print(f'Goodbye {name}, it was {adjective} to meet you.')

atexit.register(goodbye, 'Donny', 'nice')
```

- si registrano più funzioni (es nell'ordine A, B, and C), `atexit` le eseguirà in ordine inverso rispetto alla registrazione (C, B, A).
- necessario togliere una registrazione utilizzare `atexit.unregister`

Capitolo 5

Input/Output

Contents

5.1	File testuali	77
5.1.1	Testo semplice	77
5.1.2	Formati tabulari (csv, tsv)	79
5.1.3	JSON	79
5.2	Formati binari	81
5.2.1	pickle	81
5.3	Accesso al filesystem	82
5.3.1	Ottenere/cambiare directory di lavoro	82
5.3.2	Listing di directory e glob files	82
5.3.3	Creazione/rimozione di file e directory	83
5.3.4	Manipolazione di path e metodi utili	83
5.3.5	Creazione filename temporaneo	85
5.3.6	Uso di file e directory temporanei	85
5.4	File di configurazione	86
5.5	Esecuzione di programmi esterni	86
5.6	Parsing opzioni da linea di comando	88
5.6.1	sys.argv e sys.argv	89
5.6.2	Modulo argparse	89
5.7	Accesso variabili d'ambiente	90

5.1 File testuali

5.1.1 Testo semplice

La funzione `open` prende in input un path e un mode (`r` per la lettura, `w` per la scrittura, `a` per l'append) restituisce un file object, quando si è finito di operare chiamare il metodo `close`:

```
f = open(file = '/tmp/test.txt', mode = 'r')
f.operazioni
f.close()
```

o meglio/più compattamente

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    f.operazioni
```

in questo secondo caso il file viene chiuso automaticamente all'uscita dal blocco anche in caso di eccezioni (warning, error).

È possibile anche utilizzare oggetti `pathlib.Path`, che hanno il metodo `open`:

```
from pathlib import Path
p = Path("/etc/motd")
with p.open() as f:
    lines = f.readlines()
print(lines)
```

5.1.1.1 Lettura

Alcuni metodi:

- `read` legge tutto il file e lo restituisce come stringa. Quando si raggiunge la fine del file, una chiamata successiva a `read` restituisce una stringa vuota

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    whole_file = f.read()
```

- `readline` legge una singola riga; anche qui quando si giunge alla fine del file restituisce una stringa vuota. `readlines` legge tutte le righe e le restituisce come lista

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    lines = f.readlines()
```

- se si vuole processare linea per linea si può ciclare su `f` come segue, dato che il file è un iteratore sulle righe

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    for line in f:
        # process line, es per stampa a video
        print(line)
```

5.1.1.2 Scrittura

Per scrittura su file si può usare `write` o `writelines` a seconda che l'input sia una stringa o una lista di stringhe; (alternativamente `print`

```
# scrittura di stringa (o "...")
with open(file = '/tmp/test.txt', mode = 'w') as f:
    f.write("test") # write restituisce il numero di caratteri scritti
    # print("test", file = f) # alternativamente

# scrittura di una lista di linee
L = ["line1", "line2"]
with open(file = '/tmp/test.txt', mode = 'w') as f:
    f.writelines(L)
```

5.1.2 Formati tabulari (csv, tsv)

Il modulo `csv` contiene le funzioni `reader` e `writer` per leggere formati testuali tabulari di vario tipo (anche separati da tab).

L'apertura/chiusura del file avviene come qualsiasi file di testo, come visto prima.

5.1.2.1 Lettura

Per importare un file e processarlo una riga alla volta `csv.DictReader` restituisce ciascuna riga come dict (altrimenti se può bastare utilizzare `csv.reader` che ritorna una lista)

```
# CSV esempio
#
# dir,repo,link    # attenzione a non lasciare spazi
# ~/.av/, https://lbraglia@bitbucket.org/lbraglia,
# ~/.configs/, https://lbraglia@github.com/lbraglia/.configs, ~/configs/
# ~/.dnd/, https://lbraglia@github.com/lbraglia/.dnd, ~/dnd

import csv
with open('setup.csv') as csvfile:
    reader = csv.DictReader(csvfile)
    for row in reader:
        dir = row['dir']    # attenzione a non lasciare spazi
        repo = row['repo']
        link = row['link']
        ...
```

5.1.2.2 Scrittura

Quello che si fa è creare un writer in cui si impostano le formattazioni di delimitatore, carattere di quoting e così via, per poi utilizzarlo per scrivere le righe. Un esempio con un dataset separato da tab

```
import csv
with open(file = '/tmp/dataset.tab', mode = 'w') as f:
    dataset = csv.writer(f,
                        delimiter = '\t',
                        quotechar = '"',
                        quoting = csv.QUOTE_NONNUMERIC)
    header = ['x', 'y', 'z']
    data = [1, 2, 'a']
    dataset.writerow(header)
    dataset.writerow(data)
```

5.1.3 JSON

L'omonimo modulo `json` di python permette l'interfaccia. Le funzioni principali sono `dump` e `load` per scrivere su file, o `dumps` e `loads` (dump-s) per scrivere e leggere stringhe. Qua vediamo l'interfaccia con i file.

Python	JSON
<code>dict</code>	object
<code>list, tuple</code>	array
<code>str</code>	string
<code>int, float</code>	number
<code>True</code>	true
<code>False</code>	false
<code>None</code>	null

Tabella 5.1: Encoding JSON

JSON	Python
object	<code>dict</code>
array	<code>list</code>
string	<code>str</code>
number (int)	<code>int</code>
number (real)	<code>float</code>
true	<code>True</code>
false	<code>False</code>
null	<code>None</code>

Tabella 5.2: Decoder JSON

5.1.3.1 Scrittura

L'encoding dei tipi base (e loro combinazioni) segue tabella 5.1

```
>>> import json

>>> data = {
...     'name' : ['ACME', "FOO", "BAR"],
...     'shares' : [100, 200, 300],
...     'price' : (321, 9, 8912)
... }

>>> with open("/tmp/data.json", "w") as f:
...     json.dump(data, f)
... 
```

5.1.3.2 Lettura

Il decoding dei tipi di base segue tabella 5.2.

```
>>> with open("/tmp/data.json", "r") as f:
...     data2 = json.load(f)
...
>>> print(data2)
{'name': ['ACME', 'FOO', 'BAR'], 'shares': [100, 200, 300], 'price': [321, 9, 8912]}
```


5.1.3.3 Formati custom

Per tipi di dati più elaborati (es classi custom, numeri complessi) vedere alcuni esempi qui: <https://realpython.com/python-json/>

5.2 Formati binari

5.2.1 pickle

Può salvare in binario qualsiasi struttura dati. Un esempio con un dict contenenti dati di varia natura a seguire.

```
>>> import pickle
>>> import pylbmisc as lb
>>> from pprint import pp

>>> # data to be saved
>>> a_dataset = lb.datasets.load()
>>> original = {i: a_dataset for i in range(2)}
>>> original["asd"] = 34
>>> original["qwe"] = [1, 2, 3]
>>> original["fun"] = lb.datasets.load

>>> # display
>>> pp(original)
{0:      logdose   n  dead
0    1.691   59    6
1    1.724   60   13
2    1.755   62   18
3    1.784   56   28
4    1.811   63   52
5    1.837   59   53
6    1.861   62   61
7    1.884   60  60,
1:      logdose   n  dead
0    1.691   59    6
1    1.724   60   13
2    1.755   62   18
3    1.784   56   28
4    1.811   63   52
5    1.837   59   53
6    1.861   62   61
7    1.884   60  60,
'asd': 34,
'qwe': [1, 2, 3],
'fun': <function load at 0x7fb058572ac0>}

>>> # save
>>> fpath = "/tmp/pickle_test.pkl"
>>> with open(fpath, "ab") as f:
...     pickle.dump(original, f)
```

```

...
>>> # load data
>>> with open(fpath, "rb") as f:
...     the_copy = pickle.load(f)
...
>>> # display the copy
>>> pp(the_copy)
{0:   logdose   n   dead
0    1.691   59     6
1    1.724   60    13
2    1.755   62    18
3    1.784   56    28
4    1.811   63    52
5    1.837   59    53
6    1.861   62    61
7    1.884   60    60,
 1:   logdose   n   dead
0    1.691   59     6
1    1.724   60    13
2    1.755   62    18
3    1.784   56    28
4    1.811   63    52
5    1.837   59    53
6    1.861   62    61
7    1.884   60    60,
  'asd': 34,
  'qwe': [1, 2, 3],
  'fun': <function load at 0x7fb058572ac0>}

```

5.3 Accesso al filesystem

Oggigiorno si usa `pathlib`, per alcune cose marginali rimasto `os` e `shutil`.

```

>>> from pathlib import Path
>>> import os
>>> import shutil

```

5.3.1 Ottenere/cambiare directory di lavoro

```

>>> # ottenere la directory
>>> os.getcwd()           # quick way, otherwise pathlib.Path.cwd()
'/home/l/.sintesi/sintesi_cs'
>>> Path.cwd()
PosixPath('/home/l/.sintesi/sintesi_cs')

>>> # cambio directory
>>> os.chdir('/tmp')

```

5.3.2 Listing di directory e glob files

```

>>> d = Path("/home/l/.sintesi")

```

```
>>> # listing di directory
>>> list(d.iterdir()) # paths del contenuto (iteratore)
[PosixPath('/home/l/.sintesi/sintesi_cs'), PosixPath('/home/l/.sintesi/sintesi_biostat'), PosixPath('/home/l/.sintesi/sintesi_biostat/figlie')]

>>> # glob/matching nome file
>>> pdf1 = sorted(d.glob("*/*.pdf")) # cerca nella sottodirectory figlie
>>> pdf2 = sorted(d.glob("**/*.pdf")) # cerca in tutto l'albero
>>> pdf3 = sorted(d.rglob("*.pdf")) # stessa cosa di sopra ma più compatta
```

5.3.3 Creazione/rimozione di file e directory

```
>>> # Creazione path/file
>>> d = Path('/tmp/barbaz/whahaa/yeah')

>>> # Creazione directory
>>> d.mkdir(parents = True) # parents se vogliamo creare tutto l'albero

>>> # creazione in maniera safe
>>> try:
...     d.mkdir(parents = True)
... except FileExistsError:
...     pass
...

>>> # Rimozione directory con tutto il contenuto
>>> rm = Path('/tmp/barbaz')
>>> # rm.rmdir() # errore: cartella deve essere vuota...
>>> shutil.rmtree(rm) # vedere dopo per shutil

>>> # Creazione rimozione di file
>>> f = Path('/tmp/asdomar.txt')
>>> f.touch()
>>> f.unlink()
```

5.3.4 Manipolazione di path e metodi utili

```
>>> f = Path("/usr/bin/python")
>>> d = Path("~/sintesi")
>>> f2 = Path("/etc/apt/sources.list")
>>> f3 = Path("Makefile")
>>> subdir = "sintesi_cs"

>>> ## questi path possono esser usati dove è accettato un os.PathLike
>>> ## alternativamente per ottenere la rappresentazione in stringa

>>> str(d)
'~/sintesi'
>>> str(f)
'/usr/bin/python'
```

```

>>> # sostituire la tilde per l'amor del cielo in paths
>>> de = d.expanduser()

>>> # test esistenza
>>> f.exists()
True
>>> d.exists() # attenzione a ~
False
>>> de.exists()
True

>>> # test tipologia
>>> f.is_file()
True
>>> d.is_dir() # attenzione a ~
False
>>> de.is_dir()
True

>>> # links
>>> f.is_symlink()
True
>>> f.readlink() # follow just one redirection
PosixPath('python3')
>>> os.path.realpath(f) # follow all redirections
'/usr/bin/python3.13'

>>> # estrarre parti di un path
>>> f2.name # nome file
'sources.list'
>>> f2.stem # nome file senza estensione
'sources'
>>> f2.suffix # estensione - per tar.gz usare suffixes
'.list'

>>> # controllare l'estensione (mediante glob)
>>> f2.match("*.list")
True

>>> # creazione di path mediante modifica di esistente
>>> d / subdir # concatenazione, alternativamente d.joinpath(subdir)
PosixPath('~/.sintesi/sintesi_cs')
>>> f.with_name("foo.list") # nome cambiato
PosixPath('/usr/bin/foo.list')
>>> f.with_stem("ssd") # stem cambiato, stessa estensione
PosixPath('/usr/bin/ssd')
>>> f.with_suffix(".deb") # estensione cambiata, stesso stem
PosixPath('/usr/bin/python.deb')
>>> f2.relative_to("/etc") # path relativo, escludendo quanto passato
PosixPath('apt/sources.list')
>>> f3.absolute() # crea l'assoluto a partire da un relativo

```

```
PosixPath('/tmp/Makefile')
>>> f3.resolve() # stessa cosa ma fixa anche symlink
PosixPath('/tmp/Makefile')
```

5.3.5 Creazione filename temporaneo

Questo crea anche il file e non lo elimina alla fine (di default lo crea in /tmp quindi viene). Si può però utilizzare il nome in un secondo momento scrivendo sul file.

```
import tempfile
tempfile = tempfile.mkstemp()
fname = tempfile[1]
```

5.3.6 Uso di file e directory temporanei

```
>>> from tempfile import TemporaryFile
>>> from tempfile import TemporaryDirectory

>>> # File
>>> # ----
>>> with TemporaryFile('w+t') as f:
...     f.write("Hello World\n")
...     f.write("Testing\n")
...     # ritorna ad inizio file e leggi quanto scritto
...     f.seek(0)
...     data = f.read()
...
12
8
0
>>> # qui il file non c'è più ma ..
>>> data
'Hello World\nTesting\n'

>>> # Directory
>>> # -----
>>> with TemporaryDirectory() as dirname:
...     print("dirname is: ", dirname)
...     ## use the directory
...
dirname is: /tmp/tmpe878va19
>>> # qui directory e suo contenuto non c'è più
```

Il mode è `w+t` per il testo o `w+b` per binario: si è posto 'w' per permettere sia lettura che scrittura che è utile qua, dato che chiudere il file implicherebbe distruggerlo.

5.4 File di configurazione

Per la scrittura di file `.ini` utilizzare la libreria `configparser`. Se interessa solo la lettura allo stato attuale è disponibile anche `tomllib` per i file `toml` che sono una evoluzione degli `.ini`

```
import configparser

# Scrittura
data = {
    'customer': "ajeje",
    'acronym': "brazorv",
    'title': "un titolo",
    'created': "2020-01-01",
    'url': "lbraglia.altervista.org"
}
fpath = "/tmp/asd.ini"
configs = configparser.ConfigParser()
configs["project"] = data # project è la sezione del file .ini
with open(fpath, 'w') as f:
    configs.write(f)

# Lettura
configs = configparser.ConfigParser()
configs.read(fpath)
print(configs["project"]["url"])

# modifica
configs["project"]["url"] = "lbraglia.github.io"
```

5.5 Esecuzione di programmi esterni

Si usa la library `subprocess`:

- se si vuole **attendere il termine del processo** utilizzare `run` (funzione di convenienza consigliata). Si specificano eventuali comandi composti da più token come lista

```
>>> import subprocess

>>> # Comandi semplici (prendi in input da comando esterno)
>>> # -----

>>> # eseguire un comando senza prendere risultati in input
>>> # in caso di parametri del comando dare una lista ["ls", "-l"]
>>> cmd = "ls -l -a -r -t"
>>> rval = subprocess.run(cmd.split(" ")) # risultati stampati a video
>>> rval # ma non disponibili nell'output
CompletedProcess(args=['ls', '-l', '-a', '-r', '-t'], returncode=0)

>>> # salvando risultati (e standard error) in formato testuale
```

```
>>> child = subprocess.run(["ls"], capture_output=True, text=True)
>>> child.returncode
0
>>> child.stdout.split("\n")
['asd.ini', 'babel-stable-853', 'babel-vYBOVI', 'data.json', 'fig_broadcasting.pdf', 'org.
>>> child.stderr
''
```

- **altrimenti Popen** (classe più generale). La classe `subprocess.Popen` class rappresenta un processo esterno quando la si istanzia si sta lanciando un programma esterno.

```
cmd = subprocess.Popen(cmd_list, stdin=None, stdout=None, stderr=None, shell=False)
```

dove

- **args**: This is a list or a string specifying the command to be executed. If it's a list, the first element is the program name, and the subsequent elements are the arguments. If it's a string, the shell argument must be set to `True` (but this has security implications, as we'll discuss later).
- **stdin, stdout, stderr**: These arguments are used to specify how the input, output, and error streams of the external process should be handled. By default, they are set to `None`, which means they inherit the parent process's settings. Use `subprocess.PIPE` per mandarli in pipe. In particolare `stdin=subprocess.PIPE` lets us send input data. `stdout=subprocess.PIPE` captures the output.
- **text=True** means inputs and outputs are treated as strings, not bytes.
- **shell**: When set to `True`, the command is executed through the shell. This can be useful for running complex shell commands but is less secure.
- **cwd**: setta la cwd del processo
- **env**: setta environment variables

Di default non attende il ritorno del figlio; si può attendere se chiamiamo il metodo `communicate`.

Alcuni esempi Per replicare `subprocess.run` di sopra

```
>>> ls = subprocess.Popen(["ls"],
...                         stdout=subprocess.PIPE,
...                         stderr=subprocess.PIPE,
...                         text=True)
>>> output, err = ls.communicate()
>>> output
'asd.ini\nbabel-stable-853\nbabel-vYBOVI\ndata.json\nfig_broadcasting.pdf\norg.chromium.Ch

>>> ls = subprocess.Popen(["ls", "/nonexistentdir"],
...                         stdout=subprocess.PIPE,
...                         stderr=subprocess.PIPE,
```

```
...                               text=True)
>>> output, err = ls.communicate()
>>> err
"ls: impossibile accedere a '/nonexistentdir': File o directory non esistente\n"
```

Per inviare input ad un programma esterno a python e riprenderne l'output

```
>>> text_input = "first line\nsecond line"
>>> nl = subprocess.Popen(["nl"],
...                         stdin=subprocess.PIPE,
...                         stdout=subprocess.PIPE,
...                         text=True)
>>> output, err = nl.communicate(input=text_input)
>>> output # le linee a cui è stato aggiunto il numerino da nl
'      1\tfirst line\n      2\tsecond line\n'
```

Per concatenare programmi esterni cerchiamo di creare `ls | nl | python` e prendere in input il risultato

```
>>> # ls non prende in input da nulla e butta nel pipe
>>> ls = subprocess.Popen(["ls"], stdout=subprocess.PIPE, text=True)
>>> # nl prende in input da ls e butta nel pipe
>>> nl = subprocess.Popen(["nl"], stdin=ls.stdout, stdout=subprocess.PIPE, text=True)
>>> ls.stdout.close() # di a ls di terminare
>>> output, err = nl.communicate() # e ad nl di fare il suo
>>> output.split("\n")
['      1\tasd.ini', '      2\tbabel-stable-853', '      3\tbabel-vYBOVI', '      4\t'
```

Per dare input con python e concatenare programmi esterni `python lista parole | sort | nl | python`

```
>>> # ls non prende in input da nulla e butta nel pipe
>>> sort = subprocess.Popen(["sort"],
...                           stdin=subprocess.PIPE,
...                           stdout=subprocess.PIPE,
...                           text=True)
>>> nl = subprocess.Popen(["nl"], stdin=sort.stdout, stdout=subprocess.PIPE,
...                           text=True)
>>> sort.stdin.write("a\nx\nb\nz\nc")
9
>>> sort.stdin.close()
>>> output, err = nl.communicate()
>>> output.split("\n")
['      1\ta', '      2\tb', '      3\tc', '      4\tx', '      5\tz', '']
```

5.6 Parsing opzioni da linea di comando

Mi sono fatto anche `pylbnmisc.utils.argparser` (basato su `argparse`) ma per la roba più rapida sotto basta e avanza.

5.6.1 `sys.argv` e `sys.argv`

Nel template

```
#!/usr/bin/env python3
import sys

print(sys.argv)
```

Per la chiamata senza parametri

```
l0m740n:~/pytests$ ./argparse_sysargv
['./argparse_sysargv']

l0m740n:~/pytests$ python argparse_sysargv
['argparse_sysargv']
```

Per la chiamata con parametri

```
l0m740n:~/pytests$ ./argparse_sysargv asd foo bar baz
['./argparse_sysargv', 'asd', 'foo', 'bar', 'baz']

l0m740n:~/pytests$ python argparse_sysargv asd foo bar baz
['argparse_sysargv', 'asd', 'foo', 'bar', 'baz']
```

5.6.2 Modulo `argparse`

Una dimostrazione veloce, per approfondimenti vedere la documentazione. Sia il template

```
#!/usr/bin/env python3
import argparse

parser = argparse.ArgumentParser()
parser.add_argument("infile")
parser.add_argument("outfile")
args = parser.parse_args()
print(args)
print(args.infile)
print(args.outfile)
```

Per l'invocazione senza argomenti da errore (sono attesi)

```
l0m740n:~/pytests$ ./argparse_tests
usage: argparse_tests [-h] infile outfile
argparse_tests: error: the following arguments are required: infile, outfile

l0m740n:~/pytests$ python argparse_tests
usage: argparse_tests [-h] infile outfile
argparse_tests: error: the following arguments are required: infile, outfile
```

Per l'invocazione con parametri

```
l@m740n:~/pytests$ ./argparse_tests asd foo
Namespace(infile='asd', outfile='foo')
asd
foo
```

```
l@m740n:~/pytests$ python argparse_tests asd foo
Namespace(infile='asd', outfile='foo')
asd
foo
```

5.7 Accesso variabili d'ambiente

Si usa `os.environ`. Se adottiamo un template

```
#!/usr/bin/python

import os

# print(os.environ) # un po too much
print(os.environ["SHELL"])
print(os.environ["BROWSER"])

# roba settata al volo
p1 = int(os.environ["PARAM1"])
p2 = int(os.environ["PARAM2"])
print(p1 + p2)
```

Si ha

```
l@m740n:~/pytests$ export PARAM1=1; export PARAM2=2 ; python envvars.py
/bin/bash
librewolf
3
```

Capitolo 6

Object Oriented Programming

Contents

6.1	Classi	91
6.1.1	Definizione e scoping	91
6.1.2	Metodi	93
6.1.3	Condivisione dati	93
6.1.4	Data hiding	94
6.2	Ereditarietà	95
6.2.1	Singola	95
6.2.2	Multipia	95
6.3	Classi notevoli	96
6.3.1	<code>dataclass</code>	96
6.3.2	Iteratori	98
6.3.3	Context Managers	105

6.1 Classi

L'implementazione della programmazione ad oggetti si basa su trick di scope (cfr sezione 4.3).

La definizione di una classe semplicemente pone un altro namespace all'interno di quello nel quale ci si trova.

6.1.1 Definizione e scoping

La definizione di una classe fa uso di:

- `class` associato ad un nome;
- una stringa di documentazione opzionale
- vari `statement` di assegnazione di variabili/definizione di funzioni (con una sintassi particolare, i *metodi* della classe)

```
class NomeClasse:
    """
    Documentation
    """
    <statement-1>
    .
    .
    .
    <statement-N>
```

Una volta valutata la definizione viene creato un *oggetto classe*, ossia un *namespace* contenuto in quello dove è stato definito, che supporta supporta due cose:

1. riferirsi ai suoi attributi in lettura o scrittura (nel Python una classe può esser modificata dopo che è stata creata);
2. creare oggetti usando il nome della classe come se fosse una funzione: così facendo si creano *oggetti istanza*.
3. **scoping**: una volta istanziato un oggetto, la ricerca dei entro una classe (a parte le variabili locali ad un metodo) continua nel modulo dove la classe è definita (sia esso `__main__` o importato).

```
>>> b = "ciao"
```

```
>>> # definizione di classe
```

```
>>> class firstClass:
...     """La mia prima classe"""
...     a = 0
...     b = "miao"
...     def get_a(self):
...         return self.a
...     def set_a(self, x):
...         self.a = x
...     def test_scoping(self):
...         print(b)
... 
```

```
>>> firstClass.a = 1          ## modifica di un attributo di una classe, volendo
```

```
>>> print(firstClass.__doc__) ## stampa la docstring della classe
```

```
La mia prima classe
```

```
>>> x = firstClass()          ## istanziamento usando il costruttore di default
```

```
>>> x.a                        ## nulla impedisce di accedere direttamente
```

```
1
```

```
>>> x.get_a()
```

```
1
```

```
>>> x.set_a(3)
```

```
>>> x.get_a()
```

```
3
```

```
>>> x.test_scoping()          # "ciao", non "miao" (per questo avremmo dovuto self.b)
```

```
ciao
```

6.1.2 Metodi

6.1.2.1 Definizione e chiamata

I metodi di una classe presentano una definizione particolare:

- il primo argomento serve per riferirsi all'oggetto istanziato: il nome `self` è arbitrario ma preferibile (standard);
- gli altri sono parametri normali da passare in chiamata del metodo

In sede di chiamata poi:

- `object.function()` è equivalente a chiamare `classe.function(object)`
- chiamare `object.function(x, y, z)` equivale a `classe.function(object, x, y, z)`

6.1.2.2 Costruttore custom

Se si desidera specificare un costruttore custom diverso da quello di default, si definisce una funzione di nome `__init__` che si occupa di inizializzare i valori (nel quale abbiamo messo anche inizializzatori di default):

```
>>> class Complex:
...     def __init__(self, realpart = 0, imagpart = 0):
...         self.r = realpart
...         self.i = imagpart
...     def value(self):
...         return('' + str(self.r) + '+' + str(self.i) + 'i')
...
>>> x = Complex()
>>> x.value()
'0+0i'
>>> y = Complex(1, 2)
>>> y.value()
'1+2i'
```

6.1.3 Condivisione dati

I dati di una classe iniziano ad esistere dal momento in cui vengono assegnati, sia ciò in definizione della classe o usando un metodo nell'oggetto istanza. Pertanto:

- gli argomenti **inizializzati nella definizione della classe** sono *comuni* a tutti gli oggetti generati;
- gli argomenti **inizializzati mediante un metodo** sono *caratteristici* dell'oggetto istanziato.

```
>>> class Dog:
...     kind = 'canine'          # class variable shared by all instances
...     def __init__(self, name):
...         self.name = name    # instance variable unique to each instance
...
>>> d = Dog('Fido')
```

```
>>> e = Dog('Buddy')
>>> d.kind                # shared by all dogs
'canine'
>>> e.kind                # shared by all dogs
'canine'
>>> d.name                # unique to d
'Fido'
>>> e.name                # unique to e
'Buddy'
```

Attenzione a quando come *dato di classe* vi è un *tipo mutabile*: la chiamata di metodi da diverse istanze andrà a modificare un dato comune (e non è spesso quello che si vuole).

```
>>> class Dog:
...     tricks = []                # Sbagliato: questo sarà condiviso da tutti i ca
...     def __init__(self, name):
...         self.name = name
...     def add_trick(self, trick):
...         self.tricks.append(trick)
...
>>> d = Dog('Fido')
>>> e = Dog('Buddy')
>>> d.add_trick('roll over')
>>> e.add_trick('play dead')
>>> d.tricks
['roll over', 'play dead']
```

```
>>> class Dog:                    # Versione corretta
...     def __init__(self, name):
...         self.name = name
...         self.tricks = []      # ok
...     def add_trick(self, trick):
...         self.tricks.append(trick)
...
>>> d = Dog('Fido')
>>> e = Dog('Buddy')
>>> d.add_trick('roll over')
>>> e.add_trick('play dead')
>>> d.tricks
['roll over']
>>> e.tricks
['play dead']
```

6.1.4 Data hiding

Nel Python

- non vi è un concetto di *data hiding*; di un oggetto istanziato si può accedere ai valori/funzioni senza problemi

- se si desidera **celare un elemento** gli si può dare un nome che inizi con “_” (cose che dovrebbero essere considerate come “private”)
- per **incrementare la celatura**, se si da un nome che inizia con __, viene preceduto dal nome della classe ed underscore, come segue (*name mangling*):

```
>>> class Asd:
...     __a = 0  ## nome della variabile più due underscore
...
>>> foo = Asd()
>>> foo._Asd__a  ## accediamo ad a comunque, ma è faticoso farlo
0
```

6.2 Ereditarietà

6.2.1 Singola

Si ha che:

- la sintassi per definire una classe che eredita da un'altra è

```
class NomeClasseDerivata(NomeClasseBase):
    <statement-1>
    .
    .
    .
    <statement-N>
```

- nella ricerca nomi, nel caso nel caso non vengano trovati nella classe derivata si procederà nella classe base (e ricorsivamente nelle classi ad essa base);
- le classi derivate possono *specializzare i metodi*, ridefinendoli con il medesimo nome della classe base.

6.2.2 Multipla

- la definizione avviene come segue:

```
class DerivedClassName(Base1, Base2, Base3):
    <statement-1>
    .
    .
    .
    <statement-N>
```

- la classe eredita da tutte e tre le classi di base;
- la risoluzione di nomi funziona prima in profondità per **Base1** (cercando anche nelle classi dalle quali questa eredita), poi passando a **Base2** (e quindi in profondità) e a **Base3**(e in profondità), evitando di cercare due volte nella stessa classe se vi sono sovrapposizioni nell'albero genealogico.

6.3 Classi notevoli

6.3.1 dataclass

Il modulo `dataclasses` fornisce un decoratore da utilizzare con le classi che vogliamo battezzare come `dataclass`

```
from dataclasses import dataclass

@dataclass
class InventoryItem:
    """Class for keeping track of an item in inventory."""
    name: str
    unit_price: float
    quantity_on_hand: int = 0

    def total_cost(self) -> float:
        return self.unit_price * self.quantity_on_hand
```

Quello che questo decoratore fa è aggiungere un iniziatore di default del tipo seguente, senza bisogno di specificarlo,

```
def __init__(self, name: str, unit_price: float, quantity_on_hand: int = 0):
    self.name = name
    self.unit_price = unit_price
    self.quantity_on_hand = quantity_on_hand
```

La `dataclass` aggiunge anche una `__repr__` gratuita per la stampa dei dati dell'oggetto (specificare `repr=False` nella funzione `field` esclude il dato dalla stampa)

6.3.1.1 field: dati mutabili, valori default, parametri

Se occorre specificare dati mutabili a livello di singola istanza (non condivisi) tra tutti gli oggetti di una determinata classe bisogna utilizzare `field` specificando la funzione utilizzata per creare l'istanza. Ad esempio se vogliamo un campo indirizzi email (lista di stringhe) che non sia condiviso tra tutti gli oggetti della classe dobbiamo programmare qualcosa del genere

```
from dataclasses import dataclass
from dataclasses import field

@dataclass
class Person:
    name: str
    address: str
    # email_addresses = [] # condiviso e sbagliato
    email_addresses: list[str] = field(default_factory=list)
```

```
l = Person(name = "Luca", address = "Via XYZ")
```

`field` e `default_factory` possono essere utilizzate per specificare una funzione che crea il valore assegnato di default se l'utente non specifica in chiamata, quindi ha anche altre applicazioni. Nel seguito la generazione di un id casuale


```

import random
import string

from dataclasses import dataclass
from dataclasses import field

# genera un id casuale
def generate_id() -> str:
    return "".join(random.choices(string.ascii_uppercase, k=12))

@dataclass
class Person:
    name: str
    address: str
    email_addresses: list[str] = field(default_factory=list)
    id: str = field(default_factory=generate_id)

```

Se si desidera che un parametro sia impostato ad un valore di default ma che non possa essere scelto dall'utente in chiamata si specifica `init=False` in `field`. Ad esempio per far sì che l'utente non possa scegliere l'id ma che questo sia generato da una funzione

```

@dataclass
class Person:
    name: str
    address: str
    email_addresses: list[str] = field(default_factory=list)
    id: str = field(init=False, default_factory=generate_id)

# questo da errore
l = Person(name="Luca", address="asd", id="foo")

```

Infine `field` accetta:

- un valore di default (utilizzato se l'utente non può o non vuole fornire in inizializzazione) con `default` (es `default=0` per un bank account saldo iniziale)
- `compare` (di default a `True`) che specifica se l'attributo è utilizzato nella comparazione (es per stabilire l'uguaglianza) o meno

6.3.1.2 Eseguire codice post inizializzazione: `post_init`

Se vogliamo eseguire del codice automaticamente post inizializzazione (es generare dati o inizializzare) definiamo la funzione `__post_init__` che verrà eseguita come nome succede. Ad esempio per creare una stringa per la ricerca a partire dai dati forniti in inizializzazione

```

class Person:
    name: str
    address: str
    email_addresses: list[str] = field(default_factory=list)
    id: str = field(init=False, default_factory=generate_id)

```

```

search_string: str = field(init=False) # stringa che non può essere

def __post_init__(self) -> None:
    self.search_string = f"{self.name} {self.address}"

```

6.3.1.3 Freezing di una dataclass

Significa impostarla che una volta inizializzata i suoi dati non possano essere modificati (es mediante semplice assegnazione)

```

@dataclass(frozen=True)
class Person:
    name: str
    address: str
    ...

l = Person(...)
l.name = "foo" # da errore

```

Ocio che anche i `post_init` falliranno se come sopra assegnano alla classe

6.3.1.4 Altri parametri utili del decoratore

Oltre a `frozen` vi sono altri parametri interessanti per il decoratore:

- `kw_only=True` in inizializzazione bisognerà specificare per esteso nome = valore e non verrà accettato il valore associato alla posizione della chiamata
- con `match_arg=False` si disabilita il structural pattern matching (uso con `match`) abilitato di default
- `slots=True`: sotto la scocca una dataclass è un dizionario molto avanzato. Se si abilita `slot` vi è un accesso molto più rapido e di base (miglioramenti del 20% a seconda dei casi). Non si usa di default perché `slots` rompe tutto quando si usa ereditarietà multipla, es quanto segue non funziona perché non si possono sommare dataclass basate su `slots`:

```

@dataclass(slots=True)
class Person:
    name: str
    address: str
    email: str

@dataclass(slots=True)
class Employee:
    dept: str

class Worker(Person, Employee):
    pass

```

6.3.2 Iterator

Il `for` del python è molto conciso e flessibile, si pensi a:

```

>>> List = [1, 2, 3]
>>> Set = (1, 2, 3)
>>> Dict = {'one': 1, 'two': 2}
>>> String = "asd"

>>> for element in List:
...     print(element)
...
1
2
3
>>> for element in Set:
...     print(element)
...
1
2
3
>>> for key in Dict:
...     print(key)
...
one
two
>>> for char in String:
...     print(char)
...
a
s
d

```

Quello che lo rende flessibile è il fatto di gestire in maniera standard quelli che in Python sono chiamati iterabili, ossia oggetti passibili di iterazione.

6.3.2.1 Funzionamento

Si ha che:

- *iterabile* è un oggetto che presenta un metodo `__iter__`, il quale restituisce un iteratore, oggetto che rappresenta un flusso di dati dell'iterabile considerato;
- un *iteratore* è un oggetto che rappresenta un flusso di dati e mediante il metodo `__next__` li ritorna un elemento alla volta (oppure ritorna `StopIteration` se non ve ne sono altri).

Ora vi sono due funzioni di utilità che servono per implementare il protocollo del `for`:

- `iter` prende in input un oggetto arbitrario e cerca di restituire un iteratore sui suoi dati (chiamando `__iter__`), oppure `TypeError` se non possibile;
- sull'iteratore possiamo utilizzare `next` (che chiama il `__next__`)

```

>>> s = 'abc'

```

```

>>> it = iter(s)
>>> it
<str_ascii_iterator object at 0x7fb062c96740>
>>> next(it)
'a'
>>> next(it)
'b'
>>> next(it)
'c'
>>> next(it)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
StopIteration

>>> iter(123) # questo da errore perché un intero non è iterabile
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'int' object is not iterable

```

Quindi complessivamente, lo statement `for`:

1. chiama innanzitutto `iter()` sull'oggetto che è in ciclo (il contenitore) ottenendone un iteratore;
2. chiama via via `next()` sull'iteratore permettendo così il processo di iterazione;
3. quando non vi sono altri elementi sui quali iterare, `next()` solleva l'eccezione `StopIteration` e `for` termina.

6.3.2.2 Implementazione mediante classe

Spesso si vuole creare classi/strutture di dati che siano iterabili; per farlo occorre:

- definire una classe con metodo `__iter__` (iterabile) che ritorni un oggetto con un metodo `__next__` senza parametri (rendendo l'oggetto ritornato un iteratore).
- caso classico: una classe ha sia `__next__` che `__iter__`. In tal caso è sufficiente che `__iter__` ritorni `self`.

```

>>> class Reverse:
...     """Iterator for looping over a sequence backwards."""
...     def __init__(self, data):
...         self.data = data
...         self.index = len(data)
...     def __iter__(self):
...         return self
...     def __next__(self):
...         if self.index == 0:
...             raise StopIteration
...         self.index = self.index - 1

```

```

...         return self.data[self.index]
...
>>> for char in Reverse('spam'):
...     print(char)
...
m
a
p
s

```

6.3.2.3 Implementazione mediante espressioni generatrici

Generatori semplici possono essere ottenuti mediante le espressioni generatrici, espressioni poste tra tonde (invece che quadre) che utilizzano una sintassi simile alle list comprehension. Alcuni esempi:

```

>>> squares = ((i*i for i in range(10)))
>>> type(squares)
<class 'generator'>
>>> sum(squares)
285

>>> data = 'golf'
>>> reversed = (data[i] for i in range(len(data) - 1, -1, -1))
>>> list(reversed)
['f', 'l', 'o', 'g']

```

Alcuni confronti:

- le espressioni generatrici sono compatte ma meno versatili rispetto alla definizione di un generatore
- rispetto a una list comprehension, le espressioni generatrici ritornano un iteratore che calcola il valore al bisogno; le list comprehension sono inutili o meno efficienti se si lavora con iteratori che ritornano uno stream infinito di valori o un numero molto alto

6.3.2.4 Implementazione mediante generatori

I generatori sono funzioni che creano degli iteratori:

- l'unica differenza dalle funzioni classiche è che usano `yield` quando vogliono ritornare dei dati;
- tutto quello che è possibile fare mediante la definizione di iteratori mediante classi è possibile farlo anche con i generatori; quello che rende questi ultimi interessanti è il fatto che i metodi `__iter__` e `__next__` sono generati automaticamente e complessivamente la programmazione è molto più chiara/compatta.

```

>>> def reverse(data):
...     for index in range(len(data) - 1, -1, -1):
...         yield data[index]

```

```

...
>>> # crea un iterabile e iteratore, ossia un oggetto che ha sia iter che next
>>> r = reverse('golf')
>>> r.__iter__
<method-wrapper '__iter__' of generator object at 0x7fb039398ba0>
>>> r.__next__
<method-wrapper '__next__' of generator object at 0x7fb039398ba0>

>>> for char in r:
...     print(char, end = ' ')
...
f l o g

```

Vediamo la differenza di funzionamento rispetto a una funzione classica:

- nel chiamare una funzione classica viene creato un namespace che contiene i dati e al `return` questo viene distrutto; una chiamata successiva alla stessa riparte con un namespace nuovo. I generatori possono essere pensati come funzioni dove il namespace non viene gettato all'uscita ma è disponibile alla successiva chiamata
- alla chiamata un generatore non ritorna un singolo valore: invece ritorna un oggetto generatore che supporta il protocollo degli iteratori. Quando si esegue `yield` il generatore restituisce l'espressione, ma a differenza di `return` l'esecuzione della funzione si sospende e le variabili locali sono preservate; alla prossima chiamata di `__next__` la funzione riprenderà l'esecuzione da capo.

6.3.2.5 Funzioni e operatori utili su iteratori

Funzioni Alcune funzioni builtin:

- su iteratori con dati logici `all` e `any` ritornano `True` rispettivamente se tutti gli elementi sono `True` o almeno uno lo è
- su iteratori con dati confrontabili, `max`, `min` ritornano l'elemento maggiore o minore, `sorted` ordina l'iteratore
- `enumerate` restituisce un oggetto involucro con un id progressivo
- `zip` prende in input più iterabili e restituisce un iteratore che genera tuple con un elemento di ciascun oggetto di partenza alla volta. Nel caso gli iterabili abbiano lunghezza diversa verrà prodotto
- per la programmazione funzionale sono utili `filter`, `map`

```

>>> all([True, True])
True
>>> any([False, False])
False
>>> max([1, 2, 10])
10

```

```
>>> A = [1,2,3]
>>> B = "letters"

>>> for a, b in zip(A, B):
...     print(a, b)
...
1 1
2 e
3 t
```

Operatori `in` e `not in`: la sintassi `X in iterator` ritorna `True` se `X` è ritrovato nell'iteratore

6.3.2.6 Il modulo `itertools`

Contiene funzioni per la creazione e gestione di iteratori

Creazione di nuovi iteratori

```
itertools.count()          ## 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, ...
itertools.cycle([1, 2, 3, 4, 5]) ## 1, 2, 3, 4, 5, 1, 2, 3, 4, 5 ...
itertools.repeat('abc')    ## abc, abc, abc, abc, abc, abc ...
itertools.chain(['a', 'b', 'c'], (1, 2, 3)) ## a, b, c, 1, 2, 3
itertools.islice(range(10), 2, 8) ## 2, 3, 4, 5, 6, 7
```

Selezione

```
itertools.filterfalse(predicate, iterable)
```

Crea un iteratore che elimina elementi da un iterabile laddove un predicato ad essi applicato è falso. Lo applichiamo ad una lista come esempio:

```
>>> import itertools

>>> def selector(x):
...     return x < 5
...
>>> res = itertools.filterfalse(selector, [1, 4, 6, 4, 1])
>>> list(res)
[6]
```

```
itertools.compress(data, selectors)
```

crea un iteratore che filtra gli elementi di `data` ritornando solo quelli che valuno `True` in `selectors`

```
>>> res = itertools.compress('ABCDEF', [1,0,1,0,1,1])
>>> list(res)
['A', 'C', 'E', 'F']
```

Grouping Vediamo:

```
itertools.groupby(iter, key_func = None)
```

si ha:

- `iter` un iterabile
- `key_func` è una funzione che restituisce un id per ogni elemento dell'iterabile

`groupby`

- assume che il contenuto di `iter` sia ordinato per chiave
- mette assieme tutti gli elements dell'iterable con stessa chiave, e ritorna uno stream di tuple di due elementi, con primo elemento la chiave e secondo elemento l'iteratore su tutti gli elementi con tale chiave

```
city_list = [('Decatur', 'AL'), ('Huntsville', 'AL'), ('Selma', 'AL'),
             ('Anchorage', 'AK'), ('Nome', 'AK'),
             ('Flagstaff', 'AZ'), ('Phoenix', 'AZ'), ('Tucson', 'AZ'),
             ...
            ]
```

```
def get_state(city_state):
    return city_state[1]
```

```
itertools.groupby(city_list, get_state) =>
('AL', iterator-1),
('AK', iterator-2),
('AZ', iterator-3), ...
```

where

```
iterator-1 =>
('Decatur', 'AL'), ('Huntsville', 'AL'), ('Selma', 'AL')
iterator-2 =>
('Anchorage', 'AK'), ('Nome', 'AK')
iterator-3 =>
('Flagstaff', 'AZ'), ('Phoenix', 'AZ'), ('Tucson', 'AZ')
```

Combinazioni e permutazioni

```
>>> list(itertools.combinations([1, 2, 3, 4, 5], 2))
[(1, 2), (1, 3), (1, 4), (1, 5), (2, 3), (2, 4), (2, 5), (3, 4), (3, 5), (4, 5)]
>>> list(itertools.combinations_with_replacement([1, 2, 3, 4, 5], 2))
[(1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (2, 2), (2, 3), (2, 4), (2, 5), (3, 3), (3, 4), (3, 5), (4, 4), (4, 5), (5, 5)]
>>> list(itertools.permutations([1, 2, 3, 4, 5]))
[(1, 2, 3, 4, 5), (1, 2, 3, 5, 4), (1, 2, 4, 3, 5), (1, 2, 4, 5, 3), (1, 2, 5, 3, 4), (1, 2, 5, 4, 3), (1, 3, 2, 4, 5), (1, 3, 2, 5, 4), (1, 3, 4, 2, 5), (1, 3, 4, 5, 2), (1, 3, 5, 2, 4), (1, 3, 5, 4, 2), (1, 4, 2, 3, 5), (1, 4, 2, 5, 3), (1, 4, 3, 2, 5), (1, 4, 3, 5, 2), (1, 4, 5, 2, 3), (1, 4, 5, 3, 2), (1, 5, 2, 3, 4), (1, 5, 2, 4, 3), (1, 5, 3, 2, 4), (1, 5, 3, 4, 2), (1, 5, 4, 2, 3), (1, 5, 4, 3, 2), (2, 1, 3, 4, 5), (2, 1, 3, 5, 4), (2, 1, 4, 3, 5), (2, 1, 4, 5, 3), (2, 1, 5, 3, 4), (2, 1, 5, 4, 3), (2, 3, 1, 4, 5), (2, 3, 1, 5, 4), (2, 3, 4, 1, 5), (2, 3, 4, 5, 1), (2, 3, 5, 1, 4), (2, 3, 5, 4, 1), (2, 4, 1, 3, 5), (2, 4, 1, 5, 3), (2, 4, 3, 1, 5), (2, 4, 3, 5, 1), (2, 4, 5, 1, 3), (2, 4, 5, 3, 1), (2, 5, 1, 3, 4), (2, 5, 1, 4, 3), (2, 5, 3, 1, 4), (2, 5, 3, 4, 1), (2, 5, 4, 1, 3), (2, 5, 4, 3, 1), (3, 1, 2, 4, 5), (3, 1, 2, 5, 4), (3, 1, 4, 2, 5), (3, 1, 4, 5, 2), (3, 1, 5, 2, 4), (3, 1, 5, 4, 2), (3, 2, 1, 3, 5), (3, 2, 1, 5, 4), (3, 2, 3, 4, 5), (3, 2, 3, 5, 4), (3, 2, 4, 3, 5), (3, 2, 4, 5, 3), (3, 2, 5, 3, 4), (3, 2, 5, 4, 3), (3, 3, 1, 4, 5), (3, 3, 1, 5, 4), (3, 3, 4, 2, 5), (3, 3, 4, 5, 2), (3, 3, 5, 2, 4), (3, 3, 5, 4, 2), (3, 4, 1, 2, 5), (3, 4, 1, 5, 2), (3, 4, 2, 1, 5), (3, 4, 2, 5, 1), (3, 4, 3, 1, 5), (3, 4, 3, 5, 1), (3, 4, 5, 1, 2), (3, 4, 5, 2, 1), (3, 5, 1, 2, 4), (3, 5, 1, 4, 2), (3, 5, 2, 1, 4), (3, 5, 2, 4, 1), (3, 5, 3, 1, 4), (3, 5, 3, 4, 1), (3, 5, 4, 1, 2), (3, 5, 4, 2, 1), (4, 1, 2, 3, 5), (4, 1, 2, 5, 3), (4, 1, 3, 2, 5), (4, 1, 3, 5, 2), (4, 1, 5, 2, 3), (4, 1, 5, 3, 2), (4, 2, 1, 3, 5), (4, 2, 1, 5, 3), (4, 2, 3, 1, 5), (4, 2, 3, 5, 1), (4, 2, 5, 1, 3), (4, 2, 5, 3, 1), (4, 3, 1, 2, 5), (4, 3, 1, 5, 2), (4, 3, 2, 1, 5), (4, 3, 2, 5, 1), (4, 3, 4, 1, 5), (4, 3, 4, 5, 1), (4, 3, 5, 1, 2), (4, 3, 5, 2, 1), (4, 4, 1, 3, 5), (4, 4, 1, 5, 3), (4, 4, 3, 1, 5), (4, 4, 3, 5, 1), (4, 4, 5, 1, 2), (4, 4, 5, 2, 1), (4, 5, 1, 2, 3), (4, 5, 1, 3, 2), (4, 5, 2, 1, 3), (4, 5, 2, 3, 1), (4, 5, 3, 1, 2), (4, 5, 3, 2, 1), (5, 1, 2, 3, 4), (5, 1, 2, 4, 3), (5, 1, 3, 2, 4), (5, 1, 3, 4, 2), (5, 1, 4, 2, 3), (5, 1, 4, 3, 2), (5, 2, 1, 3, 4), (5, 2, 1, 4, 3), (5, 2, 3, 1, 4), (5, 2, 3, 4, 1), (5, 2, 4, 1, 3), (5, 2, 4, 3, 1), (5, 3, 1, 2, 4), (5, 3, 1, 4, 2), (5, 3, 2, 1, 4), (5, 3, 2, 4, 1), (5, 3, 4, 1, 2), (5, 3, 4, 2, 1), (5, 4, 1, 2, 3), (5, 4, 1, 3, 2), (5, 4, 2, 1, 3), (5, 4, 2, 3, 1), (5, 4, 3, 1, 2), (5, 4, 3, 2, 1), (5, 5, 1, 2, 3), (5, 5, 1, 3, 2), (5, 5, 2, 1, 3), (5, 5, 2, 3, 1), (5, 5, 3, 1, 2), (5, 5, 3, 2, 1), (5, 5, 4, 1, 2), (5, 5, 4, 2, 1), (5, 5, 5, 1, 2), (5, 5, 5, 2, 1), (5, 5, 5, 3, 1), (5, 5, 5, 4, 1), (5, 5, 5, 5, 1), (5, 5, 5, 5, 2), (5, 5, 5, 5, 3), (5, 5, 5, 5, 4), (5, 5, 5, 5, 5)]
```


Prodotto cartesiano

```
>>> list(itertools.product('ABCD', 'xy'))
[('A', 'x'), ('A', 'y'), ('B', 'x'), ('B', 'y'), ('C', 'x'), ('C', 'y'), ('D', 'x'), ('D', 'y')]
```

6.3.3 Context Managers

Un context manager è un oggetto che fornisce informazioni contestuali o esecuzione automatica ad una azione ed è quello che funziona col protocollo/keyword **with**. Il più conosciuto è **open** grazie al quale **f** sarà automaticamente chiusa all'uscita dal manager (il blocco):

```
with open('file.txt') as f:
    contents = f.read()
```

Un context manager può essere implementato mediante classe o mediante generatore; la classe è meglio se vi è un tot di dati/logica da incapsulare, la funzione è meglio se abbiamo a che fare con casi più semplici.

6.3.3.1 Implementazione mediante classe

Per duplicare **open** semplicemente si programma:

```
class CustomOpen(object):
    def __init__(self, filename):
        self.file = open(filename)

    def __enter__(self):
        return self.file

    def __exit__(self, ctx_type, ctx_value, ctx_traceback):
        self.file.close()

with CustomOpen('file') as f:
    contents = f.read()
```

I due metodi speciali utilizzati da **with** sono **__enter__** e **__exit__**. Il funzionamento:

- **CustomOpen** è inizializzata con **__init__**
- **__enter__** è chiamata e qualsiasi cosa ritorni è assegnato a **f**
- quando il blocco di **with** finisce, viene chiamata **__exit__**

6.3.3.2 Implementazione mediante generatore

Bisogna utilizzare **contextmanager** dalla libreria **contextlib**:

```
from contextlib import contextmanager

@contextmanager
def custom_open(filename):
    f = open(filename)
```

```
    try:
        yield f
    finally:
        f.close()

with custom_open('file') as f:
    contents = f.read()
```

Il funzionamento:

- `custom_open` è eseguita fino a `yield`
- ritorna il controllo allo statement `with`; ciò che è stato dato da `yield` viene assegnato ad `f` (nel pezzo `as f`)
- la clausola `finally` assicura che `close` sia chiamata che vi sia stata una eccezione all'interno del blocco `with` o meno

Capitolo 7

Eccezioni

Contents

7.1	Gestire eccezioni	107
7.1.1	Sintassi minimale: <code>try except</code>	107
7.1.2	<code>else</code>	109
7.1.3	<code>finally</code>	109
7.2	Sollevare eccezioni	109
7.3	Creare eccezioni custom	111
7.4	Sollevare warnings senza stoppare l'esecuzione . .	111

Quando viene sollevata una eccezione a runtime qualcosa è andato storto Non è necessariamente un bug , qualcosa che dipende dal codice, ma può dipendere anche da una condizione esterna. Nel seguito si vede:

- come gestire eccezioni per evitare che blocchino l'esecuzione
- come sollevare eccezioni nel nostro codice, eventualmente custom made
- sollevare warnings rapidi

7.1 Gestire eccezioni

Per gestire le eccezioni si usa `try`.

7.1.1 Sintassi minimale: `try except`

Un esempio

```
try:
    x = int("prova")
except ValueError a e:
    print(e)
    # oppure altro codice per gestire l'eccezione
```

Nell'ordine:

- viene eseguito il codice sotto `try`

- se non viene sollevata alcuna eccezione `try` termina
- se viene sollevata una eccezione l'ecuzione di `try` si blocca e si cerca un match con quelle previste in `except`:
 - se una eccezione matcha viene eseguito il relativo codice dopodichè si esce dal blocco `try`;
 - se il tipo non matcha, essa viene trasmessa a eventuali istruzioni `try` di livello superiore

In `try`:

- si possono avere più clausole `except`, per specificare gestori di differenti eccezioni
- se si vuole gestire molteplici eccezioni con lo stesso codice, porle in una tupla:

```
except (RuntimeError, TypeError, NameError) as e:
    print(e)
```

- per ignorare una eccezione (ma non è best practice) porre `pass` nel relativo chunk. Alternativamente se il `try` è all'interno di un loop `for` si potrebbe dare `continue` per passare al prossimo elemento
- sebbene sia meglio avere una gestione granulare delle eccezioni, per matchare qualsiasi eccezione utilizzare `Exception` (che è parent di tutte le eccezioni). Best practice potrebbe essere loggare tutte le eccezioni non gestite

```
import logging

try:
    code
except A as e:
    ...
except B as e:
    ...
except Exception as e:
    logging.exception(e)
```

- se si desidera che una eccezione sia così grave da bloccare il programma si può usare `sys.exit`

```
try:
    ...
except SevereError as e:
    print(e)
    sys.exit(1)
```

7.1.2 else

Opzionale, va posta dopo tutte le `except`. È il contrario di queste nel senso che esegue codice se *try va a buon fine*:

```
for arg in sys.argv[1:]:
    try:
        f = open(arg, 'r')
    except IOError:
        print('cannot open', arg)
    else:
        print(arg, 'has', len(f.readlines()), 'lines')
        f.close()
```

7.1.3 finally

Opzionale, e serve per eseguire codice in ogni caso (sia in caso positivo che fail), es per azioni di pulizia che vengono eseguite comunque

```
>>> def divide(x, y):
...     try:
...         result = x / y
...     except ZeroDivisionError:
...         print("Division by zero!")
...     else:
...         print("Result is", result)
...     finally:
...         print("Executing finally clause")
...
>>> divide(2, 1)
Result is 2.0
Executing finally clause
>>> divide(2, 0)
Division by zero!
Executing finally clause
>>> divide("2", "1")
Executing finally clause
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "<stdin>", line 3, in divide
TypeError: unsupported operand type(s) for /: 'str' and 'str'
```

Nelle applicazioni reali, la clausola `finally` è utile per rilasciare risorse esterne (file, network connection) indipendentemente dal fatto che l'uso della risorsa sia andata a buon fine.

7.2 Sollevare eccezioni

Lo statement `raise` permette di sollevare eccezioni;

```
>>> raise NameError("Messaggio informativo")
Traceback (most recent call last):
```

```
File "<stdin>", line 1, in <module>
NameError: Messaggio informativo
```

La gerarchia delle eccezioni disponibili allo stato attuale, cercare di utilizzare l'eccezione più appropriata.

```
BaseException
+-- SystemExit
+-- KeyboardInterrupt
+-- GeneratorExit
+-- Exception
    +-- StopIteration
    +-- StopAsyncIteration
    +-- ArithmeticError
    |   +-- FloatingPointError
    |   +-- OverflowError
    |   +-- ZeroDivisionError
    +-- AssertionError
    +-- AttributeError
    +-- BufferError
    +-- EOFError
    +-- ImportError
    |   +-- ModuleNotFoundError
    +-- LookupError
    |   +-- IndexError
    |   +-- KeyError
    +-- MemoryError
    +-- NameError
    |   +-- UnboundLocalError
    +-- OSError
    |   +-- BlockingIOError
    |   +-- ChildProcessError
    |   +-- ConnectionError
    |       +-- BrokenPipeError
    |       +-- ConnectionAbortedError
    |       +-- ConnectionRefusedError
    |       +-- ConnectionResetError
    |   +-- FileExistsError
    |   +-- FileNotFoundError
    |   +-- InterruptedError
    |   +-- IsADirectoryError
    |   +-- NotADirectoryError
    |   +-- PermissionError
    |   +-- ProcessLookupError
    |   +-- TimeoutError
    +-- ReferenceError
    +-- RuntimeError
    |   +-- NotImplementedError
    |   +-- RecursionError
    +-- SyntaxError
    |   +-- IndentationError
```

```

|          +-- TabError
+-- SystemError
+-- TypeError
+-- ValueError
|   +-- UnicodeError
|       +-- UnicodeDecodeError
|       +-- UnicodeEncodeError
|       +-- UnicodeTranslateError
+-- Warning
    +-- DeprecationWarning
    +-- PendingDeprecationWarning
    +-- RuntimeWarning
    +-- SyntaxWarning
    +-- UserWarning
    +-- FutureWarning
    +-- ImportWarning
    +-- UnicodeWarning
    +-- BytesWarning
    +-- ResourceWarning

```

7.3 Creare eccezioni custom

Se l'utente vuol definire delle eccezioni custom deve implementarle mediante classi; in questo modo è possibile creare gerarchie di eccezioni. La definizione può esser anche vuota mediante `pass`

```

class MyException(Exception):
    pass

```

Una volta definita si potrà sollevarla mediante `raise`, ad esempio all'interno di un `try`, con un un template del genere

```

try:
    some_risky_code
    if my_test == wrong:
        raise MyException("Message")
except MyException as e:
    do_things

```

7.4 Sollevare warnings senza stoppare l'esecuzione

```

import warnings
warnings.warn("Warning message")

```


Capitolo 8

Debugging

Contents

8.1	Debugging	113
-----	---------------------	-----

8.1 Debugging

Lo strumento è il modulo `pdb`. Alcune applicazioni:

- per entrare in modalità tipo `browser` di R porre una chiamata a

`breakpoint()`

dove necessario. Questo fa andare in pausa l'esecuzione appena il flusso arriva nel punto, dopodiché entra in modalità debugging. `breakpoint` è il modo nuovo (si vedono anche chiamate `pdb.set_trace`) e permette di gestirlo; ad esempio settando `PYTHONBREAKPOINT=0` come environment variable (credo) disabilita tutti i breakpoint

- per eseguire uno script in modalità debugging (senza modificarne il codice)

`python3 -m pdb app.py arg1 arg2`

In modalità debugging (scritta (Pdb) ad inizio linea) i comandi principali utilizzabili sono in tabella 8.1.

Command	Description
h	help
h topic	help su un topic
h pdb	documentazione pdb
q(uit)	chiudi debugger
ENTER	ripeti il comando precedente
dir()	listare variabili disponibili (as usual)
p	stampa espressione (es variabile)
pp	prettyprinta espressione
display expr	monitora variazioni ad una espressione (eg variabile)
display	lista le espressioni monitorate)
undisplay	togli monitoraggio
expr	
b	lista i breakpoint o settane uno alla linea specificata
n(ext)	continua l'esecuzione sino alla prossima linea della funzione corrente (eg se no scende nelle librerie)
s(tep)	esegui linea corrente, stoppa alla prima occasion (in funzione chiamata o funzione corrente) current (Step into a subroutine)
c(ontinue)	continua l'esecuzione e stoppa al prossimo breakpoint
unt n	continua l'esecuzione sino a linea numero n
r(eturn)	Return out of a subroutine
w	stampa la stack (frame più recente alla fine)
u(p)	sali nella stack
d(own)	scendi nella stack
l(ist)	Lista il codice attorno alla posizione corrente
ll	lista il codice della funzione o frame corrente

Tabella 8.1: Comandi debug

Capitolo 9

Testing

Contents

9.1	Introduzione e concetti	115
9.1.1	Tipologie di testing	115
9.1.2	Test driven development	116
9.2	unittest	116
9.2.1	Test del valore ritornato	116
9.2.2	Test eccezioni	118
9.2.3	Test fixtures	119

9.1 Introduzione e concetti

9.1.1 Tipologie di testing

Si divide classicamente il testing in:

unit testing di singole funzionalità (es funzione/classe)

functional test di funzionalità più generali/complesive (derivante dall'interazione di più funzioni di base)

regression : test che l'output di un programma non cambi a successive versioni (a meno che ciò non sia intenzionale). Basati su output dell'esecuzione di versioni passate (validate ad occhio) o di programmi benchmark

I test debbono:

- essere specifici, indipendenti e svolti in maniera automatica
- testare in caso di input corretto, l'output corretto
- testare in caso di input incorretto, la gestione corretta delle eccezioni
- dovrebbero teoricamente testare tutto l'input possibile

9.1.2 Test driven development

Se l'impostazione dei test sulle funzionalità avvenga *prima* che queste funzionalità vengano implementate abbiamo il *test driven development* (TDD).

La filosofia del TDD è:

1. scrivi test completi che falliscono
2. scrivi codice fino a farli passare

Vantaggi sono:

- si specifica a priori tutti i comportamenti specifici che il nostro software deve avere/rispettare
- evitano l'overcoding: una volta che i test passano siamo a posto e non vi è bisogno di aggiungere altro
- in sede di refactoring possiamo lavorare tranquillamente garantendoci che le nuove versioni si comportino come le vecchie

9.2 unittest

Il modulo classico per lo unit testing in Python è `unittest`. Supponiamo di avere un modulo di nome `testme` e lo sottoponiamo a test nel modulo `tests`.

9.2.1 Test del valore ritornato

Nel `tests.py`, ad un livello minimale, abbiamo:

```
import testme
import unittest

class add2Tests(unittest.TestCase):

    known_value = ((1,3), (2,4))

    def test_right_input(self):
        '''add2 should add 2 to the proper input'''
        for _input, _output in self.known_value:
            result = testme.add2(_input)
            self.assertEqual(_output, result)

if __name__ == '__main__':
    unittest.main()
```

Alcune peculiarità:

- per creare un test case (ovvero un gruppo di test legati in qualche modo tra loro e identificati dal nome della classe), creiamo una classe che eredita dalla classe `unittest.TestCase`, la quale definisce diversi metodi utili per lo unit testing

- ogni metodo della classe definita costituisce un singolo test ed è identificato dal nome della funzione (quindi anche qui l'importanza di nomi esplicativi): nel caso di sopra il test che abbiamo impostato si verifica che l'output fornito dalla funzione sia uguale a quello specificato come corretto in `known_value` (la di cui correttezza di contenuto deve essere verificata/validata a mano);
- la classe `TestCase` fornisce metodi di utilità generale per il testing: qui abbiamo utilizzato `assertEqual` che si occupa di verificare che due valori siano uguali. Altri metodi utili sono `assertTrue` e `assertFalse`;
- `unittest.main` cerca in tutti i simboli del namespace globale quali sono le classi che ereditano da `unittest.TestCase`; per ciascuna di queste classi trova tutti i metodi che di nome iniziano con `test` e per ognuno di essi istanzia un nuovo oggetto (per creare un contesto pulito ogni volta) ed esegue la singola funzione.

Per ogni singolo test di ogni test suite:

1. stampa la docstring ed esegue il codice
2. dice se il test è **passato** (esecuzione completata, risultato corretto), **fallito** (esecuzione completata, risultato incorretto) o da **errore** (esecuzione non completata)
3. nel caso di problemi viene stampata la traceback
4. fa alcune statistiche complessive

In seguito, nel file `testme.py`:

```
def add2(x):
    pass
```

In questa fase:

- definiamo solamente l'api della funzione
- partiamo con una bozza
- ci assicuriamo che i test falliscano: i test dovrebbero fallire perchè si ritorna `None` (che è diverso da 3)

Per effettuare i test basta eseguire il file `tests.py`, se si vuole *verbose* con l'opzione `-v` specificata alla fine; se effettuiamo i test effettivamente quello che otteniamo è:

```
l@740n:~/cs/python/code$ python3 tests.py -v
test_right_input (__main__.add2Tests)
add2 should add 2 to the proper input ... FAIL
```

```
=====
FAIL: test_right_input (__main__.add2Tests)
add2 should add 2 to the proper input
```

```
-----
Traceback (most recent call last):
```

```
File "tests.py", line 12, in test_right_input
```

```
self.assertEqual(_output, result)
AssertionError: 3 != None
```

```
-----
Ran 1 test in 0.000s
```

```
FAILED (failures=1)
```

che ci indica il fallimento dei test come preventivato. Se però ridefiniamo `add2` come

```
def add2(x):
    return x + 2
```

allora abbiamo

```
l@740n:~/cs/python/code$ python tests.py -v
test_right_input (__main__.add2Tests)
add2 should add 2 to the proper input ... ok
```

```
-----
Ran 1 test in 0.000s
```

```
OK
```

Che ci indica corretto test.

9.2.2 Test eccezioni

Possiamo evolvere l'esempio considerando che la nostra funzione possa accettare solamente valori numerici e in caso di input che non sia tale si deve comportare in maniera appropriata, ovvero deve fallire sollevando una eccezione. In questo caso `unittest.TestCase` fornisce il metodo `assertRaises` che prende in input:

- l'oggetto eccezione di interesse
- la funzione
- i parametri da dare alla funzione

Ad esempio se in Python si somma 3 ed `'a'` viene restituito `TypeError`, possiamo assicurarci che ciò avvenga nella nostra funzione definendo un test del genere (sempre all'interno della classe `add2Tests`)

```
not_numerics = ('a', 'b')

def test_not_numeric_input(self):
    ''' not numeric input should raise TypeError '''
    for i in self.not_numerics:
        self.assertRaises(TypeError, testme.add2, i)
```

Se volessimo che la funzione gestisse solo interi o simili potremmo sollevare una eccezione custom nel caso contrario dovremmo ridefinire `testme` come segue:

```

class add2NotHandledType(TypeError):
    pass

def add2(x):
    if not isinstance(x, int):
        raise add2NotHandledType('Only int handled')
    return x + 2

```

e il testing complessivamente come

```

import testme
import unittest

class add2Tests(unittest.TestCase):

    known_value = ((1,3), (2,4))

    def test_right_input(self):
        '''add2 should add 2 to the proper input'''
        for _input, _output in self.known_value:
            result = testme.add2(_input)
            self.assertEqual(_output, result)

    not_integers = ('a', 1.1)

    def test_not_numeric_input(self):
        ''' not numeric input should raise TypeError '''
        for i in self.not_integers:
            self.assertRaises(testme.add2NotHandledType, testme.add2, i)

if __name__ == '__main__':
    unittest.main()

```

All'esecuzione abbiamo:

```

l0m740n:~/cs/python/code$ python3 tests.py -v
test_not_numeric_input (__main__.add2Tests)
not numeric input should raise TypeError ... ok
test_right_input (__main__.add2Tests)
add2 should add 2 to the proper input ... ok

```

```

-----
Ran 2 tests in 0.000s

```

OK

9.2.3 Test fixtures

Potremmo essere interessati a impostare delle **test fixtures** ovvero due funzioni appartenenti alla classe del test case, obbligatoriamente di nome **setUp** e **tearDown**, che vengono utilizzate per predisporre (pre) e pulire (post) .

Il funzionamento diviene così: per ogni metodo di ogni test case

- istanzia un oggetto di test
- esegui `setUp`
- esegui il metodo di test
- esegui `tearDown`

Un esempio

```
class Test(unittest.TestCase):
    def setUp(self):
        self.seq = range(0, 10)
        random.shuffle(self.seq)

    def tearDown(self):
        del self.seq

    def test_basic_sort(self):
        self.seq.sort()
        self.assertEqual(self.seq, range(0, 10))
```


Capitolo 10

Espressioni regolari

```
>>> import re

>>> # search/replace semplice (qui la gente inserisce le espressioni regolari)
>>> re.sub("à", "a", "ààestaaaà")
'aaestaaaa'
>>> re.sub("est", "a", "ààestaaaà")
'ââaaaaâ'
>>> re.sub('[^0-9]', '', "sgdf352sc")
'352'
>>> # quando si usano \* meglio porre r per raw string e semplificare la sintassi
>>> re.sub(r"^(\w+) (\w+) (\w+)", r"\2", "asd foo bar")
'foo'

>>> # re.subn fa la stessa cosa ma ritorna una tupla con la stringa sostituita e il
>>> # numero di sostituzioni. Poco interessante for the moment

>>> # re.split splitta sulla base di un pattern, restituendo lista
>>> re.split(r"\d", "asd5foo66bar")
['asd', 'foo', '', 'bar']

>>> # re.findall ritorna tutti i match non sovrapposti come lista di stringhe o di
>>> # tuple
>>> re.findall(r'(\w+)=(\d+)', 'set width=20 and height=10')
[('width', '20'), ('height', '10')]
>>> re.findall(r'\b[a-z]*', 'which foot or hand fell fastest') # parole inizianti f
['foot', 'fell', 'fastest']

>>> # re.finditer restituisce un iteratore sui match nella stringa (vedere sotto per Match)
>>> for m in re.finditer(r'(\w+)=(\d+)', 'set width=20 and height=10'):
...     print("-----")
...     print(m[0])
...     print(m[1])
...     print(m[2])
...
-----
width=20
```

```

width
20
-----
height=10
height
10
>>> # -----
>>> # Ricerca/estrazione elementi
>>> # -----

>>> # Scan della stringa e restituisce un Match. Tre funzioni: match, search,
>>> # fullmatch.

>>> # re.match() cerca un singolo match all'inizio della stringa. Occhio che un
>>> # singolo match può essere composto da più elementi
>>> re.match("c", "abcdef")      # No match
>>> re.match(r"(\w+) (\w+)", "Isaac Newton, physicist") # Match sino a virgola
<re.Match object; span=(0, 12), match='Isaac Newton'>

>>> # re.search() cerca il primo match ovunque nella the string (default di Perl)
>>> re.search("c", "abcdef")     # Match
<re.Match object; span=(2, 3), match='c'>
>>> re.search("^a", "abcdef")   # Cercare solo all'inizio con search
<re.Match object; span=(0, 1), match='a'>

>>> # re.fullmatch() verifica se l'intera stringa è match
>>> re.fullmatch("p.*n", "python") # Match
<re.Match object; span=(0, 6), match='python'>
>>> re.fullmatch("t.*n", "python") # No match

>>> # Il template che si usa a valle per il processing di un match è il seguente
>>> search_match = re.search("c", "abcdefabcdef")
>>> if (search_match):
...     print("Using the match.")
...
Using the match.
>>> # Match.group
>>> # -----
>>> # restituisce sottopezzi del match: se vi sono molteplici è una tuple
>>> m1 = re.search(r"(\w+) (\w+)", "Isaac Newton, physicist")
>>> if m1:
...     m1.group(0)      # match intero
...     m1.group(1)      # contenuto prima parentesi
...     m1.group(2)      # contenuto seconda parentesi
...     m1.group(1, 2)   # selezionare elementi e porli in tupla
...     m1.group(1, 1)   # idem
...     m1[0]            # è una tupla e si può accedere anche così
...
'Isaac Newton'
'Isaac'
'Newton'

```

```

('Isaac', 'Newton')
('Isaac', 'Isaac')
'Isaac Newton'
>>> # è possibile assegnare nomi ai match per rendere più esplicito il codice
>>> m2 = re.search(r"(?P<name>\w+) (?P<surname>\w+)", "Isaac Newton, physicist")
>>> if m2:
...     # utilizziamo
...     print(m2["name"])          # match intero
...     print(m2["surname"])
...
Isaac
Newton

>>> # Match.groups
>>> # -----
>>> # restituisce una tupla con tutti i sottopezzi sia che abbiamo assegnato nomi
>>> # che no
>>> m1.groups()
('Isaac', 'Newton')
>>> m2.groups()
('Isaac', 'Newton')

>>> # Match.groupdict
>>> # -----
>>> # restituisce un dict nel caso abbiamo assegnato nomi; ocio che non da errore
>>> # se non assegnamo nomi restituisce vuoto che raffaella carrà scansati
>>> m1.groupdict() # vuoto!
{}
>>> m2.groupdict()
{'name': 'Isaac', 'surname': 'Newton'}
```

>>> # Match.expand
>>> # -----
>>> # permette di usare le sottoporzioni per generare nuove stringhe (simile a
>>> # quanto fatto da sub)
>>> m1.expand(r"\1\1\2\2") *# notare r per raw string se no avremmo dovuto usare \\1*
'IsaacIsaacNewtonNewton'

>>> # -----
>>> # In produzione
>>> # -----
>>> #
>>> # spesso vogliamo utilizzare una stessa regex con molte stringhe. Per farlo in
>>> # maniera efficiente la compiliamo in un istanza di Pattern ed usiamo i suoi
>>> # metodi search, match, fullmatch, findall, sub etc come usate sopra on the fly

```

>>> np_re = re.compile(r"(\w+) (\w+)") # occhio a r per raw string
>>> m = np_re.search("Isaac Newton, physicist")
>>> m.groups()
('Isaac', 'Newton')

```


Capitolo 11

Moduli e pacchetti

Contents

11.1	Introduzione	125
11.2	Moduli	126
11.2.1	Nome e namespace	126
11.2.2	Importazione dei moduli	126
11.2.3	Path di ricerca dei moduli	127
11.2.4	Templates	127
11.3	Pacchetti	129
11.3.1	Struttura e <code>__init__.py</code>	129
11.3.2	<code>__init__.py</code> , <code>__all__</code> e <code>import *</code> da pacchetto	131
11.4	Packaging e distribuzione di pacchetti	131
11.4.1	Flow	131
11.4.2	<code>pyproject.toml</code>	131
11.4.3	Aggiornamento toolchain	132
11.4.4	Creazione del tree del pacchetto	132
11.4.5	Installare un pacchetto in modalità devel	132
11.4.6	Build di sdist e wheel	132
11.4.7	Upload a pypi	132
11.5	Altre utilità	133
11.5.1	Inserimento di script nel pacchetto	133
11.5.2	Documentazione	133
11.5.3	Testing	135
11.5.4	Timing/temporizzazione	136
11.5.5	Profiling	136

Per la creazione di pacchetti, la guida aggiornata si trova qui: <https://packaging.python.org/en/latest>

11.1 Introduzione

Alcune distinzioni:

modulo file `.py` che può definire classi, funzioni e variabili globali importabili da un altro modulo mediante `import`

pacchetto una directory contenente moduli e un file `__init__.py`. I pacchetti sono un modo per organizzare moduli con scopi affini.

Di base `import` applicato ad un pacchetto esegue innanzitutto `__init__.py` per eventuali configurazioni/inizializzazioni.

11.2 Moduli

11.2.1 Nome e namespace

Ogni modulo ha:

- un *nome*, contenuto nella variabile globale `__name__` che solitamente coincide con:
 - `"nomefile"` senza l'estensione `.py` se il modulo è importato mediante `import`
 - `"__main__"`, qualora il modulo sia eseguito come script attraverso `python nomefile.py`
- un *namespace*: ogni modulo ha il suo che viene utilizzato da tutte le funzioni definite in esso. Le funzioni di un modulo per riferirsi ad altri oggetti definiti nello stesso, possono evitare di precedere il nome del modulo all'oggetto richiesto.

La presenza di un nome del modulo fa sì che si possa eseguire codice a seconda che il modulo sia importato o eseguito come script. Ad esempio nel file `miomodulo.py` dopo tutte le definizioni possiamo dare

```
if __name__ == "__main__":
    checks()
```

in questo caso i `checks()` verranno eseguite solamente se eseguiamo il modulo mediante `python miomodulo.py` (altrimenti mediante `import` il nome del modulo è impostato a `miomodulo` e i `checks` non vengono eseguiti).

11.2.2 Importazione dei moduli

I moduli possono importare altri moduli per ottenerne funzionalità in due modi differenti per la gestione del namespace. Supponiamo di aver creato un file `mymodule.py` nella directory corrente che contiene la funzione `do_complicated_stuff` e la variabile `strange_var`. Possiamo comandare:

- `import mymodule <as abbreviazione>`

Viene creato un oggetto-modulo chiamato `mymodule` che contiene quanto definite; per utilizzarle

```
mymodule.do_complicated_stuff()
mymodule.strange_var
```

Specificando l'abbreviazione si crea un alias per il `mymodule` (verosimilmente più piccola e veloce da ditzeggiare)

- `from mymodule import do_complicated_stuff <as abbrev>`
`from mymodule import strange_var <as abbrev>`

Si importano solamente la funzione (o la costante) ed è possibile riferirvisi in seguito con un più veloce `do_complicated_stuff` senza specificare il nome del modulo di provenienza.

- `from mymodule import *`

Si importa tutto quello che è definito nel modulo (non è considerato buona pratica)

11.2.3 Path di ricerca dei moduli

Quando viene richiesta l'importazione di un modulo di nome `spam.py` mediante `import spam` (o simili), Python cerca nell'ordine:

1. nei moduli builtin distribuiti col linguaggio;
2. nella lista di directory specificate in `sys.path`, nell'ordine specificato:

```
import sys
sys.path
```

La variabile contiene solitamente la directory corrente al primo posto (come stringa vuota), facendole assumere priorità tra quelle del `sys.path`. Se si desidera aggiungere una directory come prima si può usare

```
sys.path.insert(0, '/path/to/mod_directory')
```

11.2.4 Templates

11.2.4.1 Modulo libreria

```
#!/usr/bin/env python3          # (1) sha bang, volendo poter eseguire anche con ./
"""                             # (2) doc: disponibile mediante nomemodulo.__doc__
Documentazione del modulo
Sommario funzionalità, classi,
funzioni, variabili.
"""

import sys                      # (3) importazione di altri moduli
import os

debug = True                    # (4) variabili globali, se necessarie

class FooClass():              # (5) dichiarazione classi
    "Foo class"
    pass

def test():                     # (6) dichiarazione funzioni (qui che possono
```

```

    "Test fun"                                #    utilizzare le classi)
    foo = FooClass()
    if debug:
        print 'ran test()'

if __name__ == '__main__':    # (7) corpo main
    test()

```

L'ultima linea controlla se il codice è stato eseguito direttamente o importato; se eseguito direttamente esegue la funzione di test.

11.2.4.2 Script della libreria

Da testare: analogo al precedente ma con argparsing terminante con esecuzione della main

```

import argparse

def main():                                # (6) funzione main
    """
    Main function

    winston_sends "ciao" user::lucailgarb
    winston_sends file.pdf user::lucailgarb
    winston_sends file.png group::da_salvare
    """

    parser = argparse.ArgumentParser()
    parser.add_argument("what")
    parser.add_argument("to")
    args = parser.parse_args()
    what = args.what
    to = args.to

    # ...

if __name__ == '__main__':    # (7) corpo main
    main()

```

I benefici sono:

- si segnala a chi legge che lo script è inteso per essere eseguito da linea di comando
- ponendo codice nella funzione main lo isola meglio
- posso importare la funzione main e sarebbe come eseguirla da script da un altro file
- in alcuni casi (cicli for) vi sono benefici di performance nell'esecuzione di codici all'interno di funzioni

11.3 Pacchetti

11.3.1 Struttura e `__init__.py`

Al minimo, un pacchetto è una directory contenente un file `__init__.py` e i file `.py` che costituiscono i moduli.

I files `__init__.py` sono necessari per far sì che Python tratti la directory come un pacchetto;

- nel caso più semplice (considerata best practice) può essere un file vuoto;
- alternativamente si possono eseguire inizializzazioni o impostare la variabile `__all__` di cui si parla in seguito

11.3.1.1 Struttura semplice

Ad esempio, con una siffatta situazione:

```
mypackage/
|-- __init__.py
|-- module_a.py
+-- module_b.py
```

L'utilizzo (in uno script al di fuori della directory `mypackage`) può avvenire come:

```
import mypackage.module_a
```

11.3.1.2 Struttura con subpackages

In situazioni più complesse si possono prevedere subpackage, ossia subdirectory con moduli affini e un `__init__.py` per ogni directory/subdirectory. Ad esempio per un pacchetto che gestisce l'audio (di nome `sound`):

sound/	Top-level package
__init__.py	Initialize the sound package
formats/	Subpackage for file format conversions
__init__.py	
wavread.py	
wavwrite.py	
aiffread.py	
aiffwrite.py	
auread.py	
auwrite.py	
...	
effects/	Subpackage for sound effects
__init__.py	
echo.py	
surround.py	
reverse.py	
...	
filters/	Subpackage for filters
__init__.py	

```

equalizer.py
vocoder.py
karaoke.py
...

```

References da esterno L'importazione di funzionalità (a partire da uno script residente all'esterno di `sound`) può essere avvenire con `import` o `from`:

- `import` in `import a.b.c` ogni item tranne l'ultimo deve essere un pacchetto (directory con `__init__.py`), l'ultimo (`c`) può essere un pacchetto o un modulo
- con `from` possiamo importare moduli e funzioni, controlla che l'oggetto sia definito nel pacchetto, se sì lo importa, se no ipotizza sia un modulo e lo cerca

```

# modulo versione 1: con import è necessaria poi la full reference
import sound.effects.echo
sound.effects.echo.echofilter(input, output, delay=0.7, atten=4)

# modulo vrs 2: con from si può usare la relative reference
from sound.effects import echo
echo.echofilter(input, output, delay=0.7, atten=4) # from allows relative ref

# con from si possono importare anche funzioni
from sound.effects.echo import echofilter
echofilter(input, output, delay=0.7, atten=4)

```

Intra-package references Quando i pacchetti sono strutturati in sottopacchetti si possono usare sia referenza assoluta che relativa. Ad esempio

- se `sound.filters.vocoder` necessita del modulo `sound.effects.echo` nelle sue prime linee si può usare alternativamente

```

from sound.effects import echo
from ..effects import echo

```

•

se `sound.effects.surround` necessita `sound.effects.echo` `sound.formats` o `sound.filters.equalizer`

```

from . import echo
from .. import formats
from ..filters import equalizer

```

Gli import relativi si basano sul nome del modulo corrente: dato che il nome del modulo main è sempre `__main__`, i file `.py` (moduli) che debbono essere eseguiti come modulo main (script) debbono utilizzare sempre import assoluti.

11.3.2 `__init__.py`, `__all__` e `import *` da pacchetto

Se in `sounds/effects/__init__.py` si imposta

```
__all__ = ["echo", "surround", "reverse"]
```

e si comanda

```
from sound.effects import *
```

verranno importati `echo.py`, `surround.py` e `reverse.py`.

11.4 Packaging e distribuzione di pacchetti

Qua ci si riferisce prevalentemente a <https://packaging.python.org/en/latest/flow/> e <https://packaging.python.org/en/latest/tutorials/packaging-projects/> cui vi è da fare riferimento per pratiche standard.

11.4.1 Flow

Per pubblicare un pacchetto occorre avere:

- il codice sotto git;
- preparare un file di metadati descrittivi e di istruzione di building del pacchetto. Nella maggior parte dei casi questo è il file `pyproject.toml` nella directory radice del progetto. Questo deve almeno contenere una sezione `[build-system]` che specifica il sistema di building backend adottato (`hatch` è nuovo, `setuptools` è vecchio, poi ve ne sono altri). Qui si usa `hatch`;
- effettuare la build che produce il pacchetto di sorgenti (`sdist`) e il binario (`wheel`), detti build artifacts
- fare l'upload dei build artifacts su PyPi

11.4.2 `pyproject.toml`

In `pyb/pyproject.toml` specificare le main config del repo in accordo a. Per utilizzare `hatch` come build system

```
[build-system]
requires = ["hatchling"]
build-backend = "hatchling.build"
```

Specificare le config rimanenti in accordo a:

- lo standard su come specificare metadati <https://packaging.python.org/en/latest/specifications/declaring-project-metadata/>;
- la documentazione del build system (`hatch`).

11.4.3 Aggiornamento toolchain

```
python3 -m pip install --upgrade pip
python3 -m pip install --upgrade hatch # building backend
python3 -m pip install --upgrade build # building frontend
python3 -m pip install --upgrade twine # upload
```

11.4.4 Creazione del tree del pacchetto

Questo crea il template di directory corretto:

```
l@m740n:~/src/pypkg$ hatch new pylb
```

Porre:

- il contenuto del pacchetto in `pylb/src/pylb`
- il gitignore per un progetto python

```
wget https://raw.githubusercontent.com/github/gitignore/main/Python.gitignore
mv Python.gitignore .gitignore
```

Ora aggiungere codice, aggiungere documentazione e test, affrontati in seguito.

11.4.5 Installare un pacchetto in modalità devel

Per effettuare prove veloci su un nuovo pacchetto conviene installarlo in modalità editabile; questo permette di modificare il sorgente senza dover reinstallare il pacchetto per vedere i risultati in via di test.

Per farlo spostarsi nella directory del pacchetto e comandare

```
pip install -e .
```

11.4.6 Build di sdist e wheel

Se si vuole creare entrambi, semplicemente

```
l@m740n:~/src/pypkg$ python3 -m build pylb
```

che creerà il pacchetto dist (`tar.gz`) e il pacchetto wheel (`whl`) nella subdirectory `dist`.

11.4.7 Upload a pypi

Occorrerà utilizzare le info di login di pypi ovviamente:

```
l@m740n:~/src/pypkg$ twine upload pylb/dist/*
Uploading distributions to https://upload.pypi.org/legacy/
```

11.5 Altre utilità

11.5.1 Inserimento di script nel pacchetto

Per inserire script (es che rendano facilmente disponibili funzionalità del pacchetto da linea di comando) un template da seguire:

- creare una cartella `scripts` sotto `src/pylb`
- creare un modulo col nome dell'eseguibile desiderato (non obbligatorio ma comodo), ad esempio

```
l@ambrogio:~/src/pypkg/pylb$ cat src/pylb/scripts/pylbtestapp.py
def main():
    print("Hi There! This is pylbtestapp.")
```

- inserire in `pyproject.toml` una sezione e riga del genere

```
[project.scripts]
pylbtestapp = "pylb.scripts.pylbtestapp:main"
```

All'installazione del pacchetto, lo script verrà posto in `.local/bin`.

11.5.2 Documentazione

Si fa utilizzo di `sphinx` e si pubblica su <https://readthedocs.org/>. I tutorial da considerare sono <https://packaging.python.org/en/latest/tutorials/creating-documentation/> e <https://docs.python-guide.org/writing/documentation/>.

11.5.2.1 Setup

Iniziamo ad installare `sphinx`

```
python3 -m pip install --upgrade sphinx # documentazione
```

Creiamo la directory di documentazione e facciamo partire il tutto

```
l@m740n:~/src/pypkg$ mkdir pylb/docs
l@m740n:~/src/pypkg$ cd pylb/docs
l@m740n:~/src/pypkg/pylb/docs$ sphinx-quickstart
```

Questo farà domande sul progetto per andare a creare il file `index.rst` e un `conf.py` (configurabili), più un `Makefile` di servizio.

11.5.2.2 Doc-writing e reStructuredText

`sphinx` converte restructured text ad altri linguaggi di markup, e utilizza reStructuredText come linguaggio di markup. Per la sintassi riferirsi a <https://www.sphinx-doc.org/en/master/usage/restructuredtext/> per le convenzioni di documentazione a quelle del progetto Numpy.

11.5.2.3 Building

Setup autobuilding API Per fare sì che la documentazione di funzioni/classi etc, venga generata automaticamente occorre utilizzare l'estensione `autodoc`. Modificare `conf.py` come segue:

- aggiungere il path della libreria nel `sys.path` all'inizio di `conf.py`. Il package deve essere importabile per poter essere elaborato:

```
import os
import sys
sys.path.insert(0, os.path.abspath('../src'))
```

- modificare per aggiungere le seguenti estensioni sotto general configuration:

```
extensions = [
    'sphinx.ext.autodoc',      # generazione automatica api
    'sphinx.ext.viewcode',    # aggiungi link ipertestuali al codice
    'sphinx.ext.napoleon'     # supporta sintassi a-la numpy
]
```

- volendo si può cambiare il tema html installandolo

```
pip install --user sphinx_rtd_theme
```

e modificando la linea del tema html (sostituendo `alabaster` di default)

```
html_theme = 'sphinx_rtd_theme'
```

Al termine del setup per preparare la documentazione di funzioni etc:

```
l@m740n:~/src/pypkg/pylb/docs$ sphinx-apidoc -f ../src/pylb/ -o .
Creating file ./pylb.rst.
Creating file ./pylb.experiments.rst.
Creating file ./modules.rst.
```

Aggiungere `modules.rst` in `index.rst`

```
Welcome to pylb's documentation!
=====
```

```
.. toctree::
   :maxdepth: 2
   :caption: Contents:

   modules
```

Build definitivo Per buildare definitivamente la documentazione complessivamente si usa `make` con il formato di interesse (nella cartella `docs`). Per l'html

```
l@m740n:~/src/pypkg/pylb/docs$ make html
The HTML pages are in _build/html.
l@m740n:~/src/pypkg/pylb/docs$ firefox _build/html/index.html
```

Per il latex

```
l@740n:~/src/pypkg/pylb/docs$ make latex
The LaTeX files are in _build/latex.
Run 'make' in that directory to run these through (pdf)latex
(use `make latexpdf' here to do that automatically).
l@740n:~/src/pypkg/pylb/docs$ make latexpdf
l@740n:~/src/pypkg/pylb/docs$ okular _build/latex/pylb.pdf
```

11.5.2.4 Setup di readthedocs

Seguire il tutorial per importare il progetto e generare/hostare automaticamente la documentazione

11.5.3 Testing

Il testing di hatch è fatto mediante `pytest`:

- porre tutte i test nella directory `tests` seguendo una struttura directory simile a `src` e con `__init__.py` in ogni sottodirectory. Ad esempio per fare i test del modulo `pytest` in `experiments`, creiamo la cartella `experiments` sotto `tests` e aggiungiamo il file `test_pytest.py` in essa, oltre a `__init__.py`

```
src/pylb
|-- __init__.py
|-- __about__.py
|-- experiments
|   |-- __init__.py
|   |-- pytest.py
|   `-- sphinx.py
`-- scripts
    |-- __init__.py
    `-- pylbtestapp.py
tests/
|-- experiments
|   |-- __init__.py
|   `-- test_pytest.py
`-- __init__.py
```

Per l'esempio a mano programmino i due file come segue. Il codice `src/pylb/experiments/pytest.py`

```
def add(a, b):
    return a+b
```

mentre il codice di test

```
from pylb.experiments.pytest import add

def test_add():
    assert add(1,2) == 3
```

- Infine per comandare il testing

```
l@ambrogio:~/pylb$ hatch run test
===== test session starts =====
platform linux -- Python 3.11.2, pytest-7.3.1, pluggy-1.0.0
rootdir: /home/l/.src/pypkg/pylb
collected 1 item

tests/experiments/test_pytest.py

===== 1 passed in 0.00s =====
```

Lo unit testing sarà sviluppato maggiormente nel prossimo paragrafo

11.5.4 Timing/temporizzazione

Per misurare il tempo usiamo `time.perf_counter`

```
import time
start = time.perf_counter()
# operations ...
stop = time.perf_counter()
stop - start # difference in seconds
```

posto in un decorator `lb.utils.timeit`

11.5.5 Profiling

Il profiling serve per individuare le macrosezioni di codice dove si spende più tempo e/o si usa più memoria.

11.5.5.1 Tempo

<https://wesmckinney.com/book/ipython.html> <https://jakevdp.github.io/PythonDataScienceHandbook/01.07-timing-and-profiling.html>

11.5.5.2 Memoria

<https://wesmckinney.com/book/ipython.html> <https://jakevdp.github.io/PythonDataScienceHandbook/01.07-timing-and-profiling.html>

Capitolo 12

Logging

Contents

12.1	Uso del logger di default	137
12.1.1	Setup	137
12.2	Logger custom	139
12.2.1	Setup degli handler	139
12.2.2	Impostare la formattazione di un handler	139
12.2.3	impostare livello di log generale e di un handler	140
12.2.4	Filtrare log	140

Il modulo `logging` permette di utilizzare il logger di default o definirne uno personalizzato avente maggiore flessibilità.

Utilizzare il logger di default è un modo comodo di avere una prima impressione su come il logging funzioni; il contro è che la configurazione può essere non troppo flessibile (si basa su una singola chiamata a `basicConfig` data all'inizio). Per progetti più complessi occorre maggiore flessibilità e definire logger custom. Ad ogni modo concetto fondamentale in entrambi è il livello di logging (tab 12.1)

12.1 Uso del logger di default

12.1.1 Setup

Un template per il logging da porre a inizio file è il seguente.

Livello	Funzione (logger default)	spiegazione
DEBUG	<code>logging.debug()</code>	Informazioni dettagliate per sviluppatori.
INFO	<code>logging.info()</code>	Info di cosa sta accadendo (buon funzionamento).
WARNING	<code>logging.warning()</code>	Vi sono cose da controllare
ERROR	<code>logging.error()</code>	Un problema inatteso si è verificato.
CRITICAL	<code>logging.critical()</code>	Un problema grave (eg livello crash) si è verificato.

Tabella 12.1: Livelli di logging dal più basso (DEBUG) al più alto (CRITICAL)

```
# template per il logging
import logging
logging_level = logging.DEBUG
# logging_fmt = r"%{(levelname)s %(name)s} {(asctime)s} - {(message)s}"
logging_fmt = r"%{levelname} {name}] {asctime} - {message}"
logging_datefmt = "%Y-%m-%d %H:%M"
logging.basicConfig(level=logging_level, format=logging_fmt, datefmt=logging_datefmt,
```

Dopodiché si può procedere con il logging. Di default:

- se si utilizzano le funzioni di tab 12.1 viene usato il “root/default” logger
- se si inizia a loggare senza avere prima impostato i parametri di log non sarà possibile farlo poi a quanto pare

Per impostare il root logger si chiama `logging.basicConfig`. Un template di setup di logging è quello sopra:

- se non si specifica `level` prima di iniziare a loggare, saranno stampati **solo i messaggi dal warning in su** (no info, no debug)
- il `format` è una stringa in formato printf ma si può impostare style con la graffa aperta per avere una stringa tipo f-string variabile che ad esempio semplifica a "levelname name message" un formato possibile. Alcune variabili
 - `name` è il nome del logger (eg root)
 - `levelname` è il livello di gravità (da DEBUG a ERROR)
 - `asctime` è l'ora (formato impostabile con `datefmt`)
 - `message` è il messaggio passato in sede di chiamata.

Loggare ad un file Se si vuole evitare di mandare a console aggiungere (alle altre configurazioni di sopra)

```
logging.basicConfig(
    filename="app.log", # filepath
    encoding="utf-8", # encoding
    filemode="a" # appendi al file non sovrascrivere (es)
)
```

Loggare valore di variabili (eg a csv) torna comodo la f-string seguente

```
logging.debug(f"{varname=}")
```

Si può anche creare un formato di log che crea un csv. un template potrebbe essere

```
if some_problem:
    # output data to a csv log for external analysis
    logging.debug(f"{surname},{name},{age}")
```

Catturare stack trace Con `exc_info=True` vengono stampate nel log le informazioni di debug

```
try:
    res = 5/0
except ZeroDivisionError:
    logging.error("ErroreNelCalcolo", exc_info=True)
```

Se si logga da un except handler si può usare anche `logging.exception("ErroreNelCalcolo")` che risparmia digitazione. Questo è come `logging.error(exc_info=True)`

12.2 Logger custom

Per crearlo good practice è

```
logger = logging.getLogger(__name__) # good practice to pass __name__ as the name parameter
```

Per configurarlo non si usa una singola chiamata a `basicConfig` ma gli *handlers*. Ciascun logger può avere *uno o più handler*; nel secondo caso si mandano i log in vari posti (es `stdout` e a un file)

12.2.1 Setup degli handler

Nell'esempio di sotto impostiamo un output a file ed uno a standard error (contemporaneamente)

```
console_handler = logging.StreamHandler() # logga a console (stderr)
file_handler = logging.FileHandler("app.log", mode="a", encoding="utf-8") # logga a file
logger.addHandler(console_handler) # aggiungi l'handler al logger
logger.addHandler(file_handler) # aggiungi l'handler al logger
```

Dopo questa configurazione, quando si logga qualcosa es con `logger.warning("Messaggio")` questo verrà mandato sia a `stderr` che al file `app.log`.

Il modulo `logging` fornisce molti handler utili per specifiche applicazioni: es `RotatingFileHandler` crea un nuovo file una volta che un limite è raggiunto, o `TimedRotatingFileHandler` crea log per intervalli di tempo predefinito.

Per listare gli handler configurati

```
logger.handlers
```

12.2.2 Impostare la formattazione di un handler

Per impostare una specifica formattazione ad un handler, anche dopo che lo si è aggiunto al logger settargli un formatter come segue:

```
formatter = logging.Formatter(
    "{asctime} - {levelname} - {message}",
    style="{",
    datefmt="%Y-%m-%d %H:%M",
)

console_handler.setFormatter(formatter)
```

Questo impatta solo lo standard error, non l'output su file. Definendo/settando differenti formatter per i vari handler si può controllare l'ammontare/formato di informazione visualizzata nei log, oppure mostrare messaggi di debug in un file ma mostrare a console solo la roba più seria (o viceversa). Es csv su file verboso e messaggio stretto in standard error

12.2.3 impostare livello di log generale e di un handler

Per impostare il livello di log a livello globale (per tutti gli handler)

```
logger.setLevel("INFO")
```

Qui con due handler possiamo avere un log più verboso (con un livello inferiore) e un altro più terso.

Si può settare il livello del singolo handler mediante il suo metodo `setLevel`

```
console_handler.setLevel("DEBUG")
```

Tuttavia il **livello generale è importante** perchè settare il livello dell'handler più basso di quello del logger fa sì che i messaggi comunque non vengano stampati: il log globale definisce il livello più basso di log che verrà stampato e i singoli handler non possono mostrare log a livello più basso del logger cui sono attaccati.

Pertanto può essere utile **settare il logger a livello DEBUG** e gli handler a livello desiderato (per stderr e file). Un template per l'impostazione segue

```
logger.setLevel("DEBUG") # logger generale permetti tutto
console_handler.setLevel("WARNING") # in standard error ci va la roba seria
file_handler.setLevel("DEBUG") # nel file di debug ci va di ogni
```

12.2.4 Filtrare log

Di default il livello di log è basato sull'idea che, eg, se si è interessati nei warning si è probabilmente interessati anche in error etc. Tuttavia vi possono essere situazioni dove ha senso gestire messaggi di un dato livello a se/differentemente, e qui entrano in gioco i **Filter**.

Possono costituire un filtro

- una sottoclasse di `logging.Filter` alla quale si è sovrascritto il metodo `.filter` o comunque una classe che contiene un metodo `.filter`. In questi casi `.filter()` deve accettare un record di log e restituire un booleano. Dentro al corpo della funzione ha senso definire uno statement `if` che controlla il record di log fornito
- una callable (eg funzione) che si comporta come il metodo `filter` di cui sopra. La callable può essere una funzione con un parametro per il log record che l'handler passa al filtro per saper printare o no. Questo è il modo più semplice e lo approfondiamo di seguito

Ad esempio il filtro di sotto fa sì che l'handler mostri solo messaggi di DEBUG (non anche i superiori). Gli altri setting come quelli dati in precedenza

```
def show_only_debug(record):  
    return record.levelname == "DEBUG"
```

```
console_handler.addFilter(show_only_debug) # console printa solo il debug
```

Con questo setup qualsiasi log che non sia di livello `DEBUG` ritorna `False` e non sarà mostrato dall'handler cui è attaccato (in questo caso quello dello standard error).

Viceversa `file_handler` si comporta senza essere intaccato da questa modifica

Capitolo 13

Tools

Contents

13.1 uv	143
-------------------	-----

13.1 uv

Installazione

```
pipx install uv
```

Inizializzazione e setup Si parte dalla creazione del progetto

```
uv init --library mylib # solo libreria python
uv init --package mylib # libreria + script da commandline
```

Per aggiungere

- dipendenze alla libreria/package (necessarie per l'utilizzo)

```
uv add pandas
```

tool/package che sono necessari solo per lo sviluppo del pacchetto, non per il suo utilizzo

```
uv add --dev pytest ruff mpyy
```

Esecuzione di uno script Se in `pyproject.toml` abbiamo

```
[project.scripts]
yasss = "yasss:main"
```

Possiamo dare

```
uv run yasss
```


Parte II

Scientific Stack

Capitolo 14

Numpy

Contents

14.1	L'ndarray	148
14.1.1	Creazione e copia	148
14.1.2	Tipi (dtype): coercizione e testing	149
14.1.3	Forma, dimensioni e reshape	150
14.2	Indexing	152
14.2.1	Array unidimensionali	152
14.2.2	Array multidimensionali	153
14.2.3	Subarray come viste vs copie	156
14.2.4	Assegnazione e unicità degli indici	157
14.3	Elaborazioni di array	157
14.3.1	Inserimento/rimozione elementi (insert , delete)	157
14.3.2	Aritmetica vettorizzata	157
14.3.3	Operazioni insiemistiche	158
14.3.4	Concatenazione (concatenate , vstack , hstack)	158
14.3.5	Splitting (split , vsplit , hsplit)	159
14.3.6	Ripetizione/binding (repeat , tile)	160
14.3.7	Sorting/ordine (sort , argsort)	161
14.4	Universal functions	162
14.4.1	Introduzione	162
14.4.2	Metodi delle ufunction (reduce , accumulate , outer)	162
14.4.3	Creazione di ufunctions	164
14.5	Broadcasting	165
14.6	Altri argomenti	169
14.6.1	Lavorare con booleani	169
14.6.2	Array di stringhe	170

Il template per l'importazione è:

```
>>> import numpy as np
```

Fornisce:

- l'oggetto `ndarray`, un array multidimensionale efficiente, costruito come puntatore a dati in memoria;
- *universal functions*: funzioni per operare su tutti gli elementi di un array;
- strumenti per integrare codice scritto in C, C++ e Fortran

14.1 L'ndarray

L'ndarray è un array ad n dimensioni di dati omogenei composto da:

- un puntatore a dati in memoria;
- un attributo `dtype` che definisce il tipo di dato;
- un attributo `shape`, tuple che definisce la struttura dell'array.

14.1.1 Creazione e copia

Si usa la funzione `array` passando dati di tipo sequenza (liste, tuple ecc)

```
>>> # creazione a partire da una lista, in varie shape
>>> np.array([ 1, 2, 3]) # vector
array([1, 2, 3])
>>> x = np.array([[1, 2, 3], [4, 5, 6]]) # matrix
>>> x
array([[1, 2, 3],
       [4, 5, 6]])
```

Altre funzioni di convenienza per la generazione rapida di array:

```
>>> # Creazione rapida di dati
>>> np.arange(0, 20, 2) # simile a range(), da 0 a 20 a step di 2
array([ 0, 2, 4, 6, 8, 10, 12, 14, 16, 18])
>>> np.linspace(0, 1, 5) # interpolazione lineare
array([0. , 0.25, 0.5 , 0.75, 1. ])
>>> np.full(5, 2) # vettore riempito di 2
array([2, 2, 2, 2, 2])
>>> np.zeros(10) # array di zero
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
>>> np.ones((3, 5)) # array 3x5 di uno
array([[1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.]])
>>> np.eye(3) # matrice identità 3x3
array([[1., 0., 0.],
       [0., 1., 0.],
       [0., 0., 1.]])

>>> # creazione rapida sfruttando altre shape
>>> np.zeros_like(x) # array di 0 della stessa shape di x (np.ones_like)
array([[0, 0, 0],
       [0, 0, 0]])
```

```

>>> # Generazione casuale
>>> np.random.random((3, 3)) # array 3x3 con valori casuali uniformi 0-1
array([[0.87332816, 0.25201795, 0.49725844],
       [0.02322585, 0.37264043, 0.41684796],
       [0.78396845, 0.72582644, 0.51771643]])
>>> np.random.randint(0, 10, (3, 3)) # matrice 3x3 con interi nell'intervallo [0,10 )
array([[3, 9, 6],
       [4, 0, 6],
       [1, 5, 8]])
>>> np.random.normal(0, 1, 5) # da normale mu=0, sd=1
array([ 0.19611289, -0.58820258,  0.53888779,  0.41506749, -1.35704571])

```

Referenza vs copia di array Se si assegna una variabile array ad un'altra variabile si crea un nuovo riferimento, non una copia: ossia non viene effettuata una copia di dati ma si creano due nomi che puntano alla stessa memoria:

```

>>> x = np.arange(10)
>>> y = x
>>> x[2] = -9999
>>> y
array([ 0, 1, -9999, 3, 4, 5, 6, 7, 8,
        9])
>>> y[0] = -111
>>> x
array([-111, 1, -9999, 3, 4, 5, 6, 7, 8,
        9])

```

Se necessario creare una copia per evitare di modificare l'originale utilizzare il metodo `copy`:

```

>>> x = np.arange(3)
>>> x_copy = x.copy()
>>> x_copy[0] = -999
>>> x
array([0, 1, 2])

```

14.1.2 Tipi (dtype): coercizione e testing

I tipi di dato, chiamati `dtype`, sono riportati in tabella 14.1: per utilizzarli in creazione dell'array specificare l'omonimo parametro in uno di questi due modi possibili:

```

>>> np.zeros(10, dtype = 'int16')
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int16)
>>> np.zeros(10, dtype = np.float64)
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])

```

Coercizione del dtype Si usa il metodo `astype` sull'array da convertire

dtype	Descrizione
bool	Boolean (True or False) stored as a byte
intc	Identical to C <code>int</code> (normally <code>int32</code> or <code>int64</code>)
intp	Integer used for indexing (same as C <code>ssize_t</code> ; normally either <code>int32</code> or <code>int64</code>)
int8	Byte (-128 to 127)
int16	Integer (-32768 to 32767)
int32	Integer (-2147483648 to 2147483647)
int64	Integer (-9223372036854775808 to 9223372036854775807)
uint8	Unsigned integer (0 to 255)
uint16	Unsigned integer (0 to 65535)
uint32	Unsigned integer (0 to 4294967295)
uint64	Unsigned integer (0 to 18446744073709551615)
float16	Half precision float: sign bit, 5 bits exponent, 10 bits mantissa
float32	Single precision float: sign bit, 8 bits exponent, 23 bits mantissa
float64	Double precision float: sign bit, 11 bits exponent, 52 bits mantissa
complex64	Complex number, represented by two 32-bit floats (real and imaginary components)
complex128	Complex number, represented by two 64-bit floats (real and imaginary components)

Tabella 14.1: dtypes di numpy

```
>>> a = np.zeros(10, dtype = np.float64)
>>> b = a.astype(np.int8)
>>> b
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int8)
```

Test del tipo I tipi numpy hanno una gerarchia per la quale ad esempio gli interi derivano dalla classe genitrice `np.integer` mentre i numeri a virgola mobile da `np.floating`.

Per il testing si possono usare queste classi in `np.issubdtype`.

```
>>> np.issubdtype(a.dtype, np.integer)
False
>>> np.issubdtype(a.dtype, np.floating)
True
```

14.1.3 Forma, dimensioni e reshape

14.1.3.1 Forma e dimensioni

Ogni array ha attributo:

- `ndim`: numero di dimensioni
- `shape`: numero di elementi per ciascuna dimensione
- `size`: numero di elementi complessivi
- `nbytes`: memoria occupata in bytes (dipendente dal dtype adottato, investigabile con `itemsize`)

```
>>> z1 = np.zeros(shape = 3) # vector
>>> z2i = np.zeros(shape = (3,4), dtype = np.int8) # matrix
```

```

>>> z2f = np.zeros(shape = (3,4), dtype = np.float32)
>>> z3 = np.zeros(shape = (3,4,5)) # general array

>>> z2i.ndim
2
>>> z2i.shape
(3, 4)
>>> z2i.size
12
>>> z2i.nbytes
12
>>> z2f.nbytes
48
>>> z2i.itemsize
1
>>> z2f.itemsize
4

```

14.1.3.2 Reshaping

Per modificarla la forma si può assegnare all'attributo `shape` o utilizzare il metodo `reshape` (ricordandosi di salvare); `reshape` ritorna una vista sui dati e non effettua copie, se non necessario.

```

>>> a = np.arange(4) ## assegnare all'attributo shape (C mode/row major di default)
>>> a
array([0, 1, 2, 3])
>>> a.shape = (2,2)
>>> a
array([[0, 1],
       [2, 3]])

>>> b = a.reshape((4,1)) ## uso di reshape
>>> b
array([[0],
       [1],
       [2],
       [3]])

>>> c = a.reshape((4,)) ## tornare ad un array a una dimensione di 4
>>> c
array([0, 1, 2, 3])

>>> d = a.reshape(-1) ## stessa cosa ma ancora più comodo
>>> d
array([0, 1, 2, 3])

```

14.1.3.3 Ravelling/flattening

Altri due metodi per tornare ad una struttura dati unidimensionale sono:

- `flatten` fa il flattening producendo sempre una copia dell'array di partenza
- `ravel` fa il flattening ma non produce una copia dei dati, bensì una vista dell'array originale; se si modifica l'array ritornato da `ravel` si potrebbero modificare gli elementi dell'array originale.
`ravel` è spesso più veloce ma bisogna essere più attenti con le modifiche.

```
>>> b.flatten()
array([0, 1, 2, 3])
>>> b.ravel()
array([0, 1, 2, 3])
```

14.2 Indexing

Serve per accedere in lettura e scrittura agli elementi di un array.

14.2.1 Array unidimensionali

Si può specificare tra quadre alternativamente:

- lo slicing `start:stop:step` (con default rispettivamente a, 0, dimensione e 1) similmente ai dati builtin

```
>>> x = np.arange(10)
>>> x[1]
np.int64(1)
>>> x[1] = -1
>>> x[3:5] = [5, 4]
>>> x[:4:2] = 0
>>> x[-2] = 1
>>> x
array([ 0, -1,  0,  5,  4,  5,  6,  7,  1,  9])
```

Se `step` è negativo si procede in senso inverso (i default di `start/stop` vengono invertiti: per `start` la dimensione dell'array, per `stop` 0)

```
>>> x[::-1] # reverse an array
array([ 9,  1,  7,  6,  5,  4,  5,  0, -1,  0])
>>> x[5::-2] # reversed from index 5 backward
array([ 5,  5, -1])
```

- **liste e array numerici**; nel secondo caso la struttura ritornata ha lo stesso `shape` dell'indice (non del dato indicizzato):

```
>>> # lista
>>> select = [1, 2, 4, 5]
>>> x[select] # x[np.array(select)] alternativamente
array([-1,  0,  4,  5])

>>> # array con shape (2x2)
>>> ind = np.array([[2, 1],
```



```
... [4, 7]])
>>> x[ind]
array([[ 0, -1],
       [ 4,  7]])
```

- **liste/array logici**

```
>>> x = np.array([1, 2, 3])
>>> sell = [True, False, True]
>>> sela = np.array(sell)
>>> x[sell]
array([1, 3])
>>> x[sela]
array([1, 3])
```

14.2.2 Array multidimensionali

Tra quadre, separate da virgola, porre qualcosa di utilizzabile (slice, liste, array):

- **interi:** permettono di selezionare un singolo elemento

```
>>> # bidimensionale: [righe, colonne]
>>> x = np.arange(12).reshape(3,4)
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])

>>> x[0, 0] # singolo elemento
np.int64(0)
```

- **slicing**

```
>>> x[:2, 1:] # slicing: sino riga 2 esclusa, colonna 1 inclusa e sgg
array([[1, 2, 3],
       [5, 6, 7]])
>>> x[::-1, ::-1] # reverse
array([[11, 10,  9,  8],
       [ 7,  6,  5,  4],
       [ 3,  2,  1,  0]])
```

L'accesso a righe/colonne intere avviene combinando indici numerici/logici e slicing vuota (:). Se un indice non è specificato, si prendono tutti i dati su quella dimensione:

```
>>> # se si fornisce un solo indice alla struttura multidimensionale
>>> # viene interpretato nel primo asse/dimensione
>>> x[0] # prima riga
array([0, 1, 2, 3])

>>> # prima riga the proper way
>>> # x[0, ] # this works
>>> x[0, :]
```

```
array([0, 1, 2, 3])
>>> x[0, ::]
array([0, 1, 2, 3])
```

```
>>> # prima colonna
>>> # x[, 0] # this gives error
>>> x[:, 0]
array([0, 4, 8])
>>> x[:, :, 0]
array([0, 4, 8])
```

- **liste e array** in questo caso per l'accoppiamento degli indici funziona il *broadcasting*:

- se utilizziamo due array unidimensionali verrà restituita la selezione in parallelo
- se un indice è un array multidimensionale (vettore riga o colonna) otteniamo una struttura a due dimensioni (ogni valore di riga è matchato con ogni vettore colonna così come avviene nel *broadcasting* delle operazioni aritmetiche)

```
>>> x = np.arange(12).reshape(3,4)
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])
```

```
>>> x[[0,1], [1,2]] # liste: elemento (0, 1) ed elemento (1, 2) della x
array([1, 6])
```

```
>>> row = np.array([0, 1, 2]) # array: elementi (0, 2), (1,1) e (2,3) (broadcasting)
>>> col = np.array([2, 1, 3])
>>> x[row, col]
array([ 2,  5, 11])
```

```
>>> rowt = row.reshape(3,1) # array2
>>> rowt
array([[0],
       [1],
       [2]])
>>> col
array([2, 1, 3])
>>> (rowt * col).shape # struttura degli indici post broadcast?
(3, 3)
>>> x[rowt, col]
array([[ 2,  1,  3],
       [ 6,  5,  7],
       [10,  9, 11]])
```

Nell'indexing di liste e array la struttura ritornata riflette la shape degli indici post broadcast, non la shape dell'array indicizzato.

- **indexing logico** (*boolean masking*): la selezione di righe/colonne mediante liste/array logici si fa normalmente

```
>>> x = np.arange(12).reshape(3,4)
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])

>>> # selezione colonne (prima e seconda)
>>> c1 = [True, True, False, False]
>>> ca = np.array(c1)
>>> x[:, c1]
array([[0, 1],
       [4, 5],
       [8, 9]])
>>> x[:, ca]
array([[0, 1],
       [4, 5],
       [8, 9]])

>>> # selezione righe (prima e terza)
>>> r1 = [True, False, True]
>>> ra = np.array(r1)
>>> x[r1, :]
array([[ 0,  1,  2,  3],
       [ 8,  9, 10, 11]])
>>> x[ra, :]
array([[ 0,  1,  2,  3],
       [ 8,  9, 10, 11]])
```

Se il `ndim` dell'oggetto passato come indice coincide con quello indicizzato, viene ritornato un 1-dimensional array riempito con gli elementi corrispondenti a `True`.

Questo può essere usato per masking. Ad esempio:

```
>>> # esempio 1: masking
>>> b = np.arange(9).reshape(3, 3)
>>> b
array([[0, 1, 2],
       [3, 4, 5],
       [6, 7, 8]])
>>> b > 4
array([[False, False, False],
       [False, False,  True],
       [ True,  True,  True]])
>>> b[b > 4]
array([5, 6, 7, 8])

>>> # esempio 2: selezionare intersezione di righe e colonne
>>> rar = ra.reshape(3,1)
>>> rar
```

```

array([[ True],
       [False],
       [ True]])
>>> ca
array([ True,  True, False, False])

>>> # x[rar, ca] # doesnt work
>>> # x[ra, ca] # doesnt work

>>> rar * ca          # nel caso di logici questo è utile nell'indicare la selez
array([[ True,  True, False, False],
       [False, False, False, False],
       [ True,  True, False, False]])
>>> x[rar * ca]       # black magic come in b>4, ma non mantiene la struttura :(
array([0, 1, 8, 9])
>>> x[np.ix_(ra, ca)] # per mantenere la struttura usare quanto ritornato da np.
array([[0, 1],
       [8, 9]])

```

14.2.3 Subarray come viste vs copie

I subarray generati

- con *slicing/tuple* sono **viste**: pertanto eventuali modifiche si ripercuoteranno sull'array/struttura di base indipendentemente da dove sono state effettuate;
- con *array/liste* sono **copie**

```

>>> x = np.arange(10)          # subarray con slice sono una vista
>>> x_slice = x[5:8]
>>> x_slice[2] = 999
>>> x
array([ 0,  1,  2,  3,  4,  5,  6, 999,  8,  9])

>>> x = np.arange(10)          # subarray con lista sono copia
>>> x_slice = x[[5, 6, 7]]
>>> x_slice[2] = 999
>>> x
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])

>>> x = np.arange(4)           # subarray con array sono copia
>>> ind = np.array([True, True, False, False])
>>> x_slice = x[ind]
>>> x_slice[:] = 999
>>> x
array([0, 1, 2, 3])

```

14.2.4 Assegnazione e unicità degli indici

Se non si desiderano comportamenti inattesi, prestare attenzione all'unicità degli indici, in quanto se un indice è ripetuto l'assegnazione sarà effettuata molteplici volte, come i seguenti esempi mostrano

```
>>> x = np.zeros(10, dtype = np.int_)

>>> # primo esempio
>>> x[[0,0]] = [4, 6]
>>> # qui si ha x[0] = 4 e poi x[0] = 6
>>> x
array([6, 0, 0, 0, 0, 0, 0, 0, 0, 0])

>>> # secondo esempio
>>> i = [2,2,4,4,6,6,6,6,6,6]
>>> x[i] += 1
>>> x
array([6, 0, 1, 0, 1, 0, 1, 0, 0, 0])
>>> # anche questo non intuitivo, si pensava la posizione 6 fosse
>>> # aumentato tante volte, ma così non è per cazzi suoi
>>> # (vedi vanderplas fancy indexing nel caso, ma anche chi se ne ciava)
```

14.3 Elaborazioni di array

14.3.1 Inserimento/rimozione elementi (insert, delete)

```
>>> a = np.array([1, 2, 3]) # any change need to be assigned to be saved
>>> np.insert(a, 1, 5)      # insert element in an array
array([1, 5, 2, 3])
>>> np.delete(a, [1])      # remove item from an array
array([1, 3])
```

14.3.2 Aritmetica vettorizzata

Le operazioni aritmetiche sono vettorizzate per cui è possibile fare

```
>>> x = np.arange(4)
>>> x
array([0, 1, 2, 3])

>>> ## Operazioni aritmetiche
>>> -x      # unary negation
array([ 0, -1, -2, -3])
>>> x + 1   # addition
array([1, 2, 3, 4])
>>> x - 5   # subtraction
array([-5, -4, -3, -2])
>>> x * 2   # multiplication
array([0, 2, 4, 6])
>>> x ** 2  # power
```

Funzione	Descrizione
<code>unique(x)</code>	sorted unique elements in x
<code>intersect1d(x, y)</code>	sorted common elements in x and y
<code>union1d(x, y)</code>	sorted union of elements
<code>in1d(x, y)</code>	boolean array if each element of x is contained in y
<code>setdiff1d(x, y)</code>	set difference (elements in x that are not in y)
<code>setxor1d(x, y)</code>	set symmetric differences (elements in one of the arrays, but not both)

Tabella 14.2: Operazioni insiemistiche tra array

```

array([0, 1, 4, 9])
>>> x / 2 # division
array([0. , 0.5, 1. , 1.5])
>>> x // 2 # floor division (e.g., 3 // 2 = 1)
array([0, 0, 1, 1])
>>> x % 2 # modulus remainder
array([0, 1, 0, 1])
>>> -(0.5*x + 1) ** 2 # misc expression
array([-1. , -2.25, -4. , -6.25])

>>> ## Comparazione
>>> x == 2
array([False, False,  True, False])
>>> x != 2
array([  True,  True, False,  True])
>>> x > 2
array([False, False, False,  True])
>>> x >= 2
array([False, False,  True,  True])
>>> x < 2
array([  True,  True, False, False])
>>> x <= 2
array([  True,  True,  True, False])

```

14.3.3 Operazioni insiemistiche

Per effettuare operazioni di tipo insiemistico le funzioni sono quelle riportate in tabella 14.2.

14.3.4 Concatenazione (`concatenate`, `vstack`, `hstack`)

`numpy.concatenate` prende una tupla o una lista di array e li unisce

```

>>> x = np.array([1, 2, 3]) # unidimensionale
>>> y = np.array([3, 2, 1])
>>> z = [99, 99, 99]
>>> np.concatenate([x, y, z])
array([ 1,  2,  3,  3,  2,  1, 99, 99, 99])

>>> x = np.array([[1, 2, 3], [4, 5, 6]]) # bidimensionale
>>> y = np.array([[7, 8, 9], [10, 11, 12]])

```

```
>>> np.concatenate([x, y])           # axis=0 default
array([[ 1,  2,  3],
       [ 4,  5,  6],
       [ 7,  8,  9],
       [10, 11, 12]])
>>> np.concatenate([x, y], axis=1)
array([[ 1,  2,  3,  7,  8,  9],
       [ 4,  5,  6, 10, 11, 12]])
```

Per con array di dimensioni miste `numpy.hstack` e `numpy.vstack` tornano comode (per fare stack sulla prima o seconda dimensione)¹:

```
>>> x = np.array([1, 2, 3])
>>> grid = np.array([[9, 8, 7],
...                  [6, 5, 4]])
>>> y = np.array([[99],
...               [99]])

>>> np.hstack([grid, y])             # horizontally stack the arrays
array([[ 9,  8,  7, 99],
       [ 6,  5,  4, 99]])
>>> np.vstack([x, grid])             # vertically stack the arrays
array([[1, 2, 3],
       [9, 8, 7],
       [6, 5, 4]])
```

14.3.5 Splitting (split, vsplit, hsplit)

`numpy.split` suddivide un array in molteplici array. Si usano passando una lista di indici per indicare dove fare i tagli:

```
>>> x = [1, 2, 3, 99, 99, 3, 2, 1]    # split di array
>>> x1, x2, x3 = np.split(x, [3, 5])
>>> x1
array([1, 2, 3])
>>> x2
array([99, 99])
>>> x3
array([3, 2, 1])

>>> x = np.arange(10).reshape(5,2)    # di matrice
>>> x
array([[0, 1],
       [2, 3],
       [4, 5],
       [6, 7],
       [8, 9]])
>>> x1, x2, x3 = np.split(x, [1, 3])
>>> x1
array([[0, 1]])
```

¹Analogamente `np.dstack` effettuerà lo stack sulla terza dimensione.

```
>>> x2
array([[2, 3],
       [4, 5]])
>>> x3
array([[6, 7],
       [8, 9]])
```

`hsplit/vsplit` sono funzioni di convenienza per splittare sulla prima o seconda dimensione, specularmente a `vstack/hstack`²

```
>>> x = np.arange(16).reshape((4, 4))
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11],
       [12, 13, 14, 15]])

>>> upper, lower = np.vsplit(x, [2])    # vertical split
>>> upper
array([[0, 1, 2, 3],
       [4, 5, 6, 7]])
>>> lower
array([[ 8,  9, 10, 11],
       [12, 13, 14, 15]])

>>> left, right = np.hsplit(grid, [2]) # horizontal split
>>> left
array([[9, 8],
       [6, 5]])
>>> right
array([[7],
       [4]])
```

14.3.6 Ripetizione/binding (repeat, tile)

Per ripetere:

- i singoli argomenti di un array, ciascuno n volte, si usa `repeat`; nel caso di array multidimensionali si può selezionare l'asse della ripetizione
- un array nel suo complesso usare `tile`: se il secondo argomento è un intero viene effettuata una copia per riga, con una tuple si specifica la struttura finale

```
>>> x = np.array([1,2,3])    # unidimensional repeat
>>> x.repeat(2)              # a) each element 2 time
array([1, 1, 2, 2, 3, 3])
>>> x.repeat([3,2,1])       # b) different times
array([1, 1, 1, 2, 2, 3])

>>> np.tile(x, 2)           # unidimensional tile
```

²Analogamente `numpy.dsplit` effettua il taglio sul terzo asse.


```

array([1, 2, 3, 1, 2, 3])

>>> x = np.arange(4).reshape(2,2) # multidimensional repeat
>>> x.repeat(2, axis = 0)          # a) by row, common number
array([[0, 1],
       [0, 1],
       [2, 3],
       [2, 3]])
>>> x.repeat([2,3], axis = 1)      # b) by col, different number
array([[0, 0, 1, 1, 1],
       [2, 2, 3, 3, 3]])

>>> np.tile(x, 2)                  # multidimensional tile (default by col)
array([[0, 1, 0, 1],
       [2, 3, 2, 3]])
>>> np.tile(x, (2, 3))            # specify the building repetition
array([[0, 1, 0, 1, 0, 1],
       [2, 3, 2, 3, 2, 3],
       [0, 1, 0, 1, 0, 1],
       [2, 3, 2, 3, 2, 3]])
>>> np.tile(x, (2, 1))            # by col
array([[0, 1],
       [2, 3],
       [0, 1],
       [2, 3]])

```

14.3.7 Sorting/ordine (sort, argsort)

Per

- ordinare un array usare il metodo `sort`. Nel caso di array multidimensionale, specificare `axis` per la dimensione di sorting:

```

>>> x = np.array([2,1,3,4])        # unidimensional sorting
>>> x.sort()
>>> x
array([1, 2, 3, 4])

>>> rand = np.random.RandomState(42) # bidimensional
>>> X = rand.randint(0, 10, (4, 6))
>>> np.sort(X, axis=0)              # sorting di ogni colonna
array([[2, 1, 4, 0, 1, 5],
       [5, 2, 5, 4, 3, 7],
       [6, 3, 7, 4, 6, 7],
       [7, 6, 7, 4, 9, 9]])
>>> np.sort(X, axis=1)              # sort di ogni riga
array([[3, 4, 6, 6, 7, 9],
       [2, 3, 4, 6, 7, 7],
       [1, 2, 4, 5, 7, 7],
       [0, 1, 4, 5, 5, 9]])

```

Da notare che negli ultimi due casi si perdono eventuali relazioni tra righe e colonne.

- ottenere gli indici dell'ordine si usa `argsort`

```
>>> x = np.array([2, 1, 4, 3, 5])
>>> i = np.argsort(x)
>>> i
array([1, 0, 3, 2, 4])
>>> x[i]
array([1, 2, 3, 4, 5])
```

14.4 Universal functions

14.4.1 Introduzione

Le universal functions (reference qui), o *ufunctions*, sono funzioni chiamate come

```
np.ufunc()
```

ed eseguite su tutti gli elementi di array in maniera vettorizzata.

Vi sono funzioni *unarie* (si applicano ad un array separatamente, le più importanti in tabella 14.3) e *binarie* (si applicando a più array, le più importanti in tab 14.4).

Gli operatori aritmetici e di comparazione (es `>=`) funzionano sotto la scocca, come *ufuncs* binarie di tabella (es `a+b` chiama `np.add(a,b)`).

Altre ufuncs si trovano in `scipy.special`

14.4.2 Metodi delle ufunction (reduce, accumulate, outer)

A quanto pare le ufunction in realtà assomigliano a classi aventi propri metodi (`reduce`, `accumulate`, `reduceat`, `outer`, `at`).

La chiamata di questi metodi è utile soprattutto per funzioni che prendono in input due argomenti e ne ritornano uno singolo in output (eg binarie):

- `reduce` applica una ufuncs agli elementi di un array sino a che un singolo risultato rimane
- `accumulate` fa l'operazione cumulata
- `outer` applica una funzione al prodotto cartesiano degli elementi di due array

Un esempio con `np.add`

```
>>> x = np.arange(1, 6)

>>> np.add.reduce(x)          # come np.sum(x)
np.int64(15)
>>> np.add.accumulate(x)     # come np.cumsum(x)
array([ 1,  3,  6, 10, 15])
>>> np.add.outer(x, x)
```

Funzione	Descrizione
<code>abs, fabs</code>	absolute value
<code>sqrt</code>	square root
<code>exp, expm1</code>	esponenziale, $\exp(x) - 1$
<code>log, log10, log2, log1p</code>	Natural log, log base 10, log base 2, and $\log(1 + x)$, respectively
<code>sin, cos, tan</code>	trigonometriche
<code>arcsin, arccos, arctan</code>	trigonometriche inverse
<code>sign</code>	funzione segno: 1 se positivo, 0 se zero, o -1 se negativo
<code>ceil</code>	smallest integer $\geq$ to each element
<code>floor</code>	largest integer $\leq$ to each element
<code>rint</code>	round to nearest integer (preserving the dtype)
<code>isnan</code>	boolean indicating whether each value is NaN (Not a Number)
<code>isfinite, isinf</code>	each element is finite (non-inf, non-NaN) or infinite, respectively
<code>any</code>	per array booleani, testa se alcuni sono veri
<code>all</code>	per array booleani, testa se tutti sono veri
<code>logical_not, bitwise_not (~)</code>	logical not element-wise
<code>sum</code>	Sum of all the elements in the array or along an axis.
<code>prod</code>	Produttoria
<code>mean</code>	Arithmetic mean. Zero-length arrays have NaN mean.
<code>median</code>	Mediana
<code>percentile</code>	Percentile
<code>std, var</code>	Standard deviation and variance.
<code>min, max</code>	Minimum and maximum.
<code>argmin, argmax</code>	Indices of minimum and maximum elements, respectively.
<code>cumsum</code>	Cumulative sum of elements starting from 0
<code>cumprod</code>	Cumulative product of elements starting from 1

Tabella 14.3: *ufuncs* unarie

Funzione	Descrizione
<code>add (+)</code>	addition
<code>subtract (-)</code>	subtraction
<code>negative (-)</code>	unary negation
<code>multiply (*)</code>	multiplication
<code>divide (/)</code>	division
<code>floor_divide (//)</code>	resto divisione
<code>power (**)</code>	power
<code>mod (%)</code>	modulus remainder
<code>less (<)</code>	less than
<code>greater (>)</code>	
<code>less_equal (<=)</code>	
<code>greater_equal (>=)</code>	
<code>not_equal (!=)</code>	
<code>equal (==)</code>	
<code>maximum, fmax</code>	Element-wise maximum. <code>fmax</code> ignores NaN
<code>minimum, fmin</code>	Element-wise minimum. <code>fmin</code> ignores NaN
<code>logical_and, bitwise_and (&)</code>	and
<code>logical_or, bitwise_or ()</code>	or
<code>logical_xor, bitwise_xor (^)</code>	xor
<code>matmul (@)</code>	Matrix product of two arrays
<code>cov</code>	covariance coefficient/matrix
<code>corrcoef</code>	correlation coefficient/matrix

Tabella 14.4: *ufuncs* binarie

```
array([[ 2,  3,  4,  5,  6],
       [ 3,  4,  5,  6,  7],
       [ 4,  5,  6,  7,  8],
       [ 5,  6,  7,  8,  9],
       [ 6,  7,  8,  9, 10]])
```

14.4.3 Creazione di ufunctions

Per la creazione di funzioni vettorizzate possiamo:

- scrivere funzioni in puro python e vettorizzarle con `np.frompyfunc` (o il wrapper `vectorize`).
`numpy.frompyfunc` prende in input una funzione, il numero di inputs presi e il numero di outputs forniti; la funzione creata/ritornata restituisce sempre un array:

```
>>> def add1_worker(x): # 1 input 1 output
...     return x + 1
...
>>> add1 = np.frompyfunc(add1_worker, 1, 1)
>>> add1(np.arange(10))
array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10], dtype=object)

>>> def add2_worker(x, y): # 2 input, 1 output
```

```

...     return x + y
...
>>> add2 = np.frompyfunc(add2_worker, 2, 1)
>>> add2(np.arange(10), np.arange(10))
array([0, 2, 4, 6, 8, 10, 12, 14, 16, 18], dtype=object)

>>> def max_min_worker(x, y): # 2 input 2 output
...     return max(x, y), min(x, y) # pure python here
...
>>> maxmin = np.frompyfunc(max_min_worker, 2, 2)
>>> maxmin_wrong = np.frompyfunc(max_min_worker, 2, 1) # wrong in returned

>>> x = np.random.random(3)
>>> y = np.random.random(3)
>>> x
array([0.56777422, 0.90689179, 0.00766334])
>>> y
array([0.93149241, 0.09515047, 0.47903771])
>>> maxmin(x, y)
(array([0.9314924075528314, 0.9068917932415504, 0.47903770653037625],
      dtype=object), array([0.5677742191034004, 0.09515046559874707, 0.007663342813018725]
      dtype=object))
>>> maxmin_wrong(x, y)
array([(0.9314924075528314, 0.5677742191034004),
      (0.9068917932415504, 0.09515046559874707),
      (0.47903770653037625, 0.007663342813018725)], dtype=object)

```

`numpy.vectorize` è una alternativa meno generale/più lenta che permette di specificare il tipo ritornato la funzione.

- utilizzare compilatori LLVM con `numba` a partire da funzioni Python. Mediante Numba si creano funzioni veloci mediante il progetto LLVM (che traduce codice python in codice macchina eseguibile da CPU o GPU). Vedere https://wesmckinney.com/book/advanced-numpy.html#numpy_numba
- utilizzare l'interfaccia C (modo più generale)

14.5 Broadcasting

Per

- array della stessa dimensionalità le operazioni aritmetiche vengono effettuate elemento per elemento

```

>>> x = np.array([0, 1, 2])
>>> y = np.array([5, 5, 5])
>>> x + y
array([5, 6, 7])

```

- array di diverse dimensioni opera il *broadcasting*, ossia un set di regole per applicare ufuncs binarie ad array di dimensioni non uguale. Alcuni esempi:

```

>>> # aggiunta di costante ad array: il valore 5 viene espanso a [5 5 5] prima d
>>> x + 5
array([5, 6, 7])

>>> # aggiunta di vettore a matrice il vettore viene stretchato sulla
>>> # seconda dimensione per matchare la forma della matrice
>>> M = np.ones((3, 3))
>>> M
array([[1., 1., 1.],
       [1., 1., 1.],
       [1., 1., 1.]])
>>> M + x
array([[1., 2., 3.],
       [1., 2., 3.],
       [1., 2., 3.]])

>>> # somma di vettore 1 x 3 con sua trasposta 3 x 1: entrambi gli array
>>> # sono stretchati fino a raggiungere una dimensione comune (due
>>> # matrici 3 x 3) dopodiché viene effettuata la somma.
>>> x = np.arange(3)
>>> y = x.reshape(3,1).copy()
>>> x
array([0, 1, 2])
>>> y
array([[0],
       [1],
       [2]])
>>> x + y
array([[0, 1, 2],
       [1, 2, 3],
       [2, 3, 4]])

```

La geometria di esempi del genere è visualizzata in figura 14.1; non vi è una vera e propria espansione in memoria per ragioni di efficienza ma è utile tenere a mente come modello.

Regole di funzionamento Informalmente funziona abbastanza similmente al recycling di R: l'array più piccolo viene replicato per matchare quello più grande³. Formalmente le regole applicate in sequenza sono:

1. se gli array differiscono nel numero di dimensioni (il numero di elementi di **shape**), la forma di quello con un numero inferiori di dimensioni è riempita a sinistra con 1;
2. una volta uniformati **numpy** confronta gli **shape**, elemento (dimensione) per elemento, partendo dall'ultimo. Due dimensioni sono *compatibili* quando sono alternativamente uguali o una di esse è 1: se

- tutte le dimensioni sono *compatibili* verrà eseguita l'operazione

³Il broadcasting è lievemente più sicuro/meno flessibile perché funziona solamente se la struttura matcha perfettamente o se si ha un array di un elemento (è questo che di fatto viene riciclato).




Figura 14.1: Broadcasting geometrics.

- *non tutte sono compatibili* viene sollevata l'eccezione e l'operazione termina

Nel caso di dimensioni compatibili, se due dimensioni non sono uguali, l'array con shape 1 in quella dimensione viene stretchato per matchare l'altra dimensione;

Example 14.5.1 (Somma di un array bidimensionale a monodimensionale). Abbiamo:

```
>>> M = np.ones((2, 3))
>>> a = np.arange(3)
>>> M
array([[1., 1., 1.],
       [1., 1., 1.]])
>>> a
array([0, 1, 2])

>>> ## le shape sono
>>> M.shape
(2, 3)
>>> a.shape
(3,)
```

Applicando le regole del broadcasting:

1. per la regola 1 l'array `a` ha meno dimensioni quindi viene riempito sulla sinistra

```
M.shape -> (2, 3)
a.shape -> (1, 3)
```

2. vediamo quali dimensioni non sono in agreement, queste verranno stretchate per matchare

```
M.shape -> (2, 3)
a.shape -> (2, 3)
```

Ora le shape matchano e la shape del risultato finale sarà (2, 3)

```
>>> M+a
array([[1., 2., 3.],
       [1., 2., 3.]])
```

Example 14.5.2 (Entrambi gli array necessitano di broadcasting). Abbiamo:

```
>>> a = np.arange(3).reshape((3, 1))
>>> b = np.arange(3)
>>> a
array([[0],
       [1],
       [2]])
>>> b
array([0, 1, 2])
>>> a.shape
(3, 1)
>>> b.shape
(3,)
```

Si ha:

1. Per regola 1 b viene riempito sulla sinistra con 1

```
a.shape -> (3, 1)
b.shape -> (1, 3)
```

2. per regola 2 facciamo l'upgrade degli 1 per matchare la dimensione dell'array

```
a.shape -> (3, 3)
b.shape -> (3, 3)
```

3. visto che matchano il risultato sarà un array 3×3

Example 14.5.3 (Array incompatibili). Un caso lievemente diverso dal primo dove M è trasposta

```
>>> M = np.ones((3, 2))
>>> a = np.arange(3)
>>> M
array([[1., 1.],
       [1., 1.],
       [1., 1.]])
>>> a
array([0, 1, 2])
```



```
>>> M.shape
(3, 2)
>>> a.shape
(3,)
```

Per regola

1. riempiamo a sinistra a

```
M.shape -> (3, 2)
a.shape -> (1, 3)
```

2. la prima dimensione di a è stretchata e si ha

```
M.shape -> (3, 2)
a.shape -> (3, 3)
```

3. le dimensioni finali non matchano quindi viene sollevato un errore

```
>>> M + a
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: operands could not be broadcast together with shapes (3,2) (3,)
```

14.6 Altri argomenti

14.6.1 Lavorare con booleani

Vediamo un po' di applicazioni utili

```
>>> ## dati
>>> rng = np.random.RandomState(0)
>>> n = rng.randint(10, size=(3, 4)) # interi uniformi < 10
>>> x = np.array([True, False, True, False])
>>> y = np.array([True, True, False, False])

>>> ## operatori booleani vettorizzati
>>> x & y # np.bitwise_and
array([ True, False, False, False])
>>> x | y # np.bitwise_or
array([ True,  True,  True, False])
>>> ~x # np.bitwise_not
array([False,  True, False,  True])
>>> x ^ y # np.bitwise_xor
array([False,  True,  True, False])

>>> ## any/ all
>>> np.any(n > 8)
np.True_
>>> np.all(n < 10)
np.True_
>>> np.all(n < 8, axis=1)
```

```

array([ True, False,  True])

>>> ## conta di elementi che rispettano un test
>>> np.sum(n < 6) # overall
np.int64(8)
>>> np.sum(n < 6, axis = 1) # per riga
array([4, 2, 2])
>>> np.sum(n > 6, axis = 0) # per colonna
array([1, 1, 1, 0])

>>> ## if then else vettorizzato: np.where(test, iftrue, iffalse)
>>> t = np.arange(6)
>>> f = -t
>>> test = np.array([True, False] * 3)
>>> res = np.where(test, t, f)
>>> res
array([ 0, -1,  2, -3,  4, -5])

>>> # recoding con np.where
>>> c = np.where(t > 3, 3, np.where(t > 1, 2, 1))
>>> c
array([1, 1, 2, 2, 3, 3])

>>> # o con algebra e logica pura
>>> d = 1 + (t > 1) + (t > 3)
>>> d
array([1, 1, 2, 2, 3, 3])

```

14.6.2 Array di stringhe

Gli array possono immagazzinare anche stringhe, ma queste devono essere di dimensione fissata per motivi di efficienza

```

>>> names = ["luca", "bob", "joe"]
>>> x = np.array(names)
>>> x.dtype # stringhe di 4 elementi al massimo
dtype('<U4')
>>> x[0][0:2] # utilizzo di indici
'lu'
>>> # sono comunque normali stringhe eh ...
>>> for i in range(3):
...     x[i] = x[i].capitalize()
...
>>> x
array(['Luca', 'Bob', 'Joe'], dtype='<U4')
>>> # ... ma di lunghezza massima fissata
>>> x[2] = "asdasdasd" # assegnazione, ocio si tronca silentemente
>>> x
array(['Luca', 'Bob', 'asda'], dtype='<U4')

>>> # per allocare più spazio, ad esempio

```

```
>>> y = np.array(names, dtype = '<U16')
>>> y[2] = "asdadasd"
>>> y
array(['luca', 'bob', 'asdadasd'], dtype='<U16')
```

Per creare array di *stringhe di dimensione variabili* non preventivabile a priori si può usare `dtype=object`. Così facendo si crea un array di oggetti generici al quale si può assegnare la qualunque: si perde però l'efficienza di `numpy` (che non lavora più diretto in sequenze contigue di memoria e usare oggetti python aggiunge un sacco di overhead):

```
>>> ## https://stackoverflow.com/questions/14639496
>>> x = np.array(['apples', 'foobar', 'cowboy'], dtype=object)
>>> x
array(['apples', 'foobar', 'cowboy'], dtype=object)
>>> x[2] = "asdadasd"
>>> x
array(['apples', 'foobar', 'asdadasd'], dtype=object)

>>> for i in range(3):
...     x[i] = x[i].capitalize()
...
>>> x
array(['Apples', 'Foobar', 'Asdadasd'], dtype=object)

>>> # A questo array si può assegnare la qualunque ..
>>> x[1] = {1:2, 3:4}
>>> x
array(['Apples', {1: 2, 3: 4}, 'Asdadasd'], dtype=object)
```


Capitolo 15

Pandas

Contents

15.1 Data I/O	174
15.1.1 Importazione dati	174
15.1.2 Importazione con dati mancanti	175
15.1.3 Esportazione	175
15.2 Series	175
15.2.1 Creazione	175
15.2.2 Contenuto (<code>array</code> , <code>index</code> , <code>name</code> , <code>dtype</code>)	176
15.2.3 Indexing e selezione	176
15.2.4 Modifica valori	178
15.2.5 Funzionalità per indici (<code>reset_index</code> , <code>rename</code>)	178
15.2.6 Rimozione elementi (selezione, <code>drop</code> , <code>del</code>)	179
15.2.7 Elaborazione vettorizzata	179
15.2.8 Elaborazione allineata	180
15.2.9 Coercizione di tipo (<code>astype</code>)	180
15.2.10 Valori condizionali a-la <code>ifelse</code> (<code>.where</code>)	180
15.2.11 Applicazione di una funzione (<code>map</code>)	180
15.2.12 Applicazione di più funzioni (<code>.agg</code>)	181
15.2.13 Sostituzione (<code>replace</code>) o recode (<code>map</code>)	181
15.2.14 Test di appartenenza (<code>in</code> , <code>isin</code>)	181
15.2.15 Dati mancanti	182
15.2.16 Duplicati	182
15.2.17 Sorting	182
15.2.18 Discretizzazione/creazione di classi (<code>cut</code> , <code>qcut</code>)	183
15.2.19 Dummy variables	184
15.2.20 Stringhe	184
15.2.21 Date/ore	187
15.2.22 Dati categorici (<code>Categorical</code>)	190
15.2.23 Indexing gerarchico e reshape	192
15.3 DataFrame	194
15.3.1 Creazione	194

15.3.2	Contenuto (<code>info</code> , <code>shape</code> , <code>index</code> , <code>columns</code> , <code>values</code> , <code>name</code>)	195
15.3.3	Selezione	196
15.3.4	Modifica valori	202
15.3.5	Aggiunta di colonne	202
15.3.6	Rimozione righe/colonne (<code>drop</code> , <code>del</code>)	204
15.3.7	Rinominare colonne/indici (<code>rename</code>)	205
15.3.8	Gestione indici	205
15.3.9	Elaborazione allineata	207
15.3.10	Coercizione di tipi (<code>astype</code>)	208
15.3.11	Applicazione di funzioni	208
15.3.12	Ciclo su righe/colonne	210
15.3.13	Merge	212
15.3.14	Binding (<code>pd.concat</code>)	214
15.3.15	Reshape	215
15.3.16	Test di appartenenza (<code>in</code> , <code>isin</code>)	217
15.3.17	Dati mancanti	218
15.3.18	Duplicati	220
15.3.19	Sorting	221
15.4	Cookbook	222
15.4.1	Stampa tutto il contenuto di un <code>DataFrame</code>	222
15.4.2	Old stuff	223

Fornisce strutture (`Series` array unidimensionale, `DataFrame`, array bidimensionale, `Index`/`MultiIndex` per indici¹) e routines per gestione dati.

```
>>> import pandas as pd
>>> pd.__version__
'3.0.0'
>>> import numpy as np # spesso utile/necessario
>>> import pybmisc as lb
```

15.1 Data I/O

15.1.1 Importazione dati

L'importazione di dati in un dataframe avviene mediante le funzioni `pd.read_*`

```
# wrapper
df = lb.io.import_data("paths")

# File testuali
```

¹L'`Index` è l'oggetto che fornisce i metadati necessari per `Series`, nonché per righe e colonne del `DataFrame`. Alcune peculiarità:

- sono oggetti *immutabili* e non possono essere modificati una volta creati;
- possono contenere doppi;
- possono essere condivisi tra strutture di dati;
- si usa `in` per testare la presenza di un dato indice in un oggetto `Index`.

```
df = pd.read_csv('path.csv') # separatore virgola di default
df = pd.read_csv('path.csv', sep = ';') # separatore punto e virgola
df = pd.read_csv('path.csv', sep = '\t') # separatore tab

# Alcuni binari notevoli
df = pd.read_excel('path.xlsx', sheet_name = 'asd') # file xlsx
df = pd.read_pickle('path.pkl') # formato binario Python
```

15.1.2 Importazione con dati mancanti

Al fine di avere un tipo di dato che supporti `pd.NA` al meglio, specificare:

```
# lettura
df = pd.read_csv(path, dtype_backend="pyarrow")

# coercizione
df.convert_dtypes(dtype_backend="pyarrow")
series.convert_dtypes(dtype_backend="pyarrow")
```

15.1.3 Esportazione

L'esportazione usa i metodi `to_*` dei `DataFrame`.

```
# wrapper
df = lb.io.export_data(df_or_dict_of_dfs, path)

# File testuali
df.to_csv('path.csv')
df.to_csv('path.csv', index = False) # non scrivere l'indice
df.to_csv('path.csv', sep = ";", quoting = csv.QUOTE_NONNUMERIC) # read.csv2

# Binari
df.to_excel('path.xlsx') # singolo
df.to_pickle('path.pkl')
```

15.2 Series

`Series` è un array unidimensionale, di contenuto omogeneo, , dotato (eventualmente) di etichette/labels (index) (può essere pensato come un `dict`).

15.2.1 Creazione

Il modo base per creare una `Series` è

```
data = [1,2,3]
index = ["a", "b", "c"]
x = pd.Series(data) # senza indici (data: lista, np.array o scalare)
y = pd.Series(data, index = idx) # con indici, forniti

a_dict = {"a":1, "b":2, "c":3}
z = pd.Series(a_dict) # con indici, quelli del dict
```

15.2.2 Contenuto (array, index, name, dtype)

Gli elementi principali di una serie sono **array** (un oggetto che wrappa un array numpy) ed **index**; infine sia serie che **index** hanno l'attributo **name**, sfruttato da pandas qua e là

```
>>> x = pd.Series({'luca': 23, 'andrea': 12, 'davide': 15})
>>> x.array
<NumpyExtensionArray>
[23, 12, 15]
Length: 3, dtype: int64
>>> x.index
Index(['luca', 'andrea', 'davide'], dtype='str')
>>> x.name = 'età_anni'
>>> x.index.name = 'giocatore'
>>> x
giocatore
luca      23
andrea    12
davide    15
Name: età_anni, dtype: int64
```

15.2.3 Indexing e selezione

15.2.3.1 Utilizzo di []

Nel caso di un array con indici numerici possiamo utilizzare interi, liste, booleani (non nulli) o funzioni che li restituiscono.

```
>>> x = pd.Series([4, 1, 2, 3])
>>> x[0]                                     # un intero
np.int64(4)
>>> x[[0]]                                   # lista di un intero
0      4
dtype: int64
>>> x[[3, 0, 1]]                             # lista di interi
3      3
0      4
1      1
dtype: int64
>>> x[:2]                                     # slicing
0      4
1      1
dtype: int64
>>> x[[True, False, False, True]]             # bool non NA
0      4
3      3
dtype: int64
>>> # x[[True, False, pd.NA, True]] # FAILS!
>>> x[lambda x: x > 2]                         # predicato
0      4
3      3
dtype: int64
```


Nel caso di un array con indici stringa funziona come sopra, ad eccezione di interi o liste di interi (non utilizzabili) e si possono fornire stringhe/liste di stringhe o slice di stringhe. Di sotto le peculiarità

```
>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3}) # con indici
>>> # y[0] # FAILS!
>>> # y[[1,2,3]] # FAILS!
>>> y["a"] # stringa
np.int64(2)
>>> y[["b", "d"]] # lista di stringhe
b    1
d    4
dtype: int64
>>> y['d':'a'] # slicing con stringhe: estremi inclusi
d    4
b    1
a    2
dtype: int64
```

15.2.3.2 .iloc

`iloc` accetta interi o booleani (o una funzione che filtri) e funziona sia che la serie abbia indici numerici che stringa

```
>>> x = pd.Series([4, 1, 2, 3])
>>> x.iloc[[1, 3]]
1    1
3    3
dtype: int64
>>> x.iloc[[True, False, True, False]]
0    4
2    2
dtype: int64
>>> x.iloc[lambda x: x > 2]
0    4
3    3
dtype: int64
```

15.2.3.3 .loc

`loc` funziona solamente per Serie con indici stringa (per sicurezza) e accetta booleani, predicati che li producono o stringhe/liste di

```
>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3})
>>> y.loc[y > 2] # array di booleani
d    4
c    3
dtype: int64
>>> y.loc["a"] # stringa
np.int64(2)
>>> y.loc[["a"]] # lista di stringhe
```

```

a    2
dtype: int64
>>> y.loc[lambda x: x > 2] # predicato
d    4
c    3
dtype: int64

```

15.2.3.4 Altri metodi di selezione (.filter, .reindex)

Il metodo

- **filter** restituisce i subset i quali indici soddisfano criteri, similmente a quanto visto sopra, ma accetta anche regex in input

```

>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3})
>>> y.filter(items = ["a", "b"])
a    2
b    1
dtype: int64

```

- **reindex** estrae in base agli indici, non accetta doppi nelle chiavi ma riempie buchi senza sollevare eccezioni (es indici richiesti non esistenti)

```

>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3})
>>> y.reindex(["d", "x"])
d    4.0
x    NaN
dtype: float64

```

15.2.4 Modifica valori

Funzionante mediante indici (e broadcasting)

```

>>> x = pd.Series([4, 1, 2, 3]) # Indici numerici
>>> x[0] = 2
>>> x[:] = 0 # annullare un vettore; x = 0 è sbagliato

>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3}) # con indici
>>> y["a"] = 5 # con indici
>>> y[:] = 1 # settare tutti gli elementi a 1

```

15.2.5 Funzionalità per indici (reset_index, rename)

Il metodo

- **reset_index** sostituisce l'indice con un progressivo numerico e restituisce un dataframe col vecchio indice come variabile e la vecchia variabile

```

>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3}) # con indici
>>> y.reset_index()
   index  0
0      d  4
1      b  1
2      a  2
3      c  3

```

- `rename` effettua un recode dell'indice

```
>>> y.rename({"a": "x", "b": "y"})
d    4
y    1
x    2
c    3
dtype: int64
```

15.2.6 Rimozione elementi (selezione, drop, del)

Si può

- effettuare una selezione in uno dei modi di sopra ed assegnare allo stesso nome (che *tiene* gli indici specificati)
- utilizzare il metodo `drop` che *rimuove* temporaneamente gli indici specificati (quindi sarà necessario assegnare)

```
>>> x = pd.Series([1, 2, 3], index = ['a', 'b', 'c'])
>>> x.drop('b') # Rimozione temporanea
a    1
c    3
dtype: int64
>>> x          # la modifica non è salvata
a    1
b    2
c    3
dtype: int64
```

- utilizzare `del` per rimuovere senza necessità di assegnazione

```
>>> del x['b'] # rimozione definitiva
>>> x
a    1
c    3
dtype: int64
```

15.2.7 Elaborazione vettorizzata

Similmente a numpy le elaborazioni sono vettorizzate (si applicano *ufuncs* e broadcasting); viene preservato l'indice:

```
>>> x = pd.Series([0,1,2])
>>> np.exp(x) + 1
0    2.000000
1    3.718282
2    8.389056
dtype: float64
```

15.2.8 Elaborazione allineata

Le elaborazioni aventi per oggetto due serie diverse avvengono sulla base degli indici, effettuando il cosiddetto allineamento automaticamente

```
>>> x = pd.Series({'a': 1, 'c': 2, 'b': 3})
>>> y = pd.Series({'c': 1, 'b': 0, 'd': 0})
>>> x * y
a    NaN
b     0.0
c     2.0
d     NaN
dtype: float64
```

a non può essere calcolato perché manca in y, d perché manca in x.

15.2.9 Coercizione di tipo (astype)

Si usa il metodo `astype` fornendo alternativemente un tipo builtin di Python, una stringa, un `numpy.dtype` o i tipi di pandas

```
>>> a = pd.Series(["1", "2"])
>>> a.astype("Int64")      # stringa
0    1
1    2
dtype: Int64
>>> a.astype("category") # pandas type
0    1
1    2
dtype: category
Categories (2, str): ['1', '2']
```

15.2.10 Valori condizionali a-la ifelse (`.where`)

`pd.Series.where` prende in input una serie booleana (o un predicato) e rimpiazza con `other` laddove la condizione è `False`

```
>>> x = pd.Series(["a", "b", "c"])
>>> test = pd.Series([True, False, True])
>>> x.where(test, other = "qweqwe")
0      a
1  qweqwe
2      c
dtype: str
```

15.2.11 Applicazione di una funzione (map)

Per applicare una funzione per scalare a tutti gli elementi di una `Series` utilizzare `map`

```
>>> rng = np.random.default_rng(6235)
>>> x = pd.Series(rng.random(3))
>>> x.map(lambda x: f"{x:.2f}") # esempio di formattazione
```

```

0    0.55
1    0.67
2    0.73
dtype: str

```

15.2.12 Applicazione di più funzioni (.agg)

`agg` permette di applicare più funzioni alla stessa serie, per info sui metodi vedere Harrison pag 67. Di base quando gli si passa una stringa (es “mean” pandas mappa al metodo corrispondente per le serie)

```

>>> s = pd.Series([1, 2, 3, 4])
>>> s.agg(['min', 'max', np.var, lambda x: x[2]])
min      1.00
max      4.00
var      1.25
<lambda> 3.00
dtype: float64

```

15.2.13 Sostituzione (replace) o recode (map)

Se si vuole sostituire solo alcuni elementi e lasciare invariati gli altri si usa `replace`:

```

>>> a = pd.Series(["1", "2", "3"])
>>> a.replace({"1": "1-2", "2": "1-2"})
0    1-2
1    1-2
2      3
dtype: str

```

Se a `map` di passa un dict effettua dei *recode* (il mapping deve essere completo):

```

>>> a = pd.Series(["1", "2", "3"])
>>> rec = {"1": "1-2", "2": "1-2", "3": "3-4", "4": "3-4"}
>>> a.map(rec)
0    1-2
1    1-2
2    3-4
dtype: str

```

15.2.14 Test di appartenenza (in, isin)

Con

- la keyword `in` testa l'esistenza *negli indici*:

```

>>> x = pd.Series([1, 3], index = ['a', 'c'])
>>> 'b' in x
False

```

- il metodo `isin` si testa *nei valori*:

```
>>> x.isin([1, 2]) # uso di valori
a      True
c      False
dtype: bool
```

15.2.15 Dati mancanti

Vediamo metodi/funzioni più utili a livello di **Series**: generalmente se non si usa **inplace** i metodi restituiscono una copia.

```
>>> z = pd.Series([1, pd.NA, None], dtype = "Int64")

>>> z.isna()      # test; z.notna() sua negazione
0      False
1       True
2       True
dtype: bool
>>> z.dropna()    # filtrare
0      1
dtype: Int64
>>> z.fillna(-9) # riempimento
0      1
1     -9
2     -9
dtype: Int64
```

15.2.16 Duplicati

I metodi più utili:

```
>>> x = pd.Series([1, 2, 2, pd.NA, pd.NA], dtype="Int64")
>>> x.duplicated()      # marca i doppi (anche gli NA)
0      False
1      False
2       True
3      False
4       True
dtype: bool
>>> x.drop_duplicates() # rende unica: restituisce Series
0      1
1      2
3     <NA>
dtype: Int64
>>> x.unique()          # rende unica: restituisce ndarray
<IntegerArray>
[1, 2, <NA>]
Length: 3, dtype: Int64
```

15.2.17 Sorting

Se si vuole ordinare sulla base degli indici si usa il metodo **sort_index**, sulla base dei valori si usa il metodo **sort_values**

```
>>> x = pd.Series([1, 3, 2], index=["d", "a", "b"])
>>> x.sort_index()
a    3
b    2
d    1
dtype: int64
>>> x.sort_values()
d    1
b    2
a    3
dtype: int64
```

15.2.18 Discretizzazione/creazione di classi (cut, qcut)

Si usa la funzione `cut` sulla `Series` (che ha la peculiarità di restituire un oggetto `Categorical` che presenta notevoli somiglianze coi `factor`). Si possono fornire i `breaks` o il numero per `breaks` equispaziati.

`qcut` invece effettua un `cut` sulla base dei quantili.

```
>>> rng = np.random.default_rng(12093)
>>> age = pd.Series(rng.integers(1, 100, size = 5))
>>> age
0    32
1     2
2    79
3    26
4    93
dtype: int64

>>> # cuts specifici
>>> cuts = [0, 25, 50, 75, 100]
>>> labs = ["giovane", "medio", "senior", "anziano"]
>>> pd.cut(age, bins = cuts, labels = labs) # cuts specifici
0      medio
1  giovane
2  anziano
3      medio
4  anziano
dtype: category
Categories (4, str): ['giovane' < 'medio' < 'senior' < 'anziano']
>>> pd.cut(age, bins = 3) # 3 cut equispaziati tra minimo e massimo
0  (1.909, 32.333]
1  (1.909, 32.333]
2  (62.667, 93.0]
3  (1.909, 32.333]
4  (62.667, 93.0]
dtype: category
Categories (3, interval[float64, right]): [(1.909, 32.333] < (32.333, 62.667] < (62.667, 93.0]]
>>> pd.qcut(age, q = 5) # quintile of age
0  (29.6, 50.8]
1  (1.999, 21.2]
```

```

2      (50.8, 81.8]
3      (21.2, 29.6]
4      (81.8, 93.0]
dtype: category
Categories (5, interval[float64, right]): [(1.999, 21.2] < (21.2, 29.6] < (29.6, 50.8]
                                           (50.8, 81.8] < (81.8, 93.0]]

```

15.2.19 Dummy variables

15.2.19.1 Utilizzo base (get_dummies)

Per creare un DataFrame di dummy a partire da una serie si usa `get_dummies`

```

>>> x = pd.Series(["a", "a", "b", pd.NA]) # occhio ai na che sono ignorati
>>> pd.get_dummies(x, prefix="xvar", dtype = "Int64")
   xvar_a  xvar_b
0        1        0
1        1        0
2         0        1
3         0        0

```

15.2.19.2 Variabili a risposta multipla (str.get_dummies)

`str.get_dummies` crea dummy utile per specificare i separatori (es per risposte multiple)

```

>>> x = pd.Series(["a|b", "b|c", "a", "a|b|c"])
>>> x.str.get_dummies(sep = "|")
   a  b  c
0  1  1  0
1  0  1  1
2  1  0  0
3  1  1  1

```

15.2.20 Stringhe

Vediamo alcune funzionalità utili delle `Series` di stringhe.

- Vi sono metodi direttamente accedibili dalla `Series`
- altri metodi sono accedibili da `Series.str`

Ad ogni modo vi è overlap con i metodi delle `str` Python di base.

```

>>> suits = pd.Series(["clubs", "Diamonds", "hearts", "Spades"])
>>> rps = pd.Series(["ROck ", " paper", "sciSSORS"])

```

15.2.20.1 Paste

```

>>> rps + "5" # aggiungi in coda
0      ROck 5
1      paper5
2    sciSSORS5
dtype: str

```



```
>>> rps * 2                                # aggiungi in coda
0      ROck ROck
1      paper paper
2      sciSSORSciSSORS
dtype: str
>>> rps + rps.str[::-1] # paste di due serie
0      ROck kcOR
1      paperrepap
2      sciSSORSSROSSics
dtype: str
>>> rps.str.cat(rps)                       # aggiungi in coda
0      ROck ROck
1      paper paper
2      sciSSORSciSSORS
dtype: str
```

15.2.20.2 Collapse

```
>>> rps.str.cat(sep=", ")
'ROck , paper, sciSSORS'
```

15.2.20.3 Formattazione varia

```
>>> rps.str.strip()                        # elimina bianchi
0      ROck
1      paper
2      sciSSORS
dtype: str
>>> rps.str.pad(8, fillchar="_") # aggiungi caratteri per uniformare lunghezza
0      __ROck
1      __ paper
2      sciSSORS
dtype: str
>>> rps.str.lower()                       # tutto minuscolo
0      rock
1      paper
2      scissors
dtype: str
>>> rps.str.upper()                       # maiuscolo
0      ROCK
1      PAPER
2      SCISSORS
dtype: str
```

Per incollare/formattare assieme due/più stringhe selezionarle e applicare una funzione ad hoc per riga al dataframe

```
>>> tmp = pd.DataFrame({
...     "1": ["a", "b", "c"],
...     "n": ["1", "2", "3"]
... })
```

```
>>> tmp.apply(lambda row: f"{row['l']} ({row['n']})", # funzione di formattazione
...           axis=1) # applicala per riga
0    a (1)
1    b (2)
2    c (3)
dtype: str
```

15.2.20.4 Lunghezza ed sottostringhe

```
>>> rps.str.len() # lunghezza
0    5
1    6
2    8
dtype: int64
>>> rps.str[2:5] # subsetting stringa (es)
0    ck
1    ape
2    iSS
dtype: str
```

15.2.20.5 Splitting

```
>>> agecl = pd.Series(["0-10", "11-15", "11-15"])
>>> agecl.str.split("-", expand=True) # ritorna un df
   0  1
0  0  10
1  11  15
2  11  15
>>> agecl.str.split("-", expand=True).iloc[:, 1] # tieni solo limite superiore
0    10
1    15
2    15
Name: 1, dtype: str
```

15.2.20.6 Ricerca/rimpiazzo

```
>>> # Ricerca
>>> # -----
>>> suits.str.contains("[ae]") # ne ha?
0    False
1     True
2     True
3     True
dtype: bool
>>> suits.str.count("[ae]") # conta quanti
0    0
1    1
2    2
3    2
dtype: int64
>>> suits.str.find("e") # trova posizione match
```

```

0    -1
1    -1
2     1
3     4
dtype: int64

>>> # Ricerca e rimpiazzo semplice
>>> # -----
>>> suits.str.replace("a", "4") # str.replace per rimpiazzare singola lettera
0      clubs
1    Di4monds
2     he4rts
3     Sp4des
dtype: str
>>> suits.replace("Diamonds", "foobar") # .replace per parole intere
0      clubs
1    foobar
2    hearts
3    Spades
dtype: str
>>> suits.replace({"Diamonds": "foobar", "Spades": "asdasd"})
0      clubs
1    foobar
2    hearts
3    asdasd
dtype: str

>>> # Ricerca ed estrazione mediante regex
>>> # -----
>>> import re
>>> x = pd.Series(["primo incontro_PF_02", "primo incontro_PF_03"])
>>> reg = re.compile(r"^([\w ]+?)_(\w+)")
>>> x.apply(lambda x: reg.sub(r"\1", x)) # extract_time
0    primo incontro
1    primo incontro
dtype: str
>>> x.apply(lambda x: reg.sub(r"\2", x)) # extract_pz
0    PF_02
1    PF_03
dtype: str

```

15.2.21 Date/ore

Vediamo alcune funzionalità utili delle `Series` di date/ore. Qui invece vi è legame col modulo `datetime`.

15.2.21.1 Parsing da stringa

```

>>> # alcune stringhe in vari formati di data/or
>>> iso = pd.Series(["1969-07-20 20:12:40",
...                  "1969-11-19 06:54:35",

```

```

...             "1971-02-05 09:18:11"])

>>> eu = pd.Series(["20/07/1969 20:12:40",
...                 "19/11/1969 06:54:35",
...                 "05/02/1971 09:18:11"])

>>> us = pd.Series(["07/20/1969 20:12:40",
...                 "11/19/1969 06:54:35",
...                 "02/05/1971 09:18:11"])

>>> pd.to_datetime(iso) # iso works out of the box (anche se solo data es 2020-10-01)
0    1969-07-20 20:12:40
1    1969-11-19 06:54:35
2    1971-02-05 09:18:11
dtype: datetime64[us]
>>> pd.to_datetime(eu, dayfirst = True) # opzione per eu
0    1969-07-20 20:12:40
1    1969-11-19 06:54:35
2    1971-02-05 09:18:11
dtype: datetime64[us]
>>> pd.to_datetime(us, dayfirst = False) # opzione per us
0    1969-07-20 20:12:40
1    1969-11-19 06:54:35
2    1971-02-05 09:18:11
dtype: datetime64[us]
>>> pd.to_datetime(eu, format="%d/%m/%Y %H:%M:%S") # formato custom (non necessario q
0    1969-07-20 20:12:40
1    1969-11-19 06:54:35
2    1971-02-05 09:18:11
dtype: datetime64[us]

```

15.2.21.2 Creazione da componenti

```

>>> componenti = pd.DataFrame({
...     "year" : [1969, 1969, 1971],
...     "month" : [7, 11, 2],
...     "day" : [20, 19, 5]
... })
>>> pd.to_datetime(componenti)
0    1969-07-20
1    1969-11-19
2    1971-02-05
dtype: datetime64[us]

```

15.2.21.3 Estrazione componenti

```

>>> # Estrazione componenti
>>> isod = pd.to_datetime(iso)

>>> isod.dt.year
0    1969

```

```

1    1969
2    1971
dtype: int32
>>> isod.dt.month
0     7
1    11
2     2
dtype: int32
>>> isod.dt.month_name("it_IT.UTF-8") # see shell `locale`
0    Luglio
1   Novembre
2   Febbraio
dtype: str
>>> isod.dt.day
0    20
1    19
2     5
dtype: int32
>>> isod.dt.day_name()
0    Sunday
1   Wednesday
2    Friday
dtype: str

```

15.2.21.4 Esportazione a stringa

```

>>> # da datetime a data (ocio che è una stringa)
>>> isod.dt.date
0    1969-07-20
1    1969-11-19
2    1971-02-05
dtype: object

>>> # esportare a stringa
>>> isod.dt.strftime("%d/%m/%Y")
0    20/07/1969
1    19/11/1969
2    05/02/1971
dtype: str

```

15.2.21.5 Conversione di tipo/arrotondamenti

```

>>> # rimozione dell'ora (tenere solo la data in formato datetime)
>>> isod.dt.normalize()
0    1969-07-20
1    1969-11-19
2    1971-02-05
dtype: datetime64[us]

>>> # arrotondare datetime alla data (specificando il formato sono disponibili
>>> # altri arrotondamenti, es H, M, S per ore minuti secondi, poi possibile

```

```

>>> # arrotondare a 2H 3M etc)
>>> isod.dt.round("D")
0    1969-07-21
1    1969-11-19
2    1971-02-05
dtype: datetime64[us]
>>> isod.dt.floor("D")
0    1969-07-20
1    1969-11-19
2    1971-02-05
dtype: datetime64[us]
>>> isod.dt.ceil("D")
0    1969-07-21
1    1969-11-20
2    1971-02-06
dtype: datetime64[us]

```

15.2.21.6 Intervalli di tempo

Per una differenza di date

```

>>> import datetime as dt
>>> now = pd.to_datetime([dt.datetime.now()] * 3)
>>> datediff = now - isod
>>> datediff
0    20778 days 11:38:28.290769
1    20657 days 00:56:33.290769
2    20213 days 22:32:57.290769
dtype: timedelta64[us]
>>> datediff.dt.days / 365.25
0    56.887064
1    56.555784
2    55.340178
dtype: float64

```

Per aggiungere ad una data un certo periodo

```

>>> added_days = pd.to_timedelta(pd.Series([1,2,3]), "D")
>>> now + added_days
0    2026-06-11 07:51:08.290769
1    2026-06-12 07:51:08.290769
2    2026-06-13 07:51:08.290769
dtype: datetime64[us]

```

15.2.22 Dati categorici (Categorical)

Il `Categorical` è una rappresentazione tipo `factor` di R con interi linkati a label per risparmiare spazio rispetto a stringhe.

Se i categorici:

- sono *una serie a parte* si può accedere ai metodi esemplificati sotto direttamente

- fanno parte di un *DataFrame*: i metodi di sotto sono accessibili mediante `.cat.metodo`

Creazione e contenuto Si possono creare mediante `pd.Categorical` oppure attraverso series specificando `category` come `dtype`.

```
>>> # metodi di creazione standard
>>> c = pd.Series(list("abbccc"), dtype = 'category')
>>> c = pd.Categorical(["asd", "foo", "asd", "bar"])

>>> # wrapper comodo che imita factor
>>> import pylibmisc as lb
>>> c = lb.dm.to_categorical(
...     [1, 2, 3] * 2,
...     levels = [1,2,3],
...     labels = ["a","b","c"]
... )
```

Il contenuto low-level si può investigare con

```
>>> c.codes      # tipo as.integer
array([0, 1, 2, 0, 1, 2], dtype=int8)
>>> c.categories # livelli del factor
Index(['a', 'b', 'c'], dtype='str')
>>> c.ordered    # booleana test ordinamento
False
```

Metodi utili Alcuni attributi e metodi caratteristici:

```
>>> # -----
>>> # Modifica categorie
>>> # -----
>>> c.set_categories(["a", "b"])          # metodo imposta le categorie ad una nuova lista
['a', 'b', NaN, 'a', 'b', NaN]
Categories (2, str): ['a', 'b']
>>> c.rename_categories(["x", "y", "z"]) # rinomina le categorie
['x', 'y', 'z', 'x', 'y', 'z']
Categories (3, str): ['x', 'y', 'z']
>>> c.reorder_categories(["c", "b", "a"]) # cambia ordinamento
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['c', 'b', 'a']
>>> # -----
>>> # Aggiunta/rimozione
>>> # -----
>>> c.add_categories("asd")              # aggiunge categorie alla fine della lista
['a', 'b', 'c', 'a', 'b', 'c']
Categories (4, str): ['a', 'b', 'c', 'asd']
>>> c.remove_categories("b")             # toglie categorie creando mancanti
['a', NaN, 'c', 'a', NaN, 'c']
Categories (2, str): ['a', 'c']
>>> c.remove_unused_categories()         # toglie categorie con zero frequenze (qui non applicabile)
```

```

['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['a', 'b', 'c']
>>> # -----
>>> # Impostazione ordering
>>> # -----
>>> c.as_ordered()
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['a' < 'b' < 'c']
>>> c.as_unordered()
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['a', 'b', 'c']

```

15.2.23 Indexing gerarchico e reshape

L'indexing gerarchico implementato mediante la classe `MultiIndex`:

- permette di gestire dati multidimensionali, riconducendoli ad una tabella a due dimensioni
- serve nel *reshape* dei dati (funzioni `stack/unstack`) e nelle operazioni basate su gruppo (formare pivot table, eg statistiche stratificate).

Qui vediamo il multiindexing nelle `Series`, lasciamo quello dei `DataFrame` per più tardi

15.2.23.1 Definizione

Si fornisce come termine `index` una lista di elementi, ciascuno dei quali è un livello di indice

```

>>> df = pd.Series(rng.random(6),
...                 index = [list("aaabbc"), [1, 2, 3, 1, 2, 1]])
>>> # df = pd.Series(rng.random(10),
>>> #                 index = [list("aaabbbccdd"), [1, 2, 3] * 3 + [3]])
>>> df
a 1    0.829725
  2    0.227471
  3    0.779332
b 1    0.180644
  2    0.333745
c 1    0.997920
dtype: float64
>>> df.index
MultiIndex([('a', 1),
            ('a', 2),
            ('a', 3),
            ('b', 1),
            ('b', 2),
            ('c', 1)],
)
```


15.2.23.2 Indexing

L'indexing sulla base di un singolo indice è possibile, ad esempio

```
>>> df['b']
1    0.180644
2    0.333745
dtype: float64
>>> df['b':'c']
b 1    0.180644
   2    0.333745
c 1    0.997920
dtype: float64
>>> df.loc[["a", "c"]]
a 1    0.829725
   2    0.227471
   3    0.779332
c 1    0.997920
dtype: float64
```

Ed è possibile la selezione anche da un livello di index più interno:

```
>>> df.loc[:, 2 ]
a    0.227471
b    0.333745
dtype: float64
```

15.2.23.3 Reshape

Un esempio di reshape di una `Series` con `MultiIndex`, che diviene un `DataFrame`

```
>>> # Serie
>>> df = pd.Series(np.random.uniform(size=9),
...                 index=[["a", "a", "a", "b", "b", "c", "c", "d", "d"],
...                       [1, 2, 3, 1, 3, 1, 2, 2, 3]])
>>> df.index.names = ["id", "time"]
>>> df
id  time
a  1    0.292268
   2    0.547111
   3    0.295541
b  1    0.167924
   3    0.809538
c  1    0.725163
   2    0.526081
d  2    0.359886
   3    0.005983
dtype: float64

>>> # DataFrame wide
>>> wide = df.unstack()
>>> wide
time      1      2      3
```

```

id
a      0.292268  0.547111  0.295541
b      0.167924      NaN  0.809538
c      0.725163  0.526081      NaN
d      NaN  0.359886  0.005983

>>> # Tornare in versione long (serie)
>>> long = wide.stack()
>>> long
id  time
a   1      0.292268
   2      0.547111
   3      0.295541
b   1      0.167924
   2      NaN
   3      0.809538
c   1      0.725163
   2      0.526081
   3      NaN
d   1      NaN
   2      0.359886
   3      0.005983
dtype: float64

```

15.3 DataFrame

Struttura a due dimensioni (con indici di riga e colonna) con colonne che possono assumere tipi differenti. Può essere pensato come un `dict` di `Series` caratterizzate dagli stessi indici (di riga).

15.3.1 Creazione

Si crea mediante:

```
df = pd.DataFrame(data, index, columns) # index, columns opzionali
```

dove `data` può essere un `dict` (contenente `list`, `dicts`, `Series` o `array numpy`) un `array numpy 2d`, un altro `DataFrame` o `Series`. `index` e `column`, opzionali, servono per specificare indici di riga e nomi colonna.

```

>>> # modo più comune di creare un DataFrame per colonne: dict di liste
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> states = pd.DataFrame(data, index = list("abcdef"))

>>> # creazione di un DataFrame per riga (lista di dict)
>>> data2 = pd.DataFrame([
...     {"state": "Ohio", "year": 2000, "pop": 1.5},
...     {"state": "Ohio", "year": 2001, "pop": 1.7} # ...
... ])

```

```
>>> # Nella creazione vengono rispettati indici comuni
>>> a = pd.Series(range(3), index=['a', 'b', 'c'])
>>> b = pd.Series(range(4), index=['a', 'b', 'c', 'd'])
>>> df = pd.DataFrame({'one' : a, 'two' : b})
>>> df
```

	one	two
a	0.0	0
b	1.0	1
c	2.0	2
d	NaN	3

15.3.2 Contenuto (info, shape, index, columns, values, name)

Per avere una idea sintetica si usa il metodo `info`; gli attributi principali sono `shape`, `index`, `columns`, `values` e i loro `name`.

```
>>> df.info() # idea sintetica
<class 'pandas.DataFrame'>
Index: 4 entries, a to d
Data columns (total 2 columns):
#   Column  Non-Null Count  Dtype
---  -
0    one      3 non-null      float64
1    two      4 non-null      int64
dtypes: float64(1), int64(1)
memory usage: 100.0 bytes

>>> df.shape # come numpy
(4, 2)

>>> df.index # indici di riga
Index(['a', 'b', 'c', 'd'], dtype='str')
>>> df.columns # nomi di colonna
Index(['one', 'two'], dtype='str')
>>> df.values # valori grezzi (array numpy)
array([[ 0.,  0.],
       [ 1.,  1.],
       [ 2.,  2.],
       [nan,  3.]])

>>> # attributi name di index e columns
>>> df.index.name = "soggetto"
>>> df.columns.name = "rilevazione"
>>> df
```

	rilevazione	one	two
soggetto			
a		0.0	0
b		1.0	1
c		2.0	2
d		NaN	3

15.3.3 Selezione

Avviene mediante le quadre `[]` (più limitata) e gli attributi `.loc` e `.iloc`.

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df = pd.DataFrame(data)      # senza indice di riga
```

15.3.3.1 Uso di `[]`

Per la selezione di:

- **colonne:** specificare stringhe o accedere direttamente (restituisce una Series); oppure specificare lista di stringhe (restituisce un DataFrame),

```
>>> df["state"] # singola colonna (da una serie), sia lettura che assegnazione
0      Ohio
1      Ohio
2      Ohio
3    Nevada
4    Nevada
5    Nevada
Name: state, dtype: str
>>> df.state    # accesso diretto (da una serie), uso interattivo (sola lettura)
0      Ohio
1      Ohio
2      Ohio
3    Nevada
4    Nevada
5    Nevada
Name: state, dtype: str

>>> df[["state", "pop"]] # due colonne (da un dataframe)
   state  pop
0   Ohio  1.5
1   Ohio  1.7
2   Ohio  3.6
3  Nevada  2.4
4  Nevada  2.9
5  Nevada  3.2
```

- **righe:** utilizzare array logici e numerici interpretati come id di riga

```
>>> df[df.state == 'Ohio'] # logici
   state  year  pop
0   Ohio  2000  1.5
1   Ohio  2001  1.7
2   Ohio  2002  3.6
>>> df[:2] # slice
   state  year  pop
0   Ohio  2000  1.5
1   Ohio  2001  1.7
```

- righe e colonne: bisogna utilizzare `.loc/.iloc`

```
# df[df.state == 'Ohio', "pop"] # ERRORE
```

15.3.3.2 Uso di `.loc` e `.iloc`

Per una selezione generale fare uso di questi. Si ha che

- `loc` richiede prende *numerici o stringa* o funzioni (che restituiscono indice di riga o colonna) e *si basa su indici*. Harrison lo preferisce per il codice di produzione
- `iloc` accetta solo input interi ed è *basato su posizione* (invece che indici)

In entrambi i casi:

- specificare i criteri (per riga e colonne) separati da virgole; se si specifica un solo criterio (no virgole) viene interpretato come indice di riga
- se si specificano se su riga o colonna si prende tutto, specificare una slice vuota `:`;

Da notare che la slice in `loc` vs `iloc`:

- funziona diversamente in `loc` ed `iloc`; con `loc` include l'elemento di arrivo, con `iloc` no
- meglio sortare l'indice prima di effettuare una selezione basata su slice; un template è `sort_index` e poi `loc/iloc` (eventualmente preceduti da `set_index`)
- la slice in `loc` con stringhe può essere basata su matching parziale

Alcuni esempi a seguire:

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df = pd.DataFrame(data) # indice interi standard
>>> df_id = pd.DataFrame(data, index = list("abcdef")) # con indice di riga
```

Selezione di colonne Sia per `loc/iloc`, separare con `,` e usare slice vuota

```
>>> df.loc[:, 'pop'] # LOC: colonna singola come serie
0    1.5
1    1.7
2    3.6
3    2.4
4    2.9
5    3.2
Name: pop, dtype: float64
>>> df.loc[:, ['pop']] # LOC: colonna singola come dataframe
      pop
0    1.5
1    1.7
```

```
2  3.6
3  2.4
4  2.9
5  3.2
>>> df.loc[:, ['year', 'pop']] # LOC: multiple via lista
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
>>> df.loc[:, 'year':'pop']   # LOC: multiple via slice
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2

>>> df.iloc[:, 2]           # ILOC: colonna singola (come serie)
0    1.5
1    1.7
2    3.6
3    2.4
4    2.9
5    3.2
Name: pop, dtype: float64
>>> df.iloc[:, [2]]         # ILOC: colonna singola (come dataframe)
   pop
0  1.5
1  1.7
2  3.6
3  2.4
4  2.9
5  3.2
>>> df.iloc[:, [1, 2]] # ILOC: colonne multiple mediante lista
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
>>> df.iloc[:, 1:3]        # colonne multiple mediante slice
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
```

```
4 2002 2.9
5 2003 3.2
```

Selezione di righe Utilizzare un solo indice, interpretato di riga (oppure usare la virgola e porre : per le colonne)

```
>>> df.loc[df.year==2001] # LOC: array booleani
      state year pop
1    Ohio  2001  1.7
3  Nevada  2001  2.4
>>> df.loc[[1,2,3]]      # LOC: se gli indici sono numerici possiamo usare numeri con loc
      state year pop
1    Ohio  2001  1.7
2    Ohio  2002  3.6
3  Nevada  2001  2.4
>>> df.loc[1:5:2]        # slice include elemento finale
      state year pop
1    Ohio  2001  1.7
3  Nevada  2001  2.4
5  Nevada  2003  3.2

>>> df_id.loc['a']      # LOC con indici stringa: singola stringa da serie
state    Ohio
year     2000
pop       1.5
Name: a, dtype: object
>>> df_id.loc[['a']]    # LOC con indici stringa: lista di stringhe da df
      state year pop
a  Ohio  2000  1.5

>>> df.iloc[0]          # ILOC: Singola riga mediante indice come serie
state    Ohio
year     2000
pop       1.5
Name: 0, dtype: object
>>> df.iloc[[0]]        # Lista ritorna dataframe (anche di una sola riga)
      state year pop
0  Ohio  2000  1.5
>>> df.iloc[[2, 3]]
      state year pop
2    Ohio  2002  3.6
3  Nevada  2001  2.4
>>> df.iloc[1:5:2]      # slice esclude elemento finale
      state year pop
1    Ohio  2001  1.7
3  Nevada  2001  2.4
```

Selezione di righe e colonne Porre i criteri visti in precedenza separati da virgola

```
>>> df.loc[df.state == 'Ohio', "pop"] # righe su logico e colonna (ritornata serie)
```

```

0    1.5
1    1.7
2    3.6
Name: pop, dtype: float64
>>> df.loc[df.state == 'Ohio', ["pop"]] # stessa cosa ma dataframe di ritorno
      pop
0    1.5
1    1.7
2    3.6
>>> df_id.loc[ 'a', ['pop', 'year']] # singola riga, più colonne
      pop      year
a    1.5    2000.0
Name: a, dtype: float64
>>> df_id.loc[:"d", "year":"pop"]      # esempio con slice
      year  pop
a    2000  1.5
b    2001  1.7
c    2002  3.6
d    2001  2.4

>>> df.iloc[3, 1]          # solo numerici in iloc
np.int64(2001)
>>> df.iloc[3, [1,2]]      # selezionare più colonne con iloc
      year      pop
3    2001.0    2.4
Name: 3, dtype: float64
>>> df.iloc[:, :3]         # uso slice
      state  year  pop
0     Ohio  2000  1.5
1     Ohio  2001  1.7
2     Ohio  2002  3.6
3  Nevada  2001  2.4
4  Nevada  2002  2.9
5  Nevada  2003  3.2

```

15.3.3.3 query per selezione righe

Il metodo `query` dei dataframe permette di selezionare righe usando una sintassi SQL-like; funziona bene nel chaining (a differenza degli indici, a meno che non si usino funzioni) essendo performata sulla versione più aggiornata del dataframe. Si può

- usare i metodi delle series nella query
- riferirsi a variabili dell'ambiente prefixandole con chiocciola

```

>>> df.query("(year >= 2002) and (~state.isna()) and (pop < 3.5)")
      state  year  pop
4  Nevada  2002  2.9
5  Nevada  2003  3.2

>>> sel_years = {2000, 2003}

```



```
>>> df.query("year in @sel_years")
   state  year  pop
0   Ohio  2000  1.5
5  Nevada  2003  3.2
```

15.3.3.4 Selezione di colonne sulla base di tipo

Utilizzare `.select_dtypes`, specificando `include` (primo) o `exclude`; per selezionare

- tutti i numerici specificare `number`
- datetimes `datetime`
- timedelta `timedelta`
- categorical `category`

```
>>> df = pd.DataFrame({"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...                    "year": [2000, 2001, 2002, 2001, 2002, 2003],
...                    "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]})
>>> df.dtypes
state      str
year      int64
pop      float64
dtype: object
>>> df.select_dtypes("number")
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
>>> df.select_dtypes(exclude="number")
   state
0   Ohio
1   Ohio
2   Ohio
3  Nevada
4  Nevada
5  Nevada
```

15.3.3.5 Accesso a singoli numeri: `.at`, `.iat`

Per estrarre *singoli valori* utilizzare gli accessori `.at` o `.iat`, fornendo una coppia indice di riga e colonna. Questi

- sono equivalenti di `.loc` e `.iloc`: `at` richiede labels, `iat` richiede interi
- garantiscono che l'estrazione sia uno scalare, cosa non garantita con `loc/.iloc`
- più veloci di `.loc/.iloc` nel caso di singolo scalare

```
>>> df = pd.DataFrame(np.arange(6).reshape(3, 2), columns=['A', 'B'])

>>> df
   A  B
0  0  1
1  2  3
2  4  5
>>> df.at[2, "B"]
np.int64(5)
>>> df.iat[2, 1]
np.int64(5)
```

15.3.4 Modifica valori

Per la modifica di

- **colonne/righe/singoli valori:** assegnare a selezioni (di nomi esistenti) effettuate con `[]`, `loc` o `iloc`

```
>>> df = pd.DataFrame(np.arange(6).reshape(3, 2), columns=['A', 'B'])
>>> df.loc["a", "constant"] = 5 # singolo valore
>>> df.loc[:, "series"] = 1     # intera colonna
>>> df.iloc[1, :] = 2          # intera riga, volendo
>>> df
   A  B  constant  series
0  0  1         NaN      1
1  2  2         2.0      2
2  4  5         NaN      1
a  NaN NaN         5.0      1
```

- **singoli valori:** utilizzare `at` e `iat` come lvalue

```
>>> df.at[2, "B"] = 15321
>>> df
   A  B  constant  series
0  0  1         NaN      1
1  2  2         2.0      2
2  4  15321.0     NaN      1
a  NaN NaN         5.0      1
```

15.3.5 Aggiunta di colonne

Nuove colonne possono essere create mediante assegnazione, `insert`, `assign`

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df = pd.DataFrame(data, index = list("abcdef"))
```

15.3.5.1 Assegnazione

assegnando a nomi di colonna inesistenti (le relative colonne verranno create alla fine); torna comoda la sintassi `df['variabile']=...`

```

>>> df['constant'] = 3          # funziona broadcasting
>>> df['newvar'] = range(6)      # rispettare lunghezza
>>> df['series'] = pd.Series([10, 20, 30, 40], # Serie con indici: rispettati
...                          index = ['a', 'b', 'y', 'z'])
>>> df[['foo', 'bar']] = [0, 1] # broadcasting two columns magic
>>> df

```

	state	year	pop	constant	newvar	series	foo	bar
a	Ohio	2000	1.5	3	0	10.0	0	1
b	Ohio	2001	1.7	3	1	20.0	0	1
c	Ohio	2002	3.6	3	2	NaN	0	1
d	Nevada	2001	2.4	3	3	NaN	0	1
e	Nevada	2002	2.9	3	4	NaN	0	1
f	Nevada	2003	3.2	3	5	NaN	0	1

15.3.5.2 Uso di insert

Usando il metodo `insert` per inserire in un determinato punto del dataframe; non è necessaria l'assegnazione

```

>>> df.insert(0,          # insert in posizione specifica (prima)
...           "nomevar",  # nome variabile
...           3)          # valore (es scalar, pd.Series, o array)
>>> df

```

	nomevar	state	year	pop	constant	newvar	series	foo	bar
a	3	Ohio	2000	1.5	3	0	10.0	0	1
b	3	Ohio	2001	1.7	3	1	20.0	0	1
c	3	Ohio	2002	3.6	3	2	NaN	0	1
d	3	Nevada	2001	2.4	3	3	NaN	0	1
e	3	Nevada	2002	2.9	3	4	NaN	0	1
f	3	Nevada	2003	3.2	3	5	NaN	0	1

15.3.5.3 Uso di assign

Permette di risparmiare digitazione, usare funzioni (alle quali viene passato l'intero df) e facilitare il chaining. Il risultato va assegnato. Se i nomi variabili sono esistenti le corrispondenti variabili vengono modificate, altrimenti create sovrascritte mentre se inesistenti create. Preferibile perché

- utilizzando funzioni si prende in input il dataframe allo stato attuale/aggiornato
- meno spaghetti code rispetto a selezioni con variabili temporanee e permette concatenazione di codice rendendolo più leggibile

Volendo

- ogni riga terminerà con `astype` per coercire il tipo
- alla chiusura del metodo postporre una selezione delle variabili da tenere (mediante `.loc`) o un chaining di `.drop` per quelle da eliminare

```

>>> sel_var = df.columns.to_list() + ["test", "yearp2"]
>>> df2 = df.assign(
...     test = range(5, 11),

```

```

...     yearp1 = lambda df_: (df_.year + 1).astype("int64[pyarrow]"),
...     # qui sotto si può già usare year1p
...     yearp2 = lambda df_: (df_.yearp1 + 1).astype("float")
... )[sel_var] # tieni solo le colonne necessarie
>>> df2

```

	nomevar	state	year	pop	constant	newvar	series	foo	bar	test	yearp2
a	3	Ohio	2000	1.5	3	0	10.0	0	1	5	2002.0
b	3	Ohio	2001	1.7	3	1	20.0	0	1	6	2003.0
c	3	Ohio	2002	3.6	3	2	NaN	0	1	7	2004.0
d	3	Nevada	2001	2.4	3	3	NaN	0	1	8	2003.0
e	3	Nevada	2002	2.9	3	4	NaN	0	1	9	2004.0
f	3	Nevada	2003	3.2	3	5	NaN	0	1	10	2005.0

15.3.6 Rimozione righe/colonne (drop, del)

Per:

- righe o colonne si usa il metodo `drop`, specificando tra parentesi gli assi e assegnando il risultato (o specificando `inplace`)

```

>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df = pd.DataFrame(data) # senza indice di riga
>>> df_id = pd.DataFrame(data, index = list("abcdef")) # con indice di riga

```

```

>>> df.drop([0, 1]) # rimozione prime due righe
   state  year  pop
2  Ohio  2002  3.6
3 Nevada  2001  2.4
4 Nevada  2002  2.9
5 Nevada  2003  3.2
>>> df_id.drop(index = "d") # rimozione riga usando indice
   state  year  pop
a  Ohio  2000  1.5
b  Ohio  2001  1.7
c  Ohio  2002  3.6
e Nevada  2002  2.9
f Nevada  2003  3.2
>>> df.drop(columns = ['year', 'pop']) # rimozione colonne
   state
0  Ohio
1  Ohio
2  Ohio
3 Nevada
4 Nevada
5 Nevada

```

- le colonne si può usare `del` (senza riassegnazione)

```

>>> del df['state']
>>> df

```

	year	pop
0	2000	1.5
1	2001	1.7
2	2002	3.6
3	2001	2.4
4	2002	2.9
5	2003	3.2

15.3.7 Rinominare colonne/indici (rename)

Si usa il metodo `rename`, che può prendere dict e funzioni e applicarle a righe o colonne. Ad esempio nel seguito usiamo un dict sulle colonne, e `str.upper` sugli index/righe

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df = pd.DataFrame(data, index = list("abcdef"))    # senza indice di riga

>>> ft = {'state': 'stato', 'pop': 'popolazione'}
>>> df = df.rename(index = str.upper, columns = ft)
>>> df
```

	stato	year	popolazione
A	Ohio	2000	1.5
B	Ohio	2001	1.7
C	Ohio	2002	3.6
D	Nevada	2001	2.4
E	Nevada	2002	2.9
F	Nevada	2003	3.2

15.3.8 Gestione indici

15.3.8.1 Creazione indici da colonne

Il metodo `set_index` crea indici di riga a partire da una/più colonne. Il risultato va salvato. Per non eliminare le colonne specificate come index si usa il parametro `drop = False`.

```
>>> df = pd.DataFrame({'a': range(7), 'b': range(7, 0, -1),
...                   'c': ['one', 'one', 'one', 'two', 'two', 'two', 'two'],
...                   'd': [0, 1, 2, 0, 1, 2, 3]})
>>> df2 = df.set_index(['c', 'd'])
>>> df2
```

	a	b
one d		
0 0	7	
1 1	6	
2 2	5	
two d		
0 3	4	
1 4	3	
2 5	2	
3 6	1	

15.3.8.2 Reset indici

`reset_index` porta gli indici in opportune colonne del dataframe e li sostituisce con un progressivo numerico (a meno che `drop=True`, nel qual caso vengono eliminati)

```
>>> df2.reset_index()
   c  d  a  b
0  one  0  0  7
1  one  1  1  6
2  one  2  2  5
3  two  0  3  4
4  two  1  4  3
5  two  2  5  2
6  two  3  6  1
```

15.3.8.3 MultiIndex

Sia righe che colonne possono avere indexing multiplo e con nomi

```
>>> df = pd.DataFrame(np.arange(12).reshape((4, 3)),
...                    index=[['a', 'a', 'b', 'b'], [1, 2, 1, 2]],
...                    columns=[['Ohio', 'Ohio', 'Colorado'],
...                              ['Green', 'Red', 'Green']])
>>> df.index.names = ["key1", "key2"]
>>> df.columns.names = ["state", "color"]
>>> df
state      Ohio      Colorado
color      Green Red      Green
key1 key2
a      1      0  1      2
      2      3  4      5
b      1      6  7      8
      2      9 10     11
```

Anche sui nomi di indici di colonna è possibile effettuare selezioni

```
>>> df["Ohio"]
color      Green  Red
key1 key2
a      1      0  1
      2      3  4
b      1      6  7
      2      9 10
```

Per conoscere il numero di livelli di indici

```
>>> df.index.nlevels
2
```

Invertire gli indici Può essere necessario a volte cambiare l'ordine degli indici di un'asse (ad esempio indice più interno portarlo fuori). Questo si fa mediante `swaplevel`

```
>>> df.swaplevel("key1", "key2")
state      Ohio      Colorado
color      Green Red      Green
key2 key1
1      a          0      1          2
2      a          3      4          5
1      b          6      7          8
2      b          9     10         11
```

15.3.9 Elaborazione allineata

Nelle operazioni algebriche tra dataframe e serie e tra due dataframe sono gli indici a determinare cosa viene messo in relazione con cosa:

- se una posizione non è disponibile in entrambi gli operandi viene restituito dato mancante
- nel caso vi siano **indici ripetuti** questo si ripercuoterà sui risultati

```
>>> df = pd.DataFrame({"x" : [1,2,3,4], "y": [5,6,7,8], "z": [9,10,11,12]},
...                    index = list("abcd"))
```

```
>>> # Dataframe e serie
```

```
>>> df
```

```
   x  y  z
a  1  5  9
b  2  6 10
c  3  7 11
d  4  8 12
```

```
>>> df.mean()
```

```
x      2.5
y      6.5
z     10.5
dtype: float64
```

```
>>> df.std()
```

```
x      1.290994
y      1.290994
z      1.290994
dtype: float64
```

```
>>> # Due dataframe
```

```
>>> df1 = df.loc["a":"c", "x":"y"]
```

```
>>> df2 = df.loc["b":"d", "y":"z"]
```

```
>>> df1
```

```
   x  y
a  1  5
b  2  6
c  3  7
```

```
>>> df2
```

```
   y  z
b  6 10
c  7 11
```

```

d 8 12
>>> df1 + df2
      x      y      z
a NaN   NaN  NaN
b NaN  12.0  NaN
c NaN  14.0  NaN
d NaN   NaN  NaN

```

15.3.10 Coercizione di tipi (astype)

Possiamo usare `astype` specificando il mapping di formato in un dict.

```

>>> df = pd.DataFrame({"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...                     "year": [str(y) for y in [2000, 2001, 2002, 2001, 2002, 2003]],
...                     "pop": [str(p) for p in [1.5, 1.7, 3.6, np.nan, 2.9, 3.2]],
...                     "adate": ["2020-01-02", "2021-01-01", "2022-01-02"] * 2
...                     }) # all strings/"object"
>>> ft = {
...     "state": "category",
...     "year" : "Int16",
...     "pop"  : "Float64",
...     "adate": "datetime64[ns]" # soluzione provvisoria, credo
... } # https://wesmckinney.com/book/data-cleaning.html#p

>>> df2 = df.astype(ft)
>>> df2.info()
<class 'pandas.DataFrame'>
RangeIndex: 6 entries, 0 to 5
Data columns (total 4 columns):
#   Column  Non-Null Count  Dtype
---  -
0   state    6 non-null      category
1   year     6 non-null      Int16
2   pop      5 non-null      Float64
3   adate    6 non-null      datetime64[ns]
dtypes: Float64(1), Int16(1), category(1), datetime64[ns](1)
memory usage: 285.0 bytes

```

15.3.11 Applicazione di funzioni

15.3.11.1 A molteplici righe/colonne (apply/agg)

`apply` serve per applicare una singola funzione ad ogni riga (default) o colonna (specificando `axis=1`, simile a `lapply`):

- se la funzione restituisce uno scalare l'output sarà una serie
- se la funzione restituisce una serie, l'output sarà un dataframe

Se la funzione viene applicata a tutte le righe, per ciascuna viene fornito una sorta di dict (Series in cui gli indici sono i nomi di colonna) e dovrebbe essere lo stesso con le colonne (se gli indici di riga sono stringhe).


```

>>> df = pd.DataFrame({"a" : [1, 2, 3], "b" : [4, 5, 6]})

>>> # ----- funzione che restituisce uno scalare
>>> df.apply(lambda x: x.mean()) # applicata a tutte colonne
a    2.0
b    5.0
dtype: float64
>>> df.apply(lambda x: f"{x['a']} + 3 = {x['b']}", axis = 1) # applica a righe
0    1 + 3 = 4
1    2 + 3 = 5
2    3 + 3 = 6
dtype: str

>>> # ----- funzione che restituisce una serie
>>> def desc(x):
...     return pd.Series([x.min(), x.max(), x.mean(), x.median()],
...                       index=["min", "max", "mean", "median"])
...
>>> df.apply(desc) # colonna
      a    b
min  1.0  4.0
max  3.0  6.0
mean  2.0  5.0
median 2.0  5.0
>>> df.apply(desc, axis = 1) # riga
      min max mean median
0  1.0  4.0  2.5   2.5
1  2.0  5.0  3.5   3.5
2  3.0  6.0  4.5   4.5

```

In maniera analoga invece di definire una funzione che ritorni una serie possiamo passare al metodo `.agg` una lista con cose/aggregazioni per farle eseguire (su tutte le colonne di default).

```

>>> # conta di non missing, numero di valori unici (missing inclusi), somma valori
>>> # e primo valore
>>> analysis = ["count", "size", "sum", lambda col: col.loc[0]]
>>> df.agg(analysis)
      a    b
count  3    3
size   3    3
sum    6   15
<lambda> 1    4

```

15.3.11.2 A ciascun elemento del DataFrame (map)

`map` applica una funzione a tutti gli elementi del dataframe

```

>>> rng = np.random.default_rng(665)
>>> df = pd.DataFrame(rng.standard_normal((2, 2)))
>>> df
      0      1

```

```

0  0.259614 -0.072077
1 -0.093439 -1.180275
>>> df.map(lambda x: -1 if x < 0 else 1) # sign function
      0  1
0     1 -1
1    -1 -1

```

15.3.11.3 All'intero dataframe (pipe)

`pipe` passa l'intero dataframe a una funzione (che si attende di lavorare con dataframe) ed è utile soprattutto nel chaining di metodi

```

>>> #effective pandas 2 pag 127
>>> agecl = pd.Series(["0-10", "11-20", "20-30"])

>>> ( agecl
...   .str.split('-', expand = True) # splits in a two cols dataframe
...   .astype(int)
...   .pipe( # passa il dataframe a un generatore di numeri casuali tra le
...         # colonne
...         lambda df_ : pd.Series(
...             # qui possiamo usare df_ per riferirci al dataframe
...             np.random.randint(df_.iloc[:, 0], df_.iloc[:, 1]),
...             index=df_.index
...         ))
... )
0     2
1    15
2    23
dtype: int64

```

15.3.12 Ciclo su righe/colonne

Tipicamente questo non è di interesse. Se però, se per qualche motivo, l'applicazione di funzioni per generare nuovi dati (es mediante `apply`) come alla sezione 15.3.11 non è quello che si vuole, si può fare dei cicli generici sul `DataFrame` per utilizzarne i dati presenti.

15.3.12.1 Righe

Si usa:

- `itertuples`: ritorna una tuple con nome, che preserva i tipi ed è più veloce (indice in posizione 0)

```

>>> df = pd.DataFrame({'num_legs': [4, 2],
...                     'num_wings': [0, 2]},
...                     index=['dog', 'hawk'])

>>> for row in df.itertuples():
...     print("id =", row[0],
...           "first_elem =", row[1],

```

```

...         "second_elem = ", row[2],
...         "first_named = ", row.num_legs,
...         "second_named = ", row.num_wings)
...
id = dog first_elem = 4 second_elem = 0 first_named = 4 second_named = 0
id = hawk first_elem = 2 second_elem = 2 first_named = 2 second_named = 2

```

- **iterrows**: ritorna una coppia label e Series (forse di minor interesse data la maggior generalità del precedente)

```

>>> for lab, row in df.iterrows():
...     print(f"{lab =}")
...     print(row)
...
lab = 'dog'
num_legs      4
num_wings      0
Name: dog, dtype: int64
lab = 'hawk'
num_legs      2
num_wings      2
Name: hawk, dtype: int64

```

- può tornare talvolta utile **df.to_dict(orient="records")** che crea una lista di dict, ciascuno con una riga

```

>>> for row in df.to_dict(orient="records"):
...     print(row)
...
{'num_legs': 4, 'num_wings': 0}
{'num_legs': 2, 'num_wings': 2}

```

15.3.12.2 Colonne

Un ciclo **for** secco restituisce il nome della variabile; di maggior interesse il metodo **items** che restituisce la tupla con nome variabile e serie contenuta

```

>>> df = pd.DataFrame({'species': ['bear', 'bear', 'marsupial'],
...                     'population': [1864, 22000, 80000]},
...                     index=['panda', 'polar', 'koala'])

>>> for varname, content in df.items():
...     print(f'varname: {varname}')
...     print(f'type: {type(varname)}')
...     print(f'content: \n{content}', sep='\n')
...
varname: species
type: <class 'str'>
content:
panda      bear
polar      bear
koala      marsupial

```

```

Name: species, dtype: str
varname: population
type: <class 'str'>
content:
panda      1864
polar      22000
koala       80000
Name: population, dtype: int64

```

15.3.13 Merge

15.3.13.1 Due dataframe

Si usa `pd.merge`, o alternativamente anche il metodo `merge` sul primo `DataFrame`, che:

- funziona
 - di default **sulla base delle colonne** comuni presenti in entrambi i dataset; altrimenti specificare i nomi delle variabili comuni mediante `on` (se i due dataframe hanno variabili di merge con lo stesso nome) oppure ordinatamente `left_on` e `right_on`;
 - se si desidera che le chiavi di merge siano gli **indici (di riga)**, passare `left_index = True` e `right_index = True` (per merge utilizzando le chiavi sia del df di destra che sinistra)
- di default ritorna le righe dove la chiave è presente in entrambi i dataset (*inner join*): per altri tipi si possono specificare nel parametro `how` (es `left`, `right` ed `outer` ... vi è anche `cross` per avere il prodotto cartesiano). Tipicamente di interesse `left` se a sinistra abbiamo un dataframe al quale vogliamo integrare dati provenienti da quello di destra
- si può specificare un criterio di validazione (stringa passata a `validate`) che darà errore se non rispettato: es `1:1`, `1:m`, `m:1`.

```

>>> df1 = pd.DataFrame({'key': ['a', 'b', 'b', 'c', 'c', 'c'],
...                      'data1': range(6)})
>>> df2 = pd.DataFrame({'key': ['a', 'b', 'd'],
...                      'data2': ['x', 'y', 'z']})
>>> df1
   key  data1
0    a      0
1    b      1
2    b      2
3    c      3
4    c      4
5    c      5
>>> df2
   key data2
0    a     x
1    b     y
2    d     z

```

```

>>> # vari tipi di merge
>>> # -----
>>> pd.merge(df1, df2)                                # inner di default ("key" is common, used)
   key  data1 data2
0    a      0     x
1    b      1     y
2    b      2     y
>>> pd.merge(df1, df2, how = 'left') # tiene dataset di sx, integra con quello di dx
   key  data1 data2
0    a      0     x
1    b      1     y
2    b      2     y
3    c      3    NaN
4    c      4    NaN
5    c      5    NaN
>>> pd.merge(df1, df2, how = 'right') # tiene dataset di dx, integra con quello di sx
   key  data1 data2
0    a    0.0     x
1    b    1.0     y
2    b    2.0     y
3    d   NaN     z
>>> pd.merge(df1, df2, how = 'outer') # tieni tutto
   key  data1 data2
0    a    0.0     x
1    b    1.0     y
2    b    2.0     y
3    c    3.0    NaN
4    c    4.0    NaN
5    c    5.0    NaN
6    d   NaN     z

>>> # uso della validazione
>>> # -----
>>> # pd.merge(df1, df2, how = 'left', validate="1:1") # questo da errore
>>> pd.merge(df1, df2, how = 'left', validate="m:1") # questo è giusto
   key  data1 data2
0    a      0     x
1    b      1     y
2    b      2     y
3    c      3    NaN
4    c      4    NaN
5    c      5    NaN

```

15.3.13.2 Molteplici dataframe

Per mergiare diversi dataset aventi lo stesso nome di chiave in uno si può `reduce`

```

from functools import reduce

def merger(x, y):

```

```

return pd.merge(x, y, how = "left",
                left_on=['id', "time"],
                right_on=['id', "time"],
                suffixes=(None, None))

```

```
df = reduce(merger, [demo, lav, sal, bis])
```

15.3.14 Binding (pd.concat)

Sia per binding di riga che di colonna si usa `pd.concat` (passandogli la dimensione di interesse via `axis`). In entrambi i casi (e soprattutto per il binding di colonna) gli indici svolgono un ruolo importante.

15.3.14.1 Di riga

Nel binding di riga gli indici vengono duplicati se necessario. Si può dare

- `verify_integrity=True` se si vuole assicurare che non vi siano doppi
- `ignore_index=True` per piattare i vecchi indici e crearne nuovi

Ad esempio un equivalente di `rbind` si ottiene mediante

```

>>> # indici doppi vengono ripetuti
>>> df1 = pd.DataFrame({'key': ['a', 'b', 'd'],
...                     'data': ['x', 'y', 'z']},
...                     index=[0,1,2])
>>> df2 = pd.DataFrame({'key': ['a', 'b', 'd'],
...                     'data': ['x', 'y', 'z']},
...                     index=[1,2,3])
>>> pd.concat([df1, df2])
   key data
0    a    x
1    b    y
2    d    z
1    a    x
2    b    y
3    d    z

```

15.3.14.2 Di colonna

Attenzione, nel binding di colonna (`cbind`) **gli indici vengono rispettati rigorosamente**; nel caso usare `reset_index` con `drop=True` (ad esempio nel caso di sotto solamente nel secondo dataframe).

```

>>> # Indici non sovrapposti
>>> df1 = pd.DataFrame({'a': ['a', 'b', 'd'],
...                     'b': ['x', 'y', 'z']},
...                     index=[0, 1, 2])
>>> df2 = pd.DataFrame({'c': ['a', 'b', 'd'],
...                     'd': ['x', 'y', 'z']},
...                     index=[1, 2, 3])

```

```
>>> pd.concat([df1, df2], axis = 1) # indici rispettati, NA generati
   a  b  c  d
0  a  x NaN NaN
1  b  y  a  x
2  d  z  b  y
3 NaN NaN  d  z
>>> pd.concat([df1, df2.reset_index(drop=True)], axis = 1) # indici ignorati
   a b c d
0  a x a x
1  b y b y
2  d z d z
```

15.3.15 Reshape

Qua ci focalizziamo sul reshape basato sul contenuto delle colonne. Quanto sotto è stato posto in `lb.r.reshape`, in maniera più comoda e simile al reshape di R.

15.3.15.1 Uso di `lb.r.reshape`

È ancora sperimentale e non gestisce se le variabili hanno nomi con più di un separatore `_`

```
>>> wide = pd.DataFrame({
...     "id": ["bar", "baz", "foo"],
...     "var1_t0": [4, 5, 6],
...     "var1_t1": [7, 8, 9],
...     "var2_t0": [10, 11, 12],
...     "var2_t1": [13, 14, 15],
...     "var2_t2": [0, 0, 0],
... })
>>> wide
   id  var1_t0  var1_t1  var2_t0  var2_t1  var2_t2
0  bar         4         7        10        13         0
1  baz         5         8        11        14         0
2  foo         6         9        12        15         0
>>> longdf = lb.r.reshape(data=wide, idvar="id",
...                        wide_varying={"var1": ["var1_t0", "var1_t1"],
...                                           "var2": ["var2_t0", "var2_t1", "var2_t2"]},
...                        timesep="_",
...                        direction="long")
>>> longdf
   id time  var1  var2
0  bar  t0     4    10
1  bar  t1     7    13
2  bar  t2  <NA>     0
3  baz  t0     5    11
4  baz  t1     8    14
5  baz  t2  <NA>     0
6  foo  t0     6    12
7  foo  t1     9    15
```

```

8  foo  t2  <NA>      0
>>> back_to_wide = lb.r.reshape(longdf, idvar="id", timevar="time",
...                               towide_vars=["var1", "var2"],
...                               timesep="_at_",
...                               direction="wide")
>>> back_to_wide
   id  var1_at_t0  var1_at_t1  var2_at_t0  var2_at_t1  var2_at_t2
0  bar           4           7           10           13           0
1  baz           5           8           11           14           0
2  foo           6           9           12           15           0

```

15.3.15.2 Porre in long (melt)

Se abbiamo un dataset in formato wide si pone in long con `pd.melt`. Si può

- specificare un sottoinsieme di variabili da porre in long mediante `value_vars`
- specificare con `var_name` nome al posto di `variable` nel dataframe creato e `value_name` per specificare il nome della variabile al posto di `value`

```

>>> df = pd.DataFrame({"key": ["foo", "bar", "baz"],
...                     "x_b1": [1, 2, 3],
...                     "x_t0": [4, 5, 6],
...                     "x_t1": [7, 8, 9]}
... )

```

```

>>> df
   key  x_b1  x_t0  x_t1
0  foo     1     4     7
1  bar     2     5     8
2  baz     3     6     9
>>> pd.melt(df, id_vars = 'key') # poni in long tutto

```

```

   key variable  value
0  foo     x_b1      1
1  bar     x_b1      2
2  baz     x_b1      3
3  foo     x_t0      4
4  bar     x_t0      5
5  baz     x_t0      6
6  foo     x_t1      7
7  bar     x_t1      8
8  baz     x_t1      9
>>> pd.melt(df, id_vars = 'key', value_vars = ["x_b1", "x_t0"]) # in long una selezione
   key variable  value
0  foo     x_b1      1
1  bar     x_b1      2
2  baz     x_b1      3
3  foo     x_t0      4
4  bar     x_t0      5
5  baz     x_t0      6

```


15.3.15.3 Porre in wide (pivot)

Un dataset in formato long con colonne, id, tempo e variabili assortiti può essere posto in formato wide mediante il metodo `pivot`.

```
>>> df = pd.DataFrame({'idpz': ['one', 'one', 'one', 'two', 'two'],
...                     'time': ["b1", "t1", "t2", "b1", "t1"],
...                     'x': range(1,6),
...                     'y': ['x', 'y', 'z', 'q', 'w'],
...                     'z': range(7, 12),
... })
>>> df
   idpz time  x  y  z
0  one  b1   1  x  7
1  one  t1   2  y  8
2  one  t2   3  z  9
3  two  b1   4  q 10
4  two  t1   5  w 11

>>> wide = df.pivot(index="idpz", columns="time", values = ["x", "y"])
>>> # time sopra deve essere una stringa
>>> wide.columns = ["_".join(col) for col in wide.columns]
>>> wide.convert_dtypes().reset_index()
   idpz  x_b1  x_t1  x_t2  y_b1  y_t1  y_t2
0  one     1     2     3     x     y     z
1  two     4     5  <NA>     q     w  <NA>
```

15.3.16 Test di appartenenza (in, isin)

Si utilizza:

- `in` applicato ad un DataFrame testa la presenza di una colonna avente un determinato nome

```
>>> df = pd.DataFrame({'a': [1, 2], "b": list("xz"), "c": [2,3]})
>>> df
   a  b  c
0  1  x  2
1  2  z  3

>>> # in per check nomi colonna
>>> 'a' in df
True
>>> 'l' in df
False
```

- `isin` cerca nel contenuto del dataframe

```
>>> # Singolo elemento
>>> # -----
>>> df == 2
   a      b      c
0 False False  True
```

```

1   True  False  False
>>> df == "z"
      a      b      c
0  False  False  False
1  False   True  False
>>> df.isin([2])           # lista: cerca in tutte le colonne
      a      b      c
0  False  False   True
1   True  False  False
>>> df.isin({"c" : [2]})   # dict: cerca in alcune colonne specificate
      a      b      c
0  False  False   True
1  False  False  False
>>> ~df.isin([2])          # negazione ricerca
      a      b      c
0   True   True  False
1  False   True   True

>>> # Più elementi
>>> # -----
>>> df.isin([2, "z"])      # lista di due elementi
      a      b      c
0  False  False   True
1   True   True  False

```

15.3.17 Dati mancanti

Le funzioni ritornano una copia modificata che va eventualmente salvata

```

>>> df = pd.DataFrame({"a": [1., np.nan, 3.],
...                     "b": [1., np.nan, np.nan],
...                     "c": [np.nan, np.nan, np.nan],
...                     "d": [np.nan, np.nan, 3.]},
...                     index=list("xyz")
...                     ).convert_dtypes()
>>> df
      a      b      c      d
x     1     1  <NA>  <NA>
y  <NA>  <NA>  <NA>  <NA>
z     3  <NA>  <NA>     3

```

15.3.17.1 Identificazione

```

>>> df.isna() # df.notna() è il contrario
      a      b      c      d
x  False  False  True   True
y   True   True  True   True
z  False   True  True  False
>>> df.isna().sum()
a     1
b     2

```

```

c    3
d    2
dtype: int64
>>> df.isna().mean().sort_values()
a    0.333333
b    0.666667
d    0.666667
c    1.000000
dtype: float64

```

15.3.17.2 Rimozione

```

>>> df.dropna()                                     # righe con anche un solo NA
Empty DataFrame
Columns: [a, b, c, d]
Index: []
>>> df.dropna(how = 'all')                          # righe completamente NA
   a    b    c    d
x  1    1 <NA> <NA>
z  3 <NA> <NA>    3
>>> df.dropna(axis = "columns", how = "all") # colonne completamente NA
   a    b    d
x   1    1 <NA>
y <NA> <NA> <NA>
z   3 <NA>    3

```

15.3.17.3 Imputazione

Per l'imputazione dei dati mancanti

- il metodo `fillna` accetta un singolo valore, un `dict` dove si specifica nomecolonna-valore da imputare, o anche serie con `index` (da utilizzare per colonna) o un dataframe con la stessa struttura

```

>>> df.fillna(99)
   a    b    c    d
x  1    1  99  99
y  99  99  99  99
z   3  99  99   3
>>> df.fillna({"a":2, "b":3})
   a    b    c    d
x  1    1 <NA> <NA>
y  2    3 <NA> <NA>
z  3    3 <NA>    3
>>> df.fillna(pd.Series([1,2,3], index=list("abc"))) # meno chiaro
   a    b    c    d
x  1    1    3 <NA>
y  1    2    3 <NA>
z  3    2    3    3
>>> df.fillna(pd.DataFrame(np.arange(12).reshape(3, 4), columns=list("abcd"), index=list("xyz")))
   a    b    c    d
x  1    1    2    3

```

```

y  4  5  6  7
z  3  9 10  3

```

- il metodo `ffill` (lof di colonna andando verso il basso, se no specificare `axis`)

```

>>> df.ffmpeg()
      a  b      c      d
x  1  1  <NA>  <NA>
y  1  1  <NA>  <NA>
z  3  1  <NA>      3

```

- il metodo `interpolate` rimpiazza i mancanti con interpolazioni lineari

```

>>> df.interpolate()
      a      b      c      d
x  1.0  1.0  <NA>  <NA>
y  2.0  1.0  <NA>  <NA>
z  3.0  1.0  <NA>  3.0

```

15.3.18 Duplicati

```

>>> df = pd.DataFrame({"k1": ["one", "two"] * 3 + ["two"],
...                      "k2": [1, 1, 2, 3, 3, 4, 4]},
...                      index = list("abcdef"))
>>> df
      k1  k2
a  one   1
a  two   1
b  one   2
c  two   3
d  one   3
e  two   4
f  two   4

```

15.3.18.1 Identificazione (duplicated)

`duplicated` ritorna un vettore di booleani per indicare se una riga è duplicata

```

>>> df.duplicated()      # ricerca complessiva
a    False
a    False
b    False
c    False
d    False
e    False
f     True
dtype: bool
>>> df.duplicated('k1')  # ricerca in singola colonna
a    False
a    False
b     True
c     True

```

```

d      True
e      True
f      True
dtype: bool

```

15.3.18.2 Rimozione (drop_duplicates)

`drop_duplicates` ritorna un data frame senza duplicati.

- di default tutte le colonne sono considerate, alternativamente specificare `subset`;
- se si usa `keep` si può specificare se tenere i primi elementi duplicati ("`first`", di default), gli ultimi ("`last`") oppure eliminare tutto (`False`).

```

>>> df.drop_duplicates() # complessiva
   k1  k2
a  one  1
a  two  1
b  one  2
c  two  3
d  one  3
e  two  4
>>> df.drop_duplicates(subset = ["k1"]) # su singola colonna
   k1  k2
a  one  1
a  two  1
>>> df.drop_duplicates(subset = ["k1"], keep = 'last') # tenere ultimi elementi
   k1  k2
d  one  3
f  two  4

```

15.3.18.3 Indici duplicati

```

>>> df.index.duplicated()
array([False,  True, False, False, False, False, False])

```

15.3.19 Sorting

15.3.19.1 Su valori (sort_values)

Si usa: `sort_values` per ordinare sulla base di valori di colonna (è anche possibile fornire una funzione in `key` che elabora cose e restituisce qualcosa sulla base del quale fare ordinamento);

```

>>> rng = np.random.default_rng(23)
>>> df = pd.DataFrame({'g': ["x", "y", "x", "y"],
...                   'y' : rng.standard_normal((4)),
...                   'z' : rng.standard_normal((4))},
...                   index = list("bacd"))

>>> df.sort_values(by = 'y')
   g      y      z
a  x  -0.14  -0.44
b  y   0.76  -0.85
c  x   0.20  -0.85
d  y   0.52  -0.85

```

```

d y -2.318936  0.605966
c x -0.057990  0.909921
a y  0.217601 -2.126280
b x  0.553261  0.431494
>>> df.sort_values(by = ['g', 'y'])
      g      y      z
c x -0.057990  0.909921
b x  0.553261  0.431494
d y -2.318936  0.605966
a y  0.217601 -2.126280
>>> df.sort_values(by = ['g', 'y'], ascending = [True, False])
      g      y      z
b x  0.553261  0.431494
c x -0.057990  0.909921
a y  0.217601 -2.126280
d y -2.318936  0.605966

```

15.3.19.2 Su indici (csort_index)

`sort_index` per ordinare sulla base degli indici di riga o nomi colonna

```

>>> # ordinare righe sulla base di indici
>>> # df.set_index("some_variable").sort_index()
>>> df.sort_index()
      g      y      z
a y  0.217601 -2.126280
b x  0.553261  0.431494
c x -0.057990  0.909921
d y -2.318936  0.605966

>>> # ordinare colonne alfabeticamente per nome variabile
>>> df.sort_index(axis="columns")
      g      y      z
b x  0.553261  0.431494
a y  0.217601 -2.126280
c x -0.057990  0.909921
d y -2.318936  0.605966

```

15.4 Cookbook

15.4.1 Stampa tutto il contenuto di un DataFrame

Per una **impostazione definitiva** impostare righe e colonne

```

pd.set_option('display.max_rows', 500)
pd.set_option('display.max_columns', 500)

```

Per una **impostazione momentanea** usare il context manager `pd.option_context` con le seguenti opzioni

```

with pd.option_context('display.max_rows', None, 'display.max_columns', None):
    stampa_df()

```

15.4.2 Old stuff

15.4.2.1 Reindexing (reindex, loc)

Serve per riordinare e/o selezionare righe e colonne:

- utilizzare `reindex`: di default lavora sulle righe a meno che non si specifichi `columns`
- se si desidera un modo safe per effettuare reindexing utilizzare `loc`: funziona solo se gli indici forniti esistono già nel `DataFrame` (e non crea valori missing)

NB: di dubbia utilità: se utile porlo nella sezione dei dataframe, utilità per indici

```
>>> data = np.arange(9).reshape((3,3))
>>> id = ['a', 'c', 'd']
>>> col = ['Ohio', 'Texas', 'California']
>>> df = pd.DataFrame(data, index = id, columns = col)
>>> df
```

	Ohio	Texas	California
a	0	1	2
c	3	4	5
d	6	7	8

```
>>> df2 = df.reindex(['a', 'b', 'c', 'd']) # reindexing di riga
>>> df2 # b missing perché non disponibile nei dati di partenza
```

	Ohio	Texas	California
a	0.0	1.0	2.0
b	NaN	NaN	NaN
c	3.0	4.0	5.0
d	6.0	7.0	8.0

```
>>> states = ['Texas', 'Utah', 'California'] # reindexing di colonna
>>> df.reindex(columns = states) # si cancella Ohio, non richiesto
```

	Texas	Utah	California
a	1	NaN	2
c	4	NaN	5
d	7	NaN	8

```
>>> df.loc[["a", "d", "c"], ["California", "Texas"]] # safe reindexing
```

	California	Texas
a	2	1
d	8	7
c	5	4

15.4.2.2 Applicare diverse funzioni a diversi elementi

diverse funzioni a diverse colonne utilizzare `transform`: si genera il nuovo in un dataframe (che deve esser bindato al vecchio)

NB: boh occam razor direi, perché ricordare un altro metodo

```
>>> def two(x):
...     return x*2
...
>>> def three(x):
```

```

...     return x*3
...
>>> df = pd.DataFrame({"a": [1,2,3], "b": [4,5,6], "c": [7,8,9]})

>>> t = {"a": two, "b": three}
>>> df.transform(t)
   a  b
0  2 12
1  4 15
2  6 18

```

Alternativamente si può passare un `dict` ad `agg` che specifichi per variabile quali analisi fare

```

>>> df = pd.DataFrame({"a": [1,2,3], "b": [4,5,6], "c": [7,8,9]})
>>> analysis_dict = {
...     "a": ["count", "size"],
...     "b": ["sum", lambda col: col.loc[0]]}
>>> df.agg(analysis_dict)
      a      b
count  3.0   NaN
size   3.0   NaN
sum    NaN  15.0
<lambda> NaN   4.0

```

15.4.2.3 Reshape sulla base di indici (stack,unstack)

NB: bah direi che sulla base di valori è quello che si vuole solitamente

L'indexing gerarchico torna necessario nel reshape. Vi sono due metodi principali:

- `stack` ruota le colonne a righe (va verso long)
- `unstack` ruota da righe a colonne (va verso wide)

In questi casi utile un `name` agli indici

```

>>> df = pd.DataFrame({"one"   : [0, 3],
...                     "two"   : [1, np.nan],
...                     "three" : [2, 5],
...                     "four"  : [np.nan, 6]},
...                     index = pd.Index(["Ohio", "Colorado"], name = "state"))

>>> df
      one  two  three  four
state
Ohio      0  1.0      2   NaN
Colorado  3  NaN      5   6.0

>>> df.stack()
state
Ohio      one      0.0
          two      1.0
          three     2.0

```

stack: porre in formato long


```

        four      NaN
Colorado one      3.0
        two      NaN
        three     5.0
        four     6.0
dtype: float64
>>> df.stack(future_stack = True) # versione futura da struttura simmetrica
state
Ohio    one      0.0
        two      1.0
        three     2.0
        four     NaN
Colorado one      3.0
        two      NaN
        three     5.0
        four     6.0
dtype: float64
>>> df_long = df.stack()           # saving results

>>> df_long.unstack()              # unstack verso wide (default level = 1: usa seconda colonna)
      one two three four
state
Ohio    0.0  1.0   2.0  NaN
Colorado 3.0  NaN   5.0  6.0
>>> df_long.unstack(level = 0)      # unstack usando la prima colonna di indici
state Ohio  Colorado
one    0.0      3.0
two    1.0      NaN
three  2.0      5.0
four   NaN      6.0
>>> df_long.unstack(level = 'state') # unstack usando i name
state Ohio  Colorado
one    0.0      3.0
two    1.0      NaN
three  2.0      5.0
four   NaN      6.0

```


Capitolo 16

Matplotlib

Contents

16.1	Introduzione	228
16.2	Salvataggio figura	230
16.3	Impostazione layout figura ed esempi	230
16.3.1	Layout standard	230
16.3.2	Layout custom	232
16.4	Fine tuning	234
16.4.1	Ticks e subticks	234
16.4.2	Spines e grid	237
16.4.3	Gestire la sovrapposizione di elementi diversi (zorder)	238
16.4.4	Legenda	239
16.4.5	Plot con doppio asse delle y	245
16.4.6	Padding dei subplots (spazio bianco bordi)	245
16.5	Configurazioni	246
16.5.1	Ottenimento e modifica	246
16.5.2	Ripristino impostazioni default	247
16.5.3	Cambiare stile	247
16.6	Grafici utili	247
16.6.1	Linee	248
16.6.2	Diagramma a barre	248
16.6.3	Istogramma	249
16.6.4	Scatterplot	249
16.6.5	Matrice di scatterplot	252
16.6.6	Boxplot	252
16.6.7	Correlation matrix	255

```
import numpy as np
import pylabmisc as lb
import rdatasets
rng = np.random.default_rng(123)

# template importazione matplotlib
import matplotlib.pyplot as plt
```

Metodo	Descrizione
<code>plot</code>	linee/scatterplot
<code>hist</code>	istogramma
<code>bar</code>	diagramma a barre
<code>scatter</code>	scatterplot più flessibile/lento
<code>errorbar</code>	intervalli di confidenza
<code>set</code>	imposta tutti i seguenti in una unica chiamata
<code>set_title</code>	imposta il titolo
<code>set_xlabel, set_ylabel</code>	imposta il titolo degli assi
<code>set_xticks, set_yticks</code>	imposta la posizione dei ticks sugli assi
<code>set_xticklabels, set_yticklabels</code>	imposta l'etichetta dei ticks
<code>set_xlim, set_ylim</code>	impostare i limiti degli assi/zoom figura
<code>legend</code>	aggiunta di legenda
<code>text</code>	aggiunta di testo
<code>spines</code>	config bordi area di plot
<code>grid</code>	config griglia area di plot

Tabella 16.1: Metodi utili di `ax`

16.1 Introduzione

Alcuni punti di base:

- vi sono due stili di plotting in `matplotlib`: uno classico state-based che imita `matlab` e uno object oriented. Preferiamo questo secondo.
- una sequenza template per creare gli oggetti necessari sino a salvare la mostrare e salvare la ha il seguente template

```
fig, ax = plt.subplots() # setup fig and axis
# ...                  # do the actual plotting
plt.show()              # show the plot
fig.savefig("/tmp/first_plot.png", dpi=600) # save as png
```

- concetti fondanti:

- una *figure* è il container di una immagine;
- una figure può contenere al suo interno uno o più *axes*: questi sono gli effettivi plot dell'immagine

```
# Figura 1 x 1: 1 figure e 1 axes
fig, ax = plt.subplots()

# Figura 2 x 3: 1 figure e 6 axes
# ax è un array: (es ax[0,2] è ultimo grafico della prima riga)
fig, ax = plt.subplots(2, 3)
```

Il maggior lavoro si farà con i metodi messi a disposizione da `ax/axes`; alcuni metodi utili sono riportati in tabella 16.1, mentre l'anatomia di un grafico `matplotlib` in figura 16.1.

- gli *axis* invece sono i veri e propri assi di ciascun plot/axes




Figura 16.1: Anatomia di una figura




Figura 16.2: First plot

16.2 Salvataggio figura

Per il salvataggio figura, in `fig.savefig`:

- specificare i `dpi` per i png
- se `transparent=True` la figura sarà transparent e meglio si adatta all'inclusione in documenti con sfondo di diverso colore
- se si passa `bbox_inches='tight'` si shrinka la fig alle dimensioni del grafico interno, eliminando spazio bianco attorno ad esso ad eccezione di un piccolo ammontare di padding (aggiustabile con `pad_inches`)

Nel seguito si usa `lb.io.export_figure` per comodità (wrapper di `savefig`).

16.3 Impostazione layout figura ed esempi

16.3.1 Layout standard

Grafico singolo Esempio minimale figura 16.2:

- si aggiungono funzioni plottate con chiamate successive allo stesso `ax`
- ogni funzione ha una `label` utilizzata per la `legend`

```
fig, ax = plt.subplots(figsize=(3,3))
x = np.linspace(0, 10, 100)
ax.plot(x, np.sin(x), label = 'sin(x)')
ax.plot(x, np.cos(x), label = 'cos(x)')
ax.legend()
lb.io.export_figure(fig, label = 'first_plot')
```

Vettore di grafici Un esempio con layout grafici separati, in figura 16.3

- aumentiamo la dimensione di `figsize`
- ci riferiamo agli `ax` come ad un vettore
- interfacciamo il codice matplotlib con quello di pandas i *wrapper di pandas* in due modi
 1. prendendo in maniera grezza in indici (sull'asse delle x) e valori (sull'asse delle y) dalla serie
 2. utilizzando il metodo della serie

```
fig2, ax2 = plt.subplots(nrows=1, ncols=2, figsize=(6, 2.5))

# raw matplotlib style using index and values
psng = rdatasets.data("AirPassengers").rename(columns={"value": "number"})
psng["year"] = np.floor(psng.time)
# how to select several columns: use [[]]
monthly_mean = psng.groupby("year")[["number"]].mean()
ax2[0].plot(monthly_mean["number"].index, monthly_mean["number"].values)
# otherwise quicker single column (single [])
# monthly_mean = psng.groupby("year")["number"].mean()
# ax2[0].plot(monthly_mean.index, monthly_mean.values)

# pandas methods using iris: frequency of first 75 flower types
iris = rdatasets.data("iris")
freqs = iris.iloc[:75, 5].value_counts()
freqs.plot.bar(ax = ax2[1])

lb.io.export_figure(fig2, label = 'second_plot')
```

Matrice di grafici Matrice 2×2 in cui plottiamo i subset di un grafico

- utilizziamo `constrained_layout` per aggiustare le dimensioni dei plot affinché fittino la figura (buona idea quando si hanno più plot in una singola figura) e gli axis di un plot non vadano sopra il titolo di un altro (alternativamente possiamo fare le cose a mano mediante `fig.subplot_adjust`);
- usiamo `flatten` di `numpy` per iterare sequenzialmente sugli `ax`
- evitiamo che l'ultimo (inutile) axes venga mostrato impostando `axis` ad `off`
- impostiamo che i range di x e y siano comuni per
- aggiungiamo un titolo complessivo di figura mediante `fig.suptitle`

```
iris = rdatasets.data("iris")

fig3, ax3 = plt.subplots(nrows=2, ncols=2, figsize = (5,5), constrained_layout=True)
flat_axes = ax3.flatten()
```




Figura 16.3: Second plot

```
for ax, species in zip(flat_axes, ["setosa", "versicolor", "virginica"]):
    subs = iris.query(f"Species=='{species}'") # create subset
    ax.scatter(x=subs["Sepal.Length"], y=subs["Sepal.Width"], alpha = 0.5)
    ax.set_xlim((3, 9))
    ax.set_ylim((1, 5))
    ax.set_title(f"{species}") # single graph title
    ax.set_xlabel("length (cm)")
    ax.set_ylabel("width (cm)")

ax3[1, 1].axis("off") # non visualizzare il quarto grafico
fig3.suptitle("Sepal length and width scatterplot", fontsize=15)
lb.io.export_figure(fig3, label = 'third_plot')
```

Il risultato è in figura 16.4

16.3.2 Layout custom

Griglia di axes di dimensione variabile L'uso di `plt.subplots` è comodo ma impone che tutti gli axes abbiano dimensioni comuni. Per customizzare

- si crea una figura mediante `plt.figure`
- si determina una griglia con le proporzioni degli axes inclusi nella figura mediante `plt.GridSpec`
- si creano i singoli axes mediante `add_subplot` fornendo la griglia (con slicing) di riferimento
- per un altro esempio vedere *effective visualization* a pagina 59




Figura 16.4: Third plot

- con `plt.subplot_mosaic` si ottiene qualcosa di simile (effective visualization a pagina 67)

Sotto il codice per figura 16.5;

```
fig = plt.figure(figsize=(5,5))
grid = plt.GridSpec(nrows=2, ncols=3, figure=fig, wspace=0.4, hspace=0.3)

ax1 = fig.add_subplot(grid[0, 0])
ax1.boxplot([rng.standard_normal(50), rng.standard_normal(50) + 1])

ax2 = fig.add_subplot(grid[0, 1:])
ax2.bar(x = ["A", "B", "C", "D", "E", "F"], height = [10, 20, 40, 5, 25, 20])

ax3 = fig.add_subplot(grid[1, :2])
x = np.arange(1, 11)
ax3.stem(x, np.sin(x))

ax4 = fig.add_subplot(grid[1, 2])
x = np.linspace(start=-2, stop=2, num=100)
ax4.axhline(0) # riferimento
ax4.axvline(0) # cartesiano
ax4.plot(x, x**3, color="red")
ax4.text(-2, 1, '$y = x^3$')

lb.io.export_figure(fig, label = 'custom_grid')
```

Axes uno dentro all'altro Il setup di sopra pone subplot affiancati e riempie tutta la figura; maggiore controllo sul setup dei subplot può essere ottenuto con `add_axes`. Questa prende come input una lista di quattro numeri che specificano le coordinate [`left`, `bottom`, `width`, `height`] nel range da 0 (in basso a sinistra della figura) a 1 in alto a destra (figura 16.6).

```
fig = plt.figure(figsize = (3,3))
ax1 = fig.add_axes([0, 0, 1, 1]) # assi standard
ax2 = fig.add_axes([0.65, 0.65, 0.3, 0.3]) # assino piccolino a 0.65, 0.65
                                           # della figura ed estensione 0.3x0.3

ax1.plot(np.sin(np.linspace(0, 10)))
ax2.scatter(rng.standard_normal(100), rng.standard_normal(100))
lb.io.export_figure(fig, label = 'custom_subplots')
```

Per zoom di plot vedere anche effective visualization a pag 94

16.4 Fine tuning

16.4.1 Ticks e subticks

Qualora le configurazioni di default non vadano bene

- per impostare la *locazione*




Figura 16.5: Custom grid




Figura 16.6: Custom subplots

- per una locazione standard usare `matplotlib.ticker.MultipleLocator` nella chiamata a `ax.xaxis.set_major_locator` (ticks main) o `ax.xaxis.set_minor_locator` (ticks minor se necessari)
- per una custom/non uniforme utilizzare `ax.set_xticks` (`ax.set_yticks`)
- per date e time series usare locatori come `YearLocator` o `MonthLocator` (cfr effective visualization pag 97)
- per scegliere il *valore mostrato* `ax.set_xticklabels` (`ax.set_yticklabels`)
- per la dimensione ticks usare `ax.tick_params`
- per aggiustare il font dell'asse ottenere ciascuna label con `ax.get_xticklabels` (`ax.get_yticklabels`) dopodiché impostare dimensione/peso/famiglia con le funzioni `set_fontsize` `set_weight` `set_family`
- se invece si vuole solo **nascondere i ticks** (ma non le label) nella chiamata `ax.tick_params` impostare `left=False` o `bottom=False`

Ad esempio in 16.7

```
fig, ax = plt.subplots()
x = rng.standard_normal(50)
y = rng.standard_normal(50)
ax.scatter(x, y)
ax.set_xlim((-3, 3))
ax.set_ylim((-3, 3))
```




Figura 16.7: Ticks

```
# locazione dei ticks
from matplotlib.ticker import MultipleLocator
ax.xaxis.set_major_locator(MultipleLocator(1))
ax.xaxis.set_minor_locator(MultipleLocator(0.5))
ax.yaxis.set_major_locator(MultipleLocator(1))
ax.yaxis.set_minor_locator(MultipleLocator(0.5))

# dimensione ticks
ax.tick_params(axis='x', which='major', length=10, width=2, color="red")
ax.tick_params(axis='x', which='minor', length=5, width=1, color="orange")
ax.tick_params(axis='y', which='major', length=10, width=2, color="blue")
ax.tick_params(axis='y', which='minor', length=5, width=1, color="cyan")

# font dell'asse
for label in ax.get_xticklabels() + ax.get_yticklabels():
    label.set_fontfamily("Roboto")
    label.set_fontsize(6)

lb.io.export_figure(fig, label = 'ticks')
```

16.4.2 Spines e grid

Le *spines* sono gli assi che racchiudono l'immagine, in due dei quali sono posizionati gli assi (a sx e sotto); possiamo gestire il formato dei 4 spines indipendentemente. Le *grid* invece sono le griglie dell'area di plotting. Un esempio di entrambe in 16.8 ottenuta col codice di sotto

```
fig, ax = plt.subplots()
```




Figura 16.8: Spines grid

```
ax.scatter(rng.standard_normal(100), rng.standard_normal(100))

# tolgo spine sopra e a dx
ax.spines["top"].set_visible(False)
ax.spines["right"].set_visible(False)

# imposto che le grid siano sotto ai punti e inizio ad aggiungere le major
ax.set_axisbelow(True)
ax.grid(which='major', linestyle = '--', color='grey', linewidth=0.5, alpha=0.5)

# aggiungo ticks minor e grid minor (ogni 0.5 sia per x che y)
ax.xaxis.set_minor_locator(MultipleLocator(0.5))
ax.yaxis.set_minor_locator(MultipleLocator(0.5))
ax.grid(which='minor', linestyle = '--', color='grey', linewidth=0.1, alpha=0.5)

lb.io.export_figure(fig, label = 'spines_grid')
```

16.4.3 Gestire la sovrapposizione di elementi diversi (zorder)

Il parametro `zorder` (disponibile in diversi metodi di `ax` come `scatter`, `plot`, etc) controlla lo stacking degli elementi del plot sull'asse z determinando quali elementi appaiano più in evidenza e quali possono essere mascherati. La regola è che valori più alti sono associati ad un piano più alto/maggiore visibilità. Un esempio con grid, nuvola di punti e retta aventi rispettivamente `zorder` crescente (quindi la più visibile è la retta) in figura 16.9.

```
fig, ax = plt.subplots()
x = rng.standard_normal(100)
```




Figura 16.9: Zorder

```

y = rng.standard_normal(100) + 1
ax.scatter(x, y,
           zorder = 2)
ax.grid(which='major', linestyle = '--', color='grey', linewidth=1, alpha=0.5,
        zorder=1)
ax.plot([-2, 2], [-1, 3], color="red", lw=1, # retta da [0, 0] a [1,1]
        zorder=3)

lb.io.export_figure(fig, label = 'zorder')

```

16.4.4 Legenda

Il metodo `ax.legend` genera labels dal parametro `label` specificato nel comando di plot, ma si può fornire label custom nell'argomento `labels`. Per il posizionamento

- `loc` specifica il posizionamento tipo `upper right`, ..., `lower left`; vi è anche la possibilità di specificare `best` per il migliore (interpolato)
- `bbox_to_anchor` ottimizza la posizione in relazione agli axes; es per piazzare la legenda a destra, al di fuori dell'area di plot settare `bbox_to_anchor=(1,1)`

Alcuni esempi di entrambe a seguire di legende a livello di singolo ax; per legenda a livello di figura multipla (con molteplici grafici) da fare. Maggiori info su

- https://matplotlib.org/stable/api/_as_gen/matplotlib.axes.Axes.legend.html

- https://matplotlib.org/stable/users/explain/axes/legend_guide.html

```
# -----
# loc - posizionamento dentro ax
# -----

# opzioni: "best", 'upper right', 'upper left', 'lower left', 'lower right'
# 'right' 'center left' 'center right' 'lower center' 'upper center' 'center'
# posizionamento ottimale per non sovrapporre (il default)

fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(loc="best") # best è il default btw
lb.io.export_figure(fig, label="loc1")

# metti in alto a dx
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(loc="upper right")
lb.io.export_figure(fig, label="loc2")

# posizionamento con coordinate (percentuali di grafico x e y)
# es posiziona in mezzo per x (0.5) e a 1/4 per y (0.25)
# occhio che quello è considerato l'angolo in basso a sinistra della legenda
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(loc=(0.5, 0.25))
lb.io.export_figure(fig, label="loc3")

# -----
# uso di bbox_to_anchor
# -----

# legenda fuori dal plot in alto a dx (100% di asse x e y)
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(1, 1), loc="upper left")
lb.io.export_figure(fig, label="testbboxtoanchor1")

# legenda fuori dal plot impostare il suo centro/sinistra della legenda al 100%
# dell'asse x e 50% dell'asse y
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(1, 0.5), loc="center left")
lb.io.export_figure(fig, label="testbboxtoanchor2")
```





Figura 16.10: Loc1

```

# legenda sopra il plot da sx: occorre indicare
# - quattro numeri, che vanno a due a due, e servono per circoscrivere il
# posizionamento della legenda
# - il numero di colonne in cui splittare le etichette mediante ncols
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(0, 1, 1, 1), loc="lower left", ncols=2)
lb.io.export_figure(fig, label="testbboxtoanchor3")

# legenda sopra il plot da dx
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(0, 1, 1, 1), loc="lower right", ncols=2)
lb.io.export_figure(fig, label="testbboxtoanchor4")

# espandere la legenda per matchare i
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(0, 1, 1, 1), loc="lower right", ncols=2, mode="expand")
lb.io.export_figure(fig, label="testbboxtoanchor5")

```




Figura 16.11: Loc2




Figura 16.12: Loc3




Figura 16.13: Testbboxtoanchor1




Figura 16.14: Testbboxtoanchor2




Figura 16.15: Testbboxtoanchor3




Figura 16.16: Testbboxtoanchor4




Figura 16.17: Testbboxtoanchor5

16.4.5 Plot con doppio asse delle y

Un esempio potrebbe esser il plot della relazione di due variabili (mostrate su y) con una terza comune (su x), mostrato in fig 16.18 (oppure l'andamento di serie storiche aventi ordini di grandezza differenti).

```
df = rdatasets.data("airquality")

fig, ax1 = plt.subplots()
ax1.scatter(x=df.Ozone.values, y=df.Wind.values, alpha = 0.3, color="blue")
ax1.set_xlabel("Ozone")
ax1.set_ylabel("Wind", color="blue")
ax1.tick_params(axis="y", labelcolor="blue")

ax2 = ax1.twinx()
ax2.scatter(x=df.Ozone.values, y=df.Temp.values, alpha = 0.3, color="green")
ax2.set_ylabel("Temp", color="green")
ax2.tick_params(axis="y", labelcolor="green")

lb.io.export_figure(fig, label = 'double_y_axis')
```

16.4.6 Padding dei subplots (spazio bianco bordi)

Alternativamente all'automatico `constrained_layout=True` possiamo utilizzare `fig.subplots_adjust` per controllare il bianco verticale/orizzontale tra i bordi della figura e i bordi dell'axis:




Figura 16.18: Double y axis

- `left`, `top`, `right`, `bottom` regolano la percentuale di bianco esterna al box dell'axis (quindi se vi sono scale compresse agire su questo);
- in caso di subplot multipli `hspace` `wspace` regolano la quantità di spazio tra axis differenti

16.5 Configurazioni

Ogni volta che `matplotlib` si carica legge runtime configuration (rc) che valgono per ciascun plot creato.

16.5.1 Ottenimento e modifica

È possibile:

- listare le configurazioni indagando il dict `plt.rcParams`

```
plt.rcParams # tutte le configurazioni
plt.rcParams["figure.figsize"] # dimensioni figura
```

- modificarle mediante la funzione `plt.rc`

```
# impostare le dimensioni delle figure a 8.5 cm (figsize prende una
# lista di 2 misure in pollici come input)
plt.rc("figure", figsize = [8.5/2.54] * 2)
```

- salvare le configurazioni in `.config/matplotlib/matplotlibrc`. Ad esempio per salvare l'impostazione come default inserire

```
figure.figsize: 3.346 , 3.346 # figure size in inches
```

16.5.2 Ripristino impostazioni default

È possibile ripristinare i valori di default con la funzione `plt.rcParamsDefaults()`.

16.5.3 Cambiare stile

Sono disponibili stili di grafico diversi che servono per avere un array di configurazioni già pronto:

- per listare gli stili disponibili

```
plt.style.available
```

- per impostare lo stile dei grafici per tutto il resto della sessione

```
plt.style.use('default')
```

- per impostare uno stile temporaneamente (es per una serie di grafici) si può usare un context manager:

```
with plt.style.context('stylename'):
    make_a_plot()
    make_another_plot()
```

16.6 Grafici utili

Nel seguito alcuni grafici utili fatti mediante matplotlib o seaborn (che è un wrapper di più alto livello di matplotlib).

Per il plotting si farà preferibilmente uso del metodo `.plot` delle `Series` di `pandas` (che risulta particolarmente integrato con `matplotlib`).

Da ricordare che

- `pandas` di default plotta *l'indice* della serie/dataframe (indice di riga) sull'asse x e il valore della serie sull'asse y
- A tal proposito, a volte può essere utile trasporre il dataframe di elaborazione per invertire nomi colonne ed indici di riga (accessore `pd.DataFrame.T`) prima di procedere effettivamente a `plot`

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import pylabmisc as lb
import seaborn as sns
sns.set_theme()

# dataset
iris = sns.load_dataset('iris')
cd = lb.datasets.load("compact")
political = lb.datasets.load("political")
```

```
>>> import numpy as np
>>> import pandas as pd
>>> import matplotlib.pyplot as plt
>>> import pylbmisc as lb
>>> import seaborn as sns
>>> sns.set_theme()

>>> # dataset
>>> iris = sns.load_dataset('iris')
>>> cd = lb.datasets.load("compact")
>>> political = lb.datasets.load("political")
```

16.6.1 Linee

In figura 16.19 la durata media dei cd di una collezione per anno di pubblicazione. Se ci fossero state altre variabili oltre a durata (a parte quella di grouping) sarebbe stato plottato anche il loro andamento

```
>>> # durata media cd per anno
>>> cd.head() # dataset
   durata  anno
0      143  1966
1      150  1967
2      241  1994
3      337  1991
4      246  1994
>>> cd.groupby("anno").mean().head() # media annua di durata
   durata
anno
1958    212.0
1960    142.0
1961    150.0
1964    162.5
1965    155.75

# plotting
fig, ax = plt.subplots()
cd.groupby("anno").mean().plot.line(ax = ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_lines", caption = 'Diagramma linee')
```

16.6.2 Diagramma a barre

Si usi `bar` oppure `barh` per le barre orizzontali

```
>>> political.head()
   party_id  poid
0      3-dem    1
1      3-dem    1
2      3-dem    1
3      3-dem    1
```





Figura 16.19: Diagramma linee

```

4      3-dem      1
>>> political.party_id.astype("category").value_counts(sort = False)
party_id
1-rep      74
2-ind     111
3-dem      91
Name: count, dtype: int64

```

Per il diagramma figura 16.20 come farlo con pandas

```

fig, ax = plt.subplots()
political.party_id.astype("category").value_counts(sort = False).plot.bar(ax=ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_barre", caption = 'Diagramma a barre')

```

16.6.3 Istogramma

Utilizzando i metodi di pandas in figura 16.21

```

fig, ax = plt.subplots()
ax = iris.sepal_length.plot.hist(density = True, bins = range(9), xlim = [0, 8])
iris.sepal_length.plot.density(ax = ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_histo", caption = 'Istogramma (pandas syntax)')

```

16.6.4 Scatterplot

Uno rapido con pandas in figura 16.22 con alpha shading




Figura 16.20: Diagramma a barre




Figura 16.21: Istogramma (pandas syntax)




Figura 16.22: Scatterplot (pandas)

```
fig, ax = plt.subplots()
iris.plot.scatter(x = 'sepal_length', y = 'sepal_width', alpha = 0.5, ax=ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_scatter", caption = 'Scatterplot (pandas)')
# plt.close()
```

Uno più elaborato con colorazione condizionale, alpha shading e fatto con `seaborn` in figura 16.23

```
# data
group1 = pd.DataFrame({'x': np.random.normal(10, 1.2, 2000),
                       'y': np.random.normal(10, 1.2, 2000),
                       'group': np.repeat('A',2000) })
group2 = pd.DataFrame({'x': np.random.normal(14.5, 1.2, 2000),
                       'y': np.random.normal(14.5, 1.2, 2000),
                       'group': np.repeat('B',2000) })
group3 = pd.DataFrame({'x': np.random.normal(9.5, 1.5, 2000),
                       'y': np.random.normal(15.5, 1.5, 2000),
                       'group': np.repeat('C',2000) })
df = pd.concat([group1, group2, group3])

# Plot
fig, ax = plt.subplots()
ax = sns.scatterplot(x='x', y='y', data=df, hue='group', alpha = 0.30)
# fig = ax.get_figure()
lb.io.export_figure(fig, label="sns_scatter", caption = 'Scatterplot')
```




Figura 16.23: Scatterplot

16.6.5 Matrice di scatterplot

Invece per la matrice di scatterplot ne mettiamo senza con regressione (16.24 e con colorazioni 16.25).

```
# primo
fig, ax = plt.subplots()
plot = sns.pairplot(iris, kind="reg")
fig = plot.fig
lb.io.export_figure(fig, label="sns_pair1", caption = 'Pairplot 1', scale = 0.5)
# plt.close()

# secondo
fig, ax = plt.subplots()
plot = sns.pairplot(iris, kind="scatter", hue="species", markers=["o", "s", "D"], palette="magma")
fig = plot.fig
lb.io.export_figure(fig, label="sns_pair2", caption = 'Pairplot 2', scale = 0.5)
# plt.close()
```

16.6.6 Boxplot

In figura 16.26

```
fig, ax = plt.subplots()
ax = iris.boxplot(by = "species", column="sepal_length")
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_boxplot", caption = 'Boxplot')
```




Figura 16.24: Pairplot 1




Figura 16.25: Pairplot 2




Figura 16.26: Boxplot

16.6.7 Correlation matrix

In figure 16.27

```
corr = iris.select_dtypes("float").corr()

fig, ax = plt.subplots()
ax = sns.heatmap(corr,
                  cmap="RdBu",
                  vmin = -1, vmax = 1,
                  annot = True, fmt=".2f",
                  xticklabels=corr.columns.values, yticklabels=corr.columns.values)
fig = ax.get_figure()
lb.io.export_figure(fig, label="corrmatrix", caption = 'Correlation matrix')

# fig, ax = plt.subplots()
# ax = plt.matshow()
# fig = ax.get_figure()
# lb.io.export_figure(fig, label="corrmatrix", caption = 'Correlation matrix')
```




Figura 16.27: Correlation matrix

Parte III

Cookbook

Capitolo 17

Algebra lineare

Contents

17.1 Vettori, matrici e dimensioni	259
17.1.1 Creazione	259
17.1.2 Funzioni utilità per creazione	260
17.2 Operazioni	261
17.2.1 Somma	261
17.2.2 Trasposizione	261
17.2.3 Prodotti	262
17.3 Misc	263

Qui appunti da practical linear algebra for data science; esercizi fatti nella cartella dei test di Python.

```
>>> import numpy as np
```

17.1 Vettori, matrici e dimensioni

Con numpy si possono creare array ad una o due dimensioni; sono gli array a due dimensioni (in cui una è unitaria) ad essere assimilabili ai vettori dell'algebra lineare.

17.1.1 Creazione

Per definire un array a due dimensioni creare una lista che contiene liste delle righe dell'array

```
>>> # array ad una dimensione
>>> a_1d_array = np.array([1, 2, 3])

>>> # array a due dimensioni: vettori
>>> row_vector = np.array([      # ogni lista entro la lista più
...   [1, 2, 3]                # esterna è una riga del vettore
... ])
>>> col_vector = np.array([
```

```

...     [1],                # ogni lista entro la lista più
...     [2],                # esterna è una riga del vettore
...     [3]
... ])

>>> # array a due dimensioni matrici
>>> a_matrix = np.array([
...     [1, 2, 3],          # ogni lista entro la lista più
...     [4, 5, 6],          # esterna è una riga della matrice
...     [7, 8, 9]
... ])

>>> # non si stampano perché praticamente viene restituito
>>> # il codice inserito paro paro

>>> # differenze in termini di dimensioni e shape
>>> a_1d_array.shape      # 1d
(3,)
>>> row_vector.shape      # 2d di cui la prima è 1
(1, 3)
>>> col_vector.shape      # 2d di cui la seconda è 1
(3, 1)
>>> a_matrix.shape        # 2d con entrambe > 1
(3, 3)

>>> # len applicato a questo di fatto restituisce il numero di elementi per array
>>> # 1d e numero di righe per 2d
>>> len(a_1d_array)       # 1d (n. elementi)
3
>>> len(row_vector)       # 2d numero righe
1
>>> len(col_vector)       # 2d numero righe
3
>>> len(a_matrix)         # 2d numero righe
3

```

17.1.2 Funzioni utilità per creazione

Funzioni di convenienza per la generazione rapida di array:

```

>>> # Creazione rapida di dati
>>> np.arange(0, 20, 2)    # simile a range(), da 0 a 20 a step di 2
array([ 0,  2,  4,  6,  8, 10, 12, 14, 16, 18])
>>> np.arange(1, 10).reshape(3,3) # matrice
array([[1, 2, 3],
       [4, 5, 6],
       [7, 8, 9]])
>>> np.linspace(0, 1, 5)   # interpolazione lineare
array([0. , 0.25, 0.5 , 0.75, 1.  ])
>>> np.full(5, 2)          # vettore riempito di 2
array([2, 2, 2, 2, 2])

```

```

>>> np.zeros(10)                # array di zero
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
>>> np.ones((3, 5))             # array 3x5 di uno
array([[1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.]])
>>> np.eye(3)                   # matrice identita 3x3
array([[1., 0., 0.],
       [0., 1., 0.],
       [0., 0., 1.]])
>>> np.diag([1,2,3])            # diagonale
array([[1, 0, 0],
       [0, 2, 0],
       [0, 0, 3]])

>>> # creazione rapida sfruttando altre shape
>>> np.zeros_like(row_vector)   # array di 0 della stessa shape di x (np.ones_like)
array([[0, 0, 0]])

>>> # Generazione casuale
>>> np.random.normal(0, 1, 5)    # array 1d da normale mu=0, sd=1 di 5 elementi
array([ 0.66692562,  0.71823749, -0.67035065,  0.10155152,  0.97377111])
>>> np.random.randint(0, 10, (1, 3)) # vettore riga (1x3) con interi nell'intervallo [0,10 )
array([[6, 1, 3]])
>>> np.random.random((3, 3))     # matrice 3x3 con valori casuali uniformi 0-1
array([[0.47374685, 0.16281003, 0.36728085],
       [0.40928546, 0.81456103, 0.80206687],
       [0.93151864, 0.3805135 , 0.00898859]])

```

17.2 Operazioni

17.2.1 Somma

Occhio alle somme di vettori, per le quale funziona il broadcasting e spesso portano a risultati di programmazione inattesi

```

>>> a_1d_array + col_vector # dimensioni diverse (risultato inatteso)
array([[2, 3, 4],
       [3, 4, 5],
       [4, 5, 6]])
>>> row_vector + row_vector # dimensioni e shape uguali (risultato atteso)
array([[2, 4, 6]])
>>> row_vector + col_vector # dimensioni uguali, shape diverse (risultato inatteso)
array([[2, 3, 4],
       [3, 4, 5],
       [4, 5, 6]])

```

17.2.2 Trasposizione

Per trasporre si usa l'attributo `T` (più generale) o il metodo `transpose` degli array

```
a_1d_array.T # attenzione: non cambia (e non viene dato errore)
row_vector.T # diventa un col.vector
a_matrix.T   # come da programma
```

17.2.3 Prodotti

Prodotto standard Per il prodotto standard righe per colonne si usa `np.dot`, la chiocciola oppure il metodo `dot` di un array (dando l'altro come argomento):

```
>>> X = a_matrix

>>> np.dot(X.T, X)
array([[ 66,  78,  90],
       [ 78,  93, 108],
       [ 90, 108, 126]])
>>> X.T @ X
array([[ 66,  78,  90],
       [ 78,  93, 108],
       [ 90, 108, 126]])
>>> # anche X.T.dot(X)

>>> # fortunatamente i prodotti inizia ad essere schizzinoso come algebra
>>> # lineare comanda

>>> col_vector @ col_vector # errore: 3x1 non matcha con 3x1
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: matmul: Input operand 1 has a mismatch in its core dimension 0, with gufu
>>> row_vector @ row_vector # errore: 1x3 non matcha con 1x3
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: matmul: Input operand 1 has a mismatch in its core dimension 0, with gufu
>>> row_vector @ col_vector # ok: 1x3 con 3x1 (dimensioni conformi)
array([[14]])
>>> col_vector @ row_vector # ok: 3x1 con 1x3
array([[1, 2, 3],
       [2, 4, 6],
       [3, 6, 9]])
>>> a_matrix @ col_vector # ok: 3x3 con 3x1
array([[14],
       [32],
       [50]])
>>> a_matrix @ row_vector # errore: 3x3 non matcha con 1x3
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: matmul: Input operand 1 has a mismatch in its core dimension 0, with gufu

>>> # attenzione che dot invece non lo è troppo
>>> np.dot(row_vector, col_vector) # expected
array([[14]])
>>> np.dot(col_vector, row_vector) # unexpected
```

Funzione	Descrizione
<code>np.diag</code>	Return the diagonal (or off-diagonal) elements of a square matrix as a 1D array, or convert
<code>np.trace</code>	Compute the sum of the diagonal elements
<code>np.tril</code>	restituisce la matrice triangolare inferiore
<code>np.triu</code>	restituisce la matrice triangolare superiore
<code>np.linalg.norm</code>	Norma euclidea del vettore (radice della somma dei suoi quadrati)
<code>np.linalg.det</code>	Compute the matrix determinant
<code>np.linalg.eig</code>	Compute the eigenvalues and eigenvectors of a square matrix
<code>np.linalg.inv</code>	Compute the inverse of a square matrix
<code>np.linalg.pinv</code>	Compute the Moore-Penrose pseudo-inverse inverse of a square matrix
<code>np.linalg.qr</code>	Compute the QR decomposition
<code>np.linalg.svd</code>	Compute the singular value decomposition (SVD)
<code>np.linalg.solve</code>	Solve the linear system $\mathbf{Ax} = \mathbf{b}$ for $\mathbf{x}$, where $\mathbf{A}$ is a square matrix
<code>np.linalg.lstsq</code>	Compute the least-squares solution to $\mathbf{y} = \mathbf{Xb}$

Tabella 17.1: Funzioni per algebra lineare

```
array([[1, 2, 3],
       [2, 4, 6],
       [3, 6, 9]])
```

Prodotto di Hadamard È il prodotto elemento per elemento e si fa (su array idonei) mediante l'asterisco

```
>>> row_vector * row_vector # ok questo è il prodotto di Hadamard
array([[1, 4, 9]])
>>> row_vector * # no qui usa il broadcasting
File "<stdin>", line 1
    row_vector * # no qui usa il broadcasting
SyntaxError: invalid syntax
```

17.3 Misc

Funzioni utili riportate in tabella 17.1

Capitolo 18

Statistica descrittiva

Contents

18.1 Info generali	266
18.2 Univariate	266
18.2.1 Statistiche varie	266
18.3 Bivariate	267
18.3.1 Tabelle di contingenza	267
18.3.2 Covarianza e correlazione	268
18.3.3 Tabelle pivot	268
18.3.4 Tabella trial	270
18.3.5 Stratificate	270

```
>>> import numpy as np
>>> import pandas as pd
>>> import tableone

>>> # dataset di prova
>>> rng = np.random.default_rng(123)
>>> df1 = pd.DataFrame(rng.random((1000, 5)), columns=["a", "b", "c", "d", "e"])
>>> df1[:,2] = np.nan
>>> df2 = pd.DataFrame({
...     'name': ['Luca', 'Silvio', 'Luisa', 'Andrea', 'Giovanni'],
...     'age' : [21, 22, 23, 24, 25],
...     'income' : np.arange(5),
...     'group' : list("aaabb")
... })
>>> df3 = pd.DataFrame({"x": ["a", "a", "a", "a", "a", "b", "b"],
...                     "y": ["1", "2", "2", "2", "2", "1", "2"],
...                     "g": ["trt", "ctrl", "trt", "ctrl", "trt", "ctrl", "trt"]})

>>> categ_df = pd.DataFrame({"x": ["a", "a", "a", "a", np.nan, "b", "b"],
...                          "y": ["1", "2", "1", "2", "2", "1", "2"]})
>>> group_df = pd.DataFrame({'key1' : list('xyzzzzwww'),
...                          'key2' : ['one', 'two'] * 5,
...                          'data1' : rng.random(10),
```

```

...         'data2' : rng.random(10)},
...         index = list("abcdefghil")
...     )
>>> strata_df = pd.DataFrame({"x": np.random.randn(7),
...                           "y": np.random.randn(7),
...                           "z": np.random.randn(7),
...                           "g": ["trt", "ctrl", "trt", "ctrl", "trt", "ctrl", "trt"]})

```

18.1 Info generali

Usare `info` ed `head` sul `DataFrame` di interesse.

```

>>> df1.info()
<class 'pandas.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 5 columns):
#   Column  Non-Null Count  Dtype
---  -
0    a      500 non-null    float64
1    b      500 non-null    float64
2    c      500 non-null    float64
3    d      500 non-null    float64
4    e      500 non-null    float64
dtypes: float64(5)
memory usage: 39.2 KB
>>> df1.head()

```

	a	b	c	d	e
0	NaN	NaN	NaN	NaN	NaN
1	0.812095	0.923345	0.276574	0.819755	0.889893
2	NaN	NaN	NaN	NaN	NaN
3	0.629940	0.927407	0.231908	0.799125	0.518165
4	NaN	NaN	NaN	NaN	NaN

18.2 Univariate

18.2.1 Statistiche varie

Per le statistiche descrittive utilizzando `pd.Series`/`pd.DataFrame` consultare le funzioni riportate in tabella 18.1.

```

>>> # categoriche (frequenze)
>>> categ_df.x.value_counts()
x
a      4
b      2
Name: count, dtype: int64
>>> categ_df.x.value_counts(dropna=False)
x
a      4
b      2

```

Metodo	Series	DataFrame	Descrizione
count	✓	✓	numero di dati non mancanti
value_counts	✓	✓	frequenze
describe	✓	✓	set di statistiche descrittive
sum, prod	✓	✓	somma/prodotto dei valori
cumsum, cumprod, cummin, cummax	✓	✓	cumulate varie
diff, pct_change	✓	✓	differenze prime e variazione percentuale
min, max	✓	✓	minimo e massimo
mean	✓	✓	media
median	✓	✓	mediana
quantile	✓	✓	quantili
var, std	✓	✓	varianza/stddev campionaria
skew, kurt	✓	✓	skewness/kurtosis campionarie
argmin, argmax	✓		posizione (intera) di minimo/massimo
idxmin, idxmax	✓	✓	indici di massimo o minimo

Tabella 18.1: Metodi per analisi descrittiva

```
NaN    1
Name: count, dtype: int64
```

```
>>> # quantitative (count = non missing)
>>> df1.describe().transpose()
      count      mean      std      min      25%      50%      75%      max
a  500.0  0.502773  0.283937  0.001069  0.277015  0.504669  0.751380  0.999170
b  500.0  0.493140  0.282222  0.001018  0.266441  0.492543  0.726648  0.992696
c  500.0  0.502857  0.284280  0.001569  0.262469  0.496649  0.744064  0.999853
d  500.0  0.514312  0.292133  0.002091  0.273060  0.515317  0.768407  0.998832
e  500.0  0.504114  0.282020  0.000802  0.267343  0.505314  0.743535  0.997637
```

18.3 Bivariate

18.3.1 Tabelle di contingenza

Sono una speciale tipo di tabella pivot dove si applica il conteggio degli elementi in ciascun gruppo. Vi è una funzione apposta, `pd.crosstab`

```
>>> pd.crosstab(categ_df.x, categ_df.y, margins=True) # aggiungi totali
y      1  2  All
x
a      2  2    4
b      1  1    2
All    3  3    6
>>> pd.crosstab(categ_df.x, categ_df.y, dropna=False, margins=True) # display na
y      1  2  All
x
a      2  2    4
b      1  1    2
NaN    0  1    1
All    3  4    7
```

```
>>> pd.crosstab(categ_df.x, categ_df.y, margins=True, normalize = 'columns') # % col
y      1      2      All
x
a  0.666667  0.666667  0.666667
b  0.333333  0.333333  0.333333
```

18.3.2 Covarianza e correlazione

I metodi `cov` e `corr` permettono di ottenere la covarianza e correlazione per gli elementi di un dataframe.

```
>>> df1.cov()
      a      b      c      d      e
a  0.080620 -0.002448 -0.004181  0.003793  0.000086
b -0.002448  0.079649 -0.001561  0.006011  0.003534
c -0.004181 -0.001561  0.080815 -0.002689  0.000998
d  0.003793  0.006011 -0.002689  0.085342  0.000171
e  0.000086  0.003534  0.000998  0.000171  0.079535
>>> df1.corr() # pearson
      a      b      c      d      e
a  1.000000 -0.030547 -0.051794  0.045725  0.001079
b -0.030547  1.000000 -0.019462  0.072907  0.044398
c -0.051794 -0.019462  1.000000 -0.032377  0.012445
d  0.045725  0.072907 -0.032377  1.000000  0.002081
e  0.001079  0.044398  0.012445  0.002081  1.000000
>>> df1.corr(method='spearman')
      a      b      c      d      e
a  1.000000 -0.029228 -0.046313  0.045479 -0.000649
b -0.029228  1.000000 -0.020557  0.072495  0.044796
c -0.046313 -0.020557  1.000000 -0.033100  0.010191
d  0.045479  0.072495 -0.033100  1.000000  0.000381
e -0.000649  0.044796  0.010191  0.000381  1.000000
```

18.3.3 Tabelle pivot

Sono tabelle bivariate con statistiche stratificate per gruppi formati da righe e colonne (per intenderci il `tapply` con doppio indice di R).

Possono essere prodotte con i metodi che si vedranno sotto velocemente col metodo `pivot_table` dei `DataFrame`, che come default usa `mean` come funzione di aggregazione.

```
>>> group_df
   key1 key2  data1  data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
```

```

i    w one 0.950948 0.244235
l    w two 0.863556 0.815336
>>> group_df.pivot_table(index = "key1",      # cosa porre in riga
...                        columns = "key2",    # cosa porre in colonna
...                        values = "data1",     # dati per sintesi
...                        aggfunc = "median",   # metodo di DataFrameGroupBy
...                        margins = True)       # aggiungi i totali
key2      one      two      All
key1
w    0.715683  0.896679  0.896679
x    0.593121      NaN  0.593121
y    0.336277  0.353471  0.344874
z    0.915459  0.611006  0.822278
All   0.593121  0.822278  0.707699

```

```

>>> # utilizzo di funzioni custom: dovranno prendere in input una
>>> # serie e ritornare uno scalare

```

```

>>> def custom_fun(s): # s è una serie
...     return s.min() # qua la custom è inutile ma le cose si fanno così
...
>>> group_df.pivot_table(index = "key1",      # cosa porre in riga
...                        columns = "key2",    # cosa porre in colonna
...                        values = "data1",     # dati per sintesi
...                        aggfunc = custom_fun)
key2      one      two
key1
w    0.480418  0.863556
x    0.593121      NaN
y    0.336277  0.353471
z    0.915459  0.399734

```

Per applicare molteplici funzioni di sintesi usando una tavola pivot specificare in `aggfunc` una tuple (cose analoghe possono essere fatte usando `groupby` e poi `agg`)

```

>>> group_df.pivot_table(index = "key1",      # cosa porre in riga
...                        values = "data1",     # dati per sintesi
...                        aggfunc = ("sum", custom_fun))
custom_fun      sum
key1
w    0.480418  3.224724
x    0.593121  0.593121
y    0.336277  0.689747
z    0.399734  2.137470

>>> group_df.pivot_table(index = "key1",      # cosa porre in riga
...                        columns = "key2",    # cosa porre in colonna
...                        values = "data1",     # dati per sintesi
...                        aggfunc = ("sum", custom_fun))
custom_fun      sum

```

key2	one		two	
key1				
w	0.480418	0.863556	1.431366	1.793358
x	0.593121	NaN	0.593121	NaN
y	0.336277	0.353471	0.336277	0.353471
z	0.915459	0.399734	0.915459	1.222011

18.3.4 Tabella trial

Utilizzare la libreria `tableone`.

```
tab1_df = tableone.load_dataset('pn2012')
tab1_df.info()
tab1_df.head()
ft = {0: "alive", 1: "dead"}
tab1_df["group"] = pd.Categorical(tab1_df.death.map(ft))
select = ['Age', 'SysABP', 'Height', 'Weight', 'ICU', 'group']
categ = ['ICU', 'group']
groupby = 'group'
nonnormal = ['Age']
labels={'death': 'mortality'}
tab1 = tableone.TableOne(tab1_df,
                          columns=select,
                          categorical=categ,
                          groupby=groupby,
                          nonnormal=nonnormal,
                          rename=labels, #renaming variabili di riga
                          missing=True, # conta dei missing
                          include_null=False, # evita i missing nelle var categoriche
                          pval=False)

tab1
```

18.3.5 Stratificate

Si applica il classico split-apply-combine ossia:

1. si splitta la struttura dati (`Series` o `DataFrame`) mediante il metodo `groupby`: a questo si può passare alternativamente liste, array, dict, series o funzioni per effettuare il mapping ai gruppi. Di default `groupby` agisce splittando per sulle righe (`axis = "index"`), ma si può specificare `axis = "columns"` se si vuole splittare per colonna. Il metodo `groupby` ritorna un oggetto `GroupBy`:
 - è un iterabile sui “chunk” di dati (quindi funziona bene con i `for`) e fornisce un set di metodi già pronti da applicare
 - può essere soggetto a *indexing*, selezionando i subset di dati su cui performare le operazioni
2. si effettua l’elaborazione sui chunk di dati, alternativamente

Metodo	Descrizione
<code>any, all</code>	Vero se qualcuno o tutti sono veri (nel senso di Python)
<code>count</code>	numero di non NA
<code>cummin, cummax</code>	minimo e massimo cumulato
<code>cumsum</code>	somma cumulata
<code>cumprod</code>	produttoria cumulata
<code>first, last</code>	primo, ultimo
<code>mean</code>	media
<code>median</code>	mediana
<code>min, max</code>	minimo, massimo
<code>nth</code>	n-esimo elemento con dati ordinati
<code>prod</code>	prodotto
<code>quantile</code>	quantile
<code>rank</code>	ranghi
<code>size</code>	dimensione del gruppo
<code>sum</code>	somma
<code>std, var</code>	deviazione standard e varianza campionaria

Tabella 18.2: Metodi ottimizzati grouped

- l'oggetto `GroupBy` ha un set di metodi builtin già disponibili da applicare a tutti i chunk di dati. I metodi disponibili derivano da quelli della classe di riferimento quindi se è una `SeriesGroupBy` i metodi principali sono ereditati da quelli delle `Series`, viceversa se un `DataFrameGroupBy` dai `DataFrame`. In tabella 18.2 sono riportati alcuni metodi notevoli per `DataFrame`.
 - si possono applicare definire funzioni custom
 - si possono effettuare analisi ancor più custom (es una funzione a tutto il dataset).
3. viene riassembleato il tutto: il tipo di oggetto ritornato dipende dalle elaborazioni eseguite.

18.3.5.1 Splitting

Vediamo vari metodi di splitting:

- basato su valori di variabili

```
>>> group_df
   key1 key2  data1  data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
i    w  one  0.950948  0.244235
```

```
1      w      two      0.863556      0.815336
```

```
>>> # Splitting di DataFrame sulla base di una variabile
>>> df_spl = group_df.groupby('key2')
>>> df_spl.mean(numeric_only = True) # se no essendoci key2 da errore
      data1      data2
key2
one      0.655244      0.647341
two      0.673768      0.507612
```

```
>>> # Splitting di DataFrame sulla base di due variabili
>>> df_spl = group_df.groupby(['key1', 'key2'])
>>> df_spl.mean()
      data1      data2
key1 key2
w      one      0.715683      0.540951
      two      0.896679      0.792142
x      one      0.593121      0.764104
y      one      0.336277      0.956624
      two      0.353471      0.638191
z      one      0.915459      0.434077
      two      0.611006      0.157792
```

- sulla base degli indici di riga

```
>>> # recode mediante dict
>>> groups = {"a" : 'g1', "b" : 'g1',
...          "c" : 'g1', "d" : 'g1',
...          "e" : 'g2', "f" : 'g2',
...          "g" : 'g2', "h" : 'g2',
...          "i" : 'g2', "l" : 'g2'}
>>> df_spl = group_df.groupby(groups)
>>> df_spl.count()
      key1 key2 data1 data2
g1        4    4     4     4
g2        6    6     6     6
```

```
>>> # Splitting con Series (esempio logiche)
>>> groups = (group_df.key1 == "w") & (group_df.key2 == "one")
>>> df_spl = group_df.groupby(groups)
>>> df_spl.count()
      key1 key2 data1 data2
False     8    8     8     8
True      2    2     2     2
```

```
>>> # Splitting con funzione/predicato: viene applicata al valore degli indici
>>> df_spl = group_df.groupby(lambda x: x in ("b", "c", "d"))
>>> df_spl.count()
      key1 key2 data1 data2
False     7    7     7     7
True      3    3     3     3
```



```

>>> # anche grouping sulla base di indici è possibile
>>> # modifichiamo un attimo il dataframe per mostrare
>>> # la funzionalità. Si usa il progressivo/nome dell'indice
>>> # specificato in level

>>> group_df2 = group_df.set_index('key2')
>>> group_df2.groupby(level = 0).count()
      key1  data1  data2
key2
one         5         5         5
two         5         5         5
>>> group_df2.groupby(level = 'key2').count()
      key1  data1  data2
key2
one         5         5         5
two         5         5         5

```

18.3.5.2 Convertire indici di grouping in variabili

Negli esempi precedenti i risultati vengono restituiti con un indice, eventualmente gerarchico, composto a partire dalle chiavi di raggruppamento. Non essendo ciò sempre desiderabile, se si desidera avere qualcosa di più classico dove gli indici vengono invece messi in opportune colonne, a `groupby` si fornisce il parametro `as_index = False`.

```

>>> group_df
   key1 key2  data1  data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
i    w  one  0.950948  0.244235
l    w  two  0.863556  0.815336

>>> # aggregazione "flat"
>>> keys = ['key1', 'key2']
>>> df_spl = group_df.groupby(keys, as_index = False)
>>> df_spl.mean(numeric_only = True)
   key1 key2  data1  data2
0    w  one  0.715683  0.540951
1    w  two  0.896679  0.792142
2    x  one  0.593121  0.764104
3    y  one  0.336277  0.956624
4    y  two  0.353471  0.638191
5    z  one  0.915459  0.434077
6    z  two  0.611006  0.157792

```

18.3.5.3 Memorizzare in un dict lo split

Essendo il `GroupBy` un iterabile, è possibile elaborarlo, ad esempio trasformandolo in un `dict`, per avervi facile accesso:

```
>>> pieces = dict(list(group_df.groupby('key2')))
>>> pieces['two']
   key1 key2  data1  data2
b     y  two  0.353471  0.638191
d     z  two  0.399734  0.178105
f     z  two  0.822278  0.137480
h     w  two  0.929802  0.768947
l     w  two  0.863556  0.815336
```

18.3.5.4 Iterazione sui gruppi

Un oggetto `GroupBy` è iterabile quindi funziona bene con i `for`: questo genera una sequenza di tuple di due elementi, contenenti nome del gruppo (chiave) e chunk di dati di dati il pezzo di dati

```
>>> # chiave singola
>>> for group, data in group_df.groupby('key2'):
...     print(f"group = {group}")
...     print(data, "\n") # simple DataFrame
...
group = one
   key1 key2  data1  data2
a     x  one  0.593121  0.764104
c     y  one  0.336277  0.956624
e     z  one  0.915459  0.434077
g     w  one  0.480418  0.837667
i     w  one  0.950948  0.244235

group = two
   key1 key2  data1  data2
b     y  two  0.353471  0.638191
d     z  two  0.399734  0.178105
f     z  two  0.822278  0.137480
h     w  two  0.929802  0.768947
l     w  two  0.863556  0.815336

>>> # chiave multipla: il primo elemento della tupla è una
>>> # tupla con le chiavi
>>> for (key1, key2), data in group_df.groupby(['key1', 'key2']):
...     print(f"key1 = {key1}, key2 = {key2}")
...     print(data, "\n")
...
key1 = w, key2 = one
   key1 key2  data1  data2
g     w  one  0.480418  0.837667
i     w  one  0.950948  0.244235
```

```
key1 = w, key2 = two
  key1 key2      data1      data2
h    w  two  0.929802  0.768947
l    w  two  0.863556  0.815336
```

```
key1 = x, key2 = one
  key1 key2      data1      data2
a    x  one  0.593121  0.764104
```

```
key1 = y, key2 = one
  key1 key2      data1      data2
c    y  one  0.336277  0.956624
```

```
key1 = y, key2 = two
  key1 key2      data1      data2
b    y  two  0.353471  0.638191
```

```
key1 = z, key2 = one
  key1 key2      data1      data2
e    z  one  0.915459  0.434077
```

```
key1 = z, key2 = two
  key1 key2      data1      data2
d    z  two  0.399734  0.178105
f    z  two  0.822278  0.137480
```

18.3.5.5 Scelta delle variabili di analisi

Se il dataset è molto grande e si analizzano poche colonne per sottogruppi, conviene fare lo splitting solamente di queste ultime; alternativamente è possibile splittare tutto il dataset e procedere ad analisi dei subset in un secondo momento (senza dover rifare lo splitting).

Per farlo, gli oggetti `GroupBy` accettano l'indexing:

```
>>> df_spl = group_df.groupby('key2') # grouping/splitting

>>> df_spl['data1'] # column selection as usual
<pandas.api.typing.SeriesGroupBy object at 0x7faff7c76d00>

>>> sel = ['data1', 'data2'] # due colonne
>>> df_spl[sel]
<pandas.api.typing.DataFrameGroupBy object at 0x7faff7c0c730>
>>> df_spl[sel].mean() # elaborazione
      data1      data2
key2
one   0.655244  0.647341
two   0.673768  0.507612
```

18.3.5.6 Applicare funzioni di aggregazione custom

È possibile applicare funzioni che sintetizzano un insieme di dati in un unico valore passandole al metodo `aggregate` (o la sua abbreviazione `agg`) di un

oggetto GroupBy:

```
>>> def range(x):
...     return x.max() - x.min()
...
>>> sel = ["data1", "data2"]
>>> group_df.groupby('key2')[sel].aggregate(range)
           data1    data2
key2
one    0.614671  0.712389
two    0.576331  0.677856
```

18.3.5.7 Elaborazioni custom

Si potrebbe voler aggregare usando:

- diverse funzioni (es media e stdev) per ciascuna colonna: nel caso usare una lista di funzioni e/o stringhe con nomi di metodi scelti

```
>>> df_spl = df2.groupby('group')
>>> sel = ["income", "age"]

>>> def range(x):
...     return x.max() - x.min()
...
>>> # lista
>>> analyses = ['mean', range]
>>> df_spl[sel].agg(analyses)
           income      age
           mean range mean range
group
a           1.0      2  22.0      2
b           3.5      1  24.5      1

>>> # lista di tuple con nome colonna e funzione applicata
>>> analyses = [('Media', 'mean'), ('Range', range)]
>>> df_spl[sel].agg(analyses)
           income      age
           Media Range Media Range
group
a           1.0      2  22.0      2
b           3.5      1  24.5      1
```

- diverse funzioni su colonne differenti (es media per la prima colonna, stdev per la seconda).

```
>>> # dict con variabili analizzate e analisi effettuate
>>> analyses = {'age' : ["max", "std"], 'income' : "std"}
>>> df_spl.agg(analyses)
           age      income
           max      std      std
group
a           23  1.000000  1.000000
```

```
b      25  0.707107  0.707107
```

- Il problema è che si crea una gerarchia di colonna. Per rendere il tutto molto più flat ed esportabile, l'ultimo esempio può essere riscritto come

```
>>> df_spl.agg(age_max = ("age", "max"),
...            age_std = ("age", "std"),
...            income_std = ("income", "std"))
      age_max  age_std  income_std
group
a           23  1.000000    1.000000
b           25  0.707107    0.707107
```

18.3.5.8 Trasformazioni group-wise

Le aggregazioni effettuate mediante `aggregate` collassano un insieme di dati ad un numero. Viceversa:

- `transform` applica una funzione ad una serie: se l'output è un singolo valore questo viene broadcastato a tutti i membri del gruppo; se è un vettore (della stessa dimensione del gruppo) viene restituito. Eventuali parametri vanno specificati post funzione separati da virgole. Ad esempio lo scarto del gruppo dalla media di gruppo:

```
>>> def center(x):
...     return x - x.mean()
...
>>> def group_mean(x):
...     return x.mean()
...
>>> df_spl = group_df.groupby("key2")
>>> sel = ["data1", "data2"]
>>> df_spl[sel].transform(center)
      data1  data2
a -0.062124  0.116763
b -0.320297  0.130579
c -0.318968  0.309283
d -0.274034 -0.329507
e  0.260215 -0.213265
f  0.148509 -0.370132
g -0.174826  0.190325
h  0.256034  0.261336
i  0.295703 -0.403107
l  0.189788  0.307724
>>> df_spl[sel].transform(group_mean)
      data1  data2
a  0.655244  0.647341
b  0.673768  0.507612
c  0.655244  0.647341
d  0.673768  0.507612
e  0.655244  0.647341
f  0.673768  0.507612
```

```
g  0.655244  0.647341
h  0.673768  0.507612
i  0.655244  0.647341
l  0.673768  0.507612
```

- **apply** applica la funzione passata ai **DataFrame** creati dallo **splitting**; la funzione passatagli pu restituire uno scalare, una **list/array** o anche un **dataframe**.

Eventuali parametri della funzione specificati in seguito e separati da virgola

```
>>> def report(df, var = 'data1', method = 'high', n = 2):
...     if method == 'high':
...         sel = df[var].nlargest(n).index
...     elif method == 'low':
...         sel = df[var].nsmallest(n).index
...     return df.loc[sel, ]
...
>>> group_df
   key1 key2  data1  data2
a     x  one  0.593121  0.764104
b     y  two  0.353471  0.638191
c     y  one  0.336277  0.956624
d     z  two  0.399734  0.178105
e     z  one  0.915459  0.434077
f     z  two  0.822278  0.137480
g     w  one  0.480418  0.837667
h     w  two  0.929802  0.768947
i     w  one  0.950948  0.244235
l     w  two  0.863556  0.815336

>>> # applicata a tutto il dataframe: estrae i due valori più alti di
>>> # data1 overall
>>> report(group_df)
   key1 key2  data1  data2
i     w  one  0.950948  0.244235
h     w  two  0.929802  0.768947

>>> # stratified by key2: estrae i due valori più alti di data1 entro
>>> # gruppi di key2
>>> df_spl = group_df.groupby('key2')
>>> df_spl.apply(report, include_groups = False)
   key1  data1  data2
key2
one  i     w  0.950948  0.244235
     e     z  0.915459  0.434077
two  h     w  0.929802  0.768947
     l     w  0.863556  0.815336

>>> # uso di parametri della funzione: estrazione per data2
```

```
>>> df_spl.apply(report, var = 'data2', include_groups = False)
      key1      data1      data2
key2
one  c    y  0.336277  0.956624
     g    w  0.480418  0.837667
two  l    w  0.863556  0.815336
     h    w  0.929802  0.768947
```


Capitolo 19

Probabilità e simulazione

Contents

19.1 Funzionalità native	281
19.1.1 Combinatoria	281
19.1.2 Numeri casuali (<code>random</code>)	282
19.2 Numeri casuali (<code>numpy</code>)	283
19.2.1 Creazione del generatore	283
19.3 Variabili casuali (<code>scipy.stats</code>)	285
19.3.1 Funzioni e parametri principali	285
19.3.2 Uso interattivo rapido	285
19.3.3 Freezing di una distribuzione	286
19.3.4 Uso del generatore di <code>numpy</code>	286
19.4 Altri argomenti	286
19.4.1 Bootstrap CI	286

Importiamo le librerie qui usate

```
>>> import itertools
>>> import math
>>> import numpy as np
>>> import pandas as pd
>>> import scipy
>>> from scipy import stats
```

19.1 Funzionalità native

19.1.1 Combinatoria

Fattoriale

```
>>> math.factorial(4)
24
```

Coefficiente binomiale

```
>>> n = 4
>>> k = 2
>>> math.comb(n, k)
6
```

Permutazioni di un vettore

```
>>> data = [1,2,3]
>>> list(itertools.permutations(data))
[(1, 2, 3), (1, 3, 2), (2, 1, 3), (2, 3, 1), (3, 1, 2), (3, 2, 1)]
```

Combinazioni di elementi di un vettore

```
>>> list(itertools.combinations(data, 2))
[(1, 2), (1, 3), (2, 3)]
```

Prodotto cartesiano

```
>>> a = [1,2,3]
>>> b = [4,5,6]
>>> list(itertools.product(a,b)) # eventualmente posto in np.array
[(1, 4), (1, 5), (1, 6), (2, 4), (2, 5), (2, 6), (3, 4), (3, 5), (3, 6)]
```

19.1.2 Numeri casuali (random)

Per inizializzare il seed

```
>>> import random

>>> random.seed()      # se omesso viene utilizzato il system time (risultati cambiano)
>>> random.seed(1983)  # se specificato viene utilizzato, assicurando reproducibilita
```

Alcune funzionalità del modulo a seguire:

- per l'estrazione di interi

```
>>> # intero tra min e max
>>> d10 = random.randint(1, 10)
>>> print(d10)
2

>>> # intero casuale da un range
>>> random.randrange(1, 9, 2) # intero casuale da range(1,9,2) = [1,3,5,7]
1
```

- per numeri casuali semplici

```
>>> # uniforme 0-1
>>> random.random()
0.17028345753869512
```

- per estrazioni da urne o simili

```

>>> import string
>>> urn = list(string.ascii_lowercase[:10]) # una lista con prime 10 lettere

>>> # un elemento dall'urna
>>> random.choice(urn)
'h'

>>> # k elementi dall'urna, presi CON REIMMISSIONE (eventualmente con pesi)
>>> random.choices(urn, k=10)
['g', 'f', 'f', 'j', 'h', 'e', 'f', 'f', 'g', 'd']

>>> # k elementi SENZA REIMMISSIONE
>>> random.sample(urn, k=8)
['j', 'c', 'i', 'h', 'b', 'e', 'f', 'd']

>>> # shuffle inplace (modifica il dato di partenza)
>>> random.shuffle(urn)
>>> urn
['a', 'f', 'j', 'b', 'd', 'i', 'h', 'c', 'g', 'e']

```

19.2 Numeri casuali (numpy)

Per ottenerli si crea innanzitutto un generatore di numeri casuali (impostando seme e tipologia, volendo) dopodiché si utilizza questo per generare dati.

19.2.1 Creazione del generatore

Alternativamente si può

- utilizzando in **generatore di default**; il tutto è semplificato mediante `default_rng`

```

>>> rng = np.random.default_rng(seed = 6315744)
>>> rv = rng.standard_normal(5) # random vector
>>> rv
array([ 0.02015758,  2.22358201,  0.94127564, -0.75983371, -2.37769907])
>>> rm = rng.standard_normal((2, 3)) # random matrix
>>> rm
array([[ 0.25145986,  0.10362785, -1.26726019],
       [ 0.46240554, -0.14667618, -0.6394399 ]])

```

- **specificare il generatore**: occorre creare un generatore, alimentarlo con un bitgenerator (eg default o Mersenne-Twister) a cui si è fornito il seed impostato: ad esempio per un generatore standard e Mersenne-Twister (utilizzato da R) fatti a mano

```

>>> from numpy.random import Generator, PCG64, MT19937
>>> seed = 2154
>>> std = Generator(PCG64(seed = seed)) # equivalente al default
>>> std.standard_normal(5)
array([ 2.65496506, -0.20262369, -0.85302693, -0.37646063, -0.30786317])

```

Metodo	Descrizione
<code>integers</code>	Pesca interi in range
<code>choice</code>	Pesca casualmente da un array
<code>permutation</code>	Permutazione casuale di una array, restituendo una copia
<code>shuffle</code>	Permutazione in place
<code>random</code>	Estrazione da uniforme 0-1
<code>uniform</code>	Estrazione da uniform con min e max da specificare
<code>beta</code>	Estrazione da beta distribution
<code>binomial</code>	Estrazioni da binomiale
<code>multinomial</code>	Estrazioni da multinomiale
<code>standard_normal</code>	Estrazioni da una normale 0, 1
<code>normal</code>	Estrazioni da normal (con media/sd da specificare)
<code>multivariate_normal</code>	Estrazioni da una normale multivariata
tante altre ...	Vedere documentazione di <code>numpy.random</code>

Tabella 19.1: Alcuni metodi per la generazione di numeri casuali in `numpy`

```
>>> mt = Generator(MT19937(seed = seed))
>>> mt.standard_normal(5)
array([ 0.73327039,  1.19398753, -0.66427529, -0.42821724,  0.7421379 ])
```

Metodi per generatori casuali Una volta creato il generatore, alcuni metodi di interesse per estrarre numeri casuali (o effettuare operazioni con casualità) sono in tabella 19.1 (vedere doc).

```
>>> rng = np.random.default_rng(seed = 6315744)

>>> # interi tra min e max
>>> rng.integers(5, size=20) # 20 estrazioni da 0 a 4 (5 escluso)
array([1, 1, 0, 2, 2, 4, 4, 1, 2, 4, 4, 2, 0, 2, 2, 0, 1, 3, 0, 2])
>>> rng.integers(low = 1, high=10, size = 20, endpoint=True) # endpoint per max incluso
array([ 1,  7,  2,  1,  3,  2,  8,  3,  1,  1,  3,  4,  4,  4,  1,  4,  7,
        4, 10,  2])

>>> # pescare da un array
>>> data = np.arange(10)
>>> rng.choice(data, size=10, replace=True)
array([5, 2, 8, 9, 7, 6, 2, 1, 9, 1])

>>> # permutazioni
>>> rng.permutation(data) # copia
array([2, 4, 6, 9, 7, 5, 3, 1, 8, 0])
>>> rng.shuffle(data) # modifica dell'array inplace
>>> data
array([9, 5, 7, 4, 6, 1, 2, 3, 8, 0])

>>> #
```

Famiglia	Funzione	Famiglia	Funzione
Bernoulli	bernoulli	Uniforme cont.	uniform
Binomiale	binom	Esponenziale	expon
Geometrica	geom	Normale	norm
Binomiale neg.	nbinom	Gamma	gamma
Ipergeometrica	hypergeom	Chi-quadrato	??
Poisson	poisson	Beta	beta
Uniforme disc.	randint	T di Student	t
		F	??
		Logistica	??
		Lognormale	??
		Weibull	??
		Pareto	??

Tabella 19.2: Funzioni `scipy.stats.*` per variabili casuali in Python

Metodo	Descrizione
rvs	generazione di numeri casuali; equivalente di r* di R
pdf, pmf	probability density e mass function; equivalente di d* di R
cdf	cumulative distribution function; equivalente di p* di R
ppf	percent point function (inversa di cdf); equivalente di q* di R
sf	Survival Function (1-CDF)
isf	Inverse Survival Function (Inverse of SF)
stats	media, varianza, (Fisher's) skew, or (Fisher's) kurtosis
moment	non-central moments of the distribution

Tabella 19.3: Metodi variabili casuali `scipy`

19.3 Variabili casuali (`scipy.stats`)

Le funzioni di `numpy.random` servono esclusivamente per la generazione di numeri casuali e applicazioni MonteCarlo-like; se si vuole disporre di più funzioni per quanto riguarda le variabili casuali (paragonabili a quelle di R) occorre utilizzare `scipy.stats`

19.3.1 Funzioni e parametri principali

In `scipy.stats` le variabili casuali di maggiore interesse sono riportate in tabella 19.2, i relativi metodi sono riportati in tabella 19.3.

I parametri di maggior interesse sono **loc** (locazione) e **scale** (dispersione); alcune quantitative anche un parametro **shape**. Nel caso della normale **loc** è la media ed è impostata di default a 0, **scale** la deviazione standard ed è impostata a 1.

19.3.2 Uso interattivo rapido

Un esempio di utilizzo interattivo rapido con normale a seguire. Per facilitare, le funzioni supportano il broadcasting

```
>>> stats.norm.rvs(size = 5) # estrazioni di casuali (come rnorm(5))
```

```

array([-0.00145474, -1.31465268, -0.37961174,  1.26521065,  0.12066774])
>>> stats.norm.pdf(0.5)          # densità: come dnorm(0.5)
np.float64(0.3520653267642995)
>>> stats.norm.cdf(1.96)         # cdf: come pnorm(1.96)
np.float64(0.9750021048517795)
>>> stats.norm.ppf(0.5)          # quantile: come qnorm(0.5)
np.float64(0.0)

>>> # esempio con broadcasting
>>> stats.norm.pdf([0.025, 0.5, 0.975])
array([0.39881763, 0.35206533, 0.24801872])

```

19.3.3 Freezing di una distribuzione

Spesso capita di dover lavorare più volte con distribuzioni dai parametri differenti. Onde evitare di dover reinserire i parametri in ogni chiamata possiamo effettuare il freezing di una distribuzione

```

>>> n01 = stats.norm(loc = 0, scale = 1) # mu=0, sd=1 sono i valori di default
>>> n01.rvs(size = 5)
array([ 0.14794178, -2.75372579, -0.35689632,  0.00771784,  1.47827716])

>>> n25 = stats.norm(loc = 2, scale = 5) # mu=2, sd=5
>>> n25.rvs(size = 5)
array([-2.78807314,  8.64504053, -2.92924815,  4.35778601,  1.95626735])

```

19.3.4 Uso del generatore di numpy

Passiamo il generatore di numeri casuali in `numpy` nel metodo della funzione `freezata`

```

>>> rng = np.random.default_rng(302132)

>>> n01 = stats.norm()                # esempio d'uso:
>>> n01.rvs(size = 5, random_state = rng) # usato al momento
array([-0.14191574,  0.42922204, -0.33735776,  0.20712603, -0.9709426 ])
>>> n01.rvs(size = 5, random_state = rng) # dell'estrazione
array([ 0.64705971, -1.05564341,  0.94984921, -0.30577826, -0.61788831])

>>> rng2 = np.random.default_rng(302132) # riproduzione sequenza
>>> n01.rvs(size = 5, random_state = rng2)
array([-0.14191574,  0.42922204, -0.33735776,  0.20712603, -0.9709426 ])
>>> n01.rvs(size = 5, random_state = rng2)
array([ 0.64705971, -1.05564341,  0.94984921, -0.30577826, -0.61788831])

```

19.4 Altri argomenti

19.4.1 Bootstrap CI

```
>>> from scipy.stats import bootstrap
```

```
>>> rng = np.random.default_rng(6235)
>>> data_gen = stats.norm()
>>> data = data_gen.rvs(100, random_state = rng)

>>> # 95 bca CI of median
>>> res = bootstrap(data = [data],          # ocio qui: "sequence of array-like"
...                 statistic = np.median,
...                 n_resamples = 10000,
...                 random_state = rng)

>>> res.confidence_interval          # ci
ConfidenceInterval(low=np.float64(-0.21318771294834601), high=np.float64(0.17332161369498447))
>>> res.confidence_interval.low      # ci
np.float64(-0.21318771294834601)
>>> res.confidence_interval.high     # ci
np.float64(0.17332161369498447)
>>> res.bootstrap_distribution # valori delle stats nei resample
array([-0.08377    ,  0.09051194,  0.08447688, ..., -0.17939695,
        -0.13573812,  0.16842878], shape=(10000,))
```


Capitolo 20

Test statistici

Contents

20.1 Setup	290
20.2 Medie	290
20.2.1 Test t: 1 gruppo vs valore teorico	290
20.2.2 Test t: 2 gruppi indipendenti	290
20.2.3 Anova (2+ gruppi indipendenti)	290
20.2.4 Test t: 2 gruppi appaiati	291
20.2.5 Anova per misure ripetute (2+ gruppi appaiati)	291
20.3 Non parametric	292
20.3.1 Wilcoxon	292
20.3.2 Mann Whitney	292
20.3.3 Kruskal Wallis	292
20.3.4 Friedman test	292
20.4 Proporzioni	293
20.4.1 Test binomiale e CI clopper pearson	293
20.4.2 Test di Fisher	293
20.4.3 Chisquare	294
20.4.4 McNemar	294
20.4.5 Q di Cochran	294
20.5 Tassi	295
20.5.1 Comparazione 2 tassi	295
20.6 Correlazione	295
20.6.1 Pearson	295
20.6.2 Spearman	295
20.6.3 Tests	295
20.7 Varianze	295
20.7.1 Test di Bartlett	296
20.7.2 Test di Levene	296
20.7.3 Test di Fligner	296
20.8 Sopravvivenza	296
20.8.1 Logrank test	296
20.9 Agreement	297

20.9.1	Cohen's K	297
20.9.2	Fleiss K	297
20.9.3	Lin coefficient	297
20.10	Reliability/consistency	297
20.10.1	Cronbach α	297
20.10.2	ICC	297
20.11	Multiplicity	297
20.12	Test simulativi	298

20.1 Setup

Importiamo le librerie qui usate

```
>>> import numpy as np
>>> import pandas as pd
>>> import pingouin as pg
>>> from scipy import stats
```

20.2 Medie

20.2.1 Test t: 1 gruppo vs valore teorico

```
>>> x = [5.5, 2.4, 6.8, 9.6, 4.2]
>>> stats.ttest_1samp(x, popmean = 4)
TtestResult(statistic=np.float64(1.3973913920955365), pvalue=np.float64(0.23482367964
>>> pg.ttest(x, 4)
          T   dof alternative      p-val      CI95%   cohen-d   BF10      power
T-test  1.397391     4   two-sided  0.234824  [2.32, 9.08]  0.624932  0.766  0.191796
```

20.2.2 Test t: 2 gruppi indipendenti

```
>>> np.random.seed(123)
>>> trt = np.random.normal(size=18)
>>> ctrl = np.random.normal(size=22)
>>> stats.ttest_ind(trt, ctrl, equal_var = False)
TtestResult(statistic=np.float64(0.62859959726889), pvalue=np.float64(0.5339329415063
>>> pg.ttest(trt, ctrl)
          T      dof alternative      p-val      CI95%   cohen-d   BF10      p
T-test  0.6286  33.040969   two-sided  0.533933  [-0.54, 1.03]  0.203618  0.363  0.09
```

20.2.3 Anova (2+ gruppi indipendenti)

```
>>> df = pg.read_dataset('anova')
>>> df.head()
   Subject  Hair color  Pain threshold
0         1  Light Blond             62
1         2  Light Blond             60
2         3  Light Blond             71
3         4  Light Blond             55
```

```

4          5 Light Blond          48
>>> df["Hair color"].value_counts()
Hair color
Light Blond      5
Dark Blond       5
Dark Brunette    5
Light Brunette   4
Name: count, dtype: int64
>>> # oneway classica
>>> pg.anova(dv='Pain threshold', between='Hair color', data=df, detailed = True)
      Source      SS  DF      MS      F      p-unc      np2
0 Hair color 1360.726316   3  453.575439  6.791407  0.004114  0.575962
1      Within 1001.800000  15   66.786667      NaN      NaN      NaN
>>> chunks = [data["Pain threshold"].values
...           for color, data in df.groupby("Hair color")]
>>> stats.f_oneway(*chunks)
F_onewayResult(statistic=np.float64(6.791407046264094), pvalue=np.float64(0.00411422733307741))
>>> # non assumendo numerosità comuni e/o varianza costante
>>> pg.welch_anova(dv='Pain threshold', between='Hair color', data=df)
      Source  ddof1  ddof2      F      p-unc      np2
0 Hair color      3  8.329841  5.890115  0.018813  0.575962

```

20.2.4 Test t: 2 gruppi appaiati

```

>>> pre = [5.5, 2.4, np.nan, 9.6, 4.2]
>>> post = [6.4, 3.4, 6.4, 11., 4.8]
>>> stats.ttest_rel(pre, post, nan_policy="omit")
TtestResult(statistic=np.float64(-5.901869285972221), pvalue=np.float64(0.009712771595911211),
>>> pg.ttest(pre, post, paired=True)
      T  dof alternative      p-val      CI95%      cohen-d      BF10      power
T-test -5.901869      3  two-sided  0.009713  [-1.5, -0.45]  0.306268  7.169  0.072967

```

20.2.5 Anova per misure ripetute (2+ gruppi appaiati)

```

>>> # dataset in formato long
>>> df = pg.read_dataset('rm_anova')
>>> df.head()
      Subject  Gender Region Education  DesireToKill  Disgustingness  Frighteningness
0          1  Female  North      some           10.0             High             High
1          1  Female  North      some           9.0             High             Low
2          1  Female  North      some           6.0             Low             High
3          1  Female  North      some           6.0             Low             Low
4          2  Female  North  advance           10.0             High             High
>>> pg.rm_anova(dv='DesireToKill', within='Disgustingness',
...             subject='Subject', data=df, detailed=True)
      Source      SS  DF      MS      F      p-unc      ng2      eps
0 Disgustingness  27.485215   1  27.485215  12.043878  0.000793  0.025784  1.0
1      Error  209.952285  92   2.282090      NaN      NaN      NaN  NaN
>>> # dataset in formato wide
>>> df = pg.read_dataset('rm_anova_wide')
>>> df.head()

```

	Before	1 week	2 week	3 week
0	4.3	5.3	4.8	6.3
1	3.9	2.3	5.6	4.3
2	4.5	2.6	4.1	NaN
3	5.1	4.2	6.0	6.3
4	3.8	3.6	4.8	6.8

```

>>> pg.rm_anova(df)
      Source ddof1 ddof2      F      p-unc      ng2      eps
0 Within      3     24  5.200652  0.006557  0.346392  0.694329

```

20.3 Non parametric

20.3.1 Wilcoxon

```

>>> pre = np.array([20, 22, 19, 20, 22, 18, 24, 20, 19, 24, 26, 13])
>>> post = np.array([38, 37, 33, 29, 14, 12, 20, 22, 17, 25, 26, 16])
>>> stats.wilcoxon(pre, post)
WilcoxonResult(statistic=np.float64(20.5), pvalue=np.float64(0.2880859375))
>>> pg.wilcoxon(pre, post, correction = False)
      W-val alternative      p-val      RBC      CLES
Wilcoxon  20.5 two-sided  0.288086 -0.378788  0.395833
>>> pg.wilcoxon(pre, post) # con correzione di continuità
      W-val alternative      p-val      RBC      CLES
Wilcoxon  20.5 two-sided  0.288086 -0.378788  0.395833

```

20.3.2 Mann Whitney

```

>>> trt = np.random.uniform(low=0, high=1, size=20)
>>> ctrl = np.random.uniform(low=0.2, high=1.2, size=20)
>>> stats.mannwhitneyu(trt, ctrl, use_continuity=True)
MannwhitneyuResult(statistic=np.float64(149.0), pvalue=np.float64(0.17192970543827346))
>>> pg.mwu(trt, ctrl)
      U-val alternative      p-val      RBC      CLES
MWU  149.0 two-sided  0.17193 -0.255  0.3725

```

TODO:

`scipy.stats.brunnermunzel`

20.3.3 Kruskal Wallis

```

>>> df = pg.read_dataset('anova')
>>> # pingouin
>>> pg.kruskal(data=df, dv='Pain threshold', between='Hair color')
      Source ddof1      H      p-unc
Kruskal Hair color      3  10.58863  0.014172
>>> # scipy
>>> stats.kruskal(*chunks)
KruskalResult(statistic=np.float64(10.588630377524138), pvalue=np.float64(0.014171563))

```

20.3.4 Friedman test

Tipo un wilcoxon con più colonne di 2

```

>>> # dati da friedman.test in R
>>> df = pd.DataFrame(np.array([5.40, 5.50, 5.55,
...                             5.85, 5.70, 5.75,
...                             5.20, 5.60, 5.50,
...                             5.55, 5.50, 5.40,
...                             5.90, 5.85, 5.70,
...                             5.45, 5.55, 5.60,
...                             5.40, 5.40, 5.35,
...                             5.45, 5.50, 5.35,
...                             5.25, 5.15, 5.00,
...                             5.85, 5.80, 5.70,
...                             5.25, 5.20, 5.10,
...                             5.65, 5.55, 5.45,
...                             5.60, 5.35, 5.45,
...                             5.05, 5.00, 4.95,
...                             5.50, 5.50, 5.40,
...                             5.45, 5.55, 5.50,
...                             5.55, 5.55, 5.35,
...                             5.45, 5.50, 5.55,
...                             5.50, 5.45, 5.25,
...                             5.65, 5.60, 5.40,
...                             5.70, 5.65, 5.55,
...                             6.30, 6.30, 6.25]).reshape(22,3),
...                     columns = ["t0", "t1", "t2"])
>>> stats.friedmanchisquare(df.t0, df.t1, df.t2)
FriedmanchisquareResult(statistic=np.float64(11.142857142857132), pvalue=np.float64(0.003805040
>>> pg.friedman(df)

```

	Source	W	ddof1	Q	p-unc
Friedman	Within	0.253247	2	11.142857	0.003805

20.4 Proporzioni

20.4.1 Test binomiale e CI clopper pearson

```

>>> test = stats.binomtest(3, n=15, p=0.1) #p è la probabilità sotto h0 da rifiutare
>>> test
BinomTestResult(k=3, n=15, alternative='two-sided', statistic=0.2, pvalue=0.18406106910639106)
>>> test.proportion_ci()
ConfidenceInterval(low=0.04331200510583602, high=0.48089113380685317)

```

20.4.2 Test di Fisher

Si ha per le tabelle 2x2

```

>>> # odds ratio (stima) calcolato è diverso da quello di R (vedi doc), p-uguale
>>> tea = np.array([[3, 1], [1, 3]])
>>> stats.fisher_exact(tea)
SignificanceResult(statistic=np.float64(9.0), pvalue=np.float64(0.48571428571428565))

```

TODO:
stats.barnard_exact

20.4.3 Chisquare

Per le tabelle $n \times m$

```
>>> obs = np.array([[10, 10, 20],
...                 [20, 20, 20]])
>>> stats.chi2_contingency(obs)
Chi2ContingencyResult(statistic=np.float64(2.7777777777777777), pvalue=np.float64(0.2
[18., 18., 24.])))
>>> data = pg.read_dataset('chi2_independence')
>>> pg.chi2_independence(data, x='sex', y='target')
(target      0      1
sex
0      43.722772   52.277228
1      94.277228  112.722772, target      0      1
sex
0      24.5   71.5
1      113.5  93.5,
test      lambda      chi2      dof      pval
0      pearson   1.000000  22.717227  1.0  1.876778e-06  0.273814  0.997494
1      cressie-read 0.666667  22.931427  1.0  1.678845e-06  0.275102  0.997663
2      log-likelihood 0.000000  23.557374  1.0  1.212439e-06  0.278832  0.998096
3      freeman-tukey -0.500000  24.219622  1.0  8.595211e-07  0.282724  0.998469
4      mod-log-likelihood -1.000000  25.071078  1.0  5.525544e-07  0.287651  0.998845
5      neyman -2.000000  27.457956  1.0  1.605471e-07  0.301032  0.999481)
```

20.4.4 McNemar

```
>>> data = pg.read_dataset('chi2_mcnemar')
>>> pg.chi2_mcnemar(data, 'treatment_X', 'treatment_Y')
(treatment_Y  0  1
treatment_X
0      20  40
1      8  12,
chi2      dof      p-approx      p-exact
mcnemar  20.020833  1  0.000008  0.000003)
```

20.4.5 Q di Cochran

Mc nemar per più tempi/trattamenti su stessi soggetti

```
>>> df = pg.read_dataset('cochran')
>>> df.head()
   Subject  Time  Energetic
0         1  Monday         1
1         2  Monday         0
2         3  Monday         0
3         4  Monday         0
4         5  Monday         1
>>> df_wide = df.pivot_table(index="Subject", columns="Time", values="Energetic")
>>> pg.cochran(df_wide)
   Source  dof      Q      p-unc
cochran  Within    2  6.705882  0.034981
```

20.5 Tassi

20.5.1 Comparazione 2 tassi

Il test di poisson di python verifica che la differenza tra tassi sia nulla (quello di R che il rapporto sia unitario)

```
>>> # poisson.test(c(11, 6+8+7), c(800, 1083+1050+878))
>>> stats.poisson_means_test(11, 800, 6+8+7, 1083+1050+878)
SignificanceResult(statistic=np.float64(1.5342150126346437), pvalue=np.float64(0.13862291985862))
>>> # i risultati sono diversi ma il manuale di python dice
```

I risultati di questo test sono differenti da quelli di R ma la documentazione di python dice che ha maggior potenza del test poissoniano esatto di R.

20.6 Correlazione

```
>>> # generare dati
>>> mean, cov = [4, 6], [(1, .5), (.5, 1)]
>>> x, y = np.random.multivariate_normal(mean, cov, 30).T
>>> data = {"x": x, "y": y}
>>> df = pd.DataFrame(data)
```

20.6.1 Pearson

```
>>> stats.pearsonr(df.x, df.y)
PearsonRResult(statistic=np.float64(0.42350936826041014), pvalue=np.float64(0.01969785190872100))
>>> pg.corr(df.x, df.y)
```

	n	r	CI95%	p-val	BF10	power
pearson	30	0.423509	[0.07, 0.68]	0.019698	3.041	0.663505

20.6.2 Spearman

```
>>> stats.spearmanr(df.x, df.y)
SignificanceResult(statistic=np.float64(0.35973303670745277), pvalue=np.float64(0.0508737485072))
>>> pg.corr(df.x, df.y, method="spearman")
```

	n	r	CI95%	p-val	power
spearman	30	0.359733	[-0.0, 0.64]	0.050874	0.50986

20.6.3 Tests

```
>>> pg.rcorr
<function rcorr at 0x7faff74a8180>
```

20.7 Varianze

Vediamo le funzioni per la comparazione di k varianze sotto diverse ipotesi sempre meno restrittive

20.7.1 Test di Bartlett

Testa parametricamente la differenza di varianze ipotizzando una distribuzione normale del carattere nella popolazione. Se a 2 gruppi è il test F.

```
>>> a = [8.88, 9.12, 9.04, 8.98, 9.00, 9.08, 9.01, 8.85, 9.06, 8.99]
>>> b = [8.88, 8.95, 9.29, 9.44, 9.15, 9.58, 8.36, 9.18, 8.67, 9.05]
>>> c = [8.95, 9.12, 8.95, 8.85, 9.03, 8.84, 9.07, 8.98, 8.86, 8.98]
>>> stats.bartlett(a, b, c)
BartlettResult(statistic=np.float64(22.789434813726768), pvalue=np.float64(1.12547825
```

20.7.2 Test di Levene

Testa parametricamente la differenza di varianze non ipotizzando distribuzioni normali

```
>>> stats.levene(a, b, c)
LeveneResult(statistic=np.float64(7.584952754501659), pvalue=np.float64(0.00243150596
```

20.7.3 Test di Fligner

Equivalente non parametrico

```
>>> stats.fligner(a, b, c)
FlignerResult(statistic=np.float64(10.803687663522238), pvalue=np.float64(0.004508260
```

20.8 Sopravvivenza

Utilizziamo la libreria `lifelines`

20.8.1 Logrank test

```
>>> T1 = [1, 4, 10, 12, 12, 3, 5.4]
>>> E1 = [1, 0, 1, 0, 1, 1, 1]
>>> T2 = [4, 5, 7, 11, 14, 20, 8, 8]
>>> E2 = [1, 1, 1, 1, 1, 1, 1, 1]

>>> from lifelines.statistics import logrank_test
>>> results = logrank_test(T1, T2, event_observed_A=E1, event_observed_B=E2)
>>> results.print_summary()
<lifelines.StatisticalResult: logrank_test>
      t_0 = -1
  null_distribution = chi squared
degrees_of_freedom = 1
      test_name = logrank_test

---
test_statistic    p  -log2(p)
      0.09 0.77      0.38
>>> # results.p_value, results.test_statistic
```


20.9 Agreement

20.9.1 Cohen's K

```
>>> from statsmodels.stats.inter_rater import cohens_kappa
>>> cohens_kappa
<function cohens_kappa at 0x7faff74ab060>
```

20.9.2 Fleiss K

```
>>> from statsmodels.stats.inter_rater import fleiss_kappa
>>> fleiss_kappa
<function fleiss_kappa at 0x7faff74aaca0>
```

20.9.3 Lin coefficient

```
>>> from statsmodels.stats.inter_rater import fleiss_kappa
>>> fleiss_kappa
<function fleiss_kappa at 0x7faff74aaca0>
```

20.10 Reliability/consistency

20.10.1 Cronbach α

```
>>> pg.cronbach_alpha
<function cronbach_alpha at 0x7faff74a9b20>
```

20.10.2 ICC

```
>>> pg.intraclass_corr
<function intraclass_corr at 0x7faff74a9bc0>
```

20.11 Multiplicity

```
scipy.stats.tukey_hsd
scikit_posthocs.posthoc_dunn
```

```
statsmodels.stats.multitest.multipletests
scipy.stats.false_discovery_control
```

```
pg.multicomp
pg.pairwise_gameshowell
pg.pairwise_tukey
pg.pairwise_tests
pg.pairwise_corr
pg.ptests
```

20.12 Test simulativi

Importiamo le librerie qui usate

```
>>> from scipy import stats

>>> stats.bootstrap
<function bootstrap at 0x7fb039fe3880>
>>> stats.permutation_test
<function permutation_test at 0x7fb03a00c9a0>
>>> stats.monte_carlo_test
<function monte_carlo_test at 0x7fb039fe3b00>
```

Capitolo 21

Integrazione con R

Contents

21.1 Interscambio dataset	299
21.1.1 Da R a Python	299
21.1.2 Da Python a R	300
21.2 Chiamare R da Python: rpy2	300
21.2.1 Importazione di pacchetti	300
21.2.2 Ottenimento di dati con rpy2	300
21.2.3 Valutare stringhe di R	301
21.2.4 Creazione di vettori	301
21.2.5 Conversione <code>DataFrame</code> a R	301
21.2.6 Utilizzo di funzioni	302

21.1 Interscambio dataset

21.1.1 Da R a Python

In generale, per esportare un dataset di R verso Python, importare il dataset in R e usare `lbmisc::pddf`.

Alternativamente, per importare direttamente un dataset R noto in Python si possono importare usare i pacchetti `rdatasets` o `statsmodels`, entrambi usano

```
>>> import statsmodels.api as sm
>>> airquality = sm.datasets.get_rdataset("airquality", "datasets")
>>> df = airquality.data
>>> df
```

	Ozone	Solar.R	Wind	Temp	Month	Day
0	41.0	190.0	7.4	67	5	1
1	36.0	118.0	8.0	72	5	2
2	12.0	149.0	12.6	74	5	3
3	18.0	313.0	11.5	62	5	4
4	NaN	NaN	14.3	56	5	5
..	...	...	...	...	...	...
148	30.0	193.0	6.9	70	9	26

```

149   NaN      145.0  13.2    77      9    27
150  14.0      191.0  14.3    75      9    28
151  18.0      131.0   8.0    76      9    29
152  20.0      223.0  11.5    68      9    30

```

```

[153 rows x 6 columns]
>>> # print(airquality.__doc__)

```

21.1.2 Da Python a R

Utilizzare `pylbmisc.io.rdf`.

21.2 Chiamare R da Python: rpy2

Si installa

```
pip install --user rpy2
```

Quattro moduli principali:

- `rpy2.objects`: high-level interface. basato su `rpy2.rinterface`
- `rpy2.interactive`: high-level interface basata su `rpy2.objects` per l'uso interattivo
- `rpy2.rlike`: funzioni e dati in python che mimano funzionalità di R
- `rpy2.rinterface`: interfaccia di basso livello

Il modulo che ci interessa di più è `objects`, effettuiamo le seguenti importazioni:

```

>>> import rpy2.objects as ro                # tutto il resto ..

>>> from rpy2.objects import pandas2ri      # traduzione data.frame
>>> from rpy2.objects.packages import importr # importazione pacchetti
>>> from rpy2.objects.packages import data   # importazione dati

```

21.2.1 Importazione di pacchetti

```

>>> base = importr('base')
>>> utils = importr('utils')
>>> stats = importr('stats')
>>> lme4 = importr("lme4")

```

21.2.2 Ottenimento di dati con rpy2

Per ottenere `lme4::sleepstudy`

```

>>> sleepstudy = data(lme4).fetch('sleepstudy')['sleepstudy']
>>> print(utils.head(sleepstudy))
      Reaction Days Subject
1      249.6     0      308

```

2	258.7	1	308
3	250.8	2	308
4	321.4	3	308
5	356.9	4	308
6	414.7	5	308

È ancora in formato R, per avere un `DataFrame` pandas se lo vogliamo analizzare in python tocca fare sta roba

```
>>> with (ro.default_converter + pandas2ri.converter).context():
...     df = ro.conversion.get_conversion().rpy2py(sleepstudy)
...
>>> df.head()
   Reaction  Days Subject
1  249.5600  0.0     308
2  258.7047  1.0     308
3  250.8006  2.0     308
4  321.4398  3.0     308
5  356.8519  4.0     308
```

21.2.3 Valutare stringhe di R

rpy2 esegue R, per accedere al namespace si usa `rpy2.robjests.r`.

```
>>> pi = ro.r['pi']
>>> pi[0]
3.141592653589793

>>> # possiamo scrivere anche codice più complesso
>>> res = ro.r("""
... set.seed(123)
... f <- function(x) mean(rnorm(x))
... f(10)
... """)
>>> res[0]
0.0746256440971619
```

21.2.4 Creazione di vettori

```
>>> ints = ro.IntVector([2, 1, 3])
>>> print(ints)
[1] 2 1 3

>>> floats = ro.FloatVector([1.1, 2.2, 3.3])
```

21.2.5 Conversione DataFrame a R

Se vogliamo applicare funzioni di R questo è il modo di procedere; si usa `rpy2.robjests.pandas2ri` con sintassi speculare a quanto già visto (si usa `py2rpy` invece di `rpy2py`):

```
>>> import pandas as pd
```

```
>>> df = pd.DataFrame({'int1': [1,2,3], 'int2': [4, 5, 6]})

>>> with (ro.default_converter + pandas2ri.converter).context():
...     r_df = ro.conversion.get_conversion().py2rpy(df)
...
```

21.2.6 Utilizzo di funzioni

```
>>> # applicazione di una funzione
>>> res1 = base.sort(ints)
>>> print(res1)
[1] 1 2 3

>>> # funzione con parametri
>>> res2 = base.sort(floats, decreasing=True)
>>> print(res2)
[1] 3.3 2.2 1.1

>>> # utilizzare funzioni r su un dataframe R (ottenuto sopra)
>>> print(base.summary(r_df))
      int1      int2
Min.    :1.0   Min.    :4.0
1st Qu.:1.5   1st Qu.:4.5
Median :2.0   Median :5.0
Mean    :2.0   Mean    :5.0
3rd Qu.:2.5   3rd Qu.:5.5
Max.    :3.0   Max.    :6.0

>>> # svolgimento di una analisi
>>> lm1 = stats.lm('Reaction ~ Days', data = sleepstudy)
>>> # print(base.summary(lm1)) #verbose output
>>> fm1 = lme4.lmer('Reaction ~ Days + (Days | Subject)', data = sleepstudy)
>>> # print(base.summary(fm1)) #verbose output
```

Capitolo 22

Misc cookbook

Contents

22.1 Validazione DataFrame con pandera	303
22.2 SymPy	305
22.3 Esecuzione parallela	305
22.4 Calendario	306
22.5 Tcl/Tk	307
22.6 Telegram	307

22.1 Validazione DataFrame con pandera

`pandera` permette di definire descrizioni del dataset che vogliamo avere e validare quello che effettivamente abbiamo. Vi sono due api attualmente, una classica e una più simile a `dataclass/pydantic`. Usiamo questa seconda.

```
>>> import pandera as pa
```

Iniziamo con un dataset di esempio dove è necessario fare preprocessing e validare

```
>>> # Uno schema più evoluto su dati più real-life
>>> df = pd.DataFrame({
...     "idx" : [1,2,3,4,5,6],
...     "adate": ["2020-01-02", "2021-01-01", "2022-01-02"] * 2,
...     "state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...     "ohio" : [1, 1, 1, 0, 0, 0],
...     "year": [str(y) for y in [2000, 2001, 2002, 2001, 2002, 2003]],
...     "pop": [str(p) for p in [1.5, 1.7, 3.6, np.nan, 2.9, 3.2]]
... })
```

Definiamo una classe che descrive le caratteristiche

```
>>> # meglio usare i tipi di dato builtin
>>> class Model(pa.DataFrameModel):
...     idx: int = pa.Field(unique=True)
...     adate: pd.DatetimeTZDtype = pa.Field(dtype_kwargs={
```

```

...         "unit": "s",
...         "tz": "UTC"
...     })
...     state: pd.CategoricalDtype = pa.Field(dtype_kwargs={
...         "categories": ["Ohio", "Nevada"],
...         "ordered": False
...     })
...     ohio: bool = pa.Field()
...     year: int = pa.Field(ge=2000, le=2005)
...     pop: float = pa.Field(ge=0, nullable=True)
...     # configurazioni generali: nome Config obbligatorio
...     class Config:
...         coerce = True # coercizione al tipo specificato, prechecks
... 
```

Una volta fatto questo effettuiamo la validazione in un `try`; se va viene salvato in `out` il `DataFrame` valido, se non va in `errs` gli errori

```

>>> try:
...     out = Model.validate(df, lazy = True)
...     # print(out)
... except pa.errors.SchemaErrors as err:
...     errs = err.failure_cases # dataframe of schema errors
...     # print("Schema errors and failure cases:")
...     # print(errs.to_string())
...     # print("\nDataFrame object that failed validation:")
...     # print(err.data) # invalid dataframe
... 
```

Alcune considerazioni:

- purtroppo ad ora `nullable` (ossia accettare dati mancanti) deve essere specificato sempre (issue), al massimo si può usare il `partialling` con qualcosa del genere

```

>>> from functools import partial
>>> NullableField = partial(pa.Field, nullable=True)
>>> StdField = partial(pa.Field, coerce=True, nullable=True)

```

- sperimenti con interfaccia classica in `src/tests`
- per funzioni di check custom vedere la documentazione qui

Una procedura di importazione e cleaning La sequenza potrebbe essere:

- importare con qualsivoglia strumento (es `pd.read_csv`);
- coercire quanto di interesse per l'analisi con il metodo `transform` (eventualmente verificare qui l'introduzione di valori mancanti)
- validare quanto coercito mediante `pandera` eventualmente

22.2 SymPy

Integrazione `integrate` è utilizzato per integrali sia indefiniti che definiti

1. definire i simboli impiegati
2. definire l'espressione che ne fa uso
- 3.

```
from sympy import *
init_printing(use_unicode=False, wrap_line=False)
x = Symbol('x')
y = Symbol('y')

# indefinito
integrate(x**2 + x + 1, x)

# definito da 0 a +infinito
expr = exp(-x**2)
integrate(expr, (x, 0, oo) )

expr = (3 + x)/(12*6)
integrate(expr, (x, -3, 9) )

# definito usando due variabili
expr=exp(-x**2 - y**2)
integrate(expr, (x, 0, oo), (y, 0, oo))
```

22.3 Esecuzione parallela

Usiamo `multiprocessing`, che effettua una parallizzazione tipo quella di R a livello di processo e `Pool` che applica una funzione in maniera parallela cambiando il parametro di input.

```
from multiprocessing import Pool

import os
import numpy as np
import time

# a function with no particular setting (note how we don't have to
# define the imports which is automagically handled by the fork

def parallelized(s):
    """A test function which extract 500 random number from standard
    normal and calculates the mean.
    """
    rng = np.random.default_rng(seed = s)
    rv = rng.standard_normal(500) # random vector
    return {"pid" : os.getpid(),
            "seed": s,
```

```

        "mean" : rv.mean()}]

def main():
    start_t = time.perf_counter()
    # Pool can be used for parallel execution of a function across
    # multiple input values, distributing the input data across processes
    # data parallelism).
    rng_seeds = [1, 1, 3]
    with Pool() as p: # spawna 1 processo per core (usandoli tutti)
        # apply a function to different input, each in one separate process
        res = p.map(parallelized, rng_seeds)
    stop_t = time.perf_counter()

    os.getpid() # pid of the current process
    print(res)  # pid of working process are different
                # results are the same in the first two cases (same seed)
    print(f"Time elapsed {stop_t - start_t:.2f}")

main()

```

Per

- limitare il numero di processi da spawnare ad esempio fare Pool(5)
- i tre metodi principali che pool fornisce sono map, imap e imap_unordered

22.4 Calendario

calendar fornisce funzionalità del calendario (utile es per trovare l' x -esimo martedì del mese tal dei tali).

```

>>> import calendar
>>> import pprint
>>> from datetime import date

>>> # Stampare il calendario del mese scelto (es del mese corrente)
>>> oggi = date.today()
>>> c = calendar.TextCalendar()
>>> c.prmonth(oggi.year, oggi.month)
    giugno 2026
lu ma me gi ve sa do
 1  2  3  4  5  6  7
 8  9 10 11 12 13 14
15 16 17 18 19 20 21
22 23 24 25 26 27 28
29 30

>>> # ottenere numeri di giorni del mese come lista di liste (ogni lista è una settimana)
>>> m = calendar.monthcalendar(oggi.year, oggi.month)
>>> pprint.pprint(m)

```

```

[[1, 2, 3, 4, 5, 6, 7],
 [8, 9, 10, 11, 12, 13, 14],
 [15, 16, 17, 18, 19, 20, 21],
 [22, 23, 24, 25, 26, 27, 28],
 [29, 30, 0, 0, 0, 0, 0]]
>>> # la struttura di dati va per ogni settimana da lunedì a domenica
>>> # 0 vuol dire che il giorno non appartiene al mese, altrimenti il numero è
>>> # il progressi

>>> # stampa di tutti i sabato e domenica di un mese con numero di giorno
>>> for week in m:
...     sab = week[calendar.SATURDAY]
...     dom = week[calendar.SUNDAY]
...     if sab: # se è diverso da 0 vi è un sabato in quella settimana
...         print("sab", sab)
...     if dom: # questo dovrebbe essere sempre vero
...         print("dom", dom)
...
sab 6
dom 7
sab 13
dom 14
sab 20
dom 21
sab 27
dom 28

```

22.5 Tcl/Tk

```

from pathlib import Path
from tkinter.filedialog import askopenfilename

title = "Select the study protocol file to be imported"
initialdir = "/tmp"
filetypes = [("Formati", ".docx .doc .pdf")]
fpath = Path(
    askopenfilename(title=title, initialdir=initialdir, filetypes=filetypes)
)

```

22.6 Telegram

Un esempio di invio di messaggi di monitoraggio ai termini di un task (backup fatto mediante rsync)

```

import asyncio
import datetime as dt
import os
import telegram
from pylibmisc.tg import bot_token, user_id, group_id

```

```
# telegram message
async def send_message(start, end):
    diff = end - start
    msg = ""Backup completato. \n Inizio: {0} \n Termine: {1} \n Impiegati (min): {2}
        start.strftime("%d/%m/%Y - %H:%M:%S"),
        end.strftime("%d/%m/%Y - %H:%M:%S"),
        diff.total_seconds()/60
    )
    bot = telegram.Bot(bot_token("winston_lb_bot"))
    async with bot:
        await bot.send_message(text=msg, chat_id=user_id("lucailgarb"))

if __name__ == '__main__':
    os.system("mount usb_backup")
    start = dt.datetime.now()
    os.system("rsync -avru -L --delete doc_ricordi/ usb_backup/doc_ricordi/")
    os.system("umount usb_backup")
    end = dt.datetime.now()
    asyncio.run(send_message(start = start, end = end))
```