Python

17 agosto 2026

Indice

I Linguaggio **5**

1 Introduzione **7**
1.1 Esecuzione . . . 7
1.2 Ottenere aiuto . . . 9
1.3 Strutturazione del codice . . . 9
1.3.1 Moduli . . . 9
1.3.1.1 Nome e namespace . . . 9
1.3.1.2 Importazione dei moduli . . . 9
1.3.1.3 Path di ricerca dei moduli . . . 10
1.3.2 Pacchetti . . . 10
1.3.2.1 Struttura e `__init__.py` . . . 10
1.3.2.2 `__init__.py`, `__all__` e `import *` da pacchetto 12
1.4 Virtual environments e `uv` . . . 12
1.4.1 Inizializzazione di un progetto . . . 12
1.4.2 Contenuto directory root . . . 12
1.4.3 Shell nel virtual environment . . . 13
1.4.4 Esecuzione di cli e script . . . 13
1.4.4.1 Da dentro progetto . . . 13
1.4.4.2 Dall'esterno . . . 13
1.4.5 Aggiunta/rimozione dipendenze . . . 14

2 Dati **15**
2.1 Introduzione . . . 15
2.2 Tipi nativi . . . 16
2.3 Classificazione dei tipi di base . . . 16
2.4 Numeri . . . 17
2.5 Date e ore . . . 18
2.6 Sequenze: stringhe, liste e tuple . . . 18
2.6.1 Operatore di slice (selezione da sequenza) e indici . . . 18
2.6.2 Stringhe . . . 19
2.6.2.1 Stringhe valide . . . 19
2.6.2.2 Formattazione . . . 19
2.6.2.3 Elaborazioni varie . . . 19
2.6.2.4 Classe con formato . . . 19
2.6.3 Liste . . . 20
2.6.3.1 Definizione . . . 20
2.6.3.2 Manipolazione e modifica . . . 20
2.6.3.3 Metodi utili . . . 20

2.6.3.4 Liste nested 20
2.6.3.5 List comprehensions 20
2.6.4 Tuple 21
2.6.5 Sequence unpacking 21
2.7 Classi mapping e set 21
2.7.1 Dict 21
2.7.1.1 Dict comprehension 21
2.7.2 Sets 21
2.7.2.1 Operatori/metodi utili 21
2.7.2.2 Set comprehension 22
2.8 Altri tipi utili 22
2.8.1 `namedtuple` 22
2.8.2 `Counter` 22
2.8.3 Enum & Flag 22
2.8.3.1 Enum 22
2.8.3.2 Flag 22
2.9 Type annotation 23
2.9.1 Sintassi 23
2.9.2 Checking 23
2.9.3 Tipi utilizzabili per variabili 23
2.9.4 Creazione di alias 23
2.9.5 Annotazione di funzioni 24
2.9.6 Annotazione di metodi in classi 24

3 Controllo del flusso **25**
3.1 Costrutti condizionali: `if` e `while` 25
3.1.1 `if` 25
3.1.2 `match` 25
3.1.3 `while` 25
3.1.4 `break`, `continue` ed `else` 25
3.2 Condizioni e test logici 26
3.2.1 Test verità 26
3.2.2 Operatori booleani 26
3.2.3 Comparazioni 26
3.2.4 Comparazioni concatenate 27
3.2.5 Check appartenenza: `in` e `not in` 27
3.2.6 Comparare sequenze e altri tipi 27
3.3 Looping su oggetti: `for` 28
3.3.1 Looping in sequenze (stringhe, liste, tuple) 28
3.3.2 Looping nei dict 28
3.3.3 Looping sui set 28
3.3.4 L'utilizzo di `range` 28

4 Funzioni **29**
4.1 Definizione 29
4.2 Chiamata 30
4.2.1 Valutazione dei valori di default 30
4.2.2 Valore ritornato 30
4.2.3 Unpacking di liste/tuple/dict in chiamata 30
4.3 Regole di scope 30

4.3.1 Namespace 31
4.3.2 Attributi 31
4.3.3 Scoping 31
4.4 Funzioni anonime (`lambda`) 32
4.5 Programmazione funzionale 32
4.5.1 Funzioni classiche 32
4.5.1.1 `map` (= `Map`/`lappy`) 32
4.5.1.2 `itertools.starmap` 33
4.5.1.3 `functools.reduce` 33
4.5.1.4 `itertools.accumulate` 33
4.5.1.5 `filter` 33
4.5.2 Partialling 33
4.5.2.1 `functools.partial` 33
4.5.2.2 `functools.partialmethod` 33
4.5.3 Function factory 34
4.5.4 Composizione di funzioni 34
4.5.5 Decorators 34
4.5.5.1 Definizione e utilizzo 34
4.5.5.2 Esempi semplici 34
4.5.5.3 Decorator con parametri 35
4.5.5.4 Decoratori già disponibili 35
4.5.6 Single e multiple dispatch 35
4.5.6.1 Single dispatch (function overloading) 35
4.5.6.2 Multiple dispatch 35
4.6 Altri argomenti 36
4.6.1 `atexit` 36

5 Input/Output **37**
5.1 Accesso al filesystem 37
5.1.1 Ottenere/cambiare directory di lavoro 37
5.1.2 Listing di directory, glob files 37
5.1.3 Creazione/rimozione di file/directory 37
5.1.4 File e directory temporanei 37
5.1.5 Paths e metodi utili 37
5.2 Salvataggio/importazione file 37
5.2.1 Testo semplice 37
5.2.1.1 Lettura 38
5.2.1.2 Scrittura 38
5.2.2 `csv`/`tsv` 38
5.2.2.1 Lettura 38
5.2.2.2 Scrittura 38
5.2.3 JSON 38
5.2.3.1 Scrittura 39
5.2.3.2 Lettura 39
5.2.3.3 Formati custom 39
5.2.4 pickle 39
5.3 File di configurazione 39
5.4 Esecuzione di programmi esterni 40
5.4.1 `run` 40
5.4.2 `Popen` 40

5.5 Parsing opzioni da linea di comando . . . 41
5.5.1 `sys.argc` e `sys.argv` . . . 41
5.5.2 Modulo `argparse` . . . 41
5.6 Accesso variabili d'ambiente . . . 42

6 Object Oriented Programming 43
6.1 Classi . . . 43
6.1.1 Definizione e scoping . . . 43
6.1.2 Metodi . . . 44
6.1.2.1 Definizione e chiamata . . . 44
6.1.2.2 Costruttore custom . . . 44
6.1.3 Condivisione dati . . . 44
6.1.4 Data hiding . . . 44
6.2 Ereditarietà . . . 45
6.2.1 Singola . . . 45
6.2.2 Multipla . . . 45
6.3 Classi notevoli . . . 45
6.3.1 `dataclass` . . . 45
6.3.1.1 `field`: dati mutabili, valori default, parametri . 45
6.3.1.2 Eseguire codice post inizializzazione: `post_init` 46
6.3.1.3 Freezing di una dataclass . . . 46
6.3.1.4 Altri parametri utili del decoratore . . . 46
6.3.2 Iteratori . . . 46
6.3.2.1 Funzionamento . . . 46
6.3.2.2 Implementazione mediante classe . . . 47
6.3.2.3 Implementazione mediante espressioni generatrici 47
6.3.2.4 Implementazione mediante generatori . . . 47
6.3.2.5 Funzioni e operatori utili su iteratori . . . 48
6.3.2.6 Il modulo itertools . . . 48
6.3.3 Context Managers . . . 49
6.3.3.1 Implementazione mediante classe . . . 49
6.3.3.2 Implementazione mediante generatore . . . 50

7 Eccezioni 51
7.1 Gestire eccezioni . . . 51
7.1.1 Sintassi minimale: `try except` . . . 51
7.1.2 `else` . . . 52
7.1.3 `finally` . . . 52
7.2 Sollevare eccezioni . . . 52
7.3 Creare eccezioni custom . . . 54
7.4 Sollevare warnings senza stoppare l'esecuzione . . . 54

8 Devtools 55
8.1 Debugging . . . 55
8.2 Testing . . . 57
8.2.1 Introduzione . . . 57
8.2.1.1 Gergo . . . 57
8.2.1.2 Tipologie di testing . . . 57
8.2.1.3 Good testing practice . . . 57
8.2.1.4 Fasi di un test . . . 58

8.2.2 `pytest` . . . 58
8.2.2.1 Setup . . . 58
8.2.2.2 Esecuzione dei test . . . 58
8.2.2.3 Contenuto file di test . . . 59
8.2.2.4 Fixture . . . 59
8.2.2.5 Marking di test . . . 60
8.2.2.6 Esecuzione condizionale di test . . . 60
8.2.2.7 Failure accettate/expected . . . 60
8.2.2.8 Parametrizzazione . . . 61
8.2.3 Testing con dati/input randomici . . . 61
8.2.4 Doctest . . . 61
8.2.4.1 Skippare test . . . 62
8.2.4.2 Normalizzare spazi bianchi . . . 62
8.2.5 `unittest` . . . 62
8.3 Linting/formattazione (`ruff`) . . . 62
8.3.1 Linting . . . 62
8.3.2 Formattazione . . . 63
8.4 Type checking (`ty`) . . . 63
8.5 Timing/temporizzazione . . . 63
8.6 Profiling . . . 63
8.7 Scrittura di plugin . . . 64
8.8 Documentazione . . . 65
8.8.1 Setup . . . 65
8.8.2 Doc-writing e reStructuredText . . . 65
8.8.3 Building . . . 65
8.8.4 Setup di readthedocs . . . 66

II Scientific Stack 67

9 Numpy 69
9.1 L'`ndarray` . . . 69
9.1.1 Creazione e copia . . . 69
9.1.2 Tipi (`dtype`): coercizione e testing . . . 69
9.1.3 Forma, dimensioni e reshape . . . 70
9.1.3.1 Forma e dimensioni . . . 70
9.1.3.2 Reshaping . . . 70
9.1.3.3 Ravelling/flattening . . . 71
9.2 Indexing . . . 71
9.2.1 Array unidimensionali . . . 71
9.2.2 Array multidimensionali . . . 71
9.2.3 Subarray come viste vs copie . . . 72
9.2.4 Assegnazione e unicità degli indici . . . 72
9.3 Elaborazioni di array . . . 72
9.3.1 Inserimento/rimozione elementi (`insert`, `delete`) . . . 72
9.3.2 Aritmetica vettorizzata . . . 72
9.3.3 Operazioni insiemistiche . . . 72
9.3.4 Concatenazione (`concatenate`, `vstack`, `hstack`) . . . 72
9.3.5 Splitting (`split`, `vsplit`, `hsplit`) . . . 73
9.3.6 Ripetizione/binding (`repeat`, `tile`) . . . 73

9.3.7 Sorting/ordine (`sort`, `argsort`) . . . 73
9.4 Universal functions . . . 73
9.4.1 Introduzione . . . 73
9.4.2 Metodi delle ufunction (`reduce`, `accumulate`, `outer`) . . . 74
9.4.3 Creazione di ufunctions . . . 75
9.5 Broadcasting . . . 75
9.6 Altri argomenti . . . 77
9.6.1 Lavorare con booleani . . . 77
9.6.2 Array di stringhe . . . 77

10 Pandas **79**
10.1 Data I/O . . . 79
10.1.1 Importazione dati . . . 79
10.1.2 Importazione con dati mancanti . . . 79
10.1.3 Esportazione . . . 79
10.2 `Series` . . . 79
10.2.1 Creazione . . . 80
10.2.2 Contenuto (`array`, `index`, `name`, `dtype`) . . . 80
10.2.3 Indexing e selezione . . . 80
10.2.3.1 Utilizzo di `[]` . . . 80
10.2.3.2 `.iloc` . . . 80
10.2.3.3 `.loc` . . . 80
10.2.3.4 Altri metodi di selezione (`.filter`, `.reindex`) . 80
10.2.4 Modifica valori . . . 80
10.2.5 Funzionalità per indici (`reset_index`, `rename`) . . . 80
10.2.6 Rimozione elementi (selezione, `drop`, `del`) . . . 81
10.2.7 Elaborazione vettorizzata . . . 81
10.2.8 Elaborazione allineata . . . 81
10.2.9 Coercizione di tipo (`astype`) . . . 81
10.2.10 Valori condizionali a-la `ifelse` (`.where`) . . . 81
10.2.11 Applicazione di una funzione (`map`) . . . 81
10.2.12 Applicazione di più funzioni (`.agg`) . . . 81
10.2.13 Sostituzione (`replace`) o recode (`map`) . . . 82
10.2.14 Test di appartenenza (`in`, `isin`) . . . 82
10.2.15 Dati mancanti . . . 82
10.2.16 Duplicati . . . 82
10.2.17 Sorting . . . 82
10.2.18 Discretizzazione/creazione di classi (`cut`, `qcut`) . . . 82
10.2.19 Dummy variables . . . 82
10.2.19.1 Utilizzo base (`get_dummies`) . . . 82
10.2.19.2 Variabili a risposta multipla (`str.get_dummies`) 82
10.2.20 Stringhe . . . 83
10.2.20.1 Paste . . . 83
10.2.20.2 Collapse . . . 83
10.2.20.3 Formattazione varia . . . 83
10.2.20.4 Lunghezza ed sottostringhe . . . 83
10.2.20.5 Splitting . . . 83
10.2.20.6 Ricerca/rimpiazzo . . . 83
10.2.21 Date/ore . . . 83
10.2.21.1 Parsing da stringa . . . 83

10.2.21.2 Creazione da componenti 83
10.2.21.3 Estrazione componenti 83
10.2.21.4 Esportazione a stringa 84
10.2.21.5 Conversione di tipo/arrotondamenti 84
10.2.21.6 Intervalli di tempo 84
10.2.22 Dati categorici (`Categorical`) 84
10.2.23 Indexing gerarchico e reshape 84
10.2.23.1 Definizione 84
10.2.23.2 Indexing 85
10.2.23.3 Reshape 85
10.3 `DataFrame` 85
10.3.1 Creazione 85
10.3.2 Contenuto (`info`, `shape`, `index`, `columns`, `values`, `name`) 85
10.3.3 Selezione 85
10.3.3.1 Uso di `[]` 85
10.3.3.2 Uso di `.loc` e `.iloc` 86
10.3.3.3 `query` per selezione righe 86
10.3.3.4 Selezione di colonne sulla base di tipo 87
10.3.3.5 Accesso a singoli numeri: `.at`, `.iat` 87
10.3.4 Modifica valori 87
10.3.5 Aggiunta di colonne 87
10.3.5.1 Assegnazione 87
10.3.5.2 Uso di `insert` 87
10.3.5.3 Uso di `assign` 88
10.3.6 Rimozione righe/colonne (`drop`, `del`) 88
10.3.7 Rinominare colonne/indici (`rename`) 88
10.3.8 Gestione indici 88
10.3.8.1 Creazione indici da colonne 88
10.3.8.2 Reset indici 88
10.3.8.3 `MultiIndex` 89
10.3.9 Elaborazione allineata 89
10.3.10 Coercizione di tipi (`astype`) 89
10.3.11 Applicazione di funzioni 89
10.3.11.1 A molteplici righe/colonne (`apply`/`agg`) 89
10.3.11.2 A ciascun elemento del `DataFrame` (`map`) 89
10.3.11.3 All'intero dataframe (`pipe`) 89
10.3.12 Ciclo su righe/colonne 90
10.3.12.1 Righe 90
10.3.12.2 Colonne 90
10.3.13 Merge 90
10.3.13.1 Due dataframe 90
10.3.13.2 Molteplici dataframe 91
10.3.14 Binding (`pd.concat`) 91
10.3.14.1 Di riga 91
10.3.14.2 Di colonna 91
10.3.15 Reshape 91
10.3.15.1 Uso di `lb.r.reshape` 91
10.3.15.2 Porre in long (`melt`) 91
10.3.15.3 Porre in wide (`pivot`) 91
10.3.16 Test di appartenenza (`in`, `isin`) 92

10.3.17 Dati mancanti . . . 92
10.3.17.1 Identificazione . . . 92
10.3.17.2 Rimozione . . . 92
10.3.17.3 Imputazione . . . 92
10.3.18 Duplicati . . . 92
10.3.18.1 Identificazione (`duplicated`) . . . 92
10.3.18.2 Rimozione (`drop_duplicates`) . . . 92
10.3.18.3 Indici duplicati . . . 93
10.3.19 Sorting . . . 93
10.3.19.1 Su valori (`sort_values`) . . . 93
10.3.19.2 Su indici (`csort_index`) . . . 93
10.4 Descrittive . . . 93
10.4.1 Info generali . . . 93
10.4.2 Univariate . . . 93
10.4.2.1 Statistiche varie . . . 93
10.4.3 Bivariate . . . 94
10.4.3.1 Tabelle di contingenza . . . 94
10.4.3.2 Covarianza e correlazione . . . 94
10.4.3.3 Tabelle pivot . . . 94
10.4.3.4 Tabella trial . . . 94
10.4.3.5 Stratificate . . . 94
10.5 Cookbook . . . 96
10.5.1 Stampa tutto il contenuto di un DataFrame . . . 96
10.5.2 Old stuff . . . 97
10.5.2.1 Reindexing (`reindex`, `loc`) . . . 97
10.5.2.2 Applicare diverse funzioni a diversi elementi . . . 97
10.5.2.3 Reshape sulla base di indici (`stack`,`unstack`) . . . 97

11 Polars **99**
11.1 Introduzione . . . 99
11.1.1 Tipi di dati . . . 99
11.1.2 Espressioni e contesti . . . 100
11.1.3 Expression expansion e selettori . . . 100
11.2 Data I/O . . . 101
11.2.1 Importazione dati . . . 101
11.2.1.1 Da file . . . 101
11.2.1.2 Da pandas . . . 101
11.2.2 Esportazione dati . . . 101
11.2.2.1 Su file . . . 101
11.2.2.2 Verso pandas . . . 101
11.3 `Series` . . . 101
11.3.1 Creazione . . . 101
11.3.2 Attributi . . . 101
11.3.3 Indexing e selezione . . . 102
11.3.4 Elaborazione vettorizzata . . . 102
11.3.5 Coercizione di tipo (`cast`) . . . 102
11.3.6 Valori condizionali a-la `ifelse` (`pl.when`) . . . 102
11.3.7 Applicazione di una funzione a tutti gli elementi (`map`) . . . 102
11.3.8 Sostituzione di valori (`replace`) . . . 102
11.3.9 Test di appartenenza (`in`, `isin`) . . . 102

11.3.10 Dati mancanti . . . 102
11.3.11 Duplicati . . . 102
11.3.12 Sorting . . . 103
11.3.13 Discretizzazione/creazione di classi (`cut`, `qcut`) . . . 103
11.3.14 Dummy variables . . . 103
11.3.14.1 Utilizzo base (`get_dummies`) . . . 103
11.3.14.2 Variabili a risposta multipla . . . 103
11.3.15 Stringhe . . . 103
11.3.15.1 Paste . . . 103
11.3.15.2 Collapse . . . 103
11.3.15.3 Formattazione varia . . . 103
11.3.15.4 Lunghezza ed sottostringhe . . . 103
11.3.15.5 Splitting . . . 104
11.3.15.6 Ricerca/rimpiazzo . . . 104
11.3.15.7 Estrazione . . . 104
11.3.16 Date/ore . . . 104
11.3.16.1 Parsing da stringa . . . 104
11.3.16.2 Creazione da componenti . . . 104
11.3.16.3 Estrazione componenti . . . 104
11.3.16.4 Esportazione a stringa . . . 104
11.3.16.5 Intervalli di tempo . . . 104
11.3.17 Dati categorici (`Enum` e `Categorical`) . . . 104
11.3.18 Liste, array, structs . . . 105
11.3.18.1 Liste . . . 105
11.3.18.2 Array . . . 105
11.3.18.3 Structs . . . 106
11.4 `DataFrame` . . . 106
11.4.1 Creazione . . . 106
11.4.2 Contenuto . . . 106
11.4.3 Copia di df e di struttura (`clone`, `clear`) . . . 106
11.4.4 Selezione . . . 107
11.4.4.1 Colonne (`.select`) . . . 107
11.4.4.2 Righe (`.filter`/`.remove`) . . . 107
11.4.4.3 Righe e colonne . . . 107
11.4.4.4 Singoli elementi (`.item`) . . . 107
11.4.5 Inserimento colonna in un punto (`.insert_column`) . . . 107
11.4.6 Assegnazione (`with_columns`) . . . 107
11.4.6.1 Elaborazioni particolari . . . 108
11.4.7 Rimozione righe/colonne (`.filter`/`.drop`) . . . 108
11.4.8 Rinominare colonne . . . 108
11.4.9 Coercizione di tipi (`.cast`) . . . 108
11.4.10 Applicazione di funzioni . . . 108
11.4.10.1 All'intero dataframe . . . 108
11.4.10.2 A colonne . . . 108
11.4.10.3 A righe . . . 109
11.4.11 Ciclo su righe/colonne . . . 109
11.4.11.1 Righe . . . 109
11.4.11.2 Colonne . . . 109
11.4.12 Merge (`.join`) . . . 109
11.4.12.1 Due dataframe . . . 109

11.4.12.2 Molteplici dataframe . . . 110
11.4.12.3 Merge approssimato (`.join_asof`) . . . 110
11.4.13 Binding (`pl.concat`) . . . 110
11.4.14 Reshape . . . 110
11.4.14.1 Porre in long (`.unpivot`) . . . 110
11.4.14.2 Porre in wide (`.pivot`) . . . 110
11.4.15 Trasporre (`.transpose`) . . . 110
11.4.16 Test di appartenenza (`in`) . . . 111
11.4.17 Dati mancanti . . . 111
11.4.17.1 Identificazione . . . 111
11.4.17.2 Rimozione . . . 111
11.4.17.3 Imputazione . . . 111
11.4.18 Duplicati . . . 111
11.4.18.1 Identificazione (`.duplicated`) . . . 111
11.4.18.2 Rimozione (`.unique`) . . . 111
11.4.19 Sorting . . . 111
11.4.20 Id univoco di riga . . . 112
11.4.21 Windows functions . . . 112
11.4.22 folds (elaborazioni orizzontali) . . . 112
11.5 Descrittive . . . 112
11.5.1 Univariate . . . 113
11.5.2 Bivariate . . . 113
11.5.2.1 Tabelle di contingenza . . . 113
11.5.2.2 Covarianza e correlazione . . . 113
11.5.2.3 Tabelle pivot . . . 113
11.5.2.4 Stratificate . . . 113

12 Matplotlib **117**
12.1 Introduzione . . . 117
12.2 Salvataggio figura . . . 117
12.3 Impostazione layout figura ed esempi . . . 119
12.3.1 Layout standard . . . 119
12.3.2 Layout custom . . . 119
12.4 Fine tuning . . . 120
12.4.1 Ticks e subticks . . . 120
12.4.2 Spines e grid . . . 120
12.4.3 Gestire la sovrapposizione di elementi diversi (`zorder`) . . . 121
12.4.4 Legenda . . . 121
12.4.5 Plot con doppio asse delle y . . . 121
12.4.6 Padding dei subplots (spazio bianco bordi) . . . 121
12.5 Configurazioni . . . 122
12.5.1 Ottenimento e modifica . . . 122
12.5.2 Ripristino impostazioni default . . . 122
12.5.3 Cambiare stile . . . 122
12.6 Grafici utili . . . 122
12.6.1 Linee . . . 123
12.6.2 Diagramma a barre . . . 123
12.6.3 Istogramma . . . 123
12.6.4 Scatterplot . . . 123
12.6.5 Matrice di scatterplot . . . 123

12.6.6 Boxplot 123
12.6.7 Correlation matrix 123

III Cookbook 125

13 Espressioni regolari 127

14 Logging 129
14.1 Uso del logger di default 129
14.1.1 Setup 129
14.2 Logger custom 130
14.2.1 Setup degli handler 130
14.2.2 Impostare la formattazione di un handler 130
14.2.3 impostare livello di log generale e di un handler 131
14.2.4 Filtrare log 131

15 Algebra lineare 133
15.1 Vettori, matrici e dimensioni 133
15.1.1 Creazione 133
15.1.2 Funzioni utilità per creazione 133
15.2 Operazioni 133
15.2.1 Somma 133
15.2.2 Trasposizione 133
15.2.3 Prodotti 134
15.3 Misc 134

16 Probabilità e simulazione 135
16.1 Funzionalità native 135
16.1.1 Combinatoria 135
16.1.2 Numeri casuali (`random`) 135
16.2 Numeri casuali (`numpy`) 135
16.2.1 Creazione del generatore 136
16.3 Variabili casuali (`scipy.stats`) 136
16.3.1 Funzioni e parametri principali 136
16.3.2 Uso interattivo rapido 138
16.3.3 Freezing di una distribuzione 138
16.3.4 Uso del generatore di `numpy` 138
16.4 Altri argomenti 138
16.4.1 Bootstrap CI 138

17 Test statistici 139
17.1 Setup 139
17.2 Medie 139
17.2.1 Test t: 1 gruppo vs valore teorico 139
17.2.2 Test t: 2 gruppi indipendenti 139
17.2.3 Anova (2+ gruppi indipendenti) 139
17.2.4 Test t: 2 gruppi appaiati 139
17.2.5 Anova per misure ripetute (2+ gruppi appaiati) 139
17.3 Non parametric 139

17.3.1 Wilcoxon . . . 139
17.3.2 Mann Whitney . . . 139
17.3.3 Kruskal Wallis . . . 140
17.3.4 Friedman test . . . 140
17.4 Proporzioni . . . 140
17.4.1 Test binomiale e CI clopper pearson . . . 140
17.4.2 Test di Fisher . . . 140
17.4.3 Chisquare . . . 140
17.4.4 McNemar . . . 140
17.4.5 Q di Cochrane . . . 140
17.5 Tassi . . . 140
17.5.1 Comparazione 2 tassi . . . 140
17.6 Correlazione . . . 140
17.6.1 Pearson . . . 140
17.6.2 Spearman . . . 140
17.6.3 Tests . . . 141
17.7 Varianze . . . 141
17.7.1 Test di Bartlett . . . 141
17.7.2 Test di Levene . . . 141
17.7.3 Test di Fligner . . . 141
17.8 Sopravvivenza . . . 141
17.8.1 Logrank test . . . 141
17.9 Agreement . . . 141
17.9.1 Cohen's K . . . 141
17.9.2 Fleiss K . . . 141
17.9.3 Lin coefficient . . . 141
17.10 Reliability/consistency . . . 142
17.10.1 Cronbach α . . . 142
17.10.2 ICC . . . 142
17.11 Multiplicity . . . 142
17.12 Test simulativi . . . 142

18 Integrazione con R **143**
18.1 Interscambio dataset . . . 143
18.1.1 Da R a Python . . . 143
18.1.2 Da Python a R . . . 143
18.2 Chiamare R da Python: `rpy2` . . . 143
18.2.1 Importazione di pacchetti . . . 143
18.2.2 Ottenimento di dati con rpy2 . . . 144
18.2.3 Valutare stringhe di R . . . 144
18.2.4 Creazione di vettori . . . 144
18.2.5 Conversione `DataFrame` a R . . . 144
18.2.6 Utilizzo di funzioni . . . 144

19 Misc cookbook **145**
19.1 Tabella trial . . . 145
19.2 Validazione `DataFrame` con `pandera` . . . 145
19.3 SymPy . . . 145
19.4 Esecuzione parallela . . . 146
19.5 Calendario . . . 146

19.6 Tcl/Tk 146
19.7 Telegram 146

Parte I

Linguaggio

Capitolo 1

Introduzione

Contents

1.1 Esecuzione 7
1.2 Ottenere aiuto 9
1.3 Strutturazione del codice 9
1.3.1 Moduli 9
1.3.2 Pacchetti 10
1.4 Virtual environments e `uv` 12
1.4.1 Inizializzazione di un progetto 12
1.4.2 Contenuto directory root 12
1.4.3 Shell nel virtual environment 13
1.4.4 Esecuzione di cli e script 13
1.4.5 Aggiunta/rimozione dipendenze 14

1.1 Esecuzione

Vi sono due modi per utilizzare l'interprete classico:

- in via batch, alternativamente:
  - creando un file con estensione `.py`, che contenga istruzioni python valide a seconda della versione, ed eseguendolo attraverso `python file.py`
  - creando un file senza estensione con le seguenti sha-bang, dargli i permessi di esecuzione e porlo nel path degli eseguibili

    ```
    #!/usr/bin/env python
    #!/usr/bin/env python3
    ```

- in modalità interattiva:
  - entrando nell'interprete mediante `python` o `python3`
  - editando un file `.py` in Emacs, questi va in `python-mode`. Far partire un processo python in un buffer con `C-c C-p` e passando all'interprete i comandi descritti in tabella 1.1.

Sequenza	Comando	Descrizione
C-c C-r	python-shell-send-region	invia la regione selezionata
C-c C-e	python-shell-send-statement	manda la regione selezionata o lo statement della linea
C-c C-s	python-shell-send-string	invia una riga da specificare
C-c C-c	python-shell-send-buffer	invia tutto il buffer corrente
C-c C-l	python-shell-send-file	tipo `source` di bash
C-c <	python-indent-shift-left	indenta a sinistra
C-c >	python-indent-shift-right	indenta a destra
C-c C-d	python-describe-at-point	descrivi la cosa
C-c C-f	python-eldoc-at-point	??
C-c C-j	imenu	muoversi a definizioni
C-c C-v	python-check	usa qualche tester da impostare con python-check-command
C-c C-t c	python-skeleton-class	introduci una classe da template
C-c C-t d	python-skeleton-def	introduci una funzione da template
C-c C-t f	python-skeleton-for	introduci un for da template
C-c C-t i	python-skeleton-if	introduci un if da template
C-c C-t m	python-skeleton-import	introduci un import da template
C-c C-t t	python-skeleton-try	introduci un try da template
C-c C-t w	python-skeleton-while	introduci un while da template

Tabella 1.1: Comandi `python-mode` di emacs

1.2 Ottenere aiuto

`help` fa uso di docstring e si usa alternativamente come

```
help()        # help di sistema (moduli, keyword, simboli, topics)
help(oggetto) # help specifico di un oggetto - docstring
```

Si può accedere alla documentazione anche dalla shell mediante `pydoc`

```
pydoc nome  # equivale a help(nome) dall'interprete
```

1.3 Strutturazione del codice

Le definizioni:

modulo file `.py` che può definire classi, funzioni e variabili globali importabili da un altro modulo mediante `import`;

pacchetto una directory contenente moduli con scopi affini e un file `__init__.py` (eseguito se si fa l'import del pacchetto per configurazioni/inizializzazioni).

1.3.1 Moduli

1.3.1.1 Nome e namespace

Ogni modulo ha:

- un *nome*, contenuto nella variabile globale `__name__` che solitamente coincide con:
  - `"nomefile"` senza l'estensione `.py` se il modulo è importato mediante `import`
  - `"__main__"`, qualora il modulo sia eseguito come script attraverso `python nomefile.py`
- un *namespace*: ogni modulo ha il suo che viene utilizzato da tutte le funzioni definite in esso. Le funzioni di un modulo per riferirsi ad altri oggetti definiti nello stesso, possono evitare di precedere il nome del modulo all'oggetto richiesto.

La presenza di un nome del modulo fa sì che si possa eseguire codice a seconda che il modulo sia importato o eseguito come script. Ad esempio nel file `miomodulo.py` dopo tutte le definizioni possiamo dare

```
if __name__ == "__main__":
    checks()
```

in questo caso i `checks()` verranno eseguite solamente se eseguiamo il modulo mediante `python miomodulo.py` (altrimenti mediante `import` il nome del modulo è impostato a `miomodulo` e i `checks` non vengono eseguiti).

1.3.1.2 Importazione dei moduli

I moduli possono importare altri moduli per ottenerne funzionalità in due modi differenti per la gestione del namespace. Supponiamo di aver creato un file `mymodule.py` nella directory corrente che contiene la funzione `do_complicated_stuff` e la variabile `strange_var`. Possiamo comandare:

- `import mymodule <as abbreviazione>`

  Viene creato un oggetto-modulo chiamato `mymodule` che contiene quanto definite; per utilizzale

  ```
  mymodule.do_complicated_stuff()
  mymodule.strange_var
  ```

  Specificando l'abbreviazione si crea un alias per il `mymodule` (verosimilmente più piccola e veloce da diteggiare)

- `from mymodule import do_complicated_stuff <as abbrev>`
  `from mymodule import strange_var <as abbrev>`

  Si importano solamente la funzione (o la costante) ed è possibile riferirvisi in seguito con un più veloce `do_complicated_stuff` senza specificare il nome del modulo di provenienza.

- `from mymodule import *`

  Si importa tutto quello che è definito nel modulo (non è considerato buona pratica)

1.3.1.3 Path di ricerca dei moduli

Quando viene richiesta l'importazione di un modulo di nome `spam.py` mediante `import spam` (o simili), Python cerca nell'ordine:

1. nei moduli builtin distribuiti col linguaggio;
2. nella lista di directory specificate in `sys.path`, nell'ordine specificato:

   ```
   import sys
   sys.path
   ```

   La variabile contiene solitamente la directory corrente al primo posto (come stringa vuota), facendole assumere priorità tra quelle del `sys.path`. Se si desidera aggiungere una directory come prima si può usare

   ```
   sys.path.insert(0,'/path/to/mod_directory')
   ```

1.3.2 Pacchetti

1.3.2.1 Struttura e `__init__.py`

Al minimo, un pacchetto è una directory contenente un file `__init__.py` e i file `.py` che costituiscono i moduli.
I files `__init__.py` sono necessari per far si che Python tratti la directory come un pacchetto;

- nel caso più semplice (considerata best practice) può essere un file vuoto;
- alternativamente si possono eseguire inizializzazioni o impostare la variabile `__all__` di cui si parla in seguito

Struttura semplice Ad esempio, con una siffatta situazione:

```
mypackage/
|-- __init__.py
|-- module_a.py
+-- module_b.py
```

L'utilizzo (in uno script al di fuori della directory `mypackage`) può avvenire come:

```
import mypackage.module_a
```

Struttura con subpackages In situazioni più complesse si possono prevedere subpackage, ossia subdirectory con moduli affini e un `__init__.py` per ogni directory/subdirectory. Ad esempio per un pacchetto che gestisce l'audio (di nome `sound`):

```
sound/                          Top-level package
      __init__.py               Initialize the sound package
      formats/                  Subpackage for file format conversions
              __init__.py
              wavread.py
              wavwrite.py
              aiffread.py
              aiffwrite.py
              auread.py
              auwrite.py
              ...
      effects/                  Subpackage for sound effects
              __init__.py
              echo.py
              surround.py
              reverse.py
              ...
      filters/                  Subpackage for filters
              __init__.py
              equalizer.py
              vocoder.py
              karaoke.py
              ...
```

References da esterno L'importazione di funzionalità può essere avvenire con `import` o `from`:

- con `import` possiamo importare *pacchetti o moduli*. In `import a.b.c` ogni item tranne l'ultimo deve essere un pacchetto (directory con `__init__.py`); `c` può essere un pacchetto o un modulo

```
# modulo versione 1: con import è necessaria poi la full reference
import sound.effects.echo
sound.effects.echo.echofilter(input, output, delay=0.7, atten=4)

# (consigliabile usare as sinonimo)
```

- con `from` possiamo importare *moduli e funzioni*, controlla che l'oggetto sia definito nel pacchetto, se sì lo importa, se no ipotizza sia un modulo e lo cerca

```
# modulo vrs 2: con from si può usare la relative reference
from sound.effects import echo
echo.echofilter(input, output, delay=0.7, atten=4) # from allows relative ref

# funzione
from sound.effects.echo import echofilter
echofilter(input, output, delay=0.7, atten=4)
```

Intra-package references Quando i pacchetti sono strutturati in sottopacchetti si possono usare sia referenza assoluta che relativa. Ad esempio

- se `sound.filters.vocoder` necessita del modulo `sound.effects.echo` nelle sue prime linee si può usare alternativamente

```
from sound.effects import echo
from ..effects import echo
```

- se `sound.effects.surround` necessita `sound.effects.echo` `sound.formats` o `sound.filters.equalizer`

```
from . import echo
from .. import formats
from ..filters import equalizer
```

Gli import relativi si basano sul nome del modulo corrente: dato che il nome del modulo main è sempre `__main__`, i file `.py` (moduli) che debbono essere eseguiti come modulo main (script) debbono utilizare sempre import assoluti.

1.3.2.2 `__init__.py`, `__all__` e `import *` da pacchetto

Se in `sounds/effects/__init__.py` si imposta

```
__all__ = ["echo", "surround", "reverse"]
```

e si comanda

```
from sound.effects import *
```

verranno importati `echo.py`, `surround.py` e `reverse.py`.

1.4 Virtual environments e uv

I virtual environments fanno si che interprete Python e singoli pacchetti possano essere installati in un maniera isolata per una data applicazione/progetto. Il tool moderno per fare questo è uv.

1.4.1 Inizializzazione di un progetto

Dopo l'installazione di `uv` per la creazione di un progetto/environment isolato:

```
uv init --library mylib # solo libreria python
uv init --package mylib # libreria + script da commandline
```

Ad esempio la creazione di un pacchetto crea la seguente struttura

```
$ uv init --package mypkg
Initialized project `mypkg` at `/tmp/mypkg`

$ tree mypkg/
mypkg
|-- pyproject.toml
|-- README.md
`-- src
    `-- mypkg
        `-- __init__.py
```

1.4.2 Contenuto directory root

Dopo un utilizzo (es `uv run`) viene inizializzata la seguente directory root di default

```
$ ls -la mypkg
totale 44
drwxr-xr-x  5 l    users  4096 25 giu 06.05 .
drwxrwxrwt 22 root root  12288 25 giu 06.18 ..
drwxr-xr-x  6 l    users  4096 25 giu 06.04 .git
-rw-r--r--  1 l    users   109 25 giu 06.04 .gitignore
-rw-r--r--  1 l    users   349 25 giu 06.04 pyproject.toml
-rw-r--r--  1 l    users     5 25 giu 06.04 .python-version
-rw-r--r--  1 l    users     0 25 giu 06.04 README.md
drwxr-xr-x  3 l    users  4096 25 giu 06.04 src
-rw-r--r--  1 l    users   126 25 giu 06.05 uv.lock
drwxr-xr-x  4 l    users  4096 25 giu 06.05 .venv
```

Il progetto viene gia posto sotto git e vengono creati alcuni file

- `pyproject.toml` contiene i metadati del progetto
- `.python-version` fissa la versione di python utilizzata
- la cartella `.venv` contiene il virtual environment (eseguibile python e pacchetti/dipendenze)
- `uv.lock` contiene le versioni specifiche sulle dipendenze per garantire riproducibilità; dovrebbe essere sotto git ma *non* editato a mano

1.4.3 Shell nel virtual environment

Per una shell Python che abbia il progetto a disposizione

```
$ uv run python
Python 3.13.13 (main, Apr  7 2026, 18:19:01) [GCC 15.2.0] on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import mypkg
>>> mypkg.main()
Hello from mypkg!
```

1.4.4 Esecuzione di cli e script

1.4.4.1 Da dentro progetto

cli L'unica differenza del `-package` dalla `-library` è la presenza nel file toml della sezione

```
[project.scripts]
mypkg = "mypkg:main"
```

che permette di eseguire la funzione main in `__init__.py` come script

```
$ uv run mypkg
Using CPython 3.13.13 interpreter at: /run/current-system/sw/bin/python3.13
Creating virtual environment at: .venv
      Built mypkg @ file:///tmp/mypkg
Installed 1 package in 1ms
Hello from mypkg!
```

script Se si ha nel progetto uno script (es in `scripts/example.py`), per eseguirlo facendo uso dell'environment

```
$ uv run scripts/example.py arg1 arg2 ..
```

1.4.4.2 Dall'esterno

Provato vari metodi ma il meglio (più indipendente da sistema operativo e si basa solo su uv) è creare uno script esterno in `PATH` che si posizioni nella directory del progetto che chiami

- `uv run` per entry point specificati in `pyproject.toml`
- `uv run -script` per altri file (eg residenti nella subdirectory `scripts`)

Qualcosa del tipo:

```
#!/usr/bin/env bash

cd  ~/src/pypkg/myuvpkg && uv run --quiet mypkg $*
# cd  ~/src/pypkg/myuvpkg && uv run --quiet scripts/mioscriptsimple.py
```

L'approccio di sopra può creare problemi se specifichiamo path relativi da linea di comando; per usi personali si può modificare lo script bash affinché passi la vecchia `PWD` al codice python, che la gestisca opportunamente. Un esempio è `winston_sends`:

```
#!/usr/bin/env bash

OLDPWD=$(pwd)
cd ~/src/pypkg/winston && uv run --quiet winston_sends $OLDPWD $*
```

1.4.5 Aggiunta/rimozione dipendenze

Di sotto le operazioni più comuni, per maggiori info qui.

Aggiunta dipendenze Per aggiungere:

- dipendenze per l'uso della libreria/package (necessarie per l'utilizzo)

  ```
  uv add pandas
  ```

- tool per il suo sviluppo del pacchetto (non per il successivo utilizzo)

  ```
  uv add --dev pytest ruff mypy
  ```

I comandi andranno a modificare il file `pyproject.toml` opportunamente per garantire riproducibilità anche altrove/in futuro.

Rimozione dipendenze Per rimuovere

```
uv remove pandas
```

Aggiornamento pacchetto Per aggiornare un pacchetto all'ultima versione compatibile lasciando il resto intatto

```
uv lock --upgrade-package pandas
```

Capitolo 2

Dati

Contents

2.1 Introduzione 15
2.2 Tipi nativi 16
2.3 Classificazione dei tipi di base 16
2.4 Numeri 17
2.5 Date e ore 18
2.6 Sequenze: stringhe, liste e tuple 18
2.6.1 Operatore di slice (selezione da sequenza) e indici . . 18
2.6.2 Stringhe 19
2.6.3 Liste 20
2.6.4 Tuple 21
2.6.5 Sequence unpacking 21
2.7 Classi mapping e set 21
2.7.1 Dict 21
2.7.2 Sets 21
2.8 Altri tipi utili 22
2.8.1 `namedtuple` 22
2.8.2 `Counter` 22
2.8.3 Enum & Flag 22
2.9 Type annotation 23
2.9.1 Sintassi 23
2.9.2 Checking 23
2.9.3 Tipi utilizzabili per variabili 23
2.9.4 Creazione di alias 23
2.9.5 Annotazione di funzioni 24
2.9.6 Annotazione di metodi in classi 24

2.1 Introduzione

Assegnazione Gli oggetti del linguaggio vengono creati mediante l'**assegnazione**, che avviene attraverso l'uso di `=`, e non vi è necessità di dichiarare precedentemente il tipo della variabile (dinamically typed):

```
message = 'Hi friend'
pi = 3.1415926535897932
```

Keyword linguaggio I nomi non utilizzabili come identificatori sono:

```
and       del       from      not       while
as        elif      global    or        with
assert    else      if        pass      yield
break     except    import    print
class     in        raise     nonlocal
continue  finally   is        return
def       for       lambda    try
```

Eliminazione oggetti La rimozione del binding ad aree di memoria (pre intervento del garbage collector) avviene mediante la keyword `del`

```
a = 1
del a
```

Operazioni su oggetti Di ogni oggetto è possibile:

- conoscere la **classe di appartenenza** mediante `type` o `isinstance`

  ```
  >>> type(1)
  <class 'int'>
  >>> isinstance(1, int)
  True
  ```

- **listare dati e metodi disponibili** (ai quali si accede mediante l'operatore punto), derivanti dalla classe di appartenenza mediante `dir`

  ```
  >>> dir(1)
  ['__abs__', '__add__', '__and__', '__bool__', '__ceil__', '__class__', '__delatt
  ```

- ottenere un **identificatore univoco** (della singola istanzazione), ottenuto mediante la funzione `id` applicata all'oggetto (questa non restituisce altro che l'indirizzo in memoria dell'oggetto)

  ```
  >>> a = 1
  >>> id(a)
  10754768
  ```

2.2 Tipi nativi

I tipi più di base che il python mette a disposizione sono:

- `bool`: variabili booleane come `True` o `False`
- `int`: gli interi
- `float`: numeri con virgola mobile
- `str`: stringhe di caratteri unicode (non modificabili) compresi tra virgolette

- `bytes`: per la manipolazione di binario

A partire da questi tipi di base si possono creare oggetti composti tra i quali:

- `set`: insiemi di elementi non ordinati
- `list` sono sequenze ordinate e modificabili di elementi
- `tuple` sono sequenze ordinate e non modificabili di elementi
- `dict`: sono array coppie chiave - valore

Infine altri tipi builtin (che servono soprattutto nell'ottica della programmazione) sono:

- `type`: la classe di un oggetto è essa stessa un oggetto di classe `type`
- `None`: serve per indicare un valore vuoto ed ha classe `NoneType`. Non presenta attributi.
- funzioni
- classi
- moduli

Il nome del singolo tipo (ad esempio `int`) serve generalmente, se utilizzato come funzione[1], per **coercire da un tipo all'altro**:

```
>>> int(1.1)
1
>>> float(1)
1.0
>>> str(123)
'123'
```

2.3 Classificazione dei tipi di base

I tipi di base possono essere classificati a seconda di:

- **storage** model: quanti oggetti base possono essere contenuti in un oggetto? in base a questo distinguiamo
  - *oggetti scalari*: contengono un singolo oggetto base
  - *oggetti container*: contengono molteplici oggetti singoli. Il fatto che contengano molteplici oggetti pone poi che questi debbano essere o meno della stessa tipologia. In python tutti i tipi container base possono esser formati da oggetti base di tipo diverso.
- **update** model: una volta creato l'oggetto può esser modificato? Distinguiamo oggetti *mutabili* e *immutabili*
- **access** model: come si accede ad un singolo elemento facente parte dell'oggetto? distinguiamo

[1] Questo perchè il nome di una classe usato come funzione, serve come costruttore.

Data type	Storage	Update	Access
Numbers	Scalar	Immutable	Direct
Strings	Scalar	Immutable	Sequence
Lists	Container	Mutable	Sequence
Tuples	Container	Immutable	Sequence
Dictionaries	Container	Mutable	Mapping

Tabella 2.1: Classificazione dei tipi

- accesso *direct*: caratteristico di alcuni oggetti atomici per i quali non si pone problemi di accesso particolare
- accesso *sequence*: accesso mediante indice numerico
- accesso *mapping*: accesso mediante key alfanumerica

Tabella 2.1 sintetizza la classificazione seguendo i criteri presentati.

2.4 Numeri

Vi sono tre tipi numerici: interi, floating point e complessi; i booleani sono un sottotipo di intero. Tutti i tipi numerici ad eccezione dei complessi supportano le seguenti operazioni, le quali hanno maggior priorità che gli operatori di comparazione

```
x + y    somma
x - y    differenza
x * y    prodotto
x / y    quoziente
x // y   parte intera della divisione
x % y    resto della divisione
divmod(x, y)  la coppia (x // y, x % y)
x ** y       elevamento a potenza
pow(x, y)    elevamento a potenza
abs(x)   valore assoluto
int(x)   x convertito a intero
float(x) x convertito a virgola mobile
complex(re, im)    numero complesso con re parte reale e im immaginaria
c.conjugate()      conjugate of the complex number c
```

`int` e `float` supportano

```
math.trunc(x)     parte intera
round(x[, n])     x arrotondato a n digits (se omesso default a 0)
math.floor(x)     maggiore intero <= x
math.ceil(x)      minor intero >= x
```

Infine l'unico metodo che sembra veramente utile per i `float` è `is_integer` (gli int non hanno metodi di interesse soprattutto in ambito reale)

```
>>> f1 = 2.0
>>> f1.is_integer()
```

```
True

>>> f2 = 1.2
>>> f2.is_integer()
False
```

Per operazioni aggiungive vedere i moduli `math` e `cmath`

2.5 Date e ore

il modulo `datetime` mette a disposizione le classi di base per date, ore, dateore etc

```
>>> import datetime as dt

>>> # definire date/ore
>>> birth = dt.date(1983, 11, 4) # year, month, day
>>> birth_time = dt.time(15, 50, 37) # hour, minute, second
>>> birth_dt = dt.datetime(1983, 11, 4, 15, 50, 37) # tutto

>>> # parsing/importazione da stringhe
>>> dt.datetime.strptime("11/11/2011", "%d/%m/%Y") # custom
datetime.datetime(2011, 11, 11, 0, 0)
>>> dt.datetime.strptime("11/11/2011 12:12:12", "%d/%m/%Y %H:%M:%S") #  custom
datetime.datetime(2011, 11, 11, 12, 12, 12)
>>> dt.date.fromisoformat('2019-12-04') #  iso
datetime.date(2019, 12, 4)
>>> dt.datetime.fromisoformat('2011-11-04T00:05:23') #  iso
datetime.datetime(2011, 11, 4, 0, 5, 23)

>>> # oggi/ora
>>> oggi = dt.date.today()  # oggi: data
>>> ora = dt.datetime.now() # adesso: datetime

>>> # accesso a singoli elementi
>>> [birth.year, birth.month, birth.day]
[1983, 11, 4]
>>> [birth_time.hour, birth_time.minute, birth_time.second]
[15, 50, 37]
>>> [birth_dt.year, birth_dt.month, birth_dt.day,
...  birth_dt.hour, birth_dt.minute, birth_dt.second]
[1983, 11, 4, 15, 50, 37]

>>> # convertire datetime in date
>>> ora.date()
datetime.date(2026, 8, 17)

>>> # differenze di date
>>> diff = oggi - birth
>>> diff
datetime.timedelta(days=15627)
```

```
>>> diff.days / 365.25
42.784394250513344

>>> # differenza di tempi
>>> a = dt.datetime(2000, 11, 11, 2, 50, 30)
>>> b = dt.datetime(2001, 11, 13, 2, 50, 0)
>>> diff_t = b - a
>>> diff_t
datetime.timedelta(days=366, seconds=86370)
>>> diff_t.total_seconds() # secondi di differenza totali
31708770.0

>>> # far scorrere il tempo
>>> un_giorno = dt.timedelta(days = 1)
>>> ieri = oggi - un_giorno
>>> ieri
datetime.date(2026, 8, 16)
>>> domani = oggi + un_giorno
>>> domani
datetime.date(2026, 8, 18)

>>> # esportazione/formattazione a stringa
>>> ora.strftime("%d-%m-%Y") #  custom
'17-08-2026'
>>> ora.strftime("%d-%m-%Y - %H:%M:%S") #  custom
'17-08-2026 - 10:24:33'
>>> oggi.isoformat() # iso
'2026-08-17'
>>> ora.isoformat() # iso
'2026-08-17T10:24:33.153527'
```

2.6 Sequenze: stringhe, liste e tuple

Introduciamo prima gli operatori e le funzioni builtin che funzionano con tutte le sequenze per affrontare le peculiarità di ognuna in sezione separata.
Gli operatori presentati in tabella 2.2 si applicano a tutte le sequenze. Altre funzioni di utilità per tutte le sequenze[2] sono quelle di tabella 2.3 Agli iterabili (di cui le sequenze fanno parte) si possono applicano le funzioni di tabella 2.4 per coercirli a sequenze.

2.6.1 Operatore di slice (selezione da sequenza) e indici

Le parentesi `[]` (operatore di slice) servono per effettuare estrazione da una sequenza. Le sequenze hanno indici che, alternativamente

- vanno da 0 (indice del primo elemento) a `n-1` dove `n` è la lunghezza della sequenza, restituita da `len` (analogamente a quanto avviene nel C).
- vanno da `-n` a `-1` per riferirsi agli oggetti dal primo all'ultimo con indici negativi

[2] A parte len, reversed e sum queste si applicano agli iteratori in genere

Operatore	Funzione
`seq[:::]`	accedi ad elementi specifici di `seq`
`seq[ind1:ind2]`	da `ind1` incluso sino a `ind2` escluso
`seq[ind1:ind2:ind3]`	da `ind1` incluso a `ind2` escluso, facendo passi di `ind3`
`seq * expr`	ripeti la sequenza `expr` volte
`seq1 + seq2`	concatena le due sequenze
`obj in seq`	testa se l'oggetto `obj` è presente nella sequenza `seq`
`obj not in seq`	contrario del precedente test

Tabella 2.2: Operatori comuni per le sequenze

Funzione	Attività
`enumerate(iter)`	ritorna un oggetto enumerato
`len(seq)`	ritorna la lunghezza della sequenza
`max(iter)`	ritorna il massimo del'iterabile
`min(iter)`	ritorna il minimo del'iterabile
`reversed(seq)`	ritorna un iteratore che attraversa la sequenza in ordine inverso
`sorted(iter)`	ritorna una lista ordinata dell'iterabile fornito
`sum(seq)`	somma della sequenza

Tabella 2.3: Operatori per la coercizione a sequenze

Funzione	Attività
`list(iter)`	converti l'iterabile ad una lista
`str(iter)`	converti l'iterabile ad una stringa
`tuple(iter)`	converti l'iterabile ad una tuple

Tabella 2.4: Operatori per la coercizione a sequenze

```
len = 6
 +---+---+---+---+---+---+
 | P | y | t | h | o | n |
 +---+---+---+---+---+---+
   0   1   2   3   4   5
  -6  -5  -4  -3  -2  -1
```

La sintassi dello slicing prevede al massimo tre indici

`seq[partenza:termine:passo]`

- indice di partenza: specifica da che elemento partire, se mancante (o `None`) si intende di partire dall'inizio della sequenza
- indice di termine: specifica sino a quale elemento (escluso) terminare con l'estrazione. Se mancante (o `None`) si intende il termine della sequenza.
- indice di passo: specifica lo step dell'estrazione: se mancante lo step è di singola unità

2.6.2 Stringhe

La creazione avviene normalmente mediante assegnazione; la stringa può essere ugualmente inclusa tra apici singoli o doppi. Vediamo alcuni metodi comuni

2.6.2.1 Stringhe valide

```
>>> stringa = "asdomar"
>>> stringa_multilinea = """
... bla bla bla
... qua qua qua
... za za za
... """
>>> stringa_multilinea2 = (
...     "Queste stringhe tra parentesi, senza virgola, "
...     "saranno concatenate "
...     "come avviene nel C, "
...     "sono utili per spezzare."
... )
>>> print(stringa_multilinea2)
Queste stringhe tra parentesi, senza virgola, saranno concatenate come avviene nel C,
```

2.6.2.2 Formattazione

```
>>> import datetime

>>> s = "test"
>>> n = 13
>>> p = 2/3
>>> a_mill = 1000000
>>> dt = datetime.datetime.now()
>>> the_format = ".3f"
```

```
>>> address = "Via Tal dei tali"
>>> name = "Mario"

>>> # per formattazione. Quello messo a dx di : dipende dal tipo
>>> f"{s} {n}"          # standard..
'test 13'
>>> f"{p:.2f}"          # float con numero decimali
'0.67'
>>> f"{p:.0f}"          # rimuovere decimali da un float
'1'
>>> f"{p:{the_format}}" # formato nested
'0.667'
>>> f"{p:.2%}"          # percentuali con due decimali
'66.67%'
>>> f"{p:e}"            # notazione scientifica
'6.666667e-01'
>>> f"{a_mill:,}"       # re di migliaia
'1,000,000'
>>> f"{a_mill:,.2f}"    # separatore di migliaia e specifica dec
'1,000,000.00'
>>> f"{dt:%d/%m/%Y}"            # date
'17/08/2026'
>>> f"{dt:%Y-%m-%d (%H:%M:%S)}" # datetime
'2026-08-17 (10:24:33)'
>>> f"today is a {dt:%A of %B}" # giorno della settimana e mese
'today is a Monday of August'

>>> # per debugging: a sinistra di = una espressione, a destra il risultato
>>> f"{s = }, {n = }"
"s = 'test', n = 13"
>>> f"{n % 2 = }" # qualsiasi espressione a sinistra viene valutata
'n % 2 = 1'
>>> f"{isinstance(n, int) = }" # e il rispettivo valore restituito
'isinstance(n, int) = True'

>>> # padding/allineamento di stringhe e numeri
>>> f"{s:8}"  # allineato a sinistra in campo da 8
'test    '
>>> f"{s:>8}"  # allineato a destra
'    test'
>>> f"{s:*<8}"  # allineato a sx riempiendo con *
'test****'
>>> f"{s:_^8}"  # centrato riempiendo con _
'__test__'
>>> f'{s:_^{n}}' # uso di una variabile per n. di padding
'____test_____'
>>> f'{address:20}{name:10}' # tabulating without libs
'Via Tal dei tali    Mario     '
>>> f"{n:06}" # aggiungere zeri prima di un numero
'000013'
```

2.6.2.3 Elaborazioni varie

```
>>> # Aggiunta di zero
>>> # ----------------
>>> "123".zfill(4)      # Aggiunta di 0 iniziali
'0123'

>>> # Rimozione spazi
>>> # ----------------
>>> "  test di strip ".strip()  # finali e iniziali
'test di strip'
>>> "   test ".lstrip()         # solo iniziali
'test '
>>> " test   ".rstrip()         # solo finali
' test'

>>> # Join di iterabili contenenti stringhe
>>> # ----------------
>>> ", ".join(["a", "b", "c"])
'a, b, c'

>>> # Ricerca/rimpiazzo
>>> # ----------------
>>> "aiuola".find("a")    # Ricerca da sx (prima occorrenza)
0
>>> "aiuola".find("u")
2
>>> "aiuola".find("x")
-1
>>> "aiuola".rfind("a")  #Ricerca da destra (ultima occorrenza)
5
>>> "prova".replace("a", "e")    # Rimpiazzo
'prove'

>>> # Splitting
>>> # ----------------
>>> "amicici".partition("c")
('ami', 'c', 'ici')
>>> "amicici".rpartition("c")
('amici', 'c', 'i')
>>> "amicici".split("c")
['ami', 'i', 'i']
>>> "linea1\nlinea2".splitlines()
['linea1', 'linea2']

>>> # Checks
>>> # ------
>>> "PROVA".islower()            # Lower/upper case
False
>>> "PROVA".isupper()
True
```

```
>>> "BRGLCU83S04H223C".isalnum() # alfanumerico/alfabetico
True
>>> "BRGLCU83S04H223C".isalpha()
False
>>> "prova".startswith("f")      # inizia/termina con
False
>>> "prova".endswith("a")
True

>>> # Coercizioni
>>> # -----------
>>> "PROVA".lower()
'prova'
>>> "prova".upper()
'PROVA'
>>> "uno due tre prova".capitalize()
'Uno due tre prova'
>>> "uno due tre prova".title()
'Uno Due Tre Prova'
```

2.6.2.4 Classe con formato

```
>>> class MyClass:
...     def __format__(self, format_spec) -> str:
...         return "object"
...
>>> class MyClass2:
...     def __format__(self, format_spec) -> str:
...         match format_spec:
...             case 'upper':
...                 return "OBJECT"
...             case 'lower':
...                 return "object"
...             case _:
...                 raise ValueError(f"{format_spec} not accepted")
...
>>> obj1 = MyClass()
>>> obj2 = MyClass2()

>>> f"{obj1}"          # classe con formato
'object'
>>> f"{obj2:upper}"    # classe con formato e parametro
'OBJECT'
>>> f"{obj2:lower}"    #
'object'
```

2.6.3 Liste

Le **liste** una sequenza di valori, non necessariamente dello stesso tipo, separati da virgole e racchiusi tra parentesi quadre. Le liste sono modificabili

2.6.3.1 Definizione

La definizione di una lista avviene come segue

```
>>> squares = [1, 2, 4, 9, 16, 25]
>>> letters = ['a','b','c','d']
>>> squares
[1, 2, 4, 9, 16, 25]
>>> letters
['a', 'b', 'c', 'd']
```

2.6.3.2 Manipolazione e modifica

Le liste si comportano similmente alle stringhe per ciò che riguarda il **subset**:

```
>>> squares[0]
1
>>> squares[-1]
25
>>> squares[-3:]
[9, 16, 25]
```

e operatori (concatenazione, moltiplicazione)

```
>>> squares + squares
[1, 2, 4, 9, 16, 25, 1, 2, 4, 9, 16, 25]
>>> squares*2
[1, 2, 4, 9, 16, 25, 1, 2, 4, 9, 16, 25]
```

A differenza delle stringhe sono modificabili:

```
>>> squares[0] = 0 # modifica di un valore
>>> squares
[0, 2, 4, 9, 16, 25]
>>> letters[1:2] = []  # eliminazione di valori
>>> letters
['a', 'c', 'd']
```

Le liste sono oggetti e hanno **metodi** per le operazioni più classiche. Si veda `help(list)`.

2.6.3.3 Metodi utili

```
>>> l = []
>>> a = ["a", "c", "d"]

>>> # Aggiunta elementi
>>> # ------------------
>>> l.append(1)       # un elemento in coda
>>> a.insert(1, "b")  # un elemento prima dell'indice specificato
>>> l.extend([1,2,3]) # elementi da un iterabile in coda

>>> # Rimozione elementi
>>> # ------------------
```

```
>>> a.remove("c")      # rimuove la prima occorrenza di un elemento
>>> x = a.pop(1)       # rimuove il valore all'indice specificato e lo ritorna
>>> l.clear()          # rimuove tutti gli elementi

>>> # Ricerca elementi
>>> # ----------------
>>> ["a", "x", "c", "x"].index("x") # indice di un elemento (prima occorrenza)
1
>>> [1,2,1,3].count(1)              # conta le occorrenze di un dato elemento
2

>>> # Ordinamento
>>> # -----------
>>> x = ["w", "j", "a" ]
>>> x.sort()    # ordina
>>> x.reverse() # inverti
```

2.6.3.4 Liste nested

Le liste possono essere nested, e nel caso il subsetting necessita di una parentesi graffa per ogni livello:

```
>>> a = [1, 2, 3]
>>> b = ['a', 'b', 'c']
>>> c = [a, b, 3]
>>> c
[[1, 2, 3], ['a', 'b', 'c'], 3]
>>> c[0]
[1, 2, 3]
>>> c[1]
['a', 'b', 'c']
>>> c[2]
3
>>> c[1][2]
'c'
```

2.6.3.5 List comprehensions

Sono un trick del linguaggio per creare liste in maniera concisa.

Definizione La versione più generale è

```
newlist = [expression for item1 in iterable1 if condition1
                      for item2 in iterable2 if condition2
                      ...                    ...
                      for itemN in iterableN if conditionN
           if conditionN+1
           if conditionN+2
           ...
           if conditionN+M
]
```

con:

1. `expression` è una espressione contenente `item1..itemN`;
2. seguita da uno statement `for` (obbligatorio) che si riferisca ad un iterabile (volendo filtrato mediante `if`);
3. al quale seguono 0+ più ulteriori statement `for` con altrettanti iterabili (per ciclare su altro, eventualmente filtrando con `if`);
4. al quale seguono 0+ statement `if` (opzionalmente per selezionare gli elementi da porre nell'output).

Gli `iterable*` non necessariamente debbono essere della stessa lunghezza, perché sono iterate da sinistra a destra, non in parallelo: per ogni elemento in `iterable1`, viene fatto loop su `iterable2` e tutte le rimanenti a cascata

Esempi

```
>>> ## Esempio base
>>> doubled = [x * 2 for x in range(10)]
>>> doubled
[0, 2, 4, 6, 8, 10, 12, 14, 16, 18]

>>> ## Esempio con if
>>> combs = [(x, y) for x in [1, 2, 3] for y in [3, 1, 4] if x != y]
>>> # che equivale a
>>> combs = []
>>> for x in [1,2,3]:
...     for y in [3,1,4]:
...         if x != y:
...             combs.append((x, y))
...

>>> X = [1, 2, 3]
>>> Y = [4, 5, 6]
>>> res = [[x, y, x*y]
...        for x in X if x > 1
...        for y in Y if y < 6
...        if y % x == 0]
```

Espressioni più complesse e trick utili a seguire

```
>>> vec = [-4, -2, 0, 2, 4]

>>> ## Selezionare gli elementi >= 0
>>> [x for x in vec if x >= 0]
[0, 2, 4]

>>> ## Applicare una funzione a tutti gli elementi di una lista
>>> [abs(x) for x in vec]
[4, 2, 0, 2, 4]
```

```
>>> ## utilizzo di più di un if: stampa dei numeri divisibili per 2 e per 5
>>> ## tra 0 e 100
>>> [y for y in range(100) if y % 2 == 0 if y % 5 == 0]
[0, 10, 20, 30, 40, 50, 60, 70, 80, 90]

>>> ## Le espressioni possono essere molto generali;
>>> ## if .. else con list comprehension
>>> [">=0" if i>=0 else "<0" for i in vec]
['<0', '<0', '>=0', '>=0', '>=0']

>>> ## creiamo una lista composta da tuple
>>> [(x, x**2) for x in range(6)]
[(0, 0), (1, 1), (2, 4), (3, 9), (4, 16), (5, 25)]

>>> ## esegui un metodo su ogni elemento
>>> fruit = ['banana', 'strawberry', 'passion fruit']
>>> [y.capitalize() for y in fruit]
['Banana', 'Strawberry', 'Passion fruit']
```

List comprehensions nested Espressione di una list comprehension può esser qualunque cosa, quindi anche una list comprehension. Questo può essere utile per creare liste di liste, che possono avere applicazione.

```
>>> ## Calcolo tabelline del 7 e dell'8 (nb:cicla per prima è la lista
>>> ## esterna, poi quella interna)
>>> nl = [[i*j for j in range(1, 11)] for i in range(7, 9)]
>>> nl
[[7, 14, 21, 28, 35, 42, 49, 56, 63, 70], [8, 16, 24, 32, 40, 48, 56, 64, 72, 80]]

>>> ## Trasposizione di matrice creata mediante lista di liste
>>> matrix = [
...             [1, 2,   3,  4],
...             [5, 6,   7,  8],
...             [9, 10, 11, 12]
...          ]
>>> t = [[row[i] for row in matrix] for i in range(4)]
>>> t
[[1, 5, 9], [2, 6, 10], [3, 7, 11], [4, 8, 12]]
```

2.6.4 Tuple

Le **tuple** sono insiemi di valori separati da virgole (buona norma porle tra parentesi tonde per chiarezza) e non modificabili una volta create

```
>>> ## Definizione
>>> atuple = ('robots', 77, 93, 'try')
>>> atuple
('robots', 77, 93, 'try')

>>> ## subset
>>> atuple[:3]
```

```
('robots', 77, 93)

>>> ## tuple nested
>>> a = (1, 2)
>>> b = ('x', 'y')
>>> c = (a, b)
>>> c
((1, 2), ('x', 'y'))

>>> ## modifica diretta? no: da errore
>>> atuple[1] = 1
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'tuple' object does not support item assignment
>>> ## tuttavia è possibile creare tuple che contengono oggetti modificabili
>>> btuple = ([1,2], "abc")
>>> btuple[0][0] = 3
>>> btuple
([3, 2], 'abc')

>>> ## Metodi utili, uguali a quelli delle liste
>>> atuple.count(93)
1
>>> atuple.index("try")
3
```

2.6.5 Sequence unpacking

Consiste nell'assegnare gli elementi di una sequenza (posta come *rvalue*) a variabili separate (*lvalue*)

```
>>> ## Esempio con lista
>>> a, b, c = [1, 2, 'goodbye']

>>> ## Esempio con tupla
>>> t = (12345, 54321, 'hello!')
>>> t1, t2, t3 = t

>>> ## Esempio con stringa
>>> x, y, z = 'cia'
```

2.7 Classi mapping e set

2.7.1 Dict

Sono un insieme non ordinato di coppie `key:value`, con `key` univoche all'interno di un dict (e immutabili), utile per memorizzare un dato e ritornarlo attraverso la sua chiave.

```
>>> ## Definizione, accesso e modifica
>>> ## ------------------------------
```

```
>>> d = {'planet':'earth', 'region':'europe', 'prefix':39, 'number_list': [1,2,3]}
>>> d
{'planet': 'earth', 'region': 'europe', 'prefix': 39, 'number_list': [1, 2, 3]}
>>> d2 = {1: "a", 2: "b"} # esempio con chiave numerica
>>> f = dict(sape = 4139, guido = 4127, jack = 4098) # Metodo alternativo: funzione dict
>>> g = dict([('sape', 4139), ('guido', 4127), ('jack', 4098)])

>>> ## Accesso/modifica
>>> ## ----------------
>>> d.get('planet')    # ottiene un valore data la chiave
'earth'
>>> d['prefix']        # accesso in lettura ad un elemento
39
>>> d['prefix'] = 45   # modifica consentita
>>> d['foo'] = "bar"   # nuovo inserimento consentito
>>> d2[1]
'a'
>>> g.clear()          # rimuove tutti gli item

>>> ## ottenere le chiavi/valori come iterabili (es per un for)
>>> ## --------------------------------------------------------
>>> d.keys()    # ottenere le chiavi
dict_keys(['planet', 'region', 'prefix', 'number_list', 'foo'])
>>> 'foo' not in d.keys()
False
>>> d.values() # ottenere valori come iterabile
dict_values(['earth', 'europe', 45, [1, 2, 3], 'bar'])
>>> d.items() # coppia (indice, valore) come iterabile per unpacking
dict_items([('planet', 'earth'), ('region', 'europe'), ('prefix', 45), ('number_list', [1, 2, 3
```

2.7.1.1 Dict comprehension

Hanno sintassi analoga a quella delle liste e possono tornare talvolta utili come forma di mapping

```
>>> pow2 = {x: x**2 for x in (2, 4, 6)}
>>> pow2[2]
4
```

2.7.2 Sets

Sono una collezione di elementi senza ordine e duplicati. Si usano tipicamente per:

- verificare l'appartenenza di un qualcosa ad un insieme (mediante `in`);
- per eliminare duplicati di altre strutture dati
- per effettuare operazioni insiemistiche

Si definiscono mediante parentesi graffe o la funzione `set`.

```
>>> basket = {'apple', 'orange', 'apple', 'pear'}
>>> basket ## elementi doppi vengono eliminati
{'apple', 'pear', 'orange'}

>>> ## definizione mediante set: dalla sequenza fornita sono eliminati i doppi
>>> a = set('abracadabra')                    ## stringa
>>> a
{'c', 'r', 'd', 'b', 'a'}
>>> a = set(['asd', 'foo', 'bar', 'asd'])     ## lista
>>> a
{'bar', 'foo', 'asd'}
>>> a = set( ('asd', 'foo', 'bar', 'asd') )   ## tuple
>>> a
{'bar', 'foo', 'asd'}

>>> ## emptyset: si usa set, non due graffe (usate per dict vuoto)
>>> empty = set()

>>> ## Test appartenenza
>>> 'orange' in basket
True
>>> 'strawberry' in basket
False

>>> ## aggiunta, rimozione, azzeramento
>>> empty.add(1)
>>> empty.remove(1)
>>> empty
set()
>>> empty.add(1)
>>> empty.add(2)
>>> empty.clear()
```

2.7.2.1 Operatori/metodi utili

```
>>> ## Applicazione operatori numerici e logici
>>> a = set('abracadabra')
>>> b = set('alacazam')
>>> a
{'c', 'r', 'd', 'b', 'a'}
>>> b
{'c', 'm', 'l', 'a', 'z'}

>>> ## Operazioni insiemistiche
>>> a - b # lettere in a ma non in b
{'d', 'r', 'b'}
>>> a | b # lettere in a o in b
{'c', 'r', 'd', 'b', 'm', 'l', 'a', 'z'}
>>> a & b # lettere sia in a che in b
{'a', 'c'}
>>> a ^ b # xor: lettere in a o in b ma non in entrambi
```

```
{'m', 'l', 'r', 'b', 'd', 'z'}

>>> ## Test insiemistici
>>> # intersezione
>>> {1,2}.isdisjoint({3,4})
True
>>> {1,2}.isdisjoint({2,3})
False
>>> # sottinsieme e sovrainsieme
>>> a = {1, 2}
>>> b = {1}
>>> a.issuperset(b)
True
>>> b.issubset(a)
True
```

2.7.2.2 Set comprehension

Le comprehension sono ammesse anche nei set

```
>>> a = {x for x in 'abracadabra' if x not in 'abc'}
>>> a
{'d', 'r'}
```

2.8 Altri tipi utili

2.8.1 namedtuple

Espandono le tuple (immutabili) con l'uso di key dei dict per facilità di accesso

```
>>> from collections import namedtuple

>>> # Problem with tuples and dictionary
>>> # color = (55, 155, 255)  # immutable but standard tuple has no names, less readable
>>> # color = {"red": 55, "green": 155, "blue": 255} # dict is mutable

>>> # the right mix
>>> Color = namedtuple("Color", ["red", "green", "blue"]) # create the object
>>> color1 = Color(blue = 55, green = 155, red = 255)     # create an instance
>>> color2 = Color(255, 255, 255)                         # another instance

>>> # Accessing data two way (still read-only)
>>> color1
Color(red=255, green=155, blue=55)
>>> color1.red # no color1["red"]
255
>>> color1.red = 123 # error: tuples are still immutable
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
AttributeError: can't set attribute
```

2.8.2 Counter

Sono versioni speciali di `dict` che servono per contare frequenze di occorrenze

```
>>> from collections import Counter
>>> import random

>>> c = Counter() # create an empty counter

>>> # it's dict like, no initialization needed
>>> c["a"] += 1   # increase count of an element (starting from 0)
>>> c["a"] += 3   # increase count of an element (starting from 0)
>>> c["b"] =  2
>>> c["c"] =  1
>>> c["x"]           # no elements counted
0

>>> # typical methods
>>> sorted(c.elements()) # accesso a tutti gli elementi, con ripetizione
['a', 'a', 'a', 'a', 'b', 'b', 'c']
>>> c.total() # sum of all frequencies
7
>>> c.most_common(2) # most common modalities
[('a', 4), ('b', 2)]

>>> # # other are as in dict
>>> # c.keys()
>>> # c.values()
>>> # c.items()


>>> # example 2: 100d4
>>> d4 = [1, 2, 3, 4]
>>> c2 = Counter()
>>> for i in range(100):
...     roll = random.choice(d4)
...     c2[roll] += 1
...
>>> c2
Counter({4: 32, 3: 28, 1: 23, 2: 17})

>>> # example3: use a counter on elements of a list
>>> rolls = random.choices(d4, k = 200) # list of 200 d4 rolls
>>> c3 = Counter(rolls)
>>> c3
Counter({4: 58, 2: 54, 3: 46, 1: 42})
```

2.8.3 Enum & Flag

2.8.3.1 Enum

Sono usate per dati con un set prefissato di opzioni /categorie

- raggruppano ordinatamente stati/costanti prefissate
- aumentano leggibilita
- facilitano debugging
- single source of truth/consistency

Possono essere pensate come un binding nome valore

```
>>> from enum import Enum

>>> class State(Enum):
...     OFF: int = 0
...     ON: int = 1
...
>>> class Color(Enum):
...     RED: str = 'R'
...     GREEN: str = 'G'
...     BLUE: str = 'B'
...
>>> # Cosa contengono
>>> dir(Color)
['BLUE', 'GREEN', 'RED', '__class__', '__contains__', '__doc__', '__getitem__', '__init_subclas
>>> dir(Color.RED)
['__class__', '__doc__', '__eq__', '__hash__', '__module__', 'name', 'value']
>>> Color.RED.name    # etichetta
'RED'
>>> Color.RED.value   # valore associato
'R'
```

L'utilizzo base è chiaro dal punto di vista del codice

```
>>> print(Color.RED) # autocompletamento dopo . fornisce i colori disponibili
Color.RED
>>> print(Color("R"))
Color.RED
>>> Color("R") == Color.RED  # si può usare sia il valore che l'etichetta
True
>>> Color.RED is Color("R") # same thing direi
True


>>> def create_car(color: Color) -> None:
...     match color:
...         case Color.RED:
...             print("A red car was created")
...         case Color.BLUE:
...             print("A blue car was created")
...         case Color.GREEN:
...             print("A green car was created")
...         case _:
...             print(f"We don't have {color} in our database")
```

```
...

>>> create_car(Color.RED)
A red car was created

>>> # # in una classe
>>> # macchina.color = Color.RED
>>> # ...
>>> # if macchina.color == Color.BLUE:
>>> #     ...
```

2.8.3.2 Flag

Sono enum che permettono di combinare valori per indicare assiemi di valori (tipo set)

```
>>> from enum import Flag

>>> # Se definiamo a mano meglio usare le potenze del 2
>>> class Color(Flag):
...     RED: int = 1     # 00001
...     GREEN: int = 2   # 00010
...     BLUE: int = 4    # 00100
...     YELLOW: int = 8  # 01000
...     BLACK: int = 16  # 10000
...

>>> # Mix di colori
>>> red_and_yellow = Color.RED | Color.YELLOW

>>> # stampa del contenuto (tipo set)
>>> print(red_and_yellow)
Color.RED|YELLOW
>>> for col in red_and_yellow:
...     print(col)
...
Color.RED
Color.YELLOW
>>> # utilizzo (set/combination)
>>> cool_colors = Color.YELLOW | Color.BLACK | Color.RED # creo set colori
>>> my_car_color = Color.BLACK
>>> my_car_color in cool_colors # testo appartenenza a set di colori
True
```

Sotto la scocca una combinazione di gruppi di enum somma le relative costanti associate;

```
>>> red_and_yellow.value
9
```

nella definizione sopra non abbiamo impostato a 9 nessun colore nella definizione se no il programma si confonde e ci restituisce il colore impostato a 9. Tuttavia se impostiamo le costanti a mano potremmo fare danni

```
>>> # power of two
>>> class Wrong(Flag):
...     RED: int = 1      # 00001
...     GREEN: int = 2    # 00010
...     BLUE: int = 3     # 00100
...

>>> red_or_green = Wrong.RED | Wrong.GREEN
>>> red_or_green
<Wrong.BLUE: 3>
>>> red_or_green.value
3
```

Motivo per cui si può usare `auto` nella definizione (di `Flag` ed `enum`)

```
>>> # to prevent these errors, use auto in definition
>>> from enum import Flag, auto

>>> class Right(Flag):
...     RED: int = auto()      # auto assign a proper value
...     GREEN: int = auto()    # we don't have to worry
...     BLUE: int = auto()
...
>>> Right.RED
<Right.RED: 1>
>>> Right.GREEN
<Right.GREEN: 2>
>>> Right.BLUE
<Right.BLUE: 4>
```

Nel caso di `Enum` secche, auto non usa le potenze di due ma un progressivo numerico

```
>>> class Right2(Enum):
...     RED: int = auto()
...     GREEN: int = auto()
...     BLUE: int = auto()
...

>>> Right2.RED
<Right2.RED: 1>
>>> Right2.GREEN
<Right2.GREEN: 2>
>>> Right2.BLUE
<Right2.BLUE: 3>

>>> # btw with enums one cannot use | . errore
>>> Right2.RED | Right2.GREEN
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: unsupported operand type(s) for |: 'Right2' and 'Right2'
```

Al termine, come informazione, Possiamo usare la combinazione anche in sede di definizione con |

```
>>> class Right2(Flag):
...     RED: int = auto()
...     GREEN: int = auto()
...     BLUE: int = auto()
...     ALL: int = RED | GREEN | BLUE # 1 + 2 + 4
...

>>> Right2.ALL
<Right2.ALL: 7>
```

2.9 Type annotation

Qui sono presentati concetti che richiedono conoscenze più approfondite rispetto ad una prima lettura, nella quale si possono tralasciare.
Sebbene Python sia un dynamic language con variabili aventi un tipo non stabilito a priori/che può variare nel corso dell'esecuzione del programma, è possibile specificare il tipo assunto da una variabile nonché il tipo ritornato da una funzione in maniera tale da usare tool esterni che analizzino il codice e riportino utilizzi impropri.

2.9.1 Sintassi

```
>>> ## ------------
>>> ## File test.py
>>> ## ------------

>>> # formati per variabile: in unico colpo
>>> x: int = 4

>>> # spezzato
>>> x: int
>>> x = "4"  # qua viene dato errore nei programmi giusti, non nell'interprete

>>> # esempio con funzioni, notare i parametri e il tipo restituito
>>> # z è un parametro opzionale (può essere int al massimo) di default a None
>>> def repeat(x: str, y: int = 2, z: int|None = None) -> None:
...     if z is None:
...         print(x * y)
...     else:
...         print(x * y * z)
...
>>> repeat(x = 'foo')
foofoo
```

2.9.2 Checking

La sintassi di cui sopra è tool indipendente quindi può essere potenzialmente gestita da diversi eseguibili. Qui utilizziamo `mypy`. Per installarlo

```
pip install --user mypy
```

Dopodiché per controllare il file di cui sopra

```
mypy test.py
```

Per controllare una pacchetto posizionarsi nella directory base (quella con requirements.txt e compagnia) e comandare

```
mypy .
```

2.9.3 Tipi utilizzabili per variabili

Tutti i tipi di base quindi `str`, `int`, `float`, `bool`, ma anche `None` per indicare che la funzione non ritorna nulla.
Per i tipi compositi: sotto alcuni esempi di assegnazione corretta

```
# lista di sole stringhe
x: list[str] = ["foo", "bar"]

# insieme di interi
x: set[int] = {6, 7}

# per dict fornire il tipo di key e value
x: dict[str, float] = {"field": 2.0}

# tuple di dimensione fissa si specifica il tipo di ogni elemento
x: tuple[int, str, float] = (3, "yes", 7.5)

# tuple di dimensione variabile: si usa un tipo e l'ellissi
x: tuple[int, ...] = (1, 2, 3)

# se ad esempio vogliamo essere generali
# e specificare un iterabile (lista, tuple, set, altro) di interi

from typing import Iterable
x: Iterable[str] = ...

# i tipi Mapping sono dict-like non mutabili (con metodo __getitem__)
from typing import Mapping
x: Mapping[int, str] = {3: 'yes', 4: 'no'}
x[5] = 'foo' # qui mypy si lamenta

# MutableMapping sono dict-like mutabili (con metodo __setitem__)
x: MutableMapping[int, str] = {3: 'yes', 4: 'no'}
x[5] = 'foo' # qui mypy non si lamenta

# accettare tipi molteplici
x: list[int | str] = [3, 5, "test", "fun"]
# questo è utile in funzioni per specificare parametri opzionali

# Optional per dati che possono essere anche None
```

```
from typing import Optional
x: Optional[str] = "something" if some_condition() else None
```

mypy conosce i tipi della standard library e fornisce suggerimenti sui pacchetti da installare nel caso non sia così

```
prog.py:2: error: Library stubs not installed for "requests"
prog.py:2: note: Hint: "python3 -m pip install types-requests"
```

2.9.4 Creazione di alias

La digitazione di tipi complessi più volte può essere evitata mediante la creazione di alias, fatti semplicemente mediante assegnazione. Ad esempio

```
Vector = list[float]

def scale(scalar: float, vector: Vector) -> Vector:
    return [scalar * num for num in vector]

# utile anche per rendere i tipi più leggibili/compatti/riutilizzabili
ConnectionOptions = dict[str, str]
Address = tuple[str, int]
Server = tuple[Address, ConnectionOptions]
def broadcast_message(message: str, servers: Sequence[Server]) -> None:
    ...
```

2.9.5 Annotazione di funzioni

Abbiamo già visto un esempio abbastanza generico di funzione

```
def show(value: str, excitement: int = 10) -> None:
    print(value + "!" * excitement)
```

Per la programmazione funzionale può essere necessario specificare un tipo `Callable` (funzione):

```
from typing import Callable

def repeat(x: str, y: int = 2) -> None:
     print(x * y)

# variabile:  x può essere una funzione di tipo def xx(str, int): -> None
x: Callable[[str, int], None] = repeat
```

Per funzioni generatrici che restituiscono un iteratore di int si può fare così

```
def gen(n: int) -> Iterator[int]:
    i = 0
    while i < n:
        yield i
        i += 1
```

2.9.6 Annotazione di metodi in classi

`self` non va caratterizzato (nei parametri, se restituito si usa `Self`), poi spesso le funzioni di classi modificano dati internamente non restituendo nulla quindi si userà `None` come dato restituito

```
from typing import Self

class BankAccount:
    def __init__(self, account_name: str, initial_balance: int = 0) -> None:
        self.account_name = account_name
        self.balance = initial_balance

    def deposit(self, amount: int) -> None:
        self.balance += amount

    def withdraw(self, amount: int) -> None:
        self.balance -= amount

    def returnme(self) -> Self:
        return self
```

Le classi definite dall'utente sono tipi validi da usare per le annotazioni

```
account: BankAccount = BankAccount("Alice", 400)
def transfer(src: BankAccount, dst: BankAccount, amount: int) -> None:
    src.withdraw(amount)
    dst.deposit(amount)
```

Funzioni che accettano una classe, accetteranno anche classi derivate senza problemi:

```
class BankAccountForYoungs(BankAccount):
     ....

timmysba = BankAccountForYoungs("Timmy", 2)
transfer(account, timmysba, 100)  # type checks!
```

Capitolo 3

Controllo del flusso

Contents

3.1 Costrutti condizionali: `if` e `while` 25
3.1.1 `if` 25
3.1.2 `match` 25
3.1.3 `while` 25
3.1.4 `break`, `continue` ed `else` 25
3.2 Condizioni e test logici 26
3.2.1 Test verità 26
3.2.2 Operatori booleani 26
3.2.3 Comparazioni 26
3.2.4 Comparazioni concatenate 27
3.2.5 Check appartenenza: `in` e `not in` 27
3.2.6 Comparare sequenze e altri tipi 27
3.3 Looping su oggetti: `for` 28
3.3.1 Looping in sequenze (stringhe, liste, tuple) 28
3.3.2 Looping nei dict 28
3.3.3 Looping sui set 28
3.3.4 L'utilizzo di `range` 28

3.1 Costrutti condizionali: `if` e `while`

3.1.1 `if`

Ha la seguente sintassi con `<>` a indicare un contenuto obbligatorio, `[]` uno facoltativo e `*` la possibilità di ripetizione:

```
if <condizione>:
    <istruzioni>
[elif <condizione>:
     <istruzioni>]*
[else:
     <istruzioni>]
```

3.1.2 `match`

Simile allo switch di altri linguaggi, `match` prende una espressione e la compara ad una casistica di altre espresioni (poste dopo `case`) per eseguire azioni specificate:

```
def http_error(status):
    match status:
        case 400:
            return "Bad request"
        case 401 | 403 | 404:
            return "Not allowed"
        case 418:
            return "I'm a teapot"
        case _:
            return "Something's wrong with the internet"
```

Si notano che si possono specificare match multipli con `|`, mentre `_` matcha sempre e quindi può essere usato come caso default (eventualmente) quando nessun altro caso ha matchato.

3.1.3 `while`

python ha solo l'istruzione `while` per implementare l'iterazione nel senso di altri linguaggi come il Pascal o il C:

```
while <condizione>:
    <istruzioni>
[else:
    <istruzioni>]
```

3.1.4 `break`, `continue` ed `else`

Sia in `while` che `for` (che vedremo poi):

- `continue` permette di saltare le rimanenti istruzioni del ciclo passando all'iterazione successiva;
- `break` termina il ciclo;
- se è presente la clausola `else` le sue istruzioni vengono eseguite qualora il ciclo termini normalmente, mentre non vengono eseguite se il ciclo termina a causa dell'istruzione break.

3.2 Condizioni e test logici

3.2.1 Test verità

Un oggetto può essere testato come `True`/`False` in un `if` o in un `while`: in generale un oggetto è considerato `True` a meno che, alternativamente

- la sua classe definisce il metodo `__bool__`, che restituisce `False`

- il metodo `__len__` ritorna qualcosa, se chiamato sull'oggetto

Quindi:

- `None` è valutato `False`
- i numeri restituiscono tutti `True` ad eccezione dello 0 (`int` o `float` che sia) che è `False`
- stringa, lista, tuple, set e dict **vuoti restituiscono** `False`, altrimenti (con almeno un elemento) viene restituito `True` (indipendentemente dal contenuto)

Mediante una funzioni del genere possiamo testare la valutazione booleana di oggetti di natura diversa:

```
>>> def is_it_true(anything):
...     if anything:
...         print("yes, it's true")
...     else:
...         print("no, it's false")
...
```

3.2.2 Operatori booleani

Le comparazioni possono esser elaborate mediante operatori booleani `and` `or` e `not`.
È sempre meglio aggiungere le parentesi per indirizzare ordine/priorità di valutazione. In assenza tra gli operatori `not` ha la priorità maggiore, `or` la minore. Pertanto:

```
A and not B or C
```

equivale a

```
(A and (not B)) or C
```

3.2.3 Comparazioni

Vi sono otto operatori di comparazione, hanno tutti la stessa priorità (che è superiore a quella degli operatori booleani

```
<        minore
<=       minore o uguale
>        maggiore
>=       maggiore o uguale
==       equal
!=       not equal
is       due oggetti sono identici
is not   due oggetti sono diversi
```

Alcune regole:

- oggetti di tipo differente (esclusi numeri) son sempre diversi

- oggetti non identici di una stessa classe sono diversi, a meno che forniscano un metodo `__eq__` che li battezzi come uguali
- istanze di una classe non possono essere ordinate tra loro a meno che la classe non definisca `__lt__` ed `__eq__` (si può definire volendo `__lt__`, `__le__`, `__gt__`, `__ge__`)
- il funzionamento di `is` e `is not` non può esser modificato ed è supportato da iterabili o oggetti che implementano il metodo `__contains__`

3.2.4 Comparazioni concatenate

Le comparazioni possono essere concatenate, come in:

```
a < b == c
```

che equivale a in pratica

```
(a < b) and (b == c)
```

3.2.5 Check appartenenza: `in` e `not in`

`in` e `not in` controllano se un valore è presente o meno in una sequenza

3.2.6 Comparare sequenze e altri tipi

Oggetti di tipo sequenza possono esser comparati con oggetti del medesimo tipo; la comparazione avviene in maniera ricorsiva, con ordinamento lessicografico (in base a unicode). Vi sono alcune peculiarità:

- se tutti gli item di due sequenze sono uguali, le sequenze sono considerate uguali
- se una sequenza costituisce l'inizio di un'altra sequenza più lunga, la sequenza più corta è considerata minore

La comparazione restituisce un valore `True` o `False`; ad esempio nei seguenti casi viene restituito sempre `True`:

```
>>> (1, 2, 3)              < (1, 2, 4)
True
>>> [1, 2, 3]              < [1, 2, 4]
True
>>> 'ABC' < 'C' < 'Pascal' < 'Python'
True
>>> (1, 2, 3, 4)           < (1, 2, 4)
True
>>> (1, 2)                 < (1, 2, -1)
True
>>> (1, 2, 3)             == (1.0, 2.0, 3.0)
True
>>> (1, 2, ('aa', 'ab'))   < (1, 2, ('abc', 'a'), 4)
True
```

3.3 Looping su oggetti: `for`

Nel python serve per iterare sugli elementi di una sequenza (come lista stringa o tuple) e presenta questa sintassi

```
for <variabile> in <sequenza>:
    <istruzioni>
[else:
     <istruzioni>]
```

Il funzionamento interno del `for` verrà spiegato nella sezione di OOP; qui si riassume l'utilizzo standard coi dati più comuni.

3.3.1 Looping in sequenze (stringhe, liste, tuple)

Nelle sequenze possiamo:

- fare loop sul singolo elemento (ponendo la sequenza nel `for` direttamente)
- ottenere un progressivo numerico indice e il contenuto della sequenza con `enumerate`
- fare loop sull'oggetto ordinato con `sorted`
- fare loop sull'oggetto ordinato in maniera decrescente con `reversed`

Gli esempi presentano liste, ma il funzionamento è speculare anche per stringhe e tuple:

```
>>> games = ['monopoli', 'risiko', 'dnd']

>>> for g in games:
...     print(g)
...
monopoli
risiko
dnd
>>> for i, g in enumerate(games):
...     print(i, g)
...
0 monopoli
1 risiko
2 dnd
>>> for g in sorted(games):
...     print(g)
...
dnd
monopoli
risiko
>>> for g in reversed(games):
...     print(g)
...
dnd
risiko
monopoli
```

3.3.2 Looping nei dict

Di un dict possiamo volere le chiavi (usiamo l'oggetto direttamente o ne chiamiamo/esplicitiamo il metodo `keys`), i contenuti (risp `values`) o tutti e due (`items`):

```
>>> knights = {"gallahad": "the pure", "ciro": "the brave"}

>>> for k in knights:
...     print(k)
...
gallahad
ciro
>>> for k in knights.keys():
...     print(k)
...
gallahad
ciro
>>> for v in knights.values():
...     print(v)
...
the pure
the brave
>>> for k, v in knights.items():
...     print(k, v)
...
gallahad the pure
ciro the brave
```

3.3.3 Looping sui set

La forma più semplice, si pone il set nel for

```
>>> S = {2, 3, 5, 7}
>>> for i in S:
...     print(i)
...
2
3
5
7
```

3.3.4 L'utilizzo di `range`

Se è necessario iterare su una sequenza di interi la funzione `range` torna utile

```
>>> range(5)              # 0, 1, 2, 3, 4
range(0, 5)
>>> range(5, 10)          # 5, 6, 7, 8, 9
range(5, 10)
>>> range(0, 10, 3)       # 0, 3, 6, 9
range(0, 10, 3)
```

```
>>> range(-10, -100, -30)  # -10, -40, -70
range(-10, -100, -30)
```

Capitolo 4

Funzioni

Contents

4.1 Definizione 29
4.2 Chiamata 30
4.2.1 Valutazione dei valori di default 30
4.2.2 Valore ritornato 30
4.2.3 Unpacking di liste/tuple/dict in chiamata 30
4.3 Regole di scope 30
4.3.1 Namespace 31
4.3.2 Attributi 31
4.3.3 Scoping 31
4.4 Funzioni anonime (`lambda`) 32
4.5 Programmazione funzionale 32
4.5.1 Funzioni classiche 32
4.5.2 Partialling 33
4.5.3 Function factory 34
4.5.4 Composizione di funzioni 34
4.5.5 Decorators 34
4.5.6 Single e multiple dispatch 35
4.6 Altri argomenti 36
4.6.1 `atexit` 36

4.1 Definizione

Avviene mediante `def`, seguita dal nome della funzione e ponendo tra tonde i parametri:

```
def nome_funzione(arg1, arg2 = default2, *args, **kwargs):
    """
    Stringa di documentazione disponibile in nome_funzione.__doc__
    """
    codice
    ...
```

Gli argomenti devono essere specificati nell'ordine di cui sopra, e sono:

1. *positional argument* (`arg1`) son definiti con solamente il nome dell'argomento. In chiamata è obbligatorio specificarli inserendo alternativamente `valore` o `nome = valore` (in questo secondo caso sarà possibile seguire un ordine di argomenti diverso da quello dato in definizione);

2. *keyword argument* (`arg2`) son definiti con un valore di default: in sede di chiamata non sono obbligatori da specificare (e si possono specificare sia con `valore` che `nome=valore`);

3. *arbitrary argument list*: se si specifica `*args` in definizione, la variabile `args` memorizzerà una tupla con gli argomenti posizionali della chiamata (specificati mediante il solo `valore`) esclusi i valori associati ad altri argomenti posizionali: ad esempio sopra prima viene riempito `arg1`, poi `args`);

4. *arbitrary keyword argument list*: se si specifica `**kwargs` in definizione, la variabile `kwargs` memorizzerà un dizionario con i keyword argument (`nome=valore`) specificati in sede di chiamata (esclusi quelli che matchano keyworded argument specificati, es `arg2`)

Parametri speciali `/*` in definizione Gli argomenti possono esser passati alle funzioni sia per posizione che utilizzando la keyword. Si può (leggibilità/performance) in definizione imporre che la chiamata di alcuni possa avvenire in un modo, nell'altro o in entrambi, specificando gli argomenti opzionali `/` e `*`

```
def f(pos1, pos2, /, pos_or_kwd, *, kwd1, kwd2):
      -----------    ----------     ----------
        |             |                  |
        |        Positional or keyword   |
        |                                  +-- Keyword only
        +-- Positional only
```

Esempio definizione

```
>>> def args_demo(arg1, x=1, *args, **kwargs):
...     print("arg1 = ", arg1)
...     print("x = ", x)
...     print("args = ", args)
...     print("kwargs = ", kwargs)
...
```

4.2 Chiamata

In chiamata si:

- vanno specificati tutti i parametri posizionali (senza default);

- i posizionali vanno posti prima dei keyworded;

- i posizionali posti senza `nome=` verranno associati nell'ordine dato in definizione; se si specificano tutti `nome=valore` l'ordine può differire dalla definizione

```
>>> args_demo("asd", "baz", 2, [1,2,3], kw1=1, kw2=5)
arg1 =  asd
x =  baz
args =  (2, [1, 2, 3])
kwargs =  {'kw1': 1, 'kw2': 5}
>>> args_demo(1, 2, 3, foo = 6, baz = 7)
arg1 =  1
x =  2
args =  (3,)
kwargs =  {'foo': 6, 'baz': 7}
```

4.2.1 Valutazione dei valori di default

Questa:

- avviene nel punto in cui la funzione è stata *definita*, non quando viene chiamata, e il valore valutato viene conservato per le future chiamate

```
>>> x = 5

>>> def f(arg = x):
...     print(arg)
...
>>> x = 6
>>> f()
5
```

- se il valore di default è modificabile (lista, dict, classe) e viene modificato entro la funzione, la versione *cambiata* sarà conservata per le prossime chiamate (cosa raramente voluta)

```
>>> # qui un intero (1 valutato in definizione) è immodificabile quindi
>>> # eventuali entro la funzione non intaccano le prossime chiamate
>>> def f(x = 1):
...     print(x)
...     x = 2
...
>>> f()
1
>>> f()
1

>>> # qui L è una lista modificabile. Se la modifichiamo entro funzione il valore
>>> # verrà ritrovato nelle prossime chiamate
>>> def f(x, L = []): # una lista è modificabile
...     L.append(x)
...     return L
...
```

```
>>> f(1)
[1]
>>> f(2)
[1, 2]
>>> f(3)
[1, 2, 3]
```

Se non si vuole che il valore di default sia condiviso tra successive chiamate scrivere una funzione come la seguente

```
def f(x, L = None):
    if L is None:
        L = []
    L.append(x)
    return L
```

4.2.2 Valore ritornato

Se:

- si utilizza l'istruzione `return`, viene restituito dalla funzione alla chiamante un determinato dato fornito come argomento di `return`;
- se non si specifica nulla (o `return` senza argomenti) viene restituito `None`.

4.2.3 Unpacking di liste/tuple/dict in chiamata

Si può usare `*` (per lista, tuple) o `**` (dict) prima del nome della variable per spacchettare gli argomenti. Un esempio

```
>>> def foo(x,y,z):
...     print("x=" + str(x))
...     print("y=" + str(y))
...     print("z=" + str(z))
...
>>> l = [1,2,3] # esempio con lista
>>> foo(*l)
x=1
y=2
z=3

>>> d = {'z':'foo','x':'bar','y':'baz'} # esempio con dict
>>> foo(**d)
x=bar
y=baz
z=foo
```

4.3 Regole di scope

Vediamo le regole con cui Python cerca i valori delle variabili/nomi forniti in programmazione.

4.3.1 Namespace

Un *namespace* è abbinamento di nomi ad oggetti presenti in memoria; sono *creati in diversi momenti* e hanno *differente durata*. I principali sono:

- i nomi **builtin**: creato all'avvio dell'interprete e dura sino al termine dell'esecuzione;
- i nomi di un **modulo** (`__main__` o moduli importati): è reso disponibile quando il modulo viene caricato (e anche esso generalmente dura sino al termine dell'esecuzione);
- i nomi di **funzione**: creato alla chiamata, viene distrutto quando la funzione ritorna o solleva una eccezione non gestita[1].

Per ottenere la lista di nomi di un namespace si utilizza `dir`:

```
>>> import sys

>>> dir(__builtins__) ## nomi builtin del linguaggio
['__class__', '__class_getitem__', '__contains__', '__delattr__', '__delitem__', '__dir__', '__
>>> dir()             ## nomi nel modulo globale (workspace)
['Color', 'Counter', 'Enum', 'Flag', 'MyClass', 'MyClass2', 'Right', 'Right2', 'S', 'State', 'W
>>> dir(sys)          ## nomi di un modulo importato
['__breakpointhook__', '__displayhook__', '__doc__', '__excepthook__', '__interactivehook__', '

>>> # nomi in una funzione
>>> def f():
...     a = 1
...     b = 2
...     print(dir())
...
>>> f()
['a', 'b']
```

4.3.2 Attributi

Qualsiasi nome che segue un punto: ad esempio in `z.real`, `real` è un attributo di `z` (qualsiasi cosa sia).
Gli attributi possono essere *read-only* o *scrivibili*; nel secondo caso:

- è possibile assegnarvi qualcosa mediante `x.attributo = valore`;
- è possibile eliminarli mediante `del x.attributo`, che rimuove attributo da `x`.

4.3.3 Scoping

All'interno della chiamata di una funzione, la ricerca di un nome avviene nel seguente ordine:

1. nel namespace della *funzione corrente*;

[1] Le funzioni ricorsive hanno un namespace per ogni chiamata

2. nella funzione *enclosing* (quella all'interno del quale la funzione corrente è stata definita[2]); dopodichè la *enclosing della enclosing*, e così via;
3. il *namespace del modulo* corrente, sia esso main o importato
4. il namespace delle *builtin* functions.

Eccezioni: `nonlocal` e `global` Alcuni casi particolari:

- `nonlocal` serve per dichiarare nomi che devono essere presi non dal namespace corrente ma da quelli enclosing

```
>>> a = 1

>>> def scope_local():
...     a = 2
...     print(a)
...
>>> scope_local()
2

>>> def scope_nonlocal_read():
...     a = 3
...     def nested():
...         nonlocal a
...         print(a)
...     nested()
...
>>> scope_nonlocal_read()
3

>>> def scope_nonlocal_write():
...     a = 3
...     def nested():
...         nonlocal a
...         a = 4
...     nested()
...     print(a)
...
>>> scope_nonlocal_write()
4
```

- se un nome è dichiarato mediante `global` la lettura e scrittura da tale variabile va a inficiare il namespace del modulo, indipendentemente da dove essa sia stata effettuata

```
>>> a = 1

>>> def scope_global():
...     global a
...     print(a)
```

[2] Questo è quello che permette le *function factory*.

```
...
>>> scope_global()
1
```

4.4 Funzioni anonime (lambda)

Le funzioni anonime:

- sono create mediante la keyword `lambda`. dove i parametri di input sono separati dal valore restituito da `:`
  Ad esempio la seguente ritorna la somma dei due argomenti passati:

  ```
  lambda a, b: a + b
  ```

  Possono essere assegnate (volendo) comportandosi come normali funzioni ma questo è considerato bad practice da taluni

  ```
  >>> x = lambda a, b : a * b
  >>> x(5, 6)
  30
  ```

- possono essere usate dove è necessaria una funzione (il suo nome). Ad esempio anche con:

  ```
  >>> (lambda a, b: a+b)(1, 2)
  3
  ```

- sono limitate a *una singola espressione* come corpo

4.5 Programmazione funzionale

Le funzioni sono first class object (quindi possono essere date in input e ritornate come output) e ciò rende possibile la programmazione funzionale. In questa si possono sfruttare caratteristiche del linguaggio come:

- funzioni builtin tipiche della pf: `map`, `filter` etc
- funzioni anonime definite mediante `lambda`
- per i dati analizzati: *iterabili* e *iteratori* (quindi anche generatori ed espressioni generatrici) e le funzioni utili su di essi (es `enumerate`, `sorted`, `any`, `all`, `zip`)

A livello di pacchetti

- `itertools`: iteratori comuni e funzioni per elaborarli
- `functools`: high order functions (funzioni che processano funzioni modificandole)
- `operator`: funzioni che corrispondono agli operatori del python e possono aiutare in un approccio funzionale (evitandoci di scrivere funzioni triviali per effettuare singole operazioni)

4.5.1 Funzioni classiche

4.5.1.1 `map` (= `Map`/`lappy`)

La builtin

```
map(f, iterA, iterB, ...)
```

restituisce un iteratore sulla sequenza che applica la funzione con argomenti presi dagli iterabili passati:

```
f(iterA[0], iterB[0]), f(iterA[1], iterB[1]),  ....
```

Se applicata con

- un singolo iterabile (e una funzione che prende in input un solo argomento) è di fatto equivalente a `lapply` di R

  ```
  >>> a = ['sentence', 'fragment']
  >>> list(map(str.upper, a))
  ['SENTENCE', 'FRAGMENT']
  ```

- due/più iterabili (uno per ciascun argomento della funzione passata) è equivalente a `Map`

  ```
  >>> b = ["foo", "bar"]
  >>> list(map(lambda x, y: f"{x} + {y}", a, b))
  ['sentence + foo', 'fragment + bar']
  ```

4.5.1.2 `itertools.starmap`

Applicata ad un singolo iterabile crea un iteratore che valuta la funzione utilizzando argomenti ottenuti dall'iterabile; da utilizzare al posto di `map` quando gli input sono già stati raggruppati (iterabile di iterabili) o zippati nell'iterabile passato

```
>>> from itertools import starmap

>>> def custom_f(a, b, c):
...     return(a * b - c)
...
>>> x = (2,5,2)
>>> y = (3,2,1)
>>> z = (10,3,2)

>>> # qui applichiamo la funzione prendendo sequenzialmente argomenti da x, poi y e
>>> # poi da z
>>> list(starmap(custom_f, [x, y, z]))
[8, 5, 28]

>>> # qui prendiamo in parallelo da tutti e tre
>>> list(starmap(custom_f, zip(x, y, z)))
[-4, 7, 0]
```

4.5.1.3 `functools.reduce`

Applica una funzione che prende in input due parametri e ne restituisce uno agli elementi di una sequenza:

- la funzione è applicata ai primi due, il risultato applicato insieme al terzo elemento, e così via
- se `initializer` è presente viene piazzato prima della sequenza nel calcolo e funge da default se la sequenza è vuota;

```
>>> from functools import reduce
>>> from operator import add

>>> reduce(add, [1,2,3])
6
>>> reduce(add, [1,2,3], 5)
11
```

4.5.1.4 `itertools.accumulate`

A differenza di `functools.reduce` (che da il risultato finale) restituisce un iteratore sui risultati parziali:

```
>>> from itertools import accumulate
>>> from operator import add

>>> cumsum = accumulate([1,2,3], add)
>>> list(cumsum)
[1, 3, 6]
```

4.5.1.5 `filter`

```
filter(predicate, iter)
```

ritorna un iteratore su tutti gli elementi che rispettano un `predicate`, ossia una funzione che restituisce `True` o `False`. Per funzionare con filter, il predicato deve prendere in input un singolo parametro

```
>>>  # funzione per selezionare i pari (x%2==0 è True)
>>> list(filter(lambda x: x%2==0, range(10)))
[0, 2, 4, 6, 8]
```

Su iteratori funzionalità analoghe si hanno con `filterfalse` e `takewhile` di `itertools`

4.5.2 Partialling

Consiste nel creare una copia di una funzione con uno o più argomenti settati ad un default

4.5.2.1 functools.partial

Per parzializzare funzioni

```
>>> from functools import partial

>>> def spam(a, b, c, d):
...     print(a, b, c, d)
...
>>> s1 = partial(spam, 1)        # a = 1
>>> s1(4, 5, 6)
1 4 5 6

>>> s2 = partial(spam, d = 42)   # d = 42
>>> s2(4, 5, 6)
4 5 6 42

>>> s3 = partial(spam, 1, 2, d = 42)   # a = 1, b = 2, d = 42
>>> s3(5)
1 2 5 42
```

4.5.2.2 functools.partialmethod

Per parzializzare metodi

```
from functools import partialmethod

class Cell:

    def __init__(self):
        self._alive = False

    @property
    def alive(self):
        return self._alive

    # general method ...
    def set_state(self, state):
        self._alive = bool(state)

    # ... and partialled methods
    set_alive = partialmethod(set_state, True)
    set_dead = partialmethod(set_state, False)


c = Cell()
c.alive # False

c.set_alive()
c.alive # True
```

4.5.3 Function factory

Le function factory fanno uso della capacità del linguaggio di ritornare una funzione che fa uso del namespace della chiamante per la risoluzione di alcune free variable. Vediamo una implementazione di una function factory che crea funzioni potenze in base al parametro passatogli

```
>>> def make_power(n):
...     def power(x):
...         print(x ** n)
...     return power
...
>>> square = make_power(2)
>>> square(3) # restituisce 9
9

>>> # con funzione anonima
>>> def lambda_power(n):
...     return lambda x: print(x ** n)
...
>>> squarel = lambda_power(2)
>>> squarel(3)
9
```

4.5.4 Composizione di funzioni

Sfruttando le function factory per comporre diverse funzioni in una sola si può definire la seguente

```
>>> def compose(*funs):
...     """
...     Return a new function which is composition in math sense
...     compose(f,g,...)(x) = f(g(...(x)))
...     """
...     def worker(data, funs = funs):
...         result = data
...         for f in reversed(funs):
...             result = f(result)
...         return result
...     return worker
...
>>> def add2(x):
...     return x+2
...
>>> def mul2(x):
...     return x*2
...
>>> f = compose(add2, mul2) # 2x + 2
>>> g = compose(mul2, add2) # 2*(x+2)

>>> X = [1,2,3]
>>> [f(x) for x in X]
```

```
[4, 6, 8]
>>> [g(x) for x in X]
[6, 8, 10]
```

Alternativamente, `functools.reduce` può essere utilizzata per comporre una lista di funzioni, ad esempio:

```
>>> import functools

>>> def compose(f, g):
...     return lambda x: f(g(x))
...
>>> funcs = [lambda s: s + "a",
...          lambda s: s + "j",
...          lambda s: s + "e",
...          lambda s: s + "j",
...          lambda s: s + "e"]
>>> # questo è necessario se compose è definita
>>> # applicando la funzione sinistra come seconda (come in math) invece
>>> # di prima, come pensiamo a livello di logica sopra
>>> funcs.reverse()

>>> worker = functools.reduce(compose, funcs)
>>> worker("brazorv_")
'brazorv_ajeje'
```

4.5.5 Decorators

Un decorator è una funzione, solitamente[3], che wrappa un'altra funzione modificandone il comportamento standard in qualche modo

4.5.5.1 Definizione e utilizzo

La definizione è del tipo:

```
def decorator(fun):
    def worker:
       # function definition using fun
    return worker
```

Una volta definito possiamo usarlo

- prima definendo la funzione da decorare e poi decorandola

  ```
  def undecorated():
      # do something

  dec = decorator(undecorated)  # dec is decorated
  ```

- mediante una sintassi compatta equivalente dove viene prefisso il nome del decoratore alla definizione della funzione da decorare

[3] Decorator può essere qualsiasi callable, ovvero un oggetto che presenta il metodo `__call__`

```
@decorator
def undecorated():    # undecorated is actually decorated
    # do something
```

- i decorator possono essere concatenati, facendo si che ad una funzione base vengano applicati più decoratori contemporaneamente (aggiungendo feature in maniera pulita).

```
@decorator1
@decorator2
def undecorated():    # undecorated is actually double-decorated
    # do something
```

4.5.5.2 Esempi semplici

Memoization Per renderla più veloce una funzione che viene utilizzata più volte si puo possono salvare i risultati in una cache che verrà consultata alla prossima chiamata prima (facendo eseguire la funzione decorata solo se i risultati non siano già disponibili. Vediamo un esempio con la sequenza di fibonacci

```
>>> def memoize(f):
...     cache = {}
...     def helper(x):
...         if x not in cache:
...             cache[x] = f(x)
...         return cache[x]
...     return helper
...

>>> @memoize
... def fib(n):
...     if n in (0,1):
...        return n
...     else:
...        return fib(n - 1) + fib(n - 2)
...

>>> fib(1)
1
>>> fib(1) # using cache, not computing
1
```

Decorator multipli Se vogliamo aggiungere sia la memoizzazione che il logging alla funzione `fib` di cui prima, definiamo prima i due decorator `memoize` e `trace`, dopodichè decoriamo la definizione di `fib`

```
>>> def trace(f):
...     def helper(x):
...         call_str = f"{f.__name__}({x})"
...         print(f"Calling {call_str} ...")
...         result = f(x)
...         print(f"... returning from {call_str} = {result}")
```

```
...         return result
...     return helper
...
>>> @memoize
... @trace
... def fib(n):
...     # stesso codice di prima
...     if n in (0,1):
...         return n
...     else:
...         return fib(n - 1) + fib(n - 2)
...
>>> fib(3)
Calling fib(3) ...
Calling fib(2) ...
Calling fib(1) ...
... returning from fib(1) = 1
Calling fib(0) ...
... returning from fib(0) = 0
... returning from fib(2) = 1
... returning from fib(3) = 2
2
>>> fib(1)
1
>>> fib(4)
Calling fib(4) ...
... returning from fib(4) = 3
3
```

4.5.5.3 Decorator con parametri

I decoratori visti sin'ora non si prestano ad essere configurati (ossia ad utilizzare parametri. Il seguente codice

```
@decorator(params)
def func_name():
    ''' Function implementation'''
```

è equivalente a

```
func_name = (decorator(params))(undecorated_implementation)
```

L'interpretazione avviene da sinistra a destra: viene chiamato il decoratore col suo parametro; questo deve ritornare una funzione (`inner`, di sotto) che elabora la funzione passatagli in sede di chiamata (restituendone una versione modificata `wrapper`).
Un esempio di decoratore con parametro (temporizza il codice, il parametro `n` serve per scegliere il numero di esecuzioni della funzione

```
def timeit(n=1):     # la funzione esterna prende in input i parametri del decoratore
    def inner(f):    # l'intermedia è la funzione utilizzata in chiamata (come in prec
        def wrapper(*args, **kwargs):    # la piu interna i parametri della chiamata
```

```
            start_time = _time.perf_counter()
            for i in range(n):
                rval = f(*args, **kwargs)
            stop_time = _time.perf_counter()
            elapsed = stop_time - start_time
            function_name = f.__name__
            msg_start = f"{n} calls of" if n > 1 else "Function"
            msg_end = f" (mean: {elapsed/n:.4f} secs)" if n > 1 else "."
            msg = f"{msg_start} {function_name} [{args=} {kwargs=}] " \
                f"took {elapsed:.2f} secs{msg_end}"
            print(msg)
            return rval
        return wrapper
    return inner


# esempio di utilizzo per temporizzare tre esecuzioni ad ogni chiamata
@timeit(n=3)
def test2():
     time.sleep(2)

test2()
```

I decoratori con parametri vanno sempre chiamati con aperta e chiusa direi, anche se si vogliono utilizzare i valori di default

```
@timeit()
def test3:
    pass
```

4.5.5.4 Decoratori già disponibili

Alcuni utili sono

- `functools.cache` memorizza i risultati di una funzione in un dict e controlla alla seconda chiamata che non sia già disponibile (tipo memoize usata sotto)
- ...

4.5.6 Single e multiple dispatch

4.5.6.1 Single dispatch (function overloading)

Le funzioni con single dispatch sono tipo le S3 di R, che stabiliscono come comportarsi (evitando `if`/`elif`) sulla base dell'input (un parametro) fornito. Per definire:

- una *funzione generica* `gen` la si decora con `functools.singledispatch`: dopodiché si definiranno gli handler per tipo di dato decorandoli con `@gen.register`
- un metodo di classe come generico si usa (`functools.singledispatchmethod`) (qui tralasciata)

```
>>> from functools import singledispatch

>>> @singledispatch
... def f(arg, verbose = False):
...       print("Unhandled arg")
...
>>> @f.register
... def _(arg: int, verbose = False):
...       print(arg, "is integer")
...       if verbose:
...             print("f call was verbose too")
...

>>> @f.register
... def _(arg: str, verbose = True):
...       print(arg, "is a string")
...       if verbose:
...             print("f call was verbose too")
...

>>> f(3)                          # tipi conosciuti
3 is integer
>>> f("foo")
foo is a string
f call was verbose too
>>> f("bar", verbose = False)
bar is a string
>>> f({'planet':'earth', 'region':'europe', 'prefix':39}) # tipo non conosciuto da de
Unhandled arg
```

La definizione si può veder scritta anche come segue, dove il tipo di arg è passato a f.register

```
>>> @f.register(list)
... def _(arg, verbose = True):
...       print(arg * 2)
...
>>> f([1,2,3])
[1, 2, 3, 1, 2, 3]
```

Questa definizione è necessaria, utilizzata in stack, se vogliamo registrare uno stesso metodo per dati differenti

```
>>> @f.register(float)
... @f.register(bool)
... def _(arg, verbose = False):
...       print(arg * 2)
...
>>> f(2.5)
5.0
>>> f(True)
2
```

4.5.6.2 Multiple dispatch

Consiste nel programmare una funzione per comportarsi diversamente a seconda dei tipi (di più di un parametro) passati.
Si implementa mediante `multimethod` (dall'omonimo pacchetto) che viene applicato ripetutamente alla generica e ai vari handler specifici.
Un esempio che riproduce il funzionamento di `*` con numeri e stringhe:

```
>>> from multimethod import multimethod

>>> @multimethod
... def test(a, b): # default senza specificare il tipo
...     print("boo")
...
>>> @multimethod
... def test(a: int, b: int): # particolarizzando il tipo
...     return a * b
...
>>> @multimethod
... def test(a: str, b: int):
...     return a * b
...
>>> test(2, 3)
6
>>> test("a", 3)
'aaa'
>>> test("e", "qui?")
boo
```

Un esempio col metodo di una classe: definiamo `do` come l'interfaccia pubblica al multimethod sottostante per gestire i parametri passati in inizializzazione:

```
from dataclasses import dataclass
from multimethod import multimethod

@dataclass
class Test:
    x: int|str
    y: int|str|None = None

    def do(self):
        self._dispatch(self.x, self.y)

    @multimethod
    def _dispatch(self, a, b): # default case
        print("dunno")

    @multimethod
    def _dispatch(self, a: int, b: None):
        print("int x none")

    @multimethod
```

```
    def _dispatch(self, a: str, b: None):
        print("str x none")

    @multimethod
    def _dispatch(self, a: int, b: str):
        print("int x str")

    @multimethod
    def _dispatch(self, a: str, b: str):
        print("str x str")


Test(1).do() # int x none
Test("test").do() # str x none
Test(1, "test").do() # int x str
Test("test", "test").do() # str x str
```

4.6 Altri argomenti

4.6.1 atexit

Similmente a `on.exit` di R possiamo registrare funzioni che vengano eseguite prima dell'uscita da una funzione mediante il decoratore `atexit.register`

```
import atexit

# General before exit actions in exit_from_main
@atexit.register
def before_exit_from_main():
    print("Before exiting from main")


def my_fun():
    # function specific act
    @atexit.register
    def before_exit_from_function():
        print("Before exiting from my_fun")

    print("Within my_fun")


print("In main")
my_fun()
```

Che una volta fatto eseguire farà

```
l@ambrogio:~/src/tests/python$ python atexit.py
In main
Within my_fun
Before exiting from my_fun
Before exiting from main
```

Se

- necessario registrare una chiamata ad una funzione con parametri utilizzare esplicitamente `atexit.register`

```
def goodbye(name, adjective):
    print(f'Goodbye {name}, it was {adjective} to meet you.')

atexit.register(goodbye, 'Donny', 'nice')
```

- si registrano più funzioni (es nell'ordine A, B, and C), atexit le eseguirà in ordine inverso rispetto alla registrazione (C, B, A).
- necessario togliere una registrazione utilizzare `atexit.unregister`

Capitolo 5

Input/Output

Contents

5.1 Accesso al filesystem 37
5.1.1 Ottenere/cambiare directory di lavoro 37
5.1.2 Listing di directory, glob files 37
5.1.3 Creazione/rimozione di file/directory 37
5.1.4 File e directory temporanei 37
5.1.5 Paths e metodi utili 37
5.2 Salvataggio/importazione file 37
5.2.1 Testo semplice 37
5.2.2 `csv`/`tsv` 38
5.2.3 JSON 38
5.2.4 pickle 39
5.3 File di configurazione 39
5.4 Esecuzione di programmi esterni 40
5.4.1 `run` 40
5.4.2 `Popen` 40
5.5 Parsing opzioni da linea di comando 41
5.5.1 `sys.argc` e `sys.argv` 41
5.5.2 Modulo `argparse` 41
5.6 Accesso variabili d'ambiente 42


```
>>>   import polars as pl
  File "<stdin>", line 1
    import polars as pl
IndentationError: unexpected indent
>>>   pl.Config.set_ascii_tables(True) # altrimenti la stampa di df da problemi
  File "<stdin>", line 1
    pl.Config.set_ascii_tables(True) # altrimenti la stampa di df da problemi
IndentationError: unexpected indent
```

5.1 Accesso al filesystem

Oggigiorno si usa `pathlib`, per alcune cose marginali rimasto `os` e `shutil`.

```
>>> from pathlib import Path
>>> import os
>>> import shutil
```

5.1.1 Ottenere/cambiare directory di lavoro

```
>>> # ottenere la directory
>>> os.getcwd()
'/home/l/.sintesi/sintesi_cs'
>>> Path.cwd()
PosixPath('/home/l/.sintesi/sintesi_cs')

>>> # cambio directory
>>> os.chdir('/tmp')
```

5.1.2 Listing di directory, glob files

```
>>> d = Path("/home/l/.sintesi")

>>> # listing di directory
>>> list(d.iterdir()) # paths del contenuto (iteratore)
[PosixPath('/home/l/.sintesi/sintesi_cs'), PosixPath('/home/l/.sintesi/sintesi_biosta

>>> # glob/matching nome file
>>> pdf1 = sorted(d.glob("*/*.pdf"))  # cerca nella sottodirectory figlie
>>> pdf2 = sorted(d.glob("**/*.pdf")) # cerca in tutto l'albero
>>> pdf3 = sorted(d.rglob("*.pdf"))   # stessa cosa di sopra ma più compatta
```

5.1.3 Creazione/rimozione di file/directory

```
>>> # Creazione path/file
>>> d = Path('/tmp/barbaz/whahaa/yeah')

>>> # Creazione directory
>>> d.mkdir(parents = True) # parents se vogliamo creare tutto l'albero

>>> # creazione in maniera safe
>>> try:
...     d.mkdir(parents = True)
... except FileExistsError:
...     pass
...

>>> # Rimozione directory con tutto il contenuto
>>> rm = Path('/tmp/barbaz')
>>> # rm.rmdir() # erore: cartella deve essere vuota...
>>> shutil.rmtree(rm) # vedere dopo per shutil
```

```
>>> # Creazione rimozione di file
>>> f = Path('/tmp/asdomar.txt')
>>> f.touch()
>>> f.unlink()
```

5.1.4 File e directory temporanei

```
>>> from tempfile import TemporaryFile
>>> from tempfile import NamedTemporaryFile
>>> from tempfile import TemporaryDirectory


>>> # File con path (è quello che si vuole molto probabilmente)
>>> # ------------------------------------------------------------
>>> with NamedTemporaryFile() as f:
...     print(f.file)  # file object
...     print(f.name)  # path
...     # fai cose con f
...
<_io.BufferedRandom name='/tmp/tmpqwjapucv'>
/tmp/tmpqwjapucv
>>> # qui il file non c'è più

>>> # File senza nome
>>> # ---------------
>>> with TemporaryFile('w+t') as f:
...    f.write("Hello World\n")
...    f.write("Testing\n")
...    # ritorna ad inizio file e leggi quanto scritto
...    f.seek(0)
...    data = f.read()
...
12
8
0
>>> # qui il file non c'è più ma ..
>>> data
'Hello World\nTesting\n'

>>> # Directory
>>> # ---------
>>> with TemporaryDirectory() as dirname:
...     print("dirname is: ", dirname)
...     ## use the directory
...
dirname is:  /tmp/tmp_14vydxg
>>> # qui directory e suo contenuto non c'è più
```

Il mode è `w+t` per il testo o `w+b` per binario: si è posto 'w' per permettere sia lettura che scrittura che è utile qua, dato che chiudere il file implicherebbe

distruggerlo.

5.1.5 Paths e metodi utili

```
>>> f = Path("/usr/bin/python")
>>> d = Path("~/.sintesi")
>>> f2 = Path("/etc/apt/sources.list")
>>> f3 = Path("Makefile")
>>> subdir = "sintesi_cs"

>>> ## questi path possono esser usati dove è accettato un os.PathLike
>>> ## alternativamente per ottenere la rappresentazione in stringa

>>> str(d)
'~/.sintesi'
>>> str(f)
'/usr/bin/python'

>>> # sostituire la tilde per l'amor del cielo in paths
>>> de = d.expanduser()

>>> # test esistenza
>>> f.exists()
True
>>> d.exists() # attenzione a ~
False
>>> de.exists()
True

>>> # test tipologia
>>> f.is_file()
True
>>> d.is_dir() # attenzione a ~
False
>>> de.is_dir()
True

>>> # links
>>> f.is_symlink()
True
>>> f.readlink()  # follow just one redirection
PosixPath('python3')
>>> os.path.realpath(f) # follow all redirections
'/usr/bin/python3.13'

>>> # estrarre parti di un path
>>> f2.parent  # directory del file
PosixPath('/etc/apt')
>>> f2.name  # nome file
'sources.list'
>>> f2.stem  # nome file senza estensione
```

```
'sources'
>>> f2.suffix # estensione - per tar.gz usare suffixes
'.list'
>>> Path(f2.parent) / f2.stem # fpath_sans_ext (only one extension)
PosixPath('/etc/apt/sources')

>>> # controllare l'estensione (mediante glob)
>>> f2.match("*.list")
True

>>> # creazione di path mediante modifica di esistente
>>> d / subdir # concatenazione, alternativamente d.joinpath(subdir)
PosixPath('~/.sintesi/sintesi_cs')
>>> f.with_name("foo.list") # nome cambiato
PosixPath('/usr/bin/foo.list')
>>> f.with_stem("ssd")      # stem cambiato, stessa estensione
PosixPath('/usr/bin/ssd')
>>> f.with_suffix(".deb")   # estensione cambiata, stesso stem
PosixPath('/usr/bin/python.deb')
>>> f2.relative_to("/etc")  # path relativo, escludendo quanto passato
PosixPath('apt/sources.list')
>>> f3.absolute() # crea l'assoluto a partire da un relativo
PosixPath('/tmp/Makefile')
>>> f3.resolve()  # stessa cosa ma fixa anche symlink
PosixPath('/tmp/Makefile')
```

5.2 Salvataggio/importazione file

5.2.1 Testo semplice

La funzione `open` prende in input un path e un mode (`r` per la lettura, `w` per la scrittura, `a` per l'appending) restituisce un file object, quando si è finito di operare chiamare il metodo `close`:

```
f = open(file = '/tmp/test.txt', mode = 'r')
f.operazioni
f.close()
```

o meglio/più compattamente

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    f.operazioni
```

in questo secondo caso il file viene chiuso automaticamente all'uscita dal blocco anche in caso di eccezioni (warning, error).
È possibile anche utilizzare oggetti `pathlib.Path`, che hanno il metodo `open`:

```
from pathlib import Path
p = Path("/etc/motd")
with p.open() as f:
    lines = f.readlines()
print(lines)
```

5.2.1.1 Lettura

Alcuni metodi:

- `read` legge tutto il file e lo restituisce come stringa. Quando si raggiunge la fine del file, una chiamata successiva a read restituisce una stringa vuota

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    whole_file = f.read()
```

- `readline` legge una singola riga; anche qui quando si giunge alla fine del file restituisce una stringa vuota. `readlines` legge tutte le righe e le restituisce come lista

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    lines = f.readlines()
```

- se si vuole processare linea per linea si può ciclare su f come segue, dato che il file è un iteratore sulle righe

```
with open(file = '/tmp/test.txt', mode = 'r') as f:
    for line in f:
       # process line, es per stampa a video
       print(line)
```

5.2.1.2 Scrittura

Per scrittura su file si può usare `write` o `writelines` a seconda che l'input sia una stringa o una lista di stringhe; (alternativamente `print`

```
# scrittura di stringa (o """...""")
with open(file = '/tmp/test.txt', mode = 'w') as f:
    f.write("test") # write restituisce il numero di caratteri scritti
    # print("test", file = f) # alternativamente

# scrittura di una lista di linee
L = ["line1", "line2"]
with open(file = '/tmp/test.txt', mode = 'w') as f:
    f.writelines(L)
```

5.2.2 csv/tsv

Il modulo `csv` contiene le funzioni `reader` e `writer` per leggere formati testuali tabulari di vario tipo (anche separati da tab).
L'apertura/chiusura del file avviene come qualsiasi file di testo, come visto prima.

5.2.2.1 Lettura

Per importare un file e processarlo una riga alla volta `csv.DictReader` restituisce ciascuna riga come dict (altrimenti se può bastare utilizzare `csv.reader` che ritorna una lista)

```
# CSV esempio
#
# dir,repo,link   # attenzione a non lasciare spazi
# ~/.av/, https://lbraglia@bitbucket.org/lbraglia,
# ~/.configs/, https://lbraglia@github.com/lbraglia/.configs, ~/configs/
# ~/.dnd/, https://lbraglia@github.com/lbraglia/.dnd, ~/dnd

import csv
with open('setup.csv') as csvfile:
    reader = csv.DictReader(csvfile, quoting=csv.QUOTE_NONNUMERIC)
    for row in reader:
        dir = row['dir']   # attenzione a non lasciare spazi
        repo = row['repo']
        link = row['link']
        ...
```

5.2.2.2 Scrittura

Quello che si fa è creare un writer in cui si impostano le formattazioni di delimitatore, carattere di quoting e così via, per poi utilizzarlo per scrivere le righe. Un esempio con un dataset separato da tab

```
import csv
with open(file = '/tmp/dataset.tab', mode = 'w') as f:
    dataset = csv.writer(f,
                         delimiter = '\t',
                         quotechar = '"',
                         quoting = csv.QUOTE_NONNUMERIC)
    header = ['x', 'y', 'z']
    data   = [ 1,   2,  'a']
    dataset.writerow(header)
    dataset.writerow(data)
```

5.2.3 JSON

L'omonimo modulo `json` di python permette l'interfaccia. Le funzioni principali sono `dump` e `load` per scrivere su file, o `dumps` e `loads` (dump-s) per scrivere e leggere stringhe. Qua vediamo l'interfaccia con i file.

5.2.3.1 Scrittura

L'encoding dei tipi base (e loro combinazioni) segue tabella 5.1

```
>>> import json

>>> data = {
...   'name' : ['ACME', "FOO", "BAR"],
...   'shares' : [100, 200, 300],
...   'price' : (321, 9, 8912)
... }

>>> with open("/tmp/data.json", "w") as f:
```

Python	JSON
`dict`	object
`list`, `tuple`	array
`str`	string
`int`, `float`	number
`True`	true
`False`	false
`None`	null

Tabella 5.1: Encoding JSON

JSON	Python
object	`dict`
array	`list`
string	`str`
number (int)	`int`
number (real)	`float`
true	`True`
false	`False`
null	`None`

Tabella 5.2: Decoder JSON

```
...     json.dump(data, f)
...
```

5.2.3.2 Lettura

Il decoding dei tipi di base segue tabella 5.2.

```
>>> with open("/tmp/data.json", "r") as f:
...     data2 = json.load(f)
...
>>> print(data2)
{'name': ['ACME', 'FOO', 'BAR'], 'shares': [100, 200, 300], 'price': [321, 9, 8912]}
```

5.2.3.3 Formati custom

Per tipi di dati più elaborati (es classi custom, numeri complessi) vedere alcuni esempi qui: `https://realpython.com/python-json/`

5.2.4 pickle

Può salvare in binario qualsiasi struttura dati. Un esempio con un `dict` contenenti dati di varia natura a seguire.

```
>>> import pickle
>>> import pylbmisc as lb
>>> from pprint import pp

>>> # data to be saved
```

```
>>> a_dataset = lb.datasets.load().to_pandas()
>>> original = {i: a_dataset for i in range(2)}
>>> original["asd"] = 34
>>> original["qwe"] = [1, 2, 3]
>>> original["fun"] = lb.datasets.load

>>> # # display
>>> # pp(original)

>>> # save
>>> fpath = "/tmp/pickle_test.pkl"
>>> with open(fpath, "ab") as f:
...     pickle.dump(original, f)
...
>>> # load data
>>> with open(fpath, "rb") as f:
...     the_copy = pickle.load(f)
...
>>> # # display the copy
>>> # pp(the_copy)
```

5.3 File di configurazione

Per

- la lettura/scrittura di file `.ini` utilizzare la libreria `configparser`
- la lettura (solamente, per ora) di file `toml` (evoluzione degli `.ini`) è disponibile la libreria `tomllib`

```
import configparser

# Scrittura
data = {
    'customer': "ajeje",
    'acronym': "brazorv",
    'title': "un titolo",
    'created': "2020-01-01",
    'url': "lbraglia.altervista.org"
}
fpath = "/tmp/asd.ini"
configs = configparser.ConfigParser()
configs["project"] = data # project è la sezione del file .ini
with open(fpath, 'w') as f:
    configs.write(f)

# Lettura
configs = configparser.ConfigParser()
configs.read(fpath)
print(configs["project"]["url"])
```

```
# modifica
configs["project"]["url"] = "lbraglia.github.io"
```

5.4 Esecuzione di programmi esterni

Si usa la library `subprocess`

5.4.1 run

Se si vuole **attendere il termine del processo** utilizzare `run` (funzione di convenienza consigliata). Si specificano eventuali comandi composti da più token come lista

```
>>> import subprocess

>>> # Comandi semplici (prendi in input da comando esterno)
>>> # ------------------------------------------------------

>>> # eseguire un comando senza prendere risultati in input
>>> # in caso di parametri del comando dare una lista ["ls", "-l"]
>>> cmd = "ls -l -a -r -t".split(" ")
>>> rval = subprocess.run(cmd)  # risultati stampati a video
>>> rval  # ma non disponibili nell'output
CompletedProcess(args=['ls', '-l', '-a', '-r', '-t'], returncode=0)

>>> # salvando risultati (e standard error) in formato testuale
>>> child = subprocess.run(["ls"], capture_output=True, text=True)
>>> child.returncode
0
>>> child.stdout.split("\n")
['asd.ini', 'babel-OHrCbZ', 'babel-stable-4', 'corrmatrix.eps', 'corrmatrix.pdf', 'co
>>> child.stderr
''
```

5.4.2 Popen

Utilizzare **altrimenti** `Popen`, classe più generale che rappresenta un processo esterno quando la si istanzia si sta lanciando un progrmama esterno.

```
cmd = subprocess.Popen(args, stdin=None, stdout=None, stderr=None,
                       shell=False)
```

dove

- `args`: lista del comando da eseguire;
- `stdin`, `stdout`, `stderr`: come gestire input, output, and error del processo esterno. Di default `None` ereditano dal processo genitore. Utilizzare `subprocess.PIPE` per mandarli in pipe. In particolare `stdin=subprocess.PIPE` permette di inviare dati in input, mentre `stdout=subprocess.PIPE` cattura l'output;

- `text=True` fa si che input/output sian trattati come stringa, non bytes;
- `shell`: se settato a `True`, il comando è eseguito attraverso una shell (utile per eseguire comandi di shell complessi ma meno sicuro);
- `cwd`: setta la cwd del processo prima di eseguirlo
- `env`: setta environment variables

Di default *non attende* il ritorno del figlio; si può attendere se chiamiamo il metodo `comunicate`.
Alcuni esempi per replicare `subprocess.run` di sopra:

- prendere in input l'output/error fornito dal programma esterno

```
>>> ls = subprocess.Popen(["ls"],
...                       stdout=subprocess.PIPE,
...                       stderr=subprocess.PIPE,
...                       text=True)
>>> output, err = ls.communicate()
>>> output
'asd.ini\nbabel-OHrCbZ\nbabel-stable-4\ncorrmatrix.eps\ncorrmatrix.pdf\ncorrmatrix.png\ncu

>>> ls = subprocess.Popen(["ls", "/nonexistentdir"],
...                       stdout=subprocess.PIPE,
...                       stderr=subprocess.PIPE,
...                       text=True)
>>> output, err = ls.communicate()
>>> err
"ls: impossibile accedere a '/nonexistentdir': File o directory non esistente\n"
```

- inviare input ad un programma esterno a python e riprenderne l'output

```
>>> text_input = "first line\nsecond line"
>>> nl = subprocess.Popen(["nl"],
...                       stdin=subprocess.PIPE,
...                       stdout=subprocess.PIPE,
...                       text=True)
>>> output, err = nl.communicate(input=text_input)
>>> output  # le linee a cui è stato aggiunto il numerino da nl
'     1\tfirst line\n     2\tsecond line\n'
```

- concatenare programmi esterni, es `ls | nl | python` e prendere in input il risultato

```
>>> # ls non prende in input da nulla e butta nel pipe
>>> ls = subprocess.Popen(["ls"], stdout=subprocess.PIPE, text=True)
>>> # nl prende in input da ls e butta nel pipe
>>> nl = subprocess.Popen(["nl"], stdin=ls.stdout, stdout=subprocess.PIPE, text=True)
>>> ls.stdout.close() # di a ls di terminare
>>> output, err = nl.communicate()  # e ad nl di fare il suo
>>> output.split("\n")
['     1\tasd.ini', '     2\tbabel-OHrCbZ', '     3\tbabel-stable-4', '     4\tcorrmatrix.
```

- dare input con python, concatenare programmi esterni e prendere il risultato. Ad esempio `python lista parole | sort | nl | python`

```
>>> # ls non prende in input da nulla e butta nel pipe
>>> sort = subprocess.Popen(["sort"],
...                         stdin=subprocess.PIPE,
...                         stdout=subprocess.PIPE,
...                         text=True)
>>> nl = subprocess.Popen(["nl"], stdin=sort.stdout, stdout=subprocess.PIPE,
...                       text=True)
>>> sort.stdin.write("a\nx\nb\nz\nc")
9
>>> sort.stdin.close()
>>> output, err = nl.communicate()
>>> output.split("\n")
['     1\ta', '     2\tb', '     3\tc', '     4\tx', '     5\tz', '']
```

5.5 Parsing opzioni da linea di comando

Mi sono fatto anche `pylbmisc.utils.argparser` (basato su argparse) ma per la roba più rapida sotto basta e avanza.

5.5.1 `sys.argc` e `sys.argv`

Nel template

```
#!/usr/bin/env python3
import sys

print(sys.argv)
```

Per la chiamata senza parametri

```
l@m740n:~/pytests$ ./argparse_sysargv
['./argparse_sysargv']

l@m740n:~/pytests$ python argparse_sysargv
['argparse_sysargv']
```

Per la chiamata con parametri

```
l@m740n:~/pytests$ ./argparse_sysargv asd foo bar baz
['./argparse_sysargv', 'asd', 'foo', 'bar', 'baz']

l@m740n:~/pytests$ python argparse_sysargv asd foo bar baz
['argparse_sysargv', 'asd', 'foo', 'bar', 'baz']
```

5.5.2 Modulo `argparse`

Una dimostrazione veloce, per approfondimenti vedere la documentazione. Sia il template

```
#!/usr/bin/env python3
import argparse

parser = argparse.ArgumentParser()
parser.add_argument("infile")
parser.add_argument("outfile")
args = parser.parse_args()
print(args)
print(args.infile)
print(args.outfile)
```

Per l'invocazione senza argomenti da errore (sono attesi)

```
l@m740n:~/pytests$ ./argparse_tests
usage: argparse_tests [-h] infile outfile
argparse_tests: error: the following arguments are required: infile, outfile

l@m740n:~/pytests$ python argparse_tests
usage: argparse_tests [-h] infile outfile
argparse_tests: error: the following arguments are required: infile, outfile
```

Per l'invocazione con parametri

```
l@m740n:~/pytests$ ./argparse_tests asd foo
Namespace(infile='asd', outfile='foo')
asd
foo

l@m740n:~/pytests$ python argparse_tests asd foo
Namespace(infile='asd', outfile='foo')
asd
foo
```

5.6 Accesso variabili d'ambiente

Si usa `os.environ`. Se adottiamo un template

```
#!/usr/bin/python

import os

# print(os.environ) # un po too much
print(os.environ["SHELL"])
print(os.environ["BROWSER"])

# roba settata al volo
p1 = int(os.environ["PARAM1"])
p2 = int(os.environ["PARAM2"])
print(p1 + p2)
```

Si ha

```
l@m740n:~/pytests$ export PARAM1=1; export PARAM2=2 ;  python envvars.py
/bin/bash
librewolf
3
```

Capitolo 6

Object Oriented Programming

Contents

6.1 Classi 43
6.1.1 Definizione e scoping 43
6.1.2 Metodi 44
6.1.3 Condivisione dati 44
6.1.4 Data hiding 44
6.2 Ereditarietà 45
6.2.1 Singola 45
6.2.2 Multipla 45
6.3 Classi notevoli 45
6.3.1 `dataclass` 45
6.3.2 Iteratori 46
6.3.3 Context Managers 49

6.1 Classi

L'implementazione della programmazione ad oggetti si basa su trick di scope (cfr sezione 4.3).
La definizione di una classe semplicemente pone un altro namespace all'interno di quello nel quale ci si trova.

6.1.1 Definizione e scoping

La definizione di una classe fa uso di:

- `class` associato ad un nome;
- una stringa di documentazione opzionale
- vari `statement` di assegnazione di variabili/definizione di funzioni (con una sintassi particolare, i *metodi* della classe)

```
class NomeClasse:
    """
    Documentation
    """
    <statement-1>
    .
    .
    .
    <statement-N>
```

Una volta valutata la definizione viene creato un *oggetto classe*, ossia un *namespace* contenuto in quello dove è stato definito, che supporta supporta due cose:

1. riferirsi ai suoi attributi in lettura o scrittura (nel Python una classe può esser modificata dopo che è stata creata);
2. creare oggetti usando il nome della classe come se fosse una funzione: così facendo si creano *oggetti istanza*.
3. **scoping**: una volta istanziato un oggetto, la ricerca dei entro una classe (a parte le variabili locali ad un metodo) continua nel modulo dove la classe è definita (sia esso `__main__` o importato).

```
>>> b = "ciao"

>>> # definizione di classe
>>> class firstClass:
...     """La mia prima classe"""
...     a = 0
...     b = "miao"
...     def get_a(self):
...         return self.a
...     def set_a(self, x):
...         self.a = x
...     def test_scoping(self):
...         print(b)
...

>>> firstClass.a = 1          ## modifica di un attributo di una classe, volendo
>>> print(firstClass.__doc__) ## stampa la docstring della classe
La mia prima classe
>>> x = firstClass()          ## istanziamento usando il costuttore di default
>>> x.a                       ## nulla impedisce di accedere direttamente
1
>>> x.get_a()
1
>>> x.set_a(3)
>>> x.get_a()
3
>>> x.test_scoping()          # "ciao", non "miao" (per questo avremmo dovuto self.b)
ciao
```

6.1.2 Metodi

6.1.2.1 Definizione e chiamata

I metodi di una classe presentano una definizione particolare:

- il primo argomento serve per riferirsi all'oggetto istanziato: il nome `self` è arbitrario ma preferibile (standard);
- gli altri sono parametri normali da passare in chiamata del metodo

In sede di chiamata poi:

- `object.function()` è equivalente a chiamare `classe.function(object)`
- chiamare `object.function(x, y, z)` equivale a `classe.function(object, x, y, z)`

6.1.2.2 Costruttore custom

Se si desidera specificare un costruttore custom diverso da quello di default, si definisce una funzione di nome `__init__` che si occupa di inizializzare i valori (nel quale abbiamo messo anche inizializzatori di default):

```
>>> class Complex:
...     def __init__(self, realpart = 0, imagpart = 0):
...         self.r = realpart
...         self.i = imagpart
...     def value(self):
...         return('' + str(self.r)+ '+' + str(self.i) + 'i')
...
>>> x = Complex()
>>> x.value()
'0+0i'
>>> y = Complex(1, 2)
>>> y.value()
'1+2i'
```

6.1.3 Condivisione dati

I dati di una classe iniziano ad esistere dal momento in cui vengon assegnati, sia ciò in definizione della classe o usando un metodo nell'oggetto istanza. Pertanto:

- gli argomenti **inizializzati nella definizione della classe** sono *comuni* a tutti gli oggetti generati;
- gli argomenti **inizializzati mediante un metodo** sono *caratteristici* dell'oggetto istanziato.

```
>>> class Dog:
...     kind = 'canine'         # class variable shared by all instances
...     def __init__(self, name):
...         self.name = name    # instance variable unique to each instance
...
>>> d = Dog('Fido')
```

```
>>> e = Dog('Buddy')
>>> d.kind                  # shared by all dogs
'canine'
>>> e.kind                  # shared by all dogs
'canine'
>>> d.name                  # unique to d
'Fido'
>>> e.name                  # unique to e
'Buddy'
```

Attenzione a quando come *dato di classe vi è un tipo mutabile*: la chiamata di metodi da diverse istanze andrà a modificare un dato comune (e non è spesso quello che si vuole).

```
>>> class Dog:
...     tricks = []                  # Sbagliato: questo sarà condiviso da tutti i ca
...     def __init__(self, name):
...         self.name = name
...     def add_trick(self, trick):
...         self.tricks.append(trick)
...
>>> d = Dog('Fido')
>>> e = Dog('Buddy')
>>> d.add_trick('roll over')
>>> e.add_trick('play dead')
>>> d.tricks
['roll over', 'play dead']
```

```
>>> class Dog:                      # Versione corretta
...     def __init__(self, name):
...         self.name = name
...         self.tricks = []    # ok
...     def add_trick(self, trick):
...         self.tricks.append(trick)
...
>>> d = Dog('Fido')
>>> e = Dog('Buddy')
>>> d.add_trick('roll over')
>>> e.add_trick('play dead')
>>> d.tricks
['roll over']
>>> e.tricks
['play dead']
```

6.1.4 Data hiding

Nel Python

- non vi è un concetto di *data hiding*; di un oggetto istanziato si può accedere ai valori/funzioni senza problemi

- se si desidera **celare un elemento** gli si può dare un nome che inizi con "_" (cose che dovrebbero essere considerate come "private")
- per **incrementare la celatura**, se si da un nome che inizia con __, viene preceduto dal nome della classe ed underscore, come segue (*name mangling*):

```
>>> class Asd:
...     __a = 0  ## nome della variabile più due underscore
...
>>> foo = Asd()
>>> foo._Asd__a  ## accediamo ad a comunque, ma è faticoso farlo
0
```

6.2 Ereditarietà

6.2.1 Singola

Si ha che:

- la sintassi per definire una classe che eredita da un'altra è

```
class NomeClasseDerivata(NomeClasseBase):
    <statement-1>
    .
    .
    .
    <statement-N>
```

- nella ricerca nomi, nel caso nel caso non vengano trovati nella classe derivata si procederà nella classe base (e ricorsivamente nelle classi ad essa base);
- le classi derivate possono *specializzare i metodi*, ridefinendoli con il medesimo nome della classe base.

6.2.2 Multipla

- la definizione avviene come segue:

```
class DerivedClassName(Base1, Base2, Base3):
    <statement-1>
    .
    .
    .
    <statement-N>
```

- la classe eredita da tutte e tre le classi di base;
- la risoluzione di nomi funziona prima in profondità per `Base1` (cercando anche nelle classi dalle quali questa eredita), poi passando a `Base2` (e quindi in profondità) e a `Base3`(e in profondità), evitando di cercare due volte nella stessa classe se vi sono sovrapposizioni nell'albero genealogico.

6.3 Classi notevoli

6.3.1 `dataclass`

Il modulo `dataclasses` fornisce un decoratore da utilizzare con le classi che vogliamo battezzare come dataclass

```
from dataclasses import dataclass

@dataclass
class InventoryItem:
    """Class for keeping track of an item in inventory."""
    name: str
    unit_price: float
    quantity_on_hand: int = 0

    def total_cost(self) -> float:
        return self.unit_price * self.quantity_on_hand
```

Quello che questo decoratore fa è aggiungere un inizializzatore di default del tipo seguente, senza bisogno di specificarlo,

```
def __init__(self, name: str, unit_price: float, quantity_on_hand: int = 0):
    self.name = name
    self.unit_price = unit_price
    self.quantity_on_hand = quantity_on_hand
```

La `dataclass` aggiunge anche una `__repr__` gratuita per la stampa dei dati dell'oggetto (specificare `repr=False` nella funzione `field` esclude il dato dalla stampa)

6.3.1.1 `field`: dati mutabili, valori default, parametri

Se occorre specificare dati mutabili a livello di singola istanza (non condivisi) tra tutti gli oggetti di una determinata classe bisogna utilizzare `field` specificando la funzione utilizzata per creare l'istanza. Ad esempio se vogliamo un campo indirizzi email (lista di stringhe) che non sia condiviso tra tutti gli oggetti della classe dobbiamo programmare qualcosa del genere

```
from dataclasses import dataclass
from dataclasses import field

@dataclass
class Person:
    name: str
    address: str
    # email_addresses = []  # condiviso e sbagliato
    email_addresses: list[str] = field(default_factory=list)

l = Person(name = "Luca", address = "Via XYZ")
```

`field` e `default_factory` possono essere utilizzate per specificare una funzione che crea il valore assegnato di default se l'utente non specifica in chiamata, quindi ha anche altre applicazioni. Nel seguito la generazione di un id casuale

```
import random
import string

from dataclasses import dataclass
from dataclasses import field

# genera un id casuale
def generate_id() -> str:
    return "".join(random.choices(string.ascii_uppercase, k=12))

@dataclass
class Person:
    name: str
    address: str
    email_addresses: list[str] = field(default_factory=list)
    id: str = field(default_factory=generate_id)
```

Se si desidera che un parametro sia impostato ad un valore di default ma che non possa essere scelto dall'utente in chiamata si specifica `init=False` in field. Ad esempio per far sì che l'utente non possa scegliere l'id ma che questo sia generato da una funzione

```
@dataclass
class Person:
    name: str
    address: str
    email_addresses: list[str] = field(default_factory=list)
    id: str = field(init=False, default_factory=generate_id)

# questo da errore
l = Person(name="Luca", address="asd", id="foo")
```

Infine field accetta:

- un valore di default (utilizzato se l'utente non può o non vuole fornire in inizializzazione) con `default` (es `default=0` per un bank account saldo iniziale)
- `compare` (di default a `True`) che specifica se l'attributo è utilizzato nella comparazione (es per stabilire l'uguaglianza) o meno

6.3.1.2 Eseguire codice post inizializzazione: `post_init`

Se vogliamo eseguire del codice automaticamente post inizializzazione (es generare dati o inizializzare) definiamo la funzione `__post_init__` che verrà eseguita come nome succede. Ad esempio per creare una stringa per la ricerca a partire dai dati forniti in inizializzazione

```
class Person:
    name: str
    address: str
    email_addresses: list[str] = field(default_factory=list)
    id: str = field(init=False, default_factory=generate_id)
```

```
    search_string: str = field(init=False) # stringa che non può essere

    def __post_init__(self) -> None:
        self.search_string = f"{self.name} {self.address}"
```

6.3.1.3 Freezing di una dataclass

Significa impostarla che una volta inizializzata i suoi dati non possano essere modificati (es mediante semplice assegnazione)

```
@dataclass(frozen=True)
class Person:
    name: str
    address: str
    ...

l = Person(...)
l.name = "foo" # da errore
```

Ocio che anche i `post_init` falliranno se come sopra assegnano alla classe

6.3.1.4 Altri parametri utili del decoratore

Oltre a `frozen` vi sono altri parametri interessanti per il decoratore:

- `kw_only=True` in inizializzazione bisognerà specificare per esteso nome = valore e non verrà accettato il valore associato alla posizione della chiamata
- con `match_arg=False` si disabilita il structural pattern matching (uso con `match`) abilitato di default
- `slots=True`: sotto la scocca una dataclass è un dizionario molto avanzato. Se si abilita `slot` vi è un accesso molto più rapido e di base (miglioramenti del 20% a seconda dei casi). Non si usa di default perché slots rompe tutto quando si usa ereditarietà multipla, es quanto segue non funziona perché non si possono sommare dataclass basate su slots:

  ```
  @dataclass(slots=True)
  class Person:
     name:str
     address: str
     email: str

  @dataclass(slots=True)
  class Employee:
      dept: str

  class Worker(Person, Employee):
      pass
  ```

6.3.2 Iteratori

Il `for` del python è molto conciso e flessibile, si pensi a:

```
>>> List = [1, 2, 3]
>>> Set = (1, 2, 3)
>>> Dict = {'one': 1, 'two': 2}
>>> String = "asd"

>>> for element in List:
...     print(element)
...
1
2
3
>>> for element in Set:
...     print(element)
...
1
2
3
>>> for key in Dict:
...     print(key)
...
one
two
>>> for char in String:
...     print(char)
...
a
s
d
```

Quello che lo rende flessibile è il fatto di gestire in maniera standard quelli che in Python sono chiamati iterabili, ossia oggetti passibili di iterazione.

6.3.2.1 Funzionamento

Si ha che:

- *iterabile* è un oggetto che presenta un metodo `__iter__`, il quale restituisce un iteratore, oggetto che rappresenta un flusso di dati dell'iterabile considerato;
- un *iteratore* è un oggetto che rappresenta un flusso di dati e mediante il metodo `__next__` li ritorna un elemento alla volta (oppure ritorna `StopIteration` se non ve ne sono altri).

Ora vi sono due funzioni di utilità che servono per implementare il protocollo del for:

- `iter` prende in input un oggetto arbitrario e cerca di restituire un iteratore sui suoi dati (chiamando `__iter__`), oppure `TypeError` se non possibile;
- sull'iteratore possiamo utilizzare `next` (che chiama il `__next__`)

```
>>> s = 'abc'
```

```
>>> it = iter(s)
>>> it
<str_ascii_iterator object at 0x7f151b19fbe0>
>>> next(it)
'a'
>>> next(it)
'b'
>>> next(it)
'c'
>>> next(it)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
StopIteration

>>> iter(123) # questo da errore perché un intero non è iterabile
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'int' object is not iterable
```

Quindi complessivamente, lo statement `for`:

1. chiama innanzitutto `iter()` sull'oggetto che è in ciclo (il contenitore) ottenendone un iteratore;
2. chiama via via `next()` sull'iteratore permettendo cosi il processo di iterazione;
3. quando non vi sono altri elementi sui quali iterare, `next()` solleva l'eccezione `StopIteration` e `for` termina.

6.3.2.2 Implementazione mediante classe

Spesso si vuole creare classi/strutture di dati che siano iterabili; per farlo occorre:

- definire una classe con metodo `__iter__` (iterabile) che ritorni un oggetto con un metodo `__next__` senza parametri (rendendo l'oggetto ritornato un iteratore).
- caso classico: una classe ha sia `__next__` che `__iter__`. In tal caso è sufficiente che `__iter__` ritorni `self`.

```
>>> class Reverse:
...     """Iterator for looping over a sequence backwards."""
...     def __init__(self, data):
...         self.data = data
...         self.index = len(data)
...     def __iter__(self):
...         return self
...     def __next__(self):
...         if self.index == 0:
...             raise StopIteration
...         self.index = self.index - 1
```

```
...         return self.data[self.index]
...
>>> for char in Reverse('spam'):
...     print(char)
...
m
a
p
s
```

6.3.2.3 Implementazione mediante espressioni generatrici

Generatori semplici possono essere ottenuti mediante le espressioni generatrici, espressioni poste tra tonde (invece che quadre) che utilizzano una sintassi simile alle list comprehension. Alcuni esempi:

```
>>> squares = ((i*i for i in range(10)))
>>> type(squares)
<class 'generator'>
>>> sum(squares)
285

>>> data = 'golf'
>>> reversed = (data[i] for i in range(len(data) - 1, -1, -1))
>>> list(reversed)
['f', 'l', 'o', 'g']
```

Alcuni confronti:

- le espressioni generatrici sono compatte ma meno versatili rispetto alla definizione di un generatore
- rispetto a una list comprehension, le espressioni generatrici ritornano un iteratore che calcola il valore al bisogno; le list comprehension sono inutili o meno efficienti se si lavora con iteratori che ritornano uno stream infinito di valori o un numero molto alto

6.3.2.4 Implementazione mediante generatori

I generatori sono funzioni che creano degli iteratori:

- l'unica differenza dalle funzioni classiche è che usano `yield` quando vogliono ritornare dei dati;
- tutto quello che è possibile fare mediante la definizione di iteratori mediante classi è possibile farlo anche con i generatori; quello che rende questi ultimi interessanti è il fatto che i metodi `__iter__` e `__next__` sono generati automaticamente e complessivamente la programmazione è molto più chiara/compatta.

```
>>> def reverse(data):
...     for index in range(len(data) - 1, -1, -1):
...         yield data[index]
```

```
...
>>> # crea un iterabile e iteratore, ossia un oggetto che ha sia iter che next
>>> r = reverse('golf')
>>> r.__iter__
<method-wrapper '__iter__' of generator object at 0x7f151b153300>
>>> r.__next__
<method-wrapper '__next__' of generator object at 0x7f151b153300>

>>> for char in r:
...     print(char, end = ' ')
...
f l o g
```

Vediamo la differenza di funzionamento rispetto a una funzione classica:

- nel chiamare una funzione classica viene creato un namespace che contiene i dati e al `return` questo viene distrutto; una chiamata successiva alla stessa riparte con un namespace nuovo. I generatori possono essere pensati come funzioni dove il namespace non viene gettato all'uscita ma è disponibile alla successiva chiamata
- alla chiamata un generatore non ritorna un singolo valore: invece ritorna un oggetto generatore che supporta il protocollo degli iteratori. Quando si esegue `yield` il generatore restituisce l'espressione, ma a differenza di `return` l'esecuzione della funzione si sospende e le variabili locali sono preservate; alla prossima chiamata di `__next__` la funzione riprenderà l'esecuzione da capo.

6.3.2.5 Funzioni e operatori utili su iteratori

Funzioni Alcune funzioni builtin:

- su iteratori con dati logici `all` e `any` ritornano `True` rispettivamente se tutti gli elementi sono `True` o almeno uno lo è
- su iteratori con dati confrontabili, `max`, `min` ritornano l'elemento maggiore o minore, `sorted` ordina l'iteratore
- `enumerate` restituisce un oggetto involucro con un id progressivo
- `zip` prende in input più iterabili e restituisce un iteratore che genera tuple con un elemento di ciascun oggetto di partenza alla volta. Nel caso gli iterabili abbiano lunghezza diversa verrà prodotto
- per la programmazione funzionale sono utili `filter`, `map`

```
>>> all([True, True])
True
>>> any([False, False])
False
>>> max([1, 2, 10])
10
```

```
>>> A = [1,2,3]
>>> B = "letters"

>>> for a, b in zip(A, B):
...     print(a, b)
...
1 l
2 e
3 t
```

Operatori `in` e `not in`: la sintassi `X in iterator` ritorna `True` se `X` è ritrovato nell'iteratore

6.3.2.6 Il modulo itertools

Contiene funzioni per la creazione e gestione di iteratori

Creazione di nuovi iteratori

```
itertools.count()                ## 0, 1, 2, 3, 4, 5, 6, 7, 8, 9, ...
itertools.cycle([1, 2, 3, 4, 5]) ## 1, 2, 3, 4, 5, 1, 2, 3, 4, 5  ...
itertools.repeat('abc')          ## abc, abc, abc, abc, abc, abc  ...
itertools.chain(['a', 'b', 'c'], (1, 2, 3)) ##  a, b, c, 1, 2, 3
itertools.islice(range(10), 2, 8)    ##  2, 3, 4, 5, 6, 7
```

Selezione

```
itertools.filterfalse(predicate, iterable)
```

Crea un iteratore che elimina elementi da un iterabile laddove un predicato ad essi applicato è falso. Lo applichiamo ad una lista come esempio:

```
>>> import itertools

>>> def selector(x):
...      return x < 5
...
>>> res = itertools.filterfalse(selector, [1, 4, 6, 4, 1])
>>> list(res)
[6]
```

```
itertools.compress(data, selectors)
```

crea un iteratore che filtra gli elementi di `data` ritornando solo quelli che valuno `True` in `selectors`

```
>>> res = itertools.compress('ABCDEF', [1,0,1,0,1,1])
>>> list(res)
['A', 'C', 'E', 'F']
```

Grouping Vediamo:

```
itertools.groupby(iter, key_func = None)
```

si ha:

- `iter` un iterabile
- `key_func` è una funzione che restituisce un id per ogni elemento dell'iterabile

`groupby`

- assume che il contenuto di `iter` sia ordinato per chiave
- mette assieme tutti gli elements dell'iterable con stessa chiave, e ritorna uno stream di tuple di due elementi, con primo elemento la chiave e secondo elemento l'iteratore su tutti gli elementi con tale chiave

```
city_list = [('Decatur', 'AL'), ('Huntsville', 'AL'), ('Selma', 'AL'),
             ('Anchorage', 'AK'), ('Nome', 'AK'),
             ('Flagstaff', 'AZ'), ('Phoenix', 'AZ'), ('Tucson', 'AZ'),
             ...
            ]

def get_state(city_state):
    return city_state[1]

itertools.groupby(city_list, get_state) =>
  ('AL', iterator-1),
  ('AK', iterator-2),
  ('AZ', iterator-3), ...

where
iterator-1 =>
  ('Decatur', 'AL'), ('Huntsville', 'AL'), ('Selma', 'AL')
iterator-2 =>
  ('Anchorage', 'AK'), ('Nome', 'AK')
iterator-3 =>
  ('Flagstaff', 'AZ'), ('Phoenix', 'AZ'), ('Tucson', 'AZ')
```

Combinazioni e permutazioni

```
>>> list(itertools.combinations([1, 2, 3, 4, 5], 2))
[(1, 2), (1, 3), (1, 4), (1, 5), (2, 3), (2, 4), (2, 5), (3, 4), (3, 5), (4, 5)]
>>> list(itertools.combinations_with_replacement([1, 2, 3, 4, 5], 2))
[(1, 1), (1, 2), (1, 3), (1, 4), (1, 5), (2, 2), (2, 3), (2, 4), (2, 5), (3, 3), (3,

>>> list(itertools.permutations([1, 2, 3, 4, 5]))
[(1, 2, 3, 4, 5), (1, 2, 3, 5, 4), (1, 2, 4, 3, 5), (1, 2, 4, 5, 3), (1, 2, 5, 3, 4),
>>> list(itertools.permutations([1, 2, 3, 4, 5], 2))
[(1, 2), (1, 3), (1, 4), (1, 5), (2, 1), (2, 3), (2, 4), (2, 5), (3, 1), (3, 2), (3,
```

Prodotto cartesiano

```
>>> list(itertools.product('ABCD', 'xy'))
[('A', 'x'), ('A', 'y'), ('B', 'x'), ('B', 'y'), ('C', 'x'), ('C', 'y'), ('D', 'x'), ('D', 'y')
```

6.3.3 Context Managers

Un context manager è un oggetto che fornisce informazioni contestuali o esecuzione automatica ad una azione ed è quello che funziona col protocollo/keyword `with`. Il più conosciuto è `open` grazie al quale `f` sarà automaticamente chiusa all'uscita dal manager (il blocco):

```
with open('file.txt') as f:
    contents = f.read()
```

Un context manager può essere implementato mediante classe o mediante generatore; la classe è meglio se vi è un tot di dati/logica da incapsulare, la funzione è meglio se abbiamo a che fare con casi più semplici.

6.3.3.1 Implementazione mediante classe

Per duplicare `open` semplicemente si programma:

```
class CustomOpen(object):
    def __init__(self, filename):
        self.file = open(filename)

    def __enter__(self):
        return self.file

    def __exit__(self, ctx_type, ctx_value, ctx_traceback):
        self.file.close()

with CustomOpen('file') as f:
    contents = f.read()
```

I due metodi speciali utilizzati da with sono `__enter__` e `__exit__`. Il funzionamento:

- `CustomOpen` è inizializzata con `__init__`
- `__enter__` è chiamata e qualsiasi cosa ritorni è assegnato a `f`
- quando il blocco di `with` finisce, viene chiamata `__exit__`

6.3.3.2 Implementazione mediante generatore

Bisogna utilizzare `contextmanager` dalla libreria `contextlib`:

```
from contextlib import contextmanager

@contextmanager
def custom_open(filename):
    f = open(filename)
```

```
    try:
        yield f
    finally:
        f.close()

with custom_open('file') as f:
    contents = f.read()
```

Il funzionamento:

- `custom_open` è eseguita fino a `yield`
- ritorna il controllo allo statement with; ciò che è stato dato da `yield` viene assegnato ad `f` (nel pezzo `as f`)
- la clausola `finally` assicura che `close` sia chiamata che vi sia stata una eccezione all'interno del blocco `with` o meno

Capitolo 7

Eccezioni

Contents

7.1 Gestire eccezioni 51
7.1.1 Sintassi minimale: `try except` 51
7.1.2 `else` 52
7.1.3 `finally` 52
7.2 Sollevare eccezioni 52
7.3 Creare eccezioni custom 54
7.4 Sollevare warnings senza stoppare l'esecuzione . . 54

Quando viene sollevata una eccezione a runtime qualcosa è andato storto Non è necessariamente un bug , qualcosa che dipende dal codice, ma può dipendere anche da una condizione esterna. Nel seguito si vede:

- come gestire eccezioni per evitare che blocchino l'esecuzione
- come sollevare eccezioni nel nostro codice, eventualmente custom made
- sollevare warnings rapidi

7.1 Gestire eccezioni

Per gestire le eccezioni si usa `try`.

7.1.1 Sintassi minimale: `try except`

Un esempio

```
try:
    x = int("prova")
except ValueError a e:
    print(e)
    # oppure altro codice per gestire l'eccezione
```

Nell'ordine:

- viene eseguito il codice sotto `try`

- se *non viene sollevata alcuna eccezione* `try` termina
- se *viene sollevata una eccezione* l'ecuzione di `try` si blocca e si cerca un match con quelle previste in `except`:
  - se una eccezione matcha viene eseguito il relativo codice dopodichè si esce dal blocco `try`;
  - se il tipo non matcha, essa viene trasmessa a eventuali istruzioni `try` di livello superiore

In `try`:

- si possono avere più clausole `except`, per specificare gestori di differenti eccezioni
- se si vuole gestire molteplici eccezioni con lo stesso codice, porle in una tupla:

```
except (RuntimeError, TypeError, NameError) as e:
    print(e)
```

- per ignorare una eccezione (ma non è best practice) porre `pass` nel relativo chunk. Alternativamente se il `try` è all'interno id un loop `for` si potrebbe dare `continue` per passare al prossimo elemento
- sebbene sia meglio avere una gestione granulare delle eccezioni, per matchare qualsiasi eccezione utilizzare `Exception` (che è parent di tutte le eccezioni). Best practice potrebbe essere loggare tutte le eccezioni non gestite

```
import logging

try:
    code
except A as e:
    ...
except B as e:
    ...
except Exception as e:
    logging.exception(e)
```

- se si desidera che una eccezione sia cosi grave da bloccare il programma si può usare `sys.exit`

```
try:
    ...
except SevereError as e:
    print(e)
    sys.exit(1)
```

7.1.2 else

Opzionale, va posta dopo tutte le `except`. È il contrario di queste nel senso che esegue codice se `try` *va a buon fine*:

```
for arg in sys.argv[1:]:
    try:
        f = open(arg, 'r')
    except IOError:
        print('cannot open', arg)
    else:
        print(arg, 'has', len(f.readlines()), 'lines')
        f.close()
```

7.1.3 finally

Opzionale, e serve per eseguire codicein ogni caso (sia in caso positivo che fail), es per azioni di pulizia che vengono eseguite comunque

```
>>> def divide(x, y):
...     try:
...         result = x / y
...     except ZeroDivisionError:
...         print("Division by zero!")
...     else:
...         print("Result is", result)
...     finally:
...         print("Executing finally clause")
...
>>> divide(2, 1)
Result is 2.0
Executing finally clause
>>> divide(2, 0)
Division by zero!
Executing finally clause
>>> divide("2", "1")
Executing finally clause
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "<stdin>", line 3, in divide
TypeError: unsupported operand type(s) for /: 'str' and 'str'
```

Nelle applicazioni reali, la clausola `finally` è utile per rilasciare risorse esterne (file, network connection) indipendentemente dal fatto che l'uso della risorsa sia andata a buon fine.

7.2 Sollevare eccezioni

Lo statement `raise` permette di sollevare eccezioni;

```
>>> raise NameError("Messaggio informativo")
Traceback (most recent call last):
```

```
  File "<stdin>", line 1, in <module>
NameError: Messaggio informativo
```

La gerarchia delle eccezioni disponibili allo stato attuale, cercare di utilizzare l'eccezione più appropriata.

```
BaseException
 +-- SystemExit
 +-- KeyboardInterrupt
 +-- GeneratorExit
 +-- Exception
      +-- StopIteration
      +-- StopAsyncIteration
      +-- ArithmeticError
      |    +-- FloatingPointError
      |    +-- OverflowError
      |    +-- ZeroDivisionError
      +-- AssertionError
      +-- AttributeError
      +-- BufferError
      +-- EOFError
      +-- ImportError
      |    +-- ModuleNotFoundError
      +-- LookupError
      |    +-- IndexError
      |    +-- KeyError
      +-- MemoryError
      +-- NameError
      |    +-- UnboundLocalError
      +-- OSError
      |    +-- BlockingIOError
      |    +-- ChildProcessError
      |    +-- ConnectionError
      |    |    +-- BrokenPipeError
      |    |    +-- ConnectionAbortedError
      |    |    +-- ConnectionRefusedError
      |    |    +-- ConnectionResetError
      |    +-- FileExistsError
      |    +-- FileNotFoundError
      |    +-- InterruptedError
      |    +-- IsADirectoryError
      |    +-- NotADirectoryError
      |    +-- PermissionError
      |    +-- ProcessLookupError
      |    +-- TimeoutError
      +-- ReferenceError
      +-- RuntimeError
      |    +-- NotImplementedError
      |    +-- RecursionError
      +-- SyntaxError
      |    +-- IndentationError
```

```
|         +-- TabError
+-- SystemError
+-- TypeError
+-- ValueError
|    +-- UnicodeError
|         +-- UnicodeDecodeError
|         +-- UnicodeEncodeError
|         +-- UnicodeTranslateError
+-- Warning
     +-- DeprecationWarning
     +-- PendingDeprecationWarning
     +-- RuntimeWarning
     +-- SyntaxWarning
     +-- UserWarning
     +-- FutureWarning
     +-- ImportWarning
     +-- UnicodeWarning
     +-- BytesWarning
     +-- ResourceWarning
```

7.3 Creare eccezioni custom

Se l'utente vuol definire delle eccezioni custom deve implementarle mediante classi; in questo modo è possibile creare gerarchie di eccezioni.
La definizione può esser anche vuota mediante `pass`

```
class MyException(Exception):
    pass
```

Una volta definita si potrà sollevarla mediante `raise`, ad esempio all'interno di un `try`, con un un template del genere

```
try:
    some_risky_code
    if my_test == wrong:
        raise MyException("Message")
except MyException as e:
    do_things
```

7.4 Sollevare warnings senza stoppare l'esecuzione

```
import warnings
warnings.warn("Warning message")
```

Capitolo 8

Devtools

Contents

8.1 Debugging 55
8.2 Testing 57
8.2.1 Introduzione 57
8.2.2 `pytest` 58
8.2.3 Testing con dati/input randomici 61
8.2.4 Doctest 61
8.2.5 `unittest` 62
8.3 Linting/formattazione (`ruff`) 62
8.3.1 Linting 62
8.3.2 Formattazione 63
8.4 Type checking (`ty`) 63
8.5 Timing/temporizzazione 63
8.6 Profiling 63
8.7 Scrittura di plugin 64
8.8 Documentazione 65
8.8.1 Setup 65
8.8.2 Doc-writing e reStructuredText 65
8.8.3 Building 65
8.8.4 Setup di readthedocs 66

8.1 Debugging

Lo strumento è il modulo `pdb`. Alcune applicazioni:

- per emulare `browser` di R porre una chiamata a

  ```
  breakpoint()
  ```

  dove necessario. Questo fa andare in pausa l'esecuzione appena il flusso arriva nel punto, dopodiché entra in modalità debugging.
  In modalità debugging (scritta (Pdb) ad inizio linea) i comandi principali utilizzabili sono in tabella 8.1;

- per simulare il `traceback` di R, al fine di ispezionare la stack dove l'errore si è verificato utilizzare `pdb.post_mortem()` in un template del genere con try-except:

```
import pdb

def f(x):
    result = 1 / x
    return result

try:
    f(0)
except:
    pdb.post_mortem()
```

  dopodiché si è in modalità debugging e ci si può muovere con `up` e `down` nella stack;

- per eseguire uno script in modalità debugging/linea per linea (senza porre `breakpoint()` all'inizio)

```
python3 -m pdb app.py arg1 arg2
```

Command	Description
`h`	help
`h topic`	help su un topic
`h pdb`	documentazione `pdb`
`q(uit)`	chiudi debugger
`ENTER`	ripeti il comando precedente
`dir()`	listare variabili disponibili (as usual)
`p`	stampa espressione (es variabile)
`pp`	prettyprinta espressione
`display expr`	monitora variazioni ad una espressione (eg variabile)
`display`	lista le espressioni monitorate)
`undisplay expr`	togli monitoraggio
`b`	lista i breakpoint o settane uno alla linea specificata
`n(ext)`	continua l'esecuzione sino alla prossima linea della funzione corrente (eg se no scende nelle librerie)
`s(tep)`	esegui linea corrente, stoppa alla prima occasion (in funzione chiamata o funzione corrente) current (Step into a subroutine)
`c(ontinue)`	continua l'esecuzione e stoppa al prossimo breakpoint
`unt n`	continua l'esecuzione sino a linea numero `n`
`r(eturn)`	Return out of a subroutine
`w`	stampa la stack (frame più recente alla fine)
`u(p)`	sali nella stack
`d(own)`	scendi nella stack
`l(ist)`	Lista il codice attorno alla posizione corrente
`ll`	lista il codice della funzione o frame corrente

Tabella 8.1: Comandi debug

8.2 Testing

8.2.1 Introduzione

8.2.1.1 Gergo

test pezzo di codice che verifica un comportamento

test suite insieme di test del progetto

assertion specifica del comportamento atteso (eg `assert`)

fixture setup richiesto per un test

test driven development l'impostazione dei test sulle funzionalità avviene *prima* che queste vengano implementate. La filosofia del TDD è:

1. scrivi test completi che falliscono
2. scrivi codice fino a farli passare

Vantaggi

- si specificano a priori tutti i comportamenti necessari
- evita overcoding: una volta che i test passano siamo a posto
- in refactoring possiamo lavorare tranquillamente garantendoci da regressioni

8.2.1.2 Tipologie di testing

Si divide il testing in:

unit testing di singole funzionalità (es funzione/classe)

functional test di funzionalità più generali/complessive (derivante dall'interazione di più funzioni di base)

regression : test che l'output di un programma non cambi a successive versioni (a meno che ciò non sia intenzionale). Basati su output dell'esecuzione di versioni passate (validate ad occhio) o di programmi benchmark

8.2.1.3 Good testing practice

I test debbono:

- essere specifici, indipendenti e svolti in maniera automatica
- testare in caso di input corretto, l'output corretto
- testare in caso di input erroneo, la gestione corretta delle eccezioni
- dovrebbero teoricamente testare tutto l'input possibile

8.2.1.4 Fasi di un test

Sono

- *fixture setup*: setup della situazione/condizione precedente al test. È tutto ciò che rende il codice di test eseguibile
- esecuzione del test: idealmente una singola linea/cosa compatta
- verifica dei risultati
- *fixture teardown*: rimozione/cleaning delle condizioni nelle quali il test si è svolto (es liberazione risorse/file/io/etc)

Al fine di gestire setup e che teardown/pulizia siano eseguiti automaticamente indipendentemente dall'esito del test

- un ottimo modo sono i context manager con `with` (che garantiscono l'esecuzione di codice indipendentemente dall'esito delle valutazioni nel contesto)

```
with tempfile.TemporaryDirectory() as tmpdir:      # setup e teardown
   testfile = Path(tmpdir) / "test.txt"            # setup
   testfile.write_text("1\n2\n")                   # fine setup
   result = do_check(testfile)
   assert result == right_value
   # cleanup done by default
```

- alternativamente utilizzare try/finally in un template del genere

```
fixture_setup_test() # stup del test
try:
   result = do_check()          # esecuzione test
   assert result == right_value # verifica risultati
finally:
   codice_pulizia() # teardoum test
```

8.2.2 pytest

8.2.2.1 Setup

Creiamo

- una directory `tests` nella radice del progetto
- in essa diversi file dal nome `test_funzione.py` o `test_modulo.py`
- ciascun file ha
  - funzioni `test_soggetto_comportamento` dove soggetto è il nome della funzione o del modulo e comportamento è quello che viene testato. Es `test_sumfile_ignores_blanklines`
  - eventualmente classi di nome `TestXyzAsd`, senza metodo `__init__`, di cui verranno eseguiti i metodi `test_*`
- facciamo il setup di `pytest` con

```
uv add --dev pytest
```

8.2.2.2 Esecuzione dei test

Mediante uv attraverso le seguenti alternative, che verranno approfondite nel seguito

```
# esegui tutti i test
uv run pytest

# esegui in maniera quiet, utile per evidenziare solo i grossi cambiamenti
uv run pytest -q

# bloccare al primo errore o primi 3 (per stare focused e non eseguire tutto
uv run pytest -x          # exitfirst
uv run pytest --maxfail=3 # blocca al terzo errore

# per entrare in modalità debug, oltre a piazzare breakpoint qua/la si può
uv run pytest -x --pdb  # vai in modalità debug al primo errore
uv run pytest --trace file.py   # vai tipo in modalità browser di R

# verbose: fornisce test id ("file::funzione[parametrizzazione]")
uv run pytest -v

# eseguire un file specifico
uv run pytest test/test_xyz.py

# eseguire solamente un test specifico
uv run pytest file::funzione
uv run pytest "file::funzione[parametrizzazione]"

# eseguire test con un mark/tag
uv run pytest -m fast # i fast
uv run pytest -m "not slow" # tutti ad eccezione degli slow


# esegue i test filtrandoli per nome/test id (qui che hanno "filtrotestid" nel nome)
uv run pytest -k filtrotestid
uv run pytest -k "filtro1 or filtro2" # logica booleana semplice
uv run pytest -k "(api or db) and not slow" # logica booleana meno semplice
```

Per altre opzioni di run vedere Harrison, “Effective testing” a pag 74-75

8.2.2.3 Contenuto file di test

Per

- testare un singolo valore logico che deve essere `True` per non fallire utilizzare `assert`

  ```
  def test_assert():
     assert 1 == 1
  ```

- testare che una espressione sollevi una eccezione utilizzare `pytest.raises` con `with`

```
def test_exception():
   with pytest.raises(TipoEccezione):
       codice_che_solleva_TipoEccezione
```

Importante essere ragionevolmente specifici su `TipoEccezione`

- per testare l'uguaglianza di due `pd.Series` utilizzare `pd.testing.assert_series_equal` o, nel caso di `pd.Categorical`, `pd.testing.assert_extension_array_equal`. Alcuni esempi da `pylbmisc`

```
def test_to_integer_string():
    series = pd.Series(["2001", "2011", "1999", np.nan])
    expected = pd.Series([2001, 2011, 1999, pd.NA], dtype="Int64")
    result = to_integer(series)
    pd.testing.assert_series_equal(result, expected)


def test_to_sex():
    series = pd.Series(["", "m", "f", " m", "Fm", np.nan])
    expected = pd.Categorical(
         [pd.NA, "male", "female", "male", "female", pd.NA],
         categories=["male", "female"]
    )
    result = to_sex(series)
    pd.testing.assert_extension_array_equal(result, expected)
```

8.2.2.4 Fixture

Se la preparazione per test diventa complessa o ripetitiva può essre utile inglobarla in una fixture:

- è una funzione decorata con `@pytest.fixture`

```
@pytest.fixture
def dipendenza():
    return valore
```

- il nome della funzione decorata viene passata come parametro input alla funzione di test. `pytest` eseguirà la funzione fixture è fornirà (al test in chiamata) il valore ritornato da questa

```
def test_xyz(dipendenza):
    assert dipendenza == 1
```

- è possibile mettere tutte queste fixture in un file `conftest.py`, *non* da importare nel file di test. Se i test sono organizzati in directory gerarchiche, `conftest.py` fornirà fixture nella cartella corrente e nelle figlie

Per maggiori info su fixture vedere Harrison da pag 77

8.2.2.5 Marking di test

In pratica categorizza/tagga i test per poterli eseguire selettivamente. Per fare il setup:

- in `pyproject.toml` segnalare per evitare warning

  ```
  [tool.pytest.ini_options]
  markers = [
     "fast: quick checks for busy people",
     "slow: slower test"
  ]
  ```

- per markare un test come `fast`

  ```
  @pytest.mark.fast
  def test_xyz():
      code
  ```

- utilizzare `-strict-markers` nelle opzioni di pyproject, per fare in modo che non vengano utilizzati marker che non sono validati/presenti nella lista sopra (es evitare typo tipo `pytest.mark.slowww`)

- per eseguire i test fast poi

  ```
  uv run pytest -m fast # i fast
  ```

8.2.2.6 Esecuzione condizionale di test

Si implementano con `@pytest.mark.skipif`. Ad esempio se si vuole eseguire un test solo negli ambienti dove redis è disponibile

```
def redis_available():
     try:
        network_cheks()
        return True
     except OSError:
        return False

@pytest.mark.skipif(
   not redis_available(),
   reason="Redis server not available"
)
def test_cache_limit:
    # the_test
```

8.2.2.7 Failure accettate/expected

Se si vuole che failure siano viste e riportate ma non diano errore (es in un Makefile, per automazione) markare con `xfail`

```
@pytest.mark.xfail(reason="ancora non implementato")
def test_che_fallisce():
    #...
```

Quando poi il test inizia a passare (denotato con X, unexpected pass o `xpassed`) togliere il decoratore l'`xfail` per avere un test di regressione

8.2.2.8 Parametrizzazione

Serve per validare una funzionalità su diversi input ricevuti. `pytest.mark.parametrize` prende in input

- una stringa con i nomi dei parametri (nel caso più semplice 2, input fornito e output atteso)
- una lista di tuple con corrispondenti valori

```
# funzione da testare in src
def add1(x):
   return x+1

# test in tests
@pytest.mark.parametrize("inp, expected_out", [(1, 2), (5,6)])
def test_add1(inp, expected_out):
   assert add1(inp) == expected_out
```

Si possono fornire id informativi del test svolto specificando `ids`, che nel caso possono esser filtrati mediante -k

```
@pytest.mark.parametrize("inp, expected_out", [(1, 2), (5,6)], ids=["1+1==2","5+1==6"])
def test_add1(inp, expected_out):
   assert add1(inp) == expected_out
```

`skipif` e `xfail` con parametrizzazione Nel caso si voglia skippare condizionalmente o accettare fallimento di alcuni casi forniti come parametrizzazione bisogna crearli con `pytest.param` specificando i parametri standard, eventualmente l'id e specificando il marking/decorazione con `marks`:

```
import pytest
import os

# # in the library
# def add1(x):
#    return x+1


add1_test_params = [
   (1, 2),  # test eseguito sempre
   (5, 6),  # idem
   # expected failure
   pytest.param(1, 3, id="this_will_fail",
                marks=pytest.mark.xfail(reason="well, input...")),
   # don't run on windows
   pytest.param(1, 4, id="skipif_thecondition",
                marks=pytest.mark.skipif(os.name == "posix", reason="skipped on linux...")),
```

```
]

@pytest.mark.parametrize("inp, expected_out", add1_test_params)
def test_add1(inp, expected_out):
   assert add1(inp) == expected_out
```

8.2.3 Testing con dati/input randomici

Vedere la libreria Hypothesis per stresstest vari (Harrison pag 187)

8.2.4 Doctest

Molto utilizzato da librerie scientifiche (`numpy`, `pandas`), o test si possono definire nella documentazione (docstring) di funzioni o moduli:

- si effettua qualche prova alla REPL di python di esempio di utilizzo (semplice/compatto) della funzione; una volta perfezionato ...
- si scrive l'esempio di utilizzo della funzione (sia codice che output);
- dopodiché `doctest` esegue il codice verificando che l'output prodotto combaci

Il beneficio è mantenere documentazione e testing sincronizzati e gli esempi di codice accurati/aggiornati/funzionali.
Per controllare in una directory di progetto, sia doctest che pytest:

```
uv run pytest --doctest-modules
```

8.2.4.1 Skippare test

A volte si desidera che il codice sia fornito solo come esempio e non testato (es per motivi di tempo o altro, equivalente di `dontrun` in roxygen2), nel caso porre `# doctest:  +SKIP` nella linea che si vuole skippare

```
Examples
--------
>>> import time
>>> from pylbmisc.utils import timeit
>>>
>>> @timeit()
... def test():
...     time.sleep(1)
...
>>> test()                 # doctest: +SKIP
Function test [args=() kwargs={}] took 1.00 secs.
```

8.2.4.2 Normalizzare spazi bianchi

Utilizzare a fianco delle linee che sollevano errori apparentemente esistenti (es due linee confrontate sono uguale ma differiscono per il numero di spazi bianchi)

```
# doctest: +NORMALIZE_WHITESPACE
```

8.2.5 unittest

Il modulo classico per lo unit testing in Python è `unittest`, orientato alle classi. Commentato nel sorgente, nel caso sia necessario rivedere alla luce di Harrison "Effective testing" pag 47

8.3 Linting/formattazione (ruff)

ruff serve per

- linting: ossia controllo statico di codice, senza eseguirlo, per evidenziare possibili problemi
- formatting: ossia riscrittura deterministica per seguire un certo stile

```
uv add --dev ruff
```

8.3.1 Linting

Si ottiene con

```
uv run ruff check
```

Vengono mostrate tutte le violazioni con un codice costituito da lettera e numero dove la lettera è

- `F` per le regole di pyflakes
- `E` per pycodestyle
- `I` per import etc

Per

- autofixare il possibile

  ```
  uv run ruff check --fix
  ```

- vedere a cosa si riferisce un errore

  ```
  uv run ruff rule E501
  ```

- ulteriori configurazioni (es come escludere dei check) vedere harrison pag 252

8.3.2 Formattazione

Si ottiene con

```
uv run ruff format # formattazione
```

8.4 Type checking (ty)

Programmi di questo tipo (es `mypy`, `pyright`) controllano i type hints nelle definizioni per anticipare possibili problemi dovuti a tipi nell'esecuzione del programma.
Quello che usiamo qui è ty

```
uv add --dev ty
```

Il controllo viene effettuato mediante

```
uv run ty check
```

8.5 Timing/temporizzazione

Per misurare il tempo usiamo `time.perf_counter` (posto in un decorator `lb.utils.timeit`)

```
import time
start = time.perf_counter()
# operations ...
stop = time.perf_counter()
stop - start # difference in seconds
```

8.6 Profiling

Il profiling serve per individuare le macrosezioni di codice dove si spende più tempo. Il modulo principale di profiling è `cProfile`.

Profilare codice al volo Fare qualcosa del genere

```
import cProfile
import re
cProfile.run('re.compile("foo|bar")') # ordine per cumulative time
cProfile.run('re.compile("foo|bar")', sort="tottime") # ordine per tottime
```

che da

```
      214 function calls (207 primitive calls) in 0.002 seconds

Ordered by: cumulative time

ncalls  tottime  percall  cumtime  percall filename:lineno(function)
     1    0.000    0.000    0.002    0.002 {built-in method builtins.exec}
     1    0.000    0.000    0.001    0.001 <string>:1(<module>)
     1    0.000    0.000    0.001    0.001 __init__.py:250(compile)
     1    0.000    0.000    0.001    0.001 __init__.py:289(_compile)
     1    0.000    0.000    0.000    0.000 _compiler.py:759(compile)
...
```

La prima riga dice che 214 chiamate sono state monitorate, di cui 207 erano primitive (non ricorsive). La riga successiva specifica l'ordinamento della tabella (per tempo cumulato nella sezione di codice).
Gli header di colonna:

- `ncalls`: numero chiamate
- `tottime`: tempo speso nella funzione (escludendo le funzioni da questa chiamata)
- `percall`: `tottime/ncalls`
- `cumtime`: tempo totale speso nella funzione (includendo le funzioni chiamate)
- `percall`: `tottime` / primitive calls
- `filename:lineno(function)`: la sezione di codice

Se vi sono due numeri nella prima colonna (es 3/1), significa che la funzione è ricorrente: il secondo valore è il numero di chiamate primitive, il primo le chiamate totali (se la funzione chiamata solo una volta vi è un solo numero)

Profilare uno script uno script ordinando le sezioni di codice per tempo cumulato entro ogni posto (`cumtime`)

```
python -m cProfile cprof_example.py # ordine per cumtime
python -m cProfile -s tottime cprof_example.py
```

8.7 Scrittura di plugin

Approfondire

- `https://oneuptime.com/blog/post/2026-01-30-python-plugin-systems/view`
- `https://stackoverflow.com/questions/932069/building-a-minimal-plugin-architecture-in-pytho`
- `https://packaging.python.org/en/latest/guides/creating-and-discovering-plugins/`
- un esempio, credo, vedere il commento di `pytest-ty` di Harrison a pag 280

8.8 Documentazione

Si fa utilizzo di `sphinx` e si pubblica su `https://readthedocs.org/`. I tutorial da considerare sono `https://packaging.python.org/en/latest/tutorials/creating-documentation/` e `https://docs.python-guide.org/writing/documentation/`.

8.8.1 Setup

Iniziamo ad installare `sphinx`

```
uv add --dev sphinx
```

Creiamo la directory di documentazione e facciamo partire il tutto

```
l@m740n:~/src/pypkg$ mkdir pylb/docs
l@m740n:~/src/pypkg$ cd pylb/docs
l@m740n:~/src/pypkg/pylb/docs$ uv run sphinx-quickstart
```

Questo farà domande sul progetto per andare a creare il file `index.rst` e un `conf.py` (configurabili), più un `Makefile` di servizio.

8.8.2 Doc-writing e reStructuredText

`sphinx` converte restructured text ad altri linguaggi di markup, e utilizza reStructuredText come linguaggio di markup. Per la sintassi riferirsi a `https://www.sphinx-doc.org/en/master/usage/restructuredtext/` per le convenzioni di documentazione a quelle del progetto Numpy.

8.8.3 Building

Setup autobuilding API Per fare si che la documentazione di funzioni/classi etc, venga generata automaticamente occorre utilizzare l'estensione `autodoc`. Modificare `conf.py` come segue:

- aggiungere il path della libreria nel `sys.path` all'inizio di `conf.py`. Il package deve essere importabile per poter essere elaborato:

  ```
  import os
  import sys
  sys.path.insert(0, os.path.abspath('../src'))
  ```

- modificare per aggiungere le seguenti estensioni sotto general configuration:

  ```
  extensions = [
      'sphinx.ext.autodoc',    # generazione automatica api
      'sphinx.ext.viewcode',   # aggiungi link ipertestuali al codice
      'sphinx.ext.napoleon'    # supporta sintassi a-la numpy
  ]
  ```

- volendo si può cambiare il tema html installandolo

  ```
  pip install --user sphinx_rtd_theme
  ```

  e modificando la linea del tema html (sostituendo `alabaster` di default)

  ```
  html_theme = 'sphinx_rtd_theme'
  ```

Al termine del setup per preparare la documentazione di funzioni etc:

```
l@m740n:~/src/pypkg/pylb/docs$ sphinx-apidoc -f ../src/pylb/ -o .
Creating file ./pylb.rst.
Creating file ./pylb.experiments.rst.
Creating file ./modules.rst.
```

Aggiungere `modules.rst` in `index.rst`

```
Welcome to pylb's documentation!
================================

.. toctree::
   :maxdepth: 2
   :caption: Contents:

   modules
```

Build definitivo Per buildare definitivamente la documentazione complessivamente si usa `make` con il formato di interesse (nella cartella `docs`). Per l'html

```
l@m740n:~/src/pypkg/pylb/docs$ make html
The HTML pages are in _build/html.
l@m740n:~/src/pypkg/pylb/docs$ firefox _build/html/index.html
```

Per il latex

```
l@m740n:~/src/pypkg/pylb/docs$ make latex
The LaTeX files are in _build/latex.
Run 'make' in that directory to run these through (pdf)latex
(use `make latexpdf' here to do that automatically).
l@m740n:~/src/pypkg/pylb/docs$ make latexpdf
l@m740n:~/src/pypkg/pylb/docs$ okular _build/latex/pylb.pdf
```

8.8.4 Setup di readthedocs

Seguire il tutorial per importare il progetto e generare/hostare automaticamente la documentazione

Parte II

Scientific Stack

Capitolo 9

Numpy

Contents

9.1 L'ndarray 69
9.1.1 Creazione e copia 69
9.1.2 Tipi (dtype): coercizione e testing 69
9.1.3 Forma, dimensioni e reshape 70
9.2 Indexing 71
9.2.1 Array unidimensionali 71
9.2.2 Array multidimensionali 71
9.2.3 Subarray come viste vs copie 72
9.2.4 Assegnazione e unicità degli indici 72
9.3 Elaborazioni di array 72
9.3.1 Inserimento/rimozione elementi (insert, delete) . . 72
9.3.2 Aritmetica vettorizzata 72
9.3.3 Operazioni insiemistiche 72
9.3.4 Concatenazione (concatenate, vstack, hstack) . . . 72
9.3.5 Splitting (split, vsplit, hsplit) 73
9.3.6 Ripetizione/binding (repeat, tile) 73
9.3.7 Sorting/ordine (sort, argsort) 73
9.4 Universal functions 73
9.4.1 Introduzione 73
9.4.2 Metodi delle ufunction (reduce, accumulate, outer) 74
9.4.3 Creazione di ufunctions 75
9.5 Broadcasting 75
9.6 Altri argomenti 77
9.6.1 Lavorare con booleani 77
9.6.2 Array di stringhe 77

Il template per l'importazione è:

```
>>> import numpy as np
```

Fornisce:

- l'oggetto `ndarray`, un array multidimensionale efficiente, costruito come puntatore a dati in memoria;
- *universal functions*: funzioni per operare su tutti gli elementi di un array;
- strumenti per integrare codice scritto in C, C++ e Fortran

9.1 L'ndarray

L'`ndarray` è un array ad n dimensioni di dati omogenei composto da:

- un puntatore a dati in memoria;
- un attributo `dtype` che definisce il tipo di dato;
- un attribito `shape`, tuple che definisce la struttura dell'array.

9.1.1 Creazione e copia

Si usa la funzione `array` passando dati di tipo sequenza (liste, tuple ecc)

```
>>> # creazione a partire da una lista, in varie shape
>>> np.array([ 1,  2,  3])   # vector
array([1, 2, 3])
>>> x = np.array([[1, 2, 3], [4, 5, 6]]) # matrix
>>> x
array([[1, 2, 3],
       [4, 5, 6]])
```

Altre funzioni di convenienza per la generazione rapida di array:

```
>>> # Creazione rapida di dati
>>> np.arange(0, 20, 2)    # simile a range(), da 0 a 20 a step di 2
array([ 0,  2,  4,  6,  8, 10, 12, 14, 16, 18])
>>> np.linspace(0, 1, 5)   # interpolazione lineare
array([0.  , 0.25, 0.5 , 0.75, 1.  ])
>>> np.full(5, 2)          # vettore riempito di 2
array([2, 2, 2, 2, 2])
>>> np.zeros(10)           # array di zero
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
>>> np.ones((3, 5))        # array 3x5 di uno
array([[1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.]])
>>> np.eye(3)              # matrice identita 3x3
array([[1., 0., 0.],
       [0., 1., 0.],
       [0., 0., 1.]])

>>> # creazione rapida sfruttando altre shape
>>> np.zeros_like(x)  # array di 0 della stessa shape di x (np.ones_like)
array([[0, 0, 0],
       [0, 0, 0]])
```

```
>>> # Generazione casuale
>>> np.random.random((3, 3))     # array 3x3 con valori casuali uniformi 0-1
array([[0.68626509, 0.37494871, 0.16815698],
       [0.2363675 , 0.14431943, 0.93526657],
       [0.77627679, 0.15882882, 0.69634133]])
>>> np.random.randint(0, 10, (3, 3)) # matrice 3x3 con interi nell'intervallo [0,10 )
array([[9, 3, 0],
       [2, 1, 6],
       [4, 6, 7]])
>>> np.random.normal(0, 1, 5)    # da normale mu=0, sd=1
array([-0.77926596, -0.84547294, -1.49342551,  1.68203331,  0.59082992])
```

Referenza vs copia di array Se si assegna una variabile array ad un'altra variabile si crea un nuovo riferimento, non una copia: ossia non viene effettuata una copia di dati ma si creano due nomi che puntano alla stessa memoria:

```
>>> x = np.arange(10)
>>> y = x
>>> x[2] = -9999
>>> y
array([    0,     1, -9999,     3,     4,     5,     6,     7,     8,
           9])
>>> y[0] = -111
>>> x
array([ -111,     1, -9999,     3,     4,     5,     6,     7,     8,
           9])
```

Se necessario creare una copia per evitare di modificare l'originale utilizzare il metodo `copy`:

```
>>> x = np.arange(3)
>>> x_copy = x.copy()
>>> x_copy[0] = -999
>>> x
array([0, 1, 2])
```

9.1.2 Tipi (`dtype`): coercizione e testing

I tipi di dato, chiamati `dtype`, sono riportati in tabella 9.1: per utilizzarli in creazione dell'array specificare l'omonimo parametro in uno di questi due modi possibili:

```
>>> np.zeros(10, dtype = 'int16')
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int16)
>>> np.zeros(10, dtype = np.float64)
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
```

Coercizione del `dtype` Si usa il metodo `astype` sull'array da convertire

dtype	Descrizione
bool	Boolean (True or False) stored as a byte
intc	Identical to C int (normally int32 or int64)
intp	Integer used for indexing (same as C ssize_t; normally either int32 or int64)
int8	Byte (-128 to 127)
int16	Integer (-32768 to 32767)
int32	Integer (-2147483648 to 2147483647)
int64	Integer (-9223372036854775808 to 9223372036854775807)
uint8	Unsigned integer (0 to 255)
uint16	Unsigned integer (0 to 65535)
uint32	Unsigned integer (0 to 4294967295)
uint64	Unsigned integer (0 to 18446744073709551615)
float16	Half precision float: sign bit, 5 bits exponent, 10 bits mantissa
float32	Single precision float: sign bit, 8 bits exponent, 23 bits mantissa
float64	Double precision float: sign bit, 11 bits exponent, 52 bits mantissa
complex64	Complex number, represented by two 32-bit floats (real and imaginary components)
complex128	Complex number, represented by two 64-bit floats (real and imaginary components)

Tabella 9.1: dtypes di numpy

```
>>> a = np.zeros(10, dtype = np.float64)
>>> b = a.astype(np.int8)
>>> b
array([0, 0, 0, 0, 0, 0, 0, 0, 0, 0], dtype=int8)
```

Test del tipo I tipi numpy hanno una gerarchia per la quale ad esempio gli interi derivano dalla classe genitrice np.integer mentre i numeri a virgola mobile da np.floating.
Per il testing si possono usare queste classi in np.issubdtype.

```
>>> np.issubdtype(a.dtype, np.integer)
False
>>> np.issubdtype(a.dtype, np.floating)
True
```

9.1.3 Forma, dimensioni e reshape

9.1.3.1 Forma e dimensioni

Ogni array ha attributo:

- ndim: numero di dimensioni
- shape: numero di elementi per ciascuna dimensione
- size: numero di elementi complessivi
- nbytes: memoria occupata in bytes (dipendente dal dtype adottato, investigabile con itemsize)

```
>>> z1  = np.zeros(shape = 3) # vector
>>> z2i = np.zeros(shape = (3,4), dtype = np.int8)     # matrix
```

```
>>> z2f = np.zeros(shape = (3,4), dtype = np.float32)
>>> z3  = np.zeros(shape = (3,4,5)) # geneneral array

>>> z2i.ndim
2
>>> z2i.shape
(3, 4)
>>> z2i.size
12
>>> z2i.nbytes
12
>>> z2f.nbytes
48
>>> z2i.itemsize
1
>>> z2f.itemsize
4
```

9.1.3.2 Reshaping

Per modificarla la forma si può assegnare all'attributo `shape` o utilizzare il metodo `reshape` (ricordandosi di salvare); `reshape` ritorna una vista sui dati e non effettua copie, se non necessario.

```
>>> a = np.arange(4) ## assegnare all'attributo shape (C mode/row major di default)
>>> a
array([0, 1, 2, 3])
>>> a.shape = (2,2)
>>> a
array([[0, 1],
       [2, 3]])

>>> b = a.reshape((4,1)) ## uso di reshape
>>> b
array([[0],
       [1],
       [2],
       [3]])

>>> c = a.reshape((4,)) ## tornare ad un array a una dimensione di 4
>>> c
array([0, 1, 2, 3])

>>> d = a.reshape(-1) ## stessa cosa ma ancora più comodo
>>> d
array([0, 1, 2, 3])
```

9.1.3.3 Ravelling/flattening

Altri due metodi per tornare ad una struttura dati unidimensionale sono:

- `flatten` fa il flattening producendo sempre una copia dell'array di partenza
- `ravel` fa il flattening ma non produce una copia dei dati, bensì una vista dell'array originale; se si modifica l'array ritornato da ravel si potrebbero modificare gli elementi dell'array originale.
  `ravel` è spesso più veloce ma bisogna essere più attenti con le modifiche.

```
>>> b.flatten()
array([0, 1, 2, 3])
>>> b.ravel()
array([0, 1, 2, 3])
```

9.2 Indexing

Serve per accedere in lettura e scrittura agli elementi di un array.

9.2.1 Array unidimensionali

Si può specificare tra quadre alternativamente:

- lo slicing `start:stop:step` (con default rispettivamente a, 0, dimensione e 1) similmente ai dati builtin

  ```
  >>> x = np.arange(10)
  >>> x[1]
  np.int64(1)
  >>> x[1] = -1
  >>> x[3:5] = [5, 4]
  >>> x[:4:2] = 0
  >>> x[-2] = 1
  >>> x
  array([ 0, -1,  0,  5,  4,  5,  6,  7,  1,  9])
  ```

  Se `step` è negativo si procede in senso inverso (i default di `start`/`stop` vengono invertiti: per `start` la dimensione dell'array, per `stop` 0)

  ```
  >>> x[::-1]   # reverse an array
  array([ 9,  1,  7,  6,  5,  4,  5,  0, -1,  0])
  >>> x[5::-2]  # reversed from index 5 backward
  array([ 5,  5, -1])
  ```

- **liste e array numerici**; nel secondo caso la struttura ritornata ha lo stesso `shape` dell'indice (non del dato indicizzato):

  ```
  >>> # lista
  >>> select = [1, 2, 4, 5]
  >>> x[select] # x[np.array(select)] alternativamente
  array([-1,  0,  4,  5])

  >>> # array con shape (2x2)
  >>> ind = np.array([[2, 1],
  ```

```
...                 [4, 7]])
>>> x[ind]
array([[ 0, -1],
       [ 4,  7]])
```

- **liste/array logici**

```
>>> x = np.array([1, 2, 3])
>>> sell = [True, False, True]
>>> sela = np.array(sell)
>>> x[sell]
array([1, 3])
>>> x[sela]
array([1, 3])
```

9.2.2 Array multidimensionali

Tra quadre, separate da virgola, porre qualcosa di utilizzabile (slice, liste, array):

- **interi**: permettono di selezionare un singolo elemento

```
>>> # bidimensionale: [righe, colonne]
>>> x = np.arange(12).reshape(3,4)
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])

>>> x[0, 0]                    # singolo elemento
np.int64(0)
```

- **slicing**

```
>>> x[ :2, 1: ]                # slicing: sino riga 2 esclusa, colonna 1 inclusa e sgg
array([[1, 2, 3],
       [5, 6, 7]])
>>> x[ ::-1, ::-1 ]            # reverse
array([[11, 10,  9,  8],
       [ 7,  6,  5,  4],
       [ 3,  2,  1,  0]])
```

L'**accesso a righe/colonne intere** avviene combinando indici numerici/logici e slicing vuota (`:`). Se un indice non è specificato, si prendono tutti i dati su quella dimensione:

```
>>> # se si fornisce un solo indice alla struttura multidimensionale
>>> # viene interpretato nel primo asse/dimensione
>>> x[0] # prima riga
array([0, 1, 2, 3])

>>> # prima riga the proper way
>>> # x[0, ]   # this works
>>> x[0, :]
```

```
array([0, 1, 2, 3])
>>> x[0, ::]
array([0, 1, 2, 3])

>>> # prima colonna
>>> # x[, 0] # this gives error
>>> x[:, 0]
array([0, 4, 8])
>>> x[::, 0]
array([0, 4, 8])
```

- **liste e array** in questo caso per l'accoppiamento degli indici funziona il *broadcasting*:
  - se utilizziamo due array unidimensionali verrà restituita la selezione in parallelo
  - se un indice è un array multidimensionale (vettore riga o colonna) otteniamo una struttura a due dimensioni (ogni valore di riga è matchato con ogni vettore colonna così come avviene nel broadcasting delle operazioni aritmetiche)

```
>>> x = np.arange(12).reshape(3,4)
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])

>>> x[[0,1], [1,2]]           # liste: elemento (0, 1) ed elemento (1, 2) della
array([1, 6])


>>> row = np.array([0, 1, 2]) # array: elementi (0, 2), (1,1) e (2,3)  (broadcas
>>> col = np.array([2, 1, 3])
>>> x[row, col]
array([ 2,  5, 11])

>>> rowt = row.reshape(3,1) # array2
>>> rowt
array([[0],
       [1],
       [2]])
>>> col
array([2, 1, 3])
>>> (rowt * col).shape    # struttura degli indici post broadcast?
(3, 3)
>>> x[rowt, col]
array([[ 2,  1,  3],
       [ 6,  5,  7],
       [10,  9, 11]])
```

Nell'indexing di liste e array la struttura ritornata riflette la shape degli indici post broadcast, non la shape dell'array indicizzato.

- **indexing logico** (*boolean masking*): la selezione di righe/colonne mediante liste/array logici si fa normalmente

```
>>> x = np.arange(12).reshape(3,4)
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11]])

>>> # selezione colonne (prima e seconda)
>>> cl = [True, True, False, False]
>>> ca = np.array(cl)
>>> x[:, cl]
array([[0, 1],
       [4, 5],
       [8, 9]])
>>> x[:, ca]
array([[0, 1],
       [4, 5],
       [8, 9]])

>>> # selezione righe (prima e terza)
>>> rl = [True, False, True]
>>> ra = np.array(rl)
>>> x[rl, :]
array([[ 0,  1,  2,  3],
       [ 8,  9, 10, 11]])
>>> x[ra, :]
array([[ 0,  1,  2,  3],
       [ 8,  9, 10, 11]])
```

Se il `ndim` dell'oggetto passato come indice coincide con quello indicizzato, viene ritornato un 1-dimensional array riempito con gli elementi corrispondenti a `True`.
Questo può essere usato per masking. Ad esempio:

```
>>> # esempio 1: masking
>>> b = np.arange(9).reshape(3, 3)
>>> b
array([[0, 1, 2],
       [3, 4, 5],
       [6, 7, 8]])
>>> b > 4
array([[False, False, False],
       [False, False,  True],
       [ True,  True,  True]])
>>> b[b > 4]
array([5, 6, 7, 8])

>>> # esempio 2: selezionare intersezione di righe e colonne
>>> rar = ra.reshape(3,1)
>>> rar
```

```
array([[ True],
       [False],
       [ True]])
>>> ca
array([ True,  True, False, False])

>>> # x[rar, ca] # doesnt work
>>> # x[ra, ca]  # doesnt work

>>> rar * ca          # nel caso di logici questo è utile nell'indicare la selez
array([[ True,  True, False, False],
       [False, False, False, False],
       [ True,  True, False, False]])
>>> x[rar * ca]       # black magic come in b>4, ma non mantiene la struttura :(
array([0, 1, 8, 9])
>>> x[np.ix_(ra, ca)] # per mantenere la struttura usare quanto ritornato da np.
array([[0, 1],
       [8, 9]])
```

9.2.3 Subarray come viste vs copie

I subarray generati

- con *slicing/tuple* sono **viste**: pertanto eventuali modifiche si ripercuoteranno sull'array/struttura di base indipendentemente da dove sono state effettuate;

- con *array*/liste sono **copie**

```
>>> x = np.arange(10)      # subarray con slice sono una vista
>>> x_slice = x[5:8]
>>> x_slice[2] = 999
>>> x
array([  0,   1,   2,   3,   4,   5,   6, 999,   8,   9])

>>> x = np.arange(10)      # subarray con lista sono copia
>>> x_slice = x[[5, 6, 7]]
>>> x_slice[2] = 999
>>> x
array([0, 1, 2, 3, 4, 5, 6, 7, 8, 9])

>>> x = np.arange(4)       # subarray con array sono copia
>>> ind = np.array([True, True, False, False])
>>> x_slice = x[ind]
>>> x_slice[:] = 999
>>> x
array([0, 1, 2, 3])
```

9.2.4 Assegnazione e unicità degli indici

Se non si desiderano comportamenti inattesi, prestare attenzione all'unicità degli indici, in quanto se un indice è ripetuto l'assegnazione sarà effettuata molteplici volte, come i seguenti esempi mostrano

```
>>> x = np.zeros(10, dtype = np.int_)

>>> # primo esempio
>>> x[[0,0]] = [4, 6]
>>> # qui si ha x[0] = 4 e poi x[0] = 6
>>> x
array([6, 0, 0, 0, 0, 0, 0, 0, 0, 0])

>>> # secondo esempio
>>> i = [2,2,4,4,4,6,6,6,6,6,6]
>>> x[i] += 1
>>> x
array([6, 0, 1, 0, 1, 0, 1, 0, 0, 0])
>>> # anche questo non intuitivo, si pensava la posizione 6 fosse
>>> # aumentato tante volte, ma cosi non è per cazzi suoi
>>> # (vedi vanderplas fancy indexing nel caso, ma anche chi se ne ciava)
```

9.3 Elaborazioni di array

9.3.1 Inserimento/rimozione elementi (`insert`, `delete`)

```
>>> a = np.array([1, 2, 3]) # any change need to be assigned to be saved
>>> np.insert(a, 1, 5)      # insert element in an array
array([1, 5, 2, 3])
>>> np.delete(a, [1])       # remove item from an array
array([1, 3])
```

9.3.2 Aritmetica vettorizzata

Le operazioni aritmetiche sono vettorizzate per cui è possibile fare

```
>>> x = np.arange(4)
>>> x
array([0, 1, 2, 3])

>>> ## Operazioni aritmetiche
>>> -x     # unary negation
array([ 0, -1, -2, -3])
>>> x + 1  # addition
array([1, 2, 3, 4])
>>> x - 5  # subtraction
array([-5, -4, -3, -2])
>>> x * 2  # multiplication
array([0, 2, 4, 6])
>>> x ** 2 # power
```

Funzione	Descrizione
`unique(x)`	sorted unique elements in x
`intersect1d(x, y)`	sorted common elements in x and y
`union1d(x, y)`	sorted union of elements
`in1d(x, y)`	boolean array if each element of x is contained in y
`setdiff1d(x, y)`	set difference (elements in x that are not in y)
`setxor1d(x, y)`	set symmetric differences (elements in one of the arrays, but not both)

Tabella 9.2: Operazioni insiemistiche tra array

```
array([0, 1, 4, 9])
>>> x / 2  # division
array([0. , 0.5, 1. , 1.5])
>>> x // 2 # floor division (e.g., 3 // 2 = 1)
array([0, 0, 1, 1])
>>> x % 2  # modulus remainder
array([0, 1, 0, 1])
>>> -(0.5*x + 1) ** 2 # misc expression
array([-1.  , -2.25, -4.  , -6.25])

>>> ## Comparazione
>>> x == 2
array([False, False,  True, False])
>>> x != 2
array([ True,  True, False,  True])
>>> x > 2
array([False, False, False,  True])
>>> x >= 2
array([False, False,  True,  True])
>>> x < 2
array([ True,  True, False, False])
>>> x <= 2
array([ True,  True,  True, False])
```

9.3.3 Operazioni insiemistiche

Per effettuare operazioni di tipo insiemistico le funzioni sono quelle riportate in tabella 9.2.

9.3.4 Concatenazione (`concatenate`, `vstack`, `hstack`)

`numpy.concatenate` prende una tupla o una lista di array e li unisce

```
>>> x = np.array([1, 2, 3])           # unidimensionale
>>> y = np.array([3, 2, 1])
>>> z = [99, 99, 99]
>>> np.concatenate([x, y, z])
array([ 1,  2,  3,  3,  2,  1, 99, 99, 99])

>>> x = np.array([[1, 2, 3], [4, 5, 6]])     # bidimensionale
>>> y = np.array([[7, 8, 9], [10, 11, 12]])
```

```
>>> np.concatenate([x, y])                    # axis=0 default
array([[ 1,  2,  3],
       [ 4,  5,  6],
       [ 7,  8,  9],
       [10, 11, 12]])
>>> np.concatenate([x, y], axis=1)
array([[ 1,  2,  3,  7,  8,  9],
       [ 4,  5,  6, 10, 11, 12]])
```

Per con array di dimensioni miste `numpy.hstack` e `numpy.vstack` tornano comode (per fare stack sulla prima o seconda dimensione)[1]:

```
>>> x = np.array([1, 2, 3])
>>> grid = np.array([[9, 8, 7],
...                  [6, 5, 4]])
>>> y = np.array([[99],
...               [99]])

>>> np.hstack([grid, y])     # horizontally stack the arrays
array([[ 9,  8,  7, 99],
       [ 6,  5,  4, 99]])
>>> np.vstack([x, grid])     # vertically stack the arrays
array([[1, 2, 3],
       [9, 8, 7],
       [6, 5, 4]])
```

9.3.5 Splitting (`split`, `vsplit`, `hsplit`)

`numpy.split` suddivide un array molteplici array. Si usano passando una lista di indici per indicare dove fare i tagli:

```
>>> x = [1, 2, 3, 99, 99, 3, 2, 1]     # split di array
>>> x1, x2, x3 = np.split(x, [3, 5])
>>> x1
array([1, 2, 3])
>>> x2
array([99, 99])
>>> x3
array([3, 2, 1])

>>> x = np.arange(10).reshape(5,2)     # di matrice
>>> x
array([[0, 1],
       [2, 3],
       [4, 5],
       [6, 7],
       [8, 9]])
>>> x1, x2, x3 = np.split(x, [1, 3])
>>> x1
array([[0, 1]])
```

[1] Analogamente `np.dstack` effettuerà lo stack sulla terza dimensione.

```
>>> x2
array([[2, 3],
       [4, 5]])
>>> x3
array([[6, 7],
       [8, 9]])
```

`hsplit`/`vsplit` sono funzioni di convenienza per splittare sulla prima o seconda dimensione, specularmente a `vstack`/`hstack`[2]

```
>>> x = np.arange(16).reshape((4, 4))
>>> x
array([[ 0,  1,  2,  3],
       [ 4,  5,  6,  7],
       [ 8,  9, 10, 11],
       [12, 13, 14, 15]])

>>> upper, lower = np.vsplit(x, [2])   # vertical split
>>> upper
array([[0, 1, 2, 3],
       [4, 5, 6, 7]])
>>> lower
array([[ 8,  9, 10, 11],
       [12, 13, 14, 15]])

>>> left, right = np.hsplit(grid, [2]) # horizontal split
>>> left
array([[9, 8],
       [6, 5]])
>>> right
array([[7],
       [4]])
```

9.3.6 Ripetizione/binding (`repeat`, `tile`)

Per ripetere:

- i singoli argomenti di un array, ciascuno n volte, si usa `repeat`; nel caso di array multidimensionali si può selezionare l'asse della ripetizione
- un array nel suo complesso usare `tile`: se il secondo argomento è un intero viene effettuata una copia per riga, con una tuple si specifica la struttura finale

```
>>> x = np.array([1,2,3])  # unidimensional repeat
>>> x.repeat(2)            # a) each element 2 time
array([1, 1, 2, 2, 3, 3])
>>> x.repeat([3,2,1])      # b) different times
array([1, 1, 1, 2, 2, 3])

>>> np.tile(x, 2)          # unidimensional tile
```

[2] Analogamente `numpy.dsplit` effettua il taglio sul terzo asse.

```
array([1, 2, 3, 1, 2, 3])

>>> x = np.arange(4).reshape(2,2) # multidimensional repeat
>>> x.repeat(2, axis = 0)         # a) by row, common number
array([[0, 1],
       [0, 1],
       [2, 3],
       [2, 3]])
>>> x.repeat([2,3], axis = 1)     # b) by col, different number
array([[0, 0, 1, 1, 1],
       [2, 2, 3, 3, 3]])

>>> np.tile(x, 2)                 # multidimensional tile (default by col)
array([[0, 1, 0, 1],
       [2, 3, 2, 3]])
>>> np.tile(x, (2, 3))            # specify the building repetition
array([[0, 1, 0, 1, 0, 1],
       [2, 3, 2, 3, 2, 3],
       [0, 1, 0, 1, 0, 1],
       [2, 3, 2, 3, 2, 3]])
>>> np.tile(x, (2, 1))            # by col
array([[0, 1],
       [2, 3],
       [0, 1],
       [2, 3]])
```

9.3.7 Sorting/ordine (`sort`, `argsort`)

Per

- ordinare un array usare il metodo `sort`. Nel caso di array multidimensionale, specificare `axis` per la dimensione di sorting:

```
>>> x = np.array([2,1,3,4])           # unidimensional sorting
>>> x.sort()
>>> x
array([1, 2, 3, 4])

>>> rand = np.random.RandomState(42) # bidimensional
>>> X = rand.randint(0, 10, (4, 6))
>>> np.sort(X, axis=0)               # sorting di ogni colonna
array([[2, 1, 4, 0, 1, 5],
       [5, 2, 5, 4, 3, 7],
       [6, 3, 7, 4, 6, 7],
       [7, 6, 7, 4, 9, 9]])
>>> np.sort(X, axis=1)               # sort di ogni riga
array([[3, 4, 6, 6, 7, 9],
       [2, 3, 4, 6, 7, 7],
       [1, 2, 4, 5, 7, 7],
       [0, 1, 4, 5, 5, 9]])
```

Da notare che negli ultimi due casi si perdono eventuali relazioni tra righe e colonne.

- ottenere gli indici dell'ordine si usa `argsort`

```
>>> x = np.array([2, 1, 4, 3, 5])
>>> i = np.argsort(x)
>>> i
array([1, 0, 3, 2, 4])
>>> x[i]
array([1, 2, 3, 4, 5])
```

9.4 Universal functions

9.4.1 Introduzione

Le universal functions (reference qui), o *ufunctions*, sono funzioni chiamate come

```
np.ufunc()
```

ed eseguite su tutti gli elementi di array in maniera vettorizzata.
Vi sono funzioni *unarie* (si applicano ad un array separatamente, le più importanti in tabella 9.3) e *binarie* (si applicando a più array, le più importanti in tab 9.4).
Gli operatori aritmetici e di comparazione (es `>=`) funzionano sotto la scocca, come *ufuncs* binarie di tabella (es `a+b` chiama `np.add(a,b)`).
Altre ufuncs si trovano in `scipy.special`

9.4.2 Metodi delle ufunction (`reduce`, `accumulate`, `outer`)

A quanto pare le ufunction in realtà assomigliano a classi aventi propri metodi (`reduce`, `accumulate`, `reduceat`, `outer`, `at`).
La chiamata di questi metodi è utile soprattutto per funzioni che prendono in input due argomenti e ne ritornano uno singolo in output (eg binarie):

- `reduce` applica una ufuncs agli elementi di un array sino a che un singolo risultato rimane
- `accumulate` fa l'operazione cumulata
- `outer` applica una funzione al prodotto cartesiano degli elementi di due array

Un esempio con `np.add`

```
>>> x = np.arange(1, 6)

>>> np.add.reduce(x)       # come np.sum(x)
np.int64(15)
>>> np.add.accumulate(x)  # come np.cumsum(x)
array([ 1,  3,  6, 10, 15])
>>> np.add.outer(x, x)
```

Funzione	Descrizione
`abs`, `fabs`	absolute value
`sqrt`	square root
`exp`, `expm1`	esponenziale, $\exp(x) - 1$
`log`, `log10`, `log2`, `log1p`	Natural log, log base 10, log base 2, and $log(1 + x)$, respectively
`sin`, `cos`, `tan`	trigonometriche
`arcsin`, `arccos`, `arctan`	trigonometriche inverse
`sign`	funzione segno: 1 se positivo, 0 se zero, o -1 se negativo
`ceil`	smallest integer $\geq$ to each element
`floor`	largest integer $\leq$ to each element
`rint`	round to nearest integer (preserving the dtype)
`isnan`	boolean indicating whether each value is NaN (Not a Number)
`isfinite`, `isinf`	each element is finite (non-inf , non-NaN) or infinite, respectively
`any`	per array booleani, testa se alcuni sono veri
`all`	per array booleani, testa se tutti sono veri
`logical_not`, `bitwise_not` (`~`)	logical not element-wise
`sum`	Sum of all the elements in the array or along an axis.
`prod`	Produttoria
`mean`	Arithmetic mean. Zero-length arrays have NaN mean.
`median`	Mediana
`percentile`	Percentile
`std`, `var`	Standard deviation and variance.
`min`, `max`	Minimum and maximum.
`argmin`, `argmax`	Indices of minimum and maximum elements, respectively.
`cumsum`	Cumulative sum of elements starting from 0
`cumprod`	Cumulative product of elements starting from 1

Tabella 9.3: *ufuncs* unarie

Funzione	Descrizione
`add` (+)	addition
`subtract` (-)	subtraction
`negative` (-)	unary negation
`multiply` (*)	multiplication
`divide` (/)	division
`floor_divide` (//)	resto divisione
`power` (**)	power
`mod` (%)	modulus remainder
`less` (<)	less than
`greater` (>)	
`less_equal` (<=)	
`greater_equal` (>=)	
`not_equal` (!=)	
`equal` (==)	
`maximum`, `fmax`	Element-wise maximum. `fmax` ignores `NaN`
`minimum`, `fmin`	Element-wise minimum. `fmin` ignores `NaN`
`logical_and`, `bitwise_and` (&)	and
`logical_or`, `bitwise_or` (|)	or
`logical_xor`, `bitwise_xor` (^)	xor
`matmul` (@)	Matrix product of two arrays
`cov`	covariance coefficient/matrix
`corrcoef`	correlation coefficient/matrix

Tabella 9.4: *ufuncs* binarie

```
array([[ 2,  3,  4,  5,  6],
       [ 3,  4,  5,  6,  7],
       [ 4,  5,  6,  7,  8],
       [ 5,  6,  7,  8,  9],
       [ 6,  7,  8,  9, 10]])
```

9.4.3 Creazione di ufunctions

Per la creazione di funzioni vettorizzate possiamo:

- scrivere funzioni in puro python e vettorizzarle con `np.frompyfunc` (o il wrapper `vectorize`).
  `numpy.frompyfunc` prende in input una funzione, il numero di inputs presi e il numero di outputs forniti; la funzione creata/ritornata restituisce sempre un array:

```
>>> def add1_worker(x):    # 1 input 1 output
...     return x + 1
...
>>> add1 = np.frompyfunc(add1_worker, 1, 1)
>>> add1(np.arange(10))
array([1, 2, 3, 4, 5, 6, 7, 8, 9, 10], dtype=object)

>>> def add2_worker(x, y): # 2 input, 1 output
```

```
...     return x + y
...
>>> add2 = np.frompyfunc(add2_worker, 2, 1)
>>> add2(np.arange(10), np.arange(10))
array([0, 2, 4, 6, 8, 10, 12, 14, 16, 18], dtype=object)

>>> def max_min_worker(x, y): # 2 input 2 output
...     return max(x, y), min(x, y) # pure python here
...
>>> maxmin = np.frompyfunc(max_min_worker, 2, 2)
>>> maxmin_wrong = np.frompyfunc(max_min_worker, 2, 1) # wrong in returned

>>> x = np.random.random(3)
>>> y = np.random.random(3)
>>> x
array([0.01106533, 0.900498  , 0.77940815])
>>> y
array([0.04608615, 0.3916269 , 0.50805576])
>>> maxmin(x, y)
(array([0.04608615426274154, 0.900497996286135, 0.7794081546383606],
      dtype=object), array([0.011065332922191584, 0.3916269037343899, 0.5080557598116051],
      dtype=object))
>>> maxmin_wrong(x, y)
array([(0.04608615426274154, 0.011065332922191584),
       (0.900497996286135, 0.3916269037343899),
       (0.7794081546383606, 0.5080557598116051)], dtype=object)
```

`numpy.vectorize` è una alternativa meno generale/più lenta che permette di specificare il tipo ritornato la funzione.

- utilizzare compilatori LLVM con `numba` a partire da funzioni Python. Mediante Numba si creano funzioni veloci mediante il progetto LLVM (che traduce codice python in codice macchina eseguibile da CPU o GPU). Vedere `https://wesmckinney.com/book/advanced-numpy.html#numpy_numba`
- utilizzare l'interfaccia C (modo più generale)

9.5 Broadcasting

Per

- array della stessa dimensionalità le operazioni aritmetiche vengono effettuate elemento per elemento

```
>>> x = np.array([0, 1, 2])
>>> y = np.array([5, 5, 5])
>>> x + y
array([5, 6, 7])
```

- array di diverse dimensioni opera il *broadcasting*, ossia un set di regole per applicare ufuncs binarie ad array di dimensioni non uguale. Alcuni esempi:

```
>>> # aggiunta di costante ad array: il valore 5 viene espanso a [5 5 5] prima d
>>> x + 5
array([5, 6, 7])

>>> # aggiunta di vettore a matrice il vettore viene stretchato sulla
>>> # seconda dimensione per matchare la forma della matrice
>>> M = np.ones((3, 3))
>>> M
array([[1., 1., 1.],
       [1., 1., 1.],
       [1., 1., 1.]])
>>> M + x
array([[1., 2., 3.],
       [1., 2., 3.],
       [1., 2., 3.]])

>>> # somma di vettore 1 x 3 con sua trasposta 3 x 1: entrambi gli array
>>> # sono stretchati fino a raggiungere una dimensione comune (due
>>> # matrici $3 x 3$) dopodiché viene effettuata la somma.
>>> x = np.arange(3)
>>> y = x.reshape(3,1).copy()
>>> x
array([0, 1, 2])
>>> y
array([[0],
       [1],
       [2]])
>>> x + y
array([[0, 1, 2],
       [1, 2, 3],
       [2, 3, 4]])
```

La geometria di esempi del genere è visualizzata in figura **??**; non vi è una vera e propria espansione in memoria per ragioni di efficienza ma è utile tenere a mente come modello.

Regole di funzionamento Informalmente funziona abbastanza similmente al recycling di R: l'array più piccolo viene replicato per matchare quello più grande[3]. Formalmente le regole applicate in sequenza sono:

1. se gli array differiscono nel numero di dimensioni (il numero di elementi di `shape`), la forma di quello con un numero inferiori di dimensioni è riempita a sinistra con 1;

2. una volta uniformati `numpy` confronta gli `shape`, elemento (dimensione) per elemento, partendo dall'ultimo. Due dimensioni sono *compatibili* quando sono alternativamente uguali o una di esse è 1: se

   - *tutte le dimensioni sono compatibili* verrà eseguita l'operazione

[3] Il broadcasting è lievemente più sicuro/meno flessibile perché funziona solamente se la struttura matcha perfettamente o se si ha un array di un elemento (è questo che di fatto viene riciclato).

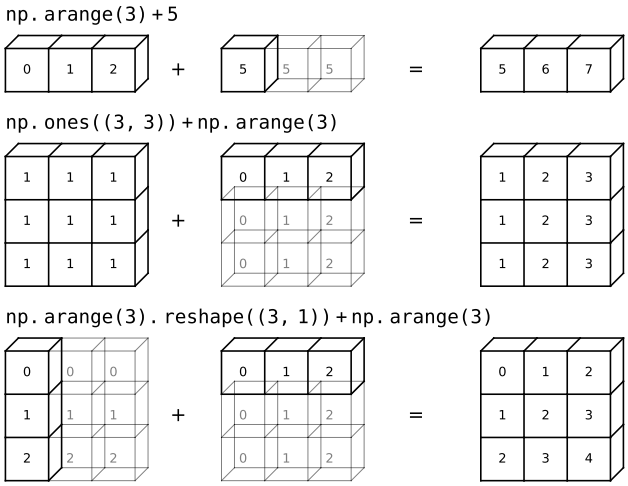


Figura 9.1: Broadcasting geometrics.

- *non tutte sono compatibili* viene sollevata l'eccezione e l'operazione termina

Nel caso di dimensioni compatibili, se due dimensioni non sono uguali, l'array con shape 1 in quella dimensione viene stretchato per matchare l'altra dimensione;

Example 9.5.1 (Somma di un array bidimensionale a monodimensionale)**.** Abbiamo:

```
>>> M = np.ones((2, 3))
>>> a = np.arange(3)
>>> M
array([[1., 1., 1.],
       [1., 1., 1.]])
>>> a
array([0, 1, 2])

>>> ## le shape sono
>>> M.shape
(2, 3)
>>> a.shape
(3,)
```

Applicando le regole del broadcasting:

1. per la regola 1 l'array `a` ha meno dimensioni quindi viene riempito sulla sinistra

   ```
   M.shape -> (2, 3)
   a.shape -> (1, 3)
   ```

2. vediamo quali dimensioni non sono in agreement, queste verranno stretchate per matchare

   ```
   M.shape -> (2, 3)
   a.shape -> (2, 3)
   ```

   Ora le shape matchano e la shape del risultato finale sarà `(2, 3)`

```
>>> M+a
array([[1., 2., 3.],
       [1., 2., 3.]])
```

Example 9.5.2 (Entrambi gli array necessitano di broadcasting)**.** Abbiamo:

```
>>> a = np.arange(3).reshape((3, 1))
>>> b = np.arange(3)
>>> a
array([[0],
       [1],
       [2]])
>>> b
array([0, 1, 2])
>>> a.shape
(3, 1)
>>> b.shape
(3,)
```

Si ha:

1. Per regola 1 `b` viene riempito sulla sinistra con 1

   ```
   a.shape -> (3, 1)
   b.shape -> (1, 3)
   ```

2. per regola 2 facciamo l'upgrade degli 1 per matchare la dimensione dell'array

   ```
   a.shape -> (3, 3)
   b.shape -> (3, 3)
   ```

3. visto che matchano il risultato sarà un array 3×3

Example 9.5.3 (Array incompatibili)**.** Un caso lievemente diverso dal primo dove `M` è trasposta

```
>>> M = np.ones((3, 2))
>>> a = np.arange(3)
>>> M
array([[1., 1.],
       [1., 1.],
       [1., 1.]])
>>> a
array([0, 1, 2])
```

```
>>> M.shape
(3, 2)
>>> a.shape
(3,)
```

Per regola

1. riempiamo a sinistra `a`

   ```
   M.shape -> (3, 2)
   a.shape -> (1, 3)
   ```

2. la prima dimensione di `a` è stretchata e si ha

   ```
   M.shape -> (3, 2)
   a.shape -> (3, 3)
   ```

3. le dimensioni finali non matchano quindi viene sollevato un errore

```
>>> M + a
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: operands could not be broadcast together with shapes (3,2) (3,)
```

9.6 Altri argomenti

9.6.1 Lavorare con booleani

Vediamo un po' di applicazioni utili

```
>>> ## dati
>>> rng = np.random.RandomState(0)
>>> n = rng.randint(10, size=(3, 4)) # interi uniformi < 10
>>> x = np.array([True, False, True, False])
>>> y = np.array([True, True, False, False])

>>> ## operatori booleani vettorizzati
>>> x & y              # np.bitwise_and
array([ True, False, False, False])
>>> x | y              # np.bitwise_or
array([ True,  True,  True, False])
>>> ~x                 # np.bitwise_not
array([False,  True, False,  True])
>>> x ^ y              # np.bitwise_xor
array([False,  True,  True, False])

>>> ## any/ all
>>> np.any(n > 8)
np.True_
>>> np.all(n < 10)
np.True_
>>> np.all(n < 8, axis=1)
```

```
array([ True, False,  True])

>>> ## conta di elementi che rispettano un test
>>> np.sum(n < 6)              # overall
np.int64(8)
>>> np.sum(n < 6, axis = 1)    # per riga
array([4, 2, 2])
>>> np.sum(n > 6, axis = 0)    # per colonna
array([1, 1, 1, 0])

>>> ## if then else vettorizzato: np.where(test, iftrue, iffalse)
>>> t = np.arange(6)
>>> f = -t
>>> test = np.array([True, False] * 3)
>>> res = np.where(test, t, f)
>>> res
array([ 0, -1,  2, -3,  4, -5])

>>> # recoding con np.where
>>> c = np.where(t > 3, 3, np.where(t > 1, 2, 1))
>>> c
array([1, 1, 2, 2, 3, 3])

>>> # o con algebra e logica pura
>>> d = 1 + (t > 1) + (t > 3)
>>> d
array([1, 1, 2, 2, 3, 3])
```

9.6.2 Array di stringhe

Gli array possono immagazzinare anche stringhe, ma queste devono essere di dimensione fissata per motivi di efficienza

```
>>> names = ["luca", "bob", "joe"]
>>> x = np.array(names)
>>> x.dtype  # stringhe di 4 elementi al massimo
dtype('<U4')
>>> x[0][0:2]  # utilizzo di indici
'lu'
>>> # sono comunque normali stringhe eh ...
>>> for i in range(3):
...     x[i] = x[i].capitalize()
...
>>> x
array(['Luca', 'Bob', 'Joe'], dtype='<U4')
>>> # ... ma di lunghezza massima fissata
>>> x[2] = "asdasdasd"  # assegnazione, ocio si tronca silentemente
>>> x
array(['Luca', 'Bob', 'asda'], dtype='<U4')

>>> # per allocare più spazio, ad esempio
```

```
>>> y = np.array(names, dtype = '<U16')
>>> y[2] = "asdasdasd"
>>> y
array(['luca', 'bob', 'asdasdasd'], dtype='<U16')
```

Per creare array di *stringhe di dimensione variabili* non preventivabile a priori si può usare `dtype=object`. Così facendo si crea un array di oggetti generici al quale si può assegnare la qualunque: si perde però l'efficienza di `numpy` (che non lavora più diretto in sequenze contigue di memoria e usare oggetti python aggiunge un sacco di overhead):

```
>>> ## https://stackoverflow.com/questions/14639496
>>> x = np.array(['apples', 'foobar', 'cowboy'], dtype=object)
>>> x
array(['apples', 'foobar', 'cowboy'], dtype=object)
>>> x[2] = "asdasdasd"
>>> x
array(['apples', 'foobar', 'asdasdasd'], dtype=object)

>>> for i in range(3):
...     x[i] = x[i].capitalize()
...
>>> x
array(['Apples', 'Foobar', 'Asdasdasd'], dtype=object)

>>> # A questo array si può assegnare la qualunque ..
>>> x[1] = {1:2, 3:4}
>>> x
array(['Apples', {1: 2, 3: 4}, 'Asdasdasd'], dtype=object)
```

Capitolo 10

Pandas

Contents

10.1 Data I/O 79
10.1.1 Importazione dati 79
10.1.2 Importazione con dati mancanti 79
10.1.3 Esportazione 79
10.2 `Series` 79
10.2.1 Creazione 80
10.2.2 Contenuto (`array`, `index`, `name`, `dtype`) 80
10.2.3 Indexing e selezione 80
10.2.4 Modifica valori 80
10.2.5 Funzionalità per indici (`reset_index`, `rename`) . . . 80
10.2.6 Rimozione elementi (selezione, `drop`, `del`) 81
10.2.7 Elaborazione vettorizzata 81
10.2.8 Elaborazione allineata 81
10.2.9 Coercizione di tipo (`astype`) 81
10.2.10 Valori condizionali a-la `ifelse` (`.where`) 81
10.2.11 Applicazione di una funzione (`map`) 81
10.2.12 Applicazione di più funzioni (`.agg`) 81
10.2.13 Sostituzione (`replace`) o recode (`map`) 82
10.2.14 Test di appartenenza (`in`, `isin`) 82
10.2.15 Dati mancanti 82
10.2.16 Duplicati 82
10.2.17 Sorting 82
10.2.18 Discretizzazione/creazione di classi (`cut`, `qcut`) . . . 82
10.2.19 Dummy variables 82
10.2.20 Stringhe 83
10.2.21 Date/ore 83
10.2.22 Dati categorici (`Categorical`) 84
10.2.23 Indexing gerarchico e reshape 84
10.3 `DataFrame` 85
10.3.1 Creazione 85

10.3.2 Contenuto (`info`, `shape`, `index`, `columns`, `values`, `name`) . . . 85
10.3.3 Selezione . . . 85
10.3.4 Modifica valori . . . 87
10.3.5 Aggiunta di colonne . . . 87
10.3.6 Rimozione righe/colonne (`drop`, `del`) . . . 88
10.3.7 Rinominare colonne/indici (`rename`) . . . 88
10.3.8 Gestione indici . . . 88
10.3.9 Elaborazione allineata . . . 89
10.3.10 Coercizione di tipi (`astype`) . . . 89
10.3.11 Applicazione di funzioni . . . 89
10.3.12 Ciclo su righe/colonne . . . 90
10.3.13 Merge . . . 90
10.3.14 Binding (`pd.concat`) . . . 91
10.3.15 Reshape . . . 91
10.3.16 Test di appartenenza (`in`, `isin`) . . . 92
10.3.17 Dati mancanti . . . 92
10.3.18 Duplicati . . . 92
10.3.19 Sorting . . . 93
10.4 Descrittive . . . 93
10.4.1 Info generali . . . 93
10.4.2 Univariate . . . 93
10.4.3 Bivariate . . . 94
10.5 Cookbook . . . 96
10.5.1 Stampa tutto il contenuto di un DataFrame . . . 96
10.5.2 Old stuff . . . 97

Fornisce strutture (`Series` array unidimensionale, `DataFrame`, array bidimensionale, `Index`/`MultiIndex` per indici[1]) e routines per gestione dati.

```
>>> import pandas as pd
>>> pd.__version__
'3.0.0'
>>> import numpy  as np  # spesso utile/necessario
>>> import pylbmisc as lb
```

10.1 Data I/O

10.1.1 Importazione dati

L'importazione di dati in un dataframe avviene mediante le funzioni `pd.read_*`

[1] L'`Index` è l'oggetto che fornisce i metadati necessari per `Series`, nonchè per righe e colonne del `DataFrame`. Alcune peculiarità:

- sono oggetti *immutabili* e non possono essere modificati una volta creati;
- possono contenere doppi;
- possono essere condivisi tra strutture di dati;
- si usa `in` per testare la presenza di un dato indice in un oggetto `Index`.

```
# wrapper
df = lb.io.import_data("paths")

# File testuali
df = pd.read_csv('path.csv')  # separatore virgola di default
df = pd.read_csv('path.csv', sep = ';')   # separatore punto e virgola
df = pd.read_csv('path.csv', sep = '\t')  # separatore tab

# Alcuni binari notevoli
df = pd.read_excel('path.xlsx', sheet_name = 'asd')  # file xlsx
df = pd.read_pickle('path.pkl')      # formato binario Python
```

10.1.2 Importazione con dati mancanti

Al fine di avere un tipo di dato che supporti `pd.NA` al meglio, specificare:

```
# lettura
df = pd.read_csv(path, dtype_backend="pyarrow")

# coercizione
df.convert_dtypes(dtype_backend="pyarrow")
series.convert_dtypes(dtype_backend="pyarrow")
```

10.1.3 Esportazione

L'esportazione usa i metodi `to_*` dei `DataFrame`.

```
# wrapper
df = lb.io.export_data(df_or_dict_of_dfs, path)

# File testuali
df.to_csv('path.csv')
df.to_csv('path.csv', index = False) # non scrivere l'indice
df.to_csv('path.csv', sep = ";", quoting = csv.QUOTE_NONNUMERIC) # read.csv2

# Binari
df.to_excel('path.xlsx') # singolo
df.to_pickle('path.pkl')
```

10.2 Series

`Series` è un array unidimensionale, di contenuto omogeneo, , dotato (eventualmente) di etichette/labels (index) (può essere pensato come un `dict`).

10.2.1 Creazione

Il modo base per creare una `Series` è

```
data = [1,2,3]
index = ["a", "b", "c"]
x = pd.Series(data)       # senza indici (data: lista, np.array o scalare)
```

```
y = pd.Series(data, index = idx)    # con indici, forniti

a_dict = {"a":1, "b":2, "c":3}
z = pd.Series(a_dict)       # con indici, quelli del dict
```

10.2.2 Contenuto (array, index, name, dtype)

Gli elementi principali di una serie sono `array` (un oggetto che wrappa un array `numpy`) ed `index`; infine sia serie che `index` hanno l'attributo `name`, sfruttato da pandas qua e la

```
>>> x = pd.Series({'luca': 23, 'andrea': 12, 'davide': 15})
>>> x.array
<NumpyExtensionArray>
[23, 12, 15]
Length: 3, dtype: int64
>>> x.index
Index(['luca', 'andrea', 'davide'], dtype='str')
>>> x.name = 'età_anni'
>>> x.index.name = 'giocatore'
>>> x
giocatore
luca      23
andrea    12
davide    15
Name: età_anni, dtype: int64
```

10.2.3 Indexing e selezione

10.2.3.1 Utilizzo di []

Nel caso di un array con indici numerici possiamo utilizzare interi, liste, booleani (non nulli) o funzioni che li restituiscono.

```
>>> x = pd.Series([4, 1, 2, 3])
>>> x[0]                              # un intero
np.int64(4)
>>> x[[0]]                            # lista di un intero
0    4
dtype: int64
>>> x[[3, 0, 1]]                      # lista di interi
3    3
0    4
1    1
dtype: int64
>>> x[:2]                             # slicing
0    4
1    1
dtype: int64
>>> x[[True, False, False, True]]     # bool non NA
0    4
3    3
```

```
dtype: int64
>>> # x[[True, False, pd.NA, True]] # FAILS!
>>> x[lambda x: x > 2]              # predicato
0    4
3    3
dtype: int64
```

Nel caso di un array con indici stringa funziona come sopra, ad eccezione di interi o liste di interi (non utilizzabili) e si possono fornire stringhe/liste di stringhe o slice di stringhe. Di sotto le peculiarita

```
>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3}) # con indici
>>> # y[0]                              # FAILS!
>>> # y[[1,2,3]]                        # FAILS!
>>> y["a"]                              # stringa
np.int64(2)
>>> y[["b", "d"]]                       # lista di stringhe
b    1
d    4
dtype: int64
>>> y['d':'a']                          # slicing con stringhe: estremi inclusi
d    4
b    1
a    2
dtype: int64
```

10.2.3.2 `.iloc`

`iloc` accetta interi o booleani (o una funzione che filtri) e funziona sia che la serie abbia indici numerici che stringa

```
>>> x = pd.Series([4, 1, 2, 3])
>>> x.iloc[[1, 3]]
1    1
3    3
dtype: int64
>>> x.iloc[[True, False, True, False]]
0    4
2    2
dtype: int64
>>> x.iloc[lambda x: x > 2]
0    4
3    3
dtype: int64
```

10.2.3.3 `.loc`

`loc` funziona solamente per Serie con indici stringa (per sicurezza) e accetta booleani, predicati che li producono o stringhe/liste di

```
>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3})

>>> y.loc[y > 2]           # array di booleani
```

```
d    4
c    3
dtype: int64
>>> y.loc["a"]             # stringha
np.int64(2)
>>> y.loc[["a"]]           # lista di stringhe
a    2
dtype: int64
>>> y.loc[lambda x: x > 2] # predicato
d    4
c    3
dtype: int64
```

10.2.3.4 Altri metodi di selezione (`.filter`, `.reindex`)

Il metodo

- `filter` restituisce i subset i quali indici soddisfano criteri, similmente a quanto visto sopra, ma accetta anche regex in input

  ```
  >>> y = pd.Series({"d":4, "b":1, "a":2, "c":3})
  >>> y.filter(items = ["a", "b"])
  a    2
  b    1
  dtype: int64
  ```

- `reindex` estrae in base agli indici, non accetta doppi nelle chiavi ma riempie buchi senza sollevare eccezioni (es indici richiesti non esistenti)

  ```
  >>> y = pd.Series({"d":4, "b":1, "a":2, "c":3})
  >>> y.reindex(["d", "x"])
  d    4.0
  x    NaN
  dtype: float64
  ```

10.2.4 Modifica valori

Funzionante mediante indici (e broadcasting)

```
>>> x = pd.Series([4, 1, 2, 3])                  # Indici numerici
>>> x[0] = 2
>>> x[:] = 0   # annullare un vettore; x = 0 è sbagliato

>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3}) # con indici
>>> y["a"] = 5 # con indici
>>> y[:]   = 1 # settare tutti gli elementi a 1
```

10.2.5 Funzionalità per indici (`reset_index`, `rename`)

Il metodo

- `reset_index` sostituisce l'indice con un prograssivo numerico e restituisceun dataframe col vecchio indice come variabile e la vecchia variabile

```
>>> y = pd.Series({"d":4, "b":1, "a":2, "c":3}) # con indici
>>> y.reset_index()
  index  0
0     d  4
1     b  1
2     a  2
3     c  3
```

- `rename` effettua un recode dell'indice

```
>>> y.rename({"a": "x", "b": "y"})
d    4
y    1
x    2
c    3
dtype: int64
```

10.2.6 Rimozione elementi (selezione, `drop`, `del`)

Si può

- effettuare una selezione in uno dei modi di sopra ed assegnare allo stesso nome (che *tiene* gli indici specificati)
- utilizzare il metodo `drop` che *rimuove* temporaneamente gli indici specificati (quindi sarà necessario assegnare)

```
>>> x = pd.Series([1, 2, 3], index = ['a', 'b', 'c'])
>>> x.drop('b') # Rimozione temporanea
a    1
c    3
dtype: int64
>>> x           # la modifica non è salvata
a    1
b    2
c    3
dtype: int64
```

- utilizzare `del` per rimuovere senza necessità di assegnazione

```
>>> del x['b']  # rimozione definitiva
>>> x
a    1
c    3
dtype: int64
```

10.2.7 Elaborazione vettorizzata

Similmente a numpy le elaborazioni sono vettorizzate (si applicano *ufuncs* e broadcasting); viene preservato l'indice:

```
>>> x = pd.Series([0,1,2])
>>> np.exp(x) + 1
```

```
0    2.000000
1    3.718282
2    8.389056
dtype: float64
```

10.2.8 Elaborazione allineata

Le elaborazioni aventi per oggetto due serie diverse avvengono sulla base degli indici, effettuando il cosiddetto allineamento automaticamente

```
>>> x = pd.Series({'a': 1, 'c': 2, 'b': 3})
>>> y = pd.Series({'c': 1, 'b': 0, 'd': 0})
>>> x * y
a    NaN
b    0.0
c    2.0
d    NaN
dtype: float64
```

`a` non può essere calcolato perché manca in `y`, `d` perché manca in `x`.

10.2.9 Coercizione di tipo (`astype`)

Si usa il metodo `astype` fornendo alternativamente un tipo builtin di Python, una stringa, un `numpy.dtype` o i tipi di pandas

```
>>> a = pd.Series(["1", "2"])
>>> a.astype("Int64")    # stringa
0    1
1    2
dtype: Int64
>>> a.astype("category") # pandas type
0    1
1    2
dtype: category
Categories (2, str): ['1', '2']
```

10.2.10 Valori condizionali a-la `ifelse` (`.where`)

`pd.Series.where` prende in input una serie booleana (o un predicato) e rimpiazza con `other` laddove la condizione è `False`

```
>>> x = pd.Series(["a", "b", "c"])
>>> test = pd.Series([True, False, True])
>>> x.where(test, other = "qweqwe")
0         a
1    qweqwe
2         c
dtype: str
```

10.2.11 Applicazione di una funzione (`map`)

Per applicare una funzione per scalare a tutti gli elementi di una `Series` utilizzare `map`

```
>>> rng = np.random.default_rng(6235)
>>> x = pd.Series(rng.random(3))
>>> x.map(lambda x: f"{x:.2f}") # esempio di formattazione
0    0.55
1    0.67
2    0.73
dtype: str
```

10.2.12 Applicazione di più funzioni (`.agg`)

`agg` permette di applicare più funzioni alla stessa serie, per info sui metodi vedere Harrison pag 67. Di base quando gli si passa una stringa (es "mean" pandas mappa al metodo corrispondente per le serie)

```
>>> s = pd.Series([1, 2, 3, 4])
>>> s.agg(['min', 'max', np.var, lambda x: x[2]])
min         1.00
max         4.00
var         1.25
<lambda>    3.00
dtype: float64
```

10.2.13 Sostituzione (`replace`) o recode (`map`)

Se si vuole sostituire solo alcuni elementi e lasciare invariati gli altri si usa `replace`:

```
>>> a = pd.Series(["1", "2", "3"])
>>> a.replace({"1" : "1-2", "2":"1-2"})
0    1-2
1    1-2
2      3
dtype: str
```

Se a `map` di passa un dict effettua dei *recode* (il mapping deve essere completo):

```
>>> a = pd.Series(["1", "2", "3"])
>>> rec = {"1":"1-2", "2":"1-2", "3":"3-4", "4":"3-4"}
>>> a.map(rec)
0    1-2
1    1-2
2    3-4
dtype: str
```

10.2.14 Test di appartenenza (`in`, `isin`)

Con

- la keyword `in` testa l'esistenza *negli indici*:

```
>>> x = pd.Series([1, 3], index = ['a', 'c'])
>>> 'b' in x
False
```

- il metodo `isin` si testa *nei valori*:

```
>>> x.isin([1, 2]) # uso di valori
a     True
c    False
dtype: bool
```

10.2.15 Dati mancanti

Vediamo metodi/funzioni più utili a livello di `Series`: generalmente se non si usa `inplace` i metodi restituiscono una copia.

```
>>> z = pd.Series([1, pd.NA, None], dtype = "Int64")

>>> z.isna()      # test; z.notna() sua negazione
0    False
1     True
2     True
dtype: bool
>>> z.dropna()    # filtrare
0    1
dtype: Int64
>>> z.fillna(-9) # riempimento
0     1
1    -9
2    -9
dtype: Int64
```

10.2.16 Duplicati

I metodi più utili:

```
>>> x = pd.Series([1, 2, 2, pd.NA, pd.NA], dtype="Int64")
>>> x.duplicated()        # marca i doppi (anche gli NA)
0    False
1    False
2     True
3    False
4     True
dtype: bool
>>> x.drop_duplicates()  # rende unica: restituisce Series
0       1
1       2
3    <NA>
dtype: Int64
>>> x.unique()           # rende unica: restituisce ndarray
```

```
<IntegerArray>
[1, 2, <NA>]
Length: 3, dtype: Int64
```

10.2.17 Sorting

Se si vuole ordinare sulla base degli indici si usa il metodo `sort_index`, sulla base dei valori si usa il metodo `sort_values`

```
>>> x = pd.Series([1, 3, 2], index=["d", "a", "b"])
>>> x.sort_index()
a    3
b    2
d    1
dtype: int64
>>> x.sort_values()
d    1
b    2
a    3
dtype: int64
```

10.2.18 Discretizzazione/creazione di classi (`cut`, `qcut`)

Si usa la funzione `cut` sulla `Series` (che ha la peculiarità di restituire un oggetto `Categorical` che presenta notevoli somiglianze coi factor). Si possono fornire i breaks o il numero per breaks equispaziati.
`qcut` invece effettua un `cut` sulla base dei quantili.

```
>>> rng = np.random.default_rng(12093)
>>> age = pd.Series(rng.integers(1, 100, size = 5))
>>> age
0    32
1     2
2    79
3    26
4    93
dtype: int64
```

```
>>> # cuts specificati
>>> cuts = [0, 25, 50, 75, 100]
>>> labs = ["giovane", "medio", "senior", "anziano"]
>>> pd.cut(age, bins = cuts, labels = labs) # cuts specificati
0      medio
1    giovane
2    anziano
3      medio
4    anziano
dtype: category
Categories (4, str): ['giovane' < 'medio' < 'senior' < 'anziano']
>>> pd.cut(age, bins = 3)  # 3 cut equispaziati tra minimo e massimo
0    (1.909, 32.333]
```

```
1    (1.909, 32.333]
2     (62.667, 93.0]
3    (1.909, 32.333]
4     (62.667, 93.0]
dtype: category
Categories (3, interval[float64, right]): [(1.909, 32.333] < (32.333, 62.667] < (62.6
>>> pd.qcut(age, q = 5)     # quintile of age
0     (29.6, 50.8]
1    (1.999, 21.2]
2     (50.8, 81.8]
3     (21.2, 29.6]
4     (81.8, 93.0]
dtype: category
Categories (5, interval[float64, right]): [(1.999, 21.2] < (21.2, 29.6] < (29.6, 50.8
                                           (50.8, 81.8] < (81.8, 93.0]]
```

10.2.19 Dummy variables

10.2.19.1 Utilizzo base (`get_dummies`)

Per creare un `DataFrame` di dummy a partire da una serie si usa `get_dummies`

```
>>> x = pd.Series(["a","a","b", pd.NA]) # occhio ai na che sono ignorati
>>> pd.get_dummies(x, prefix="xvar", dtype = "Int64")
   xvar_a  xvar_b
0       1       0
1       1       0
2       0       1
3       0       0
```

10.2.19.2 Variabili a risposta multipla (`str.get_dummies`)

`str.getdummies` crea dummy utile per specificare i separatori (es per risposte multiple)

```
>>> x = pd.Series(["a|b", "b|c", "a", "a|b|c"])
>>> x.str.get_dummies(sep = "|")
   a  b  c
0  1  1  0
1  0  1  1
2  1  0  0
3  1  1  1
```

10.2.20 Stringhe

Vediamo alcune funzionalità utili delle `Series` di stringhe.

- Vi sono metodi direttamente accedibili dalla `Series`
- altri metodi sono accedibili da `Series.str`

Ad ogni modo vi è overlap con i metodi delle `str` Python di base.

```
>>> suits = pd.Series(["clubs", "Diamonds", "hearts", "Spades"])
>>> rps = pd.Series(["ROck ", " paper", "sciSSORS"])
```

10.2.20.1 Paste

```
>>> rps + "5"           # aggiungi in coda
0       ROck 5
1       paper5
2    sciSSORS5
dtype: str
>>> rps * 2             # aggiungi in coda
0          ROck ROck
1         paper paper
2    sciSSORSsciSSORS
dtype: str
>>> rps + rps.str[::-1] # paste di due serie
0          ROck  kcOR
1         paperrepap
2    sciSSORSSROSSics
dtype: str
>>> rps.str.cat(rps)      # aggiungi in coda
0          ROck ROck
1         paper paper
2    sciSSORSsciSSORS
dtype: str
```

10.2.20.2 Collapse

```
>>> rps.str.cat(sep=", ")
'ROck ,  paper, sciSSORS'
```

10.2.20.3 Formattazione varia

```
>>> rps.str.strip()               # elimina bianchi
0        ROck
1       paper
2    sciSSORS
dtype: str
>>> rps.str.pad(8, fillchar="_")  # aggiungi caratteri per uniformare lunghezza
0    ___ROck
1    __ paper
2    sciSSORS
dtype: str
>>> rps.str.lower()               # tutto minuscolo
0       rock
1       paper
2    scissors
dtype: str
>>> rps.str.upper()               # maiuscolo
0       ROCK
1       PAPER
2    SCISSORS
dtype: str
```

Per incollare/formattare assieme due/più stringhe selezionarle e applicare una funzione ad hoc per riga al dataframe

```
>>> tmp = pd.DataFrame({
...     "l": ["a", "b", "c"],
...     "n": ["1", "2", "3"]
... })

>>> tmp.apply(lambda row: f"{row["l"]} ({row["n"]})", # funzione di formattazione
...           axis=1) # applicala per riga
0    a (1)
1    b (2)
2    c (3)
dtype: str
```

10.2.20.4 Lunghezza ed sottostringhe

```
>>> rps.str.len()                 # lunghezza
0    5
1    6
2    8
dtype: int64
>>> rps.str[2:5]                  # subsetting stringa (es)
0    ck
1    ape
2    iSS
dtype: str
```

10.2.20.5 Splitting

```
>>> agecl = pd.Series(["0-10", "11-15", "11-15"])
>>> agecl.str.split("-", expand=True)              # ritorna un df
    0   1
0   0  10
1  11  15
2  11  15
>>> agecl.str.split("-", expand=True).iloc[:, 1]    # tieni solo limite superiore
0    10
1    15
2    15
Name: 1, dtype: str
```

10.2.20.6 Ricerca/rimpiazzo

```
>>> # Ricerca
>>> # -------
>>> suits.str.contains("[ae]")  # ne ha?
0    False
1     True
2     True
3     True
dtype: bool
```

```
>>> suits.str.count("[ae]")     # conta quanti
0    0
1    1
2    2
3    2
dtype: int64
>>> suits.str.find("e")         # trova posizione match
0   -1
1   -1
2    1
3    4
dtype: int64

>>> # Ricerca e rimpiazzo semplice
>>> # ----------------------------
>>> suits.str.replace("a", "4") # str.replace per rimpiazzare singola lettera
0       clubs
1    Di4monds
2      he4rts
3      Sp4des
dtype: str
>>> suits.replace("Diamonds", "foobar") # .replace per parole intere
0     clubs
1    foobar
2    hearts
3    Spades
dtype: str
>>> suits.replace({"Diamonds": "foobar", "Spades": "asdasd"})
0     clubs
1    foobar
2    hearts
3    asdasd
dtype: str

>>> # Ricerca ed estrazione mediante regex
>>> # ------------------------------------
>>> import re
>>> x = pd.Series(["primo incontro_PF_02", "primo incontro_PF_03"])
>>> reg = re.compile(r"^([\w ]+?)_(\w+)")
>>> x.apply(lambda x: reg.sub(r"\1", x))  # extract_time
0    primo incontro
1    primo incontro
dtype: str
>>> x.apply(lambda x: reg.sub(r"\2", x))  # extract_pz
0    PF_02
1    PF_03
dtype: str
```

10.2.21 Date/ore

Vediamo alcune funzionalità utili delle `Series` di date/ore. Qui invece vi è legame col modulo `datetime`.

10.2.21.1 Parsing da stringa

```
>>> # alcune stringhe in vari formati di data/or
>>> iso = pd.Series(["1969-07-20 20:12:40",
...                  "1969-11-19 06:54:35",
...                  "1971-02-05 09:18:11"])

>>> eu = pd.Series(["20/07/1969 20:12:40",
...                 "19/11/1969 06:54:35",
...                 "05/02/1971 09:18:11"])

>>> us = pd.Series(["07/20/1969 20:12:40",
...                 "11/19/1969 06:54:35",
...                 "02/05/1971 09:18:11"])

>>> pd.to_datetime(iso) # iso works out of the box (anche se solo data es 2020-10-01)
0   1969-07-20 20:12:40
1   1969-11-19 06:54:35
2   1971-02-05 09:18:11
dtype: datetime64[us]
>>> pd.to_datetime(eu, dayfirst = True) # opzione per eu
0   1969-07-20 20:12:40
1   1969-11-19 06:54:35
2   1971-02-05 09:18:11
dtype: datetime64[us]
>>> pd.to_datetime(us, dayfirst = False) # opzione per us
0   1969-07-20 20:12:40
1   1969-11-19 06:54:35
2   1971-02-05 09:18:11
dtype: datetime64[us]
>>> pd.to_datetime(eu, format="%d/%m/%Y %H:%M:%S") # formato custom (non necessario q
0   1969-07-20 20:12:40
1   1969-11-19 06:54:35
2   1971-02-05 09:18:11
dtype: datetime64[us]
```

10.2.21.2 Creazione da componenti

```
>>> componenti = pd.DataFrame({
...     "year" : [1969, 1969, 1971],
...     "month" : [7, 11, 2],
...     "day" : [20, 19, 5]
... })
>>> pd.to_datetime(componenti)
0   1969-07-20
1   1969-11-19
2   1971-02-05
```

```
dtype: datetime64[us]
```

10.2.21.3 Estrazione componenti

```
>>> # Estrazione componenti
>>> isod = pd.to_datetime(iso)

>>> isod.dt.year
0    1969
1    1969
2    1971
dtype: int32
>>> isod.dt.month
0     7
1    11
2     2
dtype: int32
>>> isod.dt.month_name("it_IT.UTF-8") # see shell `locale`
0      Luglio
1    Novembre
2    Febbraio
dtype: str
>>> isod.dt.day
0    20
1    19
2     5
dtype: int32
>>> isod.dt.day_name()
0       Sunday
1    Wednesday
2       Friday
dtype: str
```

10.2.21.4 Esportazione a stringa

```
>>> # da datetime a data (ocio che è una stringa)
>>> isod.dt.date
0    1969-07-20
1    1969-11-19
2    1971-02-05
dtype: object

>>> # esportare a stringa
>>> isod.dt.strftime("%d/%m/%Y")
0    20/07/1969
1    19/11/1969
2    05/02/1971
dtype: str
```

10.2.21.5 Conversione di tipo/arrotondamenti

```
>>> # rimozione dell'ora (tenere solo la data in formato datetime)
>>> isod.dt.normalize()
0   1969-07-20
1   1969-11-19
2   1971-02-05
dtype: datetime64[us]

>>> # arrotondare datetime alla data (specificando il formato sono disponibili
>>> # altri arrotondamenti, es H, M, S per ore minuti secondi, poi possibile
>>> # arrotondare a 2H 3M etc)
>>> isod.dt.round("D")
0   1969-07-21
1   1969-11-19
2   1971-02-05
dtype: datetime64[us]
>>> isod.dt.floor("D")
0   1969-07-20
1   1969-11-19
2   1971-02-05
dtype: datetime64[us]
>>> isod.dt.ceil("D")
0   1969-07-21
1   1969-11-20
2   1971-02-06
dtype: datetime64[us]
```

10.2.21.6 Intervalli di tempo

Per una differenza di date

```
>>> import datetime as dt
>>> now = pd.to_datetime([dt.datetime.now()] * 3)
>>> datediff  = now - isod
>>> datediff
0   20846 days 14:11:55.700573
1   20725 days 03:30:00.700573
2   20282 days 01:06:24.700573
dtype: timedelta64[us]
>>> datediff.dt.days / 365.25
0    57.073238
1    56.741958
2    55.529090
dtype: float64
```

Per aggiungere ad una data un certo periodo

```
>>> added_days = pd.to_timedelta(pd.Series([1,2,3]), "D")
>>> now + added_days
0   2026-08-18 10:24:35.700573
1   2026-08-19 10:24:35.700573
2   2026-08-20 10:24:35.700573
```

```
dtype: datetime64[us]
```

10.2.22 Dati categorici (Categorical)

Il `Categorical` è una rappresentazione tipo `factor` di R con interi linkati a label per risparmiare spazio rispetto a stringhe.
Se i categorici:

- sono *una serie a parte* si può accedere ai metodi esemplificati sotto direttamente
- fanno *parte di un DataFrame*: i metodi di sotto sono accessibili mediante `.cat.metodo`

Creazione e contenuto Si possono creare mediante `pd.Categorical` oppure attraverso series specificando `category` come `dtype`.

```
>>> # metodi di creazione standard
>>> c = pd.Series(list("abbccc"), dtype = 'category')
>>> c = pd.Categorical(["asd", "foo", "asd", "bar"])

>>> # wrapper comodo che imita factor
>>> import pylbmisc as lb
>>> c = lb.dm.to_categorical(
...       [1, 2, 3] * 2,
...       levels = [1,2,3],
...       labels = ["a","b","c"]
... )
```

Il contenuto low-level si puo investigare con

```
>>> c.codes      # tipo as.integer
array([0, 1, 2, 0, 1, 2], dtype=int8)
>>> c.categories # livelli del factor
Index(['a', 'b', 'c'], dtype='str')
>>> c.ordered    # booleana test ordinamento
False
```

Metodi utili Alcuni attributi e metodi carattaristici:

```
>>> # ------------------
>>> # Modifica categorie
>>> # ------------------
>>> c.set_categories(["a", "b"])          # metodo imposta le categorie ad una nuova lista
['a', 'b', NaN, 'a', 'b', NaN]
Categories (2, str): ['a', 'b']
>>> c.rename_categories(["x", "y", "z"])  # rinomina le categorie
['x', 'y', 'z', 'x', 'y', 'z']
Categories (3, str): ['x', 'y', 'z']
>>> c.reorder_categories(["c", "b", "a"]) # cambia ordinamento
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['c', 'b', 'a']
```

```
>>> # ------------------
>>> # Aggiunta/rimozione
>>> # ------------------
>>> c.add_categories("asd")        # aggiunge categorie alla fine della lista
['a', 'b', 'c', 'a', 'b', 'c']
Categories (4, str): ['a', 'b', 'c', 'asd']
>>> c.remove_categories("b")       # toglie categorie creando mancanti
['a', NaN, 'c', 'a', NaN, 'c']
Categories (2, str): ['a', 'c']
>>> c.remove_unused_categories()   # toglie categorie con zero frequenze (qui non app
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['a', 'b', 'c']
>>> # --------------------
>>> # Impostazione ordering
>>> # --------------------
>>> c.as_ordered()
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['a' < 'b' < 'c']
>>> c.as_unordered()
['a', 'b', 'c', 'a', 'b', 'c']
Categories (3, str): ['a', 'b', 'c']
```

10.2.23 Indexing gerarchico e reshape

L'indexing gerarchico implementato mediante la classe `MultiIndex`:

- permette di gestire dati multidimensionali, riconducendoli ad una tabella a due dimensioni
- serve nel *reshape* dei dati (funzioni `stack`/`unstack`) e nelle operazioni basate su gruppo (formare pivot table, eg statistiche stratificate).

Qui vediamo il multiindexing nelle `Series`, lasciamo quello dei `DataFrame` per più tardi

10.2.23.1 Definizione

Si fornisce come termine `index` una lista di elementi, ciascuno dei quali è un livello di indice

```
>>> df = pd.Series(rng.random(6),
...                index = [list("aaabbc"), [1, 2, 3, 1, 2, 1]])
>>> # df = pd.Series(rng.random(10),
>>> #                index = [list("aaabbbccdd"), [1, 2, 3] * 3 + [3]])
>>> df
a  1    0.829725
   2    0.227471
   3    0.779332
b  1    0.180644
   2    0.333745
c  1    0.997920
dtype: float64
```

```
>>> df.index
MultiIndex([('a', 1),
            ('a', 2),
            ('a', 3),
            ('b', 1),
            ('b', 2),
            ('c', 1)],
           )
```

10.2.23.2 Indexing

L'indexing sulla base di un singolo indice è possibile, ad esempio

```
>>> df['b']
1    0.180644
2    0.333745
dtype: float64
>>> df['b':'c']
b  1    0.180644
   2    0.333745
c  1    0.997920
dtype: float64
>>> df.loc[["a", "c"]]
a  1    0.829725
   2    0.227471
   3    0.779332
c  1    0.997920
dtype: float64
```

Ed è possibile la selezione anche da un livello di index più interno:

```
>>> df.loc[:, 2 ]
a    0.227471
b    0.333745
dtype: float64
```

10.2.23.3 Reshape

Un esempio di reshape di una `Series` con `MultiIndex`, che diviene un `DataFrame`

```
>>> # Serie
>>> df = pd.Series(np.random.uniform(size=9),
...                index=[["a", "a", "a", "b", "b", "c", "c", "d", "d"],
...                       [1, 2, 3, 1, 3, 1, 2, 2, 3]])
>>> df.index.names = ["id", "time"]
>>> df
id  time
a   1       0.848285
    2       0.835464
    3       0.036381
b   1       0.877160
    3       0.892128
c   1       0.494396
```

```
    2       0.559093
d   2       0.398783
    3       0.136188
dtype: float64

>>> # DataFrame wide
>>> wide = df.unstack()
>>> wide
time         1         2         3
id
a     0.848285  0.835464  0.036381
b     0.877160       NaN  0.892128
c     0.494396  0.559093       NaN
d          NaN  0.398783  0.136188

>>> # Tornare in versione long (serie)
>>> long = wide.stack()
>>> long
id  time
a   1       0.848285
    2       0.835464
    3       0.036381
b   1       0.877160
    2            NaN
    3       0.892128
c   1       0.494396
    2       0.559093
    3            NaN
d   1            NaN
    2       0.398783
    3       0.136188
dtype: float64
```

10.3 DataFrame

Struttura a due dimensioni (con indici di riga e colonna) con colonne che possono assumere tipi differenti. Può essere pensato come un `dict` di `Series` caratterizzate dagli stessi indici (di riga).

10.3.1 Creazione

Si crea mediante:

```
df = pd.DataFrame(data, index, columns) # index, columns opzionali
```

dove `data` può essere un dict (contenente list, dicts, Series o array numpy) un array numpy 2d, un altro `DataFrame` o `Series`. `index` e `column`, opzionali, servono per specificare indici di riga e nomi colonna.

```
>>> # modo più comune di creare un DataFrame per colonne: dict di liste
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
```

```
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> states = pd.DataFrame(data, index = list("abcdef"))

>>> # creazione di un DataFrame per riga (lista di dict)
>>> data2 = pd.DataFrame([
...     {"state": "Ohio", "year": 2000, "pop": 1.5},
...     {"state": "Ohio", "year": 2001, "pop": 1.7} # ...
... ])


>>> # Nella creazione vengono rispettati indici comuni
>>> a = pd.Series(range(3), index=['a', 'b', 'c'])
>>> b = pd.Series(range(4), index=['a', 'b', 'c', 'd'])
>>> df = pd.DataFrame({'one' : a, 'two' : b})
>>> df
   one  two
a  0.0    0
b  1.0    1
c  2.0    2
d  NaN    3
```

10.3.2 Contenuto (`info`, `shape`, `index`, `columns`, `values`, `name`)

Per avere una idea sintetica si usa il metodo `info`; gli attributi principali sono `shape`, `index`, `columns`, `values` e i loro `name`.

```
>>> df.info()  # idea sintetica
<class 'pandas.DataFrame'>
Index: 4 entries, a to d
Data columns (total 2 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   one     3 non-null      float64
 1   two     4 non-null      int64
dtypes: float64(1), int64(1)
memory usage: 100.0 bytes

>>> df.shape   # come numpy
(4, 2)
>>> df.index   # indici di riga
Index(['a', 'b', 'c', 'd'], dtype='str')
>>> df.columns # nomi di colonna
Index(['one', 'two'], dtype='str')
>>> df.values  # valori grezzi (array numpy)
array([[ 0.,  0.],
       [ 1.,  1.],
       [ 2.,  2.],
       [nan,  3.]])

>>> # attributi name di index e columns
```

```
>>> df.index.name   = "soggetto"
>>> df.columns.name = "rilevazione"
>>> df
rilevazione  one  two
soggetto
a            0.0    0
b            1.0    1
c            2.0    2
d            NaN    3
```

10.3.3 Selezione

Avviene mediante le quadre `[]` (più limitata) e gli attributi `.loc` e `.iloc`.

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df  = pd.DataFrame(data)     # senza indice di riga
```

10.3.3.1 Uso di `[]`

Per la selezione di:

- **colonne**: specificare stringhe o accedere direttamente (restituisce una Series); oppurespecificare lista di stringhe (restituisce un DataFrame),

  ```
  >>> df["state"] # singola colonna (da una serie), sia lettura che assegnazione
  0      Ohio
  1      Ohio
  2      Ohio
  3    Nevada
  4    Nevada
  5    Nevada
  Name: state, dtype: str
  >>> df.state     # accesso diretto (da una serie), uso interattivo (sola lettura)
  0      Ohio
  1      Ohio
  2      Ohio
  3    Nevada
  4    Nevada
  5    Nevada
  Name: state, dtype: str

  >>> df[["state", "pop"]] # due colonne (da un dataframe)
      state  pop
  0    Ohio  1.5
  1    Ohio  1.7
  2    Ohio  3.6
  3  Nevada  2.4
  4  Nevada  2.9
  5  Nevada  3.2
  ```

- **righe**: utilizzare array logici e numerici interpretati come id di riga

```
>>> df[df.state == 'Ohio']     # logici
  state  year  pop
0  Ohio  2000  1.5
1  Ohio  2001  1.7
2  Ohio  2002  3.6
>>> df[:2]                     # slice
  state  year  pop
0  Ohio  2000  1.5
1  Ohio  2001  1.7
```

- righe e colonne: bisogna utilizzare `.loc`/`.iloc`

```
# df[df.state == 'Ohio', "pop"]   # ERRORE
```

10.3.3.2 Uso di `.loc` e `.iloc`

Per una selezione generale fare uso di questi. Si ha che

- `loc` richiede prende *numerici o stringa* o funzioni (che restituiscono indice di riga o colonna) e *si basa su indici*. Harrison lo preferisce per il codice di produzione
- `iloc` accetta solo input interi ed è *basato su posizione* (invece che indici)

In entrambi i casi:

- specificare i criteri (per riga e colonne) separati da virgole; se si specifica un solo criterio (no virgole) viene interpretato come indice di riga
- se si specificano se su riga o colonna si prende tutto, specificare una slice vuota `:`;

Da notare che la slice in loc vs iloc:

- funziona diversamente in `loc` ed `iloc`; con `loc` include l'elemento di arrivo, con `iloc` no
- meglio sortare l'indice prima di effettuare una selezione basata su slice; un template è `sort_index` e poi `loc/iloc` (eventualmente preceduti da `set_index`)
- la slice in loc con stringhe può essere basata su matching parziale

Alcuni esempi a seguire:

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df  = pd.DataFrame(data)     # indice interi standard
>>> df_id = pd.DataFrame(data, index = list("abcdef")) # con indice di riga
```

Selezione di colonne Sia per `loc`/`iloc`, separare con , e usare slice vuota

```
>>> df.loc[:, 'pop']          # LOC: colonna singola come serie
0    1.5
1    1.7
2    3.6
3    2.4
4    2.9
5    3.2
Name: pop, dtype: float64
>>> df.loc[:, ['pop']]        # LOC: colonna singola come dataframe
   pop
0  1.5
1  1.7
2  3.6
3  2.4
4  2.9
5  3.2
>>> df.loc[:, ['year','pop']] # LOC: multiple via lista
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
>>> df.loc[:, 'year':'pop']   # LOC: multiple via slice
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2

>>> df.iloc[:, 2]     # ILOC: colonna singola (come serie)
0    1.5
1    1.7
2    3.6
3    2.4
4    2.9
5    3.2
Name: pop, dtype: float64
>>> df.iloc[:, [2]]   # ILOC: colonna singola (come dataframe)
   pop
0  1.5
1  1.7
2  3.6
3  2.4
4  2.9
5  3.2
```

```
>>> df.iloc[:, [1, 2]] # ILOC: colonne multiple mediante lista
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
>>> df.iloc[:, 1:3]   # colonne multiple mediante slice
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
```

Selezione di righe Utilizzare un solo indice, interpretato di riga (oppure usare la virgola e porre : per le colonne)

```
>>> df.loc[df.year==2001] # LOC: array booleani
    state  year  pop
1    Ohio  2001  1.7
3  Nevada  2001  2.4
>>> df.loc[[1,2,3]]       # LOC: se gli indici sono numerici possiamo usare numeri con loc
    state  year  pop
1    Ohio  2001  1.7
2    Ohio  2002  3.6
3  Nevada  2001  2.4
>>> df.loc[1:5:2]         # slice include elemento finale
    state  year  pop
1    Ohio  2001  1.7
3  Nevada  2001  2.4
5  Nevada  2003  3.2

>>> df_id.loc['a']        # LOC con indici stringa: singola stringa da serie
state    Ohio
year     2000
pop       1.5
Name: a, dtype: object
>>> df_id.loc[['a']]      # LOC con indici stringa: lista di stringhe da df
  state  year  pop
a  Ohio  2000  1.5

>>> df.iloc[0]        # ILOC: Singola riga mediante indice come serie
state    Ohio
year     2000
pop       1.5
Name: 0, dtype: object
>>> df.iloc[[0]]      # Lista ritorna dataframe (anche di una sola riga)
  state  year  pop
```

```
0  Ohio  2000  1.5
>>> df.iloc[[2, 3]]
    state  year  pop
2    Ohio  2002  3.6
3  Nevada  2001  2.4
>>> df.iloc[1:5:2]    # slice esclude elemento finale
    state  year  pop
1    Ohio  2001  1.7
3  Nevada  2001  2.4
```

Selezione di righe e colonne Porre i criteri visti in precedenza separati da virgola

```
>>> df.loc[df.state == 'Ohio', "pop"]   # righe su logico e colonna (ritornata serie)
0    1.5
1    1.7
2    3.6
Name: pop, dtype: float64
>>> df.loc[df.state == 'Ohio', ["pop"]] # stessa cosa ma dataframe di ritorno
   pop
0  1.5
1  1.7
2  3.6
>>> df_id.loc[ 'a', ['pop', 'year']]  # singola riga, più colonne
pop        1.5
year    2000.0
Name: a, dtype: float64
>>> df_id.loc[:"d", "year":"pop"]     # esempio con slice
   year  pop
a  2000  1.5
b  2001  1.7
c  2002  3.6
d  2001  2.4

>>> df.iloc[3, 1]        # solo numerici in iloc
np.int64(2001)
>>> df.iloc[3, [1,2]]    # selezionare piu colonne con iloc
year    2001.0
pop        2.4
Name: 3, dtype: float64
>>> df.iloc[:, :3]       # uso slice
    state  year  pop
0    Ohio  2000  1.5
1    Ohio  2001  1.7
2    Ohio  2002  3.6
3  Nevada  2001  2.4
4  Nevada  2002  2.9
5  Nevada  2003  3.2
```

10.3.3.3 `query` per selezione righe

Il metodo `query` dei dataframe permette di selezionare righe usando una sintassi SQL-like; funziona bene nel chaining (a differenza degli indici, a meno che non si usino funzioni) essendo performata sulla versione più aggiornata del dataframe. Si può

- usare i metodi delle series nella query
- riferirsi a variabili dell'ambiente prefixandole con chiocciola

```
>>> df.query("(year >= 2002) and (~state.isna()) and (pop < 3.5)")
    state  year  pop
4  Nevada  2002  2.9
5  Nevada  2003  3.2

>>> sel_years = {2000, 2003}
>>> df.query("year in @sel_years")
    state  year  pop
0    Ohio  2000  1.5
5  Nevada  2003  3.2
```

10.3.3.4 Selezione di colonne sulla base di tipo

Utilizzare `.select_dtypes`, specificando `include` (primo) o `exclude`; per selezionare

- tutti i numerici specificare `number`
- datetimes `datetime`
- timedelta `timedelta`
- categorical `category`

```
>>> df  = pd.DataFrame({"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...                     "year": [2000, 2001, 2002, 2001, 2002, 2003],
...                     "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]})
>>> df.dtypes
state        str
year       int64
pop      float64
dtype: object
>>> df.select_dtypes("number")
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
>>> df.select_dtypes(exclude="number")
    state
0    Ohio
```

```
1    Ohio
2    Ohio
3  Nevada
4  Nevada
5  Nevada
```

10.3.3.5 Accesso a singoli numeri: `.at`, `.iat`

Per estrarre *singoli valori* utilizzare gli accessori `.at` o `.iat`,fornendo una coppia indice di riga e colonna. Questi

- sono equivalenti di `.loc` e `.iloc`: `at` richiede labels, `iat` richiede interi
- garantiscono che l'estrazione sia uno scalare, cosa non garantita con loc/.iloc
- più veloci di `.loc`/`.iloc` nel caso di singolo scalare

```
>>> df = pd.DataFrame(np.arange(6).reshape(3, 2),columns=['A', 'B'])

>>> df
   A  B
0  0  1
1  2  3
2  4  5
>>> df.at[2, "B"]
np.int64(5)
>>> df.iat[2, 1]
np.int64(5)
```

10.3.4 Modifica valori

Per la modifica di

- **colonne/righe/singoli valori**: assegnare a selezioni (di nomi esistenti) effettuate con `[]`, `loc` o `iloc`

  ```
  >>> df = pd.DataFrame(np.arange(6).reshape(3, 2),columns=['A', 'B'])
  >>> df.loc["a", "constant"] = 5 # singolo valore
  >>> df.loc[: , "series"] = 1    # intera colonna
  >>> df.iloc[1, :] = 2           # intera riga, volendo
  >>> df
       A    B  constant  series
  0  0.0  1.0       NaN       1
  1  2.0  2.0       2.0       2
  2  4.0  5.0       NaN       1
  a  NaN  NaN       5.0       1
  ```

- **singoli valori**: utilizzare `at` e `iat` come lvalue

  ```
  >>> df.at[2, "B"] = 15321
  >>> df
       A        B  constant  series
  0  0.0      1.0       NaN       1
  ```

```
1  2.0      2.0       2.0       2
2  4.0  15321.0       NaN       1
a  NaN      NaN       5.0       1
```

10.3.5 Aggiunta di colonne

Nuove colonne possono essere create mediante assegnazione, `insert`, `assign`

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df = pd.DataFrame(data, index = list("abcdef"))
```

10.3.5.1 Assegnazione

assegnando a nomi di colonna inesistenti (le relative colonne verranno create alla fine); torna comoda la sintassi `df['variabile']=...`

```
>>> df['constant'] = 3           # funziona broadcasting
>>> df['newvar'] = range(6)      # rispettare lunghezza
>>> df['series'] = pd.Series([10, 20, 30, 40], #  Serie con indici: rispettati
...                          index = ['a', 'b', 'y', 'z'])
>>> df[['foo', 'bar']] = [0, 1] # broadcasting two columns magic
>>> df
    state  year  pop  constant  newvar  series  foo  bar
a    Ohio  2000  1.5         3       0    10.0    0    1
b    Ohio  2001  1.7         3       1    20.0    0    1
c    Ohio  2002  3.6         3       2     NaN    0    1
d  Nevada  2001  2.4         3       3     NaN    0    1
e  Nevada  2002  2.9         3       4     NaN    0    1
f  Nevada  2003  3.2         3       5     NaN    0    1
```

10.3.5.2 Uso di `insert`

Usando il metodo `insert` per inserire in un determinato punto del dataframe; non è necessaria l'assegnazione

```
>>> df.insert(0,          # insert in posizione specifica (prima)
...           "nomevar", # nome variabile
...           3)         # valore (es scalar, pd.Series, o array)
>>> df
   nomevar   state  year  pop  constant  newvar  series  foo  bar
a        3    Ohio  2000  1.5         3       0    10.0    0    1
b        3    Ohio  2001  1.7         3       1    20.0    0    1
c        3    Ohio  2002  3.6         3       2     NaN    0    1
d        3  Nevada  2001  2.4         3       3     NaN    0    1
e        3  Nevada  2002  2.9         3       4     NaN    0    1
f        3  Nevada  2003  3.2         3       5     NaN    0    1
```

10.3.5.3 Uso di `assign`

Permette di risparmiare digitazione, usare funzioni (alle quali viene passato l'intero df) e facilitare il chaining. Il risultato va assegnato. Se i nomi variabili

sono esistenti le corrispondenti variabili vengono modificate, altrimenti create sovrascritte mentre se inesistenti create. Preferibile perché

- utilizzando funzioni si prende in input il dataframe allo stato attuale/aggiornato
- meno spaghetti code rispetto a selezioni con variabili temporanee e permette concatenazione di codice rendendolo più leggibile

Volendo

- ogni riga terminerà con `astype` per coercire il tipo
- alla chisura del metodo postporre una selezione delle variabili da tenere (mediante `.loc`) o un chaining di `.drop` per quelle da eliminare

```
>>> sel_var = df.columns.to_list() + ["test", "yearp2"]
>>> df2 = df.assign(
...     test = range(5, 11),
...     yearp1 = lambda df_: (df_.year + 1).astype("int64[pyarrow]"),
...     # qui sotto si può già usare year1p
...     yearp2 = lambda df_: (df_.yearp1 + 1).astype("float")
... )[sel_var] # tieni solo le colonne necessarie
>>> df2
   nomevar   state  year  pop  constant  newvar  series  foo  bar  test  yearp2
a        3    Ohio  2000  1.5         3       0    10.0    0    1     5  2002.0
b        3    Ohio  2001  1.7         3       1    20.0    0    1     6  2003.0
c        3    Ohio  2002  3.6         3       2     NaN    0    1     7  2004.0
d        3  Nevada  2001  2.4         3       3     NaN    0    1     8  2003.0
e        3  Nevada  2002  2.9         3       4     NaN    0    1     9  2004.0
f        3  Nevada  2003  3.2         3       5     NaN    0    1    10  2005.0
```

10.3.6 Rimozione righe/colonne (`drop`, `del`)

Per:

- righe o colonne si usa il metodo `drop`, specificando tra parentesi gli assi e *assegnando il risultato* (o specificando `inplace`)

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df  = pd.DataFrame(data)    # senza indice di riga
>>> df_id = pd.DataFrame(data, index = list("abcdef")) # con indice di riga

>>> df.drop([0, 1])       # rimozione prime due righe
    state  year  pop
2    Ohio  2002  3.6
3  Nevada  2001  2.4
4  Nevada  2002  2.9
5  Nevada  2003  3.2
>>> df_id.drop(index = "d")  # rimozione riga usando indice
    state  year  pop
a    Ohio  2000  1.5
```

```
b    Ohio  2001  1.7
c    Ohio  2002  3.6
e  Nevada  2002  2.9
f  Nevada  2003  3.2
>>> df.drop(columns = ['year', 'pop']) # rimozione colonne
    state
0    Ohio
1    Ohio
2    Ohio
3  Nevada
4  Nevada
5  Nevada
```

- le colonne si può usare `del` (senza riassegnazione)

```
>>> del df['state']
>>> df
   year  pop
0  2000  1.5
1  2001  1.7
2  2002  3.6
3  2001  2.4
4  2002  2.9
5  2003  3.2
```

10.3.7 Rinominare colonne/indici (`rename`)

Si usa il metodo `rename`, che può prendere dict e funzioni e applicarle a righe o colonne. Ad esempio nel seguito usiamo un dict sulle colonne, e `str.upper` sugli index/righe

```
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> df  = pd.DataFrame(data, index = list("abcdef"))     # senza indice di riga

>>> ft = {'state': 'stato', 'pop': 'popolazione'}
>>> df = df.rename(index = str.upper, columns = ft)
>>> df
    stato  year  popolazione
A    Ohio  2000          1.5
B    Ohio  2001          1.7
C    Ohio  2002          3.6
D  Nevada  2001          2.4
E  Nevada  2002          2.9
F  Nevada  2003          3.2
```

10.3.8 Gestione indici

10.3.8.1 Creazione indici da colonne

Il metodo `set_index` crea indici di riga a partire da una/più colonne. Il risultato va savato. Per non eliminare le colonne specificate come index si usa il parametro

`drop = False`.

```
>>> df = pd.DataFrame({'a': range(7), 'b': range(7, 0, -1),
...                    'c': ['one', 'one', 'one', 'two', 'two', 'two', 'two'],
...                    'd': [0, 1, 2, 0, 1, 2, 3]})
>>> df2 = df.set_index(['c', 'd'])
>>> df2
       a  b
c   d
one 0  0  7
    1  1  6
    2  2  5
two 0  3  4
    1  4  3
    2  5  2
    3  6  1
```

10.3.8.2 Reset indici

`reset_index` porta gli indici in opportune colonne del dataframe e li sostituisce con un progressivo numerico (a meno che `drop=True`, nel qual caso vengono eliminati)

```
>>> df2.reset_index()
     c  d  a  b
0  one  0  0  7
1  one  1  1  6
2  one  2  2  5
3  two  0  3  4
4  two  1  4  3
5  two  2  5  2
6  two  3  6  1
```

10.3.8.3 `MultiIndex`

Sia righe che colonne possono avere indexing multiplo e con nomi

```
>>> df = pd.DataFrame(np.arange(12).reshape((4, 3)),
...                   index=[['a', 'a', 'b', 'b'], [1, 2, 1, 2]],
...                   columns=[['Ohio', 'Ohio', 'Colorado'],
...                            ['Green', 'Red', 'Green']])
>>> df.index.names = ["key1", "key2"]
>>> df.columns.names = ["state", "color"]
>>> df
state      Ohio     Colorado
color     Green Red    Green
key1 key2
a    1        0   1        2
     2        3   4        5
b    1        6   7        8
     2        9  10       11
```

Anche sui nomi di indici di colonna è possibile effettuare selezioni

```
>>> df["Ohio"]
color      Green  Red
key1 key2
a    1         0    1
     2         3    4
b    1         6    7
     2         9   10
```

Per conoscere il numero di livelli di indici

```
>>> df.index.nlevels
2
```

Invertire gli indici Può essere necessario a volte cambiare l'ordine degli indici di un'asse (ad esempio indice più interno portarlo fuori). Questo si fa mediante `swaplevel`

```
>>> df.swaplevel("key1", "key2")
state      Ohio     Colorado
color     Green Red    Green
key2 key1
1    a        0   1        2
2    a        3   4        5
1    b        6   7        8
2    b        9  10       11
```

10.3.9 Elaborazione allineata

Nelle operazioni algebriche tra dataframe e serie e tra due dataframe sono gli indici a determinare cosa viene messo in relazione con cosa:

- se una posizione non è disponibile in entrambi gli operandi viene restituito dato mancante
- nel caso vi siano **indici ripetuti** questo si ripercuoterà sui risultati

```
>>> df = pd.DataFrame({"x" : [1,2,3,4], "y": [5,6,7,8], "z":[9,10,11,12]},
...                   index = list("abcd"))

>>> # Dataframe e serie
>>> df
   x  y   z
a  1  5   9
b  2  6  10
c  3  7  11
d  4  8  12
>>> df.mean()
x     2.5
y     6.5
z    10.5
dtype: float64
>>> df.std()
```

```
x    1.290994
y    1.290994
z    1.290994
dtype: float64

>>> # Due dataframe
>>> df1 = df.loc["a":"c", "x":"y"]
>>> df2 = df.loc["b":"d", "y":"z"]
>>> df1
   x  y
a  1  5
b  2  6
c  3  7
>>> df2
   y   z
b  6  10
c  7  11
d  8  12
>>> df1 + df2
    x     y   z
a NaN   NaN NaN
b NaN  12.0 NaN
c NaN  14.0 NaN
d NaN   NaN NaN
```

10.3.10 Coercizione di tipi (`astype`)

Possiamo usare `astype` specificando il mapping di formato in un `dict`.

```
>>> df = pd.DataFrame({"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"]
...                    "year":  [str(y) for y in [2000, 2001, 2002, 2001, 2002, 2003]]
...                    "pop":   [str(p) for p in [1.5, 1.7, 3.6, np.nan, 2.9, 3.2]],
...                    "adate": ["2020-01-02", "2021-01-01", "2022-01-02"] * 2
...                    }) # all strings/"object"
>>> ft = {
...     "state": "category",
...     "year" : "Int16",
...     "pop"  : "Float64",
...     "adate": "datetime64[ns]" # soluzione provvisoria, credo
... }                             # https://wesmckinney.com/book/data-cleaning.html#p

>>> df2 = df.astype(ft)
>>> df2.info()
<class 'pandas.DataFrame'>
RangeIndex: 6 entries, 0 to 5
Data columns (total 4 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   state   6 non-null      category
 1   year    6 non-null      Int16
 2   pop     5 non-null      Float64
```

```
 3   adate   6 non-null      datetime64[ns]
dtypes: Float64(1), Int16(1), category(1), datetime64[ns](1)
memory usage: 285.0 bytes
```

10.3.11 Applicazione di funzioni

10.3.11.1 A molteplici righe/colonne (`apply`/`agg`)

`apply` serve per applicare una singola funzione ad ogni riga (default) o colonna (specificando `axis=1`, simile a `lapply`):

- se la funzione restituisce uno scalare l'output sarà una serie
- se la funzione restituisce una serie, l'output sarà un dataframe

Se la funzione viene applicata a tutte le righe, per ciascuna viene fornito una sorta di dict (Series in cui gli indici sono i nomi di colonna) e dovrebbe essere lo stesso con le colonne (se gli indici di riga sono stringhe).

```
>>> df = pd.DataFrame({"a" : [1, 2, 3], "b" : [4, 5, 6]})

>>> # ------------------  funzione che restituisce uno scalare
>>> df.apply(lambda x: x.mean())                              # applicata a tutte colonne
a    2.0
b    5.0
dtype: float64
>>> df.apply(lambda x: f"{x["a"]} + 3 = {x["b"]}", axis = 1)  # applica a righe
0    1 + 3 = 4
1    2 + 3 = 5
2    3 + 3 = 6
dtype: str

>>> # ------------------ funzione che restituisce una serie
>>> def desc(x):
...     return pd.Series([x.min(), x.max(), x.mean(), x.median()],
...                      index=["min", "max", "mean", "median"])
...
>>> df.apply(desc)           # colonna
          a    b
min     1.0  4.0
max     3.0  6.0
mean    2.0  5.0
median  2.0  5.0
>>> df.apply(desc, axis = 1) # riga
   min  max  mean  median
0  1.0  4.0   2.5     2.5
1  2.0  5.0   3.5     3.5
2  3.0  6.0   4.5     4.5
```

In maniera analoga invece di definire una funzione che ritorni una serie possiamo passare al metodo `.agg` una lista con cose/aggregazioni per farle eseguire (su tutte le colonne di default).

```
>>> # conta di non missing, numero di valori unici (missing inclusi), somma valori
>>> # e primo valore
>>> analysis = ["count", "size", "sum", lambda col: col.loc[0]]
>>> df.agg(analysis)
             a   b
count        3   3
size         3   3
sum          6  15
<lambda>     1   4
```

10.3.11.2 A ciascun elemento del `DataFrame` (`map`)

`map` applica una funzione a tutti gli elementi del dataframe

```
>>> rng = np.random.default_rng(665)
>>> df = pd.DataFrame(rng.standard_normal((2, 2)))
>>> df
          0         1
0  0.259614 -0.072077
1 -0.093439 -1.180275
>>> df.map(lambda x: -1 if x < 0 else 1) # sign function
   0  1
0  1 -1
1 -1 -1
```

10.3.11.3 All'intero dataframe (`pipe`)

`pipe` passa l'intero dataframe a una funzione (che si attende di lavorare con dataframe) ed è utile soprattutto nel chaining di metodi

```
>>> #effective pandas 2 pag 127
>>> agecl = pd.Series(["0-10", "11-20", "20-30"])

>>> ( agecl
...   .str.split('-', expand = True) # splits in a two cols dataframe
...   .astype(int)
...   .pipe( # passa il dataframe a un generatore di numeri casuali tra le
...       # colonne
...       lambda df_ : pd.Series(
...           # qui possiamo usare df_ per riferirci al dataframe
...           np.random.randint(df_.iloc[:, 0], df_.iloc[:, 1]),
...           index=df_.index
...       ))
... )
0     5
1    18
2    20
dtype: int64
```

10.3.12 Ciclo su righe/colonne

Tipicamente questo non è di interesse. Se però, se per qualche motivo, l'applicazione di funzioni per generare nuovi dati (es mediante `apply`) come alla sezione 11.4.10 non è quello che si vuole, si può fare dei cicli generici sul `DataFrame` per utilizzarne i dati presenti.

10.3.12.1 Righe

Si usa:

- `itertuples`: ritorna una tuple con nome, che preserva i tipi ed è più veloce (indice in posizione 0)

```
>>> df = pd.DataFrame({'num_legs': [4, 2],
...                    'num_wings': [0, 2]},
...                   index=['dog', 'hawk'])

>>> for row in df.itertuples():
...     print("id =", row[0],
...           "first_elem = ", row[1],
...           "second_elem = ", row[2],
...           "first_named = ", row.num_legs,
...           "second_named = ", row.num_wings)
...
id = dog first_elem =  4 second_elem =  0 first_named =  4 second_named =  0
id = hawk first_elem =  2 second_elem =  2 first_named =  2 second_named =  2
```

- `iterrows`: ritorna una coppia label e Series (forse di minor interesse data la maggior generalità del precedente)

```
>>> for lab, row in df.iterrows():
...     print(f"{lab =}")
...     print(row)
...
lab ='dog'
num_legs     4
num_wings    0
Name: dog, dtype: int64
lab ='hawk'
num_legs     2
num_wings    2
Name: hawk, dtype: int64
```

- può tornare talvolta utile `df.to_dict(orient="records")` che crea una lista di dict, ciascuno con una riga

```
>>> for row in df.to_dict(orient="records"):
...     print(row)
...
{'num_legs': 4, 'num_wings': 0}
{'num_legs': 2, 'num_wings': 2}
```

10.3.12.2 Colonne

Un ciclo `for` secco restituisce il nome della variabile; di maggior interesse il metodo `items` che restituisce la tupla con nome variabile e serie contenuta

```
>>> df = pd.DataFrame({'species': ['bear', 'bear', 'marsupial'],
...                    'population': [1864, 22000, 80000]},
...                    index=['panda', 'polar', 'koala'])

>>> for varname, content in df.items():
...     print(f'varname: {varname}')
...     print(f'type: {type(varname)}')
...     print(f'content:\n{content}', sep='\n')
...
varname: species
type: <class 'str'>
content:
panda         bear
polar         bear
koala    marsupial
Name: species, dtype: str
varname: population
type: <class 'str'>
content:
panda     1864
polar    22000
koala    80000
Name: population, dtype: int64
```

10.3.13 Merge

10.3.13.1 Due dataframe

Si usa `pd.merge`, o alternativamente anche il metodo `merge` sul primo DataFrame, che:

- funziona
  - di default **sulla base delle colonne** comuni presenti in entrambi i dataset; altrimenti specificare i nomi delle variabili comuni mediante `on` (se i due dataframe hanno variabili di merge con lo stesso nome) oppure ordinatamente `left_on` e `right_on`;
  - se si desidera che le chiave di merge siano gli **indici (di riga)**, passare `left_index = True` e `right_index = True` (per merge utilizzando le chiavi sia del df di destra che sinitra)
- di default ritorna le righe dove la chiave è presente in entrambi i dataset (*inner join*): per altri tipi si possono specificare nel parametro `how` (es `left`, `right` ed `outer` ... vi è anche `cross` per avere il prodotto cartesiano). Tipicamente di interesse `left` se a sinistra abbiamo un dataframe al quale vogliamo integrare dati provenienti da quello di destra

- si può specificare un criterio di validazione (stringa passata a `validate`) che darà errore se non rispettato: es `1:1`, `1:m`, `m:1`.

```
>>> df1 = pd.DataFrame({'key': ['a', 'b', 'b', 'c', 'c', 'c'],
...                     'data1': range(6)})
>>> df2 = pd.DataFrame({'key': ['a', 'b', 'd'],
...                     'data2': ['x', 'y', 'z']})
>>> df1
  key  data1
0   a      0
1   b      1
2   b      2
3   c      3
4   c      4
5   c      5
>>> df2
  key data2
0   a     x
1   b     y
2   d     z

>>> # vari tipi di merge
>>> # ------------------
>>> pd.merge(df1, df2)                # inner di default ("key" is common, used)
  key  data1 data2
0   a      0     x
1   b      1     y
2   b      2     y
>>> pd.merge(df1, df2, how = 'left')  # tiene dataset di sx, integra con quello di dx
  key  data1 data2
0   a      0     x
1   b      1     y
2   b      2     y
3   c      3   NaN
4   c      4   NaN
5   c      5   NaN
>>> pd.merge(df1, df2, how = 'right') # tiene dataset di dx, integra con quello di sx
  key  data1 data2
0   a    0.0     x
1   b    1.0     y
2   b    2.0     y
3   d    NaN     z
>>> pd.merge(df1, df2, how = 'outer') # tieni tutto
  key  data1 data2
0   a    0.0     x
1   b    1.0     y
2   b    2.0     y
3   c    3.0   NaN
4   c    4.0   NaN
5   c    5.0   NaN
6   d    NaN     z
```

```
>>> # uso della validazione
>>> # ---------------------
>>> # pd.merge(df1, df2, how = 'left', validate="1:1") # questo da errore
>>> pd.merge(df1, df2, how = 'left', validate="m:1") # questo è giusto
  key  data1 data2
0   a      0     x
1   b      1     y
2   b      2     y
3   c      3   NaN
4   c      4   NaN
5   c      5   NaN
```

10.3.13.2 Molteplici dataframe

Per mergiare diversi dataset aventi lo stesso nome di chiave in uno si può `reduce`

```
from functools import reduce

def merger(x, y):
    return pd.merge(x, y, how = "left",
                    left_on=['id', "time"],
                    right_on=['id', "time"],
                    suffixes=(None, None))


df = reduce(merger, [demo, lav, sal, bis])
```

10.3.14 Binding (`pd.concat`)

Sia per binding di riga che di colonna si usa `pd.concat` (passandogli la dimensione di interesse via `axis`). In entrambi i casi (e soprattutto per il binding di colonna) gli indici svolgono un ruolo importante.

10.3.14.1 Di riga

Nel binding di riga gli indici vengono duplicati se necessario. Si può dare

- `verify_integrity=True` se si vuole assicurare che non vi siano doppi
- `ignore_index=True` per piallare i vecchi indici e crearne nuovi

Ad esempio un equivalente di `rbind` si ottiene mediante

```
>>> # indici doppi vengono ripetuti
>>> df1 = pd.DataFrame({'key': ['a', 'b', 'd'],
...                     'data': ['x', 'y', 'z']},
...                    index=[0,1,2])
>>> df2 = pd.DataFrame({'key': ['a', 'b', 'd'],
...                     'data': ['x', 'y', 'z']},
...                    index=[1,2,3])
>>> pd.concat([df1, df2])
  key data
```

```
0   a    x
1   b    y
2   d    z
1   a    x
2   b    y
3   d    z
```

10.3.14.2 Di colonna

Attenzione, nel binding di colonna (`cbind`) **gli indici vengono rispettati rigorosamente**; nel caso usare `reset_index` con `drop=True` (ad esempio nel caso di sotto solamente nel secondo dataframe).

```
>>> # Indici non overlappanti
>>> df1 = pd.DataFrame({'a': ['a', 'b', 'd'],
...                     'b': ['x', 'y', 'z']},
...                    index=[0, 1, 2])
>>> df2 = pd.DataFrame({'c': ['a', 'b', 'd'],
...                     'd': ['x', 'y', 'z']},
...                    index=[1, 2, 3])
>>> pd.concat([df1, df2], axis = 1) # indici rispettati, NA generati
     a    b    c    d
0    a    x  NaN  NaN
1    b    y    a    x
2    d    z    b    y
3  NaN  NaN    d    z
>>> pd.concat([df1, df2.reset_index(drop=True)], axis = 1) # indici ignorati
   a  b  c  d
0  a  x  a  x
1  b  y  b  y
2  d  z  d  z
```

10.3.15 Reshape

Qua ci focalizziamo sul reshape basato sul contenuto delle colonne. Quanto sotto è stato posto in `lb.r.reshape`, in maniera più comoda e simile al reshape di R.

10.3.15.1 Uso di `lb.r.reshape`

È ancora sperimentale e non gestisce se le variabili hanno nomi con più di un separatore `_`

```
>>> wide = pd.DataFrame({
...     "id": ["bar", "baz", "foo"],
...     "var1_t0": [4,   5,  6],
...     "var1_t1": [7,   8,  9],
...     "var2_t0": [10, 11, 12],
...     "var2_t1": [13, 14, 15],
...     "var2_t2": [0,   0,  0],
... })
>>> wide
```

```
    id  var1_t0  var1_t1  var2_t0  var2_t1  var2_t2
0  bar        4        7       10       13        0
1  baz        5        8       11       14        0
2  foo        6        9       12       15        0
>>> longdf = lb.r.reshape(data=wide, idvar="id",
...                       wide_varying={"var1": ["var1_t0", "var1_t1"],
...                                     "var2": ["var2_t0", "var2_t1", "var2_t2"]},
...                       timesep="_",
...                       direction="long")
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
AttributeError: module 'pylbmisc.r' has no attribute 'reshape'
>>> longdf
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'longdf' is not defined. Did you mean: 'long'?
>>> back_to_wide = lb.r.reshape(longdf, idvar="id", timevar="time",
...                             towide_vars=["var1", "var2"],
...                             timesep="_at_",
...                             direction="wide")
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
AttributeError: module 'pylbmisc.r' has no attribute 'reshape'
>>> back_to_wide
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'back_to_wide' is not defined
```

10.3.15.2 Porre in long (`melt`)

Se abbiamo un dataset in formato wide si pone in long con `pd.melt`. Si può

- specificare un sottoinsieme di variabili da porre in long mediante `value_vars`
- specificare con `var_name` nome al posto di `variable` nel dataframe creato e `value_name` per specificare il nome della variabile al posto di `value`

```
>>> df = pd.DataFrame({"key": ["foo", "bar", "baz"],
...                    "x_bl": [1, 2, 3],
...                    "x_t0": [4, 5, 6],
...                    "x_t1": [7, 8, 9]}
... )

>>> df
   key  x_bl  x_t0  x_t1
0  foo     1     4     7
1  bar     2     5     8
2  baz     3     6     9
>>> pd.melt(df, id_vars = 'key')  # poni in long tutto
   key variable  value
0  foo     x_bl      1
1  bar     x_bl      2
```

```
2  baz     x_bl      3
3  foo     x_t0      4
4  bar     x_t0      5
5  baz     x_t0      6
6  foo     x_t1      7
7  bar     x_t1      8
8  baz     x_t1      9
>>> pd.melt(df, id_vars = 'key', value_vars = ["x_bl", "x_t0"]) # in long una selezione
   key variable  value
0  foo     x_bl      1
1  bar     x_bl      2
2  baz     x_bl      3
3  foo     x_t0      4
4  bar     x_t0      5
5  baz     x_t0      6
```

10.3.15.3 Porre in wide (`pivot`)

Un dataset in formato long con colonne, id, tempo e variabili assortiti può essere posto in formato wide mediante il metodo `pivot`.

```
>>> df = pd.DataFrame({'idpz': ['one', 'one', 'one', 'two', 'two'],
...                    'time': ["bl", "t1", "t2", "bl", "t1"],
...                    'x': range(1,6),
...                    'y': ['x', 'y', 'z', 'q', 'w'],
...                    'z': range(7, 12),
... })
>>> df
  idpz time  x  y   z
0  one   bl  1  x   7
1  one   t1  2  y   8
2  one   t2  3  z   9
3  two   bl  4  q  10
4  two   t1  5  w  11

>>> wide = df.pivot(index="idpz", columns="time", values = ["x", "y"])
>>> # time sopra deve essere una stringa
>>> wide.columns = ["_".join(col) for col in wide.columns]
>>> wide.convert_dtypes().reset_index()
  idpz  x_bl  x_t1  x_t2 y_bl y_t1  y_t2
0  one     1     2     3    x    y     z
1  two     4     5  <NA>    q    w  <NA>
```

10.3.16 Test di appartenenza (`in`, `isin`)

Si utilizza:

- `in` applicato ad un DataFrame testa la presenza di una colonna avente un determinato nome

  ```
  >>> df = pd.DataFrame({"a": [1, 2], "b": list("xz"), "c": [2,3]})
  >>> df
  ```

```
   a  b  c
0  1  x  2
1  2  z  3

>>> # in per check nomi colonna
>>> 'a' in df
True
>>> 'l' in df
False
```

- `isin` cerca nel contenuto del dataframe

```
>>> # Singolo elemento
>>> # ----------------
>>> df == 2
       a      b      c
0  False  False   True
1   True  False  False
>>> df == "z"
       a      b      c
0  False  False  False
1  False   True  False
>>> df.isin([2])          # lista: cerca in tutte le colonne
       a      b      c
0  False  False   True
1   True  False  False
>>> df.isin({"c" : [2]}) # dict: cerca in alcune colonne specificate
       a      b      c
0  False  False   True
1  False  False  False
>>> ~df.isin([2])         # negazione ricerca
       a     b      c
0   True  True  False
1  False  True   True

>>> # Più elementi
>>> # ------------
>>> df.isin([2, "z"])   # lista di due elementi
       a      b      c
0  False  False   True
1   True   True  False
```

10.3.17 Dati mancanti

Le funzioni ritornano una copia modificata che va eventualmente salvata

```
>>> df = pd.DataFrame({"a": [1., np.nan, 3.],
...                    "b":[1., np.nan, np.nan],
...                    "c":[np.nan, np.nan, np.nan],
...                    "d":[np.nan, np.nan, 3.]},
...                    index=list("xyz")
...                    ).convert_dtypes()
```

```
>>> df
      a     b     c     d
x     1     1  <NA>  <NA>
y  <NA>  <NA>  <NA>  <NA>
z     3  <NA>  <NA>     3
```

10.3.17.1 Identificazione

```
>>> df.isna()  # df.notna() è il contrario
       a      b     c      d
x  False  False  True   True
y   True   True  True   True
z  False   True  True  False
>>> df.isna().sum()
a    1
b    2
c    3
d    2
dtype: int64
>>> df.isna().mean().sort_values()
a    0.333333
b    0.666667
d    0.666667
c    1.000000
dtype: float64
```

10.3.17.2 Rimozione

```
>>> df.dropna()                                  # righe con anche un solo NA
Empty DataFrame
Columns: [a, b, c, d]
Index: []
>>> df.dropna(how = 'all')                       # righe completamente NA
   a     b     c     d
x  1     1  <NA>  <NA>
z  3  <NA>  <NA>     3
>>> df.dropna(axis = "columns", how = "all") # colonne completamente NA
      a     b     d
x     1     1  <NA>
y  <NA>  <NA>  <NA>
z     3  <NA>     3
```

10.3.17.3 Imputazione

Per l'imputazione dei dati mancanti

- il metodo `fillna` accetta un singolo valore, un `dict` dove si specifica nomecolonna-valore da imputare, o anche serie con index (da utilizzare per colonna) o un dataframe con la stessa struttura

  ```
  >>> df.fillna(99)
      a   b   c   d
  ```

```
x   1   1  99  99
y  99  99  99  99
z   3  99  99   3
>>> df.fillna({"a":2, "b":3})
   a  b     c     d
x  1  1  <NA>  <NA>
y  2  3  <NA>  <NA>
z  3  3  <NA>     3
>>> df.fillna(pd.Series([1,2,3], index=list("abc"))) # meno chiaro
   a  b  c     d
x  1  1  3  <NA>
y  1  2  3  <NA>
z  3  2  3     3
>>> df.fillna(pd.DataFrame(np.arange(12).reshape(3, 4), columns=list("abcd"), inc
   a  b   c  d
x  1  1   2  3
y  4  5   6  7
z  3  9  10  3
```

- il metodo `ffill` (locf di colonna andando verso il basso, se no specificare `axis`)

```
>>> df.ffill()
   a  b     c     d
x  1  1  <NA>  <NA>
y  1  1  <NA>  <NA>
z  3  1  <NA>     3
```

- il metodo `interpolate` rimpiazza i mancanti con interpolazioni lineari

```
>>> df.interpolate()
     a    b     c     d
x  1.0  1.0  <NA>  <NA>
y  2.0  1.0  <NA>  <NA>
z  3.0  1.0  <NA>   3.0
```

10.3.18 Duplicati

```
>>> df = pd.DataFrame({"k1": ["one", "two"] * 3 + ["two"],
...                    "k2": [1, 1, 2, 3, 3, 4, 4]},
...                   index = list("aabcdef"))
>>> df
    k1  k2
a  one   1
a  two   1
b  one   2
c  two   3
d  one   3
e  two   4
f  two   4
```

10.3.18.1 Identificazione (duplicated)

`duplicated` ritorna un vettore di booleani per indicare se una riga è duplicatac

```
>>> df.duplicated()        # ricerca complessiva
a    False
a    False
b    False
c    False
d    False
e    False
f     True
dtype: bool
>>> df.duplicated('k1')    # ricerca in singola colonna
a    False
a    False
b     True
c     True
d     True
e     True
f     True
dtype: bool
```

10.3.18.2 Rimozione (drop_duplicates)

`drop_duplicates` ritorna un data frame senza duplicati.

- di default tutte le colonne sono considerate, alternativamente specificare `subset`;
- se si usa `keep` si può specificare se tenere i primi elementi duplicati (`"first"`, di default), gli ultimi (`"last"`) oppure eliminare tutto (`False`).

```
>>> df.drop_duplicates()  # complessiva
    k1  k2
a  one   1
a  two   1
b  one   2
c  two   3
d  one   3
e  two   4
>>> df.drop_duplicates(subset = ["k1"]) # su singola colonna
    k1  k2
a  one   1
a  two   1
>>> df.drop_duplicates(subset = ["k1"], keep = 'last') # tenere ultimi elementi
    k1  k2
d  one   3
f  two   4
```

10.3.18.3 Indici duplicati

```
>>> df.index.duplicated()
array([False,  True, False, False, False, False, False])
```

10.3.19 Sorting

10.3.19.1 Su valori (sort_values)

Si usa: `sort_values` per ordinare sulla base di valori di colonna (è anche possibile fornire una funzione in `key` che elabora cose e restituisce qualcosa sulla base del quale fare ordinamento);

```
>>> rng = np.random.default_rng(23)
>>> df = pd.DataFrame({'g': ["x", "y", "x", "y"],
...                    'y' : rng.standard_normal((4)),
...                    'z' : rng.standard_normal((4))},
...                    index = list("bacd"))

>>> df.sort_values(by = 'y')
   g         y         z
d  y -2.318936  0.605966
c  x -0.057990  0.909921
a  y  0.217601 -2.126280
b  x  0.553261  0.431494
>>> df.sort_values(by = ['g', 'y'])
   g         y         z
c  x -0.057990  0.909921
b  x  0.553261  0.431494
d  y -2.318936  0.605966
a  y  0.217601 -2.126280
>>> df.sort_values(by = ['g', 'y'], ascending = [True, False])
   g         y         z
b  x  0.553261  0.431494
c  x -0.057990  0.909921
a  y  0.217601 -2.126280
d  y -2.318936  0.605966
```

10.3.19.2 Su indici (csort_index)

`sort_index` per ordinare sulla base degli indici di riga o nomi colonna

```
>>> # ordinare righe sulla base di indici
>>> # df.set_index("some_variable").sort_index()
>>> df.sort_index()
   g         y         z
a  y  0.217601 -2.126280
b  x  0.553261  0.431494
c  x -0.057990  0.909921
d  y -2.318936  0.605966

>>> # ordinare colonne alfabeticamente per nome variabile
>>> df.sort_index(axis="columns")
   g         y         z
b  x  0.553261  0.431494
a  y  0.217601 -2.126280
c  x -0.057990  0.909921
d  y -2.318936  0.605966
```

10.4 Descrittive

```
>>> import numpy as np
>>> import pandas as pd
>>> import tableone

>>> # dataset di prova
>>> rng = np.random.default_rng(123)
>>> df1 = pd.DataFrame(rng.random((1000, 5)), columns=["a", "b", "c", "d", "e"])
>>> df1[::2] = np.nan
>>> df2 = pd.DataFrame({
...     'name': ['Luca', 'Silvio', 'Luisa', 'Andrea', 'Giovanni'],
...     'age' : [21, 22, 23, 24, 25],
...     'income' : np.arange(5),
...     'group' : list("aaabb")
... })
>>> df3 = pd.DataFrame({"x": ["a", "a", "a", "a", "a", "b", "b"],
...                     "y": ["1", "2", "2", "2", "2", "1", "2"],
...                     "g": ["trt", "ctrl", "trt", "ctrl", "trt", "ctrl", "trt"]})

>>> categ_df = pd.DataFrame({"x": ["a", "a", "a", "a", np.nan, "b", "b"],
...                          "y": ["1", "2", "1", "2", "2", "1", "2"]})
>>> group_df = pd.DataFrame({'key1' : list('xyyzzzwwww'),
...                     'key2' : ['one', 'two'] * 5,
...                     'data1' : rng.random(10),
...                     'data2' : rng.random(10)},
...                     index = list("abcdefghil")
... )
>>> strata_df = pd.DataFrame({"x": np.random.randn(7),
...                           "y": np.random.randn(7),
...                           "z": np.random.randn(7),
...                           "g": ["trt", "ctrl", "trt", "ctrl", "trt", "ctrl", "trt"]})
```

10.4.1 Info generali

Usare `info` ed `head` sul `DataFrame` di interesse.

```
>>> df1.info()
<class 'pandas.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 5 columns):
 #   Column  Non-Null Count  Dtype
---  ------  --------------  -----
 0   a       500 non-null    float64
 1   b       500 non-null    float64
 2   c       500 non-null    float64
 3   d       500 non-null    float64
 4   e       500 non-null    float64
dtypes: float64(5)
memory usage: 39.2 KB
>>> df1.head()
```

Metodo	Series	DataFrame	Descrizione
count	✓	✓	numero di dati non mancanti
value_counts	✓	✓	frequenze
describe	✓	✓	set di statistiche descrittive
sum, prod	✓	✓	somma/prodotto dei valori
cumsum, cumprod, cummin, cummax	✓	✓	cumulate varie
diff, pct_change	✓	✓	differenze prime e variazione percentuale
min, max	✓	✓	minimo e massimo
mean	✓	✓	media
median	✓	✓	mediana
quantile	✓	✓	quantili
var, std	✓	✓	varianza/stddev campionaria
skew, kurt	✓	✓	skewness/kurtosis campionarie
argmin, argmax	✓		posizione (intera) di minimo/massimo
idxmin, idxmax	✓	✓	indici di massimo o minimo

Tabella 10.1: Metodi per analisi descrittiva

```
          a         b         c         d         e
0       NaN       NaN       NaN       NaN       NaN
1  0.812095  0.923345  0.276574  0.819755  0.889893
2       NaN       NaN       NaN       NaN       NaN
3  0.629940  0.927407  0.231908  0.799125  0.518165
4       NaN       NaN       NaN       NaN       NaN
```

10.4.2 Univariate

10.4.2.1 Statistiche varie

Per le statistiche descrittive utilizzando `pd.Series`/`pd.DataFrame` consultare le funzioni riportate in tabella 11.1.

```
>>> # categoriche (frequenze)
>>> categ_df.x.value_counts()
x
a    4
b    2
Name: count, dtype: int64
>>> categ_df.x.value_counts(dropna=False)
x
a      4
b      2
NaN    1
Name: count, dtype: int64

>>> # quantitative (count = non missing)
>>> df1.describe().transpose()
   count      mean       std       min       25%       50%       75%       max
a  500.0  0.502773  0.283937  0.001069  0.277015  0.504669  0.751380  0.999170
b  500.0  0.493140  0.282222  0.001018  0.266441  0.492543  0.726648  0.992696
c  500.0  0.502857  0.284280  0.001569  0.262469  0.496649  0.744064  0.999853
```

```
d  500.0  0.514312  0.292133  0.002091  0.273060  0.515317  0.768407  0.998832
e  500.0  0.504114  0.282020  0.000802  0.267343  0.505314  0.743535  0.997637
```

10.4.3 Bivariate

10.4.3.1 Tabelle di contingenza

Sono una speciale tipo di tabella pivot dove si applica il conteggio degli elementi in ciascun gruppo. Vi è una funzione apposta, `pd.crosstab`

```
>>> pd.crosstab(categ_df.x, categ_df.y, margins=True) # aggiungi totali
y    1  2  All
x
a    2  2    4
b    1  1    2
All  3  3    6
>>> pd.crosstab(categ_df.x, categ_df.y, dropna=False, margins=True) # display na
y    1  2  All
x
a    2  2    4
b    1  1    2
NaN  0  1    1
All  3  4    7
>>> pd.crosstab(categ_df.x, categ_df.y, margins=True, normalize = 'columns') # % col
y         1         2       All
x
a  0.666667  0.666667  0.666667
b  0.333333  0.333333  0.333333
```

10.4.3.2 Covarianza e correlazione

I metodi `cov` e `corr` permettono di ottenere la covarianza e correlazione per gli elementi di un dataframe.

```
>>> df1.cov()
          a         b         c         d         e
a  0.080620 -0.002448 -0.004181  0.003793  0.000086
b -0.002448  0.079649 -0.001561  0.006011  0.003534
c -0.004181 -0.001561  0.080815 -0.002689  0.000998
d  0.003793  0.006011 -0.002689  0.085342  0.000171
e  0.000086  0.003534  0.000998  0.000171  0.079535
>>> df1.corr() # pearson
          a         b         c         d         e
a  1.000000 -0.030547 -0.051794  0.045725  0.001079
b -0.030547  1.000000 -0.019462  0.072907  0.044398
c -0.051794 -0.019462  1.000000 -0.032377  0.012445
d  0.045725  0.072907 -0.032377  1.000000  0.002081
e  0.001079  0.044398  0.012445  0.002081  1.000000
>>> df1.corr(method='spearman')
          a         b         c         d         e
a  1.000000 -0.029228 -0.046313  0.045479 -0.000649
b -0.029228  1.000000 -0.020557  0.072495  0.044796
```

```
c -0.046313 -0.020557  1.000000 -0.033100  0.010191
d  0.045479  0.072495 -0.033100  1.000000  0.000381
e -0.000649  0.044796  0.010191  0.000381  1.000000
```

10.4.3.3 Tabelle pivot

Sono tabelle bivariate con statistiche stratificate per gruppi formati da righe e colonne (per intenderci il `tapply` con doppio indice di R).
Possono essere prodotte con i metodi che si vedranno sotto velocemente col metodo `pivot_table` dei `DataFrame`, che come default usa `mean` come funzione di aggregazione.

```
>>> group_df
  key1 key2     data1     data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
i    w  one  0.950948  0.244235
l    w  two  0.863556  0.815336
>>> group_df.pivot_table(index =   "key1",      # cosa porre in riga
...                      columns = "key2",      # cosa porre in colonna
...                      values =  "data1",     # dati per sintesi
...                      aggfunc = "median",    # metodo di DataFrameGroupBy
...                      margins = True)        # aggiungi i totali
key2       one       two       All
key1
w     0.715683  0.896679  0.896679
x     0.593121       NaN  0.593121
y     0.336277  0.353471  0.344874
z     0.915459  0.611006  0.822278
All   0.593121  0.822278  0.707699

>>> # utilizzo di funzioni custom: dovranno prendere in input una
>>> # serie e ritornare uno scalare

>>> def custom_fun(s): # s è una serie
...      return s.min() # qua la custom è inutile ma le cose si fanno cosi
...
>>> group_df.pivot_table(index =   "key1",      # cosa porre in riga
...                      columns = "key2",      # cosa porre in colonna
...                      values =  "data1",     # dati per sintesi
...                      aggfunc = custom_fun)
key2       one       two
key1
w     0.480418  0.863556
x     0.593121       NaN
```

```
y     0.336277  0.353471
z     0.915459  0.399734
```

Per applicare molteplici funzioni di sintesi usando una tavella pivot specificare in `aggfunc` una tuple (cose analoghe possono essere fatte usando `groupby` e poi `agg`)

```
>>> group_df.pivot_table(index =   "key1",      # cosa porre in riga
...                      values =  "data1",     # dati per sintesi
...                      aggfunc = ("sum", custom_fun))
      custom_fun       sum
key1
w       0.480418  3.224724
x       0.593121  0.593121
y       0.336277  0.689747
z       0.399734  2.137470

>>> group_df.pivot_table(index =   "key1",      # cosa porre in riga
...                      columns = "key2",      # cosa porre in colonna
...                      values =  "data1",     # dati per sintesi
...                      aggfunc = ("sum", custom_fun))
     custom_fun                 sum
key2        one       two       one       two
key1
w      0.480418  0.863556  1.431366  1.793358
x      0.593121       NaN  0.593121       NaN
y      0.336277  0.353471  0.336277  0.353471
z      0.915459  0.399734  0.915459  1.222011
```

10.4.3.4 Tabella trial

Utilizzare la libreria `tableone`.

```
tab1_df = tableone.load_dataset('pn2012')
tab1_df.info()
tab1_df.head()
ft = {0: "alive", 1: "dead"}
tab1_df["group"] = pd.Categorical(tab1_df.death.map(ft))
select = ['Age', 'SysABP', 'Height', 'Weight', 'ICU', 'group']
categ = ['ICU', 'group']
groupby = 'group'
nonnormal = ['Age']
labels={'death': 'mortality'}
tab1 = tableone.TableOne(tab1_df,
                         columns=select,
                         categorical=categ,
                         groupby=groupby,
                         nonnormal=nonnormal,
                         rename=labels, #renaming variabili di riga
                         missing=True, # conta dei missing
                         include_null=False, # evita i missing nelle var categoriche
                         pval=False)
```

Metodo	Descrizione
`any`, `all`	Vero se qualcuno o tutti sono veri (nel senso di Python)
`count`	numero di non NA
`cummin`, `cummax`	minimo e massimo cumulato
`cumsum`	somma cumulata
`cumprod`	produttoria cumulata
`first`, `last`	primo, ultimo
`mean`	media
`median`	mediana
`min`, `max`	minimo, massimo
`nth`	n-esimo elemento con dati ordinati
`prod`	prodotto
`quantile`	quantile
`rank`	ranghi
`size`	dimensione del gruppo
`sum`	somma
`std`, `var`	deviazione standard e varianza campionaria

Tabella 10.2: Metodi ottimizzati grouped

```
tab1
```

10.4.3.5 Stratificate

Si applica il classico split-apply-combine ossia:

1. si splitta la struttura dati (`Series` o `DataFrame`) mediante il metodo `groupby`: a questo si può passare alternativamente liste, array, dict, series o funzioni per effettuare il mapping ai gruppi.
   Di default `groupby` agisce splittando per sulle righe (`axis = "index"`), ma si può specificare `axis = "columns"` se si vuole splittare per colonna.
   Il metodo `groupby` ritorna un oggetto `GroupBy`:
   - è un iterabile sui "chunk" di dati (quindi funziona bene con i `for`) e fornisce un set di metodi già pronti da applicare
   - può essere soggetto a *indexing*, selezionando i subset di dati su cui performare le operazioni
2. si effettua l'elaborazione sui chunk di dati, alternativamente
   - l'oggetto `GroupBy` ha un set di metodi builtin già disponibili da applicare a tutti i chunk di dati. I metodi disponibili derivano da quelli della classe di riferimento quindi se è una `SeriesGroupBy` i metodi principali sono ereditati da quelli delle `Series`, viceversa se un `DataFrameGroupBy` dai `DataFrame`. In tabella 10.2 sono riportati alcuni metodi notevoli per `DataFrame`.
   - si possono applicare definire funzioni custom
   - si possono effettuare analisi ancor più custom (es una funzione a tutto il dataset).

3. viene riassemblato il tutto: il tipo di oggetto ritornato dipende dalle elaborazioni eseguite.

Splitting Vediamo vari metodi di splitting:

- basato su valori di variabili

```
>>> group_df
  key1 key2     data1     data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
i    w  one  0.950948  0.244235
l    w  two  0.863556  0.815336

>>> # Splitting di DataFrame sulla base di una variabile
>>> df_spl = group_df.groupby('key2')
>>> df_spl.mean(numeric_only = True) # se no essendoci key2 da errore
         data1     data2
key2
one   0.655244  0.647341
two   0.673768  0.507612

>>> # Splitting di DataFrame sulla base di due variabili
>>> df_spl = group_df.groupby(['key1', 'key2'])
>>> df_spl.mean()
              data1     data2
key1 key2
w    one   0.715683  0.540951
     two   0.896679  0.792142
x    one   0.593121  0.764104
y    one   0.336277  0.956624
     two   0.353471  0.638191
z    one   0.915459  0.434077
     two   0.611006  0.157792
```

- sulla base degli indici di riga

```
>>> # recode mediante dict
>>> groups = {"a" : 'g1', "b" : 'g1',
...           "c" : 'g1', "d" : 'g1',
...           "e" : 'g2', "f" : 'g2',
...           "g" : 'g2', "h" : 'g2',
...           "i" : 'g2', "l" : 'g2'}
>>> df_spl = group_df.groupby(groups)
>>> df_spl.count()
    key1  key2  data1  data2
```

```
g1     4     4      4      4
g2     6     6      6      6

>>> # Splitting con Series (esempio logiche)
>>> groups = (group_df.key1 == "w") & (group_df.key2 == "one")
>>> df_spl = group_df.groupby(groups)
>>> df_spl.count()
       key1  key2  data1  data2
False     8     8      8      8
True      2     2      2      2

>>> # Splitting con funzione/predicato: viene applicata al valore degli indici
>>> df_spl = group_df.groupby(lambda x: x in ("b", "c", "d"))
>>> df_spl.count()
       key1  key2  data1  data2
False     7     7      7      7
True      3     3      3      3

>>> # anche grouping sulla base di indici è possibile
>>> # modifichiamo un attimo il dataframe per mostrare
>>> # la funzionalità. Si usa il progressivo/nome dell'indice
>>> # specificato in level

>>> group_df2 = group_df.set_index('key2')
>>> group_df2.groupby(level = 0).count()
      key1  data1  data2
key2
one      5      5      5
two      5      5      5
>>> group_df2.groupby(level = 'key2').count()
      key1  data1  data2
key2
one      5      5      5
two      5      5      5
```

Convertire indici di grouping in variabili Negli esempi precedenti i risultati vengono restituiti con un indice, eventualmente gerarchico, composto a partire dalle chiavi di raggruppamento. Non essendo ciò sempre desiderabile, se si desidera avere qualcosa di più classico dove gli indici vengono invece messi in opportune colonne, a `groupby` si fornisce il parametro `as_index = False`.

```
>>> group_df
  key1 key2     data1     data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
```

```
i    w  one  0.950948  0.244235
l    w  two  0.863556  0.815336
```

```
>>> # aggregazione "flat"
>>> keys = ['key1', 'key2']
>>> df_spl = group_df.groupby(keys, as_index = False)
>>> df_spl.mean(numeric_only = True)
  key1 key2     data1     data2
0    w  one  0.715683  0.540951
1    w  two  0.896679  0.792142
2    x  one  0.593121  0.764104
3    y  one  0.336277  0.956624
4    y  two  0.353471  0.638191
5    z  one  0.915459  0.434077
6    z  two  0.611006  0.157792
```

Memorizzare in un dict lo split Essendo il `GroupBy` un iterabile, è possibile elaborarlo, ad esempio trasformandolo in un `dict`, per avervi facile accesso:

```
>>> pieces = dict(list(group_df.groupby('key2')))
>>> pieces['two']
  key1 key2     data1     data2
b    y  two  0.353471  0.638191
d    z  two  0.399734  0.178105
f    z  two  0.822278  0.137480
h    w  two  0.929802  0.768947
l    w  two  0.863556  0.815336
```

Iterazione sui gruppi Un oggetto `GroupBy` è iterabile quindi funziona bene con i `for`: questo genera una sequenza di tuple di due elementi, contenenti nome del gruppo (chiave) e chunk di dati di dati il pezzo di dati

```
>>> # chiave singola
>>> for group, data in group_df.groupby('key2'):
...   print(f"group = {group}")
...   print(data, "\n") # simple DataFrame
...
group = one
  key1 key2     data1     data2
a    x  one  0.593121  0.764104
c    y  one  0.336277  0.956624
e    z  one  0.915459  0.434077
g    w  one  0.480418  0.837667
i    w  one  0.950948  0.244235

group = two
  key1 key2     data1     data2
b    y  two  0.353471  0.638191
d    z  two  0.399734  0.178105
f    z  two  0.822278  0.137480
h    w  two  0.929802  0.768947
```

```
l    w  two  0.863556  0.815336

>>> # chiave multipla: il primo elemento della tupla è una
>>> # tupla con le chiavi
>>> for (key1, key2), data in group_df.groupby(['key1', 'key2']):
...   print(f"key1 = {key1}, key2 = {key2}")
...   print(data, "\n")
...
key1 = w, key2 = one
  key1 key2     data1     data2
g    w  one  0.480418  0.837667
i    w  one  0.950948  0.244235

key1 = w, key2 = two
  key1 key2     data1     data2
h    w  two  0.929802  0.768947
l    w  two  0.863556  0.815336

key1 = x, key2 = one
  key1 key2     data1     data2
a    x  one  0.593121  0.764104

key1 = y, key2 = one
  key1 key2     data1     data2
c    y  one  0.336277  0.956624

key1 = y, key2 = two
  key1 key2     data1     data2
b    y  two  0.353471  0.638191

key1 = z, key2 = one
  key1 key2     data1     data2
e    z  one  0.915459  0.434077

key1 = z, key2 = two
  key1 key2     data1     data2
d    z  two  0.399734  0.178105
f    z  two  0.822278  0.137480
```

Scelta delle variabili di analisi Se il dataset è molto grande e si analizzano poche colonne per sottogruppi, conviene fare lo splitting solamente di queste ultime; alternativamente è possibile splittare tutto il dataset e procedere ad analisi dei subset in un secondo momento (senza dover rifare lo splitting).
Per farlo, gli oggetti `GroupBy` accettano l'indexing:

```
>>> df_spl = group_df.groupby('key2')  # grouping/splitting

>>> df_spl['data1']              # column selection as usual
<pandas.api.typing.SeriesGroupBy object at 0x7f151a3f2d00>

>>> sel = ['data1', 'data2']     # due colonne
```

```
>>> df_spl[sel]
<pandas.api.typing.DataFrameGroupBy object at 0x7f151a3c5de0>
>>> df_spl[sel].mean()          # elaborazione
         data1     data2
key2
one   0.655244  0.647341
two   0.673768  0.507612
```

Applicare funzioni di aggregazione custom È possibile applicare funzioni che sintetizzano un insieme di dati in un unico valore passandole al metodo `aggregate` (o la sua abbreviazione `agg`) di un oggetto `GroupBy`:

```
>>> def range(x):
...     return x.max() - x.min()
...
>>> sel = ["data1", "data2"]
>>> group_df.groupby('key2')[sel].aggregate(range)
         data1     data2
key2
one   0.614671  0.712389
two   0.576331  0.677856
```

Elaborazioni custom Si potrebbe voler aggregare usando:

- diverse funzioni (es media e stdev) per ciascuna colonna: nel caso usare una lista di funzioni e/o stringhe con nomi di metodi scelti

  ```
  >>> df_spl = df2.groupby('group')
  >>> sel = ["income", "age"]

  >>> def range(x):
  ...     return x.max() - x.min()
  ...
  >>> # lista
  >>> analyses = ['mean', range]
  >>> df_spl[sel].agg(analyses)
        income         age
          mean range  mean range
  group
  a        1.0     2  22.0     2
  b        3.5     1  24.5     1

  >>> # lista di tuple con nome colonna e funzione applicata
  >>> analyses = [('Media', 'mean'), ('Range', range)]
  >>> df_spl[sel].agg(analyses)
        income         age
         Media Range Media Range
  group
  a        1.0     2  22.0     2
  b        3.5     1  24.5     1
  ```

- diverse funzioni su colonne differenti (es media per la prima colonna, stdev per la seconda).

```
>>> # dict con variabili analizzate e analisi effettuate
>>> analyses = {'age' : ["max", "std"], 'income' : "std"}
>>> df_spl.agg(analyses)
      age              income
      max       std       std
group
a      23  1.000000  1.000000
b      25  0.707107  0.707107
```

- Il problema è che si crea una gerarchia di colonna. Per rendere il tutto molto piu flat ed esportabile, l'ultimo esempio può essere riscritto come

```
>>> df_spl.agg(age_max = ("age", "max"),
...            age_std = ("age", "std"),
...            income_std = ("income", "std"))
       age_max   age_std  income_std
group
a           23  1.000000    1.000000
b           25  0.707107    0.707107
```

Trasformazioni group-wise Le aggregazioni effettuate mediante `aggregate` collassano un insieme di dati ad un numero. Viceversa:

- `transform` applica una funzione ad una serie: se l'output è un singolo valore questo viene broadcastato a tutti i membri del gruppo; se è un vettore (della stessa dimensione del gruppo) viene restituito. Eventuali parametri vanno specificati post funzione separati da virgole.
  Ad esempio lo scarto del gruppo dalla media di gruppo:

```
>>> def center(x):
...       return x - x.mean()
...
>>> def group_mean(x):
...       return x.mean()
...
>>> df_spl = group_df.groupby("key2")
>>> sel = ["data1", "data2"]
>>> df_spl[sel].transform(center)
      data1     data2
a -0.062124  0.116763
b -0.320297  0.130579
c -0.318968  0.309283
d -0.274034 -0.329507
e  0.260215 -0.213265
f  0.148509 -0.370132
g -0.174826  0.190325
h  0.256034  0.261336
i  0.295703 -0.403107
l  0.189788  0.307724
```

```
>>> df_spl[sel].transform(group_mean)
      data1     data2
a  0.655244  0.647341
b  0.673768  0.507612
c  0.655244  0.647341
d  0.673768  0.507612
e  0.655244  0.647341
f  0.673768  0.507612
g  0.655244  0.647341
h  0.673768  0.507612
i  0.655244  0.647341
l  0.673768  0.507612
```

- `apply` applica la funzione passata ai `DataFrame` creati dallo splitting; la funzione passatagli pu restituire uno scalare, una list/array o anche un dataframe.

  Eventuali parametri della funzione specificati in seguito e separati da virgola

```
>>> def report(df, var = 'data1', method = 'high', n = 2):
...     if method == 'high':
...         sel = df[var].nlargest(n).index
...     elif method == 'low':
...         sel = df[var].nsmallest(n).index
...     return df.loc[sel, ]
...
>>> group_df
  key1 key2     data1     data2
a    x  one  0.593121  0.764104
b    y  two  0.353471  0.638191
c    y  one  0.336277  0.956624
d    z  two  0.399734  0.178105
e    z  one  0.915459  0.434077
f    z  two  0.822278  0.137480
g    w  one  0.480418  0.837667
h    w  two  0.929802  0.768947
i    w  one  0.950948  0.244235
l    w  two  0.863556  0.815336

>>> # applicata a tutto il dataframe: estrae i due valori più alti di
>>> # data1 overall
>>> report(group_df)
  key1 key2     data1     data2
i    w  one  0.950948  0.244235
h    w  two  0.929802  0.768947

>>> # stratified by key2: estrae i due valori più alti di data1 entro
>>> # gruppi di key2
>>> df_spl = group_df.groupby('key2')
>>> df_spl.apply(report, include_groups = False)
```

```
       key1     data1     data2
key2
one  i    w  0.950948  0.244235
     e    z  0.915459  0.434077
two  h    w  0.929802  0.768947
     l    w  0.863556  0.815336

>>> # uso di parametri della funzione: estrazione per data2
>>> df_spl.apply(report, var = 'data2', include_groups = False)
       key1     data1     data2
key2
one  c    y  0.336277  0.956624
     g    w  0.480418  0.837667
two  l    w  0.863556  0.815336
     h    w  0.929802  0.768947
```

10.5 Cookbook

10.5.1 Stampa tutto il contenuto di un DataFrame

Per una **impostazione definitiva** impostare righe e colonne

```
pd.set_option('display.max_rows', 500)
pd.set_option('display.max_columns', 500)
```

Per una **impostazione momentanea** usare il context manager `pd.option_context` con le seguenti opzioni

```
with pd.option_context('display.max_rows', None, 'display.max_columns', None):
    stampa_df()
```

10.5.2 Old stuff

10.5.2.1 Reindexing (`reindex`, `loc`)

NB: di dubbia utilità: se utile porlo nella sezione dei dataframe, utilità per indici

Serve per riordinare e/o selezionare righe e colonne:

- utilizzare `reindex`: di default lavora sulle righe a meno che non si specifichi `columns`
- se si desidera un modo safe per effettuare reindexing utilizzare `loc`: funziona solo se gli indici forniti esistono già nel `DataFrame` (e non crea valori missing)

```
>>> data = np.arange(9).reshape((3,3))
>>> id = ['a', 'c', 'd']
>>> col = ['Ohio', 'Texas', 'California']
>>> df = pd.DataFrame(data, index = id, columns = col)
>>> df
   Ohio  Texas  California
a     0      1           2
c     3      4           5
d     6      7           8
```

```
>>> df2 = df.reindex(['a', 'b', 'c', 'd']) # reindexing di riga
>>> df2 # b missing perché non disponibile nei dati di partenza
   Ohio  Texas  California
a   0.0    1.0         2.0
b   NaN    NaN         NaN
c   3.0    4.0         5.0
d   6.0    7.0         8.0

>>> states = ['Texas', 'Utah', 'California'] # reindexing di colonna
>>> df.reindex(columns = states) # si cancella Ohio, non richiesto
   Texas  Utah  California
a      1   NaN           2
c      4   NaN           5
d      7   NaN           8

>>> df.loc[["a", "d", "c"], ["California", "Texas"]] # safe reindexing
   California  Texas
a           2      1
d           8      7
c           5      4
```

10.5.2.2 Applicare diverse funzioni a diversi elementi

diverse funzioni a diverse colonne utilizzare `transform`: si genera il nuovo in un dataframe (che deve esser bindato al vecchio)

NB: boh occam razor direi, perché ricordare un altro metodo

```
>>> def two(x):
...     return x*2
...
>>> def three(x):
...     return x*3
...
>>> df  = pd.DataFrame({"a": [1,2,3], "b": [4,5,6], "c": [7,8,9]})

>>> t = {"a": two, "b": three}
>>> df.transform(t)
   a   b
0  2  12
1  4  15
2  6  18
```

Alternativamente si può passare un `dict` ad `agg` che specifichi per variabile quali analisi fare

```
>>> df  = pd.DataFrame({"a": [1,2,3], "b": [4,5,6], "c": [7,8,9]})
>>> analysis_dict = {
...     "a": ["count", "size"],
...     "b": ["sum", lambda col: col.loc[0]]}
>>> df.agg(analysis_dict)
            a     b
count     3.0   NaN
```

```
size      3.0   NaN
sum       NaN  15.0
<lambda>  NaN   4.0
```

10.5.2.3 Reshape sulla base di indici (stack,unstack)

NB: bah direi che sulla base di valori è quello che si vuole solitamente

L'indexing gerarchico torna necessario nel reshape. Vi sono due metodi principali:

- `stack` ruota le colonne a righe (va verso long)
- `unstack` ruota da righe a colonne (va verso wide)

In questi casi utile un `name` agli indici

```
>>> df = pd.DataFrame({"one"   : [0, 3],
...                    "two"   : [1, np.nan],
...                    "three" : [2, 5],
...                    "four"  : [np.nan, 6]},
...                   index = pd.Index(["Ohio", "Colorado"], name = "state"))

>>> df
          one  two  three  four
state
Ohio        0  1.0      2   NaN
Colorado    3  NaN      5   6.0

>>> df.stack()                    # stack: porre in formato long
state
Ohio      one      0.0
          two      1.0
          three    2.0
          four     NaN
Colorado  one      3.0
          two      NaN
          three    5.0
          four     6.0
dtype: float64
>>> df.stack(future_stack = True) # versione futura da struttura simmetrica
state
Ohio      one      0.0
          two      1.0
          three    2.0
          four     NaN
Colorado  one      3.0
          two      NaN
          three    5.0
          four     6.0
dtype: float64
>>> df_long = df.stack()          # saving results

>>> df_long.unstack()                # unstack verso wide (default level = 1: usa sec
```

```
          one  two  three  four
state
Ohio      0.0  1.0    2.0   NaN
Colorado  3.0  NaN    5.0   6.0
>>> df_long.unstack(level = 0)       # unstack usando la prima colonna di indici
state  Ohio  Colorado
one     0.0       3.0
two     1.0       NaN
three   2.0       5.0
four    NaN       6.0
>>> df_long.unstack(level = 'state') # unstack usando i name
state  Ohio  Colorado
one     0.0       3.0
two     1.0       NaN
three   2.0       5.0
four    NaN       6.0
```

Capitolo 11

Polars

Contents

11.1 Introduzione 99
11.1.1 Tipi di dati 99
11.1.2 Espressioni e contesti 100
11.1.3 Expression expansion e selettori 100
11.2 Data I/O 101
11.2.1 Importazione dati 101
11.2.2 Esportazione dati 101
11.3 `Series` 101
11.3.1 Creazione 101
11.3.2 Attributi 101
11.3.3 Indexing e selezione 102
11.3.4 Elaborazione vettorizzata 102
11.3.5 Coercizione di tipo (`cast`) 102
11.3.6 Valori condizionali a-la `ifelse` (`pl.when`) 102
11.3.7 Applicazione di una funzione a tutti gli elementi (`map`) 102
11.3.8 Sostituzione di valori (`replace`) 102
11.3.9 Test di appartenenza (`in`, `isin`) 102
11.3.10 Dati mancanti 102
11.3.11 Duplicati 102
11.3.12 Sorting 103
11.3.13 Discretizzazione/creazione di classi (`cut`, `qcut`) . . . 103
11.3.14 Dummy variables 103
11.3.15 Stringhe 103
11.3.16 Date/ore 104
11.3.17 Dati categorici (`Enum` e `Categorical`) 104
11.3.18 Liste, array, structs 105
11.4 `DataFrame` 106
11.4.1 Creazione 106
11.4.2 Contenuto 106
11.4.3 Copia di df e di struttura (`clone`, `clear`) 106
11.4.4 Selezione 107

11.4.5 Inserimento colonna in un punto (.insert_column) . 107
11.4.6 Assegnazione (with_columns) 107
11.4.7 Rimozione righe/colonne (.filter/.drop) 108
11.4.8 Rinominare colonne 108
11.4.9 Coercizione di tipi (.cast) 108
11.4.10 Applicazione di funzioni 108
11.4.11 Ciclo su righe/colonne 109
11.4.12 Merge (.join) 109
11.4.13 Binding (pl.concat) 110
11.4.14 Reshape 110
11.4.15 Trasporre (.transpose) 110
11.4.16 Test di appartenenza (in) 111
11.4.17 Dati mancanti 111
11.4.18 Duplicati 111
11.4.19 Sorting 111
11.4.20 Id univoco di riga 112
11.4.21 Windows functions 112
11.4.22 folds (elaborazioni orizzontali) 112
11.5 Descrittive 112
11.5.1 Univariate 113
11.5.2 Bivariate 113

Series e DataFrame di nuova generazione, non ha il concetto di indice:

```
>>> import polars as pl
>>> pl.__version__
'1.42.1'

>>> import numpy as np
```

Per settare opzioni

- semi-definitivamente usare

  ```
  >>> pl.Config.set_ascii_tables(True) # altrimenti la stampa di df da problemi co
  <class 'polars.config.Config'>
  ```

- al volo utilizzare with

  ```
  # stampa tutte le righe e colonne del df in ascii art
  with pl.Config(tbl_rows=-1, tbl_cols=-1, ascii_tables=True):
      print(df)
  ```

11.1 Introduzione

11.1.1 Tipi di dati

Polars supporta vari **tipi di dati**:

- numeric data types: signed integers, unsigned integers, floating point numbers, and decimals.

- temporal: dates, datetimes, times, and time deltas
- miscellanei: strings, binary data, Booleans, categoricals, enums, and objects
- *nested* data types: lists, structs, and arrays.

Tutti i tipi supportano valori mancanti rappresentati tramite `null` (in input inserire `None`); è diverso da `NaN` rinvenibile solo nei floating point (inseribile come `np.nan` o `float("nan")`)

- `NaN` non è considerato missing (ha sue funzioni specifiche `is_nan`, `fill_nan`), non è rilevato da `null_count` ne toccato da `fill_null`
- aggregazioni numeriche su `null` ignorano i dati missing mentre `nan` fa si che vengano propagati

11.1.2 Espressioni e contesti

Le **espressioni** sono la rappresentazione di una trasformazione dati possono essere

- composte tra loro,
- salvate in una variabile
- eseguite in un *contesto*: quando si esegue una espressione Polar cerca di semplificarla e parallelizzarla se possibile

I **contesti** sono i posti dove vengono eseguite le espressioni: i più comuni sono

- `select`: applica l'espressione alle colonne, producendo nuove colonne. L'espressione passata deve produrre o una costante (che viene ripetuta per le righe) o una serie che deve matchare con la lunghezza prodotta dalle altre valutazioni all'interno della select (ma non necessariamente col il numero righe del dataframe di partenza)

```
bmi_expr = pl.col("weight") / (pl.col("height") ** 2)
result = df.select(
    bmi=bmi_expr,
    avg_bmi=bmi_expr.mean(),
    ideal_max_bmi=25,
)
# espressione con broadcasting
result = df.select(deviation=(bmi_expr - bmi_expr.mean()) / bmi_expr.std())
```

- `with_columns`: simile a `select` ma include tutto il dataframe di provenienza, assieme alle nuove colonne create. L'espressione deve creare una serie avente la stessa lunghezza delle colonne del dataframe.
- `filter`: prende in input espressioni che valutano a booleano, che vengono utilizzate per filtro (di default in and)

```
# seleziona per datanascita ed età
result = df.filter(
    pl.col("birthdate").is_between(date(1982, 12, 31), date(1996, 1, 1)),
    pl.col("height") > 1.7,
)
```

- `group_by`: in questo contesto le righe sono raggruppate secondo i valori unici prodotti dalle espressioni passate. Dopodiché si possono applicare espressioni ai gruppi risultanti (mediante `.agg`) che potrebbero ritornare risultati di lunghezza variabili (e nel caso saranno posti in liste). Se nessuna aggregazione è effettuata, semplicemente si fa l'elenco dei risultati (in una lista, se di lunghezza differente)

  ```
  # lista i nomi dei nati per decade
  result = df.group_by(
      (pl.col("birthdate").dt.year() // 10 * 10).alias("decade"),
  ).agg(pl.col("name"))
  # numero di soggetti, altezza massima ed altezze/pesi medi per decade ed altezza
  result = df.group_by(
      (pl.col("birthdate").dt.year() // 10 * 10).alias("decade"),
      (pl.col("height") < 1.7).alias("short?"),
  ).agg(
      pl.len(),
      pl.col("height").max().alias("tallest"),
      pl.col("weight", "height").mean().name.prefix("avg_"),
  )
  ```

- `List`

11.1.3 Expression expansion e selettori

Nella .agg abbiamo usato

```
pl.col("weight", "height").mean().name.prefix("avg_"),
```

che è una "expression expansion": di base applica la stessa trasformazione a diverse colonne. L'alternativa equivalente è sarebbe stata

```
[
    pl.col("weight").mean().alias("avg_weight"),
    pl.col("height").mean().alias("avg_height"),
]
```

che presenta il contro di codice ripetuto, il pro che più facilmente sarà parallelizzabile rispetto alla expression expansion.
Una expression expansion utile per il datamanagement può essere quella basata sul tipo di dato, raggiungibile come segue

```
(pl.col(pl.Float64) * 1.1).name.suffix("*1.1")
```

che moltiplica per 1.1 tutti i float e ne modifica il nome. Alcune expression expansion utili

```
# seleziona tutti i floats
df.with_columns((pl.col(pl.Float32, pl.Float64) / eur_usd_rate).round(2))

# seleziona con regex sul nome (mostra solamente)
df.select(pl.col("ticker", "^.*_high$", "^.*_low$"))

# selezionare tutte le colonne
df.select(pl.all())

# escludere colonne
df.select(pl.all().exclude("^day_.*$"))
df.select(pl.col(pl.Float64).exclude("^day_.*$"))

# rinominazione in batch con espressioni regolari
df.select(
    (pl.col("^year_.*$") / eur_usd_rate).name.prefix("in_eur_"),
    (pl.col("day_high", "day_low") / gbp_usd_rate).name.suffix("_gbp"),
    pl.col("foo", "bar", "baz").name.map(str.upper)
)
```

Per avere selezione ancor pià flessibile il submodulo `selectors` fornisce selettori per tipo di variabile e nome

```
import polars.selectors as cs

# seleziona stringhe o variabili che terminano di nome in "high"
df.select(cs.string() | cs.ends_with("_high"))

# cs.numeric()   # tutte le numeriche
# cs.temporal()  # tutte le temporali
```

i cs producono cose assimilabili ai set, pertanto possiamo usare operatori booleani

```
df.select(cs.contains("_") - cs.string())

# Operatore  Operazione
# ---------------------
# A | B      Union
# A & B      Intersection
# A - B      Difference
# A ^ B      Symmetric difference
# ~A          Complement
```

Una volta effettuata la selezione aggiungiamo espressioni come in `pl.col`

```
df.select((cs.contains("_") - cs.string()) / eur_usd_rate)
```

Modalità esecuzione Vi sono due modalità:

- **eager**: query/espressioni eseguite immediatamente; ok per l'esecuzione interattiva/esplorazione dati (e non si sa ancora quale sarà l'elaborazione da fare)

```
df = pl.read_csv("docs/assets/data/iris.csv")
df_small = df.filter(pl.col("sepal_length") > 5)
df_agg = df_small.group_by("species").agg(pl.col("sepal_width").mean())
print(df_agg)
```

- **lazy**: query/espressioni eseguite una volta che sono *collected*. Questo ha vantaggi di performance, soprattutto con dataset di grandi dimensioni, perché permette al motore di ottimizzare (es seleziona solo le colonne e righe solo necessarie necessarie)

  ```
  # definizione query
  q = (
      pl.scan_csv("docs/assets/data/iris.csv")
      .filter(pl.col("sepal_length") > 5)
      .group_by("species")
      .agg(pl.col("sepal_width").mean())
  )

  # visualizzare le operazioni effettuate
  q.explain()

  # esecuzione ed ottenimento dei risultati
  df = q.collect()
  ```

  I benefici: minore carico su memoria e cpu, permette di caricare dataset più grandi in memoria e processarli più velocemente.

11.2 Data I/O

11.2.1 Importazione dati

11.2.1.1 Da file

L'importazione di dati può avvenere

- in maniera greedy mediante i metodi `pl.read_*`

  ```
  # wrapper
  df = lb.io2.import_data("paths")

  # File testuali
  df = pl.read_csv('path.csv', separator=";", decimal_comma=True, try_parse_dates=

  # Alcuni binari notevoli
  df = pl.read_excel('path.xlsx', sheet_name = 'asd')  # file xlsx
  ```

- in maniera non greedy mediante i metodi `pl.scan_*`

  ```
  # scanning: per file di grandi dimensioni non esegue subito il codice e porta
  # tutto in memoria ma imposta una selezione e importa il necessario (non
  # fullando la ram)
  df2_query = (
      pl.scan_csv("dati.csv")
  ```

```
        .filter(pl.col("b") > 3)
    )

    df2 = df2_query.collect()
```

11.2.1.2 Da pandas

Utilizzare `pl.from_pandas`

```
df = pl.from_pandas(pandas_df)
```

11.2.2 Esportazione dati

11.2.2.1 Su file

Si usano i metodi `write_*` dei `DataFrame`

```
# # wrapper
# df = lb.io.export_data(df_or_dict_of_dfs, path)  #TODO

# File testuali
df.write_csv('path.csv')

# Binari
df.write_excel('path.xlsx') # singolo
```

11.2.2.2 Verso pandas

Si usa il metodo `to_pandas`

```
# pandas
df.to_pandas()
```

11.3 Series

11.3.1 Creazione

Il modo base per creare una `Series` è

```
>>> import datetime as dt

>>> ints = [1, 2, None, 3]
>>> floats = [4., 5., 6., None]
>>> chars = ["a", "b", "c", None]
>>> dates = [dt.date(2001,1,1), None, dt.date(2002,1,1), dt.date(2003,1,1)]

>>> # senza specificare nome della variabile (utilizzata in data.frame)
>>> i = pl.Series(ints)
>>> i
shape: (4,)
Series: '' [i64]
[
    1
```

```
    2
    null
    3
]
>>> f = pl.Series(floats)
>>> f
shape: (4,)
Series: '' [f64]
[
    4.0
    5.0
    6.0
    null
]
>>> c = pl.Series(chars)
>>> c
shape: (4,)
Series: '' [str]
[
    "a"
    "b"
    "c"
    null
]
>>> d = pl.Series(dates)
>>> d
shape: (4,)
Series: '' [date]
[
    2001-01-01
    null
    2002-01-01
    2003-01-01
]
```

Specificando nomi variabile e tipo

```
>>> i = pl.Series("some_ints", ints, dtype=pl.Int64)
>>> f = pl.Series("some_floats", floats, dtype=pl.Float64)
>>> c = pl.Series("some_chars", chars, dtype=pl.String)
>>> d = pl.Series("some_dates", dates, dtype=pl.Date)

>>> # benefit di specificare i nomi nelle serie
>>> pl.DataFrame([i,f,c,d])
shape: (4, 4)
+-----------+-------------+------------+------------+
| some_ints | some_floats | some_chars | some_dates |
| ---       | ---         | ---        | ---        |
| i64       | f64         | str        | date       |
+=================================================+
| 1         | 4.0         | a          | 2001-01-01 |
| 2         | 5.0         | b          | null       |
```

```
| null      | 6.0         | c           | 2002-01-01 |
| 3         | null        | null        | 2003-01-01 |
+-----------+-------------+-------------+------------+
```

```
>>> # Nomi possono essere aggiunti/modificati mediante alias
>>> d.alias("very_SAME_dates")
shape: (4,)
Series: 'very_SAME_dates' [date]
[
    2001-01-01
    null
    2002-01-01
    2003-01-01
]
```

11.3.2 Attributi

```
>>> i.dtype
Int64
>>> i.name
'some_ints'
>>> i.shape
(4,)
```

11.3.3 Indexing e selezione

Con `[]` possiamo utilizzare, interi, liste, slicing; per booleani usare `filter`

```
>>> i[0]                          # un intero
1
>>> i[[0]]                        # lista di un intero
shape: (1,)
Series: 'some_ints' [i64]
[
    1
]
>>> i[[3, 0, 1]]                  # lista di interi
shape: (3,)
Series: 'some_ints' [i64]
[
    3
    1
    2
]
>>> i[:2]                         # slicing
shape: (2,)
Series: 'some_ints' [i64]
[
    1
    2
]
```

```
>>> i.filter([True, False, False, True]) # lista di booleani
shape: (2,)
Series: 'some_ints' [i64]
[
    1
    3
]
>>> i.filter(i > 2)                      # serie di booleani
shape: (1,)
Series: 'some_ints' [i64]
[
    3
]
```

11.3.4 Elaborazione vettorizzata

Similmente a numpy le elaborazioni sono vettorizzate (si applicano *ufuncs* e broadcasting similmente a pandas

```
>>> np.exp(f) + 1  # questo funziona solo con i float
shape: (4,)
Series: 'some_floats' [f64]
[
    55.59815
    149.413159
    404.428793
    null
]
```

11.3.5 Coercizione di tipo (`cast`)

Si usa il metodo `cast` fornendo un tipo builtin di Python o un tipo di polars

```
>>> i.cast(pl.Float32)
shape: (4,)
Series: 'some_ints' [f32]
[
    1.0
    2.0
    null
    3.0
]
```

11.3.6 Valori condizionali a-la `ifelse` (`pl.when`)

Da saltarci fuori

11.3.7 Applicazione di una funzione a tutti gli elementi (`map`)

Per applicare una funzione per scalare a tutti gli elementi di una `Series` utilizzare `map_elements`

```
>>> i.map_elements(lambda x: f"{x:.2f}") # esempio di formattazione
shape: (4,)
Series: 'some_ints' [str]
[
    "1.00"
    "2.00"
    null
    "3.00"
]
```

11.3.8 Sostituzione di valori (`replace`)

Se si vuole sostituire solo alcuni elementi e lasciare invariati gli altri si usa `replace`:

```
>>> i.replace({1 : 999})
shape: (4,)
Series: 'some_ints' [i64]
[
    999
    2
    null
    3
]
```

11.3.9 Test di appartenenza (`in`, `isin`)

Con

- la keyword `in` testa l'esistenza nella serie e restituisce un booleano secco

  ```
  >>> 1 in i
  True
  ```

- il metodo `isin` della serie testa l'appartenenza ad un gruppo dei vari valori;

  ```
  >>> i.is_in([1, 2])
  shape: (4,)
  Series: 'some_ints' [bool]
  [
      true
      true
      null
      false
  ]
  ```

11.3.10 Dati mancanti

Vediamo metodi/funzioni più utili a livello di `Series`

```
>>> i.is_null()         # test; z.is_not_null() sua negazione
shape: (4,)
Series: 'some_ints' [bool]
[
    false
    false
    true
    false
]
>>> i.drop_nulls()      # eliminare
shape: (3,)
Series: 'some_ints' [i64]
[
    1
    2
    3
]
>>> i.fill_null(999)    # riempimento
shape: (4,)
Series: 'some_ints' [i64]
[
    1
    2
    999
    3
]
```

11.3.11 Duplicati

I metodi più utili:

```
>>> x = pl.Series([1, 2, 2, None, None])
>>> x.is_duplicated() # marca i doppi, anche le prime manifestazioni, nonchè gli NA
shape: (5,)
Series: '' [bool]
[
    false
    true
    true
    true
    true
]
>>> x.unique(maintain_order=True)   # rende unica: altrimenti cambia ordinamento
shape: (3,)
Series: '' [i64]
[
    1
    2
```

```
    null
]
```

11.3.12 Sorting

Si usa il metodo `sort`

```
>>> i.sort()
shape: (4,)
Series: 'some_ints' [i64]
[
    null
    1
    2
    3
]
```

11.3.13 Discretizzazione/creazione di classi (`cut`, `qcut`)

Si usa la funzione `cut` sulla `Series` specificando i cut o `qcut` sulla base dei quantili.

```
>>> rng = np.random.default_rng(12093)
>>> age = pl.Series(rng.integers(1, 100, size = 5))
>>> age
shape: (5,)
Series: '' [i64]
[
    32
    2
    79
    26
    93
]

>>> # cuts specificati
>>> cuts = [0, 25, 50, 75, 100]
>>> labs = ["prima_di_0", "giovane", "medio", "senior", "anziano", "oltre_100"]

>>> age.cut(breaks = cuts) # senza labels
shape: (5,)
Series: '' [enum]
[
    "(25, 50]"
    "(0, 25]"
    "(75, 100]"
    "(25, 50]"
    "(75, 100]"
]
>>> age.cut(breaks = cuts, labels = labs) # con
shape: (5,)
```

```
Series: '' [enum]
[
    "medio"
    "giovane"
    "anziano"
    "medio"
    "anziano"
]
```

```
>>> age.qcut(5)    # quintile of age
shape: (5,)
Series: '' [cat]
[
    "(29.6, 50.8]"
    "(-inf, 21.200000000000003]"
    "(50.8, 81.8]"
    "(21.200000000000003, 29.6]"
    "(81.8, inf]"
]
```

11.3.14 Dummy variables

11.3.14.1 Utilizzo base (`get_dummies`)

Per creare un `DataFrame` di dummy a partire da una serie si usa `to_dummies`.
Qui è meglio dare il nome alla variabile

```
>>> x = pl.Series("var", ["a","a","b", None]) # occhio ai na che sono ignorati
>>> x.to_dummies()
shape: (4, 3)
+-------+-------+----------+
| var_a | var_b | var_null |
| ---   | ---   | ---      |
| u8    | u8    | u8       |
+==========================+
| 1     | 0     | 0        |
| 1     | 0     | 0        |
| 0     | 1     | 0        |
| 0     | 0     | 1        |
+-------+-------+----------+
```

11.3.14.2 Variabili a risposta multipla

`str.getdummies` crea dummy utile per specificare i separatori (es per risposte multiple)

```
>>> x = pl.Series("dummies", ["a|b", "b|c", "a", "a|b|c"])
>>> # TODOHERE
```

11.3.15 Stringhe

Vediamo alcune funzionalità utili delle `Series` di stringhe.

- Vi sono metodi direttamente accedibili dalla `Series`
- altri metodi sono accedibili da `Series.str`

Ad ogni modo vi è overlap con i metodi delle `str` Python di base.

```
>>> suits = pl.Series(["clubsaaa", "Diamondsaa", "hearts", "Spades"])
>>> rps = pl.Series(["ROck ", " paper", "sciSSORS"])
```

11.3.15.1 Paste

Di due serie

```
>>> rps + "5"           # paste con costante
shape: (3,)
Series: '' [str]
[
    "ROck 5"
    " paper5"
    "sciSSORS5"
]
>>> rps + rps[::-1]     # paste di due serie
shape: (3,)
Series: '' [str]
[
    "ROck sciSSORS"
    " paper paper"
    "sciSSORSROck "
]
```

Di variabili di un dataframe

```
>>> df = pl.DataFrame({"rps1": rps, "rps2": rps})
>>> df.select(
...   pl.concat_str(["rps1", "rps2"], separator=", ").alias("pasted")
... )
shape: (3, 1)
+--------------------+
| pasted             |
| ---                |
| str                |
+====================+
| ROck , ROck        |
|  paper,  paper     |
| sciSSORS, sciSSORS |
+--------------------+
```

11.3.15.2 Collapse

```
>>> rps.str.join("_")    # collassa
shape: (1,)
Series: '' [str]
[
    "ROck _ paper_sciSSORS"
]
```

11.3.15.3 Formattazione varia

```
>>> rps.str.strip_chars()                # elimina bianchi
shape: (3,)
Series: '' [str]
[
    "ROck"
    "paper"
    "sciSSORS"
]
>>> rps.str.pad_start(8, fill_char="_")  # aggiungi caratteri all'inizio
shape: (3,)
Series: '' [str]
[
    "___ROck "
    "__ paper"
    "sciSSORS"
]
>>> rps.str.pad_end(8, fill_char="_")    # aggiungi caratteri alla fine
shape: (3,)
Series: '' [str]
[
    "ROck ___"
    " paper__"
    "sciSSORS"
]
>>> rps.str.to_lowercase()               # tutto minuscolo
shape: (3,)
Series: '' [str]
[
    "rock "
    " paper"
    "scissors"
]
>>> rps.str.to_uppercase()               # maiuscolo
shape: (3,)
Series: '' [str]
[
    "ROCK "
    " PAPER"
    "SCISSORS"
]
```

Per incollare/formattare assieme due/più stringhe selezionarle e applicare una funzione ad hoc per riga al dataframe (se non si riesce a fare in maniera alternativa con il lessico polar che è più efficiente)

```
>>> tmp = pl.DataFrame({
...     "l": ["a", "b", "c"],
...     "n": ["1", "2", "3"]
... })
```

```
>>> tmp.map_rows(lambda row: f"{row[0]} ({row[1]})")
shape: (3, 1)
+-------+
| map   |
| ---   |
| str   |
+=======+
| a (1) |
| b (2) |
| c (3) |
+-------+
```

11.3.15.4 Lunghezza ed sottostringhe

```
>>> rps.str.len_chars()                 # lunghezza
shape: (3,)
Series: '' [u32]
[
    5
    6
    8
]
>>> rps.str.slice(2,5)                  # subsetting stringa (es)
shape: (3,)
Series: '' [str]
[
    "ck "
    "aper"
    "iSSOR"
]
```

11.3.15.5 Splitting

```
>>> agecl = pl.Series(["0-10", "11-15", "11-15"])
>>> agecl.str.split("-")      # ritorna una serie di liste
shape: (3,)
Series: '' [list[str]]
[
    ["0", "10"]
    ["11", "15"]
    ["11", "15"]
]

>>> # selezione sulle componenti
>>> agecl.str.split("-").list[0]
shape: (3,)
Series: '' [str]
[
    "0"
    "11"
    "11"
```

```
]
>>> agecl.str.split("-").list.first()
shape: (3,)
Series: '' [str]
[
    "0"
    "11"
    "11"
]
>>> agecl.str.split("-").list.last()
shape: (3,)
Series: '' [str]
[
    "10"
    "15"
    "15"
]

>>> # splittare, eseguire cose su ciascun elemento e ricomporre
>>> (
...   agecl.str.split("-")
...   .list.eval((pl.element().cast(pl.Int64)+1).cast(pl.String))
...   .list.join("-||-")
... )
shape: (3,)
Series: '' [str]
[
    "1-||-11"
    "12-||-16"
    "12-||-16"
]

>>> # splittare, filtrare e ricomporre
>>> (
...   agecl.str.split("-")
...   .list.filter((pl.element().cast(pl.Int64)>5))
...   .list.join("-||-")
... )
shape: (3,)
Series: '' [str]
[
    "10"
    "11-||-15"
    "11-||-15"
]


>>> # per espandere in verticale
>>> (
...   agecl.str.split("-").alias("estremo")
...   .to_frame()
```

```
...    .with_row_index()
...    .explode("estremo")
... )
shape: (6, 2)
+-------+---------+
| index | estremo |
| ---   | ---     |
| u32   | str     |
+=================+
| 0     | 0       |
| 0     | 10      |
| 1     | 11      |
| 1     | 15      |
| 2     | 11      |
| 2     | 15      |
+-------+---------+

>>> # per avere un dataframe
>>> (
...    agecl.str.split_exact("-",1)
...    .struct.rename_fields(["upper", "lower"])
...    .to_frame()
...    .unnest()
... )
shape: (3, 2)
+-------+-------+
| upper | lower |
| ---   | ---   |
| str   | str   |
+===============+
| 0     | 10    |
| 11    | 15    |
| 11    | 15    |
+-------+-------+
```

11.3.15.6 Ricerca/rimpiazzo

```
>>> # Ricerca
>>> # -------
>>> suits.str.contains("[ae]")  # ne ha?
shape: (4,)
Series: '' [bool]
[
    true
    true
    true
    true
]
>>> suits.str.count_matches("[ae]")     # conta quanti
shape: (4,)
Series: '' [u32]
```

```
[
    3
    3
    2
    2
]
>>> suits.str.find("e")          # trova posizione match
shape: (4,)
Series: '' [u32]
[
    null
    null
    1
    4
]

>>> # Ricerca e rimpiazzo con regex
>>> # ----------------------------
>>> suits.str.replace("a", "4") # rimpiazzare la prima occorrenza
shape: (4,)
Series: '' [str]
[
    "clubs4aa"
    "Di4mondsaa"
    "he4rts"
    "Sp4des"
]
>>> suits.str.replace_all("a", "4") # rimpiazza tutte le occorrenze
shape: (4,)
Series: '' [str]
[
    "clubs444"
    "Di4monds44"
    "he4rts"
    "Sp4des"
]
>>> suits.str.replace_all("[^a-zA-Z-/:]", "") # pulizia stringa con caratteri ammessi
shape: (4,)
Series: '' [str]
[
    "clubsaaa"
    "Diamondsaa"
    "hearts"
    "Spades"
]

>>> # Ricerca di stringhe esatte senza .str
>>> # -------------------------------------
>>> suits.replace("Diamonds", "foobar") # .replace per parole intere
shape: (4,)
Series: '' [str]
```

```
[
    "clubsaaa"
    "Diamondsaa"
    "hearts"
    "Spades"
]
>>> suits.replace({"Diamonds": "foobar", "Spades": "asdasd"})
shape: (4,)
Series: '' [str]
[
    "clubsaaa"
    "Diamondsaa"
    "hearts"
    "asdasd"
]

>>> # Ricerca ed estrazione mediante regex
>>> # -------------------------------------
>>> import re
>>> x = pl.Series(["primo incontro_PF_02", "primo incontro_PF_03"])
>>> reg = re.compile(r"^([\w ]+?)_(\w+)")
>>> x.map_elements(lambda x: reg.sub(r"\1", x))  # extract_time
shape: (2,)
Series: '' [str]
[
    "primo incontro"
    "primo incontro"
]
>>> x.map_elements(lambda x: reg.sub(r"\2", x))  # extract_pz
shape: (2,)
Series: '' [str]
[
    "PF_02"
    "PF_03"
]
```

11.3.15.7 Estrazione

```
>>> x = pl.Series(["primo incontro_PF_02", "primo incontro_PF_03"])

>>> # da inizio sino a primo _, salva solo prima occorrenza
>>> x.str.extract(r"^(.+?)_", 1)
shape: (2,)
Series: '' [str]
[
    "primo incontro"
    "primo incontro"
]

>>> # estrai le 4 parole
>>> x.str.extract_all(r"([a-zA-Z0-9]+)")
```

```
shape: (2,)
Series: '' [list[str]]
[
    ["primo", "incontro", ... "02"]
    ["primo", "incontro", ... "03"]
]
>>> ( x.str.extract_all(r"([a-zA-Z0-9]+)")
...   .list.to_struct(fields=["one","two","three","four"])
...   .to_frame()
... ).unnest()
shape: (2, 4)
+-------+----------+-------+------+
| one   | two      | three | four |
| ---   | ---      | ---   | ---  |
| str   | str      | str   | str  |
+==================================+
| primo | incontro | PF    | 02   |
| primo | incontro | PF    | 03   |
+-------+----------+-------+------+
```

11.3.16 Date/ore

Vediamo alcune funzionalità utili delle `Series` di date/ore. Qui invece vi è legame col modulo `datetime`.

11.3.16.1 Parsing da stringa

```
>>> # alcune stringhe in vari formati di data/ore
>>> iso = pl.Series(["1969-07-20 20:12:40",
...                  "1969-11-19 06:54:35",
...                  "1971-02-05 09:18:11"])

>>> eu = pl.Series(["20/07/1969 20:12:40",
...                 "19/11/1969 06:54:35",
...                 "05/02/1971 09:18:11"])

>>> iso.str.to_datetime() # iso out of the box
shape: (3,)
Series: '' [datetime[s]]
[
    1969-07-20 20:12:40
    1969-11-19 06:54:35
    1971-02-05 09:18:11
]
>>> eu.str.to_datetime(format="%d/%m/%Y %H:%M:%S") # formato custom EU
shape: (3,)
Series: '' [datetime[s]]
[
    1969-07-20 20:12:40
    1969-11-19 06:54:35
    1971-02-05 09:18:11
```

```
]
```

11.3.16.2 Creazione da componenti

```
>>> df = pl.DataFrame({
...     "year" : [1969, 1969, 1971],
...     "month" : [7, 11, 2],
...     "day" : [20, 19, 5]
... })

>>> df.with_columns(pl.date(pl.col("year"), pl.col("month"), pl.col("day")))
shape: (3, 4)
+------+-------+-----+------------+
| year | month | day | date       |
| ---  | ---   | --- | ---        |
| i64  | i64   | i64 | date       |
+================================+
| 1969 | 7     | 20  | 1969-07-20 |
| 1969 | 11    | 19  | 1969-11-19 |
| 1971 | 2     | 5   | 1971-02-05 |
+------+-------+-----+------------+
```

11.3.16.3 Estrazione componenti

```
>>> isod = iso.str.to_datetime()

>>> # estrazione di anno, mese, giorno
>>> isod.dt.year()
shape: (3,)
Series: '' [i32]
[
    1969
    1969
    1971
]
>>> isod.dt.month()
shape: (3,)
Series: '' [i8]
[
    7
    11
    2
]
>>> isod.dt.day()
shape: (3,)
Series: '' [i8]
[
    20
    19
    5
]
```

```
>>> # estrazione di data/ora
>>> isod.dt.date() # da datetime a date
shape: (3,)
Series: '' [date]
[
    1969-07-20
    1969-11-19
    1971-02-05
]
>>> isod.dt.time() # da datetime a time
shape: (3,)
Series: '' [time]
[
    20:12:40
    06:54:35
    09:18:11
]
```

11.3.16.4 Esportazione a stringa

```
>>> isod.dt.strftime("%d/%m/%Y")
shape: (3,)
Series: '' [str]
[
    "20/07/1969"
    "19/11/1969"
    "05/02/1971"
]
```

11.3.16.5 Intervalli di tempo

Per una differenza di date

```
>>> # anni
>>> (dt.date.today() - isod.dt.date()).dt.total_days() / 365.25
shape: (3,)
Series: '' [f64]
[
    57.075975
    56.741958
    55.52909
]
```

11.3.17 Dati categorici (`Enum` e `Categorical`)

Sono rappresentazioni a-la `factor` di R con interi linkati a label per risparmiare spazio rispetto a stringhe. Ve ne sono due tipi

- gli Enum sono categorici con *label fisse* e ordine esplicitato

  ```
  >>> bears_enum = pl.Series(["Polar", "Panda", None, "Brown", "Polar"],
  ```

```
...                         dtype=pl.Enum(["Polar", "Panda", "Brown"]))
>>> bears_enum == "Polar"
shape: (5,)
Series: '' [bool]
[
    true
    false
    null
    false
    true
]
>>> bears_enum > "Panda"
shape: (5,)
Series: '' [bool]
[
    false
    false
    null
    true
    false
]
```

- i Categorical hanno label che posson cambiare e l'ordinamento è alfabetico/implicito

```
>>> bears_cat = pl.Series(["Polar", "Panda", None, "Brown", "Polar"],
...                       dtype=pl.Categorical)
>>> bears_cat == "Polar"
shape: (5,)
Series: '' [bool]
[
    true
    false
    null
    false
    true
]
>>> bears_cat >= "Panda"
shape: (5,)
Series: '' [bool]
[
    true
    true
    null
    false
    true
]
```

Per efficienza preferire gli `Enum` laddove possibile (si può convertire al `Categorical` se necessario).
Un wrapper

```
>>> # # wrapper comodo che imita factor
>>> # import pylbmisc as lb
>>> # c = lb.dm.to_categorical(
>>> #       [1, 2, 3] * 2,
>>> #       levels = [1,2,3],
>>> #       labels = ["a","b","c"]
>>> # )
```

Il contenuto low-level si puo investigare con

```
>>> c = bears_enum
>>> c.cast(pl.UInt8)          # tipo as.integer
shape: (5,)
Series: '' [u8]
[
    0
    1
    null
    2
    0
]
>>> c.cat.get_categories()    # livelli del factor
shape: (3,)
Series: '' [str]
[
    "Polar"
    "Panda"
    "Brown"
]
```

11.3.18 Liste, array, structs

Una Series può contenere al suo interno dati molteplici

- se di tipologia comune il tipo di dato è `Array` (consigliati, ma il numero di elementi deve essere lo stesso) oppure `List` (il numero di elementi può essere variabile da riga a riga)
- se di tipologia varia abbiamo `Structs`

11.3.18.1 Liste

Il caso classico è uno splitting di stringa che crea una lista

```
>>> # weather data
>>> dfw = pl.DataFrame(
...     {
...         "station": [f"Station {idx}" for idx in range(1, 6)],
...         "temperatures": [
...             "20 5 5 E1 7 13 19 9 6 20",
...             "18 8 16 11 23 E2 8 E2 E2 E2 90 70 40",
...             "19 24 E9 16 6 12 10 22",
...             "E2 E0 15 7 8 10 E1 24 17 13 6",
```

```
...             "14 8 E0 16 22 24 E1",
...         ],
...     }
... ).with_columns(
...     pl.col("temperatures").str.split(" "),
... )
Traceback (most recent call last):
  File "<stdin>", line 3, in <module>
TypeError: range() takes 1 positional argument but 2 were given

>>> sw = pl.Series([
...             "20 5 5 E1 7 13 19 9 6 20",
...             "18 8 16 11 23 E2 8 E2 E2 E2 90 70 40",
...             "19 24 E9 16 6 12 10 22",
...             "E2 E0 15 7 8 10 E1 24 17 13 6",
...             "14 8 E0 16 22 24 E1",
...         ]).str.split(" ")

>>> dfw
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'dfw' is not defined. Did you mean: 'df'?
>>> sw
shape: (5,)
Series: '' [list[str]]
[
    ["20", "5", ... "20"]
    ["18", "8", ... "40"]
    ["19", "24", ... "22"]
    ["E2", "E0", ... "6"]
    ["14", "8", ... "E1"]
]
```

Alternativamente si possono creare con l'accoppiata `pl.concat_list` per le colonne di un df da porre in una lista

```
>>> pl.DataFrame(
...     {
...         "station": [f"Station {idx}" for idx in range(1, 11)],
...         "day_1": [17, 11, 8, 22, 9, 21, 20, 8, 8, 17],
...         "day_2": [15, 11, 10, 8, 7, 14, 18, 21, 15, 13],
...         "day_3": [16, 15, 24, 24, 8, 23, 19, 23, 16, 10],
...     }
... ).with_columns(
...     # create the list of homogeneous data
...     pl.concat_list(pl.all().exclude("station")).alias("all_temps")
... )
Traceback (most recent call last):
  File "<stdin>", line 3, in <module>
TypeError: range() takes 1 positional argument but 2 were given
```

Una volta che abbiamo a che fare con liste, per gestirle utilizziamo l'accessore alle funzioni `.list` che contiene giusto per dire

```
list.agg                list.all                        list.any
list.arg_max            list.arg_min                    list.concat
list.contains           list.count_matches              list.diff
list.drop_nulls         list.eval                       list.explode
list.filter             list.first                      list.gather
list.gather_every       list.get                        list.head
list.item               list.join                       list.last
list.len                list.max                        list.mean
list.median             list.min                        list.n_unique
list.reverse            list.sample                     list.set_difference
list.set_intersection   list.set_symmetric_difference   list.set_union
list.shift              list.slice                      list.sort
list.std                list.sum                        list.tail
list.to_array           list.to_struct                  list.unique
list.var
```

Selezione/slicing Si usano alcune tra

```
>>> # selezione di elementi
>>> sweath.list.head(3)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'sweath' is not defined
>>> sweath.list.tail(3)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'sweath' is not defined
>>> # sweath.list.slice(1, 2)
>>> # sweath.list.last()
>>> # sweath.list.first()

>>> # dataframe
>>> weather.with_columns(
...     pl.col("temperatures").list.head(3).alias("head"),
...     pl.col("temperatures").list.tail(3).alias("tail"),
...     pl.col("temperatures").list.slice(-3, 2).alias("two_next_to_last"),
... )
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'weather' is not defined
```

Elaborazione element-wise Usiamo `eval` specificando l'espressione che usi `pl.element`. `eval` ritorna sempre una lista

```
>>> # Casting
>>> dfw.with_columns(
...     pl.col("temperatures")
...     .list.eval(pl.element().cast(pl.Int64, strict=False))
```

```
... )
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'dfw' is not defined. Did you mean: 'df'?

>>> # trasformare il tipo di dato in intero e poi in booleano contando i
>>> # missing/errori
>>> dfw.with_columns(
...     pl.col("temperatures")
...     .list.eval(pl.element().cast(pl.Int64, strict=False).is_null())
...     .list.sum()
...     .alias("errors"),
... )
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'dfw' is not defined. Did you mean: 'df'?

>>> # senza il casting usare una espressione regolare per controllare che la
>>> # misurazione non inizi con una lettera
>>> dfw.with_columns(
...     pl.col("temperatures")
...     .list.eval(pl.element().str.contains("(?i)[a-z]"))
...     .list.sum()
...     .alias("errors"),
... )
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'dfw' is not defined. Did you mean: 'df'?
```

Aggregazione `agg` possono essere utilizzate per aggregare liste

```
>>> dfw.with_columns(
...     pl.col("temperatures")
...     .list.eval(pl.element().cast(pl.Int64, strict=False))
... )
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'dfw' is not defined. Did you mean: 'df'?
```

Porre in long la lista Si usa explode

```
>>> # explode pone in long
>>> dfweath.explode("temperatures", empty_as_null=False)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'dfweath' is not defined
```

11.3.18.2 Array

Si accede alle funzioni mediante l'accessore `.arr`

11.3.18.3 Structs

Si usano per dati eterogenei

- può essere generata se passiamo una lista di dict ad una Series

```
>>> strs = pl.Series(
...     [
...         {"Movie": "Cars", "Theatre": "NE", "Avg_Rating": 4.5},
...         {"Movie": "Toy Story", "Theatre": "ME", "Avg_Rating": 4.9},
...     ],
... )
>>> strs
shape: (2,)
Series: '' [struct[3]]
[
    {"Cars","NE",4.5}
    {"Toy Story","ME",4.9}
]
```

- Può essere anche generata da elaborazioni

```
>>> # dati originali
>>> df = pl.DataFrame(
...     {
...         "Movie": ["Cars", "IT", "ET", "Cars", "Up", "IT", "Cars", "ET", "Up",
...         "Theatre": ["NE", "ME", "IL", "ND", "NE", "SD", "NE", "IL", "IL", "NE
...         "Avg_Rating": [4.5, 4.4, 4.6, 4.3, 4.8, 4.7, 4.5, 4.9, 4.7, 4.6],
...         "Count": [30, 27, 26, 29, 31, 28, 28, 26, 33, 28],
...     }
... )

>>> counts = df.select(pl.col("Theatre").value_counts(sort=True))
>>> counts
shape: (5, 1)
+-----------+
| Theatre   |
| ---       |
| struct[2] |
+===========+
| {"NE",4}  |
| {"IL",3}  |
| {"ME",1}  |
| {"ND",1}  |
| {"SD",1}  |
+-----------+
```

- può essere generata in un contesto usando `pl.struct` che torna comoda per individuare doppi sulla base di due colonne

```
>>> df.filter(pl.struct("Movie", "Theatre").is_duplicated())
shape: (5, 4)
+-------+---------+------------+-------+
```

```
| Movie | Theatre | Avg_Rating | Count |
| ---   | ---     | ---        | ---   |
| str   | str     | f64        | i64   |
+=======================================+
| Cars  | NE      | 4.5        | 30    |
| ET    | IL      | 4.6        | 26    |
| Cars  | NE      | 4.5        | 28    |
| ET    | IL      | 4.9        | 26    |
| Cars  | NE      | 4.6        | 28    |
+-------+---------+------------+-------+
```

Espandere in un df Si usa `unnest` (per struct facenti parte di un dataframe)

```
>>> counts.unnest()
shape: (5, 2)
+---------+-------+
| Theatre | count |
| ---     | ---   |
| str     | u32   |
+=================+
| NE      | 4     |
| IL      | 3     |
| ME      | 1     |
| ND      | 1     |
| SD      | 1     |
+---------+-------+
```

Nominare/rinominare i campi della struct Si usa `rename_fields`

```
>>> counts.with_columns(
...   pl.col("Theatre").struct.rename_fields(["teatro", "frequenze"])
... )
shape: (5, 1)
+-----------+
| Theatre   |
| ---       |
| struct[2] |
+===========+
| {"NE",4}  |
| {"IL",3}  |
| {"ME",1}  |
| {"ND",1}  |
| {"SD",1}  |
+-----------+
```

Non sembra che sia cambiato nulla ma torna utile sotto per la selezione e se facciamo l'unnest vengono utilizzati i nuovi nomi

Estrarre elementi si usa `field`

```
>>> counts.with_columns(
```

```
...    pl.col("Theatre").struct.rename_fields(["teatro", "frequenze"])
...    .struct.field("frequenze").alias("il_numero")
... )
shape: (5, 2)
+-----------+-----------+
| Theatre   | il_numero |
| ---       | ---       |
| struct[2] | u32       |
+=======================+
| {"NE",4}  | 4         |
| {"IL",3}  | 3         |
| {"ME",1}  | 1         |
| {"ND",1}  | 1         |
| {"SD",1}  | 1         |
+-----------+-----------+
```

Applicargli funzioni che sfruttano gli elementi Se a una struct con nomi applichiamo una funzione mediante `map_elements` all'interno della definizione possiamo programmare in dict style.
Di sotto una applicazione (overkill) giusto per fare vedere la cosa

```
>>> values = pl.DataFrame(
...     {
...         "m": [0, 0, 0, 1, 1, 1, 2],
...         "n": [2, 3, 4, 1, 2, 3, 1],
...     }
... )
```

```
>>> values.with_columns(
...     pl.struct(["m", "n"])
...     .map_elements(lambda s: s["m"] * s["n"], return_dtype=pl.Int64)
...     .alias("ack")
... )
shape: (7, 3)
+-----+-----+-----+
| m   | n   | ack |
| --- | --- | --- |
| i64 | i64 | i64 |
+=================+
| 0   | 2   | 0   |
| 0   | 3   | 0   |
| 0   | 4   | 0   |
| 1   | 1   | 1   |
| 1   | 2   | 2   |
| 1   | 3   | 3   |
| 2   | 1   | 2   |
+-----+-----+-----+
```

11.4 DataFrame

11.4.1 Creazione

Si crea mediante:

`df = pl.DataFrame(data)`

dove `data` possono essere ad esempio un dict (contenente sequences), una lista di `pl.Series` o array numpy) un dataframe `pd.DataFrame`. Si possono specificare le conversioni

- completamente mediante il parametro `schema`
- parzialmente (solo per alcune variabili) usando `schema_overrides`

```
>>> # dict di liste
>>> data = {"state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...         "year": [2000, 2001, 2002, 2001, 2002, 2003],
...         "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
>>> states = pl.DataFrame(data)
>>> states
shape: (6, 3)
+--------+------+-----+
| state  | year | pop |
| ---    | ---  | --- |
| str    | i64  | f64 |
+=====================+
| Ohio   | 2000 | 1.5 |
| Ohio   | 2001 | 1.7 |
| Ohio   | 2002 | 3.6 |
| Nevada | 2001 | 2.4 |
| Nevada | 2002 | 2.9 |
| Nevada | 2003 | 3.2 |
+--------+------+-----+

>>> # per riga (lista di dict) specificando lo schema delle coercizioni
>>> states2 = pl.DataFrame([
...     {"state": "Ohio", "year": 2000, "pop": 1.5},
...     {"state": "Ohio", "year": 2001, "pop": 1.7} # ...
...     ],
... )

>>> # per riga (lista di liste e nomi variabili specificati in schema)
>>> data = [[1, 2, 3], [4, 5, 6]]
>>> df6 = pl.DataFrame(data, schema=["a", "b", "c"], orient="row")
>>> df6
shape: (2, 3)
+-----+-----+-----+
| a   | b   | c   |
| --- | --- | --- |
| i64 | i64 | i64 |
+=================+
```

```
| 1   | 2   | 3   |
| 4   | 5   | 6   |
+-----+-----+-----+

>>> # lista di series
>>> pl.DataFrame([i, d, f])
shape: (4, 3)
+-----------+------------+-------------+
| some_ints | some_dates | some_floats |
| ---       | ---        | ---         |
| i64       | date       | f64         |
+=======================================+
| 1         | 2001-01-01 | 4.0         |
| 2         | null       | 5.0         |
| null      | 2002-01-01 | 6.0         |
| 3         | 2003-01-01 | null        |
+-----------+------------+-------------+
```

11.4.2 Contenuto

```
>>> df = states
>>> df.shape   # dimensioni
(6, 3)
>>> df.height  # nrow
6
>>> df.width   # ncol
3

>>> df.columns # nomi di colonna
['state', 'year', 'pop']
>>> df.dtypes  # tipi di variabile
[String, Int64, Float64]
>>> df.schema  # schema
Schema({'state': String, 'year': Int64, 'pop': Float64})

>>> df.describe()
shape: (9, 4)
+------------+--------+----------+----------+
| statistic  | state  | year     | pop      |
| ---        | ---    | ---      | ---      |
| str        | str    | f64      | f64      |
+=========================================+
| count      | 6      | 6.0      | 6.0      |
| null_count | 0      | 0.0      | 0.0      |
| mean       | null   | 2001.5   | 2.55     |
| std        | null   | 1.048809 | 0.836062 |
| min        | Nevada | 2000.0   | 1.5      |
| 25%        | null   | 2001.0   | 1.7      |
| 50%        | null   | 2002.0   | 2.9      |
| 75%        | null   | 2002.0   | 3.2      |
| max        | Ohio   | 2003.0   | 3.6      |
```

```
+------------+--------+----------+----------+
>>> df.glimpse()  # equivalente di str
Rows: 6
Columns: 3
$ state <str> 'Ohio', 'Ohio', 'Ohio', 'Nevada', 'Nevada', 'Nevada'
$ year  <i64> 2000, 2001, 2002, 2001, 2002, 2003
$ pop   <f64> 1.5, 1.7, 3.6, 2.4, 2.9, 3.2

>>> df.head()  # utile per dataframe piu grossi
shape: (5, 3)
+--------+------+-----+
| state  | year | pop |
| ---    | ---  | --- |
| str    | i64  | f64 |
+======================+
| Ohio   | 2000 | 1.5 |
| Ohio   | 2001 | 1.7 |
| Ohio   | 2002 | 3.6 |
| Nevada | 2001 | 2.4 |
| Nevada | 2002 | 2.9 |
+--------+------+-----+
>>> df.top_k(2, by="pop")
shape: (2, 3)
+--------+------+-----+
| state  | year | pop |
| ---    | ---  | --- |
| str    | i64  | f64 |
+======================+
| Ohio   | 2002 | 3.6 |
| Nevada | 2003 | 3.2 |
+--------+------+-----+
>>> df.bottom_k(2, by="pop")
shape: (2, 3)
+-------+------+-----+
| state | year | pop |
| ---   | ---  | --- |
| str   | i64  | f64 |
+====================+
| Ohio  | 2000 | 1.5 |
| Ohio  | 2001 | 1.7 |
+-------+------+-----+
```

11.4.3 Copia di df e di struttura (`clone`, `clear`)

`clone` crea una copia del dataframe fornito facendo si che eventuali modifiche non intacchino il dataframe di partenza.

```
>>> states_copy = df.clone()
>>> id(states)
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
```

```
TypeError: 'list' object is not callable
>>> id(states_copy) # different
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'list' object is not callable

>>> # otherwise
>>> df = states # no copy performed
>>> id(df)      # same
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'list' object is not callable
>>> id(states)  # same
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: 'list' object is not callable
```

`clear` crea una copia della struttura di un dataframe con n righe vuote

```
>>> states.clear(2)
shape: (2, 3)
+-------+------+------+
| state | year | pop  |
| ---   | ---  | ---  |
| str   | i64  | f64  |
+=====================+
| null  | null | null |
| null  | null | null |
+-------+------+------+
```

11.4.4 Selezione

```
>>> df = pl.DataFrame(
...     {
...         "name": ["Alice Archer", "Ben Brown", "Chloe Cooper", "Daniel Donovan"],
...         "birthdate": [
...             dt.date(1997, 1, 10),
...             dt.date(1985, 2, 15),
...             dt.date(1983, 3, 22),
...             dt.date(1981, 4, 30),
...         ],
...         "weight": [57.9, 72.5, 53.6, 83.1],  # (kg)
...         "height": [1.56, 1.77, 1.65, None],  # (m)
...     }
... )

>>> df2  = pl.DataFrame({
...     "state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...     "year": [2000, 2001, 2002, 2001, 2002, 2003],
...     "pop": [1.5, 1.7, 3.6, 2.4, 2.9, 3.2]}
... )
```

11.4.4.1 Colonne (.select)

La selezione può essere basata su [] o usare select

```
>>> # una colonna
>>> # -----------
>>> df["name"]                  # restituisce una Series
shape: (4,)
Series: 'name' [str]
[
    "Alice Archer"
    "Ben Brown"
    "Chloe Cooper"
    "Daniel Donovan"
]
>>> df.get_column("name")       # come sopra
shape: (4,)
Series: 'name' [str]
[
    "Alice Archer"
    "Ben Brown"
    "Chloe Cooper"
    "Daniel Donovan"
]
>>> df.get_column_index("birthdate") # restituisce l'indice di colonna
1
>>> df.select("name")           # restituisce un DataFrame
shape: (4, 1)
+-----------------+
| name            |
| ---             |
| str             |
+=================+
| Alice Archer    |
| Ben Brown       |
| Chloe Cooper    |
| Daniel Donovan  |
+-----------------+
>>> df.select(                  # restituisce un DataFrame
...     pl.col("name")
... )
shape: (4, 1)
+-----------------+
| name            |
| ---             |
| str             |
+=================+
| Alice Archer    |
| Ben Brown       |
| Chloe Cooper    |
| Daniel Donovan  |
+-----------------+
```

```
>>> # più colonne
>>> # -----------
>>> vars = ["name", "birthdate"]
>>> df[vars]              # dataframe
shape: (4, 2)
+----------------+------------+
| name           | birthdate  |
| ---            | ---        |
| str            | date       |
+============================+
| Alice Archer   | 1997-01-10 |
| Ben Brown      | 1985-02-15 |
| Chloe Cooper   | 1983-03-22 |
| Daniel Donovan | 1981-04-30 |
+----------------+------------+
>>> df.select(vars)
shape: (4, 2)
+----------------+------------+
| name           | birthdate  |
| ---            | ---        |
| str            | date       |
+============================+
| Alice Archer   | 1997-01-10 |
| Ben Brown      | 1985-02-15 |
| Chloe Cooper   | 1983-03-22 |
| Daniel Donovan | 1981-04-30 |
+----------------+------------+
>>> df.select(
...     pl.col(vars)
... )
shape: (4, 2)
+----------------+------------+
| name           | birthdate  |
| ---            | ---        |
| str            | date       |
+============================+
| Alice Archer   | 1997-01-10 |
| Ben Brown      | 1985-02-15 |
| Chloe Cooper   | 1983-03-22 |
| Daniel Donovan | 1981-04-30 |
+----------------+------------+
>>> df.get_columns(vars) # lista di serie
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
TypeError: DataFrame.get_columns() takes 1 positional argument but 2 were given


>>> # selezioni particolari con pl.col
>>> # --------------------------------
>>> df.select(pl.all().exclude("birthdate")) # tutte le colonne eccetto alcune
```

```
shape: (4, 3)
+-----------------+--------+--------+
| name            | weight | height |
| ---             | ---    | ---    |
| str             | f64    | f64    |
+==================================+
| Alice Archer    | 57.9   | 1.56   |
| Ben Brown       | 72.5   | 1.77   |
| Chloe Cooper    | 53.6   | 1.65   |
| Daniel Donovan  | 83.1   | null   |
+-----------------+--------+--------+
>>> df.select(pl.col("^.*t$"))                # regex: variabili che finiscono con t
shape: (4, 2)
+--------+--------+
| weight | height |
| ---    | ---    |
| f64    | f64    |
+=================+
| 57.9   | 1.56   |
| 72.5   | 1.77   |
| 53.6   | 1.65   |
| 83.1   | null   |
+--------+--------+
>>> df.select(pl.col(pl.Date))                # basate su dtype
shape: (4, 1)
+------------+
| birthdate  |
| ---        |
| date       |
+============+
| 1997-01-10 |
| 1985-02-15 |
| 1983-03-22 |
| 1981-04-30 |
+------------+
>>> df.select(                                # mischiare selettori
...     pl.col("name"),
...     pl.col(pl.Date)
... )
shape: (4, 2)
+-----------------+------------+
| name            | birthdate  |
| ---             | ---        |
| str             | date       |
+============================+
| Alice Archer    | 1997-01-10 |
| Ben Brown       | 1985-02-15 |
| Chloe Cooper    | 1983-03-22 |
| Daniel Donovan  | 1981-04-30 |
+-----------------+------------+
```

11.4.4.2 Righe (`.filter`/`.remove`)

Per selezionare righe si usa `filter` con `pl.col`; vengono tenute le righe che danno un risultato booleano `True` (comparazioni che riguardano dati mancanti saranno mancanti e non saranno selezionate, come spesso ragionevole).
Viceversa se si vogliono eliminare le righe `True`, utilizzare `.remove`.
Alcuni esempi con filter

```
>>> df.filter(pl.col("birthdate").dt.year() < 1990)
shape: (3, 4)
+----------------+------------+--------+--------+
| name           | birthdate  | weight | height |
| ---            | ---        | ---    | ---    |
| str            | date       | f64    | f64    |
+=============================================+
| Ben Brown      | 1985-02-15 | 72.5   | 1.77   |
| Chloe Cooper   | 1983-03-22 | 53.6   | 1.65   |
| Daniel Donovan | 1981-04-30 | 83.1   | null   |
+----------------+------------+--------+--------+

>>> # selezione basata su indici: creare un progressivo di riga (chiamato index)
>>> df.with_row_index().filter(pl.col("index") > 2)
shape: (1, 5)
+-------+----------------+------------+--------+--------+
| index | name           | birthdate  | weight | height |
| ---   | ---            | ---        | ---    | ---    |
| u32   | str            | date       | f64    | f64    |
+=================================================+
| 3     | Daniel Donovan | 1981-04-30 | 83.1   | null   |
+-------+----------------+------------+--------+--------+

>>> # Per mettere in and le condizioni di selezione fornire diverse
>>> # righe. Alternativamente usare & ma aiutare con parentesi
>>> df.filter(
...     pl.col("birthdate").dt.year() < 1990,
...     pl.col("height") > 1.7
... )
shape: (1, 4)
+-----------+------------+--------+--------+
| name      | birthdate  | weight | height |
| ---       | ---        | ---    | ---    |
| str       | date       | f64    | f64    |
+=========================================+
| Ben Brown | 1985-02-15 | 72.5   | 1.77   |
+-----------+------------+--------+--------+

>>> df.filter(
...     (pl.col("birthdate").dt.year() < 1990) & (pl.col("height") > 1.7)
... )
shape: (1, 4)
+-----------+------------+--------+--------+
| name      | birthdate  | weight | height |
```

```
| ---         | ---          | ---     | ---     |
| str         | date         | f64     | f64     |
+=========================================+
| Ben Brown | 1985-02-15 | 72.5    | 1.77    |
+-----------+------------+---------+---------+
```

```
>>> # Per mettere in or le condizioni
>>> df.filter(
...     (pl.col("birthdate").dt.year() < 1990) | (pl.col("height") > 1.7)
... )
shape: (3, 4)
+-----------------+------------+---------+---------+
| name            | birthdate  | weight | height |
| ---             | ---        | ---     | ---     |
| str             | date       | f64     | f64     |
+=================================================+
| Ben Brown       | 1985-02-15 | 72.5    | 1.77    |
| Chloe Cooper    | 1983-03-22 | 53.6    | 1.65    |
| Daniel Donovan | 1981-04-30 | 83.1    | null    |
+-----------------+------------+---------+---------+
```

```
>>> # Per negare una condizione usare ~
>>> df.filter(
...     ~ ((pl.col("birthdate").dt.year() < 1990) | (pl.col("height") > 1.7))
... )
shape: (1, 4)
+--------------+------------+---------+---------+
| name         | birthdate  | weight | height |
| ---          | ---        | ---     | ---     |
| str          | date       | f64     | f64     |
+==============================================+
| Alice Archer | 1997-01-10 | 57.9    | 1.56    |
+--------------+------------+---------+---------+
```

11.4.4.3 Righe e colonne

Alternare `select` e `filter`.

11.4.4.4 Singoli elementi (`.item`)

Si usa `item` (equivalente di at/iat di pandas)

```
>>> df
shape: (4, 4)
+-----------------+------------+---------+---------+
| name            | birthdate  | weight | height |
| ---             | ---        | ---     | ---     |
| str             | date       | f64     | f64     |
+=================================================+
| Alice Archer    | 1997-01-10 | 57.9    | 1.56    |
| Ben Brown       | 1985-02-15 | 72.5    | 1.77    |
| Chloe Cooper    | 1983-03-22 | 53.6    | 1.65    |
```

```
| Daniel Donovan | 1981-04-30 | 83.1   | null   |
+----------------+------------+--------+--------+
>>> df.item(1,1)
datetime.date(1985, 2, 15)
>>> df.item(1, "weight")
72.5
```

11.4.5 Inserimento colonna in un punto (.insert_column)

Si fa mediante `insert_column`, specificando indice e `Series` o espressione da inserire

11.4.6 Assegnazione (with_columns)

Si opera sulle colonne con `with_columns` e selezionando con `pl.col` e il tutto funziona similmente ad `assign` di pandas (ad eccezione dell'esecuzione sequenziale):

- si può assegnare (il nome della variabile) all'inizio oppure dare `alias` alla fine (ma nel caso gli alias vanno prima, come da python base)
- se la colonna non esiste verrà creata altrimenti sovrascritta
- le istruzioni non vanno intese come eseguite sequenzialmente
- costanti (soprattutto se si intende stringhe, affinché non vengano confuse con nomi variabili, vanno specificate con `pl.lit`)

```
>>> def change_sign(x):
...     return - x
...
>>> df.with_columns(
...     # creazione di costante
...     pl.lit(1).alias("one"),
...     # sovrascrittura di variabile
...     change_sign(pl.col("weight")).alias("weight"),
...     # le istruzioni NON sono svolte sequenzialmente: sotto weight è quello
...     # corretto
...     (pl.col("weight") / (pl.col("height") ** 2)).alias("bmi"),
...     # esempio di ifelse: ancora essendo non sequenziali le istruzioni il bmi
...     # deve essere ricalcolato, non si può usare quello dell'istruzione
...     # precedente; inoltre "weight" ha ancora il segno corretto
...     fat=(
...         pl.when((pl.col("weight") / (pl.col("height") ** 2)) > 25)
...         .then(pl.lit("yes"))
...         .otherwise(pl.lit("no"))
...     )
... )
shape: (4, 7)
+----------------+------------+--------+--------+-----+-----------+-----+
| name           | birthdate  | weight | height | one | bmi       | fat |
| ---            | ---        | ---    | ---    | --- | ---       | --- |
```

```
| str            | date       | f64    | f64    | i32 | f64       | str |
+=================================================================+
| Alice Archer   | 1997-01-10 | -57.9  | 1.56   | 1   | 23.791913 | no  |
| Ben Brown      | 1985-02-15 | -72.5  | 1.77   | 1   | 23.141498 | no  |
| Chloe Cooper   | 1983-03-22 | -53.6  | 1.65   | 1   | 19.687787 | no  |
| Daniel Donovan | 1981-04-30 | -83.1  | null   | 1   | null      | no  |
+----------------+------------+--------+--------+-----+-----------+-----+
```

Per la valutazione sequenziale ad ora il meglio che ho trovato è

- salvare l'espressione e richiamarla in una medesima `with_columns`, ma evitando di riscriverla per esteso. Non è sequenziale ma almeno non si duplica il codice:

```
>>> bmi = (pl.col("weight") / (pl.col("height") ** 2))

>>> df.with_columns(
...     bmi = bmi,          # bmi.alias("bmi"),
...     fat = bmi > 25,     # (bmi > 25).alias("fat")
... )
shape: (4, 6)
+----------------+------------+--------+--------+-----------+-------+
| name           | birthdate  | weight | height | bmi       | fat   |
| ---            | ---        | ---    | ---    | ---       | ---   |
| str            | date       | f64    | f64    | f64       | bool  |
+=================================================================+
| Alice Archer   | 1997-01-10 | 57.9   | 1.56   | 23.791913 | false |
| Ben Brown      | 1985-02-15 | 72.5   | 1.77   | 23.141498 | false |
| Chloe Cooper   | 1983-03-22 | 53.6   | 1.65   | 19.687787 | false |
| Daniel Donovan | 1981-04-30 | 83.1   | null   | null      | null  |
+----------------+------------+--------+--------+-----------+-------+
```

- porre nella prima chiamata le variabili indipendenti, nella seconda quelle dipendenti

```
>>> df.with_columns(
...     bmi = (pl.col("weight") / (pl.col("height") ** 2))
... ).with_columns(
...     fat = (pl.col("bmi") > 25)
... )
shape: (4, 6)
+----------------+------------+--------+--------+-----------+-------+
| name           | birthdate  | weight | height | bmi       | fat   |
| ---            | ---        | ---    | ---    | ---       | ---   |
| str            | date       | f64    | f64    | f64       | bool  |
+=================================================================+
| Alice Archer   | 1997-01-10 | 57.9   | 1.56   | 23.791913 | false |
| Ben Brown      | 1985-02-15 | 72.5   | 1.77   | 23.141498 | false |
| Chloe Cooper   | 1983-03-22 | 53.6   | 1.65   | 19.687787 | false |
| Daniel Donovan | 1981-04-30 | 83.1   | null   | null      | null  |
+----------------+------------+--------+--------+-----------+-------+
```

Vi è anche un `with_columns_seq` ma non sembra essere la soluzione.

11.4.6.1 Elaborazioni particolari

Aggiungere totali di colonna Per sommare tutte le colonne (per riga) di cui si specifica il nome utilizzare in una `with_columns` l'espressione `pl.sum_horizontal`

11.4.7 Rimozione righe/colonne (`.filter`/`.drop`)

Per le righe utilizzare `filter` similmente a sezione 11.4.4.2; per le colonne utilizzare `drop`

```
>>> df.drop(["weight"])
shape: (4, 3)
+----------------+------------+--------+
| name           | birthdate  | height |
| ---            | ---        | ---    |
| str            | date       | f64    |
+=====================================+
| Alice Archer   | 1997-01-10 | 1.56   |
| Ben Brown      | 1985-02-15 | 1.77   |
| Chloe Cooper   | 1983-03-22 | 1.65   |
| Daniel Donovan | 1981-04-30 | null   |
+----------------+------------+--------+
```

11.4.8 Rinominare colonne

Si usa il metodo `rename`

```
>>> df.rename({"weight": "peso", "height": "altezza"})
shape: (4, 4)
+----------------+------------+------+---------+
| name           | birthdate  | peso | altezza |
| ---            | ---        | ---  | ---     |
| str            | date       | f64  | f64     |
+=============================================+
| Alice Archer   | 1997-01-10 | 57.9 | 1.56    |
| Ben Brown      | 1985-02-15 | 72.5 | 1.77    |
| Chloe Cooper   | 1983-03-22 | 53.6 | 1.65    |
| Daniel Donovan | 1981-04-30 | 83.1 | null    |
+----------------+------------+------+---------+
>>> df.rename(lambda x: f"{x}2")
shape: (4, 4)
+----------------+------------+---------+---------+
| name2          | birthdate2 | weight2 | height2 |
| ---            | ---        | ---     | ---     |
| str            | date       | f64     | f64     |
+=================================================+
| Alice Archer   | 1997-01-10 | 57.9    | 1.56    |
| Ben Brown      | 1985-02-15 | 72.5    | 1.77    |
| Chloe Cooper   | 1983-03-22 | 53.6    | 1.65    |
| Daniel Donovan | 1981-04-30 | 83.1    | null    |
+----------------+------------+---------+---------+
```

11.4.9 Coercizione di tipi (`.cast`)

Possiamo usare `cast`. Se si vuole castare tutto il dataframe ad un unico tipo passarlo direttamente come in `df.cast(pl.String)`; altrimenti specificare il mapping di formato in un `dict` avente come chiave:

- i nomi variabile

```
>>> df = pl.DataFrame({
...         "foo": [1, 2, 3],
...         "bar": [6.0, 7.0, 8.0],
...         "ham": [dt.date(2020, 1, 2), dt.date(2021, 3, 4), dt.date(2022, 5, 6)],
... })

>>> df.cast({"foo": pl.Float32, "bar": pl.UInt8})
shape: (3, 3)
+-----+-----+------------+
| foo | bar | ham        |
| --- | --- | ---        |
| f32 | u8  | date       |
+=========================+
| 1.0 | 6   | 2020-01-02 |
| 2.0 | 7   | 2021-03-04 |
| 3.0 | 8   | 2022-05-06 |
+-----+-----+------------+
```

- il tipo variabile

```
>>> df.cast({pl.Date: pl.Datetime})
shape: (3, 3)
+-----+-----+---------------------+
| foo | bar | ham                 |
| --- | --- | ---                 |
| i64 | f64 | datetime[s]         |
+=================================+
| 1   | 6.0 | 2020-01-02 00:00:00 |
| 2   | 7.0 | 2021-03-04 00:00:00 |
| 3   | 8.0 | 2022-05-06 00:00:00 |
+-----+-----+---------------------+
```

- un selettore che specifica una classe di tipi

```
>>> import polars.selectors as cs
>>> df.cast({cs.numeric(): pl.UInt32, cs.temporal(): pl.String})
shape: (3, 3)
+-----+-----+------------+
| foo | bar | ham        |
| --- | --- | ---        |
| u32 | u32 | str        |
+=========================+
| 1   | 6   | 2020-01-02 |
| 2   | 7   | 2021-03-04 |
| 3   | 8   | 2022-05-06 |
+-----+-----+------------+
```

11.4.10 Applicazione di funzioni

Per applicare una funzione all'intero data.frame (es nel contesto di una cascata di chiamate) utilizzare `pipe`.
Per righe/colonne Si usano le funzioni `map` con UDF (user defined functions) anche se sono molto meno performanti rispetto alla sintassi classica (però in questo modo si possono usare funzioni proprie o di librerie terze).
Sono consigliate le `ufuncs` di numpy e scipy per cercare di evitare il Python schietto.
In caso di missing vi possono essere problemi: approfondire qui

11.4.10.1 All'intero dataframe

Nel contesto di una cascata di chiamate può tornare utile `pipe` che prende in input una funzione (che prende in input un dataframe).

```
>>> df = pl.DataFrame({"b": [1, 2, 3, 4], "a": ["10", "20", "30", "40"]})

>>> # porre in ordine alfabetico le variabili dataset
>>> df.pipe(lambda tdf: tdf.select(sorted(tdf.columns)))
shape: (4, 2)
+-----+-----+
| a   | b   |
| --- | --- |
| str | i64 |
+===========+
| 10  | 1   |
| 20  | 2   |
| 30  | 3   |
| 40  | 4   |
+-----+-----+
```

11.4.10.2 A colonne

Per

- applicare una funzione a ciascun elemento separatamente di una serie si usa `map_elements` come già visto

```
>>> import math

>>> df = pl.DataFrame(
...     {
...         "keys": ["a", "a", "b", "b"],
...         "values": [10, 7, 1, 23],
...     }
... )
>>> def my_log(value):
...     return math.log(value)
...
>>> df.select(pl.col("values").map_elements(my_log, return_dtype=pl.Float64))
```

```
shape: (4, 1)
+----------+
| values   |
| ---      |
| f64      |
+==========+
| 2.302585 |
| 1.94591  |
| 0.0      |
| 3.135494 |
+----------+
```

- applicare una funzione al contenuto intero della serie (es per avere una aggregazione) si usa `map_batches`

```
>>> # togliere la media da una serie
>>> def demean(series):
...     total = 0
...     for value in series:
...         total += value
...     mean = total / len(series)
...     return pl.Series([value - mean for value in series])
...
>>> df.select(pl.col("values").map_batches(demean, return_dtype=pl.Float64))
shape: (4, 1)
+--------+
| values |
| ---    |
| f64    |
+========+
| -0.25  |
| -3.25  |
| -9.25  |
| 12.75  |
+--------+

>>> # effettuare un recoding a una serie
>>> # questa avrebbe bisogno di specificare il tipo specificato?
>>> # df.select(pl.all().map_batches(lambda x: x.replace(NA_recoding)))
```

- `map_columns` direi faccia all'incirca la stessa cosa di `map_batches`

```
# Se la funzione prende in input una serie e restituisce una serie
df.map_columns(df.columns, lambda x: x.replace(NA_recoding))
```

11.4.10.3 A righe

`DataFrame.map_rows`

11.4.11 Ciclo su righe/colonne

Tipicamente non di interesse ma nel caso non si possa esprimere con espressioni polars ...

11.4.11.1 Righe

Si usa:

- `rows`: per ottenere tutte le righe in botta unica (equivalente di `df.to_dict(orient="records")` di pandas)
- `iter_rows`: crea un iteratore sulle righe (che non vengono caricate tutte in memoria) e ritornando una tupla (a meno che `named=True`) per ciascuna riga in sequenza

```
>>> df = pl.DataFrame({'num_legs': [4, 2], 'num_wings': [0, 2]})

>>> # tuple
>>> for row in df.iter_rows():
...     print("first_elem = ", row[0],
...           "second_elem = ", row[1])
...
first_elem =  4 second_elem =  0
first_elem =  2 second_elem =  2
>>> # dict
>>> for row in df.iter_rows(named=True):
...     print("first_named = ", row["num_legs"],
...           "second_named = ", row["num_wings"])
...
first_named =  4 second_named =  0
first_named =  2 second_named =  2
```

11.4.11.2 Colonne

Si può utilizzare

- un ciclo `for` secco restituisce la serie
- un generatore `iter_columns`

```
>>> df = pl.DataFrame({'species': ['bear', 'bear', 'marsupial'],
...                    'population': [1864, 22000, 80000]})

>>> for s in df:
...     print(s)
...
shape: (3,)
Series: 'species' [str]
[
    "bear"
    "bear"
    "marsupial"
]
shape: (3,)
Series: 'population' [i64]
[
    1864
```

```
    22000
    80000
]
>>> for s in df.iter_columns():
...     print(s)
...
shape: (3,)
Series: 'species' [str]
[
    "bear"
    "bear"
    "marsupial"
]
shape: (3,)
Series: 'population' [i64]
[
    1864
    22000
    80000
]
```

11.4.12 Merge (`.join`)

11.4.12.1 Due dataframe

Si usa il metodo `join` sul primo DataFrame:

- bisogna specificare la variabile di merge nel parametro `on` (`left_on` e `right_on` se la chiave non ha lo stesso nome nei due dataframe)
- il tipo di merge in `how`: di default ritorna le righe dove la chiave è presente in entrambi i dataset (*inner join*). `left` è quello che spesso serve
- si può specificare un criterio di validazione (stringa passata a `validate`) che darà errore se non rispettato: es `1:1`, `1:m`, `m:1`.

```
>>> df1 = pl.DataFrame({'key': ['a', 'b', 'b', 'c', 'c', 'c'],
...                     'data': range(6)})
Traceback (most recent call last):
  File "<stdin>", line 2, in <module>
  File "<stdin>", line 2, in range
AttributeError: 'int' object has no attribute 'max'
>>> df2 = pl.DataFrame({'key': ['a', 'b', 'd'],
...                     'values': ['x', 'y', 'z']})
>>> df1
            a         b         c         d         e
0         NaN       NaN       NaN       NaN       NaN
1    0.812095  0.923345  0.276574  0.819755  0.889893
2         NaN       NaN       NaN       NaN       NaN
3    0.629940  0.927407  0.231908  0.799125  0.518165
4         NaN       NaN       NaN       NaN       NaN
..        ...       ...       ...       ...       ...
```

```
995  0.999170  0.880308  0.652464  0.539020  0.901130
996       NaN       NaN       NaN       NaN       NaN
997  0.418027  0.433527  0.377572  0.371292  0.266122
998       NaN       NaN       NaN       NaN       NaN
999  0.156921  0.181935  0.564039  0.279696  0.020414

[1000 rows x 5 columns]
>>> df2
shape: (3, 2)
+-----+--------+
| key | values |
| --- | ---    |
| str | str    |
+==============+
| a   | x      |
| b   | y      |
| d   | z      |
+-----+--------+

>>> # vari tipi di merge
>>> # ------------------
>>> df1.join(df2, on = "key")                # inner di default
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "/home/l/.local/lib/python3.13/site-packages/pandas/core/frame.py", line 12813
    raise ValueError(
        "Joining multiple DataFrames only supported for joining on index"
    )
ValueError: Joining multiple DataFrames only supported for joining on index
>>> df1.join(df2, on = "key", how = 'left')  # tiene dataset di sx, integra con quell
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "/home/l/.local/lib/python3.13/site-packages/pandas/core/frame.py", line 12813
    raise ValueError(
        "Joining multiple DataFrames only supported for joining on index"
    )
ValueError: Joining multiple DataFrames only supported for joining on index
>>> df1.join(df2, on = "key", how = 'right') # tiene dataset di dx, integra con quell
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "/home/l/.local/lib/python3.13/site-packages/pandas/core/frame.py", line 12813
    raise ValueError(
        "Joining multiple DataFrames only supported for joining on index"
    )
ValueError: Joining multiple DataFrames only supported for joining on index
>>> df1.join(df2, on = "key", how = 'full') # tieni tutto
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "/home/l/.local/lib/python3.13/site-packages/pandas/core/frame.py", line 12813
    raise ValueError(
        "Joining multiple DataFrames only supported for joining on index"
```

```
    )
ValueError: Joining multiple DataFrames only supported for joining on index

>>> # validazione
>>> df2.join(df2.rename(lambda x: f"{x}2"), left_on = "key", right_on="key2",
...          how= "left", validate="1:1")
shape: (3, 3)
+-----+--------+---------+
| key | values | values2 |
| --- | ---    | ---     |
| str | str    | str     |
+=======================+
| a   | x      | x       |
| b   | y      | y       |
| d   | z      | z       |
+-----+--------+---------+
```

11.4.12.2 Molteplici dataframe

Per mergiare diversi dataset aventi lo stesso nome di chiave in uno si può usare `reduce`

```
from functools import reduce

def merger(x, y):
    return x.join(y, on=['id', "time"], how = "left")

df = reduce(merger, [demo, lav, sal, bis])
```

11.4.12.3 Merge approssimato (`.join_asof`)

Simile ad un left-join con l'eccezione che si matcha sulla chiave *più vicina*, non necessariamente la chiave esatta. Entrambi i dataframe debbono essere ordinati su `on`. Strategie possibili

- `backward` (default): per ogni riga del dataset di sinistra si prende l'ultima riga di quello di destra su cui la chiave è minore o uguale a quella del dataset di sinistra
- `forward`: maggiore o uguale
- `nearest`: (ultima) riga con la chiave più simile (in eccesso o difetto) a quello di sinistra

Può essere utile per merge approssimato su date

```
>>> from datetime import date

>>> # df sotto già ordinati per data ma male non fa
>>> gdp = pl.DataFrame({
...         "date": pl.date_range(
...             date(2016, 1, 1),
...             date(2020, 1, 1),
```

```
...             "1y",
...             eager=True,
...         ),
...         "gdp": [4164, 4411, 4566, 4696, 4827],
... }).sort("date")

>>> population = pl.DataFrame({
...         "date": [date(2016, 3, 1), date(2018, 8, 1), date(2019, 1, 1)],
...         "population": [82.19, 82.66, 83.12],
... }).sort("date")


>>> population.join_asof(gdp, on="date") # backward: default
shape: (3, 3)
+------------+------------+------+
| date       | population | gdp  |
| ---        | ---        | ---  |
| date       | f64        | i64  |
+================================+
| 2016-03-01 | 82.19      | 4164 |
| 2018-08-01 | 82.66      | 4566 |
| 2019-01-01 | 83.12      | 4696 |
+------------+------------+------+
>>> population.join_asof(gdp, on="date", strategy="forward")
shape: (3, 3)
+------------+------------+------+
| date       | population | gdp  |
| ---        | ---        | ---  |
| date       | f64        | i64  |
+================================+
| 2016-03-01 | 82.19      | 4411 |
| 2018-08-01 | 82.66      | 4696 |
| 2019-01-01 | 83.12      | 4696 |
+------------+------------+------+
>>> population.join_asof(gdp, on="date", strategy="nearest")
shape: (3, 3)
+------------+------------+------+
| date       | population | gdp  |
| ---        | ---        | ---  |
| date       | f64        | i64  |
+================================+
| 2016-03-01 | 82.19      | 4164 |
| 2018-08-01 | 82.66      | 4696 |
| 2019-01-01 | 83.12      | 4696 |
+------------+------------+------+
```

11.4.13 Binding (`pl.concat`)

Sia per binding di riga che di colonna si usa `pl.concat`

```
>>> df1 = pl.DataFrame({'key': ['a', 'b', 'd'], 'data': ['x', 'y', 'z']})
```

```
>>> pl.concat([df1, df1], how="vertical") # rbind
shape: (6, 2)
+-----+------+
| key | data |
| --- | ---  |
| str | str  |
+=============+
| a   | x    |
| b   | y    |
| d   | z    |
| a   | x    |
| b   | y    |
| d   | z    |
+-----+------+
>>> pl.concat([df1, df1.rename(lambda x: f"{x}2")],
...           how="horizontal") # cbind (ha bisogno di renaming)
shape: (3, 4)
+-----+------+------+-------+
| key | data | key2 | data2 |
| --- | ---  | ---  | ---   |
| str | str  | str  | str   |
+============================+
| a   | x    | a    | x     |
| b   | y    | b    | y     |
| d   | z    | d    | z     |
+-----+------+------+-------+
```

11.4.14 Reshape

11.4.14.1 Porre in long (`.unpivot`)

Se abbiamo un dataset in formato wide si pone in long con il metodo `.unpivot`. Si può

- specificare un sottoinsieme di variabili da porre in long mediante `on`
- specificare con `variable_name` nome al posto di `variable` nel dataframe creato e `value_name` per specificare il nome della variabile al posto di `value`

```
>>> df = pl.DataFrame({"key": ["foo", "bar", "baz"],
...                    "x_bl": [1, 2, 3],
...                    "x_t0": [4, 5, 6],
...                    "x_t1": [7, 8, 9]}
... )
```

```
>>> df
shape: (3, 4)
+-----+------+------+------+
| key | x_bl | x_t0 | x_t1 |
| --- | ---  | ---  | ---  |
```

```
| str | i64  | i64  | i64  |
+=========================+
| foo | 1    | 4    | 7    |
| bar | 2    | 5    | 8    |
| baz | 3    | 6    | 9    |
+-----+------+------+------+
>>> df.unpivot(index = 'key')  # poni in long tutto
shape: (9, 3)
+-----+----------+-------+
| key | variable | value |
| --- | ---      | ---   |
| str | str      | i64   |
+========================+
| foo | x_bl     | 1     |
| bar | x_bl     | 2     |
| baz | x_bl     | 3     |
| foo | x_t0     | 4     |
| bar | x_t0     | 5     |
| baz | x_t0     | 6     |
| foo | x_t1     | 7     |
| bar | x_t1     | 8     |
| baz | x_t1     | 9     |
+-----+----------+-------+
>>> df.unpivot(index = 'key', on = ["x_bl", "x_t0"]) # in long una selezione
shape: (6, 3)
+-----+----------+-------+
| key | variable | value |
| --- | ---      | ---   |
| str | str      | i64   |
+========================+
| foo | x_bl     | 1     |
| bar | x_bl     | 2     |
| baz | x_bl     | 3     |
| foo | x_t0     | 4     |
| bar | x_t0     | 5     |
| baz | x_t0     | 6     |
+-----+----------+-------+
```

11.4.14.2 Porre in wide (.pivot)

Un dataset in formato long con colonne, id, tempo e variabili assortite può essere posto in formato wide mediante il metodo `pivot`.

```
>>> df = pl.DataFrame({'idpz': ['one', 'one', 'one', 'two', 'two'],
...                    'time': ["bl", "t1", "t2", "bl", "t1"],
...                    'x': range(1,6),
...                    'y': ['x', 'y', 'z', 'q', 'w'],
...                    'z': range(7, 12),
... })
Traceback (most recent call last):
  File "<stdin>", line 3, in <module>
```

```
TypeError: range() takes 1 positional argument but 2 were given
>>> df
shape: (3, 4)
+-----+------+------+------+
| key | x_bl | x_t0 | x_t1 |
| --- | ---  | ---  | ---  |
| str | i64  | i64  | i64  |
+==========================+
| foo | 1    | 4    | 7    |
| bar | 2    | 5    | 8    |
| baz | 3    | 6    | 9    |
+-----+------+------+------+

>>> df.pivot(index="idpz", on="time", values = ["x", "y"])
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "/home/l/.local/lib/python3.13/site-packages/polars/_utils/deprecation.py", line 128, in
    return function(*args, **kwargs)
  File "/home/l/.local/lib/python3.13/site-packages/polars/dataframe/frame.py", line 9750, in p
    cols = self.select(on).unique(maintain_order=True)
           ~~~~~~~~~~~~~~~~
  File "/home/l/.local/lib/python3.13/site-packages/polars/dataframe/frame.py", line 10484, in
    .collect(optimizations=QueryOptFlags._eager())
     ~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~
  File "/home/l/.local/lib/python3.13/site-packages/polars/_utils/deprecation.py", line 97, in
    return function(*args, **kwargs)
  File "/home/l/.local/lib/python3.13/site-packages/polars/lazyframe/opt_flags.py", line 344, i
    return function(*args, **kwargs)
  File "/home/l/.local/lib/python3.13/site-packages/polars/lazyframe/frame.py", line 2630, in c
    return wrap_df(ldf.collect(engine, callback))
                   ~~~~~~~~~~~~~~~~~~~~~~~~~~~~
polars.exceptions.ColumnNotFoundError: unable to find column "time"; valid columns: ["key", "x_
```

11.4.15 Trasporre (.transpose)

Eventualmente selezionare le colonne da trasporre mediante `column_names`,

```
>>> df = pl.DataFrame({"a": [1, 2, 3], "b": [4, 5, 6], "c": [7, 8, 9]})
>>> df
shape: (3, 3)
+-----+-----+-----+
| a   | b   | c   |
| --- | --- | --- |
| i64 | i64 | i64 |
+=================+
| 1   | 4   | 7   |
| 2   | 5   | 8   |
| 3   | 6   | 9   |
+-----+-----+-----+
>>> df.transpose(include_header=True,
...              header_name="variabile",
```

```
...                column_names=[f"row_{x}"for x in range(3)])
Traceback (most recent call last):
  File "<stdin>", line 3, in <module>
  File "<stdin>", line 2, in range
AttributeError: 'int' object has no attribute 'max'
```

11.4.16 Test di appartenenza (in)

in applicato ad un DataFrame testa la presenza di una colonna avente un determinato nome

```
>>> df = pl.DataFrame({"a": [1, 2], "b": list("xz"), "c": [2,3]})

>>> "a" in df
True
>>> "weight" in df
False
```

11.4.17 Dati mancanti

```
>>> df = pl.DataFrame({"a": [1., None, 3.],
...                    "b":[1., None, None],
...                    "c":[None, None, None],
...                    "d":[None, None, 3.]})
>>> df
shape: (3, 4)
+------+------+------+------+
| a    | b    | c    | d    |
| ---  | ---  | ---  | ---  |
| f64  | f64  | null | f64  |
+============================+
| 1.0  | 1.0  | null | null |
| null | null | null | null |
| 3.0  | null | null | 3.0  |
+------+------+------+------+
```

11.4.17.1 Identificazione

```
>>> df.null_count() # numero mancanti
shape: (1, 4)
+-----+-----+-----+-----+
| a   | b   | c   | d   |
| --- | --- | --- | --- |
| u32 | u32 | u32 | u32 |
+=======================+
| 1   | 2   | 3   | 2   |
+-----+-----+-----+-----+
>>> df.count()      # numero non mancanti
shape: (1, 4)
+-----+-----+-----+-----+
| a   | b   | c   | d   |
```

```
| --- | --- | --- | --- |
| u32 | u32 | u32 | u32 |
+=======================+
| 2   | 1   | 0   | 1   |
+-----+-----+-----+-----+
```

11.4.17.2 Rimozione

`drop_nulls` è orientato alle righe ed elimina i casi che hanno almeno una variabile null, o che hanno almeno una variabile del subset specificato null

```
>>> df.drop_nulls()       # righe con anche un solo NA
shape: (0, 4)
+-----+-----+------+-----+
| a   | b   | c    | d   |
| --- | --- | ---  | --- |
| f64 | f64 | null | f64 |
+=========================+
+-----+-----+------+-----+
>>> df.drop_nulls(["d"])  # selezione righe senza missing nelle colonne specificate
shape: (1, 4)
+-----+------+------+-----+
| a   | b    | c    | d   |
| --- | ---  | ---  | --- |
| f64 | f64  | null | f64 |
+=========================+
| 3.0 | null | null | 3.0 |
+-----+------+------+-----+

>>> # rimozione righe tutte NA
>>> df.filter(~pl.all_horizontal([pl.col(v).is_null() for v in df.columns]))
shape: (2, 4)
+-----+------+------+------+
| a   | b    | c    | d    |
| --- | ---  | ---  | ---  |
| f64 | f64  | null | f64  |
+===========================+
| 1.0 | 1.0  | null | null |
| 3.0 | null | null | 3.0  |
+-----+------+------+------+
```

Per eliminare le colonne completamente null selezionare in base a dtype

```
>>> df.select(
...   pl.all().exclude(pl.Null())
... )
shape: (3, 3)
+------+------+------+
| a    | b    | d    |
| ---  | ---  | ---  |
| f64  | f64  | f64  |
+=====================+
```

```
| 1.0  | 1.0  | null |
| null | null | null |
| 3.0  | null | 3.0  |
+------+------+------+
```

11.4.17.3 Imputazione

Per l'imputazione dei dati mancanti si usa a livello di dataframe `fill_null`

```
>>> df
shape: (3, 4)
+------+------+------+------+
| a    | b    | c    | d    |
| ---  | ---  | ---  | ---  |
| f64  | f64  | null | f64  |
+============================+
| 1.0  | 1.0  | null | null |
| null | null | null | null |
| 3.0  | null | null | 3.0  |
+------+------+------+------+
>>> df.fill_null(99)                  # un valore comune
shape: (3, 4)
+------+------+-----+------+
| a    | b    | c   | d    |
| ---  | ---  | --- | ---  |
| f64  | f64  | i32 | f64  |
+=========================+
| 1.0  | 1.0  | 99  | 99.0 |
| 99.0 | 99.0 | 99  | 99.0 |
| 3.0  | 99.0 | 99  | 3.0  |
+------+------+-----+------+
>>> df.fill_null(strategy="forward") # locf verticale
shape: (3, 4)
+-----+-----+------+------+
| a   | b   | c    | d    |
| --- | --- | ---  | ---  |
| f64 | f64 | null | f64  |
+=========================+
| 1.0 | 1.0 | null | null |
| 1.0 | 1.0 | null | null |
| 3.0 | 1.0 | null | 3.0  |
+-----+-----+------+------+
>>> df.transpose().fill_null(strategy="forward").transpose(column_names=list("abcd"))
shape: (3, 4)
+------+------+------+------+
| a    | b    | c    | d    |
| ---  | ---  | ---  | ---  |
| f64  | f64  | f64  | f64  |
+============================+
| 1.0  | 1.0  | 1.0  | 1.0  |
| null | null | null | null |
```

```
| 3.0  | 3.0  | 3.0  | 3.0  |
+------+------+------+------+
```

o `interpolate` rimpiazza i mancanti con interpolazioni lineari

```
>>> df.interpolate()
shape: (3, 4)
+-----+------+------+------+
| a   | b    | c    | d    |
| --- | ---  | ---  | ---  |
| f64 | f64  | null | f64  |
+==========================+
| 1.0 | 1.0  | null | null |
| 2.0 | null | null | null |
| 3.0 | null | null | 3.0  |
+-----+------+------+------+
```

11.4.18 Duplicati

```
>>> df = pl.DataFrame({"k1": ["one", "two"] * 3 + ["two"],
...                    "k2": [1, 1, 2, 3, 3, 4, 4]})
>>> df
shape: (7, 2)
+-----+-----+
| k1  | k2  |
| --- | --- |
| str | i64 |
+===========+
| one | 1   |
| two | 1   |
| one | 2   |
| two | 3   |
| one | 3   |
| two | 4   |
| two | 4   |
+-----+-----+
```

11.4.18.1 Identificazione (`.duplicated`)

`duplicated` ritorna un vettore di booleani per indicare se una riga è duplicata. Occhio che marchia anche alla prima occorrenza

```
>>> df.is_duplicated()            # ricerca complessiva
shape: (7,)
Series: '' [bool]
[
    false
    false
    false
    false
    false
    true
```

```
    true
]
>>> df.filter(df.is_duplicated()) # visualizzazione
shape: (2, 2)
+-----+-----+
| k1  | k2  |
| --- | --- |
| str | i64 |
+===========+
| two | 4   |
| two | 4   |
+-----+-----+
```

11.4.18.2 Rimozione (`.unique`)

Utilizzare `.unique` eventualmente specificando

- `maintain_order=True` per evitare che sia cambiato rispetto alla sorgente
- `keep` per la scelta di quale riga (es prima/ultima) nel caso di doppi

```
>>> df.unique()          # tutto il dataset
shape: (6, 2)
+-----+-----+
| k1  | k2  |
| --- | --- |
| str | i64 |
+===========+
| two | 1   |
| one | 3   |
| one | 1   |
| two | 4   |
| two | 3   |
| one | 2   |
+-----+-----+
>>> df.unique(["k2"])    # unique basato solo su alcune colonne
shape: (4, 2)
+-----+-----+
| k1  | k2  |
| --- | --- |
| str | i64 |
+===========+
| two | 4   |
| one | 1   |
| two | 3   |
| one | 2   |
+-----+-----+
```

11.4.19 Sorting

Si usa: `sort_values` per ordinare sulla base di valori di colonna

```
>>> rng = np.random.default_rng(23)
>>> df = pl.DataFrame({'g': ["x", "y", "x", "y"],
...                    'y' : rng.standard_normal((4)),
...                    'z' : rng.standard_normal((4))})

>>> df.sort('y')
shape: (4, 3)
+-----+-----------+----------+
| g   | y         | z        |
| --- | ---       | ---      |
| str | f64       | f64      |
+============================+
| y   | -2.318936 | 0.605966 |
| x   | -0.05799  | 0.909921 |
| y   | 0.217601  | -2.12628 |
| x   | 0.553261  | 0.431494 |
+-----+-----------+----------+
>>> df.sort(['g', 'y'])
shape: (4, 3)
+-----+-----------+----------+
| g   | y         | z        |
| --- | ---       | ---      |
| str | f64       | f64      |
+============================+
| x   | -0.05799  | 0.909921 |
| x   | 0.553261  | 0.431494 |
| y   | -2.318936 | 0.605966 |
| y   | 0.217601  | -2.12628 |
+-----+-----------+----------+
>>> df.sort(['g', 'y'], descending = [False, True])
shape: (4, 3)
+-----+-----------+----------+
| g   | y         | z        |
| --- | ---       | ---      |
| str | f64       | f64      |
+============================+
| x   | 0.553261  | 0.431494 |
| x   | -0.05799  | 0.909921 |
| y   | 0.217601  | -2.12628 |
| y   | -2.318936 | 0.605966 |
+-----+-----------+----------+
```

11.4.20 Id univoco di riga

Utilizzare `hash_rows` (versioni di polars differenti possono condurre a risultati differenti)

```
>>> df = pl.DataFrame(
...     {
...         "foo": [1, None, 3, 4],
...         "ham": ["a", "b", None, "d"],
```

```
...     }
... )
>>> df.hash_rows(seed=42)
shape: (4,)
Series: '' [u64]
[
    10812957550152927 88
    16846555029793948966
    7550900513512627554
    9298298639392481527
]
```

11.4.21 Windows functions

Applicano funzioni separatamente a parti del dataset; `group_prog_id` dovrebbe essere un esempio. Sono ideali quando vogliamo effettuare operazioni per gruppo che viene selezionata mediante `.over` (che accetta un numero arbitrario di espressioni per creare i sottogruppi)

```
>>> group_df = (
...     pl.DataFrame({'group' : ['one', 'two'] * 5, 'data':rng.random(10)})
...     .sort(["group", "data"])
... )
>>> group_df
shape: (10, 2)
+-------+----------+
| group | data     |
| ---   | ---      |
| str   | f64      |
+==================+
| one   | 0.063854 |
| one   | 0.301453 |
| one   | 0.415222 |
| one   | 0.540298 |
| one   | 0.716585 |
| two   | 0.349148 |
| two   | 0.389077 |
| two   | 0.454666 |
| two   | 0.4707   |
| two   | 0.68359  |
+-------+----------+

>>> group_df.select(
...     pl.all(),
...     pl.col("data").rank().over("group").alias("group_rank")
... )
shape: (10, 3)
+-------+----------+------------+
| group | data     | group_rank |
| ---   | ---      | ---        |
| str   | f64      | f64        |
```

```
+==============================+
| one   | 0.063854 | 1.0       |
| one   | 0.301453 | 2.0       |
| one   | 0.415222 | 3.0       |
| one   | 0.540298 | 4.0       |
| one   | 0.716585 | 5.0       |
| two   | 0.349148 | 1.0       |
| two   | 0.389077 | 2.0       |
| two   | 0.454666 | 3.0       |
| two   | 0.4707   | 4.0       |
| two   | 0.68359  | 5.0       |
+-------+----------+-----------+
```

Il parametro `mapping_strategy` di `over` gestisce come i risultati delle espressioni nei gruppi sono mappate alle righe del dataframe di origine:

- di default è `group_to_rows`: il risultato dell'espressione dovrebbe essere della stessa lunghezza del gruppo di origine e sono mappate direttamente ai rispettivi elementi. Se invece il risultato è uno scalare viene mappato a tutti i membri del gruppo. Sopra un esempio del primo caso, vediamo uno del secondo

  ```
  group_df.select(
      pl.all(),
      pl.col("data").mean().over("group").alias("group_mean")
  )
  ```

- `join`: aggrega il risultato del sottogruppo in una lista e la riporta per ciascun membro del sottogruppo

  ```
  group_df.select(
      pl.all(),
      pl.col("data").sort().over("group", mapping_strategy="join").alias("sorted_values")
  )
  ```

11.4.22 folds (elaborazioni orizzontali)

Servono per creare aggregazioni custom a livello di riga se le varie funzioni `sum_horizontal`, `mean_horizontal` etc non sono abbastanza. Si specificano con `pl.fold` che prende come parametro

- `acc`: valore iniziale (es in una somma tipicamente 0)
- `function`: funzione che prende in input *due* parametri da applicare, per riga, ad ogni elemento con il risultato delle applicazioni precedenti
- `exprs`: espressioni su cui accumulare (tipicamente selezione delle colonne con `pl.col`)

```
df = pl.DataFrame(
    {
        "label": ["foo", "bar", "spam"],
        "a": [1, 2, 3],
```

```
        "b": [10, 20, 30],
    }
)

import operator
df.select(
    # equivalente di pl.sum_horizontal(pl.col("a", "b"))
    pl.fold(
        acc=pl.lit(0),
        function=operator.add,
        exprs=pl.col("a", "b"),
    ).alias("sum_fold"),
)
```

Applicazioni su trasformazioni booleane del dataset permettono di filtrare: nel seguito

- si trasformano tutte le colonne in valori booleani mediante l'espressione
- si applica la funzione che pone in and i due valori, facendo si che si selezionino le righe dove tutti gli elementi siano maggiori di 1

```
df = pl.DataFrame(
    {
        "a": [1, 2, 3],
        "b": [0, 1, 2],
    }
)

df.filter(
    pl.fold(
        acc=pl.lit(True),
        function=lambda acc, x: acc & x,
        exprs=pl.all() > 1,
    )
)
```

11.5 Descrittive

```
>>> import numpy as np
>>> import polars as pl

>>> # dataset di prova
>>> rng = np.random.default_rng(123)
>>> df2 = pl.DataFrame({
...     'name': ['Luca', 'Silvio', 'Luisa', 'Andrea', 'Giovanni'],
...     'age' : [21, 22, 23, 24, 25],
...     'income' : np.arange(5),
...     'group' : list("aaabb")
... })
>>> df3 = pl.DataFrame({"x": ["a", "a", "a", "a", "a", "b", "b"],
```

Metodo	Descrizione
`count`	numero di dati non mancanti
`value_counts`	frequenze
`describe`	set di statistiche descrittive
`sum`, `product`	somma/prodotto dei valori
`cum_sum`, `cum_min`, `cum_max`	cumulate varie
`diff`, `pct_change`	differenze prime e variazione percentuale
`min`, `max`	minimo e massimo
`mean`	media
`median`	mediana
`quantile`	quantili
`var`, `std`	varianza/stddev campionaria
`skew`, `kurtosis`	skewness/kurtosis campionarie
`arg_min`, `arg_max`	posizione (intera) di minimo/massimo

Tabella 11.1: Metodi per analisi descrittiva

```
...                     "y": ["1", "2", "2", "2", "2", "1", "2"],
...                     "g": ["trt", "ctrl", "trt", "ctrl", "trt", "ctrl", "trt"]})

>>> categ_df = pl.DataFrame({"x": ["a", "a", "a", "a", None, "b", "b"],
...                          "y": ["1", "2", "1", "2", "2", "1", "2"]})
>>> group_df = pl.DataFrame({'key1' : list('xyyzzzwwww'),
...                          'key2' : ['one', 'two'] * 5,
...                          'data1' : rng.random(10),
...                          'data2' : rng.random(10)})

>>> strata_df = pl.DataFrame({"x": np.random.randn(7),
...                           "y": np.random.randn(7),
...                           "z": np.random.randn(7),
...                           "g": ["trt", "ctrl", "trt", "ctrl", "trt", "ctrl", "trt"]})
```

11.5.1 Univariate

Per le statistiche descrittive utilizzando `pl.Series`/`pl.DataFrame` consultare le funzioni riportate in tabella 11.1.

```
>>> # categoriche (frequenze)
>>> categ_df["x"].value_counts()
shape: (3, 2)
+------+-------+
| x    | count |
| ---  | ---   |
| str  | u32   |
+==============+
| b    | 2     |
| a    | 4     |
| null | 1     |
+------+-------+
```

```
>>> # quantitative (count = non missing)
>>> df2.describe()
shape: (9, 5)
+------------+--------+----------+----------+-------+
| statistic  | name   | age      | income   | group |
| ---        | ---    | ---      | ---      | ---   |
| str        | str    | f64      | f64      | str   |
+=================================================+
| count      | 5      | 5.0      | 5.0      | 5     |
| null_count | 0      | 0.0      | 0.0      | 0     |
| mean       | null   | 23.0     | 2.0      | null  |
| std        | null   | 1.581139 | 1.581139 | null  |
| min        | Andrea | 21.0     | 0.0      | a     |
| 25%        | null   | 22.0     | 1.0      | null  |
| 50%        | null   | 23.0     | 2.0      | null  |
| 75%        | null   | 24.0     | 3.0      | null  |
| max        | Silvio | 25.0     | 4.0      | b     |
+------------+--------+----------+----------+-------+
```

11.5.2 Bivariate

11.5.2.1 Tabelle di contingenza

Sono una speciale tipo di tabella pivot dove si applica il conteggio degli elementi in ciascun gruppo

```
>>> (
...   categ_df
...   .pivot(on='x',index='y',values='x',aggregate_function='len',sort_columns=True)
...   .fill_null(0).sort('y')
... )
shape: (2, 4)
+-----+------+-----+-----+
| y   | null | a   | b   |
| --- | ---  | --- | --- |
| str | u32  | u32 | u32 |
+=======================+
| 1   | 0    | 2   | 1   |
| 2   | 1    | 2   | 1   |
+-----+------+-----+-----+
```

11.5.2.2 Covarianza e correlazione

I metodi `cov` e `corr` permettono di ottenere la covarianza e correlazione per gli elementi di un dataframe.

```
>>> df1 = strata_df[["x", "y", "z"]]
>>> df1.corr()
shape: (3, 3)
+-----------+-----------+----------+
| x         | y         | z        |
| ---       | ---       | ---      |
```

```
| f64       | f64       | f64      |
+=================================+
| 1.0       | -0.343481 | 0.487291 |
| -0.343481 | 1.0       | 0.066014 |
| 0.487291  | 0.066014  | 1.0      |
+-----------+-----------+----------+
```

11.5.2.3 Tabelle pivot

Sono tabelle bivariate con statistiche stratificate per gruppi formati da righe e colonne (per intenderci il `tapply` con doppio indice di R).
Possono essere prodotte col metodo `pivot_table` dei `DataFrame` ed eventuali funzioni custom debbono fare utilizzo di `pl.element`

```
>>> group_df
shape: (10, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+====================================+
| x    | one  | 0.682352 | 0.51297  |
| y    | two  | 0.053821 | 0.244965 |
| y    | one  | 0.22036  | 0.824242 |
| z    | two  | 0.184372 | 0.213763 |
| z    | one  | 0.175906 | 0.741467 |
| z    | two  | 0.812095 | 0.62994  |
| w    | one  | 0.923345 | 0.927407 |
| w    | two  | 0.276574 | 0.231908 |
| w    | one  | 0.819755 | 0.799125 |
| w    | two  | 0.889893 | 0.518165 |
+------+------+----------+----------+
>>> group_df.pivot(on =   "key1",      # cosa porre in colonna
...                index = "key2",      # cosa porre in riga
...                values =  "data1",     # dati per sintesi
...                aggregate_function = "median")
shape: (2, 5)
+------+----------+----------+----------+----------+
| key2 | x        | y        | z        | w        |
| ---  | ---      | ---      | ---      | ---      |
| str  | f64      | f64      | f64      | f64      |
+=================================================+
| one  | 0.682352 | 0.22036  | 0.175906 | 0.87155  |
| two  | null     | 0.053821 | 0.498233 | 0.583234 |
+------+----------+----------+----------+----------+

>>> # utilizzo di funzioni custom: min per controllo
>>> group_df.pivot(on = "key1",      # cosa porre in riga
...                index = "key2",      # cosa porre in colonna
...                values =  "data1",     # dati per sintesi
...                aggregate_function = "min")
```

```
shape: (2, 5)
+------+----------+----------+----------+----------+
| key2 | x        | y        | z        | w        |
| ---  | ---      | ---      | ---      | ---      |
| str  | f64      | f64      | f64      | f64      |
+=================================================+
| one  | 0.682352 | 0.22036  | 0.175906 | 0.819755 |
| two  | null     | 0.053821 | 0.184372 | 0.276574 |
+------+----------+----------+----------+----------+
>>> # replicato con pl.element
>>> group_df.pivot(on = "key1",      # cosa porre in riga
...                index = "key2",      # cosa porre in colonna
...                values =  "data1",     # dati per sintesi
...                aggregate_function = pl.element().min())
shape: (2, 5)
+------+----------+----------+----------+----------+
| key2 | x        | y        | z        | w        |
| ---  | ---      | ---      | ---      | ---      |
| str  | f64      | f64      | f64      | f64      |
+=================================================+
| one  | 0.682352 | 0.22036  | 0.175906 | 0.819755 |
| two  | null     | 0.053821 | 0.184372 | 0.276574 |
+------+----------+----------+----------+----------+
```

11.5.2.4 Stratificate

Si applica split-apply-combine ossia:

1. si splitta il `DataFrame` mediante il metodo `groupby`: a questo si può passare alternativamente stringhe (interpretate come nomi variabili) o espressioni. Questo ritorna un oggetto `GroupBy` è un iterabile sui "chunk" di dati (quindi funziona bene con i `for`) e fornisce un set di metodi già pronti da applicare;
2. si effettua l'elaborazione sui chunk di dati, alternativamente
   - l'oggetto `GroupBy` ha un set di metodi builtin già disponibili da applicare a tutti i chunk di dati.
   - si possono applicare definire funzioni custom (mediante `.agg`)
   - si possono applicare funzioni a tutto il sotto-dataframe e ritornare i risultati bindati (mediante `map_groups`)
3. viene riassemblato il tutto: il tipo di oggetto ritornato dipende dalle elaborazioni eseguite.

Splitting Vediamo vari metodi di splitting

```
>>> group_df
shape: (10, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
```

```
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| x    | one  | 0.682352 | 0.51297  |
| y    | two  | 0.053821 | 0.244965 |
| y    | one  | 0.22036  | 0.824242 |
| z    | two  | 0.184372 | 0.213763 |
| z    | one  | 0.175906 | 0.741467 |
| z    | two  | 0.812095 | 0.62994  |
| w    | one  | 0.923345 | 0.927407 |
| w    | two  | 0.276574 | 0.231908 |
| w    | one  | 0.819755 | 0.799125 |
| w    | two  | 0.889893 | 0.518165 |
+------+------+----------+----------+
```

```
>>> # Singola variabile
>>> df_spl = group_df.group_by('key2')
>>> df_spl.mean() # se no essendoci key2 da errore
shape: (2, 4)
+------+------+----------+----------+
| key2 | key1 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| one  | null | 0.564343 | 0.761042 |
| two  | null | 0.443351 | 0.367748 |
+------+------+----------+----------+
```

```
>>> # Due variabili
>>> df_spl = group_df.group_by(['key1', 'key2'])
>>> df_spl.mean()
shape: (7, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| z    | two  | 0.498233 | 0.421852 |
| w    | one  | 0.87155  | 0.863266 |
| y    | one  | 0.22036  | 0.824242 |
| z    | one  | 0.175906 | 0.741467 |
| w    | two  | 0.583234 | 0.375037 |
| y    | two  | 0.053821 | 0.244965 |
| x    | one  | 0.682352 | 0.51297  |
+------+------+----------+----------+
```

```
>>> # Espressione
>>> df_spl = group_df.group_by(
...     'key1',
...     (pl.col("data1") > 0.5).alias("data1_geq_05")
... )
```

```
>>> df_spl.mean()
shape: (6, 5)
+------+--------------+------+----------+----------+
| key1 | data1_geq_05 | key2 | data1    | data2    |
| ---  | ---          | ---  | ---      | ---      |
| str  | bool         | str  | f64      | f64      |
+=================================================+
| w    | false        | null | 0.276574 | 0.231908 |
| z    | false        | null | 0.180139 | 0.477615 |
| y    | false        | null | 0.13709  | 0.534603 |
| w    | true         | null | 0.877664 | 0.748232 |
| z    | true         | null | 0.812095 | 0.62994  |
| x    | true         | null | 0.682352 | 0.51297  |
+------+--------------+------+----------+----------+
```

Se si vuole che nello splitting non venga modificato l'ordinamento dei dati specificare `maintain_order=True`.
Oltre a funzioni di aggregazione ovvie come `max`, `mean`, `median`, `min`, `n_unique`, `quantile`, `sum`, `len` (contano frequenze/lunghezza dei sottogruppi tipo table) altre funzioni di interesse

- `all` crea una series dei dati in ogni gruppo
- `first`/`last`, `head`/`tail` selezionano porzioni specifiche (per queste dare `maintain_order=True` in groupby può essere voluto)
- `agg`: effettua aggregazioni custom (funzioni/variabili)
- `map_groups`: applica funzioni custom definite dall'utente (UDF)
- `having`: seleziona i gruppi che presentano date caratteristiche post splitting

Applicare funzioni di aggregazione custom `.agg` È possibile applicare funzioni che sintetizzano series dati in un unico valore passandole al metodo `agg` di un oggetto `GroupBy`:

```
>>> # a custom function taking a series and returning a number
>>> def myrange(x):
...     return x.max() - x.min()
...

>>> # a custom aggregation
>>> group_df.group_by('key2').agg(
...     # di default non aggrega nulla ma fa la lista degli elementi
...     pl.col("data1"),
...     # polars style, do elaboration and add alias at the end
...     pl.col("data1").min().alias("data1_min"),
...     pl.col("data1").max().alias("data1_max"),
...     # abbreviabili mediante
...     pl.min("data1").name.suffix("_min2"),
...     # funzione custom di un parametro (e kwargs specification)
```

```
...     data1_range = myrange(pl.col("data1")),
...     # funzione custom di due parametro (e kwargs specification)
... )
shape: (2, 6)
+------+-----------------------------------+-----------+-----------+------------+-------------+
| key2 | data1                             | data1_min | data1_max | data1_min2 | data1_range |
| ---  | ---                               | ---       | ---       | ---        | ---         |
| str  | list[f64]                         | f64       | f64       | f64        | f64         |
+=============================================================================================+
| two  | [0.053821, 0.184372, ... 0.889... | 0.053821  | 0.889893  | 0.053821   | 0.836072    |
| one  | [0.682352, 0.22036, ... 0.8197... | 0.175906  | 0.923345  | 0.175906   | 0.747439    |
+------+-----------------------------------+-----------+-----------+------------+-------------+
```

Applicare funzioni all'intero dataframe/subset Si fa mediante `map_groups` che prende in input una funzione:

- la funzione prende in input e restituisce un dataframe
- la funzione viene applicata a tutti i dataframe
- il risultato viene bindato di riga

È una soluzione più lenta delle espressioni polars (si esce dal rust e si passa dal python) e da utilizzare solo se non si riesce ad esprimere con queste

```
>>> # Per ogni gruppo di colore, campiona due righe
>>> df = pl.DataFrame({
...         "id": [0, 1, 2, 3, 4],
...         "color": ["red", "green", "green", "red", "red"],
...         "shape": ["square", "triangle", "square", "triangle", "square"],
... })
>>> df.group_by("color").map_groups(
...     lambda group_df: group_df.sample(2)
... )
shape: (4, 3)
+-----+-------+----------+
| id  | color | shape    |
| --- | ---   | ---      |
| i64 | str   | str      |
+========================+
| 0   | red   | square   |
| 4   | red   | square   |
| 1   | green | triangle |
| 2   | green | square   |
+-----+-------+----------+

>>> # alternativamente mediante espressioni polars sarebbe stato
>>> # df.filter(
>>> #     pl.int_range(pl.len()).shuffle().over("color") < 2
>>> # )
```

Filtrare gruppi Si fa mediante `having` che è equivalente a calcolare il criterio di filtro e filtrare le righe in seguito

```
>>> df = pl.DataFrame({
...     "a": ["a", "b", "a", "b", "c"],
... })
>>> df.group_by("a").having(pl.len() > 1).agg()
shape: (2, 1)
+-----+
| a   |
| --- |
| str |
+=====+
| b   |
| a   |
+-----+
```

Iterare sui gruppi con `for` Un oggetto `GroupBy` è iterabile quindi funziona bene con i `for`: questo genera una sequenza di tuple di due elementi, contenenti nome del gruppo (chiave) e chunk di dati di dati il pezzo di dati

```
>>> # chiave singola
>>> for (group, ), data in group_df.group_by('key2'):
...   print(f"group = {group}")
...   print(data, "\n") # simple DataFrame
...
group = one
shape: (5, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| x    | one  | 0.682352 | 0.51297  |
| y    | one  | 0.22036  | 0.824242 |
| z    | one  | 0.175906 | 0.741467 |
| w    | one  | 0.923345 | 0.927407 |
| w    | one  | 0.819755 | 0.799125 |
+------+------+----------+----------+

group = two
shape: (5, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| y    | two  | 0.053821 | 0.244965 |
| z    | two  | 0.184372 | 0.213763 |
| z    | two  | 0.812095 | 0.62994  |
| w    | two  | 0.276574 | 0.231908 |
```

```
| w    | two  | 0.889893 | 0.518165 |
+------+------+----------+----------+

>>> # chiave multipla: il primo elemento della tupla è una
>>> # tupla con le chiavi
>>> for (key1, key2), data in group_df.group_by(['key1', 'key2']):
...   print(f"key1 = {key1}, key2 = {key2}")
...   print(data, "\n")
...
key1 = y, key2 = one
shape: (1, 4)
+------+------+---------+----------+
| key1 | key2 | data1   | data2    |
| ---  | ---  | ---     | ---      |
| str  | str  | f64     | f64      |
+==================================+
| y    | one  | 0.22036 | 0.824242 |
+------+------+---------+----------+

key1 = z, key2 = one
shape: (1, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| z    | one  | 0.175906 | 0.741467 |
+------+------+----------+----------+

key1 = w, key2 = two
shape: (2, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| w    | two  | 0.276574 | 0.231908 |
| w    | two  | 0.889893 | 0.518165 |
+------+------+----------+----------+

key1 = z, key2 = two
shape: (2, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+==================================+
| z    | two  | 0.184372 | 0.213763 |
| z    | two  | 0.812095 | 0.62994  |
+------+------+----------+----------+
```

```
key1 = w, key2 = one
shape: (2, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+=================================+
| w    | one  | 0.923345 | 0.927407 |
| w    | one  | 0.819755 | 0.799125 |
+------+------+----------+----------+

key1 = x, key2 = one
shape: (1, 4)
+------+------+----------+---------+
| key1 | key2 | data1    | data2   |
| ---  | ---  | ---      | ---     |
| str  | str  | f64      | f64     |
+================================+
| x    | one  | 0.682352 | 0.51297 |
+------+------+----------+---------+

key1 = y, key2 = two
shape: (1, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+=================================+
| y    | two  | 0.053821 | 0.244965 |
+------+------+----------+----------+
```

Memorizzare in un dict lo split Essendo il `GroupBy` un iterabile, è possibile elaborarlo, ad esempio trasformandolo in un `dict`. Di default l'indice viene restituito come tupla di un elemento, che selezioniamo per più facile accesso

```
>>> pieces = {k[0]: v for k,v in group_df.group_by('key2')}
>>> pieces['two']
shape: (5, 4)
+------+------+----------+----------+
| key1 | key2 | data1    | data2    |
| ---  | ---  | ---      | ---      |
| str  | str  | f64      | f64      |
+=================================+
| y    | two  | 0.053821 | 0.244965 |
| z    | two  | 0.184372 | 0.213763 |
| z    | two  | 0.812095 | 0.62994  |
| w    | two  | 0.276574 | 0.231908 |
| w    | two  | 0.889893 | 0.518165 |
+------+------+----------+----------+
```

Capitolo 12

Matplotlib

Contents

12.1 Introduzione 117
12.2 Salvataggio figura 117
12.3 Impostazione layout figura ed esempi 119
12.3.1 Layout standard 119
12.3.2 Layout custom 119
12.4 Fine tuning 120
12.4.1 Ticks e subticks 120
12.4.2 Spines e grid 120
12.4.3 Gestire la sovrapposizione di elementi diversi (`zorder`) 121
12.4.4 Legenda 121
12.4.5 Plot con doppio asse delle y 121
12.4.6 Padding dei subplots (spazio bianco bordi) 121
12.5 Configurazioni 122
12.5.1 Ottenimento e modifica 122
12.5.2 Ripristino impostazioni default 122
12.5.3 Cambiare stile 122
12.6 Grafici utili 122
12.6.1 Linee 123
12.6.2 Diagramma a barre 123
12.6.3 Istogramma 123
12.6.4 Scatterplot 123
12.6.5 Matrice di scatterplot 123
12.6.6 Boxplot 123
12.6.7 Correlation matrix 123


```
import numpy as np
import pylbmisc as lb
import rdatasets
rng = np.random.default_rng(123)

# template importazione matplotlib
```

```
import matplotlib.pyplot as plt

import polars as pl
pl.__version__
pl.Config.set_ascii_tables(True) # altrimenti la stampa di df da problemi
```

12.1 Introduzione

Alcuni punti di base:

- vi sono due stili di plotting in `matplotlib`: uno classico state-based che imita matlab e uno object oriented. Preferiamo questo secondo.
- una sequenza template per creare gli oggetti necessari sino a salvare la mostrare e salvare la ha il seguente template

  ```
  fig, ax = plt.subplots() # setup fig and axis
  # ...                    # do the actual plotting
  plt.show()               # show the plot
  fig.savefig("/tmp/first_plot.png", dpi=600) # save as png
  ```

- concetti fondanti:
  - una *figure* è il container di una immagine;
  - una figure può contenere al suo interno uno o più *axes*: questi sono gli effettivi plot dell'immagine

    ```
    # Figura 1 x 1: 1 figure e 1 axes
    fig, ax = plt.subplots()

    # Figura 2 x 3: 1 figure e 6 axes
    # ax è un array:(es ax[0,2] è ultimo grafico della prima riga)
    fig, ax = plt.subplots(2, 3)
    ```

    Il maggior lavoro si farà con i metodi messi a disposizione da `ax`/`axes`; alcuni metodi utili sono riportati in tabella 12.1, mentre l'anatomia di un grafico matplotlib in figura 12.1.
  - gli *axis* invece sono i veri e propri assi di ciascun plot/axes

12.2 Salvataggio figura

Per il salvataggio figura, in `fig.savefig`:

- specificare i `dpi` per i png
- se `transparent=True` la figura sarà transparent e meglio si adatta all'inclusione in documenti con sfondo di diverso colore
- se si passa `bbox_inches='tight'` si shinka la fig alle dimensioni del grafico interno, eliminando spazio bianco attorno ad esso ad eccezione di un piccolo ammontare di padding (aggiustabile con `pad_inches`)

Nel seguito si usa `lb.io.export_figure` per comodità (wrapper di `savefig`).

Metodo	Descrizione
`plot`	linee/scatterplot
`hist`	istogramma
`bar`	diagramma a barre
`scatter`	scatterplot più flessibile/lento
`errorbar`	intervalli di confidenza
`set`	imposta tutti i seguenti in una unica chiamata
`set_title`	imposta il titolo
`set_xlabel`, `set_xlabel`	imposta il titolo degli assi
`set_xticks`, `set_yticks`	imposta la posizione dei ticks sugli assi
`set_xticklabels`, `set_yticklabels`	imposta l'etichetta dei ticks
`set_xlim`, `set_ylim`	impostare i limiti degli assi/zoom figura
`legend`	aggiunta di legenda
`text`	aggiunta di testo
`spines`	config bordi area di plot
`grid`	config griglia area di plot

Tabella 12.1: Metodi utili di `ax`

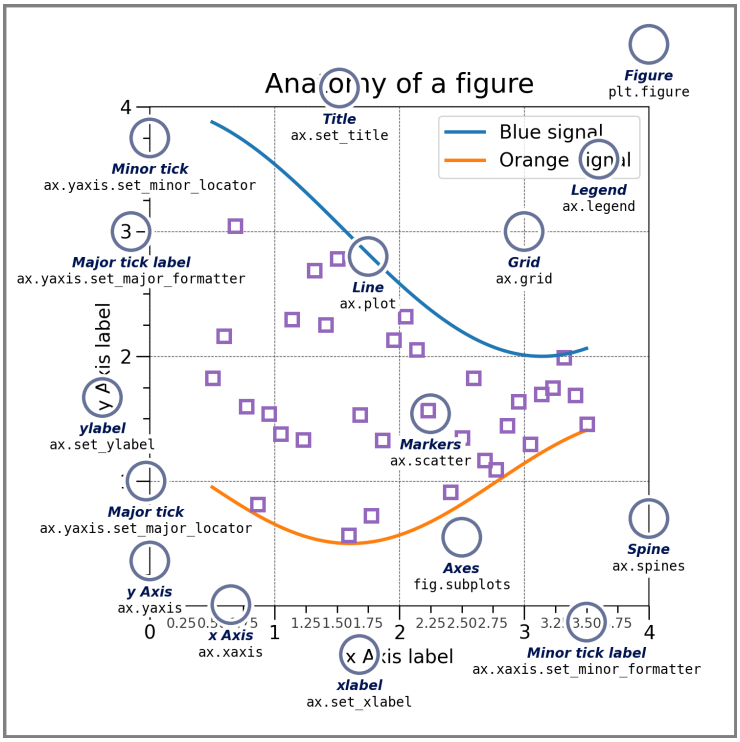


Figura 12.1: Anatomia di una figura

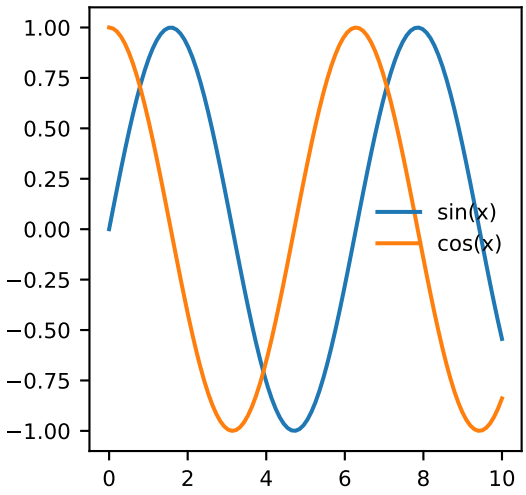


Figura 12.2: First plot

12.3 Impostazione layout figura ed esempi

12.3.1 Layout standard

Grafico singolo Esempio minimale figura **??**:

- si aggiungono funzioni plottate con chiamate successive allo stesso `ax`
- ogni funzione ha una `label` utilizzata per la `legend`

```
fig, ax = plt.subplots(figsize=(3,3))
x = np.linspace(0, 10, 100)
ax.plot(x, np.sin(x), label = 'sin(x)')
ax.plot(x, np.cos(x), label = 'cos(x)')
ax.legend()
lb.io.export_figure(fig, label = 'first_plot')
```

Vettore di grafici Un esempio con layout grafici separati, in figura **??**

- aumentiamo la dimensione di figsize
- ci riferiamo agli `ax` come ad un vettore
- interfacciamo il codice matplotlib con quello di pandas i *wrapper di pandas* in due modi
  1. prendendo in maniera grezza in indici (sull'asse delle x) e valori (sull'asse delle y) dalla serie
  2. utilizzando il metodo della serie

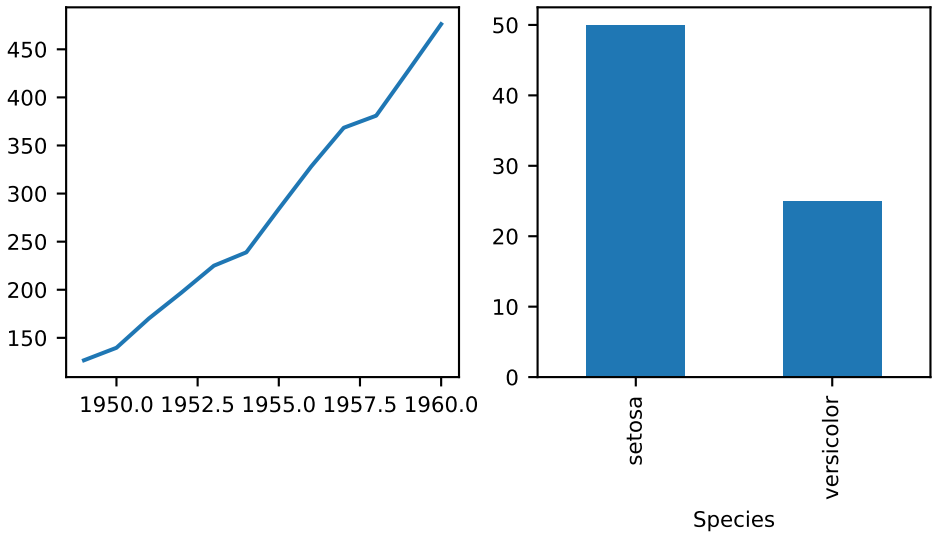


Figura 12.3: Second plot

```
fig2, ax2 = plt.subplots(nrows=1, ncols=2, figsize=(6, 2.5))

# raw matplotlib style using index and values
psng = rdatasets.data("AirPassengers").rename(columns={"value":"number"})
psng["year"] = np.floor(psng.time)
# how to select several columns: use [[]]
monthly_mean = psng.groupby("year")[["number"]].mean()
ax2[0].plot(monthly_mean["number"].index, monthly_mean["number"].values)
# otherwise quicker single column (single [])
# monthly_mean = psng.groupby("year")["number"].mean()
# ax2[0].plot(monthly_mean.index, monthly_mean.values)

# pandas methods using iris: frequency of first 75 flower types
iris = rdatasets.data("iris")
freqs = iris.iloc[:75, 5].value_counts()
freqs.plot.bar(ax = ax2[1])

lb.io.export_figure(fig2, label = 'second_plot')
```

Matrice di grafici Matrice 2×2 in cui plottiamo i subset di un grafico

- utilizziamo `constrained_layout` per aggiustare le dimensioni dei plot affinché fittino la figura (buona idea quando si hanno più plot in una singola figura) e gli axis di un plot non vadano sopra il titolo di un altro (alternativamente possiamo fare le cose a mano mediante `fig.subplot_adjust`);
- usiamo `flatten` di `numpy` per iterare sequenzialmente sugli ax
- evitiamo che l'ultimo (inutile) axes venga mostrato impostando `axis` ad `off`

- impostiamo che i range di x e y siano comuni per
- aggiungiamo un titolo complessivo di figura mediante `fig.suptitle`

```
iris = rdatasets.data("iris")

fig3, ax3 = plt.subplots(nrows=2, ncols=2, figsize = (5,5), constrained_layout=True)
flat_axes = ax3.flatten()

for ax, species in zip(flat_axes, ["setosa", "versicolor", "virginica"]):
    subs = iris.query(f"Species=='{species}'") # create subset
    ax.scatter(x=subs["Sepal.Length"], y=subs["Sepal.Width"], alpha = 0.5)
    ax.set_xlim((3, 9))
    ax.set_ylim((1, 5))
    ax.set_title(f"{species}") # single graph title
    ax.set_xlabel("length (cm)")
    ax.set_ylabel("width (cm)")

ax3[1, 1].axis("off") # non visualizzare il quarto grafico
fig3.suptitle("Sepal length and width scatterplot", fontsize=15)
lb.io.export_figure(fig3, label = 'third_plot')
```

Il risultato è in figura **??**

12.3.2 Layout custom

Griglia di axes di dimensione variabile L'uso di `plt.subplots` è comodo ma impone che tutti gli axes abbiano dimensioni comuni. Per customizzare

- si crea una figura mediante `plt.figure`
- si determina una griglia con le proporzioni degli axes inclusi nella figura mediante `plt.GridSpec`
- si creano i singoli axes mediante `add_subplot` fornendo la griglia (con slicing) di riferimento
- per un altro esempio vedere effective visualization a pagina 59
- con `plt.subplot_mosaic` si ottiene qualcosa di simile (effective visualization a pagina 67)

Sotto il codice per figura **??**;

```
fig  = plt.figure(figsize=(5,5))
grid = plt.GridSpec(nrows=2, ncols=3, figure=fig, wspace=0.4, hspace=0.3)

ax1 = fig.add_subplot(grid[0, 0])
ax1.boxplot([rng.standard_normal(50),rng.standard_normal(50) + 1])

ax2 = fig.add_subplot(grid[0, 1:])
ax2.bar(x = ["A", "B", "C", "D", "E", "F"], height = [10, 20, 40, 5, 25, 20])

ax3 = fig.add_subplot(grid[1, :2])
```

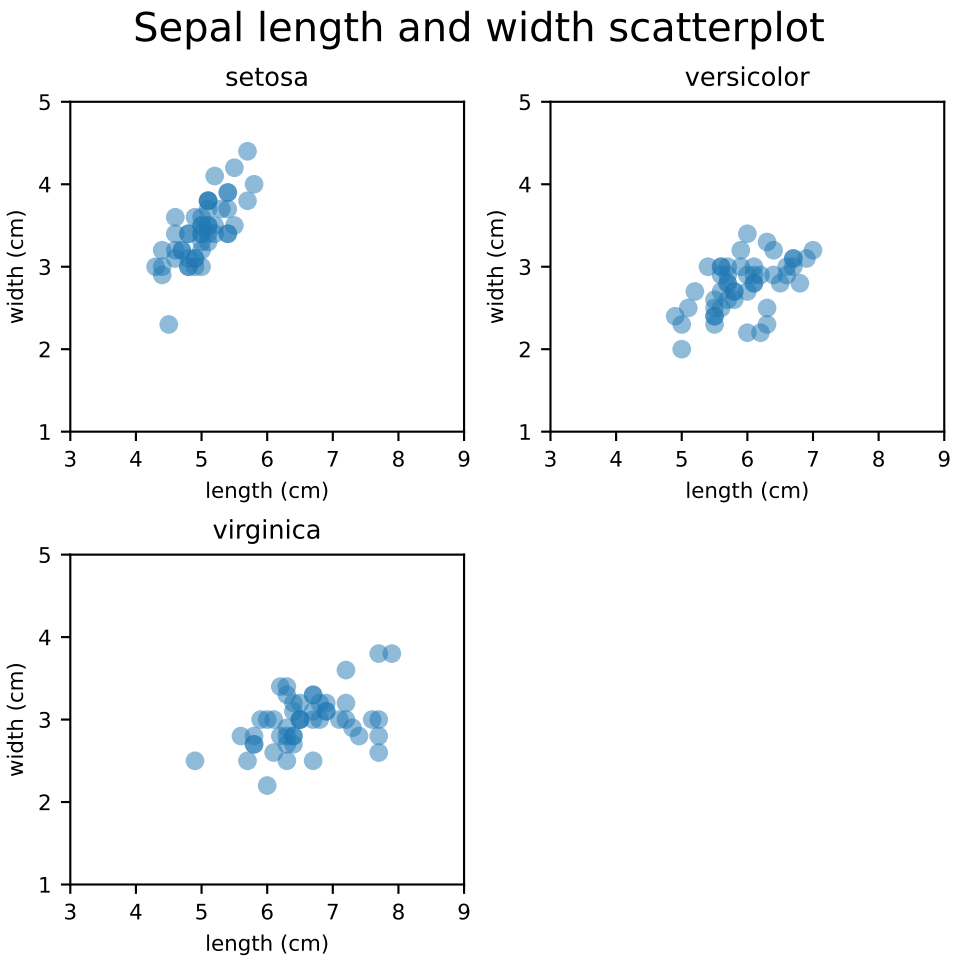


Figura 12.4: Third plot

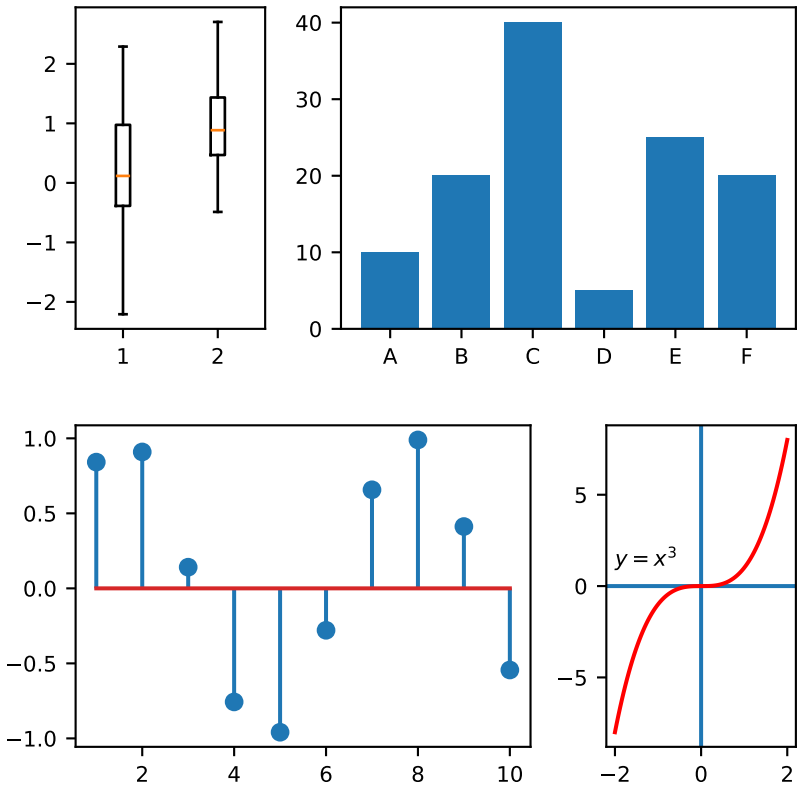


Figura 12.5: Custom grid

```
x = np.arange(1, 11)
ax3.stem(x, np.sin(x))

ax4 = fig.add_subplot(grid[1, 2])
x = np.linspace(start=-2, stop=2, num=100)
ax4.axhline(0) # riferimento
ax4.axvline(0) # cartesiano
ax4.plot(x, x**3, color="red")
ax4.text(-2, 1, '$y = x^3$')

lb.io.export_figure(fig, label = 'custom_grid')
```

Axes uno dentro all'altro Il setup di sopra pone subplot affiancati e riempie tutta la figura; maggiore controllo sul setup dei subplot può essere ottenuto con `add_axes`. Questa prende come input una lista di quattro numeri che specificano le coordinate `[left, bottom, width, height]` nel range da 0 (in basso a sinistra della figura) a 1 in alto a destra (figura **??**).

```
fig = plt.figure(figsize = (3,3))
ax1 = fig.add_axes([0,       0,    1,    1]) # assi standard
```

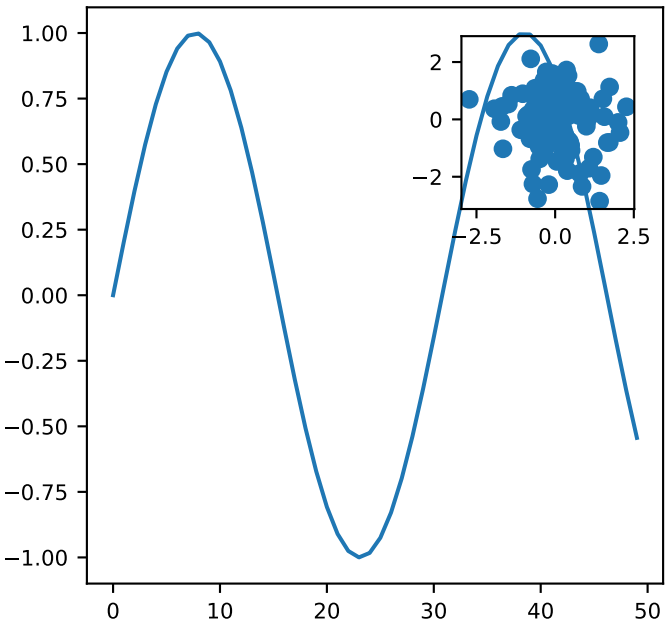


Figura 12.6: Custom subplots

```
ax2 = fig.add_axes([0.65, 0.65, 0.3, 0.3]) # assino piccolino a 0.65, 0.65
                                           # della figura ed estensione 0.3x0.3
ax1.plot(np.sin(np.linspace(0, 10)))
ax2.scatter(rng.standard_normal(100), rng.standard_normal(100))
lb.io.export_figure(fig, label = 'custom_subplots')
```

Per zoom di plot vedere anche effective visualization a pag 94

12.4 Fine tuning

12.4.1 Ticks e subticks

Qualora le configurazioni di default non vadano bene

- per impostare la *locazione*
  - per una locazione standard usare `matplotlib.ticker.MultipleLocator` nella chiamata a `ax.xaxis.set_major_locator` (ticks main) o `ax.xaxis.set_minor_locator` (ticks minor se necessari)
  - per una custom/non uniforme utilizzare `ax.set_xticks` (`ax.set_yticks`)
  - per date e time series usare locatori come `YearLocator` o `MonthLocator` cfr effective visualization pag 97)
- per scegliere il *valore mostrato* `ax.set_xticklabels` (`ax.set_yticklabels`)
- per la dimensione ticks usare `ax.tick_params`

- per aggiustare il font dell'asse ottenere ciascuna label con `ax.get_xticklabels` (`ax.get_yticklabels`) dopodiché impostare dimensione/peso/famiglia con le funzioni `set_fontsize set_weight set_family`
- se invece si vuole solo **nascondere i ticks** (ma non le label) nella chiamata `ax.tick_params` impostare `left=False` o `bottom=False`

Ad esempio in **??**

```
fig, ax = plt.subplots()
x = rng.standard_normal(50)
y = rng.standard_normal(50)
ax.scatter(x, y)
ax.set_xlim((-3, 3))
ax.set_ylim((-3, 3))

# locazione dei ticks
from matplotlib.ticker import MultipleLocator
ax.xaxis.set_major_locator(MultipleLocator(1))
ax.xaxis.set_minor_locator(MultipleLocator(0.5))
ax.yaxis.set_major_locator(MultipleLocator(1))
ax.yaxis.set_minor_locator(MultipleLocator(0.5))

# dimensione ticks
ax.tick_params(axis='x', which='major', length=10, width=2, color="red")
ax.tick_params(axis='x', which='minor', length=5,  width=1, color="orange")
ax.tick_params(axis='y', which='major', length=10, width=2, color="blue")
ax.tick_params(axis='y', which='minor', length=5,  width=1, color="cyan")

# font dell'asse
for label in ax.get_xticklabels() + ax.get_yticklabels():
    label.set_fontfamily("Roboto")
    label.set_fontsize(6)

lb.io.export_figure(fig, label = 'ticks')
```

12.4.2 Spines e grid

Le *spines* sono gli assi che racchiudono l'immagine, in due dei quali sono posizionati gli assi (a sx e sotto); possiamo gestire il formato dei 4 spines indipendentemente. Le *grid* invece sono le griglie dell'area di plotting. Un esempio di entrambe in **??** ottenuta col codice di sotto

```
fig, ax = plt.subplots()
ax.scatter(rng.standard_normal(100), rng.standard_normal(100))

# tolgo spine sopra e a dx
ax.spines["top"].set_visible(False)
ax.spines["right"].set_visible(False)

#  imposto che le grid siano sotto ai punti e inizio ad aggiungere le major
```

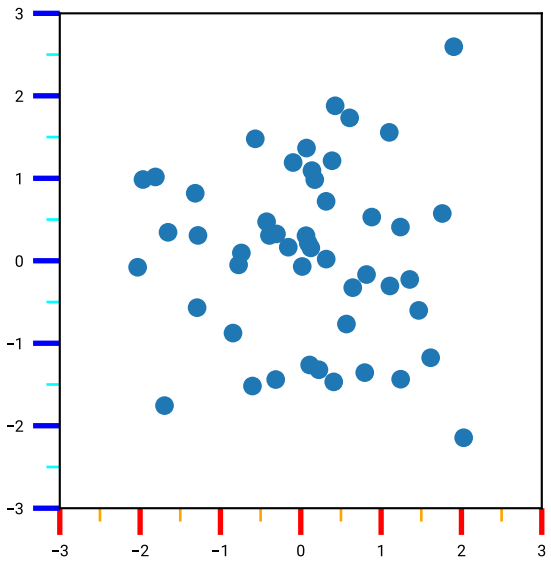


Figura 12.7: Ticks

```
ax.set_axisbelow(True)
ax.grid(which='major', linestyle = '--', color='grey', linewidth=0.5, alpha=0.5)

# aggiungo ticks minor e grid minor (ogni 0.5 sia per x che y)
ax.xaxis.set_minor_locator(MultipleLocator(0.5))
ax.yaxis.set_minor_locator(MultipleLocator(0.5))
ax.grid(which='minor', linestyle = '--', color='grey', linewidth=0.1, alpha=0.5)

lb.io.export_figure(fig, label = 'spines_grid')
```

12.4.3 Gestire la sovrapposizione di elementi diversi (`zorder`)

Il parametro `zorder` (disponibile in diversi metodi di ax come `scatter`, `plot`, etc) controlla lo stacking degli elementi del plot sull'asse z determinando quali elementi appaiano più in evidenza e quali possono essere mascherati. La regola è che valori più alti sono associati ad un piano più alto/maggiore visibilità. Un esempio con grid, nuvola di punti e retta aventi rispettivamente zorder crescente (quindi la più visibile è la retta) in figura **??**.

```
fig, ax = plt.subplots()
x = rng.standard_normal(100)
y = rng.standard_normal(100) + 1
ax.scatter(x, y,
           zorder = 2)
ax.grid(which='major', linestyle = '--', color='grey', linewidth=1, alpha=0.5,
        zorder=1)
ax.plot([-2, 2], [-1, 3], color="red", lw=1,# retta da [0, 0] a [1,1]
        zorder=3)
```

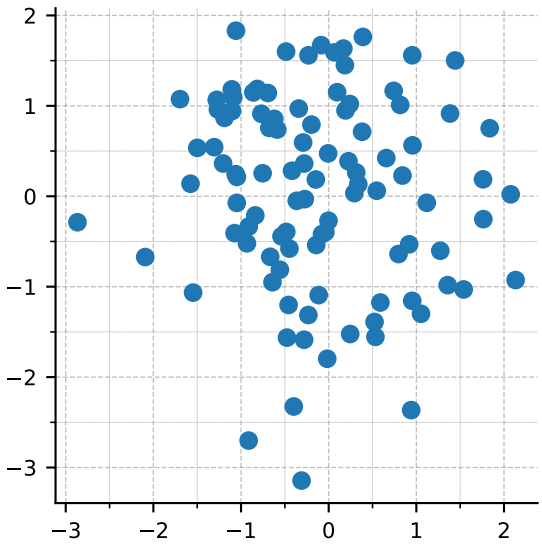


Figura 12.8: Spines grid

```
lb.io.export_figure(fig, label = 'zorder')
```

12.4.4 Legenda

Il metodo `ax.legend` genera labels dal parametro `label` specificato nel comando di plot, ma si può fornire label custom nell'argomento `labels`. Per il posizionamento

- `loc` specifica il posizionamento tipo `upper right`, ..., `lower left`; vi è anche la possibilità di specificare `best` per il migliore (interpolato)
- `bbox_to_anchor` ottimizza la posizione in relazione agli axes; es per piazzare la legenda a destra, al di fuori dell'area di plot settare `bbox_to_anchor=(1,1)`

Alcuni esempi di entrambe a seguire di legende a livello di singolo ax; per legenda a livello di figura multipla (con molteplici grafici) da fare. Maggiori info su

- `https://matplotlib.org/stable/api/_as_gen/matplotlib.axes.Axes.legend.html`
- `https://matplotlib.org/stable/users/explain/axes/legend_guide.html`

```
# ------------------------------
# loc - posizionamento dentro ax
# ------------------------------

# opzioni: "best", 'upper right', 'upper left', 'lower left', 'lower right'
```

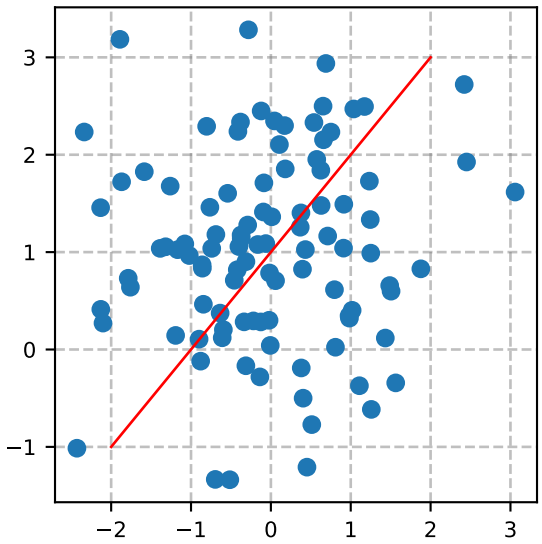


Figura 12.9: Zorder

```
# 'right' 'center left' 'center right' 'lower center' 'upper center' 'center'
# posizionamento ottimale per non overlappare (il default)

fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(loc="best") # best è il default btw
lb.io.export_figure(fig, label="loc1")

# metti in alto a dx
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(loc="upper right")
lb.io.export_figure(fig, label="loc2")

# posizionamento con coordinate (percentuali di grafico x e y)
# es posiziona in mezzo per x (0.5) e a 1/4 per y (0.25)
# occhio che quello è considerato l'angolo in basso a sinistra della legenda
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(loc=(0.5, 0.25))
lb.io.export_figure(fig, label="loc3")

# ----------------------
# uso di bbox_to_anchor
# ----------------------
```

```
# legenda fuori dal plot in alto a dx (100% di asse x e y)
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(1, 1), loc="upper left")
lb.io.export_figure(fig, label="testbboxtoanchor1")

# legenda fuori dal plot impostare il suo centro/sinistra della legenda al 100%
# dell'asse x e 50% dell'asse y
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(1, 0.5), loc="center left")
lb.io.export_figure(fig, label="testbboxtoanchor2")

# legenda sopra il plot da sx:occorre indicare
# - quattro numeri, che vanno a due a due, e servono per circoscrivere il
#   posizionamento della legenda
# - il numero di colonne in cui splittare le etichette mediante ncols
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(0, 1, 1, 1), loc="lower left", ncols=2)
lb.io.export_figure(fig, label="testbboxtoanchor3")

# legenda sopra il plot da dx
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(0, 1, 1, 1), loc="lower right", ncols=2)
lb.io.export_figure(fig, label="testbboxtoanchor4")

# espandere la legenda per matchare i
fig, ax = plt.subplots()
ax.plot([1, 2, 3], label="test1")
ax.plot([3, 2, 1], label="test2")
ax.legend(bbox_to_anchor=(0, 1, 1, 1), loc="lower right", ncols=2, mode="expand")
lb.io.export_figure(fig, label="testbboxtoanchor5")
```

12.4.5 Plot con doppio asse delle y

Un esempio potrebbe esser il plot della relazione di due variabili (mostrate su y) con una terza comune (su x), mostrato in fig **??** (oppure l'andamento di serie storiche aventi ordini di grandezza differenti).

```
df = rdatasets.data("airquality")

fig, ax1 = plt.subplots()
ax1.scatter(x=df.Ozone.values, y=df.Wind.values, alpha = 0.3, color="blue")
```

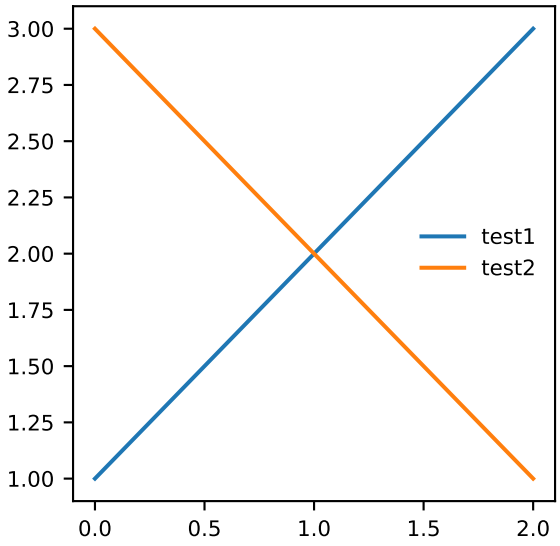


Figura 12.10: Loc1

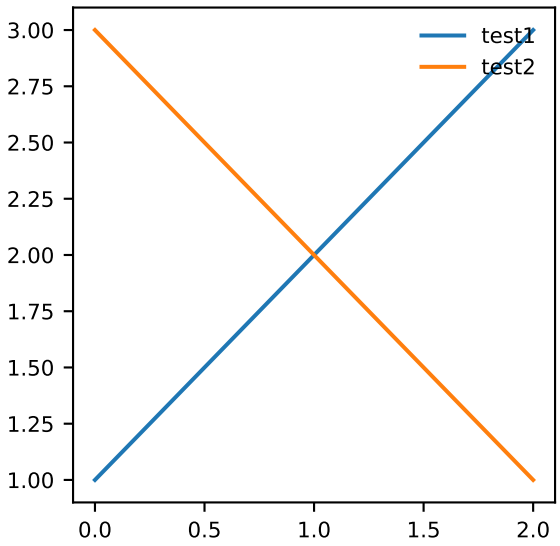


Figura 12.11: Loc2

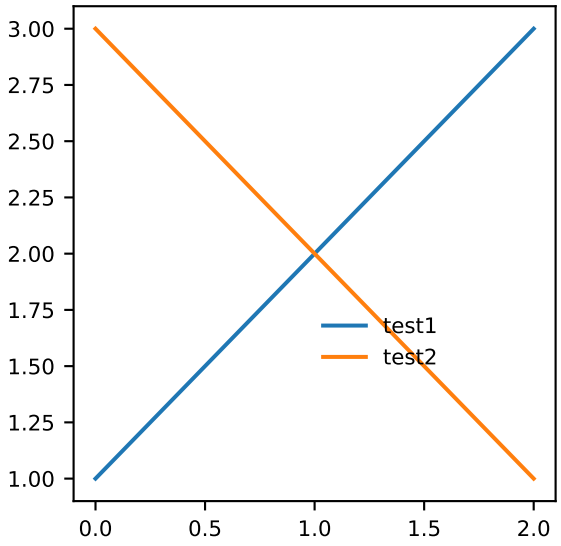


Figura 12.12: Loc3

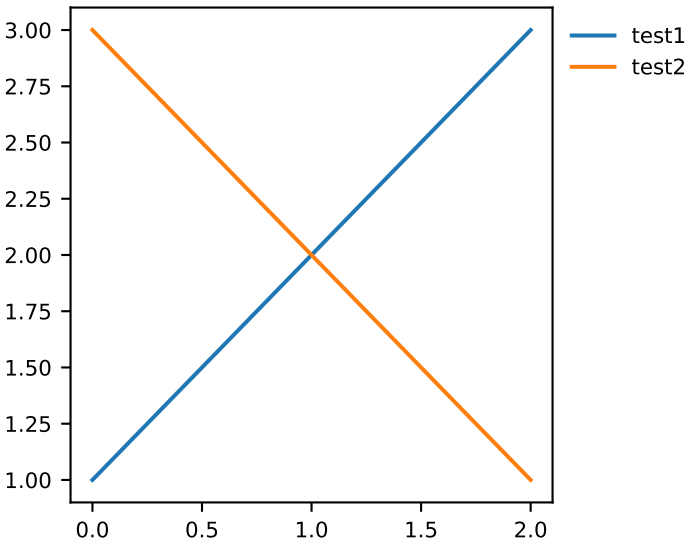


Figura 12.13: Testbboxtoanchor1

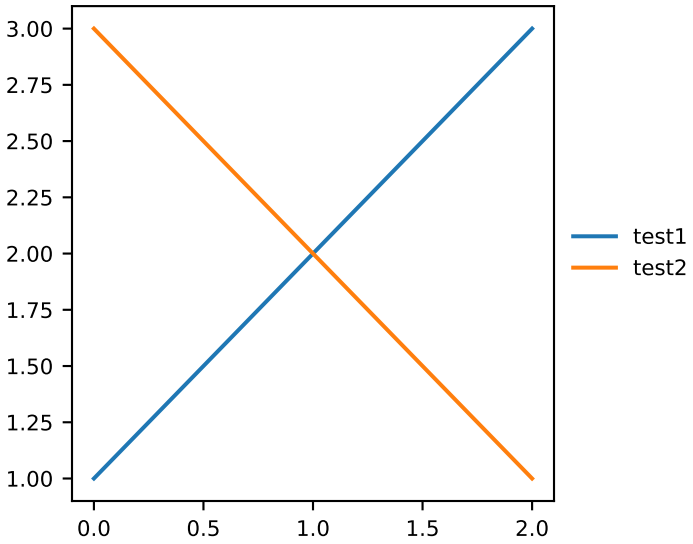


Figura 12.14: Testbboxtoanchor2

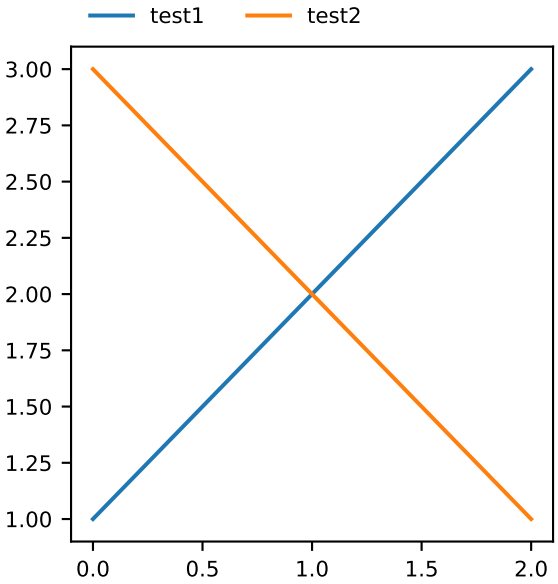


Figura 12.15: Testbboxtoanchor3

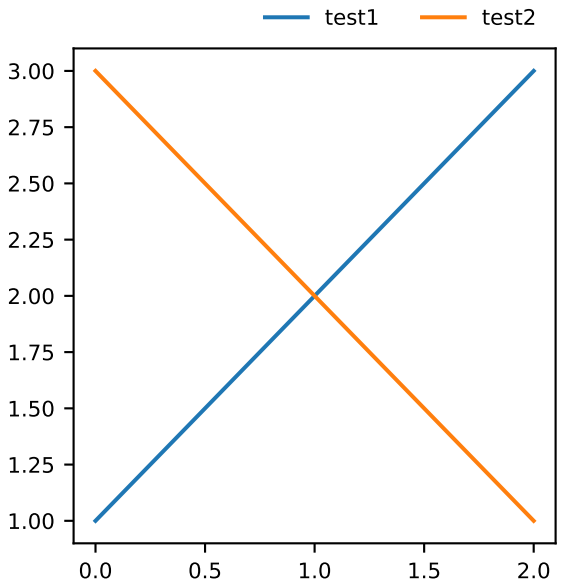


Figura 12.16: Testbboxtoanchor4

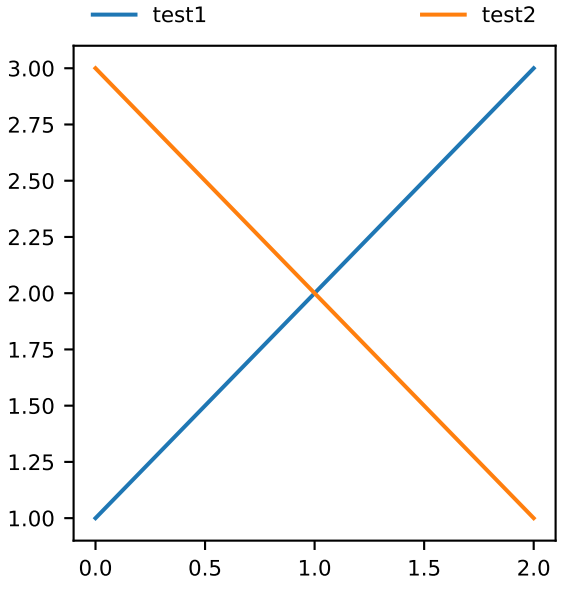


Figura 12.17: Testbboxtoanchor5

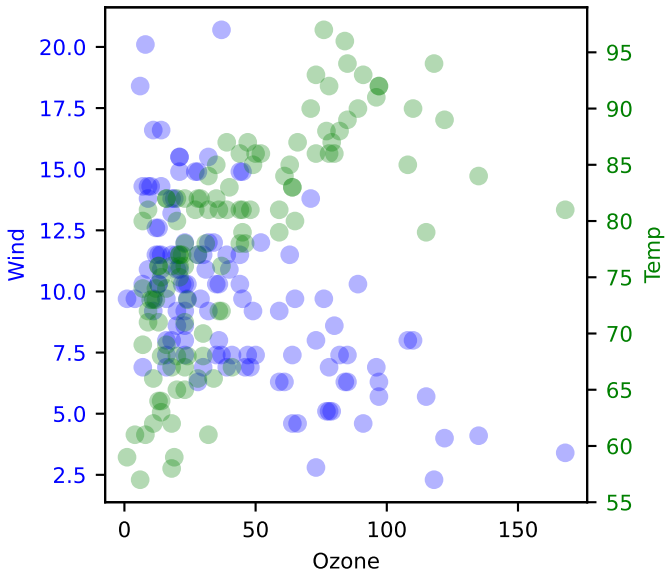


Figura 12.18: Double y axis

```
ax1.set_xlabel("Ozone")
ax1.set_ylabel("Wind", color="blue")
ax1.tick_params(axis="y", labelcolor="blue")

ax2 = ax1.twinx()
ax2.scatter(x=df.Ozone.values, y=df.Temp.values, alpha = 0.3, color="green")
ax2.set_ylabel("Temp", color="green")
ax2.tick_params(axis="y", labelcolor="green")

lb.io.export_figure(fig, label = 'double_y_axis')
```

12.4.6 Padding dei subplots (spazio bianco bordi)

Alternativamente all'automatico `constrained_layout=True` possiamo utilizzare `fig.subplots_adjust` per controllare il bianco verticale/orizzontale tra i bordi della figura e i bordi dell'axis:

- `left`, `top`, `right`, `bottom` regolano la percentuale di bianco esterna al box dell'axis (quindi se vi sono scale compresse agire su questo);
- in caso di subplot multipli `hspace` `wspace` regolano la quantità di spazio tra axis differenti

12.5 Configurazioni

Ogni volta che `matplotlib` si carica legge runtime configuration (rc) che valgono per ciascun plot creato.

12.5.1 Ottenimento e modifica

È possibile:

- listare le configurazioni indagando il dict `plt.rcParams`

  ```
  plt.rcParams # tutte le configurazioni
  plt.rcParams["figure.figsize"] # dimensioni figura
  ```

- modificarle mediante la funzione `plt.rc`

  ```
  # impostare le dimensioni delle figure a 8.5 cm (figsize prende una
  # lista di 2 misure in pollici come input)
  plt.rc("figure", figsize = [8.5/2.54] * 2)
  ```

- salvare le configurazioni in `.config/matplotlib/matplotlibrc`. Ad esempio per salvare l'impostazione come default inserire

  ```
  figure.figsize:    3.346 , 3.346  # figure size in inches
  ```

12.5.2 Ripristino impostazioni default

È possibile ripristinare i valori di default con la funzione `plt.rcdefaults()`.

12.5.3 Cambiare stile

Sono disponibili stili di grafico diversi che servono per avere un array di configurazioni già pronto:

- per listare gli stili disponibili

  ```
  plt.style.available
  ```

- per impostare lo stile dei grafici per tutto il resto della sessione

  ```
  plt.style.use('default')
  ```

- per impostare uno stile temporaneamente (es per una serie di grafici) si può usare un context manager:

  ```
  with plt.style.context('stylename'):
      make_a_plot()
      make_another_plot()
  ```

12.6 Grafici utili

Nel seguito alcuni grafici utili fatti mediante matplotlib o seaborn (che è un wrapper di più alto livello di matplotlib).
Per il plotting si farà preferibilmente uso del metodo `.plot` delle `Series` di `pandas` (che risulta particolarmente integrato con `matplotlib`).
Da ricordare che

- pandas di default plotta *l'indice* della serie/dataframe (indice di riga) sull'asse x e il valore della serie sull'asse y

- A tal proposito, a volte può essere utile trasporre il dataframe di elaborazione per invertire nomi colonne ed indici di riga (accessore `pd.DataFrame.T`) prima di procedere effettivamente a `plot`

```
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import pylbmisc as lb
import seaborn as sns
sns.set_theme()

# dataset
iris = sns.load_dataset('iris')
cd = lb.datasets.load("compact").to_pandas()
political = lb.datasets.load("political").to_pandas()
```

```
>>> import numpy as np
>>> import pandas as pd
>>> import matplotlib.pyplot as plt
>>> import pylbmisc as lb
>>> import seaborn as sns
>>> sns.set_theme()

>>> # dataset
>>> iris = sns.load_dataset('iris')
>>> cd = lb.datasets.load("compact").to_pandas()
>>> political = lb.datasets.load("political").to_pandas()
```

12.6.1 Linee

In figura **??** la durata media dei cd di una collezione per anno di pubblicazione. Se ci fossero state altre variabili oltre a durata (a parte quella di grouping) sarebbe stato plottato anche il loro andamento

```
>>> # durata media cd per anno
>>> cd.head() # dataset
   durata  anno
0     143  1966
1     150  1967
2     241  1994
3     337  1991
4     246  1994
>>> cd.groupby("anno").mean().head() # media annua di durata
      durata
anno
1958  212.00
1960  142.00
1961  150.00
1964  162.50
1965  155.75

# plotting
```

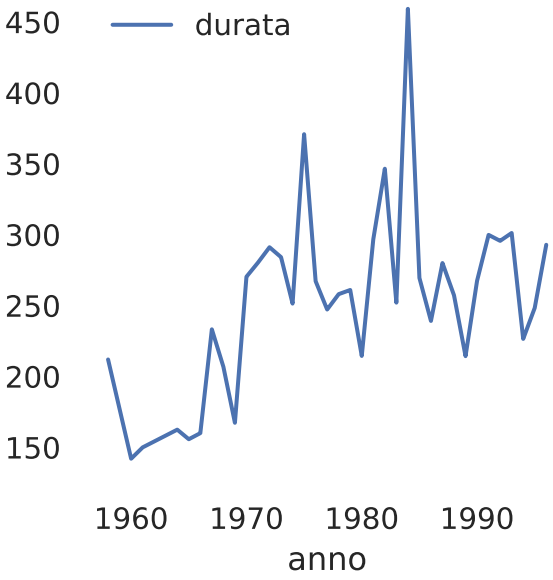


Figura 12.19: Diagramma linee

```
fig, ax = plt.subplots()
cd.groupby("anno").mean().plot.line(ax = ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_lines", caption = 'Diagramma linee')
```

12.6.2 Diagramma a barre

Si usi `bar` oppure `barh` per le barre orizzontali

```
>>> political.head()
  party_id  poid
0    3-dem     1
1    3-dem     1
2    3-dem     1
3    3-dem     1
4    3-dem     1
>>> political.party_id.astype("category").value_counts(sort = False)
party_id
1-rep     74
2-ind    111
3-dem     91
Name: count, dtype: int64
```

Per il diagramma figura **??** come farlo con pandas

```
fig, ax = plt.subplots()
political.party_id.astype("category").value_counts(sort = False).plot.bar(ax=ax)
```

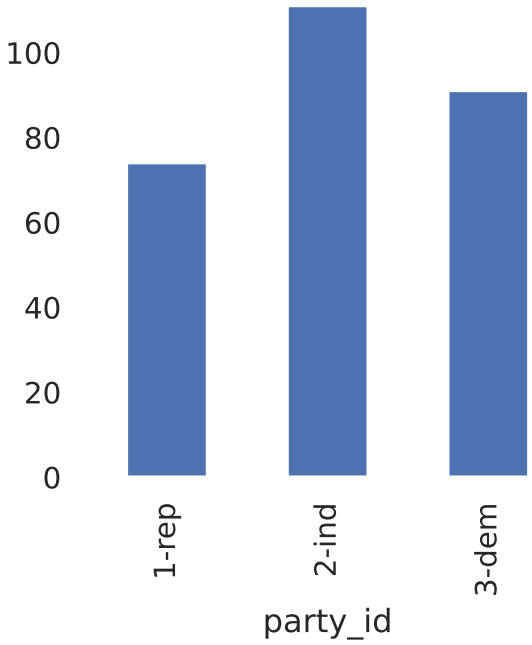


Figura 12.20: Diagramma a barre

```
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_barre", caption = 'Diagramma a barre')
```

12.6.3 Istogramma

Utilizzando i metodi di pandas in figura **??**

```
fig, ax = plt.subplots()
ax = iris.sepal_length.plot.hist(density = True, bins = range(9), xlim = [0, 8])
iris.sepal_length.plot.density(ax = ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_histo", caption = 'Istogramma (pandas syntax)')
```

12.6.4 Scatterplot

Uno rapido con `pandas` in figura **??** con alpha shading

```
fig, ax = plt.subplots()
iris.plot.scatter(x = 'sepal_length', y = 'sepal_width', alpha = 0.5, ax=ax)
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_scatter", caption = 'Scatterplot (pandas)')
# plt.close()
```

Uno più elaborato con colorazione condizionale, alpha shading e fatto con `seaborn`
in figura **??**

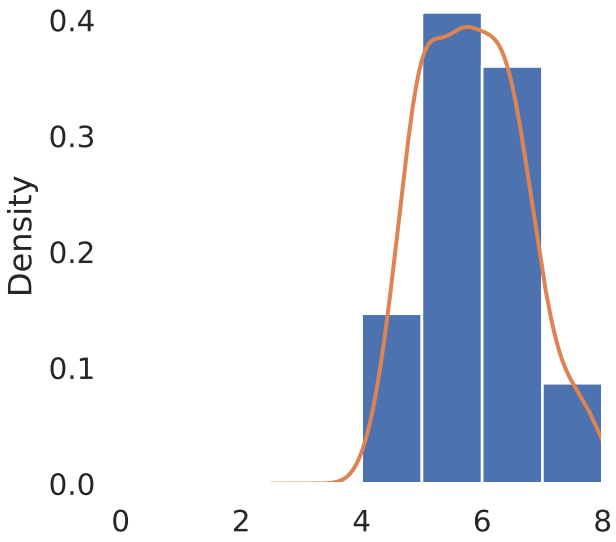


Figura 12.21: Istogramma (pandas syntax)

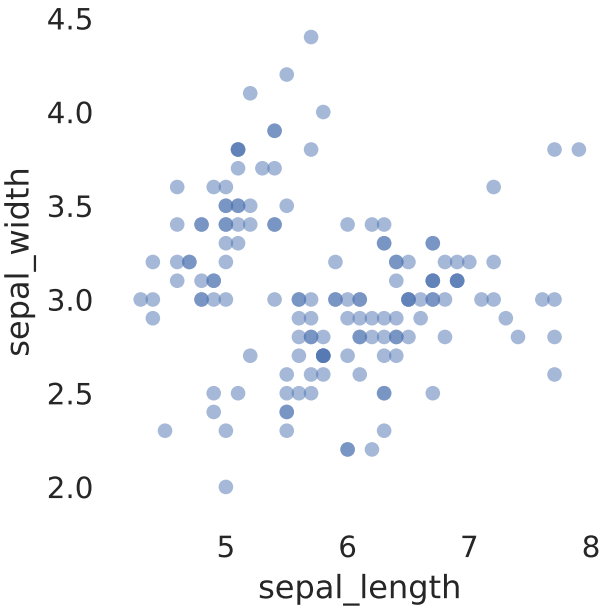


Figura 12.22: Scatterplot (pandas)

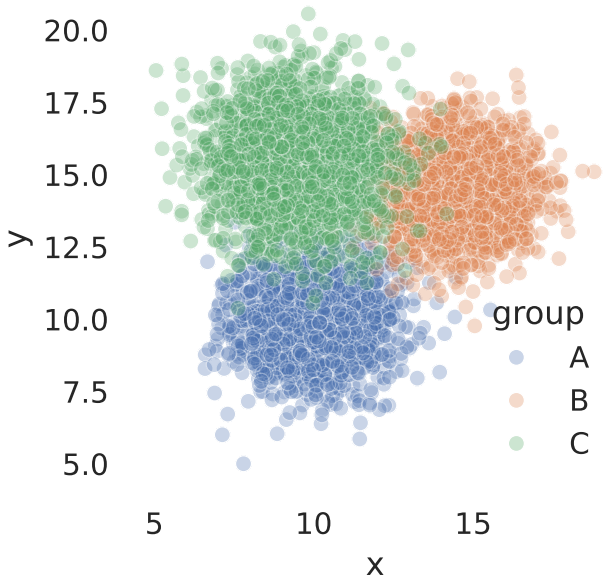


Figura 12.23: Scatterplot

```
# data
group1 = pd.DataFrame({'x': np.random.normal(10, 1.2, 2000),
                       'y': np.random.normal(10, 1.2, 2000),
                       'group': np.repeat('A',2000) })
group2 = pd.DataFrame({'x': np.random.normal(14.5, 1.2, 2000),
                       'y': np.random.normal(14.5, 1.2, 2000),
                       'group': np.repeat('B',2000) })
group3 = pd.DataFrame({'x': np.random.normal(9.5, 1.5, 2000),
                       'y': np.random.normal(15.5, 1.5, 2000),
                       'group': np.repeat('C',2000) })
df = pd.concat([group1, group2, group3])

# Plot
fig, ax = plt.subplots()
ax = sns.scatterplot(x='x', y='y', data=df, hue='group', alpha = 0.30)
# fig = ax.get_figure()
lb.io.export_figure(fig, label="sns_scatter", caption = 'Scatterplot')
```

12.6.5 Matrice di scatterplot

Invece per la matrice di scatterplot ne mettiamo senza con regressione (**??** e con colorazioni **??**.

```
# primo
fig, ax = plt.subplots()
plot = sns.pairplot(iris, kind="reg")
fig = plot.fig
```

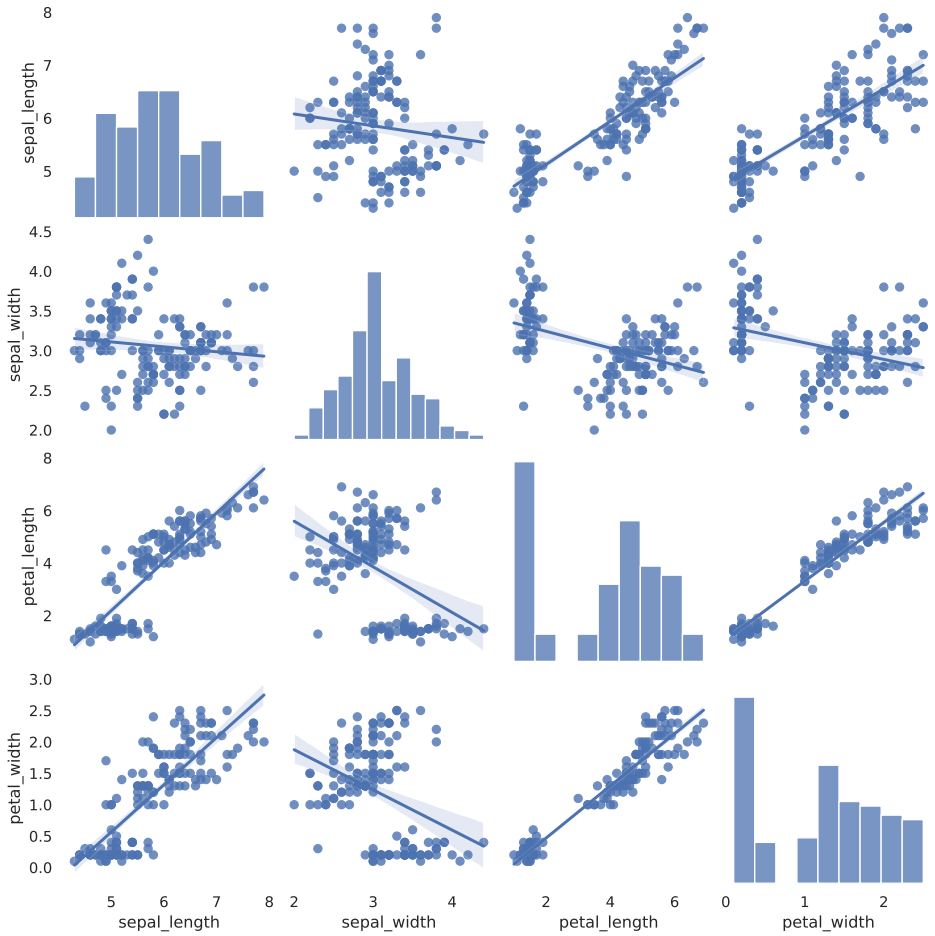


Figura 12.24: Pairplot 1

```
lb.io.export_figure(fig, label="sns_pair1", caption = 'Pairplot 1', scale = 0.5)
# plt.close()


# secondo
fig, ax = plt.subplots()
plot = sns.pairplot(iris, kind="scatter", hue="species", markers=["o", "s", "D"], pal
fig = plot.fig
lb.io.export_figure(fig, label="sns_pair2", caption = 'Pairplot 2', scale = 0.5)
# plt.close()
```

12.6.6 Boxplot

In figura ??

```
fig, ax = plt.subplots()
ax = iris.boxplot(by = "species", column="sepal_length")
```

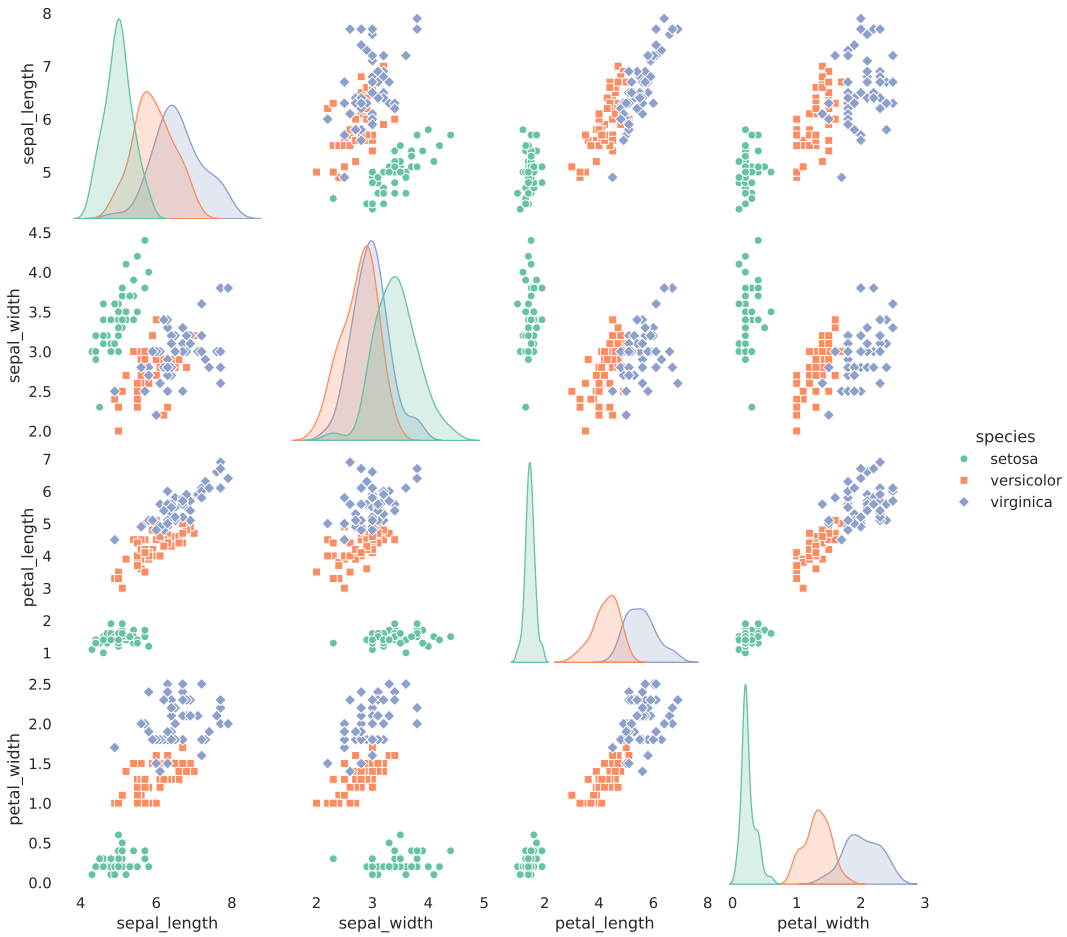


Figura 12.25: Pairplot 2

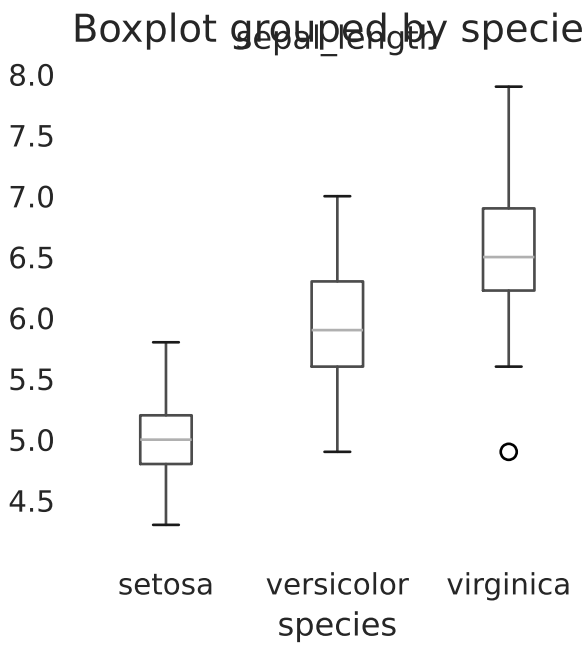


Figura 12.26: Boxplot

```
fig = ax.get_figure()
lb.io.export_figure(fig, label="pandas_boxplot", caption = 'Boxplot')
```

12.6.7 Correlation matrix

In figure **??**

```
corr = iris.select_dtypes("float").corr()

fig, ax = plt.subplots()
ax = sns.heatmap(corr,
                 cmap="RdBu",
                 vmin = -1, vmax = 1,
                 annot = True, fmt=".2f",
                 xticklabels=corr.columns.values, yticklabels=corr.columns.values)
fig = ax.get_figure()
lb.io.export_figure(fig, label="corrmatrix", caption = 'Correlation matrix')

# fig, ax = plt.subplots()
# ax = plt.matshow()
# fig = ax.get_figure()
# lb.io.export_figure(fig, label="corrmatrix", caption = 'Correlation matrix')
```

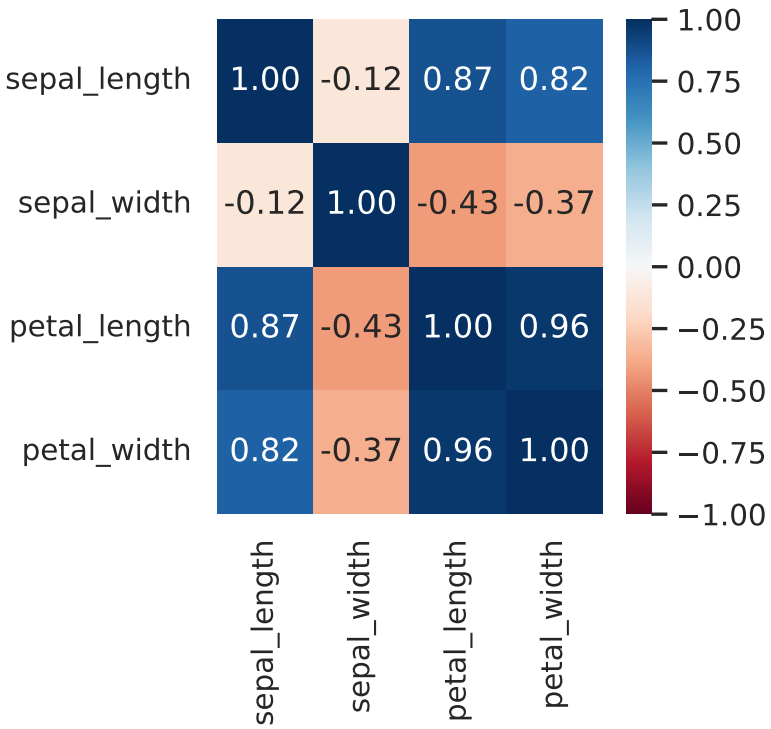


Figura 12.27: Correlation matrix

Parte III

Cookbook

Capitolo 13

Espressioni regolari

```
>>> import re

>>> # search/replace semplice (qui la gente inserisce le espressioni regolari)
>>> re.sub("à", "a", "ààestaaaà")
'aaestaaaa'
>>> re.sub("est", "a", "ààestaaaà")
'ààaaaaà'
>>> re.sub('[^0-9]', '', "sgdf352sc")
'352'
>>> # quando si usano \* meglio porre r per raw string e semplificare la sintassi
>>> re.sub(r"^(\w+) (\w+) (\w+)", r"\2", "asd foo bar")
'foo'

>>> # re.subn fa la stessa cosa ma ritorna una tupla con la stringa sostituita e il
>>> # numero di sostituzioni. Poco interessante for the moment

>>> # re.split splitta sulla base di un pattern, restituendo lista
>>> re.split(r"\d", "asd5foo66bar")
['asd', 'foo', '', 'bar']

>>> # re.findall ritorna tutti i match non overlappanti come lista di stringhe o di
>>> # tuple
>>> re.findall(r'(\w+)=(\d+)', 'set width=20 and height=10')
[('width', '20'), ('height', '10')]
>>> re.findall(r'\bf[a-z]*', 'which foot or hand fell fastest')  # parole inizianti f
['foot', 'fell', 'fastest']

>>> # re.finditer restituisce un iteratore sui match nella stringa (vedere sotto per Match)
>>> for m in re.finditer(r'(\w+)=(\d+)', 'set width=20 and height=10'):
...     print("-----")
...     print(m[0])
...     print(m[1])
...     print(m[2])
...
-----
width=20
```

```
width
20
-----
height=10
height
10
>>> # ------------------------------------------------------------------------
>>> # Ricerca/estrazione elementi
>>> # ------------------------------------------------------------------------

>>> # Scan della stringa e resitituisce un Match. Tre funzioni: match, search,
>>> # fullmatch.

>>> # re.match() cerca un singolo match all'inizio della stringa. Occhio che un
>>> # singolo match può essere composto da più elementi
>>> re.match("c", "abcdef")    # No match
>>> re.match(r"(\w+) (\w+)", "Isaac Newton, physicist")  # Match sino a virgola
<re.Match object; span=(0, 12), match='Isaac Newton'>

>>> # re.search() cerca il primo match ovunque nella the string (default di Perl)
>>> re.search("c", "abcdef")   # Match
<re.Match object; span=(2, 3), match='c'>
>>> re.search("^a", "abcdef")  # Cercare solo all'inizio con search
<re.Match object; span=(0, 1), match='a'>

>>> # re.fullmatch() verifica se l'intera stringa è match
>>> re.fullmatch("p.*n", "python")  # Match
<re.Match object; span=(0, 6), match='python'>
>>> re.fullmatch("t.*n", "python")  # No match

>>> # Il template che si usa a valle per il processing di un match è il seguente
>>> search_match = re.search("c", "abcdefabcdef")
>>> if (search_match):
...     print("Using the match.")
...
Using the match.
>>> # Match.group
>>> # -----------
>>> # restituisce sottopezzi del match: se vi sono molteplici è una tuple
>>> m1 = re.search(r"(\w+) (\w+)", "Isaac Newton, physicist")
>>> if m1:
...     m1.group(0)       # match intero
...     m1.group(1)       # contenuto prima parentesi
...     m1.group(2)       # contenuto seconda parentesi
...     m1.group(1, 2)    # selezionare elementi e porli in tupla
...     m1.group(1, 1)    # idem
...     m1[0]             # è una tupla e si può accedere anche cosi
...
'Isaac Newton'
'Isaac'
'Newton'
```

```
('Isaac', 'Newton')
('Isaac', 'Isaac')
'Isaac Newton'
>>> # è possibile assegnare nomi ai match per rendere più esplicito il codice
>>> m2 = re.search(r"(?P<name>\w+) (?P<surname>\w+)", "Isaac Newton, physicist")
>>> if m2:
...     # utilizziamo
...     print(m2["name"])       # match intero
...     print(m2["surname"])
...
Isaac
Newton

>>> # Match.groups
>>> # ------------
>>> # restituisce una tupla con tutti i sottopezzi sia che abbiamo assegnato nomi
>>> # che no
>>> m1.groups()
('Isaac', 'Newton')
>>> m2.groups()
('Isaac', 'Newton')

>>> # Match.groupdict
>>> # ------------
>>> # restituisce un dict nel caso abbiamo assegnato nomi; ocio che non da errore
>>> # se non assegnamo nomi restituisce vuoto che raffaella carrà scansati
>>> m1.groupdict()  # vuoto!
{}
>>> m2.groupdict()
{'name': 'Isaac', 'surname': 'Newton'}

>>> # Match.expand
>>> # ------------
>>> # permette di usare le sottoporzioni per generare nuove stringhe (simile a
>>> # quanto fatto da sub)
>>> m1.expand(r"\1\1\2\2")  # notare r per raw string se no avremmo dovuto usare \\1
'IsaacIsaacNewtonNewton'

>>> # --------------------------------------------------------------------------
>>> # In produzione
>>> # --------------------------------------------------------------------------
>>> #
>>> # spesso vogliamo utilizzare una stessa regex con molte stringhe. Per farlo in
>>> # maniera efficiente la compiliamo in un istanza di Pattern ed usiamo i suoi
>>> # metodi search, match, fullmatch, findall, sub etc come usate sopra on the fly

>>> np_re = re.compile(r"(\w+) (\w+)")  # occhio a r per raw string
>>> m = np_re.search("Isaac Newton, physicist")
>>> m.groups()
('Isaac', 'Newton')
```

Capitolo 14

Logging

Contents

14.1 Uso del logger di default 129
14.1.1 Setup 129
14.2 Logger custom 130
14.2.1 Setup degli handler 130
14.2.2 Impostare la formattazione di un handler 130
14.2.3 impostare livello di log generale e di un handler . . . 131
14.2.4 Filtrare log 131

Il modulo `logging` permette di utilizzare il logger di default o definirne uno personalizzato avente maggiore flessibilità.
Utilizzare il logger di default è un modo comodo di avere una prima impressione su come il logging funzioni; il contro è che la configurazione può essere non troppo flessibile (si basa su una singola chiamata a `basicConfig` data all'inizio).
Per progetti più complessi occorre maggiore flessibilità e definire logger custom.
Ad ogni modo concetto fondamentale in entrambi è il livello di logging (tab 14.1)

14.1 Uso del logger di default

14.1.1 Setup

Un template per il logging da porre a inizio file è il seguente.

Livello	Funzione (logger default)	spiegazione
`DEBUG`	`logging.debug()`	Informazioni dettagliate per sviluppatori.
`INFO`	`logging.info()`	Info di cosa sta accadendo (buon funzionamento).
`WARNING`	`logging.warning()`	Vi sono cose da controllare
`ERROR`	`logging.error()`	Un problema inatteso si è verificato.
`CRITICAL`	`logging.critical()`	Un problema grave (eg livello crash) si è verificato.

Tabella 14.1: Livelli di logging dal piu basso (`DEBUG`) al più alto (`CRITICAL`)

```
# template per il logging
import logging
logging_level = logging.DEBUG
# logging_fmt = r"[%(levelname)s %(name)s] %(asctime)s - %(message)s"
logging_fmt = r"[{levelname} {name}] {asctime} - {message}"
logging_datefmt = "%Y-%m-%d %H:%M"
logging.basicConfig(level=logging_level, format=logging_fmt, datefmt=logging_datefmt,
```

Dopodiché si può procedere con il logging. Di default:

- se si utilizzano le funzioni di tab 14.1 viene usato il "root/default" logger
- se si inizia a loggare senza avere prima impostato i parametri di log non sarà possibile farlo poi a quanto pare

Per impostare il root logger si chiama `logging.basicConfig`. Un template di setup di logging è quello sopra:

- se non si specifica `level` prima di iniziare a loggare, saranno stampati **solo i messaggi dal warning in su** (no info, no debug)
- il `format` è una stringa in formato printf ma si può impostare style con la graffa aperta per avere una stringa tipo f-string variabile che ad esempio semplifica a "levelname name message" un fomato possibile. Alcune variabili
  - `name` è il nome del logger (eg `root`)
  - `levelname` è il livello di gravita (da `DEBUG` a `ERROR`)
  - `asctime` è l'ora (formato impostabile con es `datefmt`
  - `message` è il messaggio passato in sede di chiamata.

Loggare ad un file Se si vuole evitare di mandare a console aggiungere (alle altre configurazioni di sopra)

```
logging.basicConfig(
    filename="app.log", # filepath
    encoding="utf-8",   # encoding
    filemode="a"        # appendi al file non sovrascrivere (es)
)
```

Loggare valore di variabili (eg a csv) torna comodo la f-string seguente

```
logging.debug(f"{varname=}")
```

Si può anche creare un formato di log che crea un csv. un template potrebbe essere

```
if some_problem:
   # output data to a csv log for external analysis
   logging.debug(f"{surname},{name},{age}")
```

Catturare stack trace Con `exc_info=True` vengono stampate nel log le informazioni di debug

```
try:
    res = 5/0
except ZeroDivisionError:
    logging.error("ErroreNelCalcolo", exc_info=True)
```

Se si logga da un except handler si puo usare anche `logging.exception("ErroreNelCalcolo")` che risparmia digitazione. Questo è come `logging.error(exc_info=True)`

14.2 Logger custom

Per crearlo good practice è

```
logger = logging.getLogger(__name__)  # good practice to pass __name__ as the name parameter
```

Per configurarlo non si usa una singola chiamata a `basicConfig` ma gli *handlers*. Ciascun logger puo avere *uno o più handler*; nel secondo caso si mandano i log in vari posti (es stodut e a un file)

14.2.1 Setup degli handler

Nell'esempio di sotto impostiamo un output a file ed uno a standard error (contemporaneamente)

```
console_handler = logging.StreamHandler() # logga a console (stderr)
file_handler = logging.FileHandler("app.log", mode="a", encoding="utf-8") # logga a file
logger.addHandler(console_handler) # aggiungi l'handler al logger
logger.addHandler(file_handler)    # aggiungi l'handler al logger
```

Dopo questa configurazione, quando si logga qualcosa es con `logger.warning("Messaggio")` questo verra mandato sia a `stderr` che al file `app.log`.
Il modulo `logging` fornisce molti handler utili per specifiche applicazioni: es `RotatingFileHandler` crea un nuovo file una volta che un limite è raggiunto, o `TimedRotatingFileHandler` crea log per intervalli di tempo predefinito.
Per listare gli handler configurati

```
logger.handlers
```

14.2.2 Impostare la formattazione di un handler

Per impostare una specifica formattazione ad un handler, anche dopo che lo si è aggiunto al logger settargli un formatter come segue:

```
formatter = logging.Formatter(
    "{asctime} - {levelname} - {message}",
    style="{",
    datefmt="%Y-%m-%d %H:%M",
)

console_handler.setFormatter(formatter)
```

Questo impatta solo lo standard error, non l'output su file.
Definendo/settando differenti formatter per i vari handler si può controllare l'ammontare/formato di informazione visualizzata nei log, oppure mostrare messaggi di debug in un file ma mostrare a console solo la roba piu seria (o viceversa).
Es csv su file verboso e messaggio stretto in standard error

14.2.3 impostare livello di log generale e di un handler

Per impostare il livello di log a livello globale (per tutti gli handler)

```
logger.setLevel("INFO")
```

Qui con due handler possiamo avere un log piu verboso (con un livello inferiore) e un altro piu terso.
Si può settare il livello del singolo handler mediante il suo metodo `setLevel`

```
console_handler.setLevel("DEBUG")
```

Tuttavia il **livello generale è importante** perchè settare il livello dell'handler più basso di quello del logger fa si che i messaggi comunque non vengano stampati: il log globale definisce il livello più basso di log che verrà stampato e i singoli handler non posson mostrare log a livello piu basso del logger cui sono attaccati.
Pertanto può essere utile **settare il logger a livello** `DEBUG` e gli handler a livello desiderato (per stderr e file). Un template per l'impostazione segue

```
logger.setLevel("DEBUG") # logger generale permetti tutto
console_handler.setLevel("WARNING") # in standard error ci va la roba seria
file_handler.setLevel("DEBUG") # nel file di debug ci va di ogni
```

14.2.4 Filtrare log

Di default il livello di log è basato sull'idea che, eg, se si è interessati nei warning si è probabilmente interessati anche in error etc. Tuttavia vi pososno esser situazioni dove ha senso gestire messaggi di un dato livello a se/differentemente, e qui entrano in gioco i `Filter`.
Possono costituire un filtro

- una sottoclasse di `logging.Filter` alla quale si è sovrascritto il metodo `.filter` o comunque una classe che contiene un metodo `.filter`.
  In questi casi `.filter()` deve accettare un record di log e restituire un booleano. Dentro al corpo della funzione ha senso definire uno statement `if` che controlla il record di log fornito

- una callable (eg funzione) che si comporta come il metodo `filter` di cui sopra.
  La callable può essere una funzione con un parametro per il log record che l'handler passa al filtro per saper printare o no.
  Questo è il modo piu semplice e lo approfondimao di seguito

Ad esempio il filtro di sotto fa si che l'handler mostri solo messaggi di DEBUG (non anche i superiori). Gli altri setting come quelli dati in precedenza

```
def show_only_debug(record):
    return record.levelname == "DEBUG"


console_handler.addFilter(show_only_debug) # console printa solo il debug
```

Con questo setup qualsiasi log che non sia di livello `DEBUG` ritorna `False` e non sarà mostrato dall'handler cui è attaccato (in questo caso quello dello standard error).
Viceversa `file_handler` si comporta senza essere intaccato da questa modifica

Capitolo 15

Algebra lineare

Contents

15.1 Vettori, matrici e dimensioni 133
15.1.1 Creazione 133
15.1.2 Funzioni utilità per creazione 133
15.2 Operazioni 133
15.2.1 Somma 133
15.2.2 Trasposizione 133
15.2.3 Prodotti 134
15.3 Misc 134

Qui appunti da practical linear algebra for data science; esercizi fatti nella cartella dei test di Python.

```
>>> import numpy as np
```

15.1 Vettori, matrici e dimensioni

Con numpy si possono creare array ad una o due dimensioni; sono gli array a due dimensioni (in cui una è unitaria) ad essere assimilabili ai vettori dell'algebra lineare.

15.1.1 Creazione

Per definire un array a due dimensioni creare una lista che contiene liste delle righe dell'array

```
>>> # array ad una dimensione
>>> a_1d_array = np.array([1, 2, 3])

>>> # array a due dimensioni: vettori
>>> row_vector = np.array([      # ogni lista entro la lista più
...     [1, 2, 3]                # esterna è una riga del vettore
... ])
>>> col_vector = np.array([
```

```
...     [1],                        # ogni lista entro la lista più
...     [2],                        # esterna è una riga del vettore
...     [3]
... ])

>>> # array a due dimensioni matrici
>>> a_matrix = np.array([
...     [1, 2, 3],                      # ogni lista entro la lista più
...     [4, 5, 6],                      # esterna è una riga della matrice
...     [7, 8, 9]
... ])

>>> # non si stampano perché praticamente viene restituito
>>> # il codice inserito paro paro

>>> # differenze in termini di dimensioni e shape
>>> a_1d_array.shape    # 1d
(3,)
>>> row_vector.shape    # 2d di cui la prima è 1
(1, 3)
>>> col_vector.shape    # 2d di cui la seconda è 1
(3, 1)
>>> a_matrix.shape      # 2d con entrambe > 1
(3, 3)

>>> # len applicato a questo di fatto restituisce il numero di elementi per array
>>> # 1d e numero di righe per 2d
>>> len(a_1d_array)    # 1d (n. elementi)
3
>>> len(row_vector)    # 2d numero righe
1
>>> len(col_vector)    # 2d numero righe
3
>>> len(a_matrix)      # 2d numero righe
3
```

15.1.2 Funzioni utilità per creazione

Funzioni di convenienza per la generazione rapida di array:

```
>>> # Creazione rapida di dati
>>> np.arange(0, 20, 2)           # simile a range(), da 0 a 20 a step di 2
array([ 0,  2,  4,  6,  8, 10, 12, 14, 16, 18])
>>> np.arange(1, 10).reshape(3,3) # matrice
array([[1, 2, 3],
       [4, 5, 6],
       [7, 8, 9]])
>>> np.linspace(0, 1, 5)          # interpolazione lineare
array([0.  , 0.25, 0.5 , 0.75, 1.  ])
>>> np.full(5, 2)                 # vettore riempito di 2
array([2, 2, 2, 2, 2])
```

```
>>> np.zeros(10)                  # array di zero
array([0., 0., 0., 0., 0., 0., 0., 0., 0., 0.])
>>> np.ones((3, 5))               # array 3x5 di uno
array([[1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.],
       [1., 1., 1., 1., 1.]])
>>> np.eye(3)                     # matrice identita 3x3
array([[1., 0., 0.],
       [0., 1., 0.],
       [0., 0., 1.]])
>>> np.diag([1,2,3])              # diagonale
array([[1, 0, 0],
       [0, 2, 0],
       [0, 0, 3]])

>>> # creazione rapida sfruttando altre shape
>>> np.zeros_like(row_vector)  # array di 0 della stessa shape di x (np.ones_like)
array([[0, 0, 0]])

>>> # Generazione casuale
>>> np.random.normal(0, 1, 5)        # array 1d da normale mu=0, sd=1 di 5 elementi
array([-1.02884269,  0.56967842,  0.64166478,  0.25981193,  1.19317814])
>>> np.random.randint(0, 10, (1, 3)) # vettore riga (1x3) con interi nell'intervallo [0,10 )
array([[3, 1, 6]])
>>> np.random.random((3, 3))         # matrice 3x3 con valori casuali uniformi 0-1
array([[0.17746798, 0.46784597, 0.44896452],
       [0.39606462, 0.79192543, 0.49339824],
       [0.7239479 , 0.79302303, 0.3515241 ]])
```

15.2 Operazioni

15.2.1 Somma

Occhio alle somme di vettori, per le quale funziona il broadcasting e spesso portano a risultati di programmazione inattesi

```
>>> a_1d_array + col_vector # dimensioni diverse (risultato inatteso)
array([[2, 3, 4],
       [3, 4, 5],
       [4, 5, 6]])
>>> row_vector + row_vector # dimensioni e shape uguali (risultato atteso)
array([[2, 4, 6]])
>>> row_vector + col_vector # dimensioni uguali, shape diverse (risultato inatteso)
array([[2, 3, 4],
       [3, 4, 5],
       [4, 5, 6]])
```

15.2.2 Trasposizione

Per trasporre si usa l'attributo `T` (più generale) o il metodo `transpose` degli array

```
a_1d_array.T # attenzione: non cambia (e non viene dato errore)
row_vector.T # diventa un col.vector
a_matrix.T   # come da programma
```

15.2.3 Prodotti

Prodotto standard Per il prodotto standard righe per colonne si usa `np.dot`, la chiocciola oppure il metodo `dot` di un array (dando l'altro come argomento):

```
>>> X = a_matrix

>>> np.dot(X.T, X)
array([[ 66,  78,  90],
       [ 78,  93, 108],
       [ 90, 108, 126]])
>>> X.T @ X
array([[ 66,  78,  90],
       [ 78,  93, 108],
       [ 90, 108, 126]])
>>> # anche X.T.dot(X)

>>> # fortunatamente i prodotti inizia ad essere schizzinoso come algebra
>>> # lineare comanda

>>> col_vector @ col_vector # errore: 3x1 non matcha con 3x1
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: matmul: Input operand 1 has a mismatch in its core dimension 0, with gufu
>>> row_vector @ row_vector # errore: 1x3 non matcha con 1x3
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: matmul: Input operand 1 has a mismatch in its core dimension 0, with gufu
>>> row_vector @ col_vector # ok: 1x3 con 3x1 (dimensioni conformi)
array([[14]])
>>> col_vector @ row_vector # ok: 3x1 con 1x3
array([[1, 2, 3],
       [2, 4, 6],
       [3, 6, 9]])
>>> a_matrix @ col_vector   # ok: 3x3 con 3x1
array([[14],
       [32],
       [50]])
>>> a_matrix @ row_vector   # errore: 3x3 non matcha con 1x3
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
ValueError: matmul: Input operand 1 has a mismatch in its core dimension 0, with gufu

>>> # attenzione che dot invece non lo è troppo
>>> np.dot(row_vector, col_vector) # expected
array([[14]])
>>> np.dot(col_vector, row_vector) # unexpected
```

Funzione	Descrizione
`np.diag`	Return the diagonal (or off-diagonal) elements of a square matrix as a 1D array, or convert
`np.trace`	Compute the sum of the diagonal elements
`np.tril`	restituisce la matrice triangolare inferiore
`np.triu`	restituisce la matrice triangolare superiore
`np.linalg.norm`	Norma euclidea del vettore (radice della somma dei suoi quadrati)
`np.linalg.det`	Compute the matrix determinant
`np.linalg.eig`	Compute the eigenvalues and eigenvectors of a square matrix
`np.linalg.inv`	Compute the inverse of a square matrix
`np.linalg.pinv`	Compute the Moore-Penrose pseudo-inverse inverse of a square matrix
`np.linalg.qr`	Compute the QR decomposition
`np.linalg.svd`	Compute the singular value decomposition (SVD)
`np.linalg.solve`	Solve the linear system $\mathbf{Ax} = \mathbf{b}$ for $\mathbf{x}$, where $\mathbf{A}$ is a square matrix
`np.linalg.lstsq`	Compute the least-squares solution to $\mathbf{y} = \mathbf{Xb}$

Tabella 15.1: Funzioni per algebra lineare

```
array([[1, 2, 3],
       [2, 4, 6],
       [3, 6, 9]])
```

Prodotto di Hadamard È il prodotto elemento per elemento e si fa (su array idonei) mediante l'asterisco

```
>>> row_vector * row_vector  # ok questo è il prodotto di Hadamard
array([[1, 4, 9]])
>>> row_vector *  # no qui usa il broadcasting
  File "<stdin>", line 1
    row_vector *  # no qui usa il broadcasting
SyntaxError: invalid syntax
```

15.3 Misc

Funzioni utili riportate in tabella 15.1

Capitolo 16

Probabilità e simulazione

Contents

16.1 Funzionalità native 135
16.1.1 Combinatoria 135
16.1.2 Numeri casuali (`random`) 135
16.2 Numeri casuali (`numpy`) 135
16.2.1 Creazione del generatore 136
16.3 Variabili casuali (`scipy.stats`) 136
16.3.1 Funzioni e parametri principali 136
16.3.2 Uso interattivo rapido 138
16.3.3 Freezing di una distribuzione 138
16.3.4 Uso del generatore di `numpy` 138
16.4 Altri argomenti 138
16.4.1 Bootstrap CI 138

Importiamo le librerie qui usate

```
>>> import itertools
>>> import math
>>> import numpy as np
>>> import pandas as pd
>>> import scipy
>>> from scipy import stats
```

16.1 Funzionalità native

16.1.1 Combinatoria

Fattoriale

```
>>> math.factorial(4)
24
```

Coefficiente binomiale

```
>>> n = 4
>>> k = 2
>>> math.comb(n, k)
6
```

Permutazioni di un vettore

```
>>> data = [1,2,3]
>>> list(itertools.permutations(data))
[(1, 2, 3), (1, 3, 2), (2, 1, 3), (2, 3, 1), (3, 1, 2), (3, 2, 1)]
```

Combinazioni di elementi di un vettore

```
>>> list(itertools.combinations(data, 2))
[(1, 2), (1, 3), (2, 3)]
```

Prodotto cartesiano

```
>>> a = [1,2,3]
>>> b = [4,5,6]
>>> list(itertools.product(a,b)) # eventualmente posto in np.array
[(1, 4), (1, 5), (1, 6), (2, 4), (2, 5), (2, 6), (3, 4), (3, 5), (3, 6)]
```

16.1.2 Numeri casuali (`random`)

Per inizializzare il seed

```
>>> import random

>>> random.seed()      # se omesso viene utilizzato il system time (risultati cambiano
>>> random.seed(1983) # se specificato viene utilizzato, assicurando reproducibilita
```

Alcune funzionalità del modulo a seguire:

- per l'estrazione di interi

  ```
  >>> # intero tra min e max
  >>> d10 = random.randint(1, 10)
  >>> print(d10)
  2

  >>> # intero casuale da un range
  >>> random.randrange(1, 9, 2) # intero casuale da range(1,9,2) = [1,3,5,7]
  1
  ```

- per numeri casuali semplici

  ```
  >>> # uniforme 0-1
  >>> random.random()
  0.17028345753869512
  ```

- per estrazioni da urne o simili

```
>>> import string
>>> urn = list(string.ascii_lowercase[:10]) # una lista con prime 10 lettere

>>> # un elemento dall'urna
>>> random.choice(urn)
'h'

>>> # k elementi dall'urna, presi CON REIMMISSIONE (eventualmente con pesi)
>>> random.choices(urn, k=10)
['g', 'f', 'f', 'j', 'h', 'e', 'f', 'f', 'g', 'd']

>>> # k elementi SENZA REIMMISSIONE
>>> random.sample(urn, k=8)
['j', 'c', 'i', 'h', 'b', 'e', 'f', 'd']

>>> # shuffle inplace (modifica il dato di partenza)
>>> random.shuffle(urn)
>>> urn
['a', 'f', 'j', 'b', 'd', 'i', 'h', 'c', 'g', 'e']
```

16.2 Numeri casuali (numpy)

Per ottenerli si crea innanzitutto un generatore di numeri casuali (impostando seme e tipologia, volendo) dopodiché si utilizza questo per generare dati.

16.2.1 Creazione del generatore

Alternativamente si può

- utilizzando in **generatore di default**; il tutto è semplificato mediante `default_rng`

```
>>> rng = np.random.default_rng(seed = 6315744)
>>> rv = rng.standard_normal(5) # random vector
>>> rv
array([ 0.02015758,  2.22358201,  0.94127564, -0.75983371, -2.37769907])
>>> rm = rng.standard_normal((2, 3)) # random matrix
>>> rm
array([[ 0.25145986,  0.10362785, -1.26726019],
       [ 0.46240554, -0.14667618, -0.6394399 ]])
```

- **specificare il generatore**: occorre creare un generatore, alimentarlo con un bitgenerator (eg default o Mersenne-Twister) a cui si è fornito il seed impostato: ad esempio per un generatore standard e Mersenne-Twister (utilizzato da R) fatti a mano

```
>>> from numpy.random import Generator, PCG64, MT19937
>>> seed = 2154
>>> std = Generator(PCG64(seed = seed)) # equivalente al default
>>> std.standard_normal(5)
array([ 2.65496506, -0.20262369, -0.85302693, -0.37646063, -0.30786317])
```

Metodo	Descrizione
`integers`	Pesca interi in range
`choice`	Pesca casualmente da un array
`permutation`	Permutazione casuale di una array, restituendo una copia
`shuffle`	Permutazione in place
`random`	Estrazione da uniforme 0-1
`uniform`	Estrazione da uniform con min e max da specificare
`beta`	Estrazione da beta distribution
`binomial`	Estrazioni da binomiale
`multinomial`	Estrazioni da multinomiale
`standard_normal`	Estrazioni da una normale 0, 1
`normal`	Estrazioni da normal (con media/sd da specificare)
`multivariate_normal`	Estrazioni da una normale multivariata
tante altre ...	Vedere documentazione di `numpy.random`

Tabella 16.1: Alcuni metodi per la generazione di numeri casuali in `numpy`

```
>>> mt =  Generator(MT19937(seed = seed))
>>> mt.standard_normal(5)
array([ 0.73327039,  1.19398753, -0.66427529, -0.42821724,  0.7421379 ])
```

Metodi per generatori casuali Una volta creato il generatore, alcuni metodi di interesse per estrarre numeri casuali (o effettuare operazioni con casualità) sono in tabella 16.1 (vedere doc).

```
>>> rng = np.random.default_rng(seed = 6315744)

>>> # interi tra min e max
>>> rng.integers(5, size=20) # 20 estrazioni da 0 a 4 (5 escluso)
array([1, 1, 0, 2, 2, 4, 4, 1, 2, 4, 4, 2, 0, 2, 2, 0, 1, 3, 0, 2])
>>> rng.integers(low = 1, high=10, size = 20, endpoint=True) # endpoint per max inclu
array([ 1,  7,  2,  1,  3,  2,  8,  3,  1,  1,  3,  4,  4,  4,  1,  4,  7,
        4, 10,  2])

>>> # pescare da un array
>>> data = np.arange(10)
>>> rng.choice(data, size=10, replace=True)
array([5, 2, 8, 9, 7, 6, 2, 1, 9, 1])

>>> # permutazioni
>>> rng.permutation(data)  # copia
array([2, 4, 6, 9, 7, 5, 3, 1, 8, 0])
>>> rng.shuffle(data)      # modifica dell'array inplace
>>> data
array([9, 5, 7, 4, 6, 1, 2, 3, 8, 0])

>>> #
```

Famiglia	Funzione	Famiglia	Funzione
Bernoulli	`bernoulli`	Uniforme cont.	`uniform`
Binomiale	`binom`	Esponenziale	`expon`
Geometrica	`geom`	Normale	`norm`
Binomiale neg.	`nbinom`	Gamma	`gamma`
Ipergeometrica	`hypergeom`	Chi-quadrato	`??`
Poisson	`poisson`	Beta	`beta`
Uniforme disc.	`randint`	T di Student	`t`
		F	`??`
		Logistica	`??`
		Lognormale	`??`
		Weibull	`??`
		Pareto	`??`

Tabella 16.2: Funzioni `scipy.stats.*` per variabili casuali in Python

Metodo	Descrizione
`rvs`	generazione di numeri casuali; equivalente di `r*` di R
`pdf`, `pmf`	probability density e mass function; equivalente di `d*` di R
`cdf`	cumulative distribution function; equivalente di `p*` di R
`ppf`	percent point function (inversa di cdf); equivalente di `q*` di R
`sf`	Survival Function (1-CDF)
`isf`	Inverse Survival Function (Inverse of SF)
`stats`	media, varianza, (Fisher's) skew, or (Fisher's) kurtosis
`moment`	non-central moments of the distribution

Tabella 16.3: Metodi variabili casuali `scipy`

16.3 Variabili casuali (`scipy.stats`)

Le funzioni di `numpy.random` servono esclusivamente per la generazione di numeri casuali e applicazioni MonteCarlo-like; se si vuole disporre di più funzioni per quanto riguarda le variabili casuali (paragonabili a quelle di R) occorre utilizzare `scipy.stats`

16.3.1 Funzioni e parametri principali

In `scipy.stats` le variabili casuali di maggiore interesse sono riportate in tabella 16.2, i relativi metodi sono riportati in tabella 16.3.
I parametri di maggior interesse sono `loc` (locazione) e `scale` (dispersione); alcune quantitative anche un parametro `shape`. Nel caso della normale `loc` è la media ed è impostata di default a 0, `scale` la deviazione standard ed è impostata a 1.

16.3.2 Uso interattivo rapido

Un esempio di utilizzo interattivo rapido con normale a seguire. Per facilitare, le funzioni supportano il broadcasting

```
>>> stats.norm.rvs(size = 5) # estrazioni di casuali (come rnorm(5))
```

```
array([-1.04630036,  0.26046563,  0.50120681, -0.18060433,  0.8991495 ])
>>> stats.norm.pdf(0.5)      # densità: come dnorm(0.5)
np.float64(0.3520653267642995)
>>> stats.norm.cdf(1.96)     # cdf: come pnorm(1.96)
np.float64(0.9750021048517795)
>>> stats.norm.ppf(0.5)      # quantile: come qnorm(0.5)
np.float64(0.0)

>>> # esempio con broadcasting
>>> stats.norm.pdf([0.025, 0.5, 0.975])
array([0.39881763, 0.35206533, 0.24801872])
```

16.3.3 Freezing di una distribuzione

Spesso capita di dover lavorare più volte con distribuzioni dai parametri differenti. Onde evitare di dover reinserire i parametri in ogni chiamata possiamo effettuare il freezing di una distribuzione

```
>>> n01 = stats.norm(loc = 0, scale = 1) # mu=0, sd=1 sono i valori di default
>>> n01.rvs(size = 5)
array([ 0.91389223, -0.07349538,  0.54243031,  2.2065792 ,  1.55676202])

>>> n25 = stats.norm(loc = 2, scale = 5) # mu=2, sd=5
>>> n25.rvs(size = 5)
array([ 3.79751329e+00, -9.62066304e-04, -5.51631380e+00,  3.25164557e+00,
       -1.03753238e+01])
```

16.3.4 Uso del generatore di `numpy`

Passiamo il generatore di numeri casuali in `numpy` nel metodo della funzione freezata

```
>>> rng = np.random.default_rng(302132)

>>> n01 = stats.norm()                    # esempio d'uso:
>>> n01.rvs(size = 5, random_state = rng) # usato al momento
array([-0.14191574,  0.42922204, -0.33735776,  0.20712603, -0.9709426 ])
>>> n01.rvs(size = 5, random_state = rng) # dell'estrazione
array([ 0.64705971, -1.05564341,  0.94984921, -0.30577826, -0.61788831])

>>> rng2 = np.random.default_rng(302132)   # riproduzione sequenza
>>> n01.rvs(size = 5, random_state = rng2)
array([-0.14191574,  0.42922204, -0.33735776,  0.20712603, -0.9709426 ])
>>> n01.rvs(size = 5, random_state = rng2)
array([ 0.64705971, -1.05564341,  0.94984921, -0.30577826, -0.61788831])
```

16.4 Altri argomenti

16.4.1 Bootstrap CI

```
>>> from scipy.stats import bootstrap
```

```
>>> rng = np.random.default_rng(6235)
>>> data_gen = stats.norm()
>>> data = data_gen.rvs(100, random_state = rng)

>>> # 95 bca CI of median
>>> res = bootstrap(data = [data],          # ocio qui: "sequence of array-like"
...                 statistic = np.median,
...                 n_resamples = 10000,
...                 random_state = rng)

>>> res.confidence_interval      # ci
ConfidenceInterval(low=np.float64(-0.21318771294834601), high=np.float64(0.17332161369498447))
>>> res.confidence_interval.low  # ci
np.float64(-0.21318771294834601)
>>> res.confidence_interval.high # ci
np.float64(0.17332161369498447)
>>> res.bootstrap_distribution # valori delle stats nei resample
array([-0.08377   ,  0.09051194,  0.08447688, ..., -0.17939695,
       -0.13573812,  0.16842878], shape=(10000,))
```

Capitolo 17

Test statistici

Contents

17.1 Setup 139
17.2 Medie 139
17.2.1 Test t: 1 gruppo vs valore teorico 139
17.2.2 Test t: 2 gruppi indipendenti 139
17.2.3 Anova (2+ gruppi indipendenti) 139
17.2.4 Test t: 2 gruppi appaiati 139
17.2.5 Anova per misure ripetute (2+ gruppi appaiati) . . . 139
17.3 Non parametric 139
17.3.1 Wilcoxon 139
17.3.2 Mann Whitney 139
17.3.3 Kruskal Wallis 140
17.3.4 Friedman test 140
17.4 Proporzioni 140
17.4.1 Test binomiale e CI clopper pearson 140
17.4.2 Test di Fisher 140
17.4.3 Chisquare 140
17.4.4 McNemar 140
17.4.5 Q di Cochrane 140
17.5 Tassi 140
17.5.1 Comparazione 2 tassi 140
17.6 Correlazione 140
17.6.1 Pearson 140
17.6.2 Spearman 140
17.6.3 Tests 141
17.7 Varianze 141
17.7.1 Test di Bartlett 141
17.7.2 Test di Levene 141
17.7.3 Test di Fligner 141
17.8 Sopravvivenza 141
17.8.1 Logrank test 141
17.9 Agreement 141

17.9.1 Cohen's K 141
17.9.2 Fleiss K 141
17.9.3 Lin coefficient 141
17.10Reliability/consistency 142
17.10.1 Cronbach α 142
17.10.2 ICC 142
17.11Multiplicity 142
17.12Test simulativi 142

17.1 Setup

Importiamo le librerie qui usate

```
>>> import numpy as np
>>> import pandas as pd
>>> import pingouin as pg
>>> from scipy import stats
```

17.2 Medie

17.2.1 Test t: 1 gruppo vs valore teorico

```
>>> x = [5.5, 2.4, 6.8, 9.6, 4.2]
>>> stats.ttest_1samp(x, popmean = 4)
TtestResult(statistic=np.float64(1.3973913920955365), pvalue=np.float64(0.23482367964
>>> pg.ttest(x, 4)
               T  dof alternative     p-val         CI95%   cohen-d   BF10     power
T-test  1.397391    4   two-sided  0.234824  [2.32, 9.08]  0.624932  0.766  0.191796
```

17.2.2 Test t: 2 gruppi indipendenti

```
>>> np.random.seed(123)
>>> trt  = np.random.normal(size=18)
>>> ctrl = np.random.normal(size=22)
>>> stats.ttest_ind(trt, ctrl, equal_var = False)
TtestResult(statistic=np.float64(0.62859959726889), pvalue=np.float64(0.5339329415063
>>> pg.ttest(trt, ctrl)
              T        dof alternative     p-val          CI95%   cohen-d   BF10     p
T-test   0.6286  33.040969   two-sided  0.533933  [-0.54, 1.03]  0.203618  0.363  0.09
```

17.2.3 Anova (2+ gruppi indipendenti)

```
>>> df = pg.read_dataset('anova')
>>> df.head()
   Subject   Hair color  Pain threshold
0        1  Light Blond              62
1        2  Light Blond              60
2        3  Light Blond              71
3        4  Light Blond              55
```

```
4        5  Light Blond              48
>>> df["Hair color"].value_counts()
Hair color
Light Blond       5
Dark Blond        5
Dark Brunette     5
Light Brunette    4
Name: count, dtype: int64
>>> # oneway classica
>>> pg.anova(dv='Pain threshold', between='Hair color', data=df, detailed = True)
       Source           SS  DF          MS         F     p-unc       np2
0  Hair color  1360.726316   3  453.575439  6.791407  0.004114  0.575962
1      Within  1001.800000  15   66.786667       NaN       NaN       NaN
>>> chunks = [data["Pain threshold"].values
...           for color, data in df.groupby("Hair color")]
>>> stats.f_oneway(*chunks)
F_onewayResult(statistic=np.float64(6.791407046264094), pvalue=np.float64(0.0041142273330774 1))
>>> # non assumendo numerosità comuni e/o varianza costante
>>> pg.welch_anova(dv='Pain threshold', between='Hair color', data=df)
       Source  ddof1     ddof2         F     p-unc       np2
0  Hair color      3  8.329841  5.890115  0.018813  0.575962
```

17.2.4 Test t: 2 gruppi appaiati

```
>>> pre = [5.5, 2.4, np.nan, 9.6, 4.2]
>>> post = [6.4, 3.4, 6.4, 11., 4.8]
>>> stats.ttest_rel(pre, post, nan_policy="omit")
TtestResult(statistic=np.float64(-5.901869285972221), pvalue=np.float64(0.009712771595911211),
>>> pg.ttest(pre, post, paired=True)
               T  dof alternative     p-val          CI95%   cohen-d   BF10     power
T-test -5.901869    3   two-sided  0.009713  [-1.5, -0.45]  0.306268  7.169  0.072967
```

17.2.5 Anova per misure ripetute (2+ gruppi appaiati)

```
>>> # dataset in formato long
>>> df = pg.read_dataset('rm_anova')
>>> df.head()
   Subject  Gender Region Education  DesireToKill Disgustingness Frighteningness
0        1  Female  North      some          10.0           High             High
1        1  Female  North      some           9.0           High              Low
2        1  Female  North      some           6.0            Low             High
3        1  Female  North      some           6.0            Low              Low
4        2  Female  North   advance          10.0           High             High
>>> pg.rm_anova(dv='DesireToKill', within='Disgustingness',
...             subject='Subject', data=df, detailed=True)
           Source          SS  DF         MS          F     p-unc       ng2  eps
0  Disgustingness   27.485215   1  27.485215  12.043878  0.000793  0.025784  1.0
1           Error  209.952285  92   2.282090        NaN       NaN       NaN  NaN
>>> # dataset in formato wide
>>> df = pg.read_dataset('rm_anova_wide')
>>> df.head()
```

```
   Before  1 week  2 week  3 week
0     4.3     5.3     4.8     6.3
1     3.9     2.3     5.6     4.3
2     4.5     2.6     4.1     NaN
3     5.1     4.2     6.0     6.3
4     3.8     3.6     4.8     6.8
>>> pg.rm_anova(df)
   Source  ddof1  ddof2         F     p-unc       ng2       eps
0  Within      3     24  5.200652  0.006557  0.346392  0.694329
```

17.3 Non parametric

17.3.1 Wilcoxon

```
>>> pre  = np.array([20, 22, 19, 20, 22, 18, 24, 20, 19, 24, 26, 13])
>>> post = np.array([38, 37, 33, 29, 14, 12, 20, 22, 17, 25, 26, 16])
>>> stats.wilcoxon(pre, post)
WilcoxonResult(statistic=np.float64(20.5), pvalue=np.float64(0.2880859375))
>>> pg.wilcoxon(pre, post, correction = False)
          W-val alternative     p-val       RBC      CLES
Wilcoxon   20.5   two-sided  0.288086 -0.378788  0.395833
>>> pg.wilcoxon(pre, post) # con correzione di continuità
          W-val alternative     p-val       RBC      CLES
Wilcoxon   20.5   two-sided  0.288086 -0.378788  0.395833
```

17.3.2 Mann Whitney

```
>>> trt = np.random.uniform(low=0, high=1, size=20)
>>> ctrl = np.random.uniform(low=0.2, high=1.2, size=20)
>>> stats.mannwhitneyu(trt, ctrl, use_continuity=True)
MannwhitneyuResult(statistic=np.float64(149.0), pvalue=np.float64(0.17192970543827346
>>> pg.mwu(trt, ctrl)
     U-val alternative    p-val    RBC    CLES
MWU  149.0   two-sided  0.17193 -0.255  0.3725
```

TODO:
scipy.stats.brunnermunzel

17.3.3 Kruskal Wallis

```
>>> df = pg.read_dataset('anova')
>>> # pingouin
>>> pg.kruskal(data=df, dv='Pain threshold', between='Hair color')
             Source  ddof1         H     p-unc
Kruskal  Hair color      3  10.58863  0.014172
>>> # scipy
>>> stats.kruskal(*chunks)
KruskalResult(statistic=np.float64(10.588630377524138), pvalue=np.float64(0.014171563
```

17.3.4 Friedman test

Tipo un wilcoxon con più colonne di 2

```
>>> # dati da friedman.test in R
>>> df = pd.DataFrame(np.array([5.40, 5.50, 5.55,
...                             5.85, 5.70, 5.75,
...                             5.20, 5.60, 5.50,
...                             5.55, 5.50, 5.40,
...                             5.90, 5.85, 5.70,
...                             5.45, 5.55, 5.60,
...                             5.40, 5.40, 5.35,
...                             5.45, 5.50, 5.35,
...                             5.25, 5.15, 5.00,
...                             5.85, 5.80, 5.70,
...                             5.25, 5.20, 5.10,
...                             5.65, 5.55, 5.45,
...                             5.60, 5.35, 5.45,
...                             5.05, 5.00, 4.95,
...                             5.50, 5.50, 5.40,
...                             5.45, 5.55, 5.50,
...                             5.55, 5.55, 5.35,
...                             5.45, 5.50, 5.55,
...                             5.50, 5.45, 5.25,
...                             5.65, 5.60, 5.40,
...                             5.70, 5.65, 5.55,
...                             6.30, 6.30, 6.25]).reshape(22,3),
...                       columns = ["t0", "t1", "t2"])
>>> stats.friedmanchisquare(df.t0, df.t1, df.t2)
FriedmanchisquareResult(statistic=np.float64(11.142857142857132), pvalue=np.float64(0.003805040
>>> pg.friedman(df)
          Source         W  ddof1          Q     p-unc
Friedman  Within  0.253247      2  11.142857  0.003805
```

17.4 Proporzioni

17.4.1 Test binomiale e CI clopper pearson

```
>>> test = stats.binomtest(3, n=15, p=0.1) #p è la probabilità sotto h0 da rifiutare
>>> test
BinomTestResult(k=3, n=15, alternative='two-sided', statistic=0.2, pvalue=0.18406106910639106)
>>> test.proportion_ci()
ConfidenceInterval(low=0.04331200510583602, high=0.48089113380685317)
```

17.4.2 Test di Fisher

Si ha per le tabelle 2x2

```
>>> # odds ratio (stima) calcolato è diverso da quello di R (vedi doc), p-uguale
>>> tea = np.array([[3, 1], [1, 3]])
>>> stats.fisher_exact(tea)
SignificanceResult(statistic=np.float64(9.0), pvalue=np.float64(0.4857142857142857))
```

TODO:
stats.barnard_exact

17.4.3 Chisquare

Per le tabelle $n \times m$

```
>>> obs = np.array([[10, 10, 20],
...                 [20, 20, 20]])
>>> stats.chi2_contingency(obs)
Chi2ContingencyResult(statistic=np.float64(2.7777777777777777), pvalue=np.float64(0.2
       [18., 18., 24.]]))
>>> data = pg.read_dataset('chi2_independence')
>>> pg.chi2_independence(data, x='sex', y='target')
(target          0           1
sex
0       43.722772   52.277228
1       94.277228  112.722772, target      0     1
sex
0        24.5  71.5
1       113.5  93.5,                 test    lambda       chi2  dof          pval
0           pearson  1.000000  22.717227  1.0  1.876778e-06  0.273814  0.997494
1        cressie-read  0.666667  22.931427  1.0  1.678845e-06  0.275102  0.997663
2      log-likelihood  0.000000  23.557374  1.0  1.212439e-06  0.278832  0.998096
3       freeman-tukey -0.500000  24.219622  1.0  8.595211e-07  0.282724  0.998469
4  mod-log-likelihood -1.000000  25.071078  1.0  5.525544e-07  0.287651  0.998845
5              neyman -2.000000  27.457956  1.0  1.605471e-07  0.301032  0.999481)
```

17.4.4 McNemar

```
>>> data = pg.read_dataset('chi2_mcnemar')
>>> pg.chi2_mcnemar(data, 'treatment_X', 'treatment_Y')
(treatment_Y   0   1
treatment_X
0            20  40
1             8  12,               chi2  dof  p-approx   p-exact
mcnemar  20.020833    1  0.000008  0.000003)
```

17.4.5 Q di Cochrane

Mc nemar per più tempi/trattamenti su stessi soggetti

```
>>> df = pg.read_dataset('cochran')
>>> df.head()
   Subject    Time  Energetic
0        1  Monday          1
1        2  Monday          0
2        3  Monday          0
3        4  Monday          0
4        5  Monday          1
>>> df_wide = df.pivot_table(index="Subject", columns="Time", values="Energetic")
>>> pg.cochran(df_wide)
         Source  dof         Q     p-unc
cochran  Within    2  6.705882  0.034981
```

17.5 Tassi

17.5.1 Comparazione 2 tassi

Il test di poisson di python verifica che la differenza tra tassi sia nulla (quello di R che il rapporto sia unitario)

```
>>> # poisson.test(c(11, 6+8+7), c(800, 1083+1050+878))
>>> stats.poisson_means_test(11, 800, 6+8+7, 1083+1050+878)
SignificanceResult(statistic=np.float64(1.5342150126346437), pvalue=np.float64(0.13862291985862
>>> # i risultati sono diversi ma il manuale di python dice
```

I risultati di questo test sono differenti da quelli di R ma la documentazione di python dice che ha maggior potenza del test poissoniano esatto di R.

17.6 Correlazione

```
>>> # generare dati
>>> mean, cov = [4, 6], [(1, .5), (.5, 1)]
>>> x, y = np.random.multivariate_normal(mean, cov, 30).T
>>> data = {"x": x, "y": y}
>>> df = pd.DataFrame(data)
```

17.6.1 Pearson

```
>>> stats.pearsonr(df.x, df.y)
PearsonRResult(statistic=np.float64(0.42350936826041014), pvalue=np.float64(0.01969785190872100
>>> pg.corr(df.x, df.y)
           n         r         CI95%     p-val   BF10     power
pearson   30  0.423509  [0.07, 0.68]  0.019698  3.041  0.663505
```

17.6.2 Spearman

```
>>> stats.spearmanr(df.x, df.y)
SignificanceResult(statistic=np.float64(0.35973303670745277), pvalue=np.float64(0.0508737485072
>>> pg.corr(df.x, df.y, method="spearman")
            n         r         CI95%     p-val    power
spearman   30  0.359733  [-0.0, 0.64]  0.050874  0.50986
```

17.6.3 Tests

```
>>> pg.rcorr
<function rcorr at 0x7f1433cd5120>
```

17.7 Varianze

Vediamo le funzioni per la comparazione di k varianze sotto diverse ipotesi sempre meno restrittive

17.7.1 Test di Bartlett

Testa parametricamente la differenza di varianze ipotizzando una distribuzione normale del carattere nella popolazione. Se a 2 gruppi è il test F.

```
>>> a = [8.88, 9.12, 9.04, 8.98, 9.00, 9.08, 9.01, 8.85, 9.06, 8.99]
>>> b = [8.88, 8.95, 9.29, 9.44, 9.15, 9.58, 8.36, 9.18, 8.67, 9.05]
>>> c = [8.95, 9.12, 8.95, 8.85, 9.03, 8.84, 9.07, 8.98, 8.86, 8.98]
>>> stats.bartlett(a, b, c)
BartlettResult(statistic=np.float64(22.789434813726768), pvalue=np.float64(1.12547825
```

17.7.2 Test di Levene

Testa parametricamente la differenza di varianze non ipotizzando distribuzioni normali

```
>>> stats.levene(a, b, c)
LeveneResult(statistic=np.float64(7.584952754501659), pvalue=np.float64(0.00243150596
```

17.7.3 Test di Fligner

Equivalente non parametrico

```
>>> stats.fligner(a, b, c)
FlignerResult(statistic=np.float64(10.803687663522238), pvalue=np.float64(0.004508260
```

17.8 Sopravvivenza

Utilizziamo la libreria `lifelines`

17.8.1 Logrank test

```
>>> T1 = [1, 4, 10, 12, 12, 3, 5.4]
>>> E1 = [1, 0, 1,  0,  1,  1, 1]
>>> T2 = [4, 5, 7, 11, 14, 20, 8, 8]
>>> E2 = [1, 1, 1, 1,  1,  1,  1, 1]

>>> from lifelines.statistics import logrank_test
>>> results = logrank_test(T1, T2, event_observed_A=E1, event_observed_B=E2)
>>> results.print_summary()
<lifelines.StatisticalResult: logrank_test>
               t_0 = -1
 null_distribution = chi squared
degrees_of_freedom = 1
         test_name = logrank_test

---
 test_statistic    p  -log2(p)
           0.09 0.77      0.38
>>> # results.p_value, results.test_statistic
```

17.9 Agreement

17.9.1 Cohen's K

```
>>> from statsmodels.stats.inter_rater import cohens_kappa
>>> cohens_kappa
<function cohens_kappa at 0x7f1433b24680>
```

17.9.2 Fleiss K

```
>>> from statsmodels.stats.inter_rater import fleiss_kappa
>>> fleiss_kappa
<function fleiss_kappa at 0x7f1433b24040>
```

17.9.3 Lin coefficient

```
>>> from statsmodels.stats.inter_rater import fleiss_kappa
>>> fleiss_kappa
<function fleiss_kappa at 0x7f1433b24040>
```

17.10 Reliability/consistency

17.10.1 Cronbach α

```
>>> pg.cronbach_alpha
<function cronbach_alpha at 0x7f1433cd6d40>
```

17.10.2 ICC

```
>>> pg.intraclass_corr
<function intraclass_corr at 0x7f1433cd6de0>
```

17.11 Multiplicity

```
scipy.stats.tukey_hsd
scikit_posthocs.posthoc_dunn


statsmodels.stats.multitest.multipletests
scipy.stats.false_discovery_control

pg.multicomp
pg.pairwise_gameshowell
pg.pairwise_tukey
pg.pairwise_tests
pg.pairwise_corr
pg.ptests
```

17.12 Test simulativi

Importiamo le librerie qui usate

```
>>> from scipy import stats

>>> stats.bootstrap
<function bootstrap at 0x7f152ffe9580>
>>> stats.permutation_test
<function permutation_test at 0x7f152ffea660>
>>> stats.monte_carlo_test
<function monte_carlo_test at 0x7f152ffe9800>
```

Capitolo 18

Integrazione con R

Contents

18.1 Interscambio dataset 143
18.1.1 Da R a Python 143
18.1.2 Da Python a R 143
18.2 Chiamare R da Python: `rpy2` 143
18.2.1 Importazione di pacchetti 143
18.2.2 Ottenimento di dati con rpy2 144
18.2.3 Valutare stringhe di R 144
18.2.4 Creazione di vettori 144
18.2.5 Conversione `DataFrame` a R 144
18.2.6 Utilizzo di funzioni 144

18.1 Interscambio dataset

18.1.1 Da R a Python

In generale, per esportare un dataset di R verso Python, importare il dataset in R e usare `lbmisc::pddf`.
Alternativamente, per importare direttamente un dataset R noto in Python si possono importare usare i pacchetti `rdatasets` o `statsmodels`, entrambi usano

```
>>> import statsmodels.api as sm
>>> airquality = sm.datasets.get_rdataset("airquality", "datasets")
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
  File "/home/l/.local/lib/python3.13/site-packages/statsmodels/datasets/utils.py", line 242, i
    doc, _ = _get_data(docs_base_url, dataname, cache, "rst")
             ~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~~
  File "/home/l/.local/lib/python3.13/site-packages/statsmodels/datasets/utils.py", line 166, i
    data, from_cache = _urlopen_cached(url, cache)
                       ~~~~~~~~~~~~~~~~~~~~~~~~~~~
  File "/home/l/.local/lib/python3.13/site-packages/statsmodels/datasets/utils.py", line 157, i
    data = urlopen(url, timeout=3).read()
```

```
          ~~~~~~~~~~~~~~~~~~~~
  File "/usr/lib/python3.13/urllib/request.py", line 189, in urlopen
    return opener.open(url, data, timeout)
           ~~~~~~~~~~~^^^^^^^^^^^^^^^^^^^
  File "/usr/lib/python3.13/urllib/request.py", line 489, in open
    response = self._open(req, data)
  File "/usr/lib/python3.13/urllib/request.py", line 506, in _open
    result = self._call_chain(self.handle_open, protocol, protocol +
                              '_open', req)
  File "/usr/lib/python3.13/urllib/request.py", line 466, in _call_chain
    result = func(*args)
  File "/usr/lib/python3.13/urllib/request.py", line 1367, in https_open
    return self.do_open(http.client.HTTPSConnection, req,
           ~~~~~~~~~~~~^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^^
                        context=self._context)
                        ^^^^^^^^^^^^^^^^^^^^^^
  File "/usr/lib/python3.13/urllib/request.py", line 1323, in do_open
    r = h.getresponse()
  File "/usr/lib/python3.13/http/client.py", line 1459, in getresponse
    response.begin()
    ~~~~~~~~~~~~~~^^
  File "/usr/lib/python3.13/http/client.py", line 336, in begin
    version, status, reason = self._read_status()
                              ~~~~~~~~~~~~~~~~~~^^
  File "/usr/lib/python3.13/http/client.py", line 297, in _read_status
    line = str(self.fp.readline(_MAXLINE + 1), "iso-8859-1")
               ~~~~~~~~~~~~~~~~~~~~~~~~~~~~^^^
  File "/usr/lib/python3.13/socket.py", line 719, in readinto
    return self._sock.recv_into(b)
           ~~~~~~~~~~~~~~~~~~~~^^^
  File "/usr/lib/python3.13/ssl.py", line 1304, in recv_into
    return self.read(nbytes, buffer)
           ~~~~~~~~~~~~~~~~~~~~~~~~^^
  File "/usr/lib/python3.13/ssl.py", line 1138, in read
    return self._sslobj.read(len, buffer)
           ~~~~~~~~~~~~~~~~~~~~~~~~~~~~~^^
TimeoutError: The read operation timed out
>>> df = airquality.data
Traceback (most recent call last):
  File "<stdin>", line 1, in <module>
NameError: name 'airquality' is not defined
>>> df
          x         y
0  5.318795  8.358522
1  4.412340  6.286310
2  5.528292  5.922329
3  3.257367  4.568498
4  2.157919  4.965227
5  4.815540  5.729637
6  5.240592  6.028069
7  2.110286  4.274727
```

```
8   3.637569  4.370217
9   3.254288  6.432150
10  3.774571  6.805685
11  5.620999  6.257528
12  3.861018  5.481841
13  4.432908  4.455020
14  2.084009  6.682313
15  4.004256  6.038398
16  4.775493  4.913518
17  4.433651  4.828241
18  3.748947  6.991816
19  4.386092  6.887341
20  2.983572  5.262313
21  5.353514  7.021039
22  3.315623  3.290577
23  4.514892  5.962784
24  3.521322  6.269538
25  2.741949  4.471717
26  3.046622  5.546362
27  3.871165  5.307241
28  5.413727  6.313684
29  4.494251  6.815937
>>> # print(airquality.__doc__)
```

18.1.2 Da Python a R

Utilizzare `pylbmisc.io.rdf`.

18.2 Chiamare R da Python: `rpy2`

Si installa

```
pip install --user rpy2
```

Quattro moduli principali:

- `rpy2.robjects`: high-level interface. basato su `rpy2.rinterface`
- `rpy2.interactive`: high-level interface basata su rpy2.robjects per l'uso interattivo
- `rpy2.rlike`: funzioni e dati in python che mimano funzionalità di R
- `rpy2.rinterface`: interfaccia di basso livello

Il modulo che ci interessa di più è `robjects`, effettuiamo le seguenti importazioni:

```
>>> import rpy2.robjects as ro                  # tutto il resto ..

>>> from rpy2.robjects import pandas2ri         # traduzione data.frame
>>> from rpy2.robjects.packages import importr # importazione pacchetti
>>> from rpy2.robjects.packages import data     # importazione dati
```

18.2.1 Importazione di pacchetti

```
>>> base = importr('base')
>>> utils = importr('utils')
>>> stats = importr('stats')
>>> lme4 = importr("lme4")
```

18.2.2 Ottenimento di dati con rpy2

Per ottenere `lme4::sleepstudy`

```
>>> sleepstudy = data(lme4).fetch('sleepstudy')['sleepstudy']
>>> print(utils.head(sleepstudy))
  Reaction Days Subject
1    249.6    0     308
2    258.7    1     308
3    250.8    2     308
4    321.4    3     308
5    356.9    4     308
6    414.7    5     308
```

È ancora in formato R, per avere un `DataFrame` pandas se lo vogliamo analizzare in python tocca fare sta roba

```
>>> with (ro.default_converter + pandas2ri.converter).context():
...     df = ro.conversion.get_conversion().rpy2py(sleepstudy)
...
>>> df.head()
   Reaction  Days Subject
1  249.5600   0.0     308
2  258.7047   1.0     308
3  250.8006   2.0     308
4  321.4398   3.0     308
5  356.8519   4.0     308
```

18.2.3 Valutare stringhe di R

`rpy2` esegue R, per accedere al namespace si usa `rpy2.robjects.r` .

```
>>> pi = ro.r['pi']
>>> pi[0]
3.141592653589793

>>> # possiamo scrivere anche codice più complesso
>>> res = ro.r("""
... set.seed(123)
... f <- function(x) mean(rnorm(x))
... f(10)
... """)
>>> res[0]
0.0746256440971619
```

18.2.4 Creazione di vettori

```
>>> ints = ro.IntVector([2, 1, 3])
>>> print(ints)
[1] 2 1 3

>>> floats = ro.FloatVector([1.1, 2.2, 3.3])
```

18.2.5 Conversione DataFrame a R

Se vogliamo applicare funzioni di R questo è il modo di procedere; si usa `rpy2.robjects.pandas2ri` con sintassi speculare a quanto già visto (si usa `py2rpy` invece di `rpy2py`:

```
>>> import pandas as pd
>>> df = pd.DataFrame({'int1': [1,2,3], 'int2': [4, 5, 6]})

>>> with (ro.default_converter + pandas2ri.converter).context():
...   r_df = ro.conversion.get_conversion().py2rpy(df)
...
```

18.2.6 Utilizzo di funzioni

```
>>> # applicazione di una funzione
>>> res1 = base.sort(ints)
>>> print(res1)
[1] 1 2 3

>>> # funzione con parametri
>>> res2 = base.sort(floats, decreasing=True)
>>> print(res2)
[1] 3.3 2.2 1.1


>>> # utilizzare funzioni r su un dataframe R (ottenuto sopra)
>>> print(base.summary(r_df))
      int1          int2
 Min.   :1.0   Min.   :4.0
 1st Qu.:1.5   1st Qu.:4.5
 Median :2.0   Median :5.0
 Mean   :2.0   Mean   :5.0
 3rd Qu.:2.5   3rd Qu.:5.5
 Max.   :3.0   Max.   :6.0


>>> # svolgimento di una analisi
>>> lm1 = stats.lm('Reaction ~ Days', data = sleepstudy)
>>> # print(base.summary(lm1)) #verbose output
>>> fm1 = lme4.lmer('Reaction ~ Days + (Days | Subject)', data = sleepstudy)
>>> # print(base.summary(fm1))  #verbose output
```

Capitolo 19

Misc cookbook

Contents

19.1 Tabella trial 145
19.2 Validazione DataFrame con pandera 145
19.3 SymPy 145
19.4 Esecuzione parallela 146
19.5 Calendario 146
19.6 Tcl/Tk 146
19.7 Telegram 146

19.1 Tabella trial

Utilizzare la libreria `tableone`.

```
tab1_df = tableone.load_dataset('pn2012')
tab1_df.info()
tab1_df.head()
ft = {0: "alive", 1: "dead"}
tab1_df["group"] = pd.Categorical(tab1_df.death.map(ft))
select = ['Age', 'SysABP', 'Height', 'Weight', 'ICU', 'group']
categ = ['ICU', 'group']
groupby = 'group'
nonnormal = ['Age']
labels={'death': 'mortality'}
tab1 = tableone.TableOne(tab1_df,
                         columns=select,
                         categorical=categ,
                         groupby=groupby,
                         nonnormal=nonnormal,
                         rename=labels, #renaming variabili di riga
                         missing=True, # conta dei missing
                         include_null=False, # evita i missing nelle var categoriche
                         pval=False)

tab1
```

19.2 Validazione `DataFrame` con `pandera`

`pandera` permette di definire descrizioni del dataset che vogliamo avere e validare quello che effettivamente abbiamo. Vi sono due api attualmente, una classica e una più simile a `dataclass`/`pydantic`. Usiamo questa seconda.

```
>>> import pandera as pa
```

Iniziamo con un dataset di esempio dove è necessario fare preprocessing e validare

```
>>> # Uno schema più evoluto su dati più real-life
>>> df = pd.DataFrame({
...     "idx" :   [1,2,3,4,5,6],
...     "adate": ["2020-01-02", "2021-01-01", "2022-01-02"] * 2,
...     "state": ["Ohio", "Ohio", "Ohio", "Nevada", "Nevada", "Nevada"],
...     "ohio" : [1, 1, 1, 0, 0, 0],
...     "year": [str(y) for y in [2000, 2001, 2002, 2001, 2002, 2003]],
...     "pop": [str(p) for p in [1.5, 1.7, 3.6, np.nan, 2.9, 3.2]]
... })
```

Definiamo una classe che descrive le caratteristiche

```
>>> # meglio usare i tipi di dato builtin
>>> class Model(pa.DataFrameModel):
...     idx: int = pa.Field(unique=True)
...     adate: pd.DatetimeTZDtype = pa.Field(dtype_kwargs={
...         "unit": "s",
...         "tz": "UTC"
...     })
...     state: pd.CategoricalDtype = pa.Field(dtype_kwargs={
...         "categories": ["Ohio", "Nevada"],
...         "ordered": False
...     })
...     ohio: bool = pa.Field()
...     year: int = pa.Field(ge=2000, le=2005)
...     pop: float = pa.Field(ge=0, nullable=True)
...     # configurazioni generali: nome Config obbligatorio
...     class Config:
...         coerce = True  # coercizione al tipo specificato, prechecks
...
```

Una volta fatto questo effettuiamo la validazione in un `try`; se va viene salvato in `out` il DataFrame valido, se non va in `errs` gli errori

```
>>> try:
...     out = Model.validate(df, lazy = True)
...     # print(out)
... except pa.errors.SchemaErrors as err:
...     errs = err.failure_cases # dataframe of schema errors
...     # print("Schema errors and failure cases:")
...     # print(errs.to_string())
...     # print("\nDataFrame object that failed validation:")
...     # print(err.data)  # invalid dataframe
...
```

Alcune considerazioni:

- putroppo ad ora `nullable` (ossia accettare dati mancanti) deve essere specificato sempre (issue), al massimo si può usare il partialling con qualcosa del genere

  ```
  >>> from functools import partial
  >>> NullableField = partial(pa.Field, nullable=True)
  >>> StdField = partial(pa.Field, coerce=True, nullable=True)
  ```

- esperimenti con interfaccia classica in `src/tests`
- per funzioni di check custom vedere la documentazione qui

Una procedura di importazione e cleaning La sequenza potrebbe essere:

- importare con qualsivoglia strumento (es `pd.read_csv`);
- coercire quanto di interesse per l'analisi con il metodo `transform` (eventualmente verificare qui l'introduzione di valori mancanti)
- validare quanto coercito mediante pandera eventualmente

19.3 SymPy

Integrazione `integrate` è utilizzato per integrali sia indenfiniti che definiti

1. definire i simboli impiegati
2. definire l'espressione che ne fa uso
3.

```
from sympy import *
init_printing(use_unicode=False, wrap_line=False)
x = Symbol('x')
y = Symbol('y')

# indefinito
integrate(x**2 + x + 1, x)

# definito da 0 a +infinito
expr = exp(-x**2)
integrate(expr,(x,0,oo) )

expr = (3 + x)/(12*6)
integrate(expr,(x, -3, 9) )

# definito usando due variabili
expr=exp(-x**2 - y**2)
integrate(expr,(x,0,oo),(y,0,oo))
```

19.4 Esecuzione parallela

Usiamo `multiprocessing`, che effettua una parallizzazione tipo quella di R a livello di processo e `Pool` che applica una funzione in maniera parallela cambiando il parametro di input.

```
from multiprocessing import Pool

import os
import numpy as np
import time

# a function with no particular setting (note how we don't have to
# define the imports which is automagically handled by the fork

def parallelized(s):
    """A test function which extract 500 random number from standard
    normal and calculates the mean.
    """
    rng = np.random.default_rng(seed = s)
    rv = rng.standard_normal(500) # random vector
    return {"pid" : os.getpid(),
            "seed": s,
            "mean" : rv.mean()}

def main():
    start_t = time.perf_counter()
    # Pool can be used for parallel execution of a function across
    # multiple input values, distributing the input data across processes
    # data parallelism).
    rng_seeds = [1, 1, 3]
    with Pool() as p:  # spawna 1 processo per core (usandoli tutti)
        # apply a function to different input, each in one separate process
        res = p.map(parallelized, rng_seeds)
    stop_t = time.perf_counter()

    os.getpid() # pid of the current process
    print(res)  # pid of working process are different
                # results are the same in the first two cases (same seed)
    print(f"Time elapsed {stop_t - start_t:.2f}")


main()
```

Per

- limitare il numero di processi da spawnare ad esempio fare `Pool(5)`
- i tre metodi principali che pool fornisce sono `map`, `imap` e `imap_unordered`

19.5 Calendario

`calendar` fornisce funzionalità del calendario (utile es per trovare l'x-esimo martedì del mese tal dei tali).

```
>>> import calendar
>>> import pprint
>>> from datetime import date

>>> # Stampare il calendario del mese scelto (es del mese corrente)
>>> oggi = date.today()
>>> c = calendar.TextCalendar()
>>> c.prmonth(oggi.year, oggi.month)
    agosto 2026
lu ma me gi ve sa do
                1  2
 3  4  5  6  7  8  9
10 11 12 13 14 15 16
17 18 19 20 21 22 23
24 25 26 27 28 29 30
31

>>> # ottenere numeri di giorni del mese come lista di liste (ogni lista è una settimana)
>>> m = calendar.monthcalendar(oggi.year, oggi.month)
>>> pprint.pprint(m)
[[0, 0, 0, 0, 0, 1, 2],
 [3, 4, 5, 6, 7, 8, 9],
 [10, 11, 12, 13, 14, 15, 16],
 [17, 18, 19, 20, 21, 22, 23],
 [24, 25, 26, 27, 28, 29, 30],
 [31, 0, 0, 0, 0, 0, 0]]
>>> # la struttura di dati va per ogni settimana da lunedì a domenica
>>> # 0 vuol dire che il giorno non appartiene al mese, altrimenti il numero è
>>> # il progressi

>>> # stampa di tutti i sabato e domenica di un mese con numero di giorno
>>> for week in m:
...     sab = week[calendar.SATURDAY]
...     dom = week[calendar.SUNDAY]
...     if sab: # se è diverso da 0 vi è un sabato in quella settimana
...         print("sab", sab)
...     if dom: # questo dovrebbe essere sempre vero
...         print("dom", dom)
...
sab 1
dom 2
sab 8
dom 9
sab 15
dom 16
sab 22
```

```
dom 23
sab 29
dom 30
```

19.6 Tcl/Tk

```
from pathlib import Path
from tkinter.filedialog import askopenfilename

title = "Select the study protocol file to be imported"
initialdir = "/tmp"
filetypes = [("Formati", ".docx .doc .pdf")]
fpath = Path(
            askopenfilename(title=title, initialdir=initialdir, filetypes=filetypes)
)
```

19.7 Telegram

Un esempio di invio di messaggi di monitoraggio ai termini di un task (backup fatto mediante `rsync`)

```
import asyncio
import datetime as dt
import os
import telegram
from pylbmisc.tg import bot_token, user_id, group_id

# telegram message
async def send_message(start, end):
    diff = end - start
    msg ="""Backup completato. \n Inizio: {0} \n Termine: {1} \n Impiegati (min): {2}
        start.strftime("%d/%m/%Y - %H:%M:%S"),
        end.strftime("%d/%m/%Y - %H:%M:%S"),
        diff.total_seconds()/60
    )
    bot = telegram.Bot(bot_token("winston_lb_bot"))
    async with bot:
        await bot.send_message(text=msg, chat_id=user_id("lucailgarb"))


if __name__ == '__main__':
    os.system("mount usb_backup")
    start = dt.datetime.now()
    os.system("rsync -avru -L --delete doc_ricordi/ usb_backup/doc_ricordi/")
    os.system("umount usb_backup")
    end = dt.datetime.now()
    asyncio.run(send_message(start = start, end = end))
```